پردازش گفتار

از آواشناسی و ویژگی‌های آکوستیکی تا سامانه‌های تبدیل متن به گفتار

نسخهٔ فشرده

دکتر زینب آقاهادی

دانشگاه علم و صنعت ایران

پاییز ۱۴۰۵

Spoken Language Processing

From Phonetics and Acoustic Features to Text-to-Speech Systems

Zeinab Aghahadi

Assistant Professor

School of Computer Engineering

Iran University of Science and Technology (IUST)

Fall 2026

Compact Edition, Draft v0.2 (sessions 1–10)

چکیده

پردازش گفتار شاخه‌ای کاربردی از پردازش سیگنال و هوش مصنوعی است که به تحلیل، درک و تولید گفتار انسان می‌پردازد. این جزوه با معرفی وظایف پایین‌دستی در پردازش زبان، گفتار و بینایی و ترکیب آن‌ها در محصولات واقعی آغاز می‌شود. سپس تصویر کلی علوم زبان و آواشناسی تولیدی را مرور می‌کند و به آواشناسی آکوستیکی می‌رسد: تبدیل فوریه، هارمونیک‌ها، اسپکتروگرام، مدل منبع-فیلتر و فرمنت‌ها. در ادامه، کار عملی با نرم‌افزار Praat و فضای واکه‌ای، ویژگی‌های الهام‌گرفته از شنوایی انسان مانند مقیاس مل و ضرایب MFCC، و ویژگی‌های پروسودیک گفتار بررسی می‌شوند. فصل‌های پایانی به سامانه‌های تبدیل متن به گفتار می‌پردازند: نرمال‌سازی متن، رفع ابهام کلمات هم‌نگاشت، تبدیل نویسه به واج، مدل آکوستیکی و وکودر، و نیز بازنمایی متن با embeddingهای ایستا و زمینه‌مند و افزودن اطلاعات ترتیب به آن‌ها با کدگذاری موقعیت.

کلیدواژه‌ها: پردازش گفتار، آواشناسی، اسپکتروگرام، فرمنت، MFCC، پروسودی، تبدیل متن به گفتار، embedding زمینه‌مند، کدگذاری موقعیت

Abstract

Speech processing is an applied branch of signal processing and artificial intelligence concerned with analysing, understanding and generating human speech. This booklet opens with downstream tasks in language, speech and vision, and shows how they combine into real products. It then reviews the big picture of the language sciences and articulatory phonetics, and moves on to acoustic phonetics: the Fourier transform, harmonics, spectrograms, the source–filter model and formants. Next come hands-on work with Praat and the vowel space, features inspired by human hearing such as the Mel scale and MFCCs, and the prosodic features of speech. The final chapters cover text-to-speech systems: text normalisation, homograph disambiguation, grapheme-to-phoneme conversion, acoustic models and vocoders, and text representation with static and contextual embeddings, together with positional encoding for injecting word order.

Keywords: speech processing, phonetics, spectrogram, formants, MFCC, prosody, text-to-speech, contextual embeddings, positional encoding

دربارهٔ این پیش‌نویس

این نسخهٔ فشردهٔ جزوهٔ درس پردازش گفتار است و بر پایهٔ یادداشت‌های صوتی جلسات و تختهٔ کلاس تهیه شده است. در آن مطالبی که در کلاس بیشتر روی آن‌ها تمرکز شد و برای یادگیری و امتحان مهم‌ترند نگه داشته شده‌اند و توضیح‌های تکراری و فرعی حذف شده‌اند؛ برای جزئیات کامل‌تر به نسخهٔ مفصل جزوه مراجعه کنید. چون درس هنوز ادامه دارد، فقط جلسات اول تا دهم را پوشش می‌دهد. هر جا مطلبی خارج از گفته‌های کلاس اضافه شده باشد، در کادر «محتوای افزوده» آمده است.

راهنمای کادرها:

تعریف

تعریف‌ها و مفاهیم کلیدی درس.

نکتهٔ استاد / امتحان

نکته‌هایی که استاد بر آن‌ها تأکید کرده است، اطلاعات ارزشیابی و امتحان، تمرین‌ها و نکته‌های جانبی کلاس.

اصلاح یا دقت علمی

جاهایی که گفته‌های کلاس یا یادداشت‌ها نیاز به اصلاح یا دقیق‌تر شدن داشته‌اند.

هشدار / خطای رایج

اشتباه‌های رایج و نکته‌هایی که باید با احتیاط به کار بروند.

تمرین و پروژه

تمرین‌ها و فعالیت‌های عملی که در کلاس مطرح شده‌اند.

[محتوای افزوده] مثال یا توضیح

مثال‌های عددی، شکل‌ها و توضیح‌هایی که در کلاس گفته نشده‌اند و برای فهم بهتر اضافه شده‌اند.

فهرست مطالب

۱ **آشنایی با درس و وظایف پایین‌دستی (Downstream Tasks)** ۱

۱.۱ معرفی درس ۱

۲.۱ مفهوم وظیفهٔ پایین‌دستی ۲

۳.۱ وظایف پردازش زبان طبیعی ۳

۴.۱ وظایف پردازش گفتار ۹

۵.۱ وظایف بینایی و ارتباط آن‌ها با درس ۱۱

۶.۱ ساخت محصول با ترکیب وظایف ۱۱

۷.۱ جدول جمع‌بندی وظایف ۱۴

۸.۱ جمع‌بندی ۱۴

۲ **تصویر کلی علوم زبان و آواشناسی تولیدی** ۱۵

۱.۲ مرور جلسهٔ قبل و تغییر رویکرد ۱۵

۲.۲ تصویر کلی: جایگاه پردازش گفتار در علوم زبان ۱۶

۳.۲ نظریهٔ زایشی چامسکی (۱۹۵۷) ۱۶

۴.۲ ورود به آواشناسی ۱۷

۵.۲ آناتومی تولید گفتار ۱۸

۶.۲ حنجره و تارهای صوتی ۱۹

۷.۲ زنجیرهٔ گفتار ۲۱

۸.۲ واج، همخوان، واکه و هجا ۲۲

۹.۲ واکه‌ها و نقشهٔ جایگاه زبان ۲۲

۱۰.۲ همخوان‌ها و ویژگی‌های تولیدی آن‌ها ۲۳

۱۱.۲ کاربرد آواشناسی در هوش مصنوعی ۲۵

۱۲.۲ جمع‌بندی ۲۷

۳ آواشناسی آکوستیکی: موج صوتی، طیف، اسپکتروگرام و مدل منبع-فیلتر ۲۹

۱.۳ توضیحات کلاس دربارهٔ ارزشیابی ۲۹
۲.۳ مرور جلسهٔ قبل و طرح مسئله ۲۹
۳.۳ موج صوتی، فرکانس پایه و زیر و بمی ۳۰
۴.۳ تحلیل فرکانسی و تبدیل فوریه ۳۱
۵.۳ هارمونیک‌ها ۳۲
۶.۳ اسپکتروگرام ۳۲
۷.۳ مدل منبع-فیلتر ۳۳
۸.۳ فرمنت‌ها ۳۵
۹.۳ اسپکتروگرام باند باریک و باند پهن ۳۷
۱۰.۳ پرسش و پاسخ ۳۹
۱۱.۳ کاربردهای اسپکتروگرام و تمرین ۳۹
۱۲.۳ جمع‌بندی ۳۹

۴ فرمنت‌ها، نرم‌افزار Praat و فضای واکه‌ای ۴۱

۱.۴ مرور کوتاه: از فرکانس پایه تا فرمنت ۴۱
۲.۴ نگاشت ویژگی‌های آکوستیکی به ویژگی‌های تولیدی ۴۲
۳.۴ کار عملی با Praat ۴۳
۴.۴ ساخت پیکرهٔ گفتاری برای یک جامعهٔ آماری خاص ۴۴
۵.۴ فضای واکه‌ای ۴۵
۶.۴ همخوان‌ها در اسپکتروگرام ۴۹
۷.۴ کاربردهای فضای واکه‌ای ۴۹
۸.۴ جمع‌بندی ۵۱

۵ ادراک شنیداری، مقیاس مل و ضرایب MFCC ۵۳

۱.۵ چرا باید ادراک شنیداری انسان را در نظر بگیریم؟ ۵۳
۲.۵ نقشهٔ تونوتوپیک حلزون گوش ۵۴
۳.۵ مرور سه ویژگی Pitch، Formant و Intensity در Praat ۵۵

۴.۵ کم‌شنوایی فرکانس‌های بالا با افزایش سن . . . ۵۵
۵.۵ مقیاس مل . . . ۵۶
۶.۵ بانک فیلتر مل . . . ۵۷
۷.۵ ادراک غیرخطی بلندی صدا و لگاریتم . . . ۵۹
۸.۵ افزونگی ویژگی‌ها و تبدیل کسینوسی گسسته . . . ۵۹
۹.۵ کپستروم و روایت تاریخی تحلیل کپسترال . . . ۶۰
۱۰.۵ مسیر کامل استخراج MFCC . . . ۶۱
۱۱.۵ کاربردهای MFCC . . . ۶۱
۱۲.۵ MFCC در یادگیری ماشین و یادگیری عمیق . . . ۶۳
۱۳.۵ جمع‌بندی . . . ۶۳

۶ پروسودی و ویژگی‌های زبرزنجیری گفتار ۶۵
۱.۶ مرور کوتاه جلسهٔ قبل . . . ۶۵
۲.۶ پروسودی چیست؟ . . . ۶۶
۳.۶ مؤلفهٔ اول: شدت صدا . . . ۶۸
۴.۶ مؤلفهٔ دوم: فرکانس و زیر و بمی . . . ۷۰
۵.۶ مؤلفهٔ سوم: زمان، ریتم و مکث . . . ۷۱
۶.۶ پروسودی در تبدیل متن به گفتار . . . ۷۲
۷.۶ پژوهش: اطمینان و صداقت ادراک‌شده از روی پروسودی . . . ۷۳
۸.۶ کاربردهای عملی تحلیل پروسودی . . . ۷۵
۹.۶ جمع‌بندی . . . ۷۵

۷ تبدیل متن به گفتار: مسئله و معماری خط‌لولهٔ TTS ۷۷
۱.۷ از تحلیل گفتار تا تولید گفتار . . . ۷۷
۲.۷ دو رویکرد کلی: خط‌لوله و سرتاسری . . . ۷۷
۳.۷ معماری کلی یک سامانهٔ TTS . . . ۷۸
۴.۷ مرحلهٔ اول: نرمال‌سازی متن . . . ۷۹
۵.۷ مرحلهٔ دوم: رفع ابهام هم‌نویسه‌ها . . . ۸۱
۶.۷ تبدیل نویسه به واج (G2P) . . . ۸۳
۷.۷ مرحلهٔ دوم سامانه: تولید گفتار از روی واج‌ها . . . ۸۴

۸.۷ مدل آکوستیکی ۸۵
۹.۷ وکودر: از طیف‌نگار به موج ۸۶
۱۰.۷ جمع‌بندی خط‌لولهٔ TTS ۸۷
۱۱.۷ جمع‌بندی ۸۸

۸ بازنمایی متن در TTS: از One-Hot تا بازنمایی وابسته به بافت ۸۹
۱.۸ مروری بر معماری سامانه‌های تبدیل متن به گفتار ۸۹
۲.۸ بازنمایی متن برای شبکه‌های عصبی ۹۰
۳.۸ مروری بر مبانی شبکه‌های عصبی ۹۲
۴.۸ مسئلهٔ هم‌نویسه در TTS ۹۵
۵.۸ Embedding ایستا و Word2Vec ۹۵
۶.۸ محدودیت Embedding ایستا در تشخیص هم‌نویسه ۹۷
۷.۸ چرا همهٔ تلفظ‌ها را از ابتدا برچسب نمی‌زنیم؟ ۹۷
۸.۸ Embedding وابسته به بافت (پویا) ۹۸
۹.۸ استفاده از Attention برای ساخت Embedding وابسته به بافت ۹۸
۱۰.۸ پرسش و پاسخ پایان کلاس و ادامهٔ بحث ۹۹
۱۱.۸ جمع‌بندی ۹۹

۹ آموزش شبکه، Embedding بافتی و تبدیل نویسه به واج ۱۰۱
۱.۹ مرور فرایند آموزش شبکهٔ عصبی ۱۰۱
۲.۹ آموزش در برابر استنتاج ۱۰۲
۳.۹ تعمیم‌پذیری: کم‌برازش، بیش‌برازش و پیچیدگی مدل ۱۰۳
۴.۹ Embedding ایستا و پویا (بافتی) ۱۰۵
۵.۹ راه‌های ساخت Embedding بافتی ۱۰۶
۶.۹ یادگیری خودنظارتی و BERT ۱۰۶
۷.۹ قیاس برداری (Analogy) در فضای Embedding ۱۰۸
۸.۹ کاوش (Probing) و تفسیرپذیری ۱۰۸
۹.۹ بازگشت به TTS: تلفظ درست هر واژه ۱۰۹
۱۰.۹ واژه‌های ناشناخته و G2P از نوع Sequence-to-Sequence ۱۱۱
۱۱.۹ ملاحظات مهندسی G2P و بحث پایانی ۱۱۲

۱۲.۹ جمع‌بندی ۱۱۲

۱۰ کدگذاری موقعیت ۱۱۳

۱.۱۰ جایگاه این بحث در درس ۱۱۳

۲.۱۰ مسئلهٔ ترتیب در Attention ۱۱۳

۳.۱۰ آیا مدل‌های بازگشتی هم به کدگذاری موقعیت نیاز دارند؟ ۱۱۵

۴.۱۰ سه پرسش طراحی ۱۱۵

۵.۱۰ روش اول: کدگذاری موقعیت یادگرفتنی ۱۱۶

۶.۱۰ روش دوم: کدگذاری موقعیت ثابت (فرمولی) ۱۱۷

۷.۱۰ مقایسهٔ دو روش ۱۱۹

۸.۱۰ سؤال مفهومی مهم استاد: دادهٔ آموزشی کوتاه ۱۱۹

۹.۱۰ کدگذاری موقعیت به توالی وابسته است، نه به «جمله» ۱۲۰

۱۰.۱۰ طول زمینه (Context Length) ۱۲۰

۱۱.۱۰ مثال عددی کامل: Attention در رمزگشا ۱۲۰

۱۲.۱۰ جمع‌بندی ۱۲۲

فصل ۱

آشنایی با درس و وظایف پایین‌دستی (Downstream Tasks)

۱.۱ معرفی درس

۱.۱.۱ درس پردازش گفتار در برابر DSP

درس «پردازش گفتار» با «پردازش سیگنال دیجیتال» (DSP) تفاوت اساسی دارد: DSP حوزه‌ای بنیادی و ریاضیاتی است (رادار، مخابرات، تبدیل فوریه، ...)، اما پردازش گفتار شاخه‌ای کاربردی و مبتنی بر هوش مصنوعی است که روی گفتار انسان (تحلیل، درک و تولید آن) تمرکز دارد. این درس تکرار DSP نیست و بخش مهمی از آن به مدل‌ها و معماری‌ها اختصاص دارد، نه به ریاضیات پردازش سیگنال.

۲.۱.۱ مرجع، روش تدریس و پیش‌نیازها

- مرجع اصلی: درس CS224S (Spoken Language Processing) استنفورد، نسخهٔ ۲۰۲۵. جلسهٔ اول برای ساختن ادبیات مشترک تا حدی خارج از ترتیب سیلابس است.
- تدریس روی تختهٔ دیجیتال Excalidraw انجام می‌شود؛ تصاویر تخته به اشتراک گذاشته می‌شود و کلاس‌ها ضبط می‌شوند.
- آشنایی با یادگیری عمیق، Transformer و Embedding مفید است ولی الزامی نیست؛ هر جا لازم باشد مفهوم توضیح داده می‌شود. بخش‌های ابتدایی (به‌ویژه آواشناسی) با درس‌های رایج یادگیری عمیق تفاوت دارند.
- ارزیابی مستمر است (میان‌ترم، پایان‌ترم، تمرین و پروژه)؛ جزئیات و وزن‌ها اعلام نشد و در جلسهٔ اول تمرینی با مهلت تحویل داده نشد.

مبنای سؤالات امتحانی

مبنای اصلی سؤالات امتحانی، مباحثی است که **روی تختهٔ کلاس** مطرح می‌شود. اسلایدهای استنفورد فقط مرجع تکمیلی‌اند.

کانال‌های درس

استاد: دکتر زینب آقاهادی؛ دستیار آموزشی: آقای روح‌الله ایزدی. اطلاعیه‌ها و تصاویر تخته در گروه «بله» (@slp_iust_aghahadi) قرار می‌گیرد و همهٔ دانشجویان باید عضو شوند.

۳.۱.۱ جایگاه پردازش گفتار در هوش مصنوعی

پس از دوره‌ای که توجه بیشتر روی بینایی ماشین و سپس متن بود، اکنون بسیاری از کاربردهای متنی به بلوغ رسیده‌اند و تعامل طبیعی با سامانه‌ها از راه صوت اهمیت یافته است؛ پس پردازش گفتار ظرفیت بالایی برای محصولات جدید دارد. سه نکتهٔ کلاس:

- **هوش مصنوعی لبه** (Edge AI): اجرای مدل روی دستگاه محلی، بدون پردازش ابری برای هر درخواست. ملاحظات مهم: **تأخیر** (Latency) کم، **دقت** (Accuracy) کافی، منابع محدود و در نتیجه مدل کوچک و سبک، و تفاوت توزیع داده‌های واقعی با داده‌های آموزشی.
- **زبان‌های کم‌منبع** (Low-resource Languages) (از جمله فارسی در بعضی مجموعه‌داده‌ها) با کمبود داده و لهجه روبه‌رو هستند.
- پردازش گفتار «حل‌شده» نیست: مدلی که در مکالمهٔ عمومی عالی است، ممکن است در یک سازمان با واژگان تخصصی یا محدودیت سخت‌افزاری کافی نباشد. مهندس هوش مصنوعی باید مسئله را تعریف، داده جمع‌آوری و دستورالعمل برچسب‌گذاری (Annotation) بنویسد، مدل را سازگار و خطاها را تحلیل کند.

مثال چالشی کلاس

دستیار صوتی در محیطی است که هم کاربر صحبت می‌کند و هم رادیو روشن است؛ سیستم باید تشخیص دهد کدام گفتار خطاب به دستیار بوده است. تبدیل صوت به متن به‌تنهایی کافی نیست (ایده‌های مرتبط: تشخیص کلمهٔ فعال‌ساز و بازشناسی گوینده، در ادامهٔ فصل).

۲.۱ مفهوم وظیفهٔ پایین‌دستی

۱.۲.۱ سه خانواده‌وظایف

وظایف پایین‌دستی (Downstream Tasks) در سه خانواده بررسی شدند: **وظایف زبانی** (Language Tasks) (متن)، **وظایف گفتاری** (Speech/Voice Tasks) (صوت) و **وظایف بینایی** (Vision Tasks) (تصویر و ویدئو). هنگام طراحی محصول ابتدا نیازمندی‌ها بررسی و سپس وظایف و مدل‌های لازم مشخص می‌شوند؛ مثلاً در دستیار صوتی: تشخیص گفتار، تشخیص قصد، استخراج اطلاعات و تولید پاسخ صوتی، که هر کدام یک وظیفهٔ مستقل است.

وظیفهٔ پایین‌دستی

یک مسئلهٔ مشخص و کاربردی با ورودی و خروجی تعریف‌شده (مثل ترجمه، تشخیص گفتار یا تشخیص قصد) که یک مدل یا ماژول حل می‌کند و می‌تواند جزئی از یک محصول بزرگ‌تر باشد. استاد تأکید کرد دانشجو باید با شنیدن نام یک وظیفه بتواند **ورودی، خروجی و نوع مسئلهٔ** آن را بگوید.

۲.۲.۱ دو رویکرد طراحی: سرتاسری و خط لوله

- **سرتاسری** (End-to-End): یک مدل یکپارچه ورودی را مستقیماً به خروجی نهایی تبدیل می‌کند و اجزای آن مشترکاً بهینه می‌شوند.
- **خط لوله** (Pipeline): چند ماژول مستقل پشت سر هم‌اند و خروجی هر ماژول ورودی بعدی است؛ مثلاً مترجم صوتی: Speech → Speech-to-Text → Translation → Text-to-Speech.

جدول ۱.۱: مقایسهٔ رویکرد سرتاسری و خط لوله

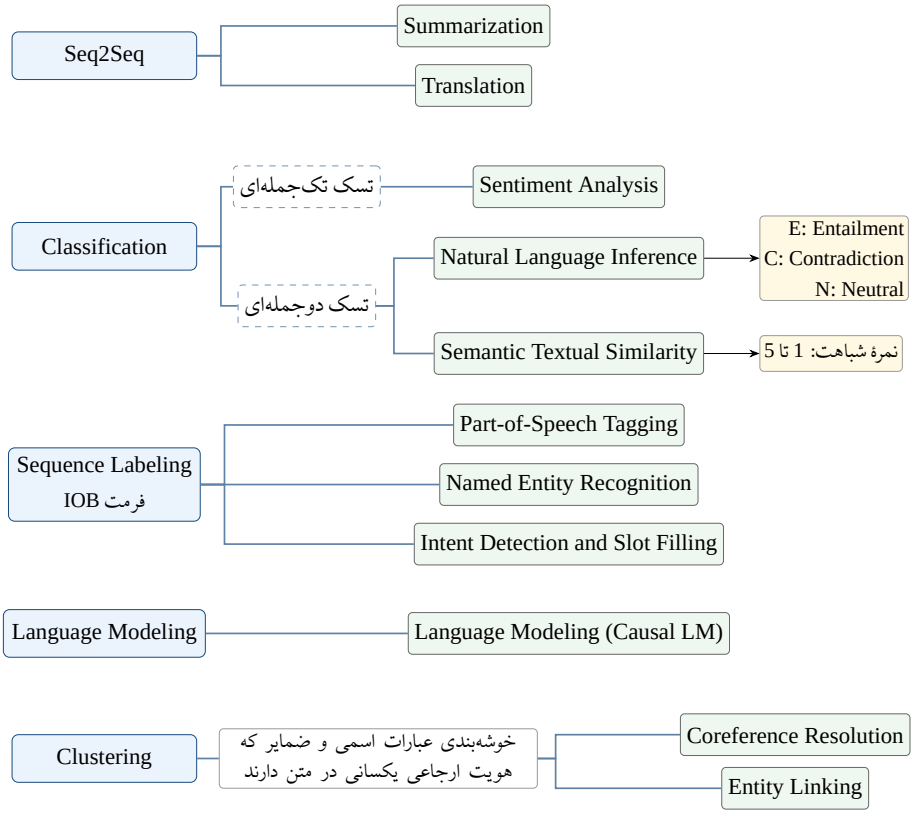
معیار	سرتاسری	خط لوله
دقت	بهینه‌سازی یکپارچه برای هدف نهایی	وابسته به دقت هر مرحله
انتشار خطا	آموزش مشترک می‌تواند آن را کاهش دهد	خطای مراحل اولیه به مراحل بعد منتقل می‌شود
استفادهٔ مجدد	معمولاً تخصصی برای یک هدف	استفاده از ماژول‌های موجود (مثلاً OCR)
تفسیرپذیری	یافتن منشأ خطا دشوارتر است	عیب‌یابی هر مرحله ساده‌تر است
هزینهٔ توسعه	معمولاً داده و آموزش اختصاصی بیشتر	استفاده از مدل‌های آماده ممکن است

نکتهٔ استاد

هیچ‌یک از دو رویکرد در همهٔ مسائل برتری قطعی ندارد؛ انتخاب به نوع مسئله، دقت، هزینه و محدودیت‌ها بستگی دارد. آشنایی با وظایف پایین‌دستی حتی هنگام استفاده از مدل‌های سرتاسری برای طراحی و تحلیل سامانه‌ها ضروری است.

۳.۱ وظایف پردازش زبان طبیعی

استاد وظایف زبانی را بر اساس شکل ورودی و خروجی دسته‌بندی کرد (شکل ۱.۱): تبدیل توالی به توالی، طبقه‌بندی (تک‌جمله‌ای و دوجمله‌ای)، برچسب‌گذاری توالی، مدل‌سازی زبان و خوشه‌بندی. منبع پیشنهادی برای آشنایی با وظایف و مجموعه‌داده‌ها: وب‌سایت NLP Progress.



شکل ۱.۱: دسته‌بندی وظایف زبانی بر اساس شکل ورودی و خروجی: تبدیل توالی به توالی، طبقه‌بندی (تک‌جمله‌ای و دوجمله‌ای)، برچسب‌گذاری توالی، مدل‌سازی زبان و خوشه‌بندی. برای NLI سه کلاس و برای STS نمره‌ای از ۱ تا ۵ در نظر گرفته می‌شود. (بازسازی‌شده از تختهٔ کلاس)

۱.۳.۱ تبدیل توالی به توالی (Seq2Seq)

در **خلاصه‌سازی** (Text Summarization) ورودی متن و خروجی نسخهٔ کوتاه‌تر آن است؛ در **ترجمهٔ ماشینی** (Machine Translation) ورودی متن زبان مبدأ و خروجی متن زبان مقصد است. در هر دو ورودی و خروجی توالی متنی‌اند. معماری پایه برای این وظایف Encoder-Decoder است: Encoder ورودی را به بازنمایی تبدیل می‌کند و Decoder از روی آن خروجی را می‌سازد.

۲.۳.۱ طبقه‌بندی (Classification)

خروجی یکی از کلاس‌های از پیش‌تعریف‌شده است. استاد آن را به وظایف «تک‌جمله‌ای» و «دوجمله‌ای» تقسیم کرد.

تحلیل احساسات (Sentiment Analysis). تک‌جمله‌ای؛ مدل جهت‌گیری متن را تعیین می‌کند. تعداد کلاس‌ها به تعریف مسئله بستگی دارد (مثلاً مثبت/منفی/خنثی یا پنج‌کلاسه از Strong Negative تا Strong Positive).

استنتاج زبان طبیعی (NLI)

Natural Language Inference وظیفه‌ای دوجمله‌ای است. استاد تأکید کرد نام وظایف در NLP معنای قراردادی دارد و فهم معنای لغوی نام کافی نیست. به مدل یک **مقدمه** (Premise) و یک **فرضیه** (Hypothesis) داده می‌شود و باید رابطهٔ آن‌ها را در یکی از سه کلاس قرار دهد:

جدول ۲.۱: سه کلاس NLI

کلاس	مفهوم
Entailment (استلزام)	فرضیه از مقدمه قابل نتیجه‌گیری است.
Contradiction (تناقض)	فرضیه با مقدمه تناقض دارد.
Neutral (خنثی)	از مقدمه نمی‌توان درستی یا نادرستی فرضیه را نتیجه گرفت.

مثال کلاس. مقدمه: «سامانهٔ راداری یک پهپاد ناشناس را شناسایی کرده است؛ به واحد پدافند ابلاغ شده که تا زمان شناسایی قطعی توسط گشت، از شلیک خودداری کند.» فرضیهٔ «واحد پدافند در حال حاضر دستور عدم درگیری را اجرا می‌کند» (Entailment)؛ «دستور دارد بلافاصله هر شیء متحرک را با آتش سنگین منهدم کند» (Contradiction)؛ «پهپاد حامل محموله غیرمجاز است» (Neutral، چون مقدمه دربارهٔ محموله چیزی نمی‌گوید).

برچسب فرضیهٔ اول وابسته به دستورالعمل برچسب‌گذاری است

از نظر منطقی سخت‌گیرانه، «دستور خودداری از شلیک داشتن» لزوماً به معنای «در حال اجرای دستور بودن» نیست و در بسیاری از دستورالعمل‌ها می‌تواند Neutral یا استلزام ضعیف تلقی شود. برچسب بالا مطابق بیان استاد حفظ شده و نشان می‌دهد تعریف دقیق دستورالعمل چقدر مهم است.

شباهت معنایی متون (STS)

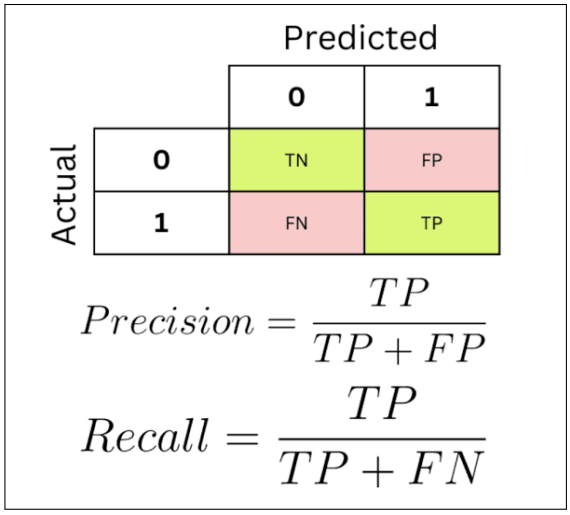
Semantic Textual Similarity نیز دوجمله‌ای است: ورودی دو متن و خروجی امتیاز شباهت معنایی (نه واژگانی). در مثال کلاس امتیاز بین ۱ تا ۵ بود. اگر خروجی فقط مقادیر گسستهٔ ۱ تا ۵ باشد و هر عدد یک کلاس تلقی شود، مسئله **طبقه‌بندی** (Classification) است؛ اگر مقادیر پیوسته مانند ۲٫۵ یا ۳٫۷ را بپذیرد، **رگرسیون** (Regression) است. پس نوع مسئله به نحوهٔ تعریف برچسب‌های مجموعه‌داده بستگی دارد.

بازه‌نمرهٔ STS

بازهٔ ۱ تا ۵ مثال کلاس است؛ در STS Benchmark نمره پیوسته در بازهٔ ۰ تا ۵ و مدل‌سازی معمولاً رگرسیون است.

۳.۳.۱ ارزیابی طبقه‌بندی: ماتریس درهم‌ریختگی و معیارها

در طبقه‌بندی دودویی هر پیش‌بینی یکی از چهار حالت است (شکل ۲.۱): **مثبت درست** (True Positive, TP)، **منفی درست** (True Negative, TN)، **مثبت کاذب** (False Positive, FP) (نمونهٔ منفی را به‌اشتباه مثبت دانسته‌ایم) و **منفی کاذب** (False Negative, FN) (نمونهٔ مثبت را به‌اشتباه منفی دانسته‌ایم). در مسائل چندکلاسه هر کلاس را می‌توان جداگانه در برابر بقیه سنجید.



شکل ۲.۱: ماتریس درهم‌ریختگی (ردیف‌ها: برچسب واقعی، ستون‌ها: پیش‌بینی) و فرمول‌های دقت (Precision) و بازیابی (Recall). (برگرفته از تختهٔ کلاس)

معیارهای ارزیابی

$$\text{Precision} = \frac{TP}{TP + FP}, \qquad \text{Recall} = \frac{TP}{TP + FN}, \qquad F_۱ = ۲ \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Precision: از میان آنچه مثبت پیش‌بینی کرده‌ایم، چه کسری واقعاً مثبت است. Recall: از میان مثبت‌های واقعی، چه کسری را پیدا کرده‌ایم. F1 میانگین هارمونیک این دو است.

[محتوای افزوده] مثال عددی: آشکارساز کلمهٔ فعال‌ساز

از ۱۰۰۰ قطعهٔ صوتی، ۶۰ قطعه واقعاً حاوی کلمهٔ فعال‌ساز است و $TP = ۴۰$، $FN = ۲۰$، $FP = ۱۰$، $TN = ۹۳۰$. آنگاه

$$\text{Precision} = \frac{۴۰}{۵۰} = ۰/۸۰, \qquad \text{Recall} = \frac{۴۰}{۶۰} \approx ۰/۶۶۷,$$

$$F_۱ = \frac{۲TP}{۲TP + FP + FN} = \frac{۸۰}{۱۱۰} \approx ۰/۷۲۷.$$

دقت کلی (Accuracy) برابر ۰/۹۷ است، در حالی که یک‌سوم کلمات فعال‌ساز تشخیص داده نشده‌اند؛ پس در داده‌های نامتوازن Accuracy به‌تنهایی گمراه‌کننده است.

استاد دو مثال برای اهمیت نوع خطا زد: در **سامانهٔ دفاعی** مثبت کاذب (شیء بی‌خطر را تهدید دانستن) خطرناک است،

پس Precision مهم است؛ در **غربالگری بیماری** از دست دادن بیمار (منفی کاذب) پیامد جدی دارد، پس Recall مهم است.

نتیجهٔ مهم

معیار ارزیابی را نباید با یک عدد عمومی انتخاب کرد؛ باید با نیازمندی و حساسیت کاربرد هماهنگ باشد. بالا بردن هم‌زمان Precision و Recall دشوار است و میان آن‌ها مصالحه (trade-off) وجود دارد.

۴.۳.۱ برچسب‌گذاری توالی (Sequence Labeling)

ورودی توالی‌ای از توکن‌هاست و برای هر توکن یک برچسب تولید می‌شود (مثال: «هواپیما شنبه از فرودگاه مهرآباد پرواز کرد» با NER: O, B-TIME, O, B-LOC, I-LOC, O, O و POS: Noun, Noun, Prep., Noun, Proper Noun, Noun, Verb؛ مجموعهٔ برچسب‌ها و تقسیم‌بندی فعل مرکب بسته به دستورالعمل می‌تواند فرق کند).

برچسب‌گذاری نقش واژگانی (POS Tagging). دستهٔ دستوری هر کلمه (Noun، Proper Noun، Pronoun، Verb، Adjective، ...) تعیین می‌شود. استاد تأکید کرد POS با نقش نحوی (فاعل، مفعول و ...) فرق دارد: یک اسم خاص در یک جمله فاعل و در جمله‌ای دیگر مفعول است، ولی دستهٔ واژگانی‌اش همچنان «اسم خاص» است.

قالب IOB و NER. شناسایی موجودیت نام‌دار (Named Entity Recognition - NER) موجودیت‌های مهم متن (شخص PER، مکان LOC، سازمان ORG، زمان و ...) را پیدا و دسته‌بندی می‌کند؛ نوع دسته‌ها به نیاز پروژه (هستی‌شناسی یا Ontology) بستگی دارد. مرز عبارت‌های چندکلمه‌ای با قالب IOB مشخص می‌شود: B (شروع عبارت)، I (ادامهٔ عبارت) و O (خارج از هر عبارت). برچسب‌گذاری مواردی مثل «شنبه» یا فعل مرکب «پرواز کرد» باید طبق دستورالعمل مجموعه‌داده باشد و مثال بالا تنها برچسب‌گذاری معتبر نیست. در ارزیابی NER می‌توان از Precision، Recall و F1 استفاده کرد و O حالت «منفی» است.

ارزیابی در سطح موجودیت

در ارزیابی استاندارد NER (مثل seqeval) یک موجودیت فقط وقتی درست است که هم نوع و هم مرز آن کاملاً درست باشد (مثلاً «فرودگاه مهرآباد» با B-LOC و I-LOC). شمارش در سطح توکن، چون بیشتر توکن‌ها O هستند، دقت را گمراه‌کننده بالا می‌برد.

دستورالعمل برچسب‌گذاری (Annotation Guideline). مهندس هوش مصنوعی ممکن است برای طراحی برچسب‌ها از زبان‌شناس کمک بگیرد. مراحل: تعیین هدف پروژه، تعریف مجموعهٔ برچسب‌ها (Tag Set)، تدوین دستورالعمل، آموزش برچسب‌گذاران، برچسب‌گذاری و بررسی سازگاری و کیفیت. همین دستورالعمل می‌تواند مبنای Prompt برچسب‌گذاری با مدل‌های زبانی هم باشد؛ پس طراحی مجموعه‌داده فقط انتخاب مدل نیست و تعریف دقیق برچسب‌ها اهمیت دارد.

۵.۳.۱ تشخیص قصد و پر کردن جایگاه‌ها (Intent Detection and Slot Filling)

این دو وظیفه در دستیارهای صوتی با هم به‌کار می‌روند.

قصد و جایگاه

قصد (Intent): هدف کاربر از کل جمله؛ طبقه‌بندی در سطح جمله. **جایگاه** (Slot): پارامترهای لازم برای اجرای آن هدف (مثلاً در قصد «خرید بلیت»: مبدأ، مقصد، ساعت)؛ معمولاً به‌صورت برچسب‌گذاری توالی با قالب IOB مدل می‌شود.

مثال کلاس. جملهٔ «دو تا چلوکباب از تهیه‌غذای فارسی به آدرس خودم» با قصد OrderFood: «چلوکباب» غذا (B-FOOD)، «تهیه‌غذای فارسی» رستوران (B-REST، I-REST، I-REST)، «آدرس خودم» آدرس تحویل (B-ADDR، I-ADDR) و بقیه O. اگر تعداد غذا هم مهم باشد، می‌توان جایگاه Quantity را اضافه کرد؛ پس برچسب‌گذاری به طرح داده (Data Schema) و نیازمندی‌ها وابسته است.

اگر جایگاه‌های لازم ناقص باشند، سیستم می‌تواند وارد گفت‌وگو شود و آن‌ها را بپرسد.

۶.۳.۱ مدل‌سازی زبان و سه الگوی معماری

در مدل‌سازی زبان علّی (Causal LM) مدل از توکن‌های قبلی، توکن بعدی را پیش‌بینی می‌کند و با تکرار آن متن تولید می‌شود:

$$P(x_t \mid x_1, x_2, \ldots, x_{t-1}).$$

«علّی» است چون مدل فقط به توکن‌های قبلی تکیه می‌کند. سه الگوی معماری Transformer:

- **Encoder-only**: درک ورودی و استخراج بازنمایی؛ مناسب طبقه‌بندی و برچسب‌گذاری.
- **Decoder-only**: تولید خودبازگشتی (autoregressive) توکن‌ها؛ مناسب مدل‌سازی زبان و تولید متن (خانوادهٔ GPT).
- **Encoder-Decoder**: بازنمایی ورودی و تولید خروجی جدید؛ مناسب Seq2Seq مانند ترجمه و خلاصه‌سازی.

Decoder-only به این معنا نیست که مدل ورودی را نمی‌فهمد؛ فقط Encoder مجزا ندارد و لایه‌هایش خود ورودی (Prompt) را پردازش می‌کنند. جزئیات Transformer در جلسات بعد می‌آید.

نکتهٔ تکمیلی

این تقسیم‌بندی ساده‌شده است: BERT با Masked LM آموزش می‌بیند و مدل‌های Decoder-only با Prompt طبقه‌بندی هم می‌کنند؛ وظایف «مناسب» هر معماری‌اند، نه «منحصر» به آن.

۷.۳.۱ هم‌ارجاعی، پیوند موجودیت و خوشه‌بندی

در **تشخیص هم‌ارجاعی** (Coreference Resolution) ورودی یک سند و خروجی گروه‌هایی از عبارت‌هایی است که به یک موجودیت اشاره دارند؛ مثلاً خوشهٔ ۱: «علی، آقای احمدی، او» و خوشهٔ ۲: «کتاب، این اثر، آن». چون تعداد خوشه‌ها و اعضای آن‌ها از پیش معلوم نیست، از نظر ساختار خروجی به **خوشه‌بندی** (Clustering) شباهت دارد.

تعریف دقیق Entity Linking

در کلاس گفته شد هم‌ارجاعی درون یک سند است و Entity Linking ارتباط اشاره‌ها در اسناد مختلف. این ساده‌سازی است: **پیوند موجودیت** (Entity Linking) یعنی نگاشت هر اشاره (mention) در متن به یک موجودیت مشخص در پایگاه دانش (مثل Wikidata)؛ مثلاً «مهرآباد» به «فرودگاه بین‌المللی مهرآباد». هم‌ارجاعی میان‌اسنادی مسئلهٔ نزدیک ولی جداست.

۴.۱ وظایف پردازش گفتار

تأکید اصلی درس بر وظایف گفتاری است.

۱.۴.۱ بازشناسی خودکار گفتار (ASR)

بازشناسی خودکار گفتار (Automatic Speech Recognition - ASR) یا Speech-to-Text (STT): ورودی سیگنال صوتی و خروجی متن.

- **غیرجریانی (دسته‌ای)** (Non-streaming / Batch): پردازش پس از دریافت بخش کامل گفتار؛ زمینهٔ کامل و معمولاً دقت بهتر، ولی تأخیر بیشتر (پردازش فایل ضبط‌شده).
- **جریانی** (Streaming / Real-time): پردازش هم‌زمان با دریافت صوت؛ تأخیر کمتر ولی زمینهٔ محدودتر و طراحی پیچیده‌تر (تعامل زنده، دستیار صوتی).

قطعه‌بندی (Chunking). مدل جریانی سیگنال را به قطعات کوچک (**چانک** (Chunk)) تقسیم می‌کند. مثلاً هنگام دریافت «چراغ اتاق را خاموش کن» ابتدا فقط «چراغ» و بعد «چراغ اتاق را» در دسترس است و در این مراحل هنوز معلوم نیست قصد روشن کردن است یا خاموش کردن. برای ساخت داده می‌توان به چانک‌ها برچسب Intent جملهٔ کامل داد. **هم‌پوشانی** (Overlap) میان چانک‌ها پیوستگی اطلاعات را حفظ می‌کند؛ طول چانک حداقل تأخیر را تعیین می‌کند و چانک کوچک‌تر یعنی تأخیر کمتر ولی زمینهٔ کمتر.

۲.۴.۱ تبدیل متن به گفتار (TTS)

تبدیل متن به گفتار (Text-to-Speech - TTS) معکوس ASR است: ورودی متن و خروجی سیگنال گفتار. در **TTS جریانی** (Streaming TTS) صوت پیش از آماده شدن کل پاسخ پخش می‌شود، که برای مکالمهٔ بلادرنگ مهم است.

۳.۴.۱ حذف نویز (Noise Suppression)

ورودی صوت نویزی و خروجی نسخهٔ بهبودیافته با همان طول است (گفتار ۱۰ ثانیه‌ای نویزی → سیگنال ۱۰ ثانیه‌ای با نویز کمتر). این وظیفه (Speech Enhancement) معمولاً از مراحل اولیهٔ خط لولهٔ پردازش گفتار است.

۴.۴.۱ تشخیص فعالیت گفتاری و کلمهٔ فعال‌ساز

تشخیص فعالیت گفتاری (Voice Activity Detection - VAD) مشخص می‌کند کدام بازه‌های سیگنال گفتار دارند؛ در ساده‌ترین شکل طبقه‌بندی دودویی (0: گفتار نیست، 1: هست). **تشخیص کلمهٔ فعال‌ساز** (Wake Word Detection) شناسایی عبارتی مشخص (مثلاً «سلام») برای فعال‌سازی سیستم است. روی تخته: تا زمانی که کلمهٔ بیدارباش شنیده نشود، مدل‌های سنگین (ASR، Intent Detection و LLM) روشن نمی‌شوند. کاربرد مشترک هر دو، صرفه‌جویی در منابع است؛ خط لوله:

$$\text{Audio} \rightarrow \text{Noise Suppression} \rightarrow \text{VAD} \rightarrow \text{Speech Processing}.$$

تفاوت: VAD وجود هر گفتاری را تشخیص می‌دهد و به محتوا وابسته نیست، ولی Wake Word فقط یک عبارت مشخص را برای فعال‌سازی دستیار تشخیص می‌دهد.

۵.۴.۱ تشخیص مستقیم قصد از گفتار (Speech-to-Intent)

ورودی گفتار و خروجی برچسب قصد است، بدون اینکه تبدیل صوت به متن مرحلهٔ مستقلی باشد (در برابر Speech $\rightarrow$ ASR $\rightarrow$ Text $\rightarrow$ Intent Detection). این ماژول می‌تواند در ابتدای سیستم تصمیم‌گیرندهٔ سبک باشد: فرمان «چراغ را خاموش کن» مستقیماً اجرا می‌شود و نیازی به فعال کردن مدل زبانی بزرگ نیست؛ برای Edge AI مفید است.

۶.۴.۱ بازشناسی و تفکیک گویندگان

بازشناسی گوینده (Speaker Recognition). شناسایی گوینده از روی ویژگی‌های صدا؛ مثال استاد: دستیاری که فقط به دستور افراد مجاز پاسخ می‌دهد، حتی اگر رادیو روشن باشد. روند: ثبت نمونهٔ صدای کاربران مجاز، دریافت صدای جدید، بررسی ویژگی‌های گوینده و ادامهٔ پردازش در صورت تطابق.

تأیید و شناسایی گوینده

بازشناسی گوینده دو حالت دارد: **تأیید گوینده** (Speaker Verification) (آیا این صدا مال همان کسی است که ادعا می‌کند؟ تصمیم دودویی) و **شناسایی گوینده** (Speaker Identification) (این صدا مال کدام‌یک از افراد ثبت‌شده است؟). مثال دستیار صوتی به تأیید نزدیک‌تر است.

تفکیک گویندگان (Speaker Diarization). مشخص می‌کند چه کسی در چه زمانی صحبت کرده است. استاد آن را شبیه Coreference Resolution دانست: بخش‌های صوتی متعلق به یک گوینده در یک گروه قرار می‌گیرند، پس نوعی Clustering است. نمونهٔ خروجی همراه با ASR (مثال کلاس):

مثلاً برای جلسه: «گوینده ۱ (علی)، 00:01: سلام، جلسه شروع شد. | گوینده ۲ (رضا)، 00:03: مدارک کجاست؟ | گوینده ۱ (علی)، 00:05: فرستادم خدمتتون.»

تفاوت: بازشناسی گوینده می‌پرسد «این صدا مال کیست؟» (کاربران از پیش شناخته‌شده؛ کنترل دسترسی)، و Diarization می‌پرسد «چه کسی در چه زمانی صحبت کرده؟» (الزاماً بدون هویت قبلی؛ تحلیل جلسات).

۵.۱ وظایف بینایی و ارتباط آن‌ها با درس

محصولات واقعی ممکن است به تصویر هم نیاز داشته باشند: **مدل‌های بینایی-زبان** (Vision-Language Models - VLM) تصویر (و گاهی ویدئو) و متن را با هم پردازش می‌کنند، و **بازشناسی نوری نویسه** (Optical Character Recognition - OCR) متن را از تصویر (مثلاً کارت شناسایی) استخراج می‌کند تا به مدل‌های NLP برسد؛ معمولاً استفاده از OCR آماده بهتر از ساختن مدل جدید است.

۶.۱ ساخت محصول با ترکیب وظایف

در بخش پایانی استاد چند محصول مطرح کرد و از دانشجویان خواست ماژول‌های لازم را مشخص کنند تا دانش وظایف مستقل به توانایی طراحی سیستم کامل تبدیل شود.

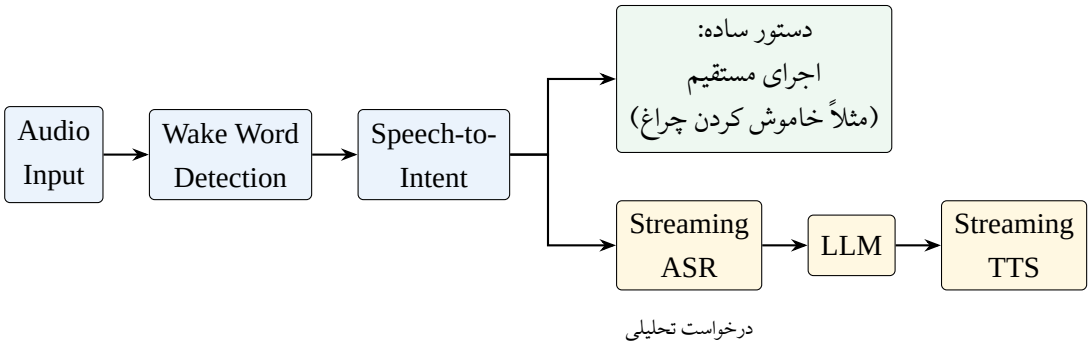
مترجم صوتی. VAD + Streaming STT + Translation + Streaming TTS؛ در ابتدا می‌توان Noise Suppression هم گذاشت. برای مترجم هم‌زمان مکالمه حالت جریانی مهم‌تر است و برای ترجمهٔ فایل ضبط‌شده غیرجریانی کافی است.

احراز هویت آنلاین (e-KYC). کاربر تصویر کارت ملی می‌دهد، تصویر یا ویدئوی چهره می‌گیرد و جمله‌ای مشخص را با صدای بلند می‌گوید. ماژول‌های تخته: OCR + NER + Face Verification + VAD + STT.

- **کارت**: OCR متن کارت را می‌خواند؛ اگر جای فیلدها ثابت نباشد، NER نوع فیلدها (نام، شماره، تاریخ تولد) را تشخیص می‌دهد و نتیجه با سامانهٔ مرجع مقایسه می‌شود.
- **چهره: تأیید چهره** (Face Verification): آیا چهرهٔ کاربر با چهرهٔ روی مدرک مطابقت دارد؟
- **جملهٔ گفته‌شده**: یکی از دانشجویان Speaker Recognition پیشنهاد کرد، اما استاد توضیح داد هدف اینجا الزاماً تشخیص هویت گوینده نیست، بلکه بررسی این است که کاربر جملهٔ خواسته‌شده را گفته است؛ پس Speech → ASR → Text Comparison. به بررسی هماهنگی لب و گفتار (Lip Sync) هم اشاره شد.

خلاصه‌ساز جلسات. با ASR و Summarization معلوم نیست هر جمله را چه کسی گفته است؛ راه‌حل استاد: Diarization + STT + Summarization، که علاوه بر محتوا، نسبت گفتار به گویندگان را هم می‌دهد.

دستیار صوتی هوشمند. دستیار باید هم فرمان‌های ساده (روشن و خاموش کردن وسایل) را اجرا کند و هم به پرسش‌های تحلیلی پاسخ دهد. فرستادن همهٔ درخواست‌ها به یک مدل زبانی بزرگ هزینه و مصرف منابع را بالا می‌برد. پیشنهاد استاد: با Speech-to-Intent درخواست‌ها ابتدا تفکیک شوند. ماژول‌ها: Wake Word + Speech-to-Intent + Streaming STT + LLM + Streaming TTS. یادداشت استاد: فرمانی مثل «خاموش کن» باید سریع به یک API وصل شود و کار انجام شود، بدون پاسخ‌گویی اضافه.



شکل ۳.۱: دستیار صوتی با مسیر سبک برای فرمان‌های ساده (بالا) و مسیر سنگین برای پرسش‌های تحلیلی (پایین) (شکل افزوده).

فرمان ساده از مسیر سبک (Speech-to-Intent → اجرا) و پرسش تحلیلی از مسیر سنگین (ASR → LLM → TTS) می‌رود؛ این تفکیک هزینه، تأخیر و مصرف منابع را کم می‌کند.

جدول ۳.۱: وظایف پایین‌دستی معرفی‌شده در جلسه

وظیفه	ورودی	خروجی	نوع مسئله
Summarization / Translation	متن	متن خلاصه / ترجمه‌شده	Seq2Seq
Sentiment Analysis	متن	کلاس احساس	Classification
NLI	دو متن	رابطهٔ معنایی (سه کلاس)	Classification
STS	دو متن	امتیاز شباهت	Regression یا Classification
POS Tagging	توالی توکن‌ها	برچسب هر توکن	Sequence Labeling
NER	متن	موجودیت‌های نام‌دار	Sequence Labeling
Intent Detection	متن	قصد کاربر	Classification
Slot Filling	متن	جایگاه‌های استخراج‌شده	Sequence Labeling
Language Modeling	توکن‌های قبلی	توکن بعدی	Next-token Prediction
Coreference	سند	خوشه‌های هم‌ارجاع	Clustering
ASR	گفتار	متن	Speech-to-Text
TTS	متن	گفتار	Speech Generation
Noise Suppression	صوت نویزی	صوت بهبودیافته	Speech Enhancement
VAD / Wake Word	صوت	بازه‌های گفتار / عبارت فعال‌ساز	Detection
Speech-to-Intent	گفتار	قصد کاربر	Classification
Speaker Recognition	صوت	هویت یا تطابق گوینده	Recognition / Verification
Speaker Diarization	صوت چندگوینده	بازه‌ها و گروه‌های گوینده	Diarization / Clustering
OCR	تصویر	متن	Text Recognition
VLM	تصویر و متن	پاسخ وابسته به وظیفه	Multimodal

۷.۱ جدول جمع‌بندی وظایف

۸.۱ جمع‌بندی

جلسهٔ اول واژگان مشترک درس را ساخت: وظایف پایین‌دستی در سه حوزهٔ زبان، گفتار و بینایی؛ دو رویکرد سرتاسری و خط لوله؛ معیارهای ارزیابی طبقه‌بندی؛ و ترکیب وظایف برای ساخت محصولاتی مانند مترجم صوتی، e-KYC، خلاصه‌ساز جلسات و دستیار صوتی. جلسات بعد از آواشناسی و سیگنال گفتار شروع می‌کنند و به مدل‌ها می‌رسند.

نکات مهم برای مرور و امتحان

- سؤالات امتحانی بر اساس مطالب تخته‌اند؛ برای هر وظیفه ورودی، خروجی و نوع مسئله را بدانید (جدول بالا).
- تفاوت Pipeline و End-to-End از نظر دقت، انتشار خطا، استفادهٔ مجدد، تفسیرپذیری و هزینه.
- تعریف TP/FP/TN/FN، فرمول Precision، Recall، F1 و اینکه کدام در کدام کاربرد مهم‌تر است.
- سه کلاس NLI؛ تفاوت STS در حالت طبقه‌بندی و رگرسیون؛ POS در برابر نقش نحوی؛ قالب IOB.
- Intent (سطح جمله) در برابر Slot (سطح توکن)؛ نقش Annotation Guideline.
- تفاوت جریانی و غیرجریانی، Chunking و هم‌پوشانی؛ تفاوت VAD و Wake Word؛ تفاوت Speaker Recognition و Diarization.
- طراحی ماژول‌های یک محصول (مترجم، دستیار صوتی، e-KYC، خلاصه‌ساز جلسه) و دلیل استفاده از VAD، Wake Word و Speech-to-Intent برای صرفه‌جویی منابع.

فصل ۲

تصویر کلی علوم زبان و آواشناسی تولیدی

۱.۲ مرور جلسهٔ قبل و تغییر رویکرد

در جلسهٔ نخست مسئله را با رویکرد **بالابه‌پایین** (Top-Down) دیدیم: ابتدا تسک‌های زبان (مانند POS Tagging، NER، Language Modeling) و گفتار (مانند STT، TTS، Speaker Diarization) و سپس ترکیب آن‌ها در یک Pipeline. از این جلسه مسیر را برعکس می‌کنیم و رویکرد **پایین‌به‌بالا** (Bottom-Up) را در پیش می‌گیریم:

۱. ابتدا خود **داده** را بشناسیم: از چه جنسی است و چگونه به وجود می‌آید؟

۲. سپس **بازنمایی** (Representation): داده را چگونه به شکلی درآوریم که رایانه پردازش کند؟ (دست‌ساز، یادگرفته‌شده یا یادگرفته‌شده با خودنظارتی)

۳. در پایان، مدل‌های پیچیده‌تر و عمیق‌تر.

جنس دادهٔ گفتاری و متنی یکسان نیست: متن دنباله‌ای از نمادهاست، اما گفتار یک پدیدهٔ فیزیکی است که در هوا منتشر می‌شود.

جدول ۱.۲: مقایسهٔ ماهیت داده در متن و گفتار

گفتار (Speech)	**متن** (Text)
ماهیت فیزیکی دارد	ماهیت نمادین دارد
به‌صورت موج صوتی منتقل می‌شود	از نمادها و نشانه‌ها تشکیل شده است
در زمان پیوسته است	در سطح توالی نمادها گسسته است

بنابراین در این جلسه ابتدا روی ماهیت دادهٔ گفتاری تمرکز می‌کنیم: موج صوتی چیست، چگونه ایجاد می‌شود و انسان چگونه صحبت می‌کند.

۲.۲ تصویر کلی: جایگاه پردازش گفتار در علوم زبان

زبان‌شناسی (Linguistics) در کنار فیزیک، ریاضی، روان‌شناسی و جامعه‌شناسی از علوم مرتبط با موضوع ماست و شاخه‌های متعددی دارد:

آواشناسی (Phonetics) مطالعهٔ صداهای گفتاری انسان: تولید، ویژگی‌های فیزیکی و شنیده‌شدن. محور اصلی این جلسه و جلسات بعد.

نحو (Syntax) قواعد چینش کلمات برای ساختن جمله؛ در NLP بسیار با آن سروکار داریم.

ریخت‌شناسی (صرف) (Morphology) ساختار درونی کلمات و تغییر شکل آن‌ها: صرف فعل «رفتن» (رفتم، رفتی، ...) یا واژه‌سازی «دانش» + «ـمند» ← «دانشمند».

دو علم میان‌رشته‌ای مرتبط:

زبان‌شناسی رایانشی (Computational Linguistics) در تقاطع زبان‌شناسی، علوم کامپیوتر و هوش مصنوعی؛ مدل‌سازی محاسباتی زبان. درس ما، **پردازش زبان گفتاری** (Spoken Language Processing)، در همین چارچوب است.

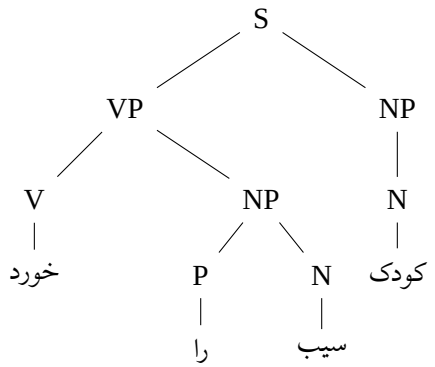
عصب‌زبان‌شناسی (Neurolinguistics) در تقاطع زبان‌شناسی و علوم اعصاب؛ سازوکارهای عصبی مغز برای پردازش زبان.

نگاه مهندسی به زبان‌شناسی

هدف ما به‌عنوان مهندس هوش مصنوعی ارائهٔ نظریهٔ تازه در زبان‌شناسی یا کشف دوبارهٔ دسته‌بندی‌های آن نیست؛ باید مفاهیم و دسته‌بندی‌های موردنیاز را بشناسیم و در ساخت مدل‌های محاسباتی از آن‌ها بهره بگیریم.

۳.۲ نظریهٔ زایشی چامسکی (۱۹۵۷)

- **دیدگاه تقلیدی (قدیمی):** کودک جمله‌ها را می‌شنود، حفظ می‌کند و تکرار می‌کند.
- **نقد چامسکی:** کودکان مرتب **جمله‌های جدیدی** می‌سازند که هرگز نشنیده‌اند. پس توانایی زبانی بیش از حفظ است و در ذهن سازوکاری برای «تولید» (generate) جمله‌ها وجود دارد؛ این ایده به شکل‌گیری علوم شناختی کمک کرد.
- **زبان خطی نیست، سلسله‌مراتبی (Hierarchical) و درختی است:** کلمات در گروه‌ها (اسمی، فعلی) سازمان می‌یابند و گروه‌ها در هم تو در تو می‌شوند (شکل ۱.۲).



شکل ۱.۲: درخت ساختار سلسله‌مراتبی برای «کودک سیب را خورد». S: جمله، NP: گروه اسمی، VP: گروه فعلی، N: اسم، V: فعل، P: نشانهٔ «را». (شکل افزوده)

دستور جهانی در برابر یادگیری آماری. پرسش اصلی: چه مقدار از توانایی زبانی از ابتدا در ذهن هست و چه مقدار از تجربه یاد گرفته می‌شود؟

۱. **دستور جهانی** (Universal Grammar): انسان از بدو تولد اصول زبانیِ جهان‌شمول دارد و متناسب با محیط «پارامترها» را تنظیم می‌کند (کودک فارسی‌زبان فارسی و کودک انگلیسی‌زبان انگلیسی یاد می‌گیرد). در کلاس با تنظیم پارامترهای یک مدل مقایسه شد: ساختار اولیه هست و تجربه شکل نهایی را تعیین می‌کند.

۲. **یادگیری توزیعی** (Distributional / Statistical Learning): انسان با دیدن نمونه‌های بسیار، قواعد را از الگوهای آماری داده یاد می‌گیرد.

نقدهای واردشده به تفسیر سخت‌گیرانهٔ دستور جهانی: تفاوت‌های ساختاری میان زبان‌ها؛ شواهد یادگیری الگوهای جدید از داده؛ ابهام دربارهٔ اینکه دقیقاً کدام ویژگی‌ها فطری‌اند. **جمع‌بندی کلاس:** ایدهٔ زایشی و سلسله‌مراتبی‌بودن زبان همچنان مهم است، اما ادعای مجموعهٔ مشخصی از قواعد دستوری مادرزادی محل بحث است و میزان فطری‌بودن زبان هنوز موضوعی پژوهشی و مورد اختلاف است.

دقت تاریخی دربارهٔ نظریهٔ چامسکی

سال ۱۹۵۷ سال انتشار Syntactic Structures است؛ نقد چامسکی بر رویکرد تقلیدی/رفتارگرا (کتاب اسکینر) در ۱۹۵۹ آمد و صورت‌بندی «اصول و پارامترها» بعدتر (دههٔ ۱۹۸۰) پدید آمد. دو دیدگاه الزاماً دو سر یک طیف‌اند: بسیاری از پژوهشگران امروز بر ترکیبی از سوگیری‌های ذاتی و یادگیری از داده تأکید می‌کنند.

۴.۲ ورود به آواشناسی

آواشناسی (Phonetics) دو بخش اصلی دارد:

آواشناسی تولیدی (Articulatory Phonetics) اینکه بدن چگونه صدا می‌سازد (لب‌ها، زبان، فک و تارهای صوتی چه می‌کنند). موضوع این جلسه.

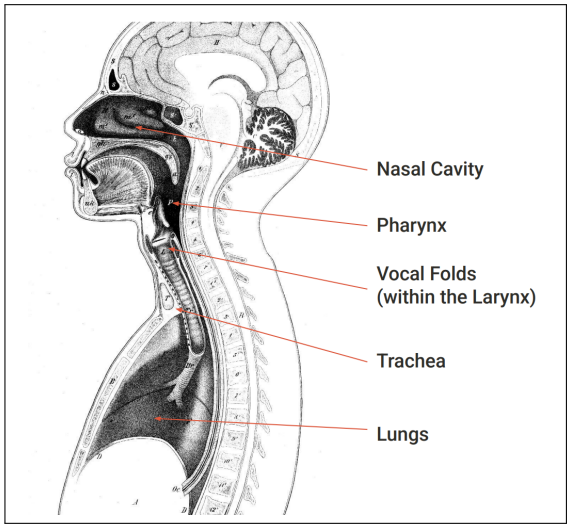
آواشناسی آکوستیکی (Acoustic Phonetics) خود موج صوتی و ویژگی‌های فیزیکی آن. موضوع جلسهٔ بعد.

هدف نهایی: پس از شناخت دادهٔ گفتاری، آن را به بازنمایی مناسب پردازش رایانه‌ای تبدیل کنیم.

واژهٔ articulation یعنی نحوهٔ حرکت و هماهنگی اندام‌های گفتاری (articulators: لب‌ها، زبان، فک، نرم‌کام و ...)؛ در کلاس برای شهود به آرتیکولاتور مکانیکی دندان‌پزشکی (شبیه‌ساز حرکت فک) اشاره شد.

۵.۲ آناتومی تولید گفتار

بدن را با سه صفحهٔ مرجع بررسی می‌کنند: **ساجیتال** (Sagittal) (نیمهٔ چپ/راست، نمای از پهلو)، **فرونتال** (Frontal / Coronal) (جلو/پشت) و **افقی** (Horizontal / Transverse) (بالا/پایین). برای مطالعهٔ حنجره، نای، دهان و مسیر هوا **نمای ساجیتال** بیشترین کاربرد را دارد (شکل ۲.۲).



شکل ۲.۲: برش ساجیتال مجرای صوتی: حفرهٔ بینی، حلق، تارهای صوتی (درون حنجره)، نای و ریه‌ها. (برگرفته از تختهٔ کلاس)

جدول ۲.۲: اندام‌های اصلی دخیل در تولید گفتار

اندام	معادل انگلیسی	نقش
ریه‌ها	Lungs	منبع جریان هوا (تأمین فشار)
دیافراگم	Diaphragm	ماهیچهٔ اصلی دم
نای	Trachea	مسیر هوا از ریه به حنجره
حنجره	Larynx	محل قرارگیری تارهای صوتی
تارهای صوتی	Vocal Folds	تولید صوت واک‌دار از راه ارتعاش
حلق	Pharynx	بخشی از مجرای صوتی بالای حنجره
حفرهٔ بینی	Nasal Cavity	تولید صداهای خیشومی
دهان، زبان، لب‌ها، فک، دندان‌ها	Oral Articulators	شکل‌دهی و تمایز صداها

تارهای صوتی **زیر حلق** و در ابتدای نای، درون حنجره قرار دارند. می‌توان اندام‌ها را در سه گروه دید: سامانهٔ تنفسی (انرژی و فشار)، حنجره («منبع صدا») و مجرای صوتی (فیلتر و شکل‌دهی)؛ این همان مدل «منبع-فیلتر» است که در جلسهٔ بعد می‌آید.

۱.۵.۲ دم و بازدم

دم (Inhalation) دیافراگم منقبض می‌شود و پایین می‌رود؛ حجم قفسه زیاد و فشار ریه کم می‌شود و هوا وارد می‌شود. تارهای صوتی در تنفس معمولی باز هستند.

بازدم (Exhalation) دیافراگم به حالت استراحت برمی‌گردد و هوا خارج می‌شود. این جریان «منبع انرژی» گفتار است: هوا هنگام عبور از حنجره تارها را به ارتعاش درمی‌آورد و صدا در مجرای بالاتر شکل می‌گیرد.

بازدم در گفتار منفعل نیست

«دیافراگم در بازدم ریلکس است» برای تنفس آرام درست است، اما در گفتار سامانهٔ عصبی-عضلانی دائماً مداخله می‌کند تا فشار زیر حنجره در طول جمله تقریباً ثابت بماند (حدود ۵ تا ۱۰ سانتی‌متر آب): ابتدای جمله عضلات دمی بازدم را «ترمز» و انتهای آن عضلات بازدمی هوا را بیرون می‌رانند.

پرسش کلاسی: چرا معمولاً هنگام بازدم صحبت می‌کنیم؟ در دم آرام تارها باز هستند و هوا بدون ارتعاش می‌گذرد؛ برای صدای واک‌دار تارها باید نزدیک هم باشند و جریان هوا با فشار کافی از آن‌ها بگذرد. گفتار هنگام دم غیرممکن نیست (برخی افراد، در آواز یا تمرین‌های صوتی، چنین می‌کنند)، اما الگوی غالب گفتار در همهٔ زبان‌ها استفاده از هوای بازدمی است؛ زیرا فشار را می‌توان در بازدم طولانی و دقیق کنترل کرد.

پرسش کلاسی: نای چرا حلقه‌حلقه است؟ نای لوله‌ای است که هوا را از حنجره به ریه می‌برد و دیوارهٔ آن **حلقه‌های غضروفی** دارد: (۱) هنگام دم فشار درون نای کمتر از بیرون می‌شود و بدون حلقه‌ها مانند نی نرم هنگام مکیدن روی هم می‌خوابید؛ (۲) فاصلهٔ میان حلقه‌ها به نای و گردن انعطاف می‌دهد. پس نای باید **همیشه باز** بماند، برخلاف تارهای صوتی که مرتب باز و بسته می‌شوند.

۶.۲ حنجره و تارهای صوتی

هوای بازدم به حنجره می‌رسد که جفت **تار صوتی** (Vocal Folds) در آن است. فضای میان دو تار **چاکنای** (Glottis) نام دارد؛ در تنفس آرام باز است و هنگام صدای واک‌دار تارها نزدیک می‌شوند و وارد چرخهٔ ارتعاش می‌شوند.

«تار» یا «چین»؟

«تارهای صوتی» ترجمهٔ تحت‌اللفظی vocal cords است و تصویر نادرستی از سیم کشیده‌شده می‌دهد؛ اصطلاح علمی vocal folds (چین‌های صوتی) است: توده‌ای از بافت ماهیچه‌ای و مخاطی که با چرخش غضروف‌های

آریتنوئید به هم نزدیک یا از هم دور می‌شود. در این جزوه به‌دلیل رواج همان «تارهای صوتی» را به کار می‌بریم.

۱.۶.۲ چرا تارها فقط یک بار باز نمی‌شوند؟ اصل برنولی

پرسش کلاسی: وقتی هوا از میان تارها می‌گذرد، چرا همان‌طور باز نمی‌مانند و مرتب باز و بسته می‌شوند؟ پاسخ با **اصل برنولی** (Bernoulli's Principle) داده شد.

اصل برنولی

در جریان پایا، تراکم‌ناپذیر و بدون اصطکاک در امتداد یک خط جریان:

$$p + \frac{1}{2}\rho v^2 + \rho g h = \text{ثابت}$$

که p فشار ایستا، ρ چگالی، v سرعت و h ارتفاع است. در ارتفاع ثابت، **سرعت بیشتر یعنی فشار ایستای کمتر.**

(آزمایش دو بطری کلاس: اگر میان دو بطری سبک هوا بدمیم، بطری‌ها به هم نزدیک می‌شوند، چون فشار ناحیهٔ پرسرعت کمتر است.)

چرخهٔ ارتعاش (روایت ساده‌شده کلاس).

۱. تارها نزدیک هم‌اند و مجرا بسته است؛ فشار زیر تارها بالا می‌رود.

۲. فشار تارها را از هم باز می‌کند.

۳. هوا با سرعت زیاد از شکاف باریک می‌گذرد.

۴. طبق اصل برنولی فشار در شکاف کم می‌شود و همراه با ارتجاع بافت، تارها دوباره بسته می‌شوند.

۵. چرخه تکرار می‌شود و ارتعاش دوره‌ای هوا موج صوتی می‌سازد.

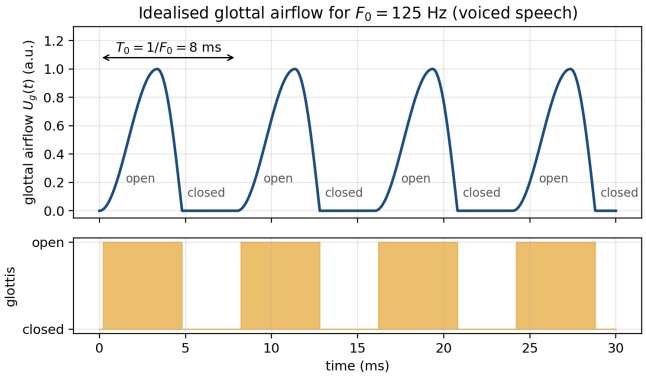
چون حرکت تکرارشونده است، **فرکانس** دارد: همان **فرکانس پایه** (Fundamental Frequency, F0) که به‌صورت زیر یا بم‌بودن صدا ادراک می‌شود.

اصل برنولی تنها توضیح ارتعاش نیست

توضیح کلاس مدلی ساده‌شده بود. نظریهٔ پذیرفته‌شده **نظریهٔ ماهیچه‌ای-ارتجاعی-آیرودینامیکی** (Myoelastic-Aerodynamic Theory) است: ماهیچه‌ها تارها را نزدیک می‌کنند، فشار زیرحنجره‌ای آن‌ها را باز می‌کند و نیروی ارتجاعی بافت به‌علاوهٔ افت فشار برنولی آن‌ها را می‌بندد. برای تداوم ارتعاش، تفاوت فاز میان لبهٔ پایینی و بالایی تارها انرژی را از جریان هوا به بافت منتقل می‌کند.

۲.۶.۲ فرکانس ارتعاش و موج حنجره‌ای

در هر چرخه تارها یک بار باز و بسته می‌شوند و هوا به‌صورت پالس‌های متناوب وارد مجرای صوتی می‌شود (شکل ۳.۲). تعداد چرخه‌ها در ثانیه همان F_0 و دورهٔ تناوب $T_0 = ۱/F_0$ است.

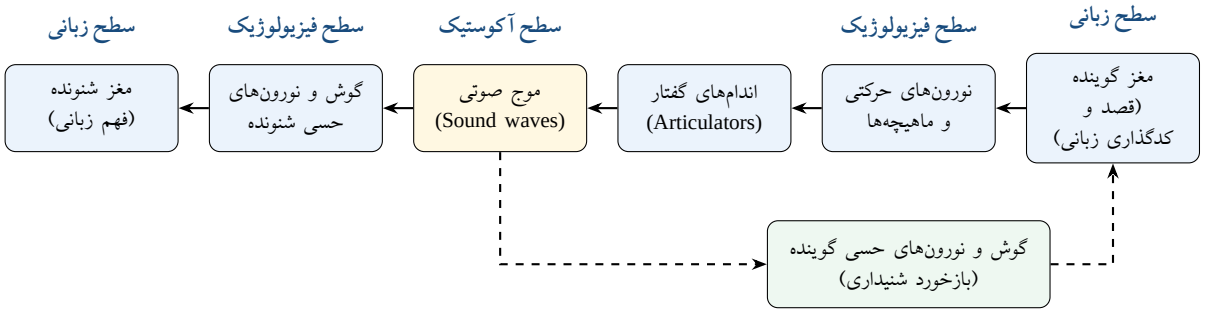


شکل ۳.۲: جریان هوای عبوری از چاکنای برای $F_0 = ۱۲۵$ هرتز؛ تارها هر ۸ میلی‌ثانیه یک بار باز و بسته می‌شوند. (شکل افزوده)

مثال: $F_0 = ۱۰۰$ هرتز (صدای مردانه) $\Rightarrow T_0 = ۱۰$ میلی‌ثانیه؛ $F_0 = ۲۰۰$ هرتز (زنانه) $\Rightarrow$ ۵ میلی‌ثانیه. F_0 مردان بزرگسال تقریباً ۸۵ تا ۱۸۰ و زنان ۱۶۵ تا ۲۵۵ هرتز است؛ تارهای کوتاه‌تر و نازک‌تر فرکانس بالاتری دارند.

۷.۲ زنجیرهٔ گفتار

یک مفهوم ذهنی چگونه به فرمان عضلانی، صدا و جمله‌ای قابل‌فهم برای مخاطب تبدیل می‌شود؟ مدل **زنجیرهٔ گفتار** (Speech Chain) (دنس و پینسون، ۱۹۶۳) این مسیر را از مغز گوینده تا مغز شنونده نشان می‌دهد (شکل ۴.۲).



شکل ۴.۲: زنجیرهٔ گفتار با سه سطح زبانی، فیزیولوژیک و آکوستیک. خط‌چین: بازخورد شنیداری گوینده. (شکل افزوده)

مراحل: مغز گوینده (قصد بیان) ← **نورون‌های حرکتی** (Motor Neurons) (فرمان به ماهیچه‌ها) ← حرکت هماهنگ اندام‌های گفتار ← موج صوتی در هوا ← گوش و **نورون‌های حسی** (Sensory Neurons) (تبدیل ارتعاش هوا به سیگنال عصبی) ← مغز شنونده. افزون بر این، **گوینده صدای خود را هم می‌شنود**؛ پس یک حلقهٔ **بازخورد** (Feedback) شنیداری برای کنترل و اصلاح گفتار وجود دارد.

۱.۷.۲ هم‌تولیدی

در کلاس ادای کلمهٔ «سیب» به نواختن پیانو تشبیه شد (هر کلید یک واج)؛ اما این تشبیه محدودیت دارد: واج‌ها یکی‌یکی و مجزا تولید نمی‌شوند. حرکات واج‌های مجاور تا حدی **هم‌پوشانی** دارند و اندام‌ها در حین یک واج برای واج بعدی آماده می‌شوند. این پدیده **هم‌تولیدی** (Coarticulation) نام دارد. مثلاً در «سو» (/su/) لب‌ها از همان /s/ گرد می‌شوند، ولی در «سی» (/si/) کشیده‌اند.

اهمیت هم‌تولیدی در پردازش گفتار

گفتار فرایندی پیوسته و هماهنگ است، نه توالی حرکات مجزا؛ پس نمی‌توان فرض کرد که در سیگنال صوتی همهٔ واج‌ها مرزهای کاملاً مشخص و مستقل دارند.

۸.۲ واج، همخوان، واکه و هجا

واج

واج (Phoneme) یکی از کوچک‌ترین واحدهای تمایزدهندهٔ معنایی در نظام آوایی یک زبان است: با جایگزینی یک واج در واژه ممکن است معنا عوض شود. مثال: «بار» و «پار» (/b/ و /p/)، «سیر» و «زیر» (/s/ و /z/) **جفت کمینه** (Minimal Pair) هستند.

واج‌ها دو دستهٔ اصلی‌اند: **همخوان (صامت)** (Consonant) و **واکه (مصوت)** (Vowel). از کنار هم قرار گرفتن واج‌ها، **هجا** (Syllable) و سپس کلمه ساخته می‌شود. الگوی هجا را با C (همخوان) و V (واکه) نشان می‌دهند؛ مثلاً «کتاب» دو هجا دارد: «کِ» (CV) و «تاب» (CVC). خود صدای فیزیکی را **آوا** (Phone) می‌گویند و واج رده‌ای انتزاعی از آواهای معادل است.

۹.۲ واکه‌ها و نقشهٔ جایگاه زبان

زبان (و فک و لب‌ها) برای هر واکه در موقعیت مشخصی از دهان قرار می‌گیرد؛ این موقعیت‌ها را در **نقشهٔ واکه‌ها** (Vowel Chart) نمایش می‌دهند. دو بُعد اصلی:

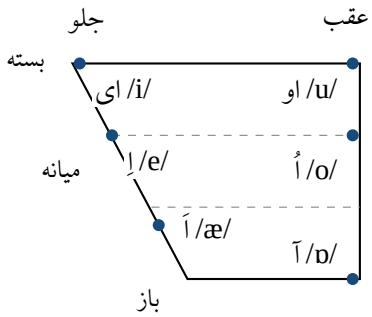
۱. **جلو یا عقب بودن زبان** (Front / Central / Back)؛

۲. **ارتفاع زبان** (بالا–میانه–پایین؛ در نمودار بسته–میانه–باز).

تعداد واکه‌ها در زبان‌ها فرق می‌کند: نمودار انگلیسی کلاس ۱۲ واکه داشت، در حالی که در **فارسی معیار شش واکهٔ اصلی** در نظر می‌گیریم.

جدول ۳.۲: واکه‌های فارسی معیار و جایگاه تقریبی زبان

واکه	نماد IPA	نمونه	جلو/عقب	ارتفاع زبان
ای	/i/	دیر	جلو	بالا (بسته)
اِ	/e/	دل	جلو	میانه
اَ	/æ/	در	جلو	پایین (باز)
آ	/ɒ/ یا /ɑ/	آب	عقب	پایین (باز)
اُ	/o/	گل	عقب	میانه
او	/u/	دور	عقب	بالا (بسته)



شکل ۵.۲: نقشهٔ تقریبی واکه‌های فارسی روی ذوزنقهٔ واکه‌ها (جلو در سمت چپ، مطابق قرارداد IPA). (شکل افزوده)

تمرین کلاسی: رسم نقشهٔ واکه‌های فارسی

جایگاه شش واکهٔ فارسی را روی نمودار واکه‌ها مشخص کنید. هر واکه را تلفظ کنید و به حرکت زبان توجه کنید: «او» (زبان بالا و عقب) و سپس «آ» (زبان پایین و عقب‌تر)، و همین‌طور «ای» و «اَ». دربارهٔ جایگاه «آ»، «اَ» و «او» در کلاس بحث شد. هدف: درک تجربی این نکته که واکه‌ها با تغییر شکل و جایگاه اندام‌های گفتار از هم متمایز می‌شوند. (شکل ۵.۲ پاسخ تقریبی است.)

بُعد سوم توصیف واکه‌ها **گردی لب‌ها** است (در فارسی /u/، /o/ و /ɒ/ گرد هستند). در جلسهٔ بعد می‌بینیم که ارتفاع زبان با فرمنت اول (F_1) و جلو/عقب‌بودن با فرمنت دوم (F_2) ارتباط مستقیم دارد.

۱۰.۲ همخوان‌ها و ویژگی‌های تولیدی آن‌ها

همخوان‌ها را با سه ویژگی توصیف می‌کنیم: **محل تولید** (Place of Articulation)، **شیوه تولید** (Manner of Articulation) و **واک‌داری** (Voicing). در کلاس هر ویژگی با یک تمرین عملی همراه بود.

۱.۱۰.۲ محل تولید

محل تولید مشخص می‌کند مسدودشدن یا تنگ‌شدن جریان هوا در کدام بخش دستگاه گفتار رخ می‌دهد:

- «ب» و «پ»: دو لب ← **دولبی** (Bilabial)؛
- «ف» و «و» (/v/): لب پایین و دندان‌های بالا ← **لبی‌دندانی** (Labiodental)؛
- «س» و «ز»: زبان نزدیک لثه ← **لثوی** (Alveolar)؛
- «ه»: ناحیهٔ چاکنای ← **چاکنایی** (Glottal).

(در فارسی معیار «و» همخوان /v/ است نه /w/، و «ح» و «ه» هر دو /h/ تلفظ می‌شوند.)

۲.۱۰.۲ شیوه‌تولید

شیوهٔ تولید مشخص می‌کند جریان هوا چگونه کنترل می‌شود:

انسدادی (Stop / Plosive) جریان هوا لحظه‌ای کاملاً بسته و سپس رها می‌شود (ضربه‌ای کوچک روی دست جلوی دهان هنگام «پ...پ...پ»). مثال: پ، ب، ت، د، ک، گ.

سایشی (Fricative) هوا ناگهانی رها نمی‌شود؛ از مجرایی باریک می‌گذرد و صدای سایشی می‌سازد («ففف...»). مثال: ف، س، ز، ش.

خیشومی (Nasal) هوا از بینی می‌گذرد («مممم...»). مثال: م، ن.

در خیشومی‌ها **نرم‌کام** (Velum) پایین می‌آید و مسیر بینی باز می‌شود، اما در دهان انسداد کامل هم هست (برای /m/ دو لب)؛ اگر بینی را بگیرید «م» تقریباً تولید نمی‌شود ولی «ب» می‌شود.

فارسی معیار حدود ۲۳ همخوان دارد. جدول زیر آن‌ها را بر اساس محل و شیوه دسته‌بندی می‌کند؛ در هر خانه ابتدا بی‌واک و سپس واک‌دار می‌آید.

جدول ۴.۲: همخوان‌های فارسی بر حسب محل، شیوه و واک‌داری

شیوه \ محل	دولبی	لبی‌دندانی	لثوی	پس‌لثوی	کامی	نرم‌کامی	ملازی	چاکنایی
انسدادی	p b		t d			k g	ɢ	ʔ
انسدادی-سایشی				tʃ dʒ				
سایشی		f v	s z	ʃ ʒ		x		h
خیشومی	m		n					
روان کناری			l					
زنشی			ɾ					
غلت (نیم‌واکه)					j			

۳.۱۰.۲ واک‌داری

واک‌داری

در صداهای **واک‌دار** (Voiced) تارهای صوتی ارتعاش دوره‌ای دارند (ز، ب، د، م و همهٔ واکه‌ها)؛ در صداهای **بی‌واک** (Voiceless) چنین ارتعاشی نیست (س، پ، ت، ف).

تمرین کلاسی: «س» و «ز»

دست خود را روی گلو بگذارید و «سسسس» و سپس «زززز» را کشیده بگویید. هنگام «ز» ارتعاش تارها را حس می‌کنید، هنگام «س» نه. همین را برای «ب» و «پ» هم انجام دهید.

جدول ۵.۲: جفت‌هایی که فقط در واک‌داری تفاوت دارند

ویژگی	/s/ س	/z/ ز	/p/ پ	/b/ ب
محل تولید	لثوی	لثوی	دولبی	دولبی
شیوهٔ تولید	سایشی	سایشی	انسدادی	انسدادی
واک‌داری	بی‌واک	واک‌دار	بی‌واک	واک‌دار

پس دو همخوان می‌توانند در محل و شیوه یکسان باشند و فقط در واک‌داری فرق کنند؛ این برای خطاهای بازشناسی اهمیت ویژه دارد (بخش بعد).

واک‌داری و «ارتعاش» همیشه یکی نیستند

تعریف «واک‌دار = ارتعاش تارها» ساده‌شده است: تمایز /p/ و /b/ بیشتر با **زمان آغاز واک** (Voice Onset Time, VOT) و دمیدگی مشخص می‌شود و گاهی /b/ در آغاز واژه کاملاً واک‌دار نیست. برای شروع، همان تعریف ارتعاش کافی است.

۱۱.۲ کاربرد آواشناسی در هوش مصنوعی

پرسش استاد: «این همه مطلب دربارهٔ زبان، تارهای صوتی و آواشناسی به چه درد ما به‌عنوان مهندس هوش مصنوعی می‌خورد؟» کاربردهای مطرح‌شده:

- **مدل‌های ساده‌تر:** در STT مبتنی بر یادگیری عمیق لازم نیست ویژگی‌های آوایی را دستی وارد کنیم، اما برای هر مسئله به مدل بزرگ نیاز نیست؛ اگر ثابت کنیم مثلاً تنها با Place of Articulation کلاس‌ها تفکیک‌پذیرند، یک طبقه‌بند ساده کافی است (شرط: ابتدا باید توان تفکیک ویژگی‌ها بررسی و اثبات شود).
- **کمبود داده (Low-Resource):** محل، شیوه و واک‌داری دانش مفیدی دربارهٔ ساختار داده می‌دهند تا مدل با داده کمتر به عملکرد مناسب برسد.

- **افزودن دانش (Knowledge Injection):** ویژگی‌های آواشناسی را به‌صورت برچسب یا ویژگی به داده می‌افزاییم؛ مثلاً برای /p/: Bilabial، Stop، Voiceless.
- **مدل‌های سبک‌تر:** اگر ویژگی‌ای را از قبل می‌شناسیم، می‌توان آن را مستقیم به مراحل بعدی داد (شبیه کاهش ابعاد مسئله). صرف افزودن ویژگی مدل را خودکار کوچک نمی‌کند؛ معماری و آموزش هم باید متناسب طراحی شوند.
- **تحلیل خطا و تفسیرپذیری** (مهم‌ترین کاربرد به نظر استاد).

تفاوت Knowledge Injection و Data Cleaning

در **پاک‌سازی داده** (Data Cleaning) داده‌های نامناسب یا خراب را اصلاح می‌کنیم؛ اما در **تزریق دانش** (Knowledge Injection) اطلاعاتی را که دانش پیشین ما دربارهٔ مسئله است به داده یا فرایند آموزش می‌افزاییم. این دو یکی نیستند.

۱.۱۱.۲ تحلیل خطا و تفسیرپذیری

فرض کنید برای یک مدل STT نرخ خطای کلمه (WER) برابر ۱۲ درصد گزارش شده است. این عدد فقط می‌گوید مدل خطا دارد، نه اینکه چه نوع خطاهایی بیشتر رخ می‌دهد. برای تحلیل دقیق‌تر، خروجی مدل (Prediction) را با مرجع صحیح (Ground Truth) مقایسه و ویژگی‌های واجیِ واج‌های اشتباه‌شده را بررسی می‌کنیم: از نظر محل، شیوه یا واک‌داری چه شباهت یا تفاوتی دارند؟ مثلاً اگر مدل «ب» و «پ» را زیاد با هم اشتباه بگیرد:

ویژگی	/b/	/p/
Place	Bilabial	Bilabial
Manner	Stop	Stop
Voicing	Voiced	Voiceless

محل و شیوه یکی است و تفاوت اصلی در واک‌داری است. به‌جای «۱۲ درصد خطا» می‌توان گفت چه سهمی از خطاها به واک‌داری و چه سهمی به محل تولید مربوط است. **بخش قابل‌توجهی از خطاها بین واج‌هایی رخ می‌دهد که از نظر ویژگی‌های آرتیکولاتوری مشابه‌اند.** پس از شناسایی الگوی خطا می‌توان داده‌های برخی واج‌ها را زیاد کرد، کیفیت و تنوع داده را بهبود داد، ویژگی‌های مرتبط را افزود یا معماری و آموزش را تغییر داد.

[محتوای افزوده] مثال عددی: WER و فاصلهٔ ویژگی‌ها

$\mathrm{WER} = (S + D + I)/N$ (جایگزینی، حذف، درج؛ تقسیم بر تعداد کلمات مرجع): برای $N = ۵۰$، $S = ۴$، $D = ۱$، $I = ۱$ داریم $۶/۵۰ = ۱۲٪$. اگر هر همخوان را با بردار دودویی (دولبی، لثوی، انسدادی، سایشی، واک‌دار) نمایش دهیم، $\mathrm{b} = (۱, ۰, ۱, ۰, ۱)$، $\mathrm{p} = (۱, ۰, ۱, ۰, ۰)$ و $\mathrm{s} = (۰, ۱, ۰, ۱, ۰)$؛ فاصلهٔ همینگ $d(b, p) = ۱$ اما $d(b, s) = ۵$: اشتباه «ب» با «پ» خطایی نزدیک و قابل‌انتظار و اشتباه «ب» با «س» جدی‌تر است.

۱۲.۲ جمع‌بندی

در این فصل رویکرد پایین‌به‌بالا و جایگاه پردازش گفتار در علوم زبان را دیدیم، نظریهٔ زایشی چامسکی را مرور کردیم و سپس به آواشناسی تولیدی رسیدیم: آناتومی دستگاه گفتار، تنفس، ارتعاش تارهای صوتی، زنجیرهٔ گفتار و هم‌تولیدی، و توصیف واکه‌ها و همخوان‌ها. در پایان دیدیم این دانش در مدل‌های ساده‌تر، تزریق دانش، کمبود داده و به‌ویژه تحلیل خطا به کار می‌آید. فصل بعد به آواشناسی آکوستیکی می‌پردازد.

نکات مهم برای مرور و امتحان

- رویکرد جلسه **پایین‌به‌بالا** است: ابتدا ماهیت داده، سپس بازنمایی، سپس مدل. گفتار سیگنالی **فیزیکی و پیوسته** است؛ متن **نمادین و گسسته**.
- درس ما در چارچوب **زبان‌شناسی رایانشی** است؛ هدف، شناخت مفاهیم زبان‌شناسی برای استفاده در مدل‌هاست.
- چامسکی: زبان زایشی و سلسله‌مراتبی است؛ بحث **دستور جهانی** در برابر **یادگیری آماری/توزیعی** هنوز باز است.
- مسیر تولید صدا: ریه (بازدم) ← نای ← حنجره و تارهای صوتی ← مجرای صوتی (حلق، دهان، بینی).
- تارهای صوتی با فشار هوا، ارتجاع بافت و اثر **برنولی** (سرعت بیشتر، فشار کمتر) دوره‌ای باز و بسته می‌شوند؛ $T_0 = 1/F_0$. نای برای باز ماندن حلقه‌دار است، ولی تارها باید باز و بسته شوند.
- **زنجیرهٔ گفتار:** مغز گوینده ← نورون حرکتی ← اندام‌ها ← موج صوتی ← گوش و نورون حسی ← مغز شنونده، به‌علاوهٔ بازخورد شنیداری.
- **هم‌تولیدی:** هم‌پوشانی حرکات واج‌های مجاور؛ مرز واج‌ها در سیگنال کاملاً مشخص نیست.
- واکه‌ها: جایگاه زبان (جلو/عقب و بالا/پایین)؛ فارسی شش واکه دارد (ای، اِ، اَ، آ، اُ، او).
- همخوان‌ها: **Place** (دولبی، لبی‌دندانی، لثوی، چاکنایی، ...)، **Manner** (انسدادی، سایشی، خیشومی، ...) و **Voicing**. مثال‌های کلیدی: «ب/پ» و «س/ز».
- کاربرد در هوش مصنوعی: مدل‌های ساده‌تر، کمبود داده، Knowledge Injection (که با Data Cleaning فرق دارد)، مدل‌های سبک‌تر و به‌ویژه تحلیل خطا: به‌جای یک عدد کلی مثل WER، بررسی الگو و علت خطاها با ویژگی‌های واجی.

فصل ۳

آواشناسی آکوستیکی: موج صوتی، طیف، اسپکتروگرام و مدل منبع-فیلتر

۱.۳ توضیحات کلاس دربارهٔ ارزشیابی

نحوهٔ نمره‌دهی درس

نمرهٔ درس: ۱۰ **نمرهٔ عملی** (فعالیت‌ها و تمرین‌ها؛ احتمالاً گزارش یا «ارائه») و ۱۰ **نمرهٔ نظری** (میان‌ترم و پایان‌ترم). سؤالات نظری از مطالب مطرح‌شده در کلاس طرح می‌شود. همچنین **تمرین اول دربارهٔ اسپکتروگرام است**؛ پس مفاهیم این فصل برای تمرین هم لازم است.

۲.۳ مرور جلسهٔ قبل و طرح مسئله

در جلسهٔ قبل با **آواشناسی تولیدی** (Articulatory Phonetics) آشنا شدیم: **نقشهٔ واکه‌ها** (Vowel Chart)، **محل تولید** (Place of Articulation) و **شیوهٔ تولید** (Manner of Articulation). این مفاهیم رویدادهای داخل دهان را توصیف می‌کنند، اما پرسش اصلی این جلسه این است: **این ویژگی‌های تولیدی در موج فیزیکی صدا چه اثری می‌گذارند؟** هدف، یافتن یک **نگاشت** (Mapping) میان ویژگی‌های تولیدی (محل زبان، بازشدن دهان) و ویژگی‌های فیزیکی موج (فرکانس، دامنه، ساختار طیفی) است؛ نگاشتی که برای Speech-to-Text، Text-to-Speech و سایر سامانه‌های گفتاری مهم است.

آواشناسی آکوستیکی (Acoustic Phonetics) به بررسی خصوصیات فیزیکی موج صوتی گفتار می‌پردازد؛ در این فصل می‌بینیم رویدادهای تارهای صوتی و مجرای صوتی چگونه در این موج منعکس می‌شوند.

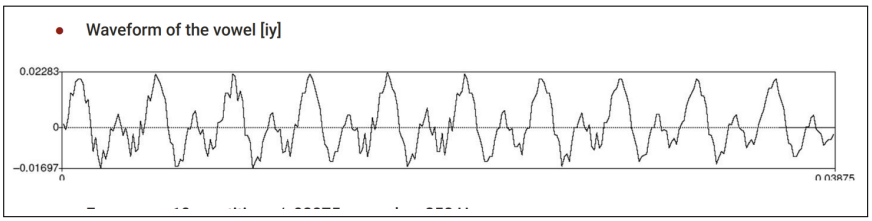
۳.۳ موج صوتی، فرکانس پایه و زیر و بمی

شکل موج (Waveform) نمایش سیگنال در **حوزه‌زمان** است: محور افقی زمان و محور عمودی دامنه، یعنی انحراف فشار هوا از فشار محیط. صدای قوی‌تر یعنی اختلاف فشار بیشتر و قله‌های بلندتر.

فرکانس (Frequency) یعنی تعداد تکرار یک الگوی نوسانی در واحد زمان: اگر در T ثانیه دقیقاً N چرخهٔ کامل داشته باشیم، $f = N/T$ (هرتز). برای یک موج متناوب با **دوره تناوب** (Period) T_0 (مدت یک چرخه):

$$F_0 = \frac{1}{T_0}, \qquad T_0 = \frac{1}{F_0}.$$

مثال: فاصلهٔ ۱۰ میلی‌ثانیه میان دو تکرار $\Rightarrow F_0 = ۱۰۰$ هرتز (صدای مردانهٔ معمولی)؛ فاصلهٔ ۵ میلی‌ثانیه $\Rightarrow F_0 = ۲۰۰$ هرتز (صدای زنانهٔ معمولی).



شکل ۳.۱: شکل موج واکهٔ [iy]. الگوی تکرارشوندهٔ قله‌ها و درّه‌ها دیده می‌شود؛ مدت یک تکرار کامل، تناوب موج است. (برگرفته از تختهٔ کلاس)

شمردن قله‌ها همیشه F_0 را نمی‌دهد

در موج پیچیدهٔ گفتار در هر دوره چند قلهٔ کوچک و بزرگ هست (اثر فرمنت‌ها)؛ آنچه باید اندازه گرفت مدت تکرار کل الگو است، نه تعداد همهٔ قله‌ها. در عمل F_0 را روی فریم‌های کوتاه با الگوریتم‌هایی مانند خودهمبستگی (autocorrelation) تخمین می‌زنند.

فرکانس پایه و Pitch

موج حاصل از ارتعاش تارهای صوتی یک **فرکانس پایه** (Fundamental Frequency) (F_0) دارد که با ادراک **زیر و بمی** (Pitch) مرتبط است: F_0 بالاتر ← صدای زیرتر؛ F_0 پایین‌تر ← صدای بم‌تر.

F_0 ویژگی فیزیکی است و Pitch ویژگی ادراکی

F_0 را از سیگنال اندازه می‌گیریم (هرتز) ولی Pitch آن چیزی است که شنونده می‌شنود. رابطهٔ این دو یکنوا است اما خطی نیست (دو برابرشدن F_0 یعنی یک اکتاو بالاتر).

چرا F_0 افراد متفاوت است؟ در توضیح ساده‌شدهٔ کلاس، تارهای ضخیم‌تر کندتر و تارهای نازک‌تر سریع‌تر می‌لرزند (حدود ۱۰۰ هرتز برای صدای مردانه و ۲۰۰ هرتز برای زنانه؛ اعداد تقریبی‌اند).

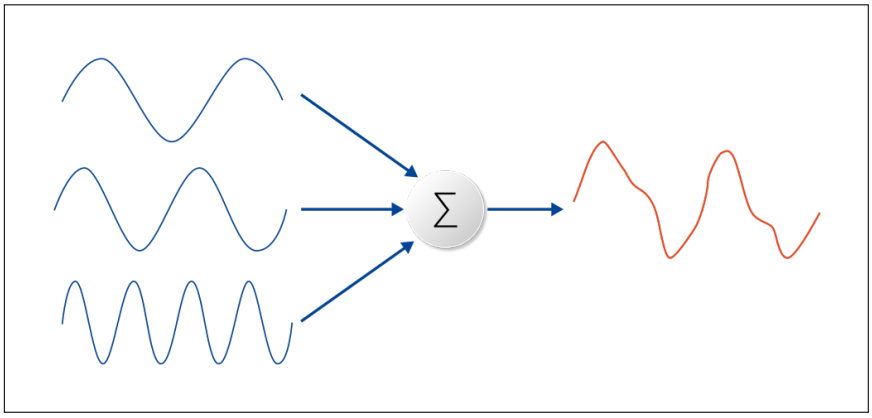
دقیق‌تر: طول، جرم و کشش

F_0 به طول، جرم و کشش تارهای صوتی (و فشار هوای زیر چاکنای) بستگی دارد، نه فقط «ضخامت». تارهای مردان بالغ بلندتر و پرجرم‌ترند؛ گوینده نیز با تغییر کشش ماهیچه‌های حنجره می‌تواند F_0 خود را ارادی تغییر دهد.

آیا Pitch جنسیت را مشخص می‌کند؟ خیر. استاد از دانشجویان خواستند «آ» را یک بار عادی و بار دیگر بم‌تر یا زیرتر بگویند: با ثابت‌ماندن شکل دهان، فقط ارتعاش تارها عوض می‌شود. برخی زنان صدای بم و برخی مردان صدای زیر دارند. علاوه بر F_0، **طول مجرای صوتی** (Vocal Tract Length) هم مؤثر است (مجرای بلندتر، فرمنت‌های پایین‌تر)؛ پس برای مقایسهٔ گویندگان نباید به F_0 اکتفا کرد.

۴.۳ تحلیل فرکانسی و تبدیل فوریه

موج گفتار فقط یک فرکانس ندارد؛ ترکیبی از مؤلفه‌های فرکانسی است. برای دانستن اینکه چه فرکانس‌هایی هست و هرکدام چه سهمی دارد، از **تبدیل فوریه** (Fourier Transform) استفاده می‌کنیم. ایده: هر سیگنال را می‌توان مجموع چند موج سینوسی با فرکانس، دامنه و فاز مناسب دانست.



شکل ۲.۳: جمع چند سینوسی با فرکانس‌های متفاوت یک موج پیچیده می‌سازد. تبدیل فوریه مسئلهٔ معکوس را حل می‌کند: از موج پیچیده، سینوسی‌های سازنده را پیدا می‌کند. (برگرفته از تختهٔ کلاس)

شهود ضرب داخلی. استاد شباهت سیگنال با یک موج مبنا را با **ضرب داخلی** (Dot Product) سنجیدند: صفر یعنی آن مؤلفه سهمی ندارد؛ غیرصفر یعنی سهم دارد و علامت منفی یعنی فاز معکوس (شکل ۳.۳).

$$x = (-1,\ \ 1,\ \ -1,\ \ 1)$$

بردار مبنا	ضرب داخلی با x	نتیجه
$b_1 = (\ 1,\ \ 1,\ \ 1,\ \ 1)$	$-1+1-1+1=0$	سهمی ندارد
$b_2 = (-1,\ -1,\ \ 1,\ \ 1)$	$1-1-1+1=0$	سهمی ندارد
$b_3 = (\ 1,\ -1,\ \ 1,\ -1)$	$-1-1-1-1=-4$	✓ سهم کامل (فاز معکوس)

شکل ۳.۳: محاسبهٔ تخته: سیگنال x (درون بیضی) با سه بردار مبنا مقایسه می‌شود؛ ضرب داخلی با دو بردار اول صفر و با بردار سوم -4 است (بازسازی‌شده از تختهٔ کلاس).

در عمل هر فریم کوتاه، رشته‌ای از N نمونهٔ دامنه است و برای هر فرکانس شباهت آن با موج مبنای $e^{-j۲\pi kn/N}$ سنجیده می‌شود:

$$X[k] = \sum_{n=۰}^{N-۱} x[n]\, e^{-j۲\pi kn/N}.$$

خروجی برای هر فرکانس یک عدد مختلط $a+jb$ است؛ اندازهٔ آن **بزرگی** (Magnitude) $\sqrt{a^۲+b^۲}$ (سهم آن فرکانس) و زاویهٔ آن **فاز** (Phase) است.

دو نکته دربارهٔ توضیح تخته

(۱) ۵۱۲ در مثال تخته «تعداد نمونه‌های یک فریم» ($N = ۵۱۲$) است، نه نرخ نمونه‌برداری. (۲) «کندترین موج = Pitch» دقیق نیست: کندترین موج مبنا فرکانس f_s/N دارد و فقط فاصلهٔ نقاط شبکهٔ فرکانسی را تعیین می‌کند؛ در یک سیگنال متناوب، کندترین مؤلفهٔ واقعاً موجود همان $F_۰$ است.

نمونه‌ها: سیگنال $x(t) = A\sin(۲\pi ft)$ در طیف یک‌طرفه تنها یک مؤلفه در f دارد (مانند بوق ممتد)؛ ساختار آن بسیار ساده‌تر از گفتار است.

۵.۳ هارمونیک‌ها

هارمونیک

در یک صدای متناوب با فرکانس پایه $F_۰$، مؤلفه‌های طیف در مضارب صحیح $F_۰$ قرار می‌گیرند:

$$F_n = n\,F_۰, \qquad n = ۱, ۲, ۳, \ldots$$

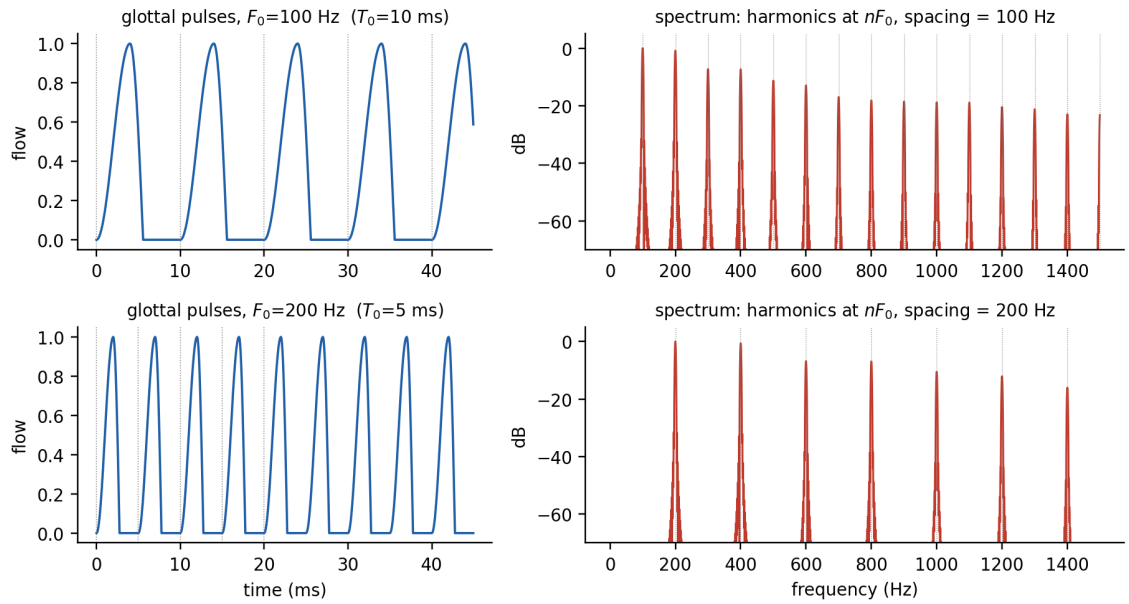
هارمونیک اول همان فرکانس پایه است ($H_۱ = F_۰$)، $H_۲ = ۲F_۰$ و ... . دامنهٔ هر هارمونیک می‌تواند متفاوت باشد.

مثال: برای $F_۰ = ۱۰۰$ هرتز، هارمونیک‌های اول تا پنجم در ۱۰۰, ۲۰۰, ۳۰۰, ۴۰۰, ۵۰۰ هرتز هستند.

فاصلهٔ دو هارمونیک متوالی برابر $F_۰$ است؛ پس هرچه $F_۰$ بزرگ‌تر (صدای زیرتر)، هارمونیک‌ها دورتر از هم‌اند و هرچه کوچک‌تر (صدای بم‌تر)، فشرده‌ترند. به همین دلیل از فاصلهٔ خطوط هارمونیکی در اسپکتروگرام می‌توان $F_۰$ و تغییرات آن را خواند. اما $F_۰$ و هارمونیک‌ها فقط «منبع» را توصیف می‌کنند و نمی‌گویند چرا «آ» با «ای» فرق دارد.

۶.۳ اسپکتروگرام

تبدیل فوریهٔ کل گفتار یک طیف واحد می‌دهد و زمان را از دست می‌دهد، در حالی که گفتار ایستا نیست. **اسپکتروگرام** (Spectrogram) تغییرات محتوای فرکانسی را در طول زمان نمایش می‌دهد. مراحل ساخت (**تبدیل فوریهٔ زمان-کوتاه** (Short-Time Fourier Transform, STFT)):



شکل ۴.۳: بالا: دنبالهٔ تپ‌های ساده‌شدهٔ هوای چاکنای با $F_0 = ۱۰۰$ هرتز و طیف آن. پایین: همان با $F_0 = ۲۰۰$ هرتز. هارمونیک‌ها در مضارب صحیح F_0 ظاهر می‌شوند و فاصلهٔ آن‌ها دقیقاً F_0 است (شکل افزوده).

۱. سیگنال به پنجره‌ها یا فریم‌های کوتاه (مثلاً ۲۵ میلی‌ثانیه) بریده می‌شود (Windowing)؛ پنجره‌ها می‌توانند هم‌پوشانی (Overlap) داشته باشند یا نداشته باشند؛

۲. روی هر فریم تبدیل فوریه اعمال و بزرگی طیف به دست می‌آید؛

۳. طیف‌ها به‌ترتیب زمان کنار هم چیده می‌شوند.

محور افقی زمان، محور عمودی فرکانس و رنگ یا روشنایی هر نقطه، بزرگی (انرژی) آن مؤلفه در آن لحظه است. رنگ گرم یعنی بزرگی بالا، که معمولاً هارمونیک صدای ورودی است.

مقیاس رنگ معمولاً دسی‌بل است

رنگ معمولاً لگاریتم بزرگی ($۲۰ \log_{۱۰} |X|$) را نشان می‌دهد، نه خود بزرگی؛ و فاز کنار گذاشته می‌شود.

فرکانس و دامنه دو چیز متفاوت‌اند

فرکانس یعنی سرعت نوسان و دامنه یعنی اندازهٔ نوسان. قرار داشتن یک مؤلفه در فرکانس بالاتر به معنی دامنهٔ بیشتر نیست. این تمایز در کلاس چند بار تأکید شد: در اسپکتروگرام «ارتفاع» فرکانس است و «پررنگی» دامنه.

۷.۳ مدل منبع-فیلتر

وقتی فردی از «آ» به «ای» می‌رود و F_0 را ثابت نگه می‌دارد، صدا فرق می‌کند؛ این تغییر از F_0 نمی‌آید. پس مدل کامل‌تری لازم است.

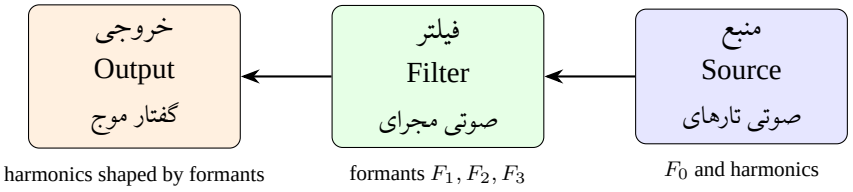
مدل منبع-فیلتر (Source–Filter)

تولید گفتار به دو بخش (در تقریب مدل، مستقل) تقسیم می‌شود:

- **منبع (Source):** برای صداهای واک‌دار، ارتعاش تارهای صوتی که موجی دوره‌ای با F_0 و هارمونیک‌هایش تولید می‌کند؛
- **فیلتر (Filter):** مجرای صوتی (Vocal Tract) که بسته به شکلش بخش‌هایی از طیف را تقویت (تشدید) و بخش‌هایی را تضعیف می‌کند.

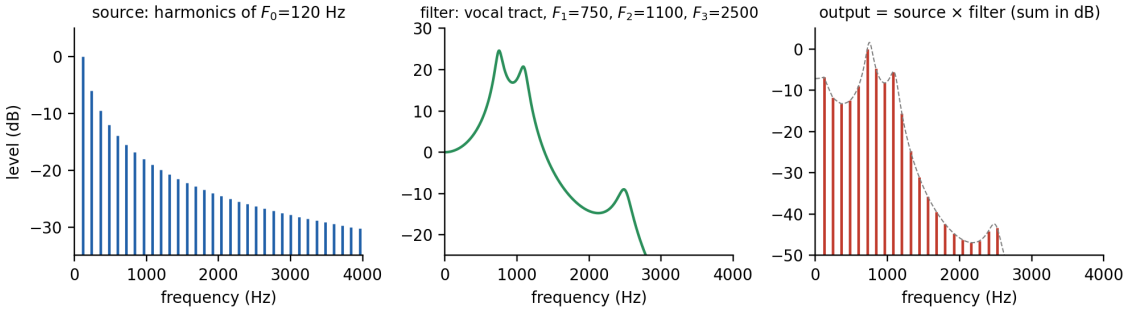
در حوزهٔ فرکانس، خروجی حاصل‌ضرب طیف منبع در پاسخ فرکانسی فیلتر است (در حوزهٔ زمان، کانولوشن؛ و در مقیاس لگاریتمی، جمع):

$$\text{Output}(f) = \text{Source}(f) \times \text{Filter}(f).$$



شکل ۵.۳: نمای ساده‌شدهٔ مدل منبع-فیلتر برای صداهای واک‌دار (شکل افزوده).

استاد مجرا را شبیه یک لوله در نظر گرفتند: هر تغییر در موقعیت زبان، باز بودن دهان، فک، لب‌ها و محل تنگ‌شدگی، مشخصات فیلتر را عوض می‌کند. این همان پیوند مطلوب ماست: تغییر وضعیت اندام‌ها ← تغییر قابل مشاهده در طیف موج.



شکل ۶.۳: نمونهٔ عددی با $F_0 = ۱۲۰$ هرتز: (الف) هارمونیک‌های منبع؛ (ب) پاسخ فرکانسی مجرا با فرمنت‌های $F_1 = ۷۵۰$، $F_2 = ۱۱۰۰$ و $F_3 = ۲۵۰۰$ هرتز؛ (ج) خروجی (جمع دو منحنی در مقیاس دسی‌بل). خط‌چین پوش طیفی است (شکل افزوده).

استقلال منبع و فیلتر تقریبی است

مدل فرض می‌کند تغییر F_0 فرمنت‌ها را جابه‌جا نمی‌کند و برعکس؛ این تقریب برای بیشتر تحلیل‌ها خوب است، ولی برهم‌کنش منبع و مجرا و تابش از لب‌ها را نادیده می‌گیرد.

آیا همهٔ صداها از تارهای صوتی می‌آیند؟ خیر؛ همخوان‌های بی‌واک مانند «س» منبعی از نویز آشفتگی جریان هوا دارند و هارمونیک ندارند. مدل «منبع = ارتعاش تارها» فقط برای صداهای واک‌دار است و تمرکز این جلسه بر همین

حالت بود.

۸.۳ فرمنت‌ها

فرمنت (Formant)

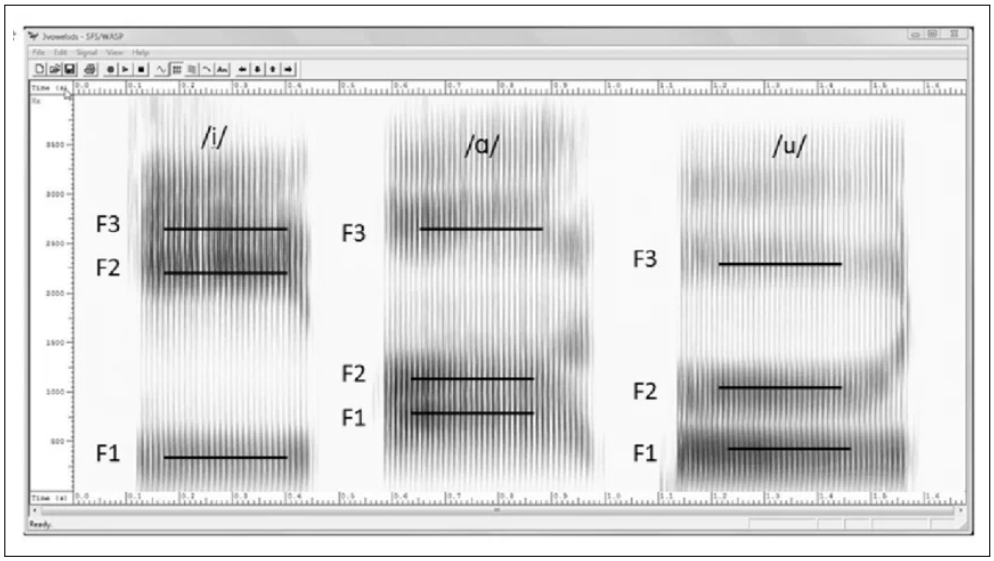
فرمنت‌ها نواحی تشدید مجرای صوتی‌اند؛ نواحی فرکانسی که فیلتر آن‌ها را تقویت می‌کند. در طیف، قله‌ای پهن در پوش طیف و در اسپکتروگرام، نواری پررنگ‌اند. فرمنت‌ها بر اساس ترتیب فرکانسی نام‌گذاری می‌شوند: $F_۱ < F_۲ < F_۳ < \cdots$ (نه ترتیب زمانی).

فرمنت یک هارمونیک منفرد نیست؛ یک ناحیه است که دامنهٔ چند هارمونیک مجاور را بالا می‌برد. فرمنت‌ها متعلق به فیلترند و ما هنگام تحلیل آن‌ها را نمی‌سازیم، بلکه از سیگنال شناسایی می‌کنیم.

ارتباط با نقشهٔ واکه‌ها (مهم‌ترین ارتباط جلسه):

ویژگی تولیدی	ویژگی آکوستیکی
ارتفاع زبان / میزان بازشدگی دهان	$F_۱$
جلو یا عقب بودن زبان	$F_۲$

- $F_۱$ برای واکه‌های بازتر بالاتر است: «آ» $F_۱$ بالاتری از «ای» دارد.
- $F_۲$ برای واکه‌های جلویی بالاتر و برای عقبی پایین‌تر است.

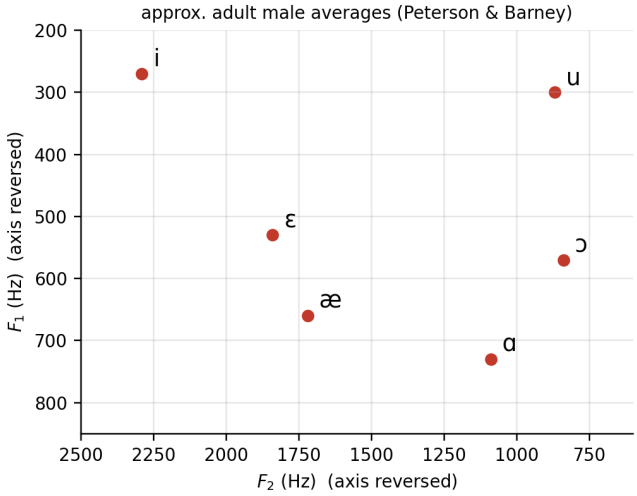


شکل ۷.۳: اسپکتروگرام سه واکهٔ /i/، /a/ و /u/ با خطوط افقی موقعیت $F_۱$ تا $F_۳$. در /i/ فاصلهٔ $F_۱$ و $F_۲$ بسیار زیاد است؛ در /a/ فرمنت اول بالاتر است؛ در /u/ هر دو فرمنت اول و دوم پایین‌اند. (برگرفته از تختهٔ کلاس)

[محتوای افزوده] مقادیر نوعی فرمنت (مردان بالغ، تقریبی)

واکه	F_1	F_2	F_3
/i/ («ای»)	۲۷۰	۲۲۹۰	۳۰۱۰
/a/ («آ»)	۷۳۰	۱۰۹۰	۲۴۴۰
/u/ («او»)	۳۰۰	۸۷۰	۲۲۴۰

میانگین‌های واکه‌های انگلیسی (پترسون و بارنی، ۱۹۵۲) برحسب هرتز؛ فقط برای نشان‌دادن الگو.

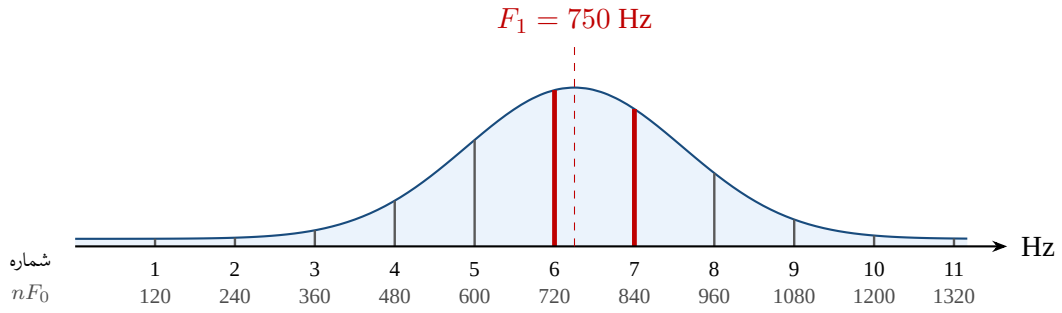


شکل ۸.۳: نقشهٔ آکوستیکی واکه‌ها در صفحهٔ F_2-F_1 (محورها معکوس)؛ شبیه نقشهٔ واکه‌ها در آواشناسی تولیدی (شکل افزوده).

طول مجرا: مجرای بلندتر، فرمنت‌ها را پایین‌تر می‌برد و مجرای کوتاه‌تر بالاتر (مجرای مردان معمولاً بلندتر است). این یکی از دلایلی است که F_0 به‌تنهایی جنسیت را مشخص نمی‌کند.

ویژگی	هارمونیک	فرمنت
منشأ اصلی	تناوب منبع (تارها)	تشدیدهای مجرای صوتی
نوع نمایش	مؤلفه در فرکانس مشخص	ناحیه یا قلهٔ تشدیدی در پوش طیف
ارتباط با F_0	مضارب صحیح F_0	لزوماً مضرب صحیح نیست

مثال کلاسی. فرض کنید $F_0 = ۱۲۰$ هرتز؛ هارمونیک‌ها $۱۲۰, ۲۴۰, ۳۶۰, ۴۸۰, ۶۰۰, ۷۲۰, ۸۴۰, ۹۶۰, \ldots$ هستند. اگر $F_1 = ۷۵۰$ هرتز باشد، کدام هارمونیک‌ها بیشتر تقویت می‌شوند؟ پاسخ: ششم (۷۲۰) و هفتم (۸۴۰) که به ۷۵۰ نزدیک‌ترند (فاصله‌ها: ۳۰ و ۹۰ هرتز). میزان دقیق تقویت به شکل و پهنای قلهٔ تشدیدی بستگی دارد؛ به همین دلیل فرمنت در اسپکتروگرام یک ناحیهٔ پررنگ است، نه یک خط (شکل ۹.۳).



شکل ۹.۳: مثال تخته: با $F_0 = ۱۲۰$ هرتز و $F_1 = ۷۵۰$ هرتز، هارمونیک‌ها در ۱۲۰، ۲۴۰، ۳۶۰، ...هرتز قرار دارند و شمارهٔ هرکدام زیر آن نوشته شده است. هارمونیک‌های نزدیک به قلهٔ تشدیدی (ششم و هفتم، ۷۲۰ و ۸۴۰ هرتز، با رنگ قرمز) بیشترین تقویت را می‌گیرند؛ منحنی آبی شکل کلی فیلتر مجرای صوتی است (منحنی افزوده) (بازسازی‌شده از تختهٔ کلاس).

۹.۳ اسپکتروگرام باند باریک و باند پهن

کلید فهم این دو نوع، یک مبادله (trade-off) بنیادی است: پنجرهٔ **کوتاه** تغییرات سریع زمانی را بهتر نشان می‌دهد ولی فرکانس‌های نزدیک را بد تفکیک می‌کند؛ پنجرهٔ **بلند** برعکس. وضوح فرکانسی تقریباً با معکوس طول پنجره متناسب است ($\Delta f \sim 1/L$)؛ مثلاً با $f_s = ۱۶۰۰۰$ و $N = ۵۱۲$ نمونه، $\Delta f = ۳۱٫۲۵$ هرتز).

باند پهن در برابر باند باریک

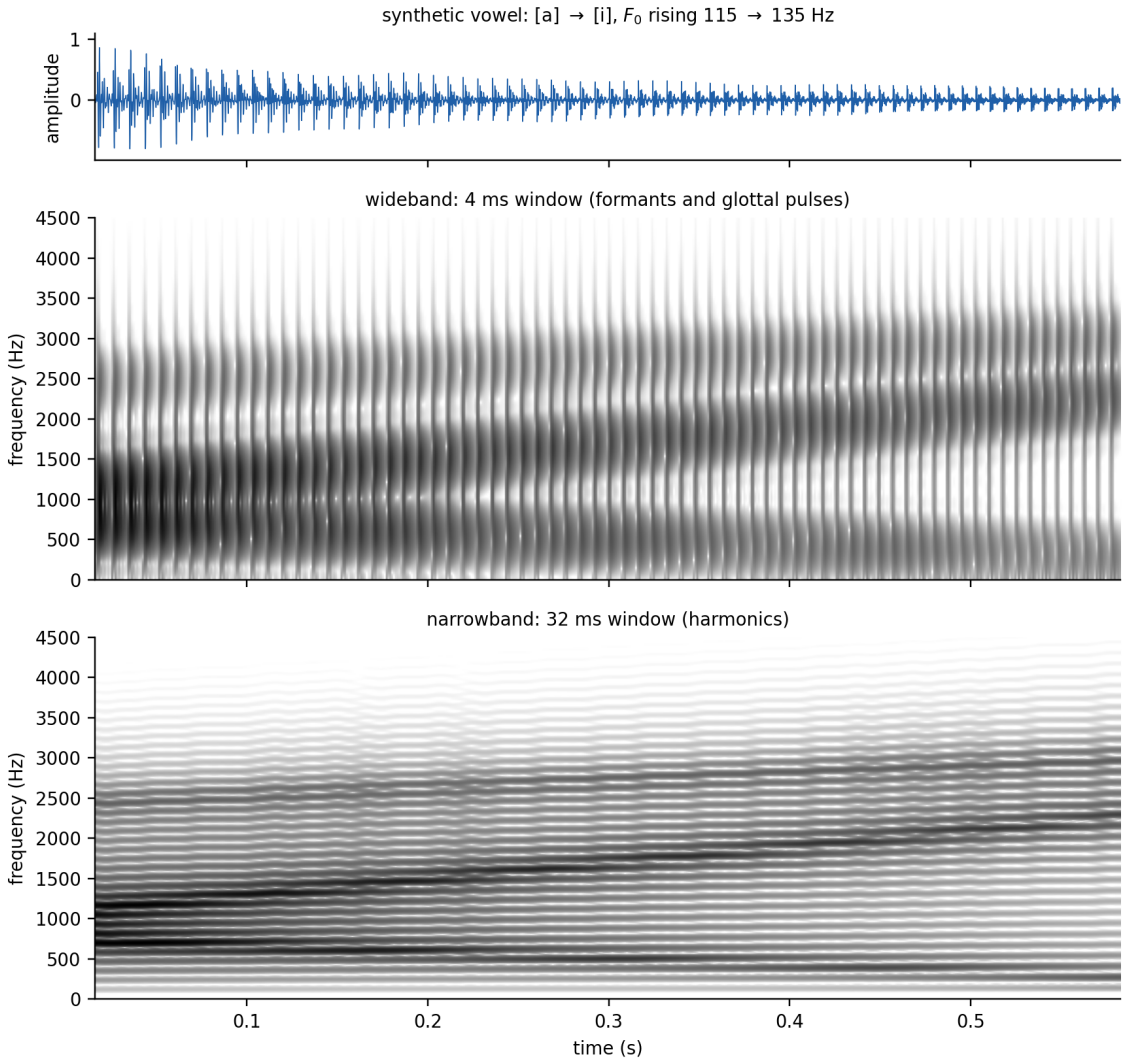
باند پهن (Wideband): پنجرهٔ کوتاه (حدود ۳ تا ۵ میلی‌ثانیه؛ در کلاس ۵). وضوح زمانی بالا، وضوح فرکانسی پایین؛ هارمونیک‌ها در هم ادغام می‌شوند و پوش طیفی (فرمنت‌ها) دیده می‌شود.
باند باریک (Narrowband): پنجرهٔ بلندتر (حدود ۲۰ تا ۵۰ میلی‌ثانیه؛ در کلاس ۳۰). وضوح فرکانسی بالا، وضوح زمانی پایین؛ هارمونیک‌ها به‌صورت خطوط افقی باریک و مجزا دیده می‌شوند.

ویژگی	باند پهن	باند باریک
طول پنجره	کوتاه	بلند
وضوح زمانی	بالا	پایین
وضوح فرکانسی	پایین	بالا
نمایش مناسب‌تر	فرمنت‌ها	هارمونیک‌ها

نکتهٔ مهم استاد

این دو نوع اسپکتروگرام مربوط به دو سیگنال متفاوت نیستند؛ هر دو از یک سیگنال با تنظیم متفاوت پنجره ساخته می‌شوند. دقت زمانی و فرمنت ⇐ wideband؛ دقت فرکانسی و هارمونیک‌ها ⇐ narrowband.

فرمنت‌ها با حرکت سریع زبان و دهان تغییر می‌کنند و ردگیری آن‌ها وضوح زمانی خوب می‌خواهد؛ به همین دلیل باند پهن برای فرمنت‌ها مناسب‌تر است.



شکل ۱۰.۳: اسپکتروگرام باند پهن (پنجرهٔ ۴ میلی‌ثانیه) و باند باریک (۳۲ میلی‌ثانیه) از یک واکهٔ ترکیبی که از «آ» به «ای» می‌رود. باند پهن نوارهای فرمنتی و خطوط عمودی تپ‌های چاکنایی را نشان می‌دهد؛ باند باریک خطوط افقی هارمونیک‌ها را (شکل افزوده).

۱۰.۳ پرسش و پاسخ

- **آیا هارمونیک‌ها و فرمنت‌ها را می‌توان کاملاً جدا کرد؟** خیر؛ فیلتر روی طیف منبع اثر گذاشته و هر دو در سیگنال حضورند. با تغییر نوع اسپکتروگرام فقط یکی بهتر دیده می‌شود.
- **اگر دهان ثابت بماند، فرمنت‌ها حذف می‌شوند؟** خیر؛ فیلتر همچنان هست و فرمنت‌ها نوارهای افقی نسبتاً ثابت‌اند.
- **آیا با تغییر فرمنت‌ها Pitch از بین می‌رود؟** خیر؛ فیلتر بر دامنهٔ هارمونیک‌ها اثر می‌گذارد، نه بر F_0.
- **آیا فرمنت‌ها را می‌توان عددی استخراج کرد؟** بله، به‌عنوان ویژگی عددی؛ الگوریتم‌هایش در این جلسه بررسی نشد.

۱۱.۳ کاربردهای اسپکتروگرام و تمرین

اسپکتروگرام ابزاری آموزشی نیست و در مسائل واقعی مانند **تشخیص احساس از گفتار** (Speech Emotion Recognition) به کار می‌رود. در بخش عملی، استاد ابزاری پایتونی (مبتنی بر پردازش سیگنال، با کاربرد در گفتاردرمانی) را روی کلمهٔ «سیب» نشان دادند: در نمایش اول خطوط هارمونیکی واضح‌تر بودند و برای دیدن بهتر فرمنت‌ها باید اندازهٔ پنجره را کوتاه کرد (باند پهن).

تمرین اول: اسپکتروگرام

تمرین اول با اسپکتروگرام مرتبط است؛ جزئیات اجرایی در این جلسه بیان نشد. مفاهیم لازم: شکل موج، F_0 و هارمونیک‌ها، تبدیل فوریه و پنجره‌بندی، تولید و تحلیل اسپکتروگرام، تفاوت باند پهن و باریک، و مشاهده و تفسیر فرمنت‌ها.

۱۲.۳ جمع‌بندی

مفهوم	تعریف و نقش
فرکانس پایه F_0	$1/T_0$؛ مرتبط با Pitch؛ وابسته به طول، جرم و کشش تارها
هارمونیک‌ها	مضارب صحیح F_0، با فاصلهٔ F_0
اسپکتروگرام	بزرگی STFT؛ محتوای فرکانسی در طول زمان
منبع / فیلتر	تارهای صوتی (واک‌دار) / مجرای صوتی که طیف منبع را شکل می‌دهد
فرمنت‌ها	نواحی تشدید مجرا ($F_1 < F_2 < F_3$)؛ F_1: ارتفاع/بازشدگی، F_2: جلو-عقب
باند پهن / باریک	پنجرهٔ کوتاه، فرمنت‌ها / پنجرهٔ بلند، هارمونیک‌ها

رابطه با جلسهٔ قبل: آواشناسی تولیدی وضعیت اندام‌ها را توصیف می‌کند؛ مدل منبع-فیلتر آن را به تحریک تارها و فیلتر مجرا ترجمه می‌کند؛ F_0، هارمونیک‌ها و فرمنت‌ها آثار قابل‌اندازه‌گیری آن هستند و اسپکتروگرام ابزار مشاهدهٔ آن‌ها است.

نکات مهم برای مرور و امتحان

- نمره: ۱۰ عملی (گزارش یا ارائه) + ۱۰ نظری (میان‌ترم و پایان‌ترم)؛ تمرین اول دربارهٔ اسپکتروگرام است.
- F_0 ویژگی فیزیکی و Pitch ادراکی است؛ F_0 بالاتر یعنی صدای زیرتر. F_0 به‌تنهایی جنسیت را تعیین نمی‌کند؛ طول مجرا نیز مؤثر است.
- هارمونیک‌ها در nF_0 و با فاصلهٔ F_0 هستند؛ F_0 بزرگ‌تر یعنی هارمونیک‌های دورتر.
- اسپکتروگرام = پنجره‌بندی + فوریه برای هر پنجره + کنار هم چیدن (افقی زمان، عمودی فرکانس، رنگ بزرگی). فرکانس و دامنه متفاوت‌اند.
- $\text{Output}(f) = \text{Source}(f) \times \text{Filter}(f)$؛ منبع = تارها (واک‌دار)، فیلتر = مجرا.
- فرمنت ناحیهٔ تشدیدی مجراست، نه یک هارمونیک؛ F_1 با ارتفاع/بازشدگی و F_2 با جلو/عقب بودن زبان مرتبط است؛ مجرای بلندتر، فرمنت‌های پایین‌تر. فرمنت‌ها «شناسایی» می‌شوند، نه «ساخته».
- باند پهن (پنجرهٔ حدود ۵ میلی‌ثانیه) ← فرمنت‌ها و وضوح زمانی؛ باند باریک (حدود ۳۰ میلی‌ثانیه) ← هارمونیک‌ها و وضوح فرکانسی؛ هر دو از یک سیگنال‌اند.
- مثال کلاسی: $F_0 = ۱۲۰$ و $F_1 = ۷۵۰$ هرتز ⇐ هارمونیک‌های ششم (۷۲۰) و هفتم (۸۴۰) بیشتر تقویت می‌شوند.

فصل ۴

فرمنت‌ها، نرم‌افزار Praat و فضای واکه‌ای

هدف این جلسه آن است که از روی سیگنال صوتی، ویژگی‌های **آکوستیکی** (Acoustic) مانند F1 و F2 را اندازه بگیریم و آن‌ها را به ویژگی‌های **تولیدی** (Articulatory) مانند ارتفاع و جلو یا عقب‌بودن زبان نگاشت کنیم. ابزار عملی این کار نرم‌افزار Praat و نتیجهٔ کار، **فضای واکه‌ای** (Vowel Space) است که در گفتاردرمانی، تشخیص صدای جعلی و پایش بیماری‌های عصبی به کار می‌رود.

۱.۴ مرور کوتاه: از فرکانس پایه تا فرمنت

جزئیات فوریه، هارمونیک‌ها و مدل منبع-فیلتر در فصل ۳ آمده است. نکته‌های مرور شده در ابتدای جلسه:

- **فرکانس پایه:** اگر موجی در هر T ثانیه یک دورهٔ کامل بزند، $f_۰ = ۱/T$ است. برای Pitch تکرار قله‌های اصلی، یعنی کندترین الگوی تناوبی، را در نظر می‌گیریم. $f_۰$ به منبع (چین‌های صوتی) و فرمنت‌ها به فیلتر (مجرای صوتی) مربوط‌اند.
- **Magnitude در برابر دامنه:** ضریب فوریه عدد مختلط $X = a + jb$ است؛ اندازهٔ آن $|X| = \sqrt{a^۲ + b^۲}$ سهم آن فرکانس در سیگنال است و زاویهٔ آن فاز. دامنهٔ زمانی سیگنال و Magnitude طیفی یکی نیستند. در اسپکتروگرام رنگ گرم‌تر یعنی مقدار طیفی بیشتر.
- **تعامد:** موج‌های مبنا باید متعامد باشند تا هر کدام مؤلفه‌ای مستقل را بسنجند: ضرب داخلی دو موج صفر باشد ($\int_۰^T x_۱(t)x_۲(t)\,dt = ۰$). موج‌هایی با تعداد صحیح دوره در بازهٔ T (فرکانس‌های $۱/T, ۲/T, \ldots$) چنین مجموعه‌ای می‌سازند.
- **هارمونیک‌ها:** فرکانس‌ها $f_n = nf_۰$ هستند ولی ضریب برخی می‌تواند صفر باشد؛ مثلاً موج مربعی با چرخهٔ کاری ۵۰ درصد فقط هارمونیک‌های فرد دارد.

پرسش و پاسخ: آیا تعداد هارمونیک‌ها بی‌نهایت است؟

از نظر ریاضی بله، اما در عمل نرخ نمونه‌برداری (نایکویست) و هدف تحلیل آن را محدود می‌کند و فقط بخش مفید طیف بررسی می‌شود.

۱.۱.۴ هارمونیک در برابر فرمنت

هارمونیک‌ها ویژگی سیگنال تناوبی (منبع) هستند، در حالی که **فرمنت‌ها** (Formants) نواحی تشدید مجرای صوتی (فیلتر) را توصیف می‌کنند و به صورت برآمدگی‌های پوش طیفی دیده می‌شوند. با نگاه به هارمونیک‌ها نمی‌توان فهمید زبان کجاست؛ برای این کار باید فرمنت‌ها را استخراج کرد. یکی از روش‌های رایج تخمین فرمنت **کدگذاری پیش‌بینی خطی** (Linear Predictive Coding (LPC)) است.

جدول ۱.۴: مقایسهٔ اسپکتروگرام پهن‌باند و باریک‌باند

ویژگی	Wideband	Narrowband
طول پنجره	کوتاه‌تر (حدود ۵ میلی‌ثانیه)	بلندتر
تفکیک زمانی / فرکانسی	زمانی بیشتر، فرکانسی کمتر	زمانی کمتر، فرکانسی بیشتر
ظاهر طیف	نواحی پهن انرژی؛ فرمنت‌ها دیده می‌شوند	خطوط هارمونیکی جداگانه
کاربرد	دنبال‌کردن فرمنت‌ها و حرکت اندام‌ها	بررسی هارمونیک‌ها و f_0

چون زبان و سایر اندام‌ها سریع جابه‌جا می‌شوند، برای دیدن فرمنت‌ها از نمای پهن‌باند استفاده می‌کنیم.

۲.۴ نگاشت ویژگی‌های آکوستیکی به ویژگی‌های تولیدی

در پردازش گفتار معمولاً موقعیت واقعی زبان را مستقیم اندازه نمی‌گیریم؛ در عوض ویژگی‌های آکوستیکی را از صوت استخراج و برای توصیف فضای واکه‌ای به کار می‌بریم. دو فرمنت اول بیشترین نقش را دارند.

نگاشت F1 و F2 به ویژگی‌های تولیدی

- **فرمنت اول** (F1): رابطهٔ معکوس با ارتفاع زبان. زبان بالاتر (واکهٔ بسته) ⇐ F1 کمتر؛ زبان پایین‌تر (واکهٔ باز) ⇐ F1 بیشتر.
- **فرمنت دوم** (F2): مرتبط با جلو یا عقب بودن زبان. زبان جلوتر ⇐ F2 بیشتر؛ زبان عقب‌تر ⇐ F2 کمتر.
- **گرد شدن لب** (Lip Rounding): F2 را کاهش می‌دهد.

این رابطه‌ها تقریبی‌اند

فرمنت‌ها تشدیدهای کل مجرای صوتی‌اند، نه یک «حفرهٔ» مشخص؛ F1 علاوه بر ارتفاع زبان به باز بودن فک و تنگی حلق نیز حساس است. به همین دلیل واکهٔ عقبی گرد مانند /u/ هم F1 هم F2 پایین دارد. پاسخ استاد به پرسش «آیا قانون ثابت است؟»: این یک قاعدهٔ کلی آواشناختی است، نه رابطه‌ای بدون استثنا؛ برای یک گروه جدید رابطه را از پیش فرض نمی‌کنیم، مقادیر واقعی را اندازه می‌گیریم و تفاوت‌ها را تفسیر می‌کنیم.

[محتوای افزوده] مثال عددی: لولهٔ یکنواخت و اثر طول مجرا

مجرای خنثی را می‌توان لولهٔ یک‌سر بسته (چین‌های صوتی) و یک‌سر باز (لب‌ها) گرفت: $F_n = \frac{(2n-1)\,c}{4L}$ با $c \approx 35000$ سانتی‌متر بر ثانیه. برای $L = 17{/}5$ سانتی‌متر (مرد بزرگسال): $F_1 = 500$، $F_2 = 1500$ و $F_3 = 2500$ هرتز. برای $L = 11$ سانتی‌متر (کودک): $F_1 \approx 795$ و $F_2 \approx 2386$ هرتز. پس مجرای کوتاه‌تر یعنی فرمنت بالاتر، و فضای واکه‌ای باید برای هر گروه جداگانه ساخته شود.

۳.۴ کار عملی با Praat

Praat نرم‌افزار رایگان تحلیل و برچسب‌گذاری گفتار است (Boersma و Weenink، آمستردام). استاد آن را برای پل زدن میان ویژگی‌های آکوستیکی و تولیدی معرفی کرد؛ تمرکز بر دو کار بود: استخراج فرمنت‌ها و برچسب‌گذاری (Annotation).

۱.۳.۴ تحلیل صوت و اندازه‌گیری فرمنت

استاد چند واکه («ای»، «آ»، «او») را ضبط کرد. در محیط تحلیل، شکل موج در بالا، **طیف‌نگاره** (Spectrogram) در پس‌زمینه، منحنی آبی Pitch و نقطه‌های قرمز Formants دیده می‌شود. با کلیک روی هر لحظه، فرمنت‌ها همان لحظه نمایش داده می‌شوند (در کلاس: F1 حدود ۳۴۰، F2 حدود ۲۰۰۰ و F3 حدود ۳۰۰۰ هرتز، الگوی شبیه /i/؛ واحد هرتز است). این‌ها اندازه‌گیری یک لحظه‌اند، نه مقدار ثابت واکه.

لازم نیست فقط در یک نقطه بخوانیم: بازهٔ زمانی یک واکه (مثلاً «آ») را انتخاب، میانگین F1 و F2 را از Praat می‌گیریم و برای تحلیل ذخیره می‌کنیم. در پژوهش‌ها معمولاً فرمنت در میانهٔ واکه (حدود ۵۰ درصد مدت) یا میانگین ۲۰ تا ۸۰ درصد خوانده می‌شود تا اثر همخوان‌های مجاور کم شود.

سقف فرمنت (Maximum formant) را بر حسب گوینده تنظیم کنید

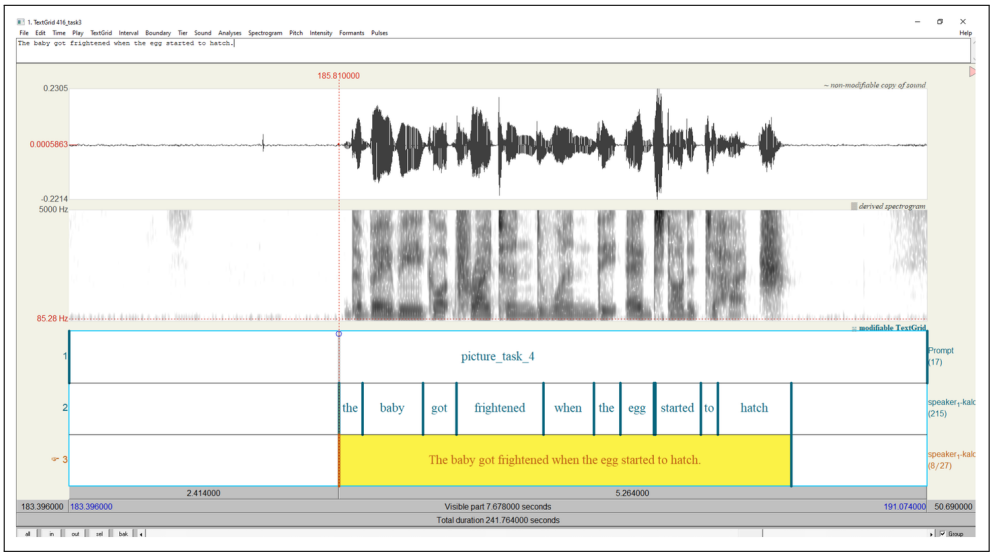
Praat فرمنت‌ها را با روش Burg (نوعی LPC) تخمین می‌زند. راهنمای معمول با ۵ فرمنت: حدود ۵۰۰۰ هرتز برای مردان، ۵۵۰۰ (پیش‌فرض) برای زنان و مقادیر بالاتر برای کودکان. سقف نامناسب فرمنتی را حذف یا اضافه می‌کند. خروجی را همیشه با طیف‌نگاره بازبینی کنید؛ وقتی f_0 بالا است (زنان و کودکان) ممکن است هارمونیک به جای فرمنت انتخاب شود. برای Pitch نیز بازهٔ جست‌وجو را متناسب با گوینده بگذارید (مردان حدود ۷۵ تا ۳۰۰ و زنان ۱۰۰ تا ۵۰۰ هرتز) وگرنه f_0 نصف یا دو برابر می‌شود.

۲.۳.۴ برچسب‌گذاری گفتار با TextGrid

مهم‌ترین کاربرد Praat در این جلسه Annotation بود: مشخص‌کردن مرزهای زمانی و برچسب‌زدن بخش‌های صوت. ساختار آن TextGrid است و از چند لایه (Tier) ساخته می‌شود. استاد سه سطح را مثال زد:

لایه	برچسب‌ها
Word Tier (سطح واژه)	ای آ او
Syllable Tier (سطح هجا)	ای آ او
Phoneme Tier (سطح واج)	/i/ /ɑ/ /u/

با تعیین بازهٔ هر واکه یا همخوان، علاوه بر برچسب زبانی، اطلاعات آکوستیکی همان بازه هم استخراج می‌شود. نتیجه مجموعه‌داده‌ای است که برای هر بازه می‌گوید چه واجی تولید شده، F1 و F2 آن چقدر بوده و گوینده به کدام گروه آماری تعلق دارد.



شکل ۱.۴: نمونهٔ یک TextGrid در Praat: شکل موج، طیف‌نگاره و سه لایهٔ برچسب برای یک جملهٔ پیکرهٔ AusKidTalk. (برگرفته از تختهٔ کلاس)

۴.۴ ساخت پیکرهٔ گفتاری برای یک جامعهٔ آماری خاص

استاد دستیار صوتی کودکان را مثال زد: سامانهٔ تشخیص گفتاری که برای بزرگسالان خوب کار می‌کند، روی گفتار کودکان بیشتر خطا می‌کند (مجرای کوتاه‌تر و فرمنت‌های بالاتر). راه‌حل ساخت پیکرهٔ اختصاصی است:

۱. ضبط نمونه‌های صوتی از کودکان جامعهٔ هدف؛

۲. بررسی در Praat و تعیین مرز واژه‌ها و واج‌ها؛

۳. برچسب‌زدن واکه‌ها و استخراج F1 و F2؛

۴. به‌دست‌آوردن دامنهٔ آماری هر واکه در آن گروه.

خروجی جدولی است با ستون‌های «واکه»، «دامنهٔ F1» و «دامنهٔ F2» که مقادیرش باید از داده‌های واقعی بیاید و جداگانه برای زنان، مردان، کودکان یا گروه‌های خاص تهیه می‌شود.

۱.۴.۴ چارچوب ASR + بازبینی انسانی

مقالهٔ AusKidTalk (LREC 2026) رونویسی گفتار پیوستهٔ کودکان استرالیایی را شرح می‌دهد: متن اولیه با ASR (نرخ خطای واژه ۲۳ درصد) تولید و سپس به‌دست انسان اصلاح شد؛ اصلاح دستی حدود ۱۱ برابر مدت گفتار زمان برد، در حالی که رونویسی دستی کامل با راستی‌آزمایی حدود ۵۰ برابر است. فرایند کلاس:

۱. ضبط گفتار کودکان؛

۲. تولید متن اولیه با مدل ASR مانند Whisper؛

۳. آماده‌سازی TextGrid و هم‌زمان‌سازی متن با صوت؛

۴. بازبینی انسانی (Annotator): گوش‌دادن و اصلاح برچسب‌ها و مرزها؛

۵. ساخت پیکرهٔ نهایی.

کار برچسب‌زن از نوشتن از صفر به «بازبینی و تصحیح» تبدیل می‌شود که سریع‌تر و عملی‌تر است. پیکرهٔ اصلاح‌شده را می‌توان برای **تنظیم دقیق** (Fine-tuning) مدلی مانند Whisper به کار برد؛ استاد این را با ایدهٔ استفاده از داده‌های دشوار (خطاهای مدل قبلی) مرتبط دانست.

نرخ خطای واژه (WER)

$$\mathrm{WER} = \frac{S + D + I}{N}$$

S جانشینی، D حذف، I درج و N تعداد واژه‌های مرجع است. مثال: مرجع با $N = ۱۰$ واژه، یک واژه تغییر کرده ($S = ۱$) و یکی حذف شده ($D = ۱$): $\mathrm{WER} = ۲/۱۰ = ۲۰٪$. چون درج‌ها هم شمرده می‌شوند، WER می‌تواند از ۱۰۰ درصد بیشتر شود.

نکتهٔ پژوهشی: مستندسازی برچسب‌گذاری

استاد گفت هنگام انتشار پژوهش، روش برچسب‌گذاری باید کاملاً مستند شود: چه کسانی برچسب زده‌اند، تجربه و تحصیلاتشان، ابزار و روش، نحوهٔ اصلاح خطاهای خروجی خودکار و سنجش کیفیت نهایی. این‌ها برای اعتبار و بازتولیدپذیری لازم‌اند.

۵.۴ فضای واکه‌ای

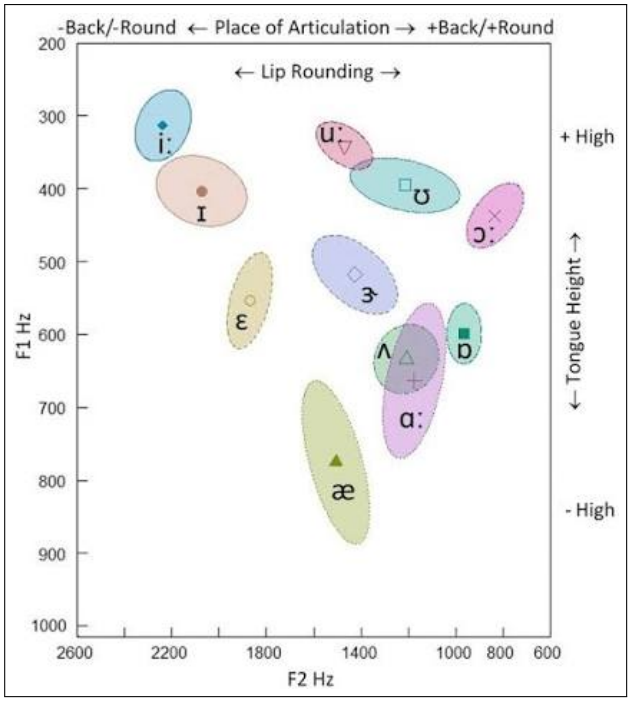
۱.۵.۴ تعریف و نمودار F1–F2

فضای واکه‌ای (Vowel Space)

نمایش هندسی جایگاه واکه‌ها بر پایهٔ ویژگی‌های تولیدی (ارتفاع و جلو یا عقب بودن زبان) یا آکوستیکی. در نمایش آکوستیکی هر واکه نقطه‌ای است با مختصات $V = (F_۱, F_۲)$ و با گردآوری نمونه‌های متعدد، پراکندگی و دامنهٔ

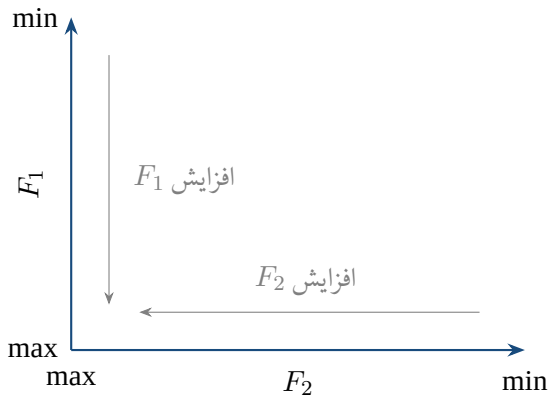
هر واکه دیده می‌شود.

روی تخته دو نقشه مقایسه شد: «نقشهٔ استاندارد و تئوریک الفبای بین‌المللی آواشناسی» که صرفاً توصیفی است، و «نقشهٔ اندازه‌گیری‌شده بر اساس داده‌های آکوستیک Praat»؛ هدف درس رسیدن به نقشهٔ دوم است. شکل ۲.۴ نسخهٔ اندازه‌گیری‌شدهٔ واکه‌های انگلیسی را نشان می‌دهد.



شکل ۲.۴: نقشهٔ اندازه‌گیری‌شدهٔ واکه‌های انگلیسی؛ هر بیضی پراکندگی یک واکه در F1–F2 است. محورها معکوس رسم شده‌اند تا با نقشهٔ نظری (بالا = بسته، چپ = جلو) هم‌خوان باشد. (برگرفته از تختهٔ کلاس)

در نمودار متداول هر دو محور معکوس‌اند: F1 (عمودی) مقدار کم در بالا و F2 (افقی) مقدار زیاد در چپ. نتیجه آن است که نمودار شبیه نقشهٔ تولیدی می‌شود: واکه‌های بسته بالا، باز پایین، جلویی چپ و عقبی راست.



شکل ۳.۴: محورهای معکوس نمودار F1–F2 (بازسازی‌شده از تختهٔ کلاس)

پرسش و پاسخ: آیا F2 را از F1 حدس می‌زنیم؟

نه. هر دو جداگانه از سیگنال اندازه‌گیری می‌شوند و سپس نقطهٔ $V = (F_۱, F_۲)$ روی نمودار قرار می‌گیرد.

۲.۵.۴ واکه‌های زبان فارسی

فارسی معیار شش واکهٔ ساده دارد. جدول زیر (از اسلاید کلاس، بدون ذکر منبع) دامنهٔ تقریبی F1 و F2 را برحسب هرتز نشان می‌دهد.

جدول ۲.۴: دامنهٔ تقریبی فرمنت‌های اول و دوم واکه‌های فارسی (هرتز)؛ جدول ارائه‌شده در کلاس

واکه	نشانه و مثال	F1 مردان	F2 مردان	F1 زنان	F2 زنان
/i/	«ای» (سیب)	۲۷۰ تا ۳۵۰	۲۱۰۰ تا ۲۳۰۰	۳۰۰ تا ۴۵۰	۲۴۰۰ تا ۲۸۰۰
/e/	«ـِ» (دل)	۴۲۰ تا ۵۰۰	۱۸۰۰ تا ۲۱۰۰	۴۸۰ تا ۶۰۰	۲۱۰۰ تا ۲۵۰۰
/æ/	«ـَ» (دست)	۶۰۰ تا ۷۵۰	۱۵۰۰ تا ۱۷۵۰	۷۰۰ تا ۹۰۰	۱۷۰۰ تا ۲۱۰۰
/ɑ/	«آ» (باد)	۶۰۰ تا ۷۰۰	۱۰۰۰ تا ۱۲۰۰	۷۰۰ تا ۸۵۰	۱۱۰۰ تا ۱۴۰۰
/o/	«ـُ» (پل)	۴۲۰ تا ۵۰۰	۸۵۰ تا ۱۰۵۰	۴۸۰ تا ۶۰۰	۹۰۰ تا ۱۲۰۰
/u/	«او» (دود)	۳۰۰ تا ۴۰۰	۷۵۰ تا ۹۵۰	۳۵۰ تا ۴۵۰	۸۰۰ تا ۱۱۰۰

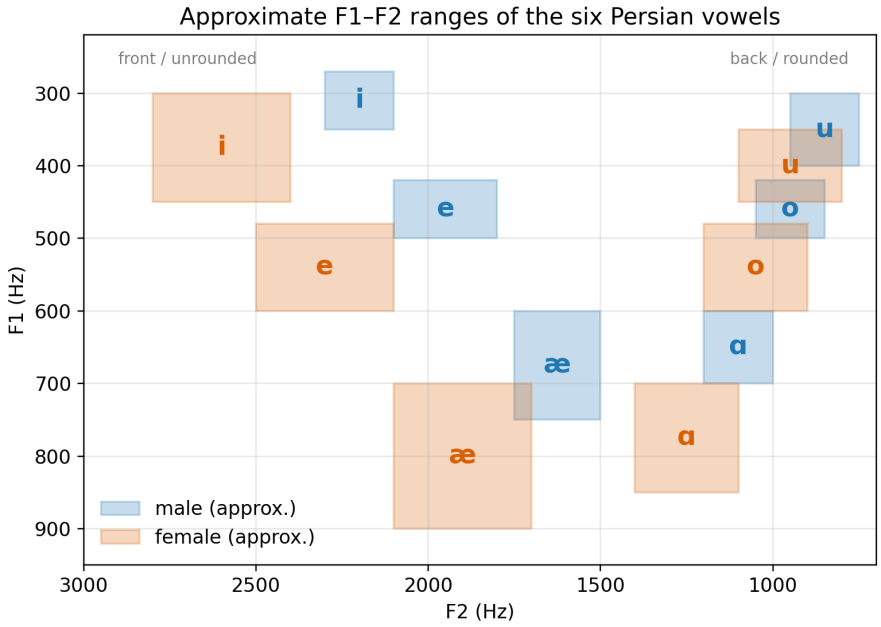
الگو با نگاشت بالا هم‌خوان است: /i/ و /u/ (بسته) کمترین F1 و /æ/ و /ɑ/ (باز) بیشترین F1 را دارند؛ /i/ جلویی‌ترین (بالاترین F2) و /u/ عقبی‌ترین است؛ و مقادیر زنان در همهٔ واکه‌ها بالاتر از مردان است. این دامنه‌ها تقریبی‌اند و به گویش، گوینده، سبک گفتار و روش اندازه‌گیری بستگی دارند؛ آن‌ها را نقطهٔ شروع بدانید، نه مرجع قطعی.

۳.۵.۴ تفاوت فضای واکه‌ای در گروه‌های مختلف

فضای واکه‌ای برای همه یکسان نیست و می‌توان آن را جداگانه برای کودکان و بزرگسالان، زنان و مردان، زبان‌های مختلف و افراد دارای اختلال گفتار استخراج کرد. انتظار داریم رابطهٔ کلی «F1 با ارتفاع و F2 با جلوآمدگی» حفظ شود، اما دامنهٔ عددی و پراکندگی تغییر کند. برای مقایسهٔ بین گویندگان معمولاً فرمنت‌ها نرمال می‌شوند، مثلاً با روش Lobanov: $z = (F - \mu)/\sigma$ برای هر گوینده و هر فرمنت.

۴.۵.۴ مساحت فضای واکه‌ای (VSA)

برای تبدیل «گستردگی فضای واکه‌ای» به یک عدد، مساحت چندضلعی واکه‌های گوشه در نمودار F1–F2 را حساب می‌کنیم (مقالهٔ Sandoval و همکاران، ۲۰۱۳: چهار واکهٔ گوشه یا سه واکهٔ /a, i, u/ برای مثلث، با اندازه‌گیری در ۵۰ درصد مدت واکه و میانگین‌گیری). VSA نمایندهٔ آکوستیکی جابه‌جایی اندام‌های گفتار است و در گفتار واضح‌تر بزرگ‌تر است.



شکل ۴.۴: نمودار F1–F2 شش واکهٔ فارسی بر پایهٔ جدول بالا؛ مستطیل‌ها دامنهٔ مردان (آبی) و زنان (نارنجی) را نشان می‌دهند. محورها معکوس و مقادیر تقریبی‌اند (شکل افزوده).

محاسبهٔ VSA با فرمول شوله‌یس (Shoelace)

اگر رأس‌های چندضلعی با ترتیب پیرامونی $(F_{۲,k}, F_{۱,k})$ باشند:

$$\mathrm{VSA} = \frac{۱}{۲}\left|\sum_{k=۱}^{n}\left(F_{۲,k}\,F_{۱,k+۱} - F_{۲,k+۱}\,F_{۱,k}\right)\right| \quad (\mathrm{Hz}^{۲}), \qquad k = n+۱ \equiv ۱.$$

برای مثلث (i, a, u):

$$\mathrm{VSA}_{\triangle} = \frac{۱}{۲}\left|F_{۱,i}(F_{۲,a}-F_{۲,u}) + F_{۱,a}(F_{۲,u}-F_{۲,i}) + F_{۱,u}(F_{۲,i}-F_{۲,a})\right|.$$

[محتوای افزوده] مثال عددی: VSA مثلثی مردان فارسی‌زبان

مرکز دامنه‌های جدول مردان: /i/ با $(F_۱, F_۲) = (۳۱۰,\ ۲۲۰۰)$، /ɑ/ با $(۶۵۰,\ ۱۱۰۰)$ و /u/ با $(۳۵۰,\ ۸۵۰)$ هرتز.

$$\begin{aligned}\mathrm{VSA}_{\triangle} &= \tfrac{۱}{۲}\left|۳۱۰(۱۱۰۰-۸۵۰) + ۶۵۰(۸۵۰-۲۲۰۰) + ۳۵۰(۲۲۰۰-۱۱۰۰)\right| \\ &= \tfrac{۱}{۲}\left|۷۷\,۵۰۰ - ۸۷۷\,۵۰۰ + ۳۸۵\,۰۰۰\right| = ۲۰۷\,۵۰۰\ \mathrm{Hz}^{۲}.\end{aligned}$$

اثر متمرکزشدن: اگر هر فاصله از مرکز ثقل ۲۰ درصد کم شود (ضریب ۰٫۸)، چون مساحت با مربع ضریب مقیاس عوض می‌شود، مساحت جدید $۱۳۲\,۸۰۰\ \mathrm{Hz}^{۲} = ۲۰۷\,۵۰۰ \times ۰٫۸^{۲}$ است، یعنی حدود ۳۶ درصد کاهش. پس VSA به متمرکز شدن واکه‌ها حساس است. (شاخص نسبتی VAI از Sapir و همکاران ۲۰۱۰ برای کاهش وابستگی به اندازهٔ مجرا پیشنهاد شده و با متمرکزشدن کاهش می‌یابد.)

۶.۴ همخوان‌ها در اسپکتروگرام

یکی از دانشجویان پرسید آیا این تحلیل فقط برای واکه‌هاست. پاسخ استاد: همخوان‌ها هم ویژگی‌های آکوستیکی خاص خود را دارند و در اسپکتروگرام قابل بررسی‌اند، اما تمرکز فعلی روی واکه‌هاست.

تمرین پیشنهادی استاد

بررسی کنید همخوان‌ها چگونه در اسپکتروگرام دیده می‌شوند و آیا با آواشناسی تولیدی هماهنگ‌اند. روی تخته: اسپکتروگرام با **سکوت** (شیوهٔ تولید) و نحوهٔ **خم‌شدن و جهش فرمنت‌ها** و **مرکز فرکانسی نویز** (جایگاه تولید)، حرکات فیزیکی اندام‌های گفتاری را کدگذاری می‌کند. به‌خصوص این موارد را ببینید:

- سکوت یا انسداد پیش از برخی همخوان‌ها؛
- انفجار (Burst) در انسدادی‌هایی مانند /b/ و /p/؛
- تغییر شکل فرمنت‌ها هنگام گذار از همخوان به واکه (Formant Transitions).

۷.۴ کاربردهای فضای واکه‌ای

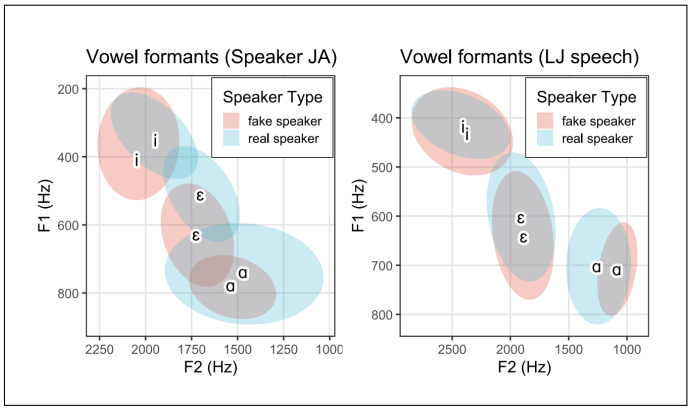
استاد از دانشجویان پرسید فضای واکه‌ای چه کاربردی دارد. پاسخ‌های اولیه (تشخیص واکه، پیش‌پردازش) کافی نبود: فضای واکه‌ای قبل از هر چیز ابزار تحلیل ساختار تولید گفتار، مقایسهٔ گروه‌ها و شناسایی الگوهای متفاوت است. سه کاربرد اصلی روی تخته بود.

۱.۷.۴ گفتاردرمانی و بازخورد زیستی تصویری

در **بیوفیدبک تصویری** (Visual Biofeedback) برای کودکان دارای اختلال گفتار، ناشنوایان یا افراد مبتلا به سندرم داون، نمایشگری زنده نقطهٔ F1–F2 گفتار فرد را نشان می‌دهد و او می‌کوشد آن را با حرکت زبان به ناحیهٔ هدف برساند. مزیت: بازخورد از حالت صرفاً شنیداری به دیداری درمی‌آید. در گفتار کودکان و زنان (f_0 بالا) تخمین فرمنت ناپایدار است، پس بهتر است هدف را یک ناحیه (بیضی دامنهٔ واکه) بگیریم، نه نقطه.

۲.۷.۴ تشخیص صدای جعلی (Deepfake)

صدای سنتزشده می‌تواند برای گوش طبیعی باشد، اما این به معنای یکسان‌بودن همهٔ ویژگی‌های آکوستیکی و تولیدی با گفتار واقعی نیست. ایده: فرمنت‌های واکه‌ها را برای نمونهٔ واقعی و سنتزشده استخراج و فضای واکه‌ای (و هم‌بستگی الگوی تغییر F1 و F2) را مقایسه کنیم. روی تخته: «تفاوت‌های بیومکانیکی در تلفظ مصوت‌ها بهترین ردپای مصنوعی‌بودن صدا هستند».



شکل ۵.۴: بیضی‌های F1–F2 چند واکه در صدای واقعی (آبی) و جعلی (قرمز) برای دو گوینده/پیکره، از مقالهٔ Conditional Speaker Normalization of Vocal Tract Shape Features for Robust Synthetic Speech Detection (IEEE Access، ۲۰۲۶) (برگرفته از تختهٔ کلاس)

«اثبات» جعل؟

این روش‌ها شواهد آماری تولید می‌کنند، نه اثبات قطعی؛ در نمودار هم بسیاری از بیضی‌های واقعی و جعلی هم‌پوشانی زیادی دارند. استاد تأکید کرد گزارهٔ کلی «فرمنت‌ها فرق دارند» برای پژوهش کافی نیست؛ باید معلوم شود: (۱) دقیقاً کدام ویژگی تفاوت دارد، (۲) چگونه اندازه‌گیری می‌شود، (۳) آیا تکرارپذیر است، (۴) آیا تفکیک قابل‌اعتماد می‌دهد.

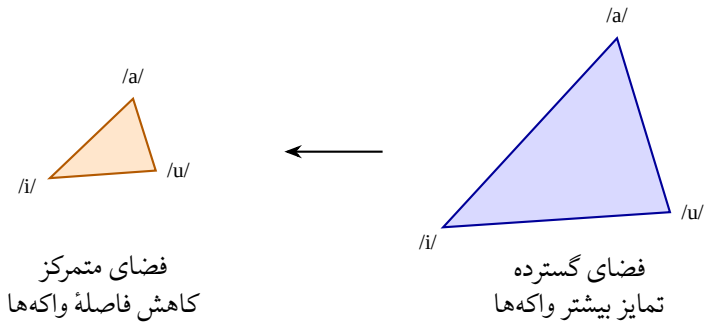
مقاوم‌سازی مدل (Robustness): اگر نقاط ضعف مدل را بشناسیم (مثلاً ضعف در برخی واکه‌ها)، از همان داده‌ها بیشتر جمع می‌کنیم؛ روش‌های مرتبط: Data Augmentation، Hard Example Mining و Adversarial Training. تحلیل فضای واکه‌ای می‌تواند یکی از راه‌های شناسایی این نقاط باشد.

۳.۷.۴ نشانگر زیستی دیجیتال (Digital Biomarker)

نشانگر زیستی دیجیتال

ویژگی قابل‌اندازه‌گیری‌ای که با ابزارهای دیجیتال به دست می‌آید و دربارهٔ وضعیت یا تغییرات یک فرایند زیستی یا بالینی اطلاعات می‌دهد؛ مثلاً ویژگی‌های آکوستیکی گفتار برای دنبال‌کردن بیماری‌های عصبی مانند پارکینسون و دمانس.

در این بیماری‌ها F1 و F2 واکه‌ها به سمت مرکز فضای صوتی جمع می‌شوند (**متمرکزشدن** (Centralization)) و مساحت فضای واکه‌ای کوچک می‌شود. اندازه‌گیری مکرر در طول زمان می‌تواند تغییراتی را نشان دهد که شنوندهٔ عادی هنوز نمی‌شنود. روند پایش: ضبط دوره‌ای واکه‌ها یا جمله‌های ثابت ← استخراج فرمنت ← ساخت فضای واکه‌ای و اندازه‌گیری گستردگی ← مقایسه با نمونه‌های قبلی همان فرد ← در صورت تغییر قابل‌توجه، ارجاع به متخصص. استاد ایدهٔ سامانه‌ای مبتنی بر **تلفن همراه** برای این پایش را مطرح کرد. (مقالهٔ Sandoval الگوریتمی برای تخمین خودکار VSA از گفتار پیوسته ارائه می‌کند.)



شکل ۶.۴: نمایش شماتیک متمرکزشدن فضای واکه‌ای: مثلث واکه‌ها کوچک می‌شود و به مرکز نزدیک می‌شود (شکل افزوده).

نشانگر زیستی دیجیتال ابزار تشخیص قطعی نیست

شواهد پژوهشی کاهش VSA یا VAI را در برخی افراد مبتلا به پارکینسون و سایر دیزآرتری‌های حرکتی نشان می‌دهند، ولی اثر آن در همهٔ بیماران و مراحل یکسان نیست و برای دمانس شواهد ضعیف‌تر است. این شاخص‌ها به‌تنهایی تشخیص قطعی نیستند و به اعتبارسنجی بالینی و تفسیر متخصص نیاز دارند؛ سن، جنس، خستگی، کیفیت میکروفون و نویز نیز VSA را تغییر می‌دهند.

۸.۴ جمع‌بندی

با اندازه‌گیری F1 و F2 در Praat می‌توان بازنمایی‌ای از الگوی تولید واکه‌ها ساخت. با برچسب‌گذاری TextGrid و بازهٔ هر واکه، جدول فرمنت‌ها برای هر گروه تهیه و در نمودار F1–F2 با محورهای معکوس فضای واکه‌ای شکل می‌گیرد. این بازنمایی امکان مقایسهٔ گروه‌ها، گفتاردرمانی تصویری، تشخیص صدای مصنوعی و پایش تغییرات گفتار را می‌دهد، اما همهٔ این کاربردها اعتبارسنجی دقیق و تفسیر محتاطانه می‌خواهند.

نکات مهم برای مرور و امتحان

مفهوم	نکتهٔ اصلی
فرکانس پایه و Magnitude	$f_۰ = ۱/T$، مربوط به منبع؛ Magnitude اندازهٔ ضریب فوریه است، نه دامنهٔ زمانی
تعامد و هارمونیک‌ها	ضرب داخلی صفر؛ هارمونیک‌ها مضرب‌های صحیح $f_۰$ (موج مربعی: فقط فرد)
فرمنت‌ها	نواحی تشدید مجرا (فیلتر)؛ تخمین با LPC
Wideband / Narrowband	تفکیک زمانی (فرمنت) در برابر تفکیک فرکانسی (هارمونیک)
F1 و F2	F1 معکوس با ارتفاع زبان؛ F2 مستقیم با جلو آمدن زبان و کاهش‌یافته با گردی لب
Praat و TextGrid	ضبط، تحلیل و استخراج فرمنت؛ لایه‌های Word، Syllable، Phoneme
فضای واکه‌ای	نمودار F1–F2 با هر دو محور معکوس؛ برای هر گروه جداگانه
ASR + بازبینی انسانی	ساخت سریع‌تر پیکره؛ مستندسازی برچسب‌گذاری ضروری
VSA	مساحت چندضلعی واکه‌های گوشه؛ کوچک‌شدن = متمرکزشدن
کاربردها	گفتاردرمانی (بیوفیدبک تصویری)، تشخیص جعل، نشانگر زیستی دیجیتال

زنجیره‌جلسه: سیگنال صوتی ← ویژگی‌های آکوستیکی (Pitch، طیف، فرمنت) ← اندازه‌گیری F2/F1 در Praat ← ساخت فضای واکه‌ای ← مقایسه با مرجع یا گروه‌های دیگر ← کاربردهای پژوهشی و عملی.

فصل ۵

ادراک شنیداری، مقیاس مل و ضرایب MFCC

تا اینجا سیگنال گفتار را از دید فیزیکی بررسی کردیم (شکل موج، فوریه، هارمونیک، فرمنت، فضای واکه‌ای) و طیفی دیدیم که همهٔ فرکانس‌ها را یکسان می‌دید. در این جلسه ویژگی‌های **سیستم شنوایی انسان** (Human Auditory System) را وارد استخراج ویژگی می‌کنیم. حاصل کار مقیاس مل، بانک فیلتر مل، لگاریتم و در نهایت **ضرایب کپسترال فرکانس مل** (Mel-Frequency Cepstral Coefficients) یا MFCC است که در جلسات بعد هم بارها به آن برمی‌گردیم.

نقشهٔ راه جلسه

(۱) چرا شنوایی را مدل کنیم؟ (۲) نقشهٔ تونوتوپیک حلزون؛ (۳) مقیاس مل و بانک فیلتر مثلثی؛ (۴) لگاریتم برای ادراک غیرخطی بلندی؛ (۵) افزونگی ویژگی‌ها، DCT و پیدایش MFCC؛ (۶) کپستروم؛ (۷) کاربردها و رابطهٔ MFCC با یادگیری ماشین.

۱.۵ چرا باید ادراک شنیداری انسان را در نظر بگیریم؟

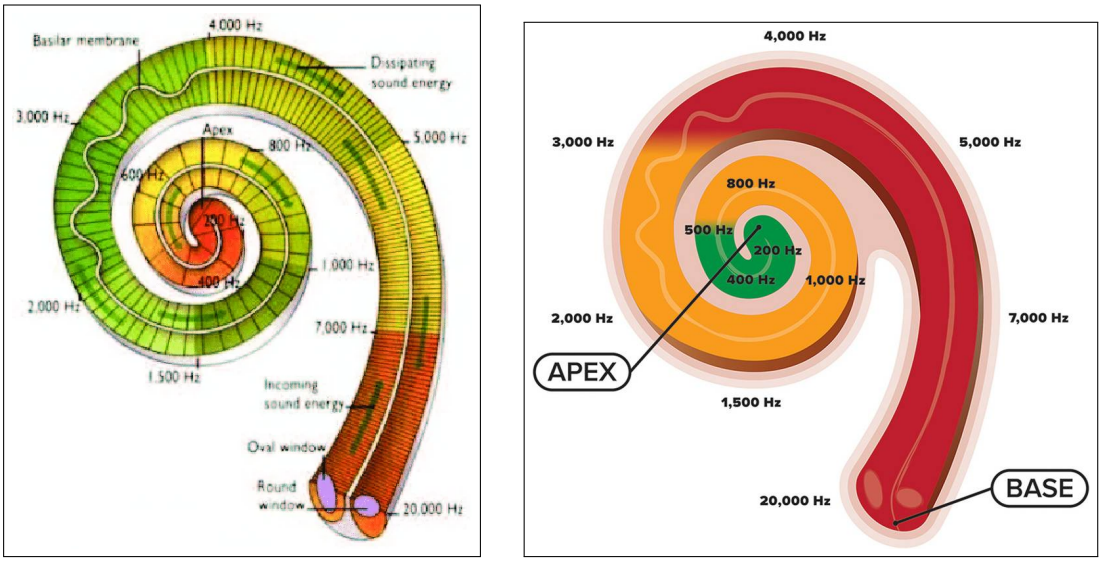
تبدیل فوریه می‌گوید هر مؤلفهٔ فرکانسی چه سهمی دارد، بی‌آنکه بپرسد انسان کدام فرکانس‌ها را بهتر تشخیص می‌دهد. انسان جوان و سالم صداهایی را در حدود ۲۰ **هرتز تا** ۲۰ **کیلوهرتز** می‌شنود، و باید دو چیز را از هم جدا کرد:

- **وجود فیزیکی ارتعاش**: پدیده‌ای که طبق قوانین فیزیک رخ می‌دهد؛
- **ادراک شنیداری ارتعاش**: فرایندی که ارتعاش را از دستگاه شنوایی عبور می‌دهد و در مغز به تجربهٔ شنیدن تبدیل می‌کند.

مثال کلاس از بینایی: چراغی که با فرکانس بسیار زیاد چشمک می‌زند را پیوسته روشن می‌بینیم، هرچند از نظر فیزیکی همچنان خاموش و روشن می‌شود.

۲.۵ نقشهٔ تونوتوپیک حلزون گوش

صدا از گوش خارجی و میانی می‌گذرد و در **حلزون گوش** (Cochlea) موجی روی **غشای پایه** (Basilar Membrane) پدید می‌آورد. نقاط مختلف این غشا به فرکانس‌های مختلف حساس‌اند؛ به این سازمان‌دهی **نقشهٔ تونوتوپیک** (Tono-topic Map) می‌گویند.



شکل ۱.۵: نقشهٔ تونوتوپیک حلزون گوش. رأس (Apex) مربوط به فرکانس‌های بم و قاعده (Base) نزدیک دریچه‌های بیضی و گرد مربوط به فرکانس‌های زیر است. (برگرفته از تختهٔ کلاس)

دقت در خواندن شکل

عدد نزدیک رأس (حدود ۲۰۰ هرتز) حد پایین واقعی شنوایی نیست؛ شنوایی تا حدود ۲۰ هرتز ادامه دارد. همچنین فاصلهٔ مکانی روی غشای پایه تقریباً با لگاریتم فرکانس متناسب است (نه خطی)؛ همین ریشهٔ فیزیولوژیک مقیاس مل است.

۱.۲.۵ تفکیک نابرابر فرکانس‌های بم و زیر

ادراک تغییرات فرکانسی خطی نیست. دو تغییر ۲۰۰ → ۱۰۰ هرتز و ۵۲۰۰ → ۵۱۰۰ هرتز هر دو ۱۰۰ هرتز اختلاف دارند، اما اولی برای گوش چشمگیر و دومی تقریباً نامحسوس است؛ یعنی تفاوت ادراکی به محدودهٔ فرکانسی هم بستگی دارد، نه فقط به اختلاف عددی. مثال‌های کلاس: تغییر کوچک در صدای موتور (فرکانس پایین) به‌سادگی شنیده می‌شود، ولی تغییر کوچک فرکانس یک سوت (فرکانس بالا) دشوارتر. گوش در فرکانس‌های پایین (زیر حدود ۱۰۰۰ هرتز) بسیار دقیق است و در فرکانس‌های بالا (بالای حدود ۴۰۰۰ هرتز) کمتر.

دقت علمی

در فرکانس‌های بالا تفکیک گوش تقریباً نسبت‌محور است. تغییر ۱۰۰ هرتز در ۵ کیلوهرتز برای شنوندهٔ آموزش‌دیده هنوز قابل‌تشخیص است؛ درست‌تر این است که از نظر ادراکی بسیار کوچک‌تر از تغییر ۱۰۰ به ۲۰۰ هرتز به‌نظر

می‌رسد. مقیاس مل همین را مدل می‌کند.

پیامد: در فرکانس‌های پایین بازه‌های باریک و در بالا بازه‌های پهن‌تر می‌خواهیم؛ این مبنای مقیاس مل است.

۳.۵ مرور سه ویژگی Pitch، Formant و Intensity در Praat

استاد روی یک سیگنال در Praat (فرمنت‌ها: نقطه‌های قرمز؛ pitch: خط آبی؛ شدت: خط زرد) سه ویژگی را مرور کرد:

- **فرمنت** (Formant): نواحی تشدید طیفی (F_1، F_2، F_3) که برای ساخت فضای واکه‌ای به کار رفتند.
- **پیچ** (Pitch): ادراک زیر و بمی؛ با فرکانس پایه F_0 (کمیت فیزیکی، تناوب سیگنال) مرتبط است ولی با آن یکی نیست.
- **شدت** (Intensity): معیار قدرت کلی صوت در هر لحظه (فریاد: شدت زیاد، صحبت آرام: شدت کم).

جدول ۱.۵: کمیت‌های فیزیکی و ادراکی که باید از هم جدا نگه داشته شوند.

کمیت فیزیکی	کمیت ادراکی	توضیح
فرکانس پایه (F_0)	زیر و بمی (Pitch)	تناوب موج در برابر احساس زیر/بم
شدت (Intensity)	بلندی (Loudness)	توان فیزیکی در برابر بلندی احساس‌شده
فرمنت‌ها / شکل طیف	رنگ صدا (Timbre)	تشدیدهای مجرای صوتی

زیر و بمی با بلندی یکی نیست: می‌توان با صدای زیر ولی آرام، یا بم و پرشدت صحبت کرد.

پرسش و پاسخ: چرا خط pitch گاهی بالاتر از نقطه‌های فرمنت است؟

چون این نمودارها با محورهای مختلف (یک مقیاس برای pitch، یکی برای فرمنت) روی یک تصویر رسم می‌شوند؛ بالاتر بودن خط روی صفحه دلیل بزرگ‌تر بودن مقدار فرکانسی نیست. نحوهٔ محاسبهٔ کانتور این ویژگی‌ها جلسهٔ بعد بررسی می‌شود.

۴.۵ کم‌شنوایی فرکانس‌های بالا با افزایش سن

چون قاعدهٔ حلزون به فرکانس‌های بالا مربوط است، آسیب به آن شنیدن صداهای زیر را کم می‌کند؛ کم‌شنوایی فرکانس‌های بالا در سنین بالا رایج است و **پیرگوشی** (Presbycusis) نام دارد. توضیح کلاس: سلول‌های ناحیهٔ قاعده در «خط مقدم» ضربه‌های مکانیکی‌اند و زودتر تحلیل می‌روند.

دقت علمی

الگوی کلی درست است، اما علت آن چندعاملی است (از دست رفتن سلول‌های مویی، تحلیل رگ‌ها، نورون‌های عصب شنوایی، نویز، ژنتیک و غیره)؛ توضیح کلاس را «سازوکارهای محتمل» بدانید نه علت قطعی. نمونهٔ عملی: همخوان‌های بی‌واک مانند /s/ و /f/ انرژی‌شان در فرکانس‌های بالاست و برای افراد دچار پیرگوشی سخت‌تر تفکیک می‌شوند.

۵.۵ مقیاس مل

مقیاس مل

مقیاس مل (Mel Scale) یک **نگاشت غیرخطی** از فرکانس فیزیکی (هرتز) به مقیاس ادراکی (مل) است که فرکانس‌های بالا را «فشرده» می‌کند تا فاصله‌های برابر روی محور مل تقریباً با تفاوت‌های ادراکی برابر در زیر و بمی متناظر باشند. نام آن از melody گرفته شده است.

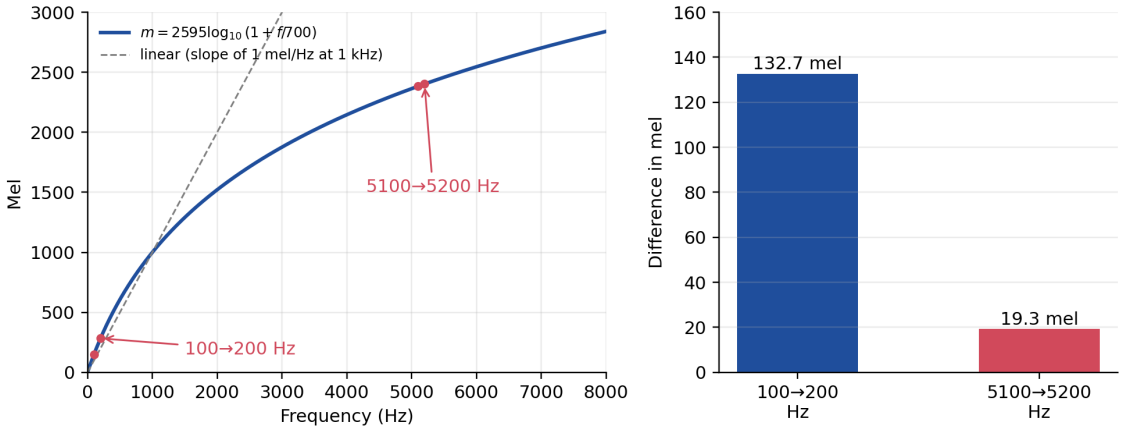
فرمول مقیاس مل

مقیاس مل را استیونز، فولکمن و نیومن (۱۹۳۷) از آزمایش‌های قضاوت زیر و بمی معرفی کردند. رایج‌ترین تقریب تحلیلی (که در کلاس به‌صورت عددی بیان نشد):

$$m = ۲۵۹۵ \log_{۱۰}\left(۱ + \frac{f}{۷۰۰}\right) \qquad \Longleftrightarrow \qquad f = ۷۰۰\left(۱۰^{\,m/۲۵۹۵} - ۱\right).$$

۱۰۰۰ هرتز به ۱۰۰۰ مل نگاشت می‌شود. قراردادهای دیگری هم وجود دارد (مثلاً نسخهٔ اسلینی)، پس خروجی کتابخانه‌ها ممکن است اندکی فرق کند.

تابع در فرکانس‌های پایین (زیر حدود ۱ کیلوهرتز) تقریباً خطی و در فرکانس‌های بالاتر لگاریتمی است.



شکل ۲.۵: چپ: منحنی تبدیل هرتز به مل. راست: همان دو تغییر ۱۰۰ هرتزی در مقیاس مل (۱۳۲٫۷ مل در برابر ۱۹٫۳ مل). (شکل افزوده)

[محتوای افزوده] مثال عددی: تبدیل هرتز به مل

f (هرتز)	۱۰۰	۲۰۰	۱۰۰۰	۲۰۰۰	۵۱۰۰	۸۰۰۰
m (مل)	۱۵۰٫۵	۲۸۳٫۲	۱۰۰۰٫۰	۱۵۲۱٫۴	۲۳۸۳٫۱	۲۸۴۰٫۰

بازهٔ ۰ تا ۸ کیلوهرتز فقط به حدود ۲۸۴۰ مل نگاشت می‌شود و نیمی از آن (۰ تا ۱۴۲۰ مل) زیر حدود ۱۷۶۰ هرتز است؛ یعنی مل به فرکانس‌های پایین «فضای بیشتری» می‌دهد.

۶.۵ بانک فیلتر مل

بانک فیلتر مل (Mel Filterbank) مجموعه‌ای از فیلترهای مثلثی هم‌پوشان روی محور فرکانس است. هر فیلتر یک بازهٔ فرکانسی را پوشش می‌دهد و از آن یک عدد (انرژی آن باند) می‌سازد.

۱.۶.۵ وزن‌دهی مثلثی

وزن هر فیلتر در ابتدای بازه نزدیک صفر، در مرکز بیشینه (معمولاً ۱) و در انتها دوباره صفر است؛ پس فرکانس‌های نزدیک مرکز سهم بیشتری دارند. مقدار طیفی هر فرکانس در وزن متناظر ضرب و حاصل‌ها جمع می‌شوند:

$$S_m = \sum_k H_m[k]\, P[k],$$

که $P[k]$ طیف توان و $H_m[k]$ وزن فیلتر mام است.

مثال عددی کلاس: خروجی یک فیلتر

فیلتری سه مؤلفهٔ طیفی با مقدارهای ۴، ۸ و ۶ و وزن‌های ۰٫۵، ۱ و ۰٫۵ دریافت می‌کند (اعداد آموزشی‌اند):

$$M_۱ = (۴ \times ۰٫۵) + (۸ \times ۱) + (۶ \times ۰٫۵) = ۲ + ۸ + ۳ = ۱۳.$$

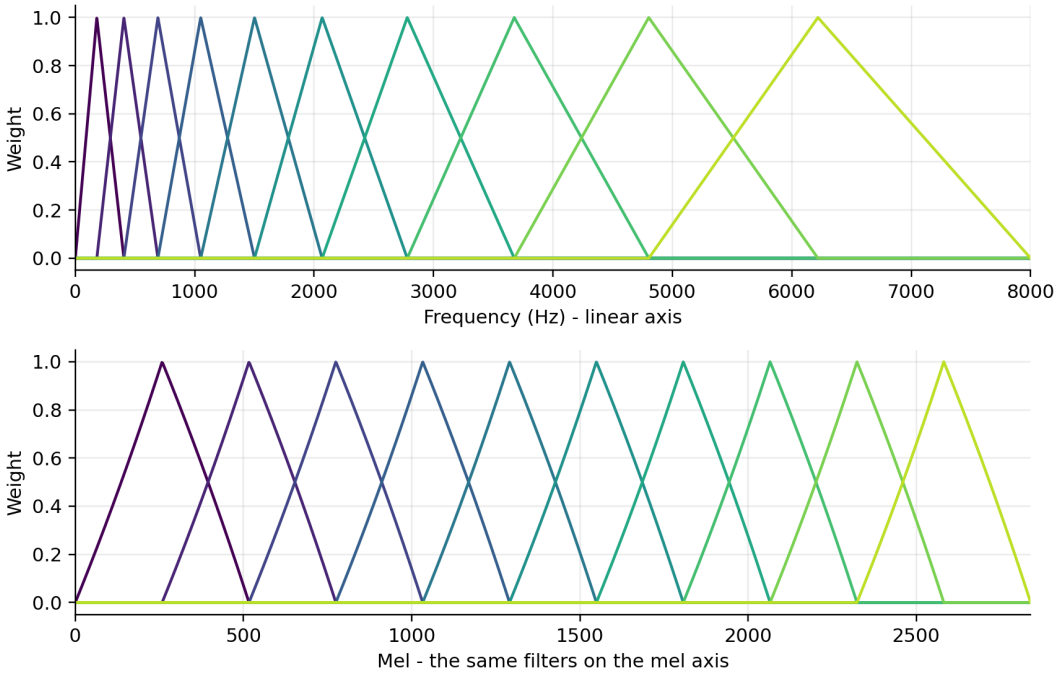
به‌جای سه مقدار، یک عدد داریم؛ این کار برای همهٔ فیلترهای بانک تکرار می‌شود.

۲.۶.۵ چرا فیلترها هم‌پوشان‌اند؟

تا اطلاعات فرکانس‌های نزدیک مرز دو باند ناگهان حذف یا دچار پرش نشود. مثال تخته: اگر مرز دو باند ۳۰۰ هرتز و فیلترها مستطیلی بدون هم‌پوشانی باشند، تغییر ۱ هرتزی (۲۹۹ به ۳۰۱) مؤلفه را ناگهان از یک فیلتر به فیلتر دیگر می‌برد و خروجی‌ها می‌پرند؛ با مثلث‌های هم‌پوشان فقط تغییری هموار و کوچک رخ می‌دهد.

۳.۶.۵ چرا عرض فیلترها یکسان نیست؟

مهم‌ترین نکتهٔ بانک فیلتر مل: روی محور خطی فرکانس، فیلترها در فرکانس‌های پایین باریک و در فرکانس‌های بالا پهن‌اند (دقت در فرکانس‌های بالا کمتر است). دلیل: فیلترها روی محور مل یکسان و هم‌فاصله‌اند و با بازگشت به هرتز در بالا پهن می‌شوند. این همان ایدهٔ نقشهٔ تونوتوپیک است.



شکل ۳.۵: نمونهٔ یک بانک ده‌فیلتری برای بازهٔ ۰ تا ۸ کیلوهرتز. بالا: روی محور خطی هرتز فیلترها به‌تدریج پهن می‌شوند. پایین: همان فیلترها روی محور مل، مثلث‌هایی یکسان و هم‌فاصله‌اند. (شکل افزوده)

۴.۶.۵ تعداد فیلترها

در کلاس: حدود ۴۰ فیلتر مل رایج است و خروجی هر فریم یک بردار ۴۰تایی $\mathbf{M} = [M_1, \ldots, M_{40}]$ است. استاد تأکید کرد ۴۰ مقدار تجربی و متداول است، نه ثابت اجباری.

طیف توان یا اندازه؟

در کلاس گفته شد اندازهٔ خروجی فوریه در مثلث‌ها ضرب می‌شود. هر دو دیده می‌شوند، اما در تعریف استاندارد MFCC فیلترها روی طیف توان (مربع اندازه، «انرژی هر باند») اعمال می‌شوند.

پرسش و پاسخ: آیا با ادغام فرکانس‌ها اطلاعات از دست نمی‌رود؟

چرا، عمداً اطلاعات را خلاصه می‌کنیم. هدف نگه‌داشتن طیف اصلی نیست، ساختن نمایشی مناسب‌تر برای گفتار است: تفکیک ریز فرکانس‌های بالا از دید ادراک اهمیت کمتری دارد و هم‌پوشانی از حذف ناگهانی اطلاعات مرزی جلوگیری می‌کند.

۷.۵ ادراک غیرخطی بلندی صدا و لگاریتم

گوش در شدت هم غیرخطی است: اگر شدت فیزیکی ۱۰۰ برابر شود، صدا را ۱۰۰ برابر بلندتر حس نمی‌کنیم، بلکه فقط چند برابر. این ویژگی به گوش اجازه می‌دهد با گسترهٔ بسیار وسیعی از شدت‌ها کار کند.

برای وارد کردن این ویژگی از خروجی هر فیلتر مل لگاریتم می‌گیریم:

$$L_i = \log(M_i), \qquad \mathbf{L} = [\log M_۱, \dots, \log M_{۴۰}].$$

لگاریتم تغییرات بزرگ را فشرده می‌کند: $\log_{۱۰}(۱۰) = ۱$، $\log_{۱۰}(۱۰۰) = ۲$، $\log_{۱۰}(۱۰۰۰) = ۳$؛ ورودی ۱۰۰ برابر شده ولی خروجی فقط از ۱ به ۳ رسیده است. در کلاس تأکید شد در این مرحله فقط روی شدت لگاریتم می‌گیریم و به زیر و بمی کاری نداریم.

لگاریتم، تقریبی از بلندی؛ نه خود بلندی

لگاریتم مدلی ساده برای فشردگی بلندی است، نه رابطهٔ دقیق آن. قانون توانی استیونز می‌گوید بلندی تقریباً با $I^{۰٫۳}$ متناسب است: ۱۰۰ برابر شدن شدت، بلندی را حدود $۱۰۰^{۰٫۳} \approx ۴$ برابر می‌کند.

لگاریتم صفر!

اگر خروجی فیلتر صفر باشد (مثلاً سکوت دیجیتال)، $\log ۰ = -\infty$ می‌شود. در عمل مقدار کوچک ε اضافه می‌شود: $L_i = \log(M_i + \varepsilon)$.

جدول ۲.۵: دو ادراک غیرخطی شنوایی و راه‌حل‌های متناظر در MFCC.

مسئله	راه‌حل
ادراک غیرخطی تفاوت فرکانس‌ها	مقیاس مل و بانک فیلتر مل
ادراک غیرخطی تغییرات شدت صوت	تبدیل لگاریتمی

۸.۵ افزونگی ویژگی‌ها و تبدیل کسینوسی گسسته

اکنون برای هر فریم ۴۰ عدد داریم، اما چون فیلترهای مجاور هم‌پوشان‌اند، این اعداد هم‌بستگی (Correlation) زیادی دارند و بخشی از اطلاعاتشان تکراری است. می‌خواهیم تعداد ویژگی‌ها را کم کنیم و بخش مهم اطلاعات را نگه داریم.

استاد این مرحله را شهودی «یک تبدیل فوریهٔ دیگر» روی همین ۴۰ عدد توصیف کرد: عملاً **تبدیل کسینوسی گسسته** (Discrete Cosine Transform, DCT). از خروجی آن ۱۲ یا ۱۳ ضریب اول نگه داشته می‌شود و همین‌ها MFCC نام دارند. برای M مقدار لگاریتمی:

$$c_n = \sum_{m=۱}^{M} L_m \cos\!\left(\frac{\pi n\,(m - \tfrac{۱}{۲})}{M}\right), \qquad n = ۰, ۱, \dots, ۱۲.$$

دنبالهٔ L_m مانند «سیگنالی» است که متغیر مستقل آن به‌جای زمان، شمارهٔ فیلتر (فرکانس) است. ضرایب پایین (n کوچک) شکل کلی طیف (پوش) را و ضرایب بالا تغییرات سریع و ریز را توصیف می‌کنند.

چرا DCT هم‌بستگی را کم می‌کند؟

پایه‌های DCT متعامدند و برای دنباله‌های هموار و به‌شدت هم‌بسته تقریب بسیار خوبی از تبدیل کارونن‌لوو (PCA) هستند: بیشتر انرژی در چند ضریب نخست جمع می‌شود و ضرایب تقریباً ناهم‌بسته‌اند. تفاوت با PCA: پایه‌های DCT ثابت‌اند و از داده آموخته نمی‌شوند.

[محتوای افزوده] مثال عددی: فشردگی انرژی با DCT

دنبالهٔ هموار $\mathbf{x} = [۵,\ ۵٫۲,\ ۴٫۹,\ ۸,\ ۸٫۱,\ ۷٫۹]$ (شبیه دنبالهٔ تخته) دو سطح تقریباً ثابت دارد. DCT-II متعامد آن $\mathbf{c} \approx [۱۵٫۹۶,\ -۳٫۲۶,\ ۰٫۰۰,\ ۱٫۲۷,\ -۰٫۲۳,\ -۰٫۹۸]$ است؛ دو ضریب اول حدود ۹۹٪ انرژی را دارند و بازسازی از همین دو ضریب شکل کلی (پایین در ابتدا، بالا در انتها) را حفظ می‌کند. این منطق نگه‌داشتن ۱۲ تا ۱۳ ضریب از ۴۰ مقدار است.

۱.۸.۵ چرا ۱۲ یا ۱۳ ضریب؟

انتخاب تجربی است. تعداد فیلترها (حدود ۴۰) و تعداد ضرایب (۱۲ یا ۱۳؛ گاهی ۵ یا بیشتر) هر دو **ابرپارامتر** (Hyperparameter)اند و بر اساس عملکرد سیستم تنظیم می‌شوند. کاهش از ۴۰ مقدار به ۱۳ ضریب یعنی حدود ۳۲٫۵٪ ابعاد اولیه.

پرسش و پاسخ: آیا انتخاب ۱۲ یا ۱۳ ضریب اثبات ریاضی دارد؟

خیر؛ تجربی است و یک ابرپارامتر قابل‌تنظیم است.

۹.۵ کپستروم و روایت تاریخی تحلیل کپسترال

واژهٔ **کپستروم** (Cepstrum) از جابه‌جایی چهار حرف نخست Spectrum ساخته شده است؛ مفهوم آن در کلاس «طیفِ یک طیف» بود. محور مستقل آن **کوفرنسی** (Quefrency) نام دارد و واحدش از جنس زمان است.

روایت تاریخی کلاس: در جنگ سرد، آمریکا می‌خواست از روی امواج ثبت‌شده تشخیص دهد رویداد زلزله بوده یا آزمایش هسته‌ای شوروی. اعمال تبدیل دوم روی اطلاعات طیفی الگوهایی را آشکار می‌کرد که در طیف اولیه به‌آسانی دیده نمی‌شد. نکتهٔ اصلی: گاهی با تبدیل دوبارهٔ یک نمایش طیفی، اطلاعاتی آشکار می‌شود که در نمایش اولیه پنهان است.

دقت تاریخی

اصل روایت درست است: کپستروم را Bogert، Healy و Tukey در ۱۹۶۳ برای تشخیص پژواک در رکوردهای لرزه‌نگاری معرفی کردند و انگیزهٔ آن با تفکیک زلزله از انفجار مرتبط دانسته می‌شود. اما MFCC را بعدها (۱۹۸۰)

Davis و Mermelstein برای تشخیص گفتار معرفی کردند و ربط مستقیمی با لرزه‌شناسی ندارد. (واژه‌های quefrency، lifter و liftering هنوز به کار می‌روند.)

شهود کپستروم: کپستروم حقیقی $c[n] = \text{IDFT}\{\log|\text{DFT}\{x[n]\}|\}$ است. در گفتار واک‌دار، هارمونیک‌های F_0 در لگاریتم طیف موج‌هایی ریز می‌سازند که در کپستروم به قله‌ای در کوفرنسی $1/F_0$ تبدیل می‌شوند، در حالی که پوش طیف (مجرای صوتی و فرمنت‌ها) در کوفرنسی‌های پایین می‌ماند؛ بدین‌ترتیب منبع و فیلتر از هم جدا می‌شوند.

کپستروم کلاسیک و DCT در MFCC یکسان نیستند

DCT در MFCC نسخه‌ای از همان ایده است، نه دقیقاً همان عمل: در کپستروم کلاسیک از لگاریتم طیف کامل با IDFT تبدیل می‌گیریم، ولی در MFCC ابتدا طیف با بانک فیلتر مل فشرده می‌شود، سپس لگاریتم و DCT. با نگه‌داشتن فقط ضرایب اول، پوش طیف (شکل مجرا، یعنی واج) حفظ می‌شود و MFCC کمتر به F_0 حساس است.

۱۰.۵ مسیر کامل استخراج MFCC

مسیر مفهومی کلاس: سیگنال گفتار ← تبدیل فوریه ← بانک فیلتر مل ← لگاریتم ← DCT ← انتخاب ضرایب اول. در پیاده‌سازی واقعی چند مرحلهٔ دیگر (که فریم‌بندی و پنجره‌گذاری‌شان را از بحث اسپکتروگرام می‌شناسیم) هم افزوده می‌شود:

مراحل پیش‌پردازش در کلاس

فهرست کلاس فقط هستهٔ ادراکی را نشان می‌دهد؛ پیش‌تأکید (فیلتر بالاگذر $y[n] = x[n] - \alpha x[n-1]$ با $\alpha \approx 0.97$)، فریم‌بندی (۲۵ میلی‌ثانیه با گام ۱۰ میلی‌ثانیه)، پنجره‌گذاری همینگ و ضرایب دلتا و دلتا-دلتا (تغییرات زمانی؛ ۱۳+۱۳+۱۳ = بردار ۳۹ بعدی) نیز به‌طور استاندارد جزو زنجیره‌اند. «MFCC ۱۲تایی» یعنی c_1 تا c_{12} و «۱۳تایی» یعنی افزودن c_0 (یا انرژی)؛ این علت دوگانهٔ «۱۲ یا ۱۳» در سخنان استاد است.

جمع‌بندی سه مسئله و راه‌حل در تخته

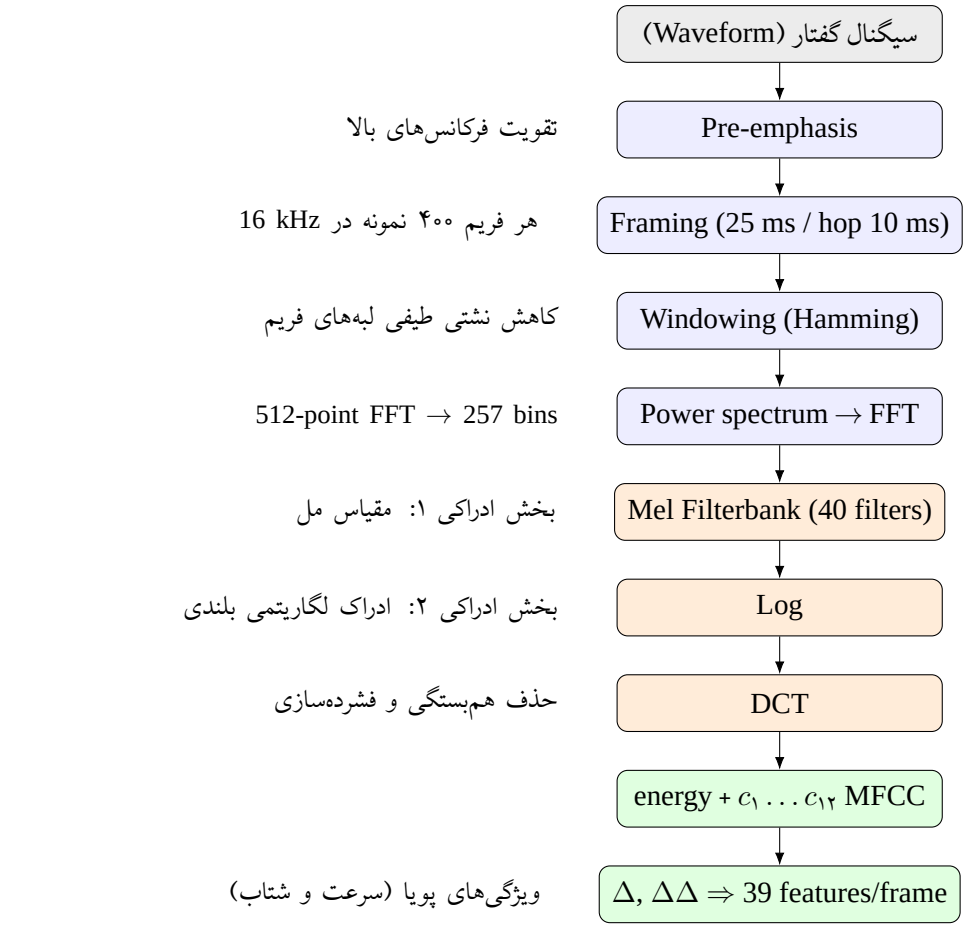
۱. **بانک فیلتر مل**: ادراک غیرخطی فرکانس ⇐ مقیاس مل.

۲. **لگاریتم**: ادراک غیرخطی بلندی (۱۰۰ برابر بلندتر را فقط چند برابر بلندتر حس می‌کنیم) ⇐ لگاریتم انرژی مل.

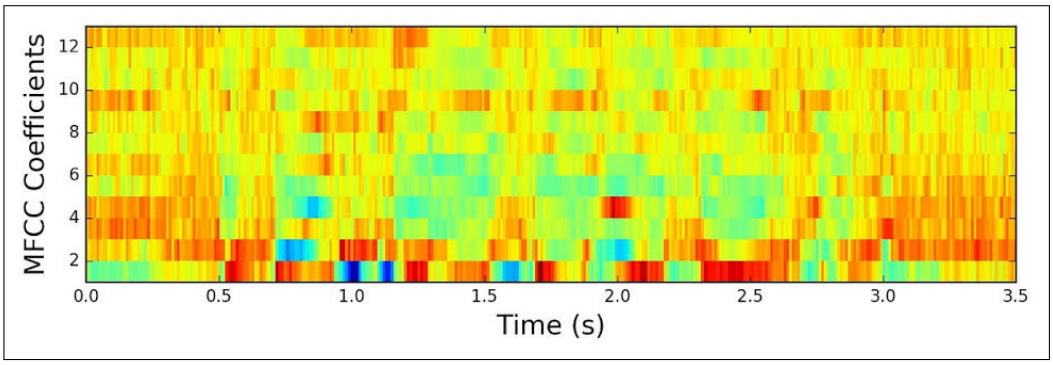
۳. **DCT**: ۴۰ عدد شبیه و تکراری ⇐ DCT و برداشتن ۱۲ تا ۱۳ ضریب اول.

۱۱.۵ کاربردهای MFCC

ماتریس MFCC (برای هر فریم یک بردار ضریب) جایگزین نمایش‌های حجیم‌تر سیگنال می‌شود. کاربردهای مطرح‌شده در کلاس:



شکل ۴.۵: نمودار بلوکی استخراج MFCC تا بردار ویژگی هر فریم. بلوک‌های نارنجی بخش‌هایی‌اند که در این جلسه تدریس شد. (شکل افزوده)



شکل ۵.۵: نمایش ماتریسی MFCC: محور افقی زمان، محور عمودی شمارهٔ ضریب (۱ تا ۱۳) و رنگ مقدار هر ضریب در هر فریم است. (برگرفته از تختهٔ کلاس)

- **مقایسهٔ سیگنال‌ها:** استخراج MFCC دو سیگنال و سنجش شباهت (مثلاً با هم‌بستگی).
- **تحلیل صدای سرفه:** مقایسهٔ سرفهٔ افراد مبتلا به یک بیماری تنفسی (مانند کووید-۱۹) با سایرین و آموزش یک طبقه‌بند؛ نشان می‌دهد MFCC فقط برای تشخیص کلمات نیست.
- **تبدیل گفتار به متن:** به‌جای موج خام، ویژگی‌های آکوستیکی مانند MFCC به مدل داده می‌شود؛ ویژگی‌های دیگر (مثل pitch) در صورت نیاز جداگانه استخراج می‌شوند.

هشدار

استخراج MFCC یا مشاهدهٔ یک هم‌بستگی به‌تنهایی برای تشخیص بیماری کافی نیست؛ داده‌های معتبر، آموزش و ارزیابی مدل لازم است. مقایسهٔ مستقیم MFCC سیگنال‌هایی با طول یا سرعت متفاوت هم به هم‌ترازسازی زمانی (مثلاً DTW) یا خلاصه‌سازی آماری نیاز دارد.

۱۲.۵ MFCC در یادگیری ماشین و یادگیری عمیق

- **آیا استخراج MFCC یادگیری ماشین است؟** استاد تأکید کرد خیر: مجموعه‌ای از عملیات ثابت پردازش سیگنال (طیف، بانک فیلتر، لگاریتم، DCT، انتخاب ضرایب) با پارامترهای مشخص است و به آموزش روی داده نیاز ندارد؛ اما خروجی‌اش را می‌توان به یک مدل یادگیری ماشین داد.
- **مقایسه با PCA** (پرسش دانشجو): از نظر هدف (نمایش فشرده) شبیه‌اند، اما MFCC زنجیرهٔ ثابت تبدیل‌هاست و PCA روشی آماری است که مؤلفه‌ها را از داده می‌آموزد. اگر پس از لگاریتم مل از PCA استفاده شود، دیگر با تعریف متداول MFCC کار نمی‌کنیم.
- **در یادگیری عمیق:** می‌توان MFCC را هم به مدل داد، چون نمایشی ساختاریافته و فشرده است؛ انتخاب میان موج خام، طیف و MFCC به مسئله و عملکرد تجربی بستگی دارد.

روند امروز: log-mel به‌جای MFCC

مدل‌های عصبی امروزی (مانند Whisper) بیشتر از لگاریتم انرژی‌های مل (log-mel) استفاده می‌کنند و DCT را حذف می‌کنند، چون شبکه خودش هم‌بستگی‌ها را می‌آموزد و DCT ترتیب فرکانسی را به هم می‌زند. برخی مدل‌ها (مانند wav2vec 2.0) از موج خام شروع می‌کنند. MFCC همچنان در مدل‌های کلاسیک (GMM-HMM)، مدل‌های سبک و داده‌های کم کاربرد دارد.

۱۳.۵ جمع‌بندی

گوش هم فرکانس را غیرخطی درک می‌کند (نقشهٔ تونوتوپیک، تفکیک بیشتر در بم) و هم شدت را. برای اولی از مقیاس مل و بانک فیلتر مثلثی هم‌پوشان با عرض‌های رشدیابنده و برای دومی از لگاریتم استفاده کردیم. چون ۴۰ انرژی لگاریتمی مل بسیار هم‌بسته‌اند، با DCT به ضرایب کپسترال تبدیل شدند و ۱۲ تا ۱۳ ضریب اول نگه داشته شد:

$$\text{Speech Signal} \to \text{Spectrum} \to \text{Mel Filters} \to \log \to \text{DCT} \to \text{MFCC}.$$

نتیجهٔ اصلی: به‌جای همهٔ اطلاعات طیفی، نمایشی فشرده و مناسب گفتار می‌سازیم که ویژگی‌های ادراکی گوش در طراحی آن لحاظ شده است.

نکات مهم برای مرور و امتحان

۱. تفاوت F_0 با Pitch و تفاوت شدت فیزیکی با بلندی ادراک‌شده را بدانید.

۲. نقشهٔ تونوتوپیک (قاعده ⇔ فرکانس بالا، رأس ⇔ فرکانس پایین) و پیامد آن (کم‌شنوایی فرکانس بالا با سن) را بشناسید.

۳. توضیح دهید چرا ادراک فرکانس خطی نیست (۱۰۰ تا ۲۰۰ در برابر ۵۱۰۰ تا ۵۲۰۰ هرتز)؛ فرمول $m = ۲۵۹۵ \log_{۱۰}(۱ + f/۷۰۰)$.

۴. بدانید چرا عرض فیلترهای مل در فرکانس‌های بالا بیشتر می‌شود، و هم‌پوشانی و وزن‌دهی مثلثی را توضیح دهید؛ خروجی یک فیلتر را حساب کنید (مثال $M_۱ = ۱۳$).

۵. دلیل لگاریتم از انرژی فیلترها را توضیح دهید.

۶. نقش DCT (کاهش هم‌بستگی و فشرده‌سازی) و دلیل نگه‌داشتن ۱۲ یا ۱۳ ضریب را بدانید؛ تعداد فیلترها (حدود ۴۰) و ضرایب ابرپارامترند، نه اجباری.

۷. مسیر استخراج MFCC را از سیگنال تا ضرایب نهایی شرح دهید.

۸. MFCC (زنجیرهٔ ثابت پردازش سیگنال) را با PCA (یادگیری از داده) مقایسه کنید.

۹. معنای واژهٔ کپستروم (جابه‌جایی حروف Spectrum، «طیفِ طیف») را بدانید.

فصل ۶

پروسودی و ویژگی‌های زبرزنجیری گفتار

در جلسات پیشین گفتار را از دید «چه گفته شد؟» بررسی کردیم: واج‌ها، فرمنت‌ها و MFCC. این جلسه به پرسش مکمل می‌پردازد: «چگونه گفته شد؟». دو گوینده می‌توانند دقیقاً یک دنبالهٔ واجی را بگویند، اما یکی آن را خبری و دیگری پرسشی، با اطمینان یا با تردید، سریع یا آهسته ادا کند. این لایهٔ دوم را **پروسودی** (Prosody) می‌نامیم.

۱.۶ مرور کوتاه جلسهٔ قبل

مراحل MFCC روی هر قاب کوتاه: تبدیل فوریه و طیف توان ← بانک فیلتر مل ← لگاریتم انرژی هر فیلتر ← DCT ← نگه‌داشتن چند ضریب نخست (مثلاً ۱۲). فیلترهای مل در فرکانس‌های پایین باریک و در فرکانس‌های بالا پهن‌ترند. تعداد خروجی‌های بانک فیلتر برابر تعداد فیلترهاست (مثلاً ۴۰)، ولی تعداد ضرایب نگه‌داشته‌شده (مثلاً ۱۲) انتخاب جداگانهٔ طراح است؛ این دو الزاماً برابر نیستند.

گام چهارم MFCC تبدیل فوریهٔ دوباره نیست

در توضیح شفاهی کلاس از «تبدیل مجدد» سخن رفت. در روش استاندارد، این گام **تبدیل کسینوسی گسسته** (DCT) است که روی لگاریتم انرژی‌های بانک فیلتر اعمال می‌شود و ضرایبی کم‌هم‌بسته‌تر می‌دهد.

MFCC و مدل منبع-فیلتر. در مدل **منبع-فیلتر** (Source–Filter)، منبع (برای گفتار واک‌دار) ارتعاش تارهای صوتی با فرکانس پایهٔ F_0 است و فیلتر کل مجرای صوتی از حنجره تا لب (نه فقط دهان، فک و دندان). MFCC عمدتاً شکل طیفی و ویژگی‌های فیلتر را نگه می‌دارد و اطلاعات دقیق منبع، مثل F_0 و زیر و بمی، در آن تضعیف یا حذف می‌شود؛ زیرا فیلترهای مل ساختار هارمونیک را هموار می‌کنند و ضرایب نخست فقط پوش کند طیف را نگه می‌دارند. پس MFCC برای تشخیص واج و طبقه‌بندی مناسب است (مثلاً طبقه‌بندی صدای سالم و بیمار، یا ورودی CNN)، اما برای مطالعهٔ آهنگ جمله کافی نیست؛ این انگیزهٔ بحث پروسودی است.

مرور «آ» و «اَ». تفاوت این دو واکه مربوط به **فیلتر** است، نه منبع: هر دو واک‌دارند و منبع یکسانی دارند، ولی موقعیت زبان فرق می‌کند و فرمنت‌ها جابه‌جا می‌شوند. هر دو زبان پایینی‌اند (F_1 نسبتاً بالا)، اما «آ» عقبی است و «اَ» جلویی، پس F_2 در «اَ» بالاتر است.

نکتهٔ امتحانی

هرچه زبان پایین‌تر باشد F_1 بالاتر است؛ هرچه زبان جلوتر باشد F_2 بالاتر است. باید بتوانید با F_1 و F_2 دربارهٔ ارتفاع و موقعیت افقی زبان در تولید واکه‌ها توضیح بدهید.

۲.۶ پروسودی چیست؟

پروسودی (نوای گفتار)

پروسودی (Prosody) مجموعهٔ ویژگی‌هایی از گفتار است که روی دنبالهٔ آواها و واژه‌ها «سوار» می‌شوند و به آن‌ها آهنگ، ریتم، تکیه و الگوی زمانی می‌دهند. پروسودی نشان می‌دهد **چگونه** گفته شده است، نه فقط **چه** گفته شده است.

مثال: «رفتی.» (خبری)، «رفتی؟» (پرسشی) و «رفتی!» (تعجب): واج‌ها یکسان، اما معنا و نیت گوینده متفاوت است. علائم نگارشی بخشی از این اطلاعات را در متن نشان می‌دهند، ولی تصویر کامل پروسودی در متن نیست و باید سیگنال صوتی را تحلیل کرد.

قیاس با عروض. استاد برای نشان دادن «لایه‌ای» بودن پروسودی به عروض اشاره کرد: شعر علاوه بر واژه و معنا روی یک الگوی وزنی (هجاهای کوتاه و بلند) سوار است، مثلاً «به نام خداوند جان و خرد» با الگوی «فعولن فعولن فعولن فعل». برای تحلیل وزن، معنای واژه‌ها اهمیتی ندارد؛ دو عبارت با معنای کاملاً متفاوت می‌توانند وزن یکسان داشته باشند. در گفتار عادی هم واج‌ها یک لایه‌اند و نحوهٔ بیان آن‌ها لایهٔ دیگر. (درس وارد تقطیع شعر نمی‌شود؛ این فقط یک قیاس است.)

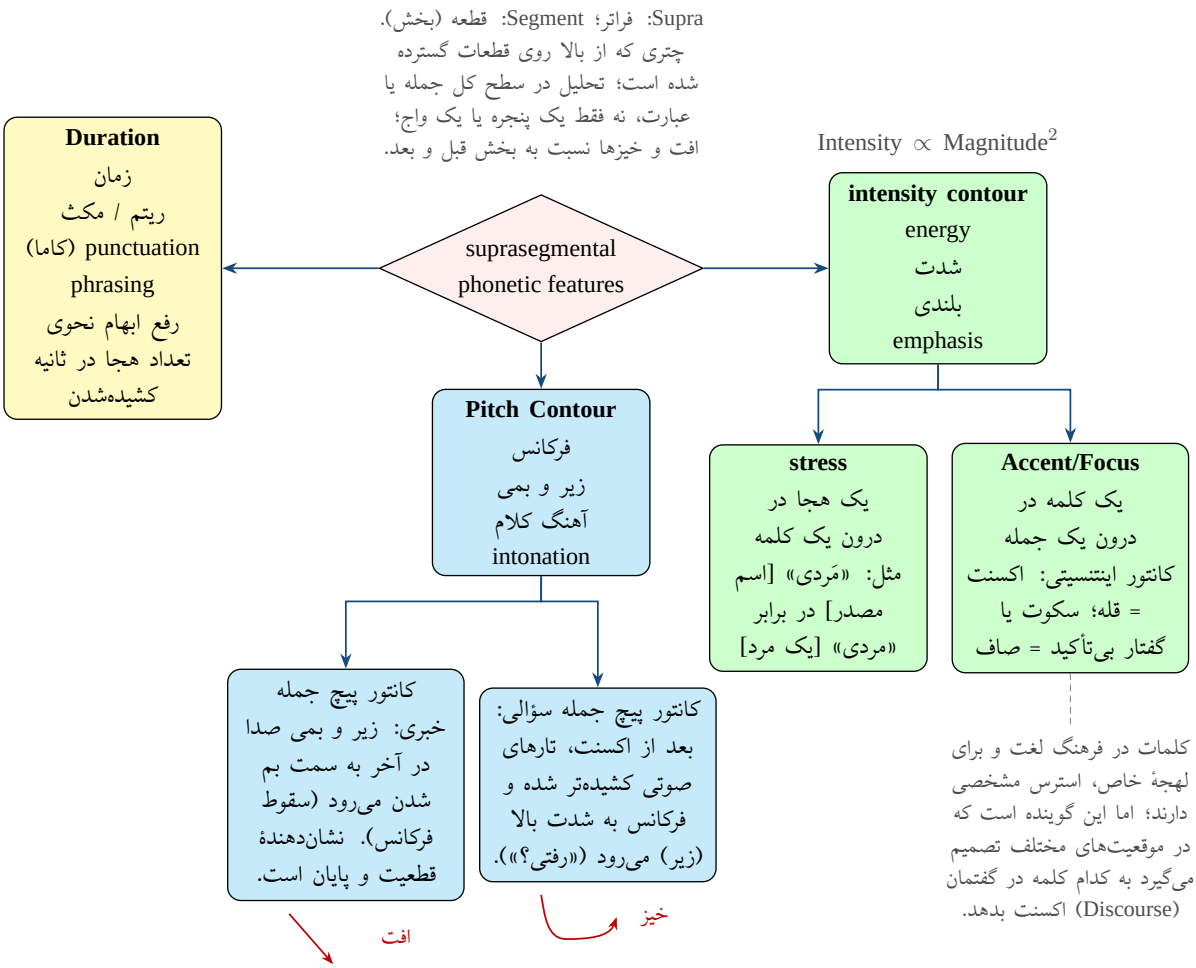
۱.۲.۶ ویژگی‌های زبرزنجیری

پروسودی را **ویژگی‌های زبرزنجیری** (Suprasegmental Features) هم می‌نامند: «فراتر از قطعه (واج)»؛ مثل چتری که روی قطعات گسترده است. دو پیامد:

- تحلیل در سطح چند هجا، عبارت یا کل جمله انجام می‌شود، نه در پنجره‌های ۲۵ میلی‌ثانیه‌ای یا یک واج.
- آنچه اهمیت دارد افت و خیزها نسبت به بخش‌های قبل و بعد است، نه مقدار مطلق در یک لحظه. از این رو مفهوم **کانتور** (Contour) (تغییرات یک ویژگی در طول زمان) محوری است.

۲.۲.۶ سه مؤلفهٔ اصلی

«عصبانیت» یا «تردید» خودشان کمیت صوتی نیستند؛ باید ببینیم چه چیزهایی در سیگنال تغییر کرده که شنونده آن را چنین درک می‌کند. این کمیت‌ها در سه گروه جای می‌گیرند: فرکانس، شدت و زمان.



شکل ۱.۶: نقشهٔ ذهنی ویژگی‌های زبرزنجیری: سه شاخهٔ زمان (Duration)، زیر و بمی (Pitch Contour) و شدت (Intensity Contour). شاخهٔ شدت به تکیهٔ واژگانی (stress) و تأکید (Accent/Focus) تقسیم شده است؛ شاخهٔ زیر و بمی به کانتور جملهٔ خبری و پرسشی. (بازسازی‌شده از تختهٔ کلاس)

جدول ۱.۶: سه مؤلفهٔ اصلی پروسودی، کمیت فیزیکی و ادراک متناظر. (جدول افزوده)

مؤلفه	کمیت فیزیکی	ادراک شنونده	واحد/ابزار
فرکانس	فرکانس پایه (F_0)	زیر و بمی (Pitch)	هرتز، نیم‌پرده؛ کانتور F_0
شدت	دامنه، انرژی	بلندی (Loudness)	دسی‌بل؛ کانتور شدت
زمان	مدت آوا/هجا، مکث	سرعت، ریتم، کشش	میلی‌ثانیه، هجا در ثانیه

۳.۶ مؤلفهٔ اول: شدت صدا

۱.۳.۶ شدت و دسی‌بل

اصطلاحات Intensity، Energy، Loudness، Amplitude و Magnitude از نظر علمی دقیقاً هم‌معنا نیستند، ولی در این جلسه در یک گروه قرار گرفته‌اند. رابطهٔ تخته: شدت با مربع دامنه متناسب است، $\text{Intensity} \propto \text{Magnitude}^2$. بلندی (Loudness) کمیتی **ادراکی** است و با شدت فیزیکی یکی نیست. چون انسان نسبت‌های شدت را حس می‌کند و بازهٔ شدت‌های شنیدنی بسیار گسترده است، از مقیاس لگاریتمی **دسی‌بل** (dB) استفاده می‌شود.

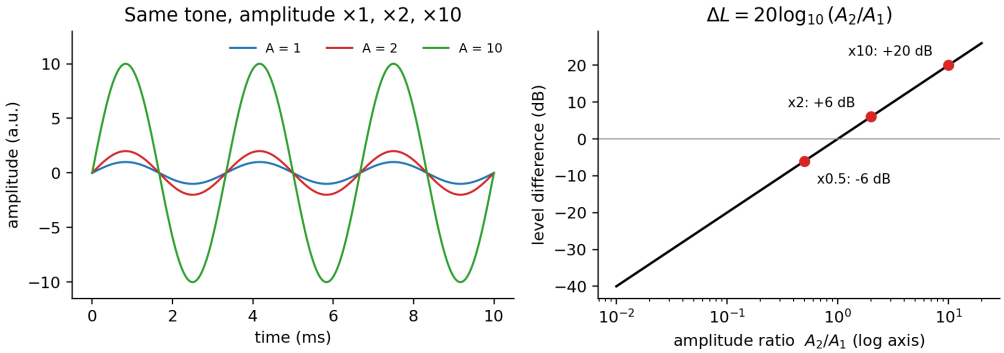
تراز شدت و تراز فشار صوت

$$L_I = 10 \log_{10}\left(\frac{I}{I_0}\right) \text{ dB}, \qquad I_0 = 10^{-12} \text{ W/m}^2$$

$$L_p = \text{SPL} = 20 \log_{10}\left(\frac{p}{p_0}\right) \text{ dB}, \qquad p_0 = 20\ \mu\text{Pa}$$

چون $I \propto p^2$، ضریب لگاریتم برای دامنه ۲۰ و برای توان یا شدت ۱۰ است.

مثال‌ها: دو برابر شدن **دامنه** برابر $20 \log_{10} 2 \approx +6$ dB است (نصف شدن: -6 dB)؛ دو برابر شدن **توان** برابر $+3$ dB؛ ده برابر شدن دامنه برابر $+20$ dB. فشار $p = 0{,}02$ Pa معادل $20 \log_{10}(1000) = 60$ SPL dB و در حد گفت‌وگوی معمولی است.



شکل ۲.۶: سمت چپ: یک تن خالص با دامنه‌های ۱، ۲ و ۱۰. سمت راست: رابطهٔ لگاریتمی دسی‌بل با نسبت دامنه؛ دو برابر شدن دامنه حدود $+6$ دسی‌بل و ده برابر شدن آن $+20$ دسی‌بل است. (شکل افزوده)

کانتور شدت: برای هر قاب (مثلاً ۲۵ میلی‌ثانیه، گام ۱۰ میلی‌ثانیه) انرژی میانگین $E = \frac{1}{N}\sum_n x^2[n]$ را حساب و $10 \log_{10}(E + \varepsilon)$ را در طول زمان رسم می‌کنیم.

بلندی با شدت یکی نیست

بلندی ادراک‌شده تابع شدت، فرکانس و مدت صوت است: دو صدا با شدت یکسان ولی فرکانس متفاوت بلندی یکسان ندارند و گوش در حدود ۲ تا ۵ کیلوهرتز حساس‌ترین است. قاعدهٔ سرانگشتی: حدود ۱۰ دسی‌بل افزایش، بلندی را تقریباً دو برابر می‌کند.

۲.۳.۶ تکیهٔ واژگانی و تأکید

Stress در برابر Accent

تکیهٔ واژگانی (Lexical Stress): برجستگی یک **هجا درون یک واژه**؛ بخشی از الگوی تلفظ واژه و وابسته به زبان و لهجه.
تأکید (Accent/Focus): برجسته‌کردن یک **واژه درون جمله**؛ گوینده بر اساس قصد و بافت تصمیم می‌گیرد کدام واژه را برجسته کند. در کانتور شدت، تأکید به‌صورت یک **قله** دیده می‌شود و گفتار بی‌تأکید یا سکوت تقریباً صاف است.

مثال‌های کلاس: در «من گفتم که این کار را بکن» تأکید روی «من» است و در «کتاب را بردار» روی «کتاب».

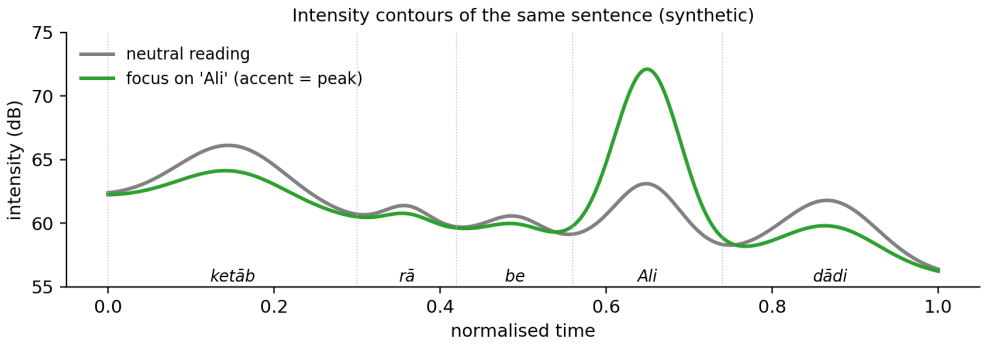
«اکسنت» دو معنا دارد

در این درس accent یعنی «تأکید روی یک واژه در جمله»، نه «لهجه» (مثل لهجهٔ شیرازی)؛ و stress یعنی «تکیه»، نه «استرس روانی».

رابطهٔ Accent با Stress (نکته‌ای که استاد چند بار تکرار کرد): هنگام تأکید روی یک واژه، برجستگی روی همان هجایی قرار می‌گیرد که تکیهٔ واژگانی دارد؛ تأکید محل تکیه را عوض نمی‌کند و فقط برجستگی هجای تکیه‌دار را تقویت می‌کند. («نمی‌توان روی هجایی اکسنت گذاشت که استرس ندارد.») این ایده با **شبکهٔ متریک** (Metrical Grid) نمایش داده می‌شود؛ استاد گفت این مبحث بیشتر مربوط به تحلیل‌های زبان‌شناختی است و در درس کاربرد تخصصی ندارد.

نشانگرهای تأکید فقط شدت نیستند

کلاس تأکید را در شاخهٔ «شدت» جای داد و با قله در کانتور شدت شناخت؛ این درست ولی ناقص است. در پژوهش‌های آوایی، نشانگرهای تکیه و تأکید ترکیبی‌اند: تغییر F_0، افزایش مدت هجا و کامل‌تر ادا شدن واکه، و سپس شدت (که در بسیاری از آزمایش‌ها ضعیف‌ترین نشانهٔ مستقل است). پس باید کانتور شدت، F_0 و مدت را هم‌زمان بررسی کرد.



شکل ۳.۶: کانتور شدت برای جملهٔ «کتاب را به علی دادی» در خوانش خنثی (خاکستری) و در حالتی که روی «علی» تأکید شده است (سبز): تأکید به‌صورت قله روی هجای تکیه‌دار آن واژه دیده می‌شود. داده‌ها مصنوعی و فقط برای توضیح مفهوم‌اند. (شکل افزوده)

تمرین پیشنهادی با Praat

یک واژه یا جمله را یک بار عادی و یک بار با تأکید یا لحن عصبانی ضبط کنید و کانتور شدت و کانتور F_0 را مقایسه کنید. بررسی کنید که افزایش شدت و کشش در همان هجای تکیه‌دار رخ می‌دهد یا نه، و محل تکیه تغییر می‌کند یا نه.

۴.۶ مؤلفهٔ دوم: فرکانس و زیر و بمی

۱.۴.۶ F_0، Pitch و آهنگ

- **فرکانس پایه** (F_0): کمیتی **فیزیکی**؛ تعداد دورهٔ ارتعاش تارهای صوتی در ثانیه (هرتز).
- **زیر و بمی** (Pitch): کمیتی **ادراکی**؛ آنچه شنونده «زیر» یا «بم» می‌شنود. در عمل با F_0 یکی گرفته می‌شود.
- **کانتور زیر و بمی** (Pitch Contour): تغییر F_0 در طول یک جمله یا عبارت.
- **آهنگ جمله** (Intonation): الگوی منظم و معنادار این تغییرات که نقش زبانی دارد (مثلاً تمایز خبر و پرسش).

[محتوای افزوده] نیم‌پرده

شنوایی زیر و بمی را تقریباً لگاریتمی حس می‌کند؛ پس برای مقایسه از **نیم‌پرده** (Semitone) استفاده می‌شود: $\Delta = ۱۲ \log_۲(f_۲/f_۱)$. مثلاً ۲۰۰ تا ۴۰۰ هرتز دقیقاً ۱۲ نیم‌پرده (یک اکتاو) است و ۲۰۰ تا ۲۵۰ هرتز حدود ۳٫۹ نیم‌پرده. همچنین F_0 فقط در قطعات واک‌دار تعریف می‌شود، پس کانتور در بی‌واک‌ها «پاره» است.

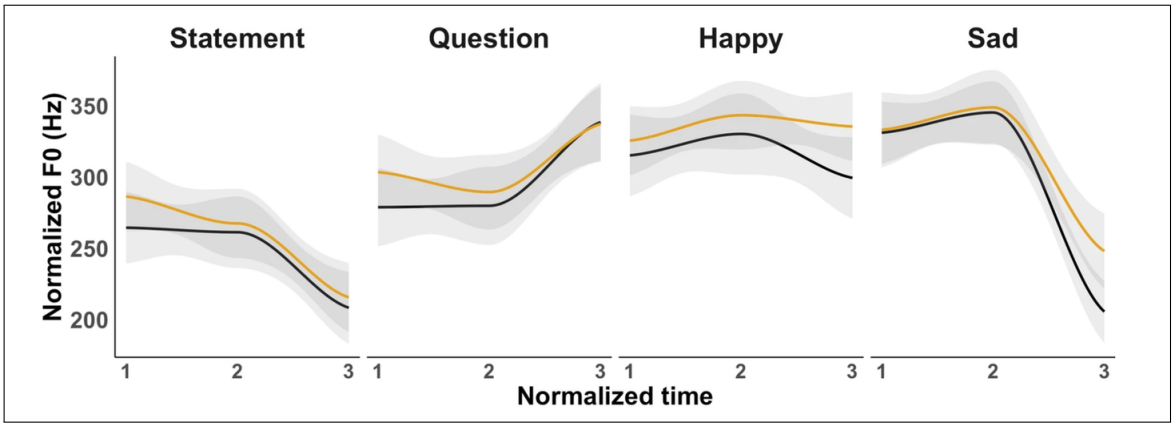
۲.۴.۶ کانتور جملهٔ خبری و پرسشی

- **جملهٔ خبری**: زیر و بمی در پایان به سمت بم‌شدن می‌رود (سقوط فرکانس)؛ نشان‌دهندهٔ **قطعیت و پایان**.
- **جملهٔ پرسشی**: بعد از اکسنت، تارهای صوتی کشیده‌تر می‌شوند و فرکانس به شدت بالا می‌رود (مثال: «رفتی؟»).

«خبری = افت، پرسشی = خیز» گرایش است، نه قانون

خیز پایانی در پرسش‌های بله/خیر رایج است، ولی پرسش‌های دارای واژهٔ پرسشی (چرا، کجا، چه) اغلب افتان‌اند. در فارسی گفتاری، پرسش بله/خیر اغلب فقط با آهنگ ساخته می‌شود («رفتی؟» در برابر «رفتی.»). شکل دقیق کانتور به گوینده، زبان و تأکید هم بستگی دارد. فارسی تونال نیست (برخلاف ماندارین که زیر و بمی در سطح واژه معنا می‌سازد).

مثال «کتاب را به علی دادی؟»: استاد این جمله را چند بار با لحن‌های گوناگون گفت: در حالت پرسشی F_0 در پایان بالا می‌رود و در حالت خبری پایین می‌آید. یک بار خیز پایانی به اندازهٔ انتظار روشن نبود؛ یعنی یک الگوی پروسودیک



شکل ۴.۶: کانتور F_0 نرمال‌شده (برحسب هرتز) در طول زمان نرمال‌شده برای چهار حالت Statement، Question، Happy و Sad. جملهٔ خبری در پایان افت می‌کند، پرسشی در پایان بالا می‌رود، حالت شاد در سطح بالاتر و تقریباً هموار است و حالت غمگین ابتدا بالا و سپس با افت شدید تمام می‌شود. دو منحنی رنگی با نوارهای اطمینان خاکستری دو گروه یا شرایط را نشان می‌دهند؛ تعریف آن‌ها در اسلاید ذکر نشده است. (برگرفته از تختهٔ کلاس)

همیشه یک‌شکل تولید نمی‌شود و باید نمونه‌های زیادی را بررسی کرد. اگر روی «علی» تأکید شود، علاوه بر شدت، کانتور F_0 هم در آن ناحیه تغییر محسوسی دارد؛ پس بهتر است کانتور شدت و زیر و بمی را هم‌زمان بررسی کنیم.

جمله‌های دستوری و احساسی: در دستور قاطع ممکن است افت پایانی شدیدتر از جملهٔ خبری معمولی باشد؛ در درخواست مؤدبانه («بفرمایید، بشینید.») الگو متفاوت و لحن ملایم‌تر است؛ و شادی و غم کانتور و سطح متفاوتی دارند (شکل بالا). الگوی زیر و بمی به شیوهٔ بیان و قصد ارتباطی هم وابسته است، نه فقط کلمات.

۵.۶ مؤلفهٔ سوم: زمان، ریتم و مکث

جدول ۲.۶: ویژگی‌های زمانی گفتار (شاخهٔ Duration در نقشهٔ کلاس).

ویژگی	توضیح
Duration	مدت‌زمان بیان یک آوا، هجا، واژه یا عبارت
Speech Rate	سرعت گفتار؛ ساده‌ترین معیار «تعداد هجا در ثانیه» است
Rhythm	الگوی زمانی و ریتمیک گفتار
Pause	مکث و سکوت
Lengthening	کشیده‌شدن آواها
Phrasing	تقسیم گفتار به گروه‌ها و عبارت‌های آهنگین

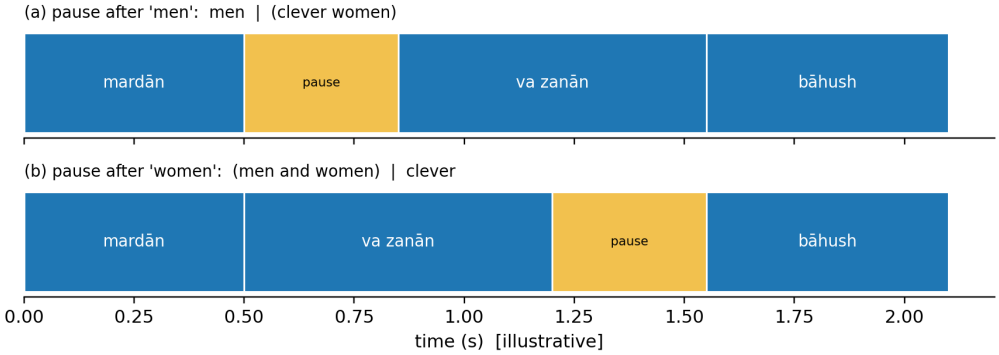
[محتوای افزوده] سرعت گفتار در برابر سرعت تلفظ

سرعت گفتار (Speech Rate) مکث‌ها را در زمان کل حساب می‌کند و **سرعت تلفظ** (Articulation Rate) فقط زمان گفتار واقعی را. مثلاً اگر ۱۹ هجا در ۴٫۵ ثانیه ادا شود که ۰٫۵ ثانیه آن مکث است: ۱۹/۴٫۵ ≈ ۴٫۲ هجا

در ثانیه (گفتار) در برابر ۴٫۷۵ ≈ ۱۹/۴ (تلفظ).

مکث و علائم نگارشی. مکث می‌تواند معنای نحوی جمله را تغییر دهد و مرز دو عبارت را روشن کند. ویرگول، دونقطه و نقطه نشانهٔ محل مکث یا بخش‌بندی‌اند؛ ولی همهٔ علائم زمانی نیستند (علامت سؤال به آهنگ مربوط است).

رفع ابهام نحوی. گاهی جمله در متن بیش از یک تفسیر دارد، اما در گفتار محل مکث‌ها، کشش آواها و گروه‌بندی زمانی ساختار مورد نظر را نشان می‌دهد (**رفع ابهام نحوی** (Syntactic Disambiguation)). مثلاً «مردان و زنان باهوش» (مثال افزوده، نه از کلاس): مکث پس از «مردان» یعنی «(مردان) و (زنان باهوش)» و مکث پس از «زنان» یعنی «(مردان و زنان) باهوش».



شکل ۵.۶: دو گروه‌بندی ممکن برای «مردان و زنان باهوش» که فقط در جای مکث تفاوت دارند. مدت‌ها فرضی و برای توضیح‌اند. (شکل افزوده)

۶.۶ پروسودی در تبدیل متن به گفتار

استاد چند نمونه خروجی از یک سامانهٔ فارسی تبدیل متن به گفتار پخش کرد. در نمونهٔ اول («مادر کتاب را روی میز اتاق گذاشت و پنجره را باز کرد.») مکث و گروه‌بندی طبیعی نبود: مدل واج‌ها را ساخته بود اما پروسودی مناسب جمله را بازسازی نکرده بود. در نمونهٔ دوم (جمله‌ای دربارهٔ شرکت Anthropic) کسرهٔ اضافه نامناسب تولید می‌شد و سرعت گفتار نسبتاً بالا بود. (استاد از داده‌های آموزشی آن سامانه مطمئن نبود، پس نتیجهٔ قطعی دربارهٔ شیوهٔ آموزش آن نمی‌توان گرفت.)

کیفیت TTS فقط به تلفظ درست واج‌ها وابسته نیست؛ سامانه باید محل مکث‌ها، طول هجاها، ریتم، الگوی تأکید، اتصال طبیعی واژه‌ها (مثل کسرهٔ اضافه) و آهنگ را هم درست تولید کند. دلیل دشواری: نگاشت متن به پروسودی «یک‌به‌چند» است و قصد گوینده و احساس در متن نیامده‌اند.

۷.۶ پژوهش: اطمینان و صداقت ادراک‌شده از روی پروسودی

تمرین طراحی آزمایش

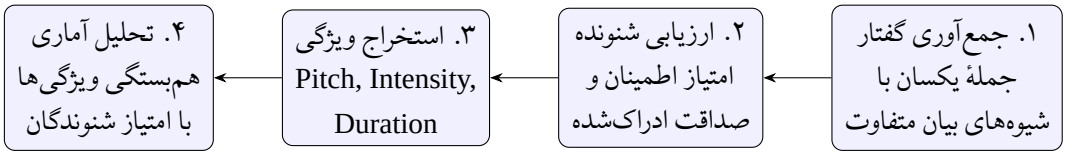
آزمایشی طراحی کنید که نشان دهد صداقت و اطمینان یک گوینده، در نحوهٔ بیان او و ویژگی‌های پروسودیک گفتارش، الگوهای مشترکی دارند.

نکتهٔ مهم: باید میان (۱) اطمینان یا صداقتی که **شنونده** از صدا برداشت می‌کند و (۲) اطمینان یا صداقت **واقعی** گوینده فرق گذاشت. آزمایش ادراکی کلاس موضوع اول را می‌سنجد.

فرضیه‌های اولیهٔ کلاس (قابل آزمون، نه قاعدهٔ قطعی):

- **شدت**: شدت بیشتر یا تأکید واضح‌تر احساس تسلط می‌دهد؛ اما بلندی صدای افراد یکسان نیست، پس ابتدا باید ویژگی‌های معمول هر گوینده را به‌عنوان **خط پایه** (Baseline) در نظر گرفت و تغییرات همان فرد را بررسی کرد.
- **زیر و بمی**: افت F_0 در پایان عبارت قطعیت را منتقل می‌کند.
- **زمان و مکث**: مکث‌های متعدد در میانهٔ جمله تردید را می‌رساند؛ اما مکث در ابتدا یا انتها ممکن است متانت را برساند. پس **محل** مکث هم مهم است.

طرح آزمایش پیشنهادی:



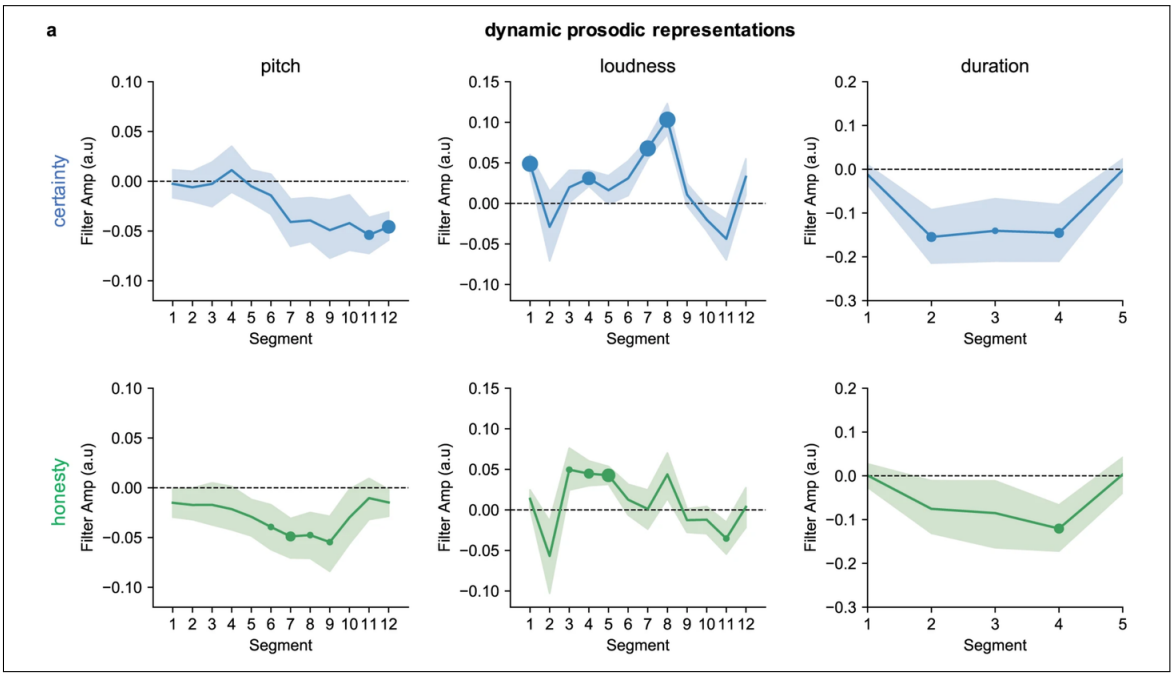
هم‌بستگی (Correlation)

هم‌بستگی مثبت: با افزایش یک متغیر، دیگری نیز تمایل به افزایش دارد (مثلاً شدت بیشتر با امتیاز اطمینان بیشتر).
هم‌بستگی منفی: دیگری تمایل به کاهش دارد (مثلاً مدت طولانی‌تر با اطمینان کمتر). نزدیک صفر یعنی رابطهٔ خطی ضعیف است. ضریب پیرسون بین -۱ و $+۱$ است و هم‌بستگی به‌تنهایی علیت را ثابت نمی‌کند.

۱.۷.۶ مقالهٔ بررسی‌شده

مقاله با عنوان *Listeners' perceptions of the certainty and honesty of a speaker are associated with a common prosodic signature* (Goupil et al., Nature Communications, 2021) است. در مطالعهٔ اول طبق گزارش‌ها، شنوندگان بین دو نسخه از یک شبه‌واژه که F_0، بلندی و مدت آن‌ها تصادفی تغییر کرده بود انتخاب می‌کردند کدام «مطمئن‌تر» یا «صادق‌تر» است، و با **هم‌بستگی معکوس** (Reverse Correlation) «هستهٔ پروسودیک» هر قضاوت به دست می‌آمد. (آنچه روی تخته آمد خلاصهٔ آموزشی است؛ جزئیات را از متن مقاله بازبینی کنید.)

خواندن نمودارها. ردیف بالا مربوط به **اطمینان** (آبی) و ردیف پایین **صداقت** (سبز) است؛ ستون‌ها pitch، loudness و duration. محور افقی «قطعه» است: بخش‌های زمانی یک محرک کوتاه (۱۲ قطعه برای F_0 و بلندی، ۵ قطعه برای مدت)، نه بخش‌های یک جملهٔ بلند. محور عمودی دامنهٔ هسته؛ خط خطچین صفر یعنی «بدون اثر».



شکل ۶.۶: هسته‌های پروسودیک اطمینان (ردیف بالا) و صداقت (ردیف پایین) برای pitch، loudness و duration در برابر قطعهٔ زمانی. مقدار مثبت یعنی ویژگی در آن قطعه با انتخاب «مطمئن‌تر/صادق‌تر» همراه بوده؛ منفی یعنی عکس؛ نزدیک صفر یعنی بی‌اثر. (مقاله: Goupil et al., 2021) (برگرفته از تختهٔ کلاس)

جدول ۳.۶: خلاصهٔ الگوهای نمودار.

ویژگی	الگوی دیده‌شده	برداشت
Pitch	در ابتدا نزدیک صفر، در نیمهٔ دوم منفی	افت آهنگ در بخش پایانی با اطمینان و صداقت بیشتر همراه است
Loudness	مثبت در چند قطعه (ابتدایی/میانی)	شدت بیشتر در این بخش‌ها با اطمینان یا صداقت بیشتر همراه است
Duration	منفی در قطعه‌های میانی، نزدیک صفر در دو سر	طولانی‌تر (کندتر) بودن با اطمینان و صداقت کمتر همراه است

نکتهٔ اصلی: اثر هر ویژگی به **جایگاه زمانی** آن بستگی دارد (مثلاً شدت در ابتدا بی‌اثر و در میانه مؤثر است)، پس میانگین کل جمله کافی نیست.

دقت در تفسیر نمودار

(۱) نمودار مدت به سرعت گفتار مربوط است، نه به «مکث» به معنای سکوت؛ در مقاله سرعت بیشتر (مدت کوتاه‌تر) با اطمینان بیشتر همراه است. (۲) «ابتدا، میانه و انتهای جمله» در کلاس را باید «ابتدا، میانه و انتهای محرک (واژه)» خواند. (۳) ایدهٔ مقاله «شکل» کانتور است؛ «فرکانس پایین‌تر» یعنی افت آهنگ در بخش پایانی، نه

صدای بم‌تر به‌طور کلی. (۴) نتیجه دربارهٔ **برداشت شنونده** است، نه صداقت واقعی، و همبستگی است نه علیت.

۸.۶ کاربردهای عملی تحلیل پروسودی

یک نمونه که استاد اشاره کرد ارزیابی نحوهٔ بیان افراد در **مصاحبهٔ شغلی** است. چنین سامانه‌ای می‌تواند ترکیب کند: (۱) **محتوا** با ASR، (۲) **نحوه‌بیان** (شدت، فرکانس، سرعت گفتار) و (۳) **تحلیل چندوجهی** (متن، صدا و گاهی تصویر) برای ارائهٔ امتیاز یا برآورد.

احتیاط در استفاده

چنین امتیازهایی لزوماً بیانگر شخصیت، تخصص یا صداقت واقعی فرد نیستند و اعتبار آن‌ها نیازمند ارزیابی مستقل و کنترل تفاوت‌های فردی، زبانی و موقعیتی است.

۹.۶ جمع‌بندی

پروسودی لایه‌ای از گفتار است که «چگونه گفتن» را توصیف می‌کند و تمام آن در متن نیست. سه مؤلفهٔ آن زیر و بمی، شدت و زمان‌اند و باید به‌صورت کانتور روی بازه‌های بلند بررسی شوند؛ تحلیل طیفی به‌تنهایی کافی نیست.

نکات مهم برای مرور و امتحان

۱. MFCC شکل طیفی و فیلتر مجرا را نشان می‌دهد و اطلاعات F_0 را عملاً حذف می‌کند. تعداد خروجی‌های بانک فیلتر برابر تعداد فیلترهاست و ضرایب نهایی (مثلاً ۱۲) می‌تواند کمتر باشد؛ گام پس از لگاریتم DCT است.

۲. اختلاف «آ» و «اَ» مربوط به فیلتر است: زبان پایین‌تر $\Rightarrow F_1$ بالاتر؛ زبان جلوتر $\Rightarrow F_2$ بالاتر.

۳. پروسودی (زبرزنجیری) ریتم، آهنگ و تأکید را توصیف می‌کند؛ سه مؤلفه: Pitch/Frequency، Intensity، Time/Duration؛ باید یک عبارت و کانتور آن را بررسی کرد.

۴. Stress: تکیه درون واژه؛ Accent: برجسته‌سازی واژه در جمله؛ تأکید روی همان هجای تکیه‌دار می‌نشیند.

۵. کانتور شدت ناحیه‌های تأکیدی را نشان می‌دهد، اما F_0 و مدت هم در تأکید نقش دارند. شدت با مربع دامنه متناسب است؛ $L_p = ۲۰ \log_{۱۰}(p/p_۰)$ و $L_I = ۱۰ \log_{۱۰}(I/I_۰)$.

۶. کانتور پرسشی اغلب با خیز و خبری با افت پایانی همراه است (گرایش، نه قانون).

۷. ویژگی‌های زمانی (سرعت گفتار، مدت هجا، ریتم، مکث، کشش) در Phrasing و رفع ابهام نحوی نقش دارند.

۸. آزمایش اطمینان/صداقت: جمع‌آوری گفتار، ارزیابی شنونده، استخراج ویژگی، تحلیل هم‌بستگی؛ جایگاه زمانی ویژگی مهم است و باید بتوانید هم‌بستگی مثبت/منفی/نزدیک صفر را در نمودار تفسیر کنید.

فصل ۷

تبدیل متن به گفتار: مسئله و معماری خط‌لولهٔ TTS

۱.۷ از تحلیل گفتار تا تولید گفتار

تا این جلسه محور درس **تحلیل سیگنال گفتار** بود: موج صوتی از پیش در اختیار ما بود و از آن طیف‌نگار، MFCC، پروزودی، فرمنت‌ها و... استخراج می‌کردیم. از این جلسه وارد سامانه‌های اصلی می‌شویم: تبدیل متن به گفتار (TTS)، سامانه‌های گفت‌وگو و تبدیل گفتار به متن (STT). موضوع این جلسه **تبدیل متن به گفتار** (Speech Synthesis) است. در TTS جهت مسئله معکوس می‌شود:

$$\text{Text} \longrightarrow \text{Speech Waveform}$$

دو مشکل بنیادی وجود دارد:

- **شکاف حجم اطلاعات:** متن بسیار کم‌حجم است (چند ده نویسه یا واج)، اما با نرخ نمونه‌برداری $f_s = ۲۴\,۰۰۰$ هرتز هر ثانیه گفتار ۲۴ هزار نمونه دارد.
- **کم‌گویی متن:** متن لحن، تأکید، سرعت، مکث و ویژگی‌های گوینده را مشخص نمی‌کند؛ پس مدل باید این‌ها را از داده و بافت **استنتاج یا تولید** کند. نگاشت متن به گفتار یک‌به‌چند است.

۲.۷ دو رویکرد کلی: خط‌لوله و سرتاسری

- **خط‌لوله‌ای (Pipeline-Based):** مسئله به چند ماژول با وظیفهٔ مشخص تقسیم می‌شود و خروجی هر ماژول ورودی بعدی است. هر بخش را می‌توان جداگانه بررسی، آموزش، اصلاح یا جایگزین کرد.
- **سرتاسری (End-to-End):** یک مدل (یا مجموعهٔ یکپارچه‌ای از لایه‌ها) متن را مستقیماً به گفتار می‌رساند و لزوماً ماژول‌های میانی مستقل و قابل مشاهده ندارد.

نکتهٔ تأکیدی استاد

رویکرد End-to-End **لزوماً بهترین گزینه برای همهٔ کاربردها نیست**. گاهی به‌دلیل تأخیر پردازش (Latency) یا ویژگی‌های دامنهٔ کاربرد (مثلاً حساسیت مرحلهٔ نرمال‌سازی متن)، ماژول‌های کلاسیک یا خط‌لوله مناسب‌ترند. در این جلسه تمرکز بر خط‌لوله است و رویکردهای سرتاسری در جلسهٔ جدا می‌آیند.

«سرتاسری» یک طیف است

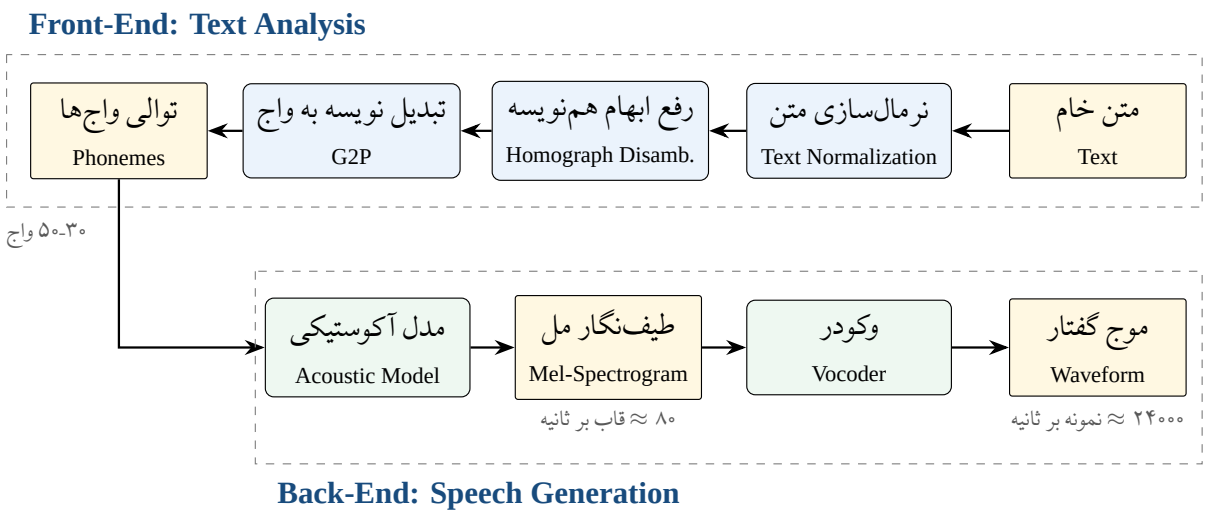
برخی مدل‌ها (مثل Tacotron 2) فقط تا طیف‌نگار سرتاسری‌اند و وکودر جدا دارند؛ مدل‌هایی مانند VITS واج را در یک مدل به موج می‌رسانند، و حتی آن‌ها نرمال‌سازی و G2P را بیرون از مدل می‌گذارند. پس مسئله بیشتر این است که مرز ماژول‌ها کجا باشد.

۳.۷ معماری کلی یک سامانهٔ TTS

سامانهٔ TTS دو بخش اصلی دارد:

Front-End (تحلیل متن، Text Analysis). ورودی هنوز متن است؛ «چه باید گفته شود». خروجی: توالی واج‌ها.

Back-End (تولید گفتار، Speech Synthesis). واج‌ها به نمایش آکوستیکی و سپس به موج تبدیل می‌شوند؛ «چگونه گفته شود».



شکل ۱.۷: نمودار بلوکی خط‌لولهٔ TTS: تحلیل متن (بالا، از راست به چپ) و تولید گفتار (پایین، از چپ به راست). مستطیل‌های زرد نمایش‌های میانی و رنگی‌ها ماژول‌های پردازشی‌اند. (شکل افزوده)

نقش ماژول‌ها (مراحل ۱ تا ۳ Front-End و ۴ و ۵ Back-End):

۱. **نرمال‌سازی متن** (Text Normalization): تبدیل متن خام به متنی که درست خوانده شود (عدد، تاریخ، ساعت، پول، اختصار).

۲. **رفع ابهام هم‌نویسه** (Homograph Disambiguation): تعیین تلفظ درست کلمات هم‌نویسه از روی بافت.

۳. **تبدیل نویسه به واج** (Grapheme-to-Phoneme, G2P): نمایش نوشتاری ← نمایش واجی.

۴. **مدل آکوستیکی** (Acoustic Model): واج‌ها ← نمایش آکوستیکی (مثل طیف‌نگار مل).

۵. **وکودر** (Vocoder): نمایش آکوستیکی ← موج.

۴.۷ مرحلهٔ اول: نرمال‌سازی متن

متن واقعی پر از عدد، تاریخ، ساعت، واحد پول و اختصار است که شکل نوشتاری‌شان با شکل گفتاری‌شان فرق دارد. در کلاس جملهٔ نمونه‌ای روی تخته نوشته شد که تقریباً همهٔ این پدیده‌ها را داشت.

در تاریخ [1] ۱۴۰۲/۱۰/۱۵ ساعت [2] ۱۶:۳۰، آن [3] مرد پس از مدت‌ها بیماری در بیمارستان [4] مرد و [5] سرم را از دستش کشیدند. [6] خواهرم گفت «[7] سرم به شدت درد می‌کند». حدود [8] ۲/۵ [9] تن گندم به ارزش [10] ۱۲۵ میلیون و [11] ۵۰۰ هزار [12] تومان با [13] ۳۰٪ تخفیف فروخته شد.

شماره‌نشانه	نوع	شکل نوشتاری	شکل گفتاری (یادداشت استاد)
۱	تاریخ	۱۴۰۲/۱۰/۱۵	پانزدهم دی‌ماه هزار و چهارصد و دو
۲	ساعت	۱۶:۳۰	چهار و نیم (بعدازظهر) یا شانزده و سی دقیقه
۳-۴	هم‌نویسه	مرد	mard (انسان مذکر) / mord (فوت کرد)
۵، ۷	هم‌نویسه	سرم	sorom (محلول تزریقی) / saram (سرِ من)
۸	عدد اعشاری	۲/۵	دو و نیم
۱۰-۱۱	عدد	۱۲۵ و ۵۰۰	صد و بیست و پنج میلیون و پانصد هزار
۱۲-۱۳	پول، درصد	تومان، ۳۰٪	تومان (محاوره‌ای: تومن)، سی درصد

شکل ۲.۷: جملهٔ نمونهٔ روی تخته و نشانه‌گذاری‌های استاد: تاریخ، ساعت، عددها، واحد پول، درصد، و دو هم‌نویسهٔ «مرد» و «سرم». (بازسازی‌شده از تختهٔ کلاس)

هدف نرمال‌سازی در TTS

متن ورودی باید به شکلی تبدیل شود که سامانه بتواند آن را **درست و طبیعی بخواند**: ساختن «شکل گفتاری» (spoken form) از «شکل نوشتاری» (written form). انتخاب شکل گفتاری (مثلاً «شانزده و سی دقیقه» یا «چهار و نیم» و نیز «تومان» یا «تومن») به کاربرد و سبک گفتار بستگی دارد.

۱.۴.۷ نرمال‌سازی در TTS با NLP فرق دارد

استاد تأکید کرد که نرمال‌سازی وابسته به هدف است: «متن را نسبت به چه هدفی نرمال می‌کنیم؟» نرمال‌ساز معمول NLP (مثلاً Hazm) **کاهنده** (Reductive) است: تنوع نوشتار را کم می‌کند (یکسان‌سازی «ي/ی» و «ك/ک»، نیم‌فاصله) تا برای جست‌وجو، دسته‌بندی، NER و POS مفید باشد. اما در TTS متن باید **خواندنی** شود: اطلاعات نباید دور ریخته شود (مثلاً حذف **واژه‌های ایست** (Stopword) نامناسب است) و حتی باید اطلاعات تازه اضافه شود. روی تخته «کاهنده» در برابر «گسترش‌دهنده و آواشناسی‌محور» (Expansive & Phonetic) مقابل هم قرار گرفت.

دو نرمال‌ساز با یک نام

نرمال‌ساز Hazm **کاهنده** است (تنوع نوشتار را برای فهم معنا کم می‌کند)؛ نرمال‌ساز TTS **گسترش‌دهنده** است (عدد را به کلمه تبدیل و اطلاعات تلفظی را روشن می‌کند). این دو را اشتباه نگیرید. (البته TTS هم به یکدست‌سازی املایی برای جست‌وجو در فرهنگ تلفظ نیاز دارد، و نباید اطلاعات مؤثر بر خواندن مثل ویرگول و علامت سؤال را حذف کند.)

۲.۴.۷ کلمات غیراستاندارد (NSW) و روش کلاسیک

هستهٔ نرمال‌سازی TTS برخورد با **کلمات غیراستاندارد** (Non-Standard Words, NSW) است: توکن‌هایی که تلفظشان از نوشتارشان با قواعد معمول به دست نمی‌آید. دسته‌های اصلی: اعداد، تاریخ، ساعت، واحد پول، درصد، اختصارات، شماره‌ها و شناسه‌ها، و شکل‌های غیررسمی.

یک رشتهٔ ارقام را نمی‌توان با قاعدهٔ ثابتی به کلمه تبدیل کرد؛ ابتدا باید **نوع و نقش** آن مشخص شود. مثلاً در انگلیسی ۱۹۷۶ اگر سال باشد «نوزده، هفتاد و شش» خوانده می‌شود ولی در یک شناسه ممکن است رقم‌به‌رقم. در فارسی هم «/» گاهی جداکنندهٔ تاریخ (۱۴۰۲/۱۰/۱۵) و گاهی ممیز اعشاری (۲/۵) است و تنها نشانهٔ تفکیک بافت است (واژهٔ «تن» پس از ۲/۵).

روش کلاسیک دو بخشی.

۱. **طبقه‌بندی توکن** (Token Classification): هر توکن به یک دسته (عدد، تاریخ، ساعت، پول، ...) نسبت داده می‌شود؛ با عبارت باقاعده (Regex)، قواعد دستی یا مدل یادگیری ماشین.

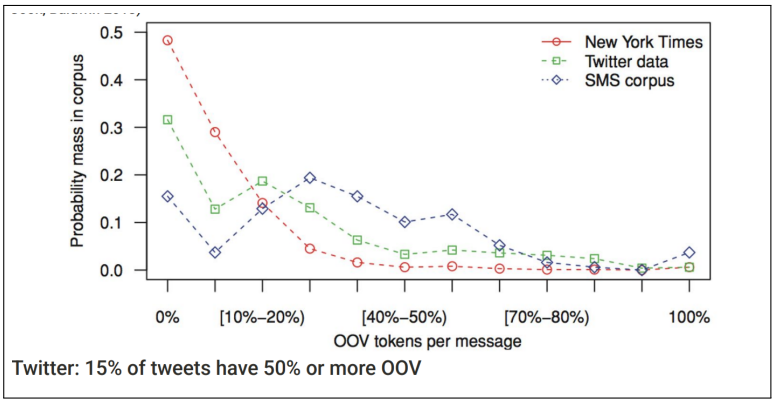
۲. **مبدل** (Converter): مبدل مخصوص آن دسته توکن را به شکل گفتاری درمی‌آورد.

$$\text{Input Token} \rightarrow \text{Token Classification} \rightarrow \text{Category-Specific Converter} \rightarrow \text{Spoken Form}$$

در کلاس کتابخانهٔ num2fawords (تبدیل عدد به حروف فارسی؛ مثلاً)۱۷۰words) برابر «یکصد و هفتاد») معرفی شد. استاد تأکید کرد که فقط برای دستهٔ **اعداد** است و تاریخ، ساعت و اختصار مبدل جدا می‌خواهند. اگر برای دسته‌ای ابزار آماده نباشد، دادهٔ آموزشی تهیه و طبقه‌بند ساخته می‌شود.

۳.۴.۷ اهمیت دامنهٔ کاربرد

فراوانی NSWها به نوع متن بستگی دارد. در کلاس سه نوع داده مقایسه شد: متن خبری (New York Times)، Twitter و SMS.



شکل ۳.۷: احتمال دیدن پیامی با نسبت معین از توکن‌های OOV در سه پیکره. در متن خبری حدود ۴۸ درصد پیام‌ها هیچ OOV ندارند؛ در توییتر حدود ۳۱ درصد و در SMS حدود ۱۵ درصد. (مقدارهای تقریبی) (برگرفته از تختهٔ کلاس)

هرچه به ارتباطات غیررسمی (توییتر و SMS) نزدیک‌تر شویم، NSWها (اختصار، املای غیررسمی، عامیانه) شایع‌تر می‌شوند. اگر شکل خواندن عبارتی تشخیص داده نشود، گفتار غیرطبیعی یا غلط می‌شود. این مزیت خطلوله است: **اهمیت و پیچیدگی هر ماژول به دامنه وابسته است**؛ برای پیام‌های کوتاه و شبکه‌های اجتماعی باید روی نرمال‌سازی بیشتر سرمایه‌گذاری کرد، برای متن رسمی می‌توان آن را ساده‌تر گرفت.

OOV و NSW یکی نیستند

نمودار OOV (خارج از واژگان) را می‌شمارد؛ NSW توکنی است که تلفظش مستقیماً از نوشتارش نمی‌آید. هم‌پوشانی زیادی دارند ولی مثلاً اشتباه تایپی OOV است نه NSW. در کلاس OOV شاخصی برای فراوانی NSW بود.

۵.۷ مرحلهٔ دوم: رفع ابهام هم‌نویسه‌ها

هم‌نویسه (Homograph)

دو یا چند واژه با نویسهٔ (املای) یکسان ولی تلفظ متفاوت. هدف **رفع ابهام هم‌نویسه** (Homograph Disambiguation) انتخاب تلفظ درست با توجه به بافت جمله است.

ریشهٔ بسیاری از هم‌نویسه‌های فارسی این است که مصوت‌های کوتاه (a، e، o) در نوشتار معمولی نمایش داده نمی‌شوند:

نوشتار	تلفظ‌های ممکن (IPA)	معنی
مرد	[mord] / [mærd]	انسان مذکر (اسم) / فوت کرد (فعل)
کرم	[kerem] / [kerm]	کرم خاکی / کرم مرطوب‌کننده
سرم	[særæm] / [serom]	محلول پزشکی / «سرِ من»

دو راه برای رفع ابهام.

۱. **اطلاعات نحوی (Syntactic Information):** نقش دستوری تلفظ را مشخص می‌کند. ابزار آن **برچسب‌گذاری اجزای کلام** (Part-of-Speech Tagging) (POS Tagging) است که برای هر کلمه اسم، فعل، صفت، قید، ضمیر و ... را تعیین می‌کند. مثلاً «مرد» در «آن مَرد رفت» اسم و در «او مُرد» فعل است.

۲. **بافت و معنا (Context):** اگر نقش دستوری یکسان باشد (کرم خاکی و کرم مرطوب‌کننده هر دو اسم‌اند) باید معنای جمله را به کار برد؛ یک راه یادگیری ماشینی **نمایش بافتی** (Contextual Embedding) است که بردار هر کلمه را با توجه به جملهٔ اطراف می‌سازد (جزئیات در جلسات بعد).

۱.۵.۷ مدلی برای رفع ابهام هم‌نویسه

روی تخته مدلی نمونه رسم شد: جمله از یک مدل Embedding می‌گذرد؛ نمایش کلمهٔ هدف («گرم») به یک طبقه‌بند داده می‌شود که فقط میان تلفظ‌های **مرتبط با همان کلمه** (garm و geram) بیشینه می‌گیرد.

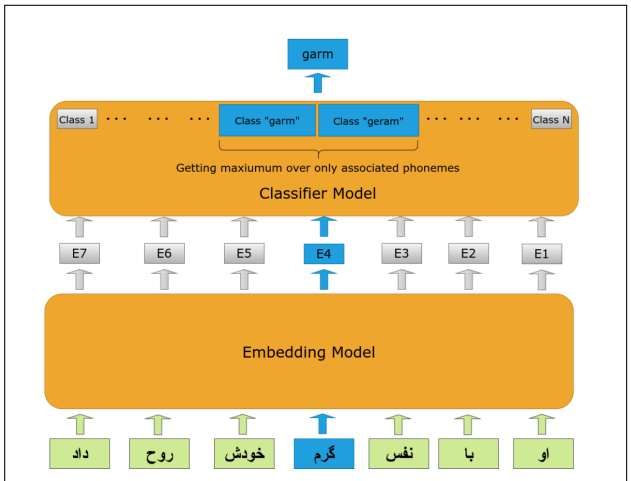


Figure 1: Proposed Homograph Disambiguation Model

شکل ۴.۷: مدل نمونهٔ رفع ابهام هم‌نویسه: Embedding بردار بافتی را می‌سازد و طبقه‌بند تنها میان تلفظ‌های نامزد کلمهٔ هدف بیشینه می‌گیرد. (برگرفته از تختهٔ کلاس)

چرا یک طبقه‌بند **سراسری** (Global Classifier) برای همهٔ هم‌نویسه‌ها، نه یکی برای هر کلمه؟ هم‌نویسه‌ها در قواعد نحوی و معنایی مشترک‌اند؛ طبقه‌بند جدا برای کلمات کم‌تکرار بیش‌برازش می‌کند یا چیزی یاد نمی‌گیرد؛ با وزن‌های مشترک (Shared Weights) دانشی که از کلمات پرتکرار یاد گرفته شده روی کلمات کم‌تکرار هم اعمال می‌شود (**یادگیری انتقالی میان‌کلمه‌ای** (Cross-word Transfer Learning)).

پرسش روی تخته: «اینجا Argmax یا تصادفی؟»

در رفع ابهام هم‌نویسه تلفظ **درست و قطعی** می‌خواهیم، پس معمولاً argmax روی نامزدهای مجاز انتخاب می‌شود؛ نمونه‌برداری تصادفی بیشتر برای تنوع خروجی‌های تولیدی (مثلاً پروزودی) مطرح است.

هر ابهام معنایی ابهام تلفظی نیست

رفع ابهام هم‌نویسه به **رفع ابهام معنایی واژه** (Word Sense Disambiguation, WSD) نزدیک است، اما هدفش تعیین **تلفظ** است. هر سه معنای «شیر» (جانور، نوشیدنی، شیر آب) در فارسی [ʃir] تلفظ می‌شود؛ پس ابهام معنایی (WSD) است ولی برای TTS هم‌نویسه نیست. اطلاعات معنایی فقط ابزاری برای رسیدن به تلفظ صحیح است.

۶.۷ تبدیل نویسه به واج (G2P)

تا اینجا ورودی توالی نویسه‌ها (Grapheme) بود؛ برای تولید گفتار به **واج** (Phoneme) نیاز داریم. این تبدیل را **نویسه‌به‌واج** (Grapheme-to-Phoneme, G2P) می‌نامند.

نویسه و واج

نویسه (Grapheme): واحد تمایزدهندهٔ نظام نوشتاری (مثل «س»، a).
واج (Phoneme): کوچک‌ترین واحد صوتی تمایزدهنده در نظام آوایی زبان؛ با الفبای آوانگاری مانند IPA نوشته می‌شود.

نویسه «معنادار» نیست

روی تخته نویسه «کوچک‌ترین واحد معنادار خط» نوشته شده بود؛ دقیق‌تر: کوچک‌ترین واحد **متمایزکننده** خط. «معنادار بودن» ویژگی **تکواژ** (Morpheme) است.

نگاشت نویسه به واج یک‌به‌یک نیست (انگلیسی هم: tion ← ʃən). در فارسی:

- مصوت‌های کوتاه نوشته نمی‌شوند ولی در نمایش واجی باید بیایند: استاد «کتاب» را ketab و «شب» را ʃab نوشت؛
- تشدید، سکون و استثناهای املایی باید در نظر گرفته شوند؛
- بعضی نویسه‌ها چند تلفظ دارند («و»: /v/، /u/، /o/ (/ow/) و بعضی واج‌ها چند نویسه :/s/ «س»، «ص»، «ث»).

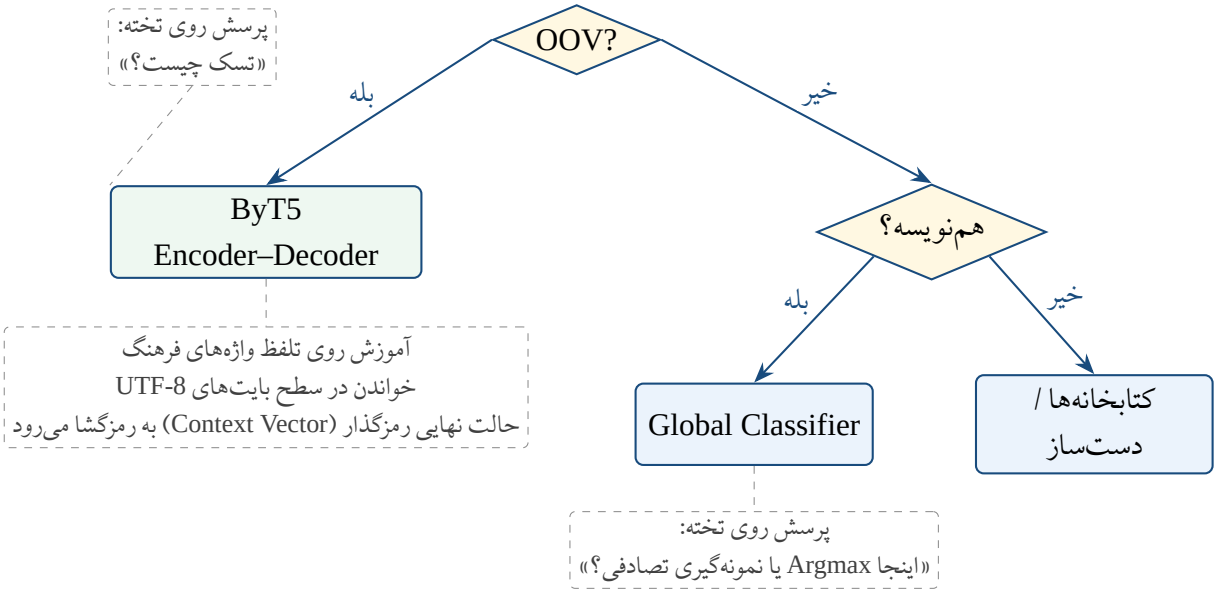
سه پیش‌نیاز طراحی G2P.

۱. **الفبای آوانگاری (الفبای آوایی بین‌المللی** (International Phonetic Alphabet, IPA)): اصل آن «یک صدا، یک نماد» است و جدولش بر پایهٔ همان ویژگی‌های تولیدی (محل و شیوهٔ تولید برای صامت‌ها؛ ارتفاع و پیشین/پسین بودن زبان برای مصوت‌ها) سازمان یافته است.

۲. **فرهنگ تلفظ** (Pronunciation Dictionary): نگاشت نوشتار به تلفظ؛ هم برای یادگیری و هم برای سنجش مدل. نمونه‌ها: KaamelDict (فرهنگ تلفظ فارسی روی Hugging Face) و Persian Phonetic Corpus؛ ابزار phonemizer متن را به IPA تبدیل می‌کند.

۳. **مدل G2P**: مثلاً مدل دنباله‌به‌دنبالهٔ رمزگذار-رمزگشا (Encoder–Decoder) که توالی نویسه‌ها را به توالی واج‌ها می‌برد (معماری در جلسات بعد).

طرح عملی پیشنهادی. روی تخته نمودار تصمیمی رسم شد: اگر کلمه در فرهنگ تلفظ نباشد (OOV)، یک مدل رمزگذار-رمزگشا در سطح بایت (ByT5) که روی تلفظ کلمات فرهنگ آموزش دیده و نوشتار را بایت‌به‌بایت (UTF-8) می‌خواند، قواعد پنهان آوایی را تعمیم می‌دهد؛ اگر در فرهنگ باشد و هم‌نویسه باشد، طبقه‌بند سراسری تلفظ را برمی‌گزیند؛ وگرنه تلفظ ثبت‌شده یا کتابخانهٔ دست‌ساز به کار می‌رود.



شکل ۵.۷: نمودار تصمیم برای بخش تلفظ: کلمهٔ OOV به ByT5، کلمهٔ هم‌نویسه به طبقه‌بند سراسری و در غیر این صورت به فرهنگ/کتابخانهٔ دست‌ساز می‌رود. (بازسازی‌شده از تختهٔ کلاس)

پایان بخش تحلیل متن

در پایان G2P خروجی یک **توالی واجی** است؛ در این نقطه Text Analysis (Front-End) پایان می‌یابد و تولید صوت (Back-End) آغاز می‌شود.

۷.۷ مرحلهٔ دوم سامانه: تولید گفتار از روی واج‌ها

ورودی مجموعه‌ای از واج‌هاست و خروجی موج گفتار. سه چالش اصلی داریم:

۱. **اطلاعات پروزودی:** متن لحن و آهنگ را مشخص نمی‌کند؛ «سلام» می‌تواند عادی، پرسشی، متعجبانه یا با تأکید گفته شود. بخشی از اطلاعات از نشانه‌های نگارشی و بافت به دست می‌آید، ولی کافی نیست؛ پس مدل

باید پروزودی را استنتاج کند یا کنترل‌های جدا (نوع صدا، سبک، حالت) بگیرد تا گفتار رباتی نباشد.

۲. **اختلاف نرخ و ابعاد:** ۳۰ واج ورودی در برابر موج ۳ ثانیه‌ای در ۲۴ کیلوهرتز:

$$N = f_s \times T = ۲۴۰۰۰ \times ۳ = ۷۲\,۰۰۰.$$

اگر طیف‌نگار مل ۸۰ بعدی با گام ۳۰۰ نمونه داشته باشیم، میانگین هر واج (۷۵ میلی‌ثانیه) حدود ۶ قاب و ۱۸۰۰ نمونه است. در کلاس به این افزایش وضوح زمانی Upsampling گفته شد؛ اما مسئله فقط زیادکردن تعداد نمونه نیست و مدل باید مقدار هر نمونه را هم تعیین کند.

۳. **تطابق زمانی (Temporal Alignment):** هر واج کی شروع شود، چقدر طول بکشد، مرز دو واج کجاست و کدام واج‌ها (به‌دلیل هم‌تولیدی) بر هم اثر می‌گذارند. این به **مدل‌سازی مدت** (Duration Modeling) مربوط است؛ واج‌ها مدت یکسان ندارند.

نرخ ۲۴ کیلوهرتز و واژه «Upsampling»

نرخ نمونه‌برداری «استاندارد» واحدی وجود ندارد (تلفن ۸، تشخیص گفتار معمولاً ۱۶، پژوهش‌های TTS عمدتاً ۲۲٫۰۵ یا ۲۴ کیلوهرتز)؛ ۲۴ کیلوهرتز مثال معقولی است. همچنین «Upsampling» اصطلاحی تقریبی است: افزایش طول در دو جا رخ می‌دهد، واج به قاب (با مدل‌سازی مدت) و قاب به نمونه (چند صد نمونه به‌ازای هر قاب).

۸.۷ مدل آکوستیکی

برای ساده‌کردن مسئله، تولید گفتار به دو مرحله تقسیم می‌شود:

$$\text{Phonemes} \xrightarrow{\text{Acoustic Model}} \text{Mel-Spectrogram} \xrightarrow{\text{Vocoder}} \text{Waveform}$$

مدل آکوستیکی (Acoustic Model) از روی واج‌ها نمایش آکوستیکی (مثل طیف‌نگار مل) می‌سازد و باید زمان‌بندی، ویژگی‌های آکوستیکی و در صورت لزوم پروزودی را لحاظ کند.

چرا طیف‌نگار به‌عنوان نمایش میانی؟ پاسخ کلاس: نمایش میانی **پیچیدگی مسئلهٔ یادگیری را کاهش می‌دهد**؛ به‌جای ساختن همهٔ جزئیات موج در یک گام، ابتدا نمایشی ساختاریافته‌تر ساخته می‌شود و ماژول دیگری آن را به موج برمی‌گرداند.

مثال استاد: مسیر تهران تا مشهد

فرض کنید فقط می‌دانیم کسی از تهران به مشهد رفته و مسافت مشخصی را طی کرده است؛ بازسازی مسیر دقیقش دشوار است (از کدام شهرها و جاده‌ها گذشته؟). اگر «نقاط عطف» میان راه را بدانیم، بازسازی ساده‌تر می‌شود. در تولید گفتار هم دانستن واج‌ها برای تعیین همهٔ جزئیات موج کافی نیست و طیف‌نگار نقش همان نقاط عطف را دارد.

نقش Embedding. برای هر واج یک بردار **تعبیه** (Embedding) (مثلاً ۵۱۲ بعدی؛ عدد فقط مثال است) یاد گرفته می‌شود که اطلاعات واج و ارتباطش با واج‌های قبل و بعد را حمل می‌کند؛ پس مدل فقط به هویت یک واج مستقل محدود نیست و می‌تواند هم‌تولیدی را بیاموزد.

مدل آکوستیکی و پروزودی. استاد تأکید کرد که «تولید طیف‌نگار» و «پیش‌بینی پروزودی» دقیقاً یک مسئله نیستند (برای یک محتوای ثابت حالت‌های پروزودی گوناگون ممکن است)؛ بنابراین در بعضی معماری‌ها برای پروزودی و خروجی آکوستیکی مؤلفه‌ها و تابع هزینه‌های جدا تعریف می‌شود (مثلاً FastSpeech 2: پیش‌بین‌های جدا برای مدت، گام و انرژی).

۹.۷ وکودر: از طیف‌نگار به موج

ماژولی که نمایش آکوستیکی را به Waveform تبدیل می‌کند **وکودر** (Vocoder) نام دارد (از «Voice + coder»).

۱.۹.۷ چرا ساختن موج از طیف‌نگار ساده نیست؟

ضرایب تبدیل فوریه هم **دامنه** دارند و هم **فاز**. برای ضریب $X = a + jb$:

$$|X| = \sqrt{a^2 + b^2}, \qquad \phi = \operatorname{atan2}(b, a).$$

طیف‌نگار فقط اندازه (Magnitude) را نگه می‌دارد و فاز را (که مشخص می‌کند هر مؤلفهٔ فرکانسی کجای زمان است و چگونه با بقیه ترکیب می‌شود) کنار می‌گذارد. پس بدون اطلاعات یا تخمین اضافی نمی‌توان همهٔ جزئیات موج اولیه را بازیافت.

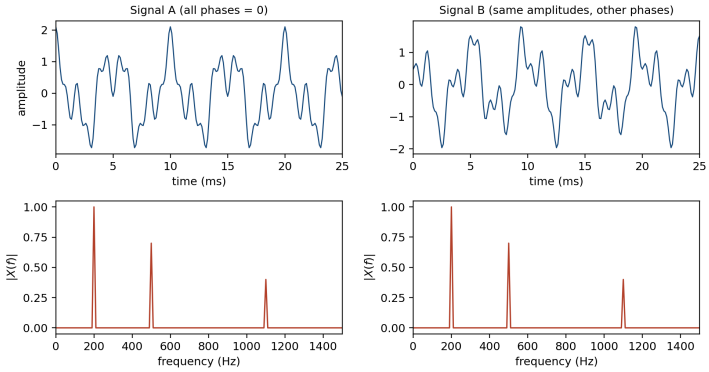
[محتوای افزوده] مثال عددی: اندازه یکسان، فاز متفاوت

$X_1 = 3 + 4j$ و $X_2 = -3 + 4j$ هر دو اندازهٔ $\sqrt{9 + 16} = 5$ دارند، ولی $\phi_1 \approx 53.1^\circ$ و $\phi_2 \approx 126.9^\circ$. از روی اندازهٔ ۵ نمی‌توان فهمید ضریب اصلی کدام بوده است. شکل زیر همین را روی سیگنال نشان می‌دهد: دو سیگنال با طیف اندازهٔ یکسان و شکل موج کاملاً متفاوت.

۲.۹.۷ بازسازی فاز و مدل‌های مولد

برای ساختن موج باید فاز را بازسازی یا سیگنالی سازگار تولید کرد:

- **کلاسیک (Griffin–Lim):** فاز را تکراری حدس می‌زند تا طیف‌نگار سیگنال با طیف‌نگار مفروض سازگار شود؛ ساده و بدون آموزش، اما صدایی مصنوعی و «وزوزی» دارد.
- **وکودرهای عصبی:** شبکه مستقیماً از طیف‌نگار به موج می‌رسد؛ مثلاً WaveNet (خودهمبسته، نمونه‌به‌نمونه و کند) و HiFi-GAN (سریع، مبتنی بر GAN).



شکل ۶.۷: دو سیگنال با طیف اندازهٔ یکسان و فازهای متفاوت: ردیف بالا شکل موج و ردیف پایین طیف اندازه. (شکل افزوده)

فاز «کاملاً» از بین نمی‌رود

چون پنجره‌های طیف‌نگار هم‌پوشان‌اند، افزونگی وجود دارد و فاز را می‌توان از سازگاری میان قاب‌ها تا حد خوبی تخمین زد (کاری که Griffin–Lim می‌کند). طیف‌نگار مل علاوه بر فاز تفکیک فرکانسی را هم کم می‌کند؛ پس ساخت موج از مل مسئله‌ای تقریباً بدوضع‌طرح‌شده است که با مدل مولد خوب حل می‌شود.

GAN. شبکهٔ مولد رقابتی (Generative Adversarial Network, GAN) دو بخش دارد: **مولد** (Generator) که خروجی مصنوعی (اینجا موج) می‌سازد و **تمایزدهنده** (Discriminator) که می‌کوشد آن را از نمونهٔ واقعی تشخیص دهد؛ بازخورد تمایزدهنده مولد را بهتر می‌کند. در پاسخ به پرسشی در کلاس، استاد روشن کرد که مدل لازم نیست «فاز» مستقل تولید کند؛ می‌تواند مستقیماً موج بسازد و با تابع‌های هزینه کیفیتش را بهتر کند. جزئیات به جلسات بعد موکول شد.

۱۰.۷ جمع‌بندی خط‌لولهٔ TTS

مرحله	ورودی	خروجی	وظیفه
Text Normalization	متن خام	متن قابل خواندن	گسترش NSW
Homograph Disamb.	متن دارای هم‌نویسه	تلفظ مشخص‌شده	رفع ابهام بافتی و نحوی
G2P	نویسه‌ها	واج‌ها	تبدیل نوشتار به نمایش واجی
Acoustic Model	توالی واج‌ها	طیف‌نگار (مل)	تولید نمایش آکوستیکی
Vocoder	طیف‌نگار	موج	تولید موج گفتار

چرا خط‌لوله هنوز مهم است؟ کنترل مستقل هر بخش (تنظیم نرمال‌ساز برای یک دامنه، کاهش تأخیر، مدل کلاسیک برای بخشی از سامانه، تمرکز روی اعداد یا هم‌نویسه‌ها) مهم است؛ انتخاب معماری باید بر پایهٔ مسئله و محدودیت‌های

کاربرد باشد.

ارزیابی و جلسات آینده

در پایان کلاس قرار شد مفاهیمی مانند Transformer، Self-Attention، Cross-Attention، Encoder–Decoder و GAN به‌اندازهٔ لازم توضیح داده شوند تا بتوان به آن‌ها ارجاع داد؛ یک جلسه هم به End-to-End اختصاص می‌یابد. استاد اشاره کرد که مطالب تدریس‌شده می‌توانند در امتحان بیایند. تکلیف مشخصی اعلام نشد.

۱۱.۷ جمع‌بندی

در این جلسه از تحلیل سیگنال به **تولید** سیگنال رسیدیم. TTS دشوار است چون متن بسیار کم‌حجم‌تر از موج است و اطلاعات پروزودی و گوینده را ندارد. سامانه به Front-End (نرمال‌سازی، رفع ابهام هم‌نویسه، G2P) و Back-End (مدل آکوستیکی و وکودر) تقسیم می‌شود. در بخش اول «خواندنی کردن» متن مهم است و با نرمال‌سازی NLP فرق دارد؛ در بخش دوم طیف‌نگار مل پیچیدگی را کم می‌کند و وکودر باید فاز ازدست‌رفته را بازسازی کند.

نکات مهم برای مرور و امتحان

۱. TTS: متن ← موج. چالش‌ها: شکاف حجم اطلاعات، کم‌گویی متن، نگاشت یک‌به‌چند.

۲. دو رویکرد Pipeline و End-to-End؛ سرتاسری لزوماً بهتر نیست (تأخیر، دامنه، کنترل).

۳. Front-End (متن ← واج) و Back-End (واج ← طیف‌نگار ← موج).

۴. نرمال‌سازی TTS گسترش‌دهنده و آواشناسی‌محور است، نه کاهنده مانند Hazm.

۵. NSW: ابتدا تشخیص دستهٔ توکن، سپس مبدل همان دسته؛ فراوانی NSW به دامنه وابسته است (توییتر و SMS بیشتر از خبر).

۶. هم‌نویسه‌ها با POS و بافت (Contextual Embedding) حل می‌شوند؛ هر ابهام معنایی ابهام تلفظی نیست.

۷. G2P: سه پیش‌نیاز: الفبای آوایی (IPA)، فرهنگ تلفظ، مدل؛ نگاشت یک‌به‌یک نیست.

۸. چالش‌های Back-End: پروزودی، اختلاف نرخ (۳۰ واج در برابر ۷۲ ۰۰۰ نمونه)، هم‌ترازی زمانی و هم‌تولیدی.

۹. مدل آکوستیکی واج را به طیف‌نگار مل می‌برد؛ نمایش میانی پیچیدگی را کم می‌کند (مثال تهران-مشهد).

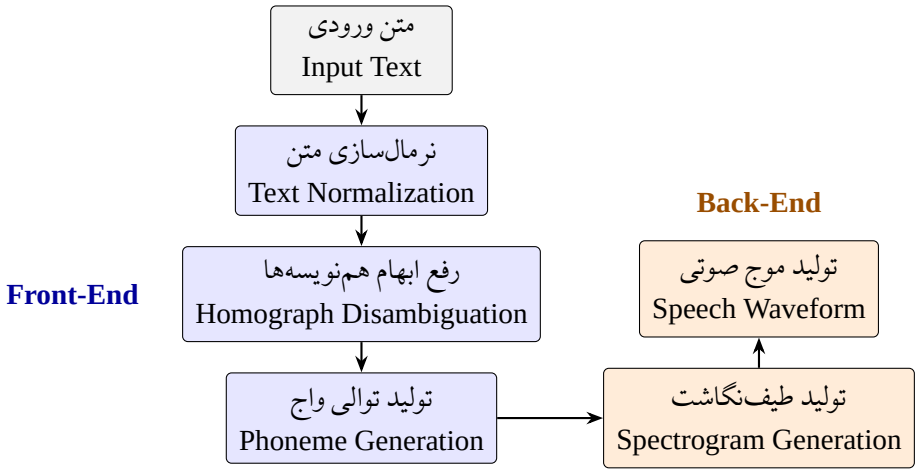
۱۰. وکودر طیف‌نگار را به موج می‌برد؛ مشکل اصلی: از دست رفتن فاز. راه‌حل‌ها: Griffin–Lim و وکودرهای عصبی (WaveNet، HiFi-GAN).

فصل ۸

بازنمایی متن در TTS: از One-Hot تا بازنمایی وابسته به بافت

۱.۸ مروری بر معماری سامانه‌های تبدیل متن به گفتار

سامانه‌های **تبدیل متن به گفتار** (Text-to-Speech) را می‌توان به دو شکل ساخت: **معماری خط‌لوله‌ای** (Pipeline-Based) (چند ماژول مستقل که خروجی هر یک ورودی بعدی است) و **معماری سرتاسری** (End-to-End) (یک مدل یکپارچه). تمرکز فعلی درس بر معماری خط‌لوله‌ای است تا هر ماژول را جداگانه بشناسیم.



شکل ۱.۸: مراحل معماری خط‌لوله‌ای TTS: سه مرحلهٔ آبی «بخش پیشین» و دو مرحلهٔ نارنجی «بخش پسین» است.

بخش پیشین و بخش پسین

بخش پیشین (Front-End) با متن کار می‌کند (نرمال‌سازی، رفع ابهام، استخراج اطلاعات تلفظی). **بخش پسین** (Back-End) با بازنمایی‌های صوتی سروکار دارد و صدای نهایی را می‌سازد. این دو با مفاهیم هم‌نام در توسعهٔ وب ارتباطی ندارند.

تأکید استاد درباره ماژولار بودن

هر ماژول را باید جداگانه یاد گرفت؛ زیرا ممکن است در پروژه‌ای به یکی از آن‌ها بیشتر نیاز داشته باشیم یا بخواهیم چند ماژول را ادغام کنیم. مدل‌های بزرگ سرتاسری از نظر منابع محاسباتی و **تأخیر** (Latency) محدودیت دارند؛ پس شناخت معماری‌های کوچک و ماژولار همچنان مهم است.

هدف اصلی این جلسه: تشخیص تلفظ درست **هم‌نویسه‌ها** (Homograph) با استفاده از بازنمایی کلمات و بافت جمله. برای این کار باید بدانیم کلمه چگونه به شبکهٔ عصبی داده می‌شود و شبکه چگونه آموزش می‌بیند.

۲.۸ بازنمایی متن برای شبکه‌های عصبی

شبکه‌های عصبی مستقیماً با کلمات کار نمی‌کنند و به بازنمایی عددی نیاز دارند.

۱.۲.۸ بازنمایی One-Hot

در بردار **تک‌داغ** (One-Hot) برای واژگانی با V کلمه، هر کلمه برداری به طول V است که فقط مؤلفهٔ متناظر با اندیس کلمه ۱ و بقیه صفرند (مثلاً کلمهٔ سوم از پنج کلمه: $(۰, ۰, ۱, ۰, ۰)$). چهار محدودیت مهم:

۱. **ابعاد زیاد:** طول بردار برابر اندازهٔ واژگان است.

۲. **پراکنده بودن (Sparse):** بیشتر مؤلفه‌ها صفرند.

۳. **تعامد (Orthogonality):** ضرب داخلی هر دو بردار متفاوت صفر است.

۴. **نبود شباهت معنایی:** کلمات هم‌معنا یا هم‌گروه (مثلاً نام دو شهر) هیچ نزدیکی عددی ندارند.

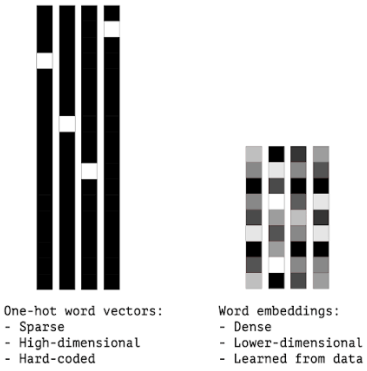
ریشهٔ مشکل: کلمات بر اساس **بافت** (Context) و **هم‌وقوعی** (Co-occurrence) به هم مرتبط‌اند و One-Hot هیچ‌یک را نشان نمی‌دهد.

۲.۲.۸ بازنمایی توزیع‌شده: Word Embedding

در **تعبیهٔ کلمه** (Word Embedding) یک بُعد دلخواه (مثلاً ۱۲۸ یا ۳۰۰) انتخاب و به هر کلمه برداری با همین طول نسبت داده می‌شود. هر مؤلفه یک ویژگی عددی است که در آموزش یاد گرفته می‌شود و لازم نیست از ابتدا معنایش مشخص باشد.

بازنمایی توزیع‌شده در برابر پراکنده

در بازنمایی پراکنده هر کلمه یک خانهٔ روشن منحصربه‌فرد است. در بازنمایی **توزیع‌شده** (Distributed) معنای هر کلمه در چند مؤلفه پخش می‌شود و هر مؤلفه در بازنمایی چندین کلمه نقش دارد؛ به همین دلیل فاصله و زاویهٔ میان بردارها معنا پیدا می‌کند.



شکل ۲.۸: مقایسهٔ بردارهای One-Hot (پراکنده، با ابعاد زیاد و ازپیش‌تعریف‌شده) و Embedding (متراکم، با ابعاد کم‌تر و آموخته‌شده از داده).

جدول ۱.۸: مقایسهٔ دو بازنمایی

ویژگی	One-Hot	Embedding
تراکم	پراکنده (Sparse)	متراکم (Dense)
بُعد	برابر اندازهٔ واژگان	کوچک و دلخواه
چگونگی ساخت	ازپیش‌تعریف‌شده	آموخته از داده
شباهت معنایی	ندارد	دارد

۳.۲.۸ بردارهای Embedding چگونه یاد گرفته می‌شوند؟

بردارها ابتدا تصادفی مقداردهی می‌شوند و سپس یک **وظیفهٔ آموزشی** (Task) تعریف می‌شود. چرخهٔ یادگیری: دریافت ورودی، پیش‌بینی خروجی، مقایسه با مقدار صحیح (Ground Truth)، محاسبهٔ خطا و تغییر وزن‌ها برای کاهش خطا. بردارهای Embedding نیز پارامتر قابل یادگیری‌اند و پس از آموزش می‌توان فقط آن‌ها را برداشت و در مدل‌های دیگر به کار برد.

یک وظیفهٔ رایج، پنهان‌کردن بخشی از جمله است: «من امروز به [MASK] رفتم.» مدل باید از کلمات اطراف حدس بزند. مزیت: به برچسب‌گذاری دستی نیاز نیست، چون پاسخ صحیح از قبل معلوم است (بخش ۷.۸).

- **پیش‌آموزش** (Pre-training): آموزش روی داده‌ای بزرگ برای یادگیری بازنمایی‌های عمومی زبان.
- **تنظیم دقیق** (Fine-tuning): برداشتن وزن‌های ازپیش‌آموزش‌دیده و ادامهٔ آموزش با داده‌های دامنهٔ موردنظر.
- **آموزش از صفر** (Training from Scratch): شروع از مقداردهی جدید، بدون وزن‌های ازپیش‌آموخته.

نکتهٔ مورد تأکید استاد

صرفاً دانلود یک Embedding آماده همیشه مسئلهٔ یک پروژهٔ تخصصی را حل نمی‌کند (مثلاً با اصطلاحات تخصصی یا کلمات OOV). باید بدانیم Embedding چگونه ساخته شده و چگونه با نیاز خودمان سازگار می‌شود.

۳.۸ مروری بر مبانی شبکه‌های عصبی

برای فهم آموزش Embeddingها و مدل‌های تشخیص تلفظ، اصول شبکه‌های عصبی را در سطح مقدماتی مرور می‌کنیم؛ در پایان جلسه قرار شد همین سطح حفظ شود.

۱.۳.۸ ساختار شبکه

شبکه از **لایهٔ ورودی** (Input Layer) (دریافت داده، مثل بردار کلمات)، **لایه‌های پنهان** (Hidden Layers) (بازنمایی‌های میانی) و **لایهٔ خروجی** (Output Layer) (مثلاً پیش‌بینی یک کلمه یا انتخاب یک کلاس تلفظ) ساخته می‌شود. با افزایش لایه‌های پنهان شبکه عمیق‌تر می‌شود و بازنمایی‌های انتزاعی‌تری می‌آموزد. استاد POS Tagging (اطلاعات نحوی)، NER (دسته‌بندی موجودیت‌های نامدار) و Commonsense Reasoning (دانش عمومی) را از نظر پیچیدگی مقایسه کرد.

قید استاد دربارهٔ مقایسهٔ وظایف

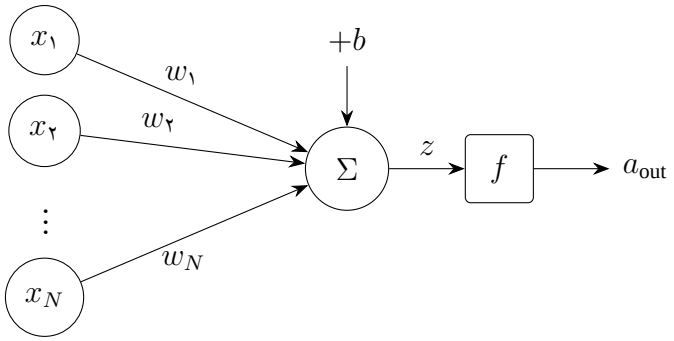
این ترتیب مطلق نیست؛ مثلاً NER می‌تواند چند کلاس ساده یا هزاران کلاس با روابط Ontology داشته باشد. عمق موردنیاز شبکه به تعریف دقیق مسئله بستگی دارد.

۲.۳.۸ نورون: مرحلهٔ پیش‌رو (Feedforward)

هر نورون ورودی‌ها را در وزن‌ها ضرب، جمع و با بایاس ترکیب می‌کند:

$$\mathbf{z} = W\mathbf{x} + \mathbf{b}, \qquad \mathbf{a} = f(\mathbf{z}),$$

که W ماتریس وزن‌ها، $\mathbf{b}$ بایاس و f تابع فعال‌سازی است.

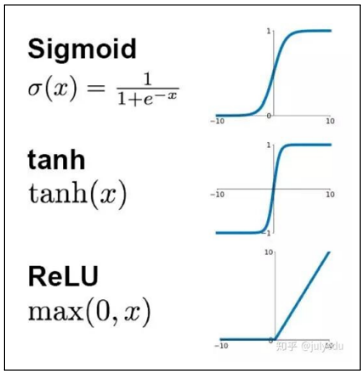


شکل ۳.۸: ساختار یک نورون: $z = b + \sum_i w_i x_i$ و سپس $a_{\text{out}} = f(z)$.

نقش بایاس. **بایاس** (Bias) به مدل اجازه می‌دهد خروجی را مستقل از حاصل‌ضرب وزن‌ها و ورودی جابه‌جا کند. استاد مثال «کرایهٔ تاکسی» زد: حتی برای سفر لغوشده (مسافت صفر) یک هزینهٔ پایه وجود دارد. هندسی: رابطه از اجبار عبور از مبدأ آزاد می‌شود.

تابع فعال‌سازی. بدون آن، ترکیب هر تعداد لایه همچنان یک تبدیل خطی است، در حالی که مرز مفاهیم در دنیای واقعی غیرخطی است. **تابع فعال‌سازی** (Activation Function) (مانند Sigmoid، tanh، ReLU) رفتار شبکه را از خط صاف به منحنی تبدیل می‌کند. برای Sigmoid:

$$\sigma(z) = \frac{۱}{۱ + e^{-z}}, \qquad \sigma'(z) = \sigma(z)\big(۱ - \sigma(z)\big).$$



شکل ۴.۸: Sigmoid، tanh و ReLU. (برگرفته از تختهٔ کلاس)

۳.۳.۸ تابع خطا، چشم‌انداز خطا و کاهش گرادیان

خروجی با Ground Truth مقایسه می‌شود؛ یک تابع خطا **میانگین مربعات خطا** (Mean Squared Error) است:

$$\text{MSE} = \frac{۱}{n}\sum_{i=۱}^{n}(y_i - \hat{y}_i)^۲,$$

که y_i مقدار واقعی و $\hat{y}_i$ پیش‌بینی است. هدف آموزش کاهش این مقدار است.

استاد از مفهوم **چشم‌انداز خطا** (Loss Landscape) استفاده کرد: سطحی که ارتفاعش مقدار خطا و بقیهٔ ابعادش وزن‌هاست.

اگر مشتق خطا نسبت به وزن مثبت باشد، افزایش وزن خطا را زیاد می‌کند؛ پس باید در جهت مخالف شیب حرکت کنیم («اگر از لاس مشتق بگیریم و مثبت شد، آن را در منفی ضرب می‌کنیم»). این مبنای **کاهش گرادیان** (Gradient Descent) است:

$$\boxed{w_{\text{new}} = w_{\text{old}} - \eta \frac{\partial E}{\partial w}}$$

که η **نرخ یادگیری** (Learning Rate) (اندازهٔ گام) است: اگر بسیار کوچک باشد حرکت کند است، اگر مناسب باشد همگرا می‌شود و اگر بسیار بزرگ باشد از کمینه می‌پرد و ممکن است همگرا نشود.



شکل ۵.۸: اثر نرخ یادگیری: بسیار کوچک، مناسب و بسیار بزرگ. (برگرفته از تختهٔ کلاس)

۴.۳.۸ پس‌انتشار و قانون زنجیره‌ای

سهم هر وزن در خطا با **قانون زنجیره‌ای** (Chain Rule) محاسبه می‌شود؛ این کار را **پس‌انتشار** (Backpropagation) می‌نامند. برای نورون خروجی با

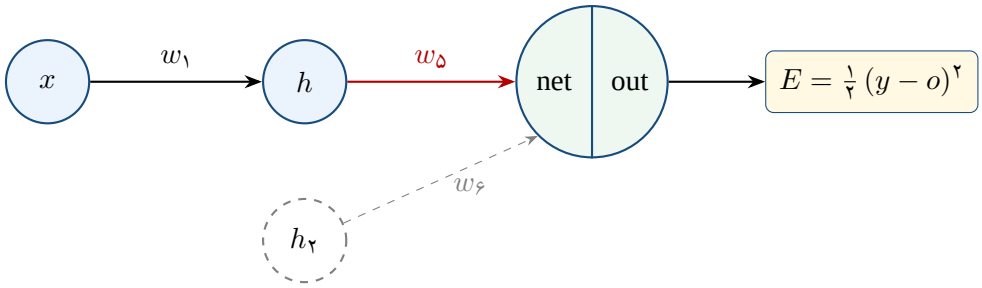
$$\text{net} = h\,w_۵ + \cdots, \qquad o = \sigma(\text{net}), \qquad E = \tfrac{۱}{۲}(y-o)^۲,$$

داریم:

$$\frac{\partial E}{\partial w_۵} = \frac{\partial E}{\partial o}\cdot\frac{\partial o}{\partial \text{net}}\cdot\frac{\partial \text{net}}{\partial w_۵}$$

$$\boxed{\frac{\partial E}{\partial w_۵} = (o-y)\,o\,(۱-o)\,h}$$

زیرا $\partial E/\partial o = o-y$، $\partial o/\partial \text{net} = o(۱-o)$ و $\partial \text{net}/\partial w_۵ = h$.



شکل ۶.۸: شبکهٔ ساده برای پس‌انتشار و محاسبهٔ $\partial E/\partial w_۵$.

دقت در علامت و ضریب مشتق

در کلاس علامت و ضریب مشتق به‌دقت تثبیت نشد. نتیجهٔ بالا برای $E = \frac{۱}{۲}(y-o)^۲$ است؛ برای تابع خطای دیگر (مثل Cross-Entropy) جزء $\partial E/\partial o$ تغییر می‌کند و باید طبق تعریف دقیق همان تابع محاسبه شود.

[محتوای افزوده] مثال عددی: یک نورون، یک گام یادگیری

ورودی $\mathbf{x} = (۲, ۱)$، وزن‌ها $\mathbf{w} = (۰/۴, -۰/۳)$، $b = ۰/۱$، Sigmoid و هدف $y = ۱$. پیش‌رو: $z = ۰/۶$، $o = \sigma(۰/۶) \approx ۰/۶۴۶$، $E \approx ۰/۰۶۲۸$. پس‌انتشار: $\delta = (o-y)\,o\,(۱-o) \approx -۰/۰۸۱۱$ و گرادیان‌ها $\delta x_۱ \approx -۰/۱۶۲$ ، $\delta x_۲ \approx -۰/۰۸۱$ ، $\delta \approx -۰/۰۸۱$. با $\eta = ۱$: $w_۱ \approx ۰/۵۶۲$ ، $w_۲ \approx -۰/۲۱۹$ ،

$b \approx ۰٫۱۸۱$؛ اکنون $o \approx ۰٫۷۴۸$ و $E \approx ۰٫۰۳۱۸$، یعنی خطا تقریباً نصف شد.

چرخهٔ آموزش پنج گام دارد: مقداردهی تصادفی، Feedforward، تولید خروجی، محاسبهٔ Loss و Backpropagation همراه با به‌روزرسانی وزن‌ها.

۴.۸ مسئلهٔ هم‌نویسه در TTS

هم‌نویسه (Homograph) کلمه‌ای است با نوشتار یکسان و تلفظ (و معمولاً معنای) متفاوت. در فارسی چون بیشتر مصوت‌های کوتاه نوشته نمی‌شوند، این مسئله اهمیت ویژه‌ای دارد.

جدول ۲.۸: نمونه‌های هم‌نویسه در فارسی

کلمه	بافت اول	بافت دوم
کرم	کرم مرطوب‌کننده (kerem)	کرم خاکی (kerm)
مرد	آن مرد وارد شد (mard)	او از دنیا مرد (mord)
سرم	سرم به شدت درد می‌کند (saram)	سرم را از دستش کشیدند (serom)

«شیر» هم‌نویسهٔ تلفظی نیست

«شیر آب»، «شیر جنگل» و «شیر خوراکی» همگی /ʃir/ تلفظ می‌شوند؛ «شیر» کلمه‌ای چندمعنایی (Homonym) است نه هم‌نویسه با تلفظ‌های متفاوت. برای TTS فقط مواردی مسئله‌ساز است که تلفظ‌ها فرق کنند (مانند «کرم» و «مرد»)؛ اما «شیر» مثال خوبی برای محدودیت Embedding ثابت در فهم معناست.

نقش POS Tagging. گاهی **برچسب‌گذاری اجزای کلام** (POS Tagging) کافی است: «او مُرد» فعل و «آن مَرد» اسم است. اما «کِرم خاکی» و «کِرمِ مرطوب‌کننده» هر دو اسم‌اند؛ پس به اطلاعات معنایی و بافتی، یعنی Contextual Embedding، نیاز داریم. مثلاً «کرم خاکی» با باغچه و خاک هم‌وقوعی دارد و «کرم مرطوب‌کننده» با پوست و آرایش؛ بازنمایی کلمه باید این بافت را در خود داشته باشد.

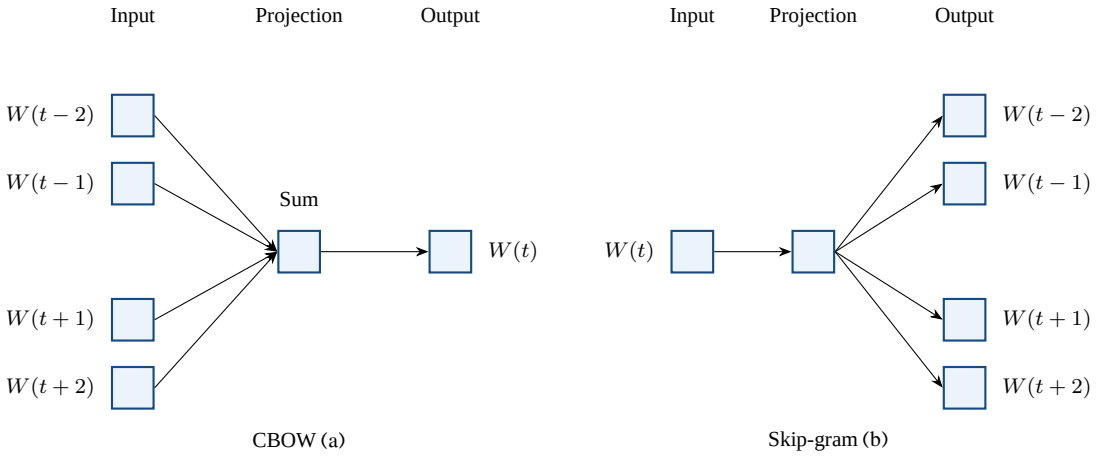
۵.۸ Embedding ایستا و Word2Vec

Word2Vec بر پایهٔ ارتباط هر کلمه با کلمات اطرافش آموزش می‌بیند و دو معماری دارد. بردارهای حاصل **ایستا** (Static) هستند: یک بردار ثابت برای هر مدخل واژگان.

- **کیسهٔ کلمات پیوسته** (Continuous Bag of Words) (CBOW): کلمات داخل یک **پنجرهٔ بافت** (Context Window) ورودی‌اند و مدل کلمهٔ مرکزی را پیش‌بینی می‌کند (بافت ← هدف)؛ بازنمایی کلمات اطراف جمع یا میانگین می‌شود.

- Skip-gram: کلمهٔ مرکزی ورودی است و مدل کلمات اطراف را پیش‌بینی می‌کند (هدف ← بافت).

Word2Vec — Static Embedding: یک بردار ثابت برای هر کلمه
در زمان آموزش: Context-Based model
در زمان استنتاج: Context-independent



هدف: پیش‌بینی کلمهٔ هدف (Target) با استفاده از کلمات پیرامون (Context).

هدف: پیش‌بینی کلمات پیرامون (Context) با دریافت یک کلمهٔ ورودی (Target).

برای کاری که کلمات نادر (Rare words) زیادی دارد کدام بهتر است؟

شکل ۷.۸: دو معماری Word2Vec: CBOW و Skip-gram، همراه با یادداشت‌های استاد روی تخته.

پرسش استاد: برای کلمات نادر کدام بهتر است؟

پاسخ: Skip-gram. در CBOW کلمهٔ نادر فقط در جایگاه «هدف» است و اطلاعات چند کلمه در یک بردار ادغام می‌شود، پس فرصت‌های یادگیری آن کم است. در Skip-gram هر رخداد کلمهٔ نادر چند جفت آموزشی (کلمه، همسایه) می‌سازد. استاد افزود اگر داده نویز نداشته باشد حتی یک رخداد هم ممکن است اطلاعات مفیدی بدهد، اما یادگیری از نمونهٔ بسیار اندک همچنان محدود است.

دقت دربارهٔ CBOW و Word2Vec

در CBOW کلمات پنجره میانگین یا جمع می‌شوند و ترتیب نقشی ندارد؛ پس همهٔ کلمات اطراف سهم برابر دارند و کلمهٔ مهم (مثلاً «مریض» برای پیش‌بینی «دکتر») وزن بیشتری نمی‌گیرد. همین انگیزهٔ مهم Attention است. همچنین بردار مورد استفاده معمولاً از ماتریس ورودی (جدول جست‌وجو) برداشته می‌شود و در عمل برای کاهش هزینهٔ خروجی از Negative Sampling یا Hierarchical Softmax استفاده می‌شود. پس از آموزش فقط بردارها را نگه می‌داریم.

۶.۸ محدودیت Embedding ایستا در تشخیص هم‌نویسه

مهم‌ترین نکتهٔ جلسه: تفاوت میان Embeddingای که در زمان آموزش از بافت ساخته شده و Embeddingای که در زمان استفاده به بافت جملهٔ جدید وابسته است.

در Word2Vec برای «کرم» یک بردار ثابت داریم:

$$E(\text{«کرم در «کرم مرطوب‌کننده را روی پوست زدم»}) = E(\text{«کرم در «کرم خاکی در باغچه بود»}).$$

این بردار در آموزش از همهٔ بافت‌ها ساخته شده (نوعی «میانگین»)، اما در استفاده برای همهٔ رخدادها یکسان است؛ پس به‌تنهایی تلفظ درست را مشخص نمی‌کند.

راه‌حل با Embedding ثابت: در کنار آن یک مدل انتخاب تلفظ می‌گذاریم: Embedding ثابت کلمه و کلمات اطراف هم‌نویسه را به مدل می‌دهیم، بخش پیش‌بینی‌کننده را با داده‌های دارای برچسب تلفظ آموزش می‌دهیم و مدل بر پایهٔ بافت تلفظ را برمی‌گزیند. اگر z_i امتیاز (logit) تلفظ iام و C بافت باشد:

$$P(P_i \mid C) = \frac{e^{z_i}}{\sum_j e^{z_j}}, \qquad \hat{P} = \arg\max_i P(P_i \mid C).$$

برای تعداد متفاوت تلفظ‌ها، استاد یک Linear Layer و سپس Softmax پیشنهاد کرد، به شرط آنکه مجموعهٔ گزینه‌ها از پیش مشخص باشد؛ معماری دقیق این بخش در جلسهٔ بعد بررسی می‌شود.

۷.۸ چرا همهٔ تلفظ‌ها را از ابتدا برچسب نمی‌زنیم؟

دانشجویی پیشنهاد کرد برای هر تلفظ از ابتدا یک بازنمایی جداگانه («کرم۱»، «کرم۲») داشته باشیم. استاد: از نظر مفهومی ممکن است، اما چه کسی باید تمام رخدادها را برچسب بزند؟ این کار بسیار پرهزینه است.

تأکید استاد

برچسب‌گذاری (Annotation) یکی از گلوگاه‌های مهم توسعهٔ سامانه‌های هوش مصنوعی است.

راه‌حل: وظایفی که برچسبشان از خود متن می‌آید، مانند **مدل‌سازی زبان نقاب‌دار** (Masked Language Modeling) (MLM: پنهان‌کردن کلمات و پیش‌بینی آن‌ها) و **پیش‌بینی جملهٔ بعدی** (Next Sentence Prediction) (NSP در BERT اولیه). NSP بیشتر یک نمونهٔ تاریخی است و پژوهش‌های بعدی (مانند RoBERTa) نشان دادند حذفش آسیبی نمی‌زند؛ MLM وظیفهٔ اصلی است.

یادگیری نظارتی در برابر خودنظارتی

در **یادگیری نظارتی** (Supervised Learning) انسان داده را برچسب می‌زند. در **یادگیری خودنظارتی** (Self-Supervised Learning) برچسب از خود داده ساخته می‌شود (مثلاً کلمهٔ حذف‌شده). نتیجه: نیاز به برچسب دستی کم می‌شود، استفاده از متن‌های بسیار بزرگ ممکن می‌شود و مدل بازنمایی عمومی می‌آموزد که بعداً تنظیم دقیق می‌شود. به تأکید استاد، یکی از جهش‌های بزرگ مدل‌های زبانی همین بود.

۸.۸ Embedding وابسته به بافت (پویا)

برای اینکه Embedding با جملهٔ ورودی تغییر کند، از **Embedding وابسته به بافت** (Contextual Embedding) (پویا) استفاده می‌کنیم. در بازنمایی ایستا $E(w) = \mathbf{v}_w$ فقط به هویت کلمه بستگی دارد؛ در بازنمایی وابسته به بافت $E(w, C) = \mathbf{v}_{w,C}$ که C جملهٔ حاوی کلمه است، و ممکن است $E(\text{کرم}, C_۱) \neq E(\text{کرم}, C_۲)$.

جدول ۳.۸: مقایسهٔ دو نوع Embedding به روایت تختهٔ کلاس

	ایستا	وابسته به بافت
تعریف	بردار خروجی تابعی از همهٔ جمله‌هایی است که کلمه در زمان آموزش در آن‌ها دیده شده	بردار خروجی تابعی از کل کلمات جملهٔ فعلی است
زمان استفاده	کلمه به‌تنهایی وارد جدول جست‌وجو می‌شود	کلمه در بستر جمله وارد شبکه می‌شود و بردار نهایی از رابطه با همسایه‌ها ساخته می‌شود
چیزی که دانلود می‌کنید	فایلی با یک سطر (مثلاً ۳۰۰ عدد) برای هر کلمه؛ «شیر» در هر معنا همان بردار است	وزن‌های شبکه (Weights & Biases)؛ بردار کلمه تا ورود جمله وجود ندارد

۹.۸ استفاده از Attention برای ساخت Embedding وابسته به بافت

سازوکار توجه (Attention Mechanism) سه گام دارد: (۱) نمایش همهٔ موقعیت‌های ورودی را در اختیار داشته باش؛ (۲) ارتباط هر موقعیت را با بقیه محاسبه کن؛ (۳) بر اساس وزن‌های ارتباط، اطلاعات موقعیت‌ها را ترکیب کن تا نمایش جدید هر موقعیت به‌دست آید. به‌جای ترکیب یکسان همهٔ کلمات اطراف (مانند CBOW) مدل می‌سنجد هر کلمه چقدر مرتبط است.

- **پرس‌وجو** (Query) (Q): نمایندهٔ چیزی که برایش اطلاعات می‌جوییم (کلمهٔ هدف).
- **کلید** (Key) (K): برای سنجش ارتباط هر کلمه با پرس‌وجو.
- **مقدار** (Value) (V): اطلاعاتی که بر اساس میزان ارتباط در خروجی شرکت می‌کند.

شباهت Query و Key (ضرب داخلی) میزان توجه به هر کلمه را می‌دهد و Valueها با این وزن‌ها ترکیب می‌شوند. ماتریس‌های وزنی Q، K و V در آموزش یاد گرفته می‌شوند و در استنتاج ثابت‌اند؛ آنچه با جمله عوض می‌شود بردارهای محاسبه‌شده و در نتیجه خروجی است. استاد تصریح کرد Attention فقط یک ضرب ساده نیست و هدف این جلسه درک شهودی بود. فرمول کامل:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V,$$

که تقسیم بر $\sqrt{d_k}$ از اشباع Softmax در بُعد زیاد جلوگیری می‌کند.

وقتی کلمات یک توالی به کلمات همان توالی توجه می‌کنند، به آن **خودتوجهی** (Self-Attention) می‌گویند: اگر «کرم» کنار «خاکی» و «باغچه» بیاید بازنمایی موجود زنده ساخته می‌شود و اگر کنار «پوست» و «مرطوب‌کننده» بیاید بازنمایی دیگری. Self-Attention هستهٔ **ترنسفورمر** (Transformer) است که در ادامهٔ درس می‌آید. تفاوت اصلی با Word2Vec: شبکه در استنتاج نیز با هر جملهٔ جدید اجرا می‌شود.

دقت دربارهٔ «بردار ثابت» و «بردار پویا»

در بازنمایی وابسته به بافت وزن‌های شبکه در استنتاج عوض نمی‌شوند؛ فقط خروجی به‌ازای جملهٔ ورودی متفاوت است. همچنین Contextual Embedding با Transformer یکی نیست: LSTM دوسویه (مانند ELMo) نیز چنین بازنمایی می‌سازد و Attention یکی از راه‌هاست.

۱۰.۸ پرسش و پاسخ پایان کلاس و ادامهٔ بحث

استاد از دانشجویان پرسید آیا مباحث شبکهٔ عصبی باید با جزئیات بیشتر (مانند **مومنتوم** (Momentum)) تدریس شوند و قرار شد همین سطح مقدماتی حفظ شود. جلسهٔ بعد: بررسی دقیق‌تر لایهٔ خروجی انتخاب تلفظ و Softmax، ادامهٔ معماری‌های مبتنی بر بافت و ورود به Transformer.

۱۱.۸ جمع‌بندی

کلمه ابتدا با One-Hot نمایش داده می‌شود که پراکنده است و شباهت معنایی ندارد. Embedding متراکم و آموخته‌شده این کمبود را جبران می‌کند و Word2Vec آن را از هم‌وقوعی کلمات می‌سازد. اما بردار Word2Vec ایستاست و برای «کرم» در همهٔ جمله‌ها یکسان می‌ماند؛ پس برای TTS یا مدلی روی بافت می‌گذاریم و با داده‌های برچسب‌دار آموزش می‌دهیم، یا از بازنمایی وابسته به بافت بهره می‌گیریم. چون برچسب‌گذاری دستی گران است، پیش‌آموزش خودنظارتی (مانند MLM) اهمیت می‌یابد و Self-Attention ابزار اصلی ساخت این بازنمایی‌هاست.

نکات مهم برای مرور و امتحان

- تفاوت Pipeline و End-to-End؛ تعریف Front-End و Back-End.
- چهار محدودیت One-Hot و مزایای Embedding (تراکم، بُعد کم، شباهت معنایی، آموخته از داده).
- چرخهٔ آموزش: مقداردهی تصادفی، Feedforward، Loss، Backpropagation و به‌روزرسانی؛ رابطهٔ $w_{\text{new}} = w_{\text{old}} - \eta\, \partial E/\partial w$ و اثر نرخ یادگیری.
- نقش بایاس (مثال کرایهٔ تاکسی) و تابع فعال‌سازی (غیرخطی‌کردن).
- CBOW در برابر Skip-gram؛ برای کلمات نادر Skip-gram بهتر است.
- Embedding ایستا: در آموزش وابسته به بافت، در استنتاج مستقل از بافت؛ چرا برای هم‌نویسه کافی نیست.

- چرا همهٔ تلفظ‌ها را برچسب نمی‌زنیم (گلوگاه Annotation) و نقش Self-Supervised Learning.
- مفاهیم Value/Key/Query و فرمول Attention.

فصل ۹

آموزش شبکه، Embedding بافتی و تبدیل نویسه به واج

این فصل سه بخش دارد: مرور آموزش شبکه (لایهٔ خروجی، آموزش در برابر استنتاج، بیش‌برازش)؛ Embeddingهای بافتی، BERT، قیاس برداری و **کاوش** (Probing)؛ و بازگشت به TTS برای یافتن تلفظ درست هر واژه (هم‌نویسه‌ها و G2P). مفاهیم پایهٔ آموزش (انتشار روبه‌جلو، خطا، پس‌انتشار، $w_{\text{new}} = w_{\text{old}} - \eta\, \partial E/\partial w$) در فصل قبل آمده‌اند.

۱.۹ مرور فرایند آموزش شبکهٔ عصبی

۱.۱.۹ طراحی لایهٔ خروجی بر اساس نوع مسئله

نکتهٔ مورد تأکید استاد: خروجی شبکه باید با *Task* هم‌خوان طراحی شود.

نوع مسئله	لایهٔ خروجی	تابع خطا	مثال
Regression	یک خروجی خطی (مقدار پیوسته)	MSE	پیش‌بینی فرکانس پایه
Binary Classification	یک خروجی Sigmoid و آستانه‌گذاری	Binary Cross-Entropy	واکدار/بی‌واک، گفتار/سکوت
Multi-class Classification	Softmax روی K کلاس	Cross-Entropy	نوع احساس صدا، تلفظ درست یک واژه

جدول ۱.۹: ارتباط نوع مسئله با لایهٔ خروجی و تابع خطا.

- **رگرسیون:** اگر شبکه بردار $X \in \mathbb{R}^{1\times 768}$ ساخته باشد، یک لایهٔ خطی $W \in \mathbb{R}^{768\times 1}$ می‌دهد $Y = XW + b$. اگر مسئله پیچیده‌تر باشد، Linear $\rightarrow$ Activation $\rightarrow$ Linear (یک MLP) به‌کار می‌رود؛ استاد تأکید کرد پیچیده‌ترکردن باید بر اساس عملکرد باشد.

- **دودویی:** خروجی یک **لاجیت** (Logit) است که از سیگموید $\sigma(x) = ۱/(۱ + e^{-x}) \in (۰, ۱)$ می‌گذرد؛ مثلاً ۰٫۸ یعنی احتمال کلاس مثبت ۸۰ درصد، و با یک آستانه (Threshold) کلاس نهایی تعیین می‌شود.
- **چندکلاسه:** Softmax لاجیت‌ها را به توزیع احتمال با مجموع ۱ تبدیل می‌کند:

$$P(y = i) = \frac{e^{z_i}}{\sum_{j=۱}^{K} e^{z_j}}, \qquad \sum_{i=۱}^{K} P(y = i) = ۱.$$

در پیش‌بینی توکن بعدی با واژگان V توکن، بردار ۱×۷۶۸ در ماتریس $۷۶۸ \times V$ ضرب می‌شود و بردار لاجیت $۱ \times V$ حاصل می‌شود.

۲.۱.۹ تابع خطا و مثال پیش‌بینی توکن بعدی

برای برچسب One-Hot، Cross-Entropy ساده می‌شود به $L = -\sum_k y_k \log \hat{y}_k = -\log \hat{y}_c$ که در آن c کلاس درست است؛ یعنی فقط احتمالی که مدل به پاسخ درست داده اهمیت دارد. مثال استاد: اگر احتمال پاسخ درست ۰٫۲ باشد، خطا $-\log ۰٫۲ \approx ۱٫۶۱$ است؛ پس از چند گام اصلاح وزن‌ها و رسیدن احتمال به ۰٫۹، خطا به $-\log ۰٫۹ \approx ۰٫۱۰۵$ کاهش می‌یابد. یعنی شبکه یاد می‌گیرد به پاسخ درست احتمال بیشتری بدهد.

۲.۹ آموزش در برابر استنتاج

در فاز **آموزش** (Training) پاسخ درست را داریم و خطا را حساب می‌کنیم؛ در فاز **استنتاج** (Inference) پاسخ درست در دسترس نیست و شبکه فقط یک توزیع احتمال می‌دهد. پرسش این است که از آن توزیع چگونه خروجی نهایی را برداریم.

	آموزش	استنتاج
حقیقت مبنا	در دسترس است	در دسترس نیست
هدف	کمینه‌کردن خطا و اصلاح وزن‌ها	گرفتن خروجی از توزیع احتمال
وزن‌ها	در حال تغییرند	ثابت‌اند
Dropout	فعال	غیرفعال
انتخاب خروجی	لازم نیست	Greedy، Sampling، Top-k، Top-p، Temperature

جدول ۲.۹: مقایسهٔ آموزش و استنتاج.

- **رمزگشایی حریصانه** (Greedy Decoding): انتخاب پراحتمال‌ترین گزینه، $y = \arg\max_i P(y = i)$؛ روشی قطعی (برای $(۰٫۱, ۰٫۳, ۰٫۶)$ همیشه گزینهٔ اول).
- **نمونه‌گیری** (Sampling): خروجی از روی توزیع نمونه‌برداری می‌شود و گزینه‌های کم‌احتمال‌تر هم شانس دارند؛ مفید برای تنوع (مثلاً متن خلاقانه).

- Top-k: فقط k گزینهٔ پراحتمال نگه داشته می‌شود؛ **Top-p** (Nucleus Sampling): کوچک‌ترین مجموعه‌ای که مجموع احتمالش دست‌کم p (مثلاً ۰٫۹) باشد؛ نمونه‌گیری فقط از همان مجموعه.

۱.۲.۹ دما (Temperature)

دما تیزی توزیع را تنظیم می‌کند؛ لاجیت‌ها پیش از Softmax بر T تقسیم می‌شوند: $P_i = e^{z_i/T} / \sum_j e^{z_j/T}$. با $T = ۱$ Softmax معمولی است؛ با $T \to ۰$ توزیع تیز و نزدیک به argmax می‌شود؛ با T بزرگ توزیع هموار و در حد، یکنواخت می‌گردد. دمای بالا تنوع را بیشتر می‌کند ولی احتمال خروجی نامناسب (Hallucination) هم بالاتر می‌رود؛ دمای پایین خروجی را تکرارپذیرتر می‌کند. (مثلاً برای لاجیت $(۲٫۰, ۱٫۰, ۰٫۱)$: $T = ۱$ احتمال‌های $(۰٫۶۶, ۰٫۲۴, ۰٫۱۰)$ و $T = ۰٫۲$ تقریباً $(۰٫۹۹, ۰٫۰۱, ۰٫۰۰)$ می‌دهد.) دما لاجیت‌های یادگرفته‌شده را عوض نمی‌کند و فقط شیوهٔ تبدیل آن‌ها به احتمال را در تولید تغییر می‌دهد.

۳.۹ تعمیم‌پذیری: کم‌برازش، بیش‌برازش و پیچیدگی مدل

برای فهمیدن اینکه مدل به‌اندازهٔ کافی آموزش دیده، خطای آموزشی کافی نیست؛ مدل باید روی داده‌ای ارزیابی شود که در به‌روزرسانی وزن‌ها به‌کار نرفته است. پس داده را به Training (یادگیری وزن‌ها)، Validation (پایش، توقف، انتخاب ابرپارامتر) و Test (گزارش نهایی) تقسیم می‌کنیم؛ مجموعهٔ آزمون نباید برای تنظیم مدل به‌کار رود.

۱.۳.۹ سه وضعیت پس از آموزش

- **کم‌برازش** (Underfitting): مدل حتی داده‌های آموزشی را هم خوب یاد نگرفته است.
- **برازش مناسب** (Good Fit): الگوهای اصلی آموخته شده و روی داده‌های تازه هم خوب عمل می‌کند.
- **بیش‌برازش** (Overfitting): مدل علاوه بر الگوی اصلی، نویز و جزئیات نامربوط داده آموزشی را حفظ کرده و تعمیم نمی‌دهد.

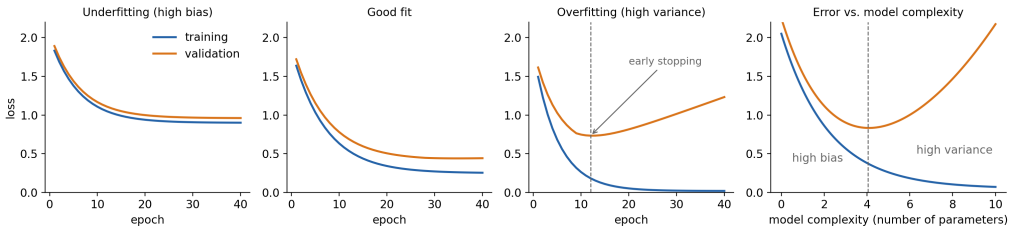
مثال استاد از بیش‌برازش در گفتار

در داده‌های آموزشی یک دستیار صوتی، هر بار که عبارت خاصی گفته شده صدای فن هم در پس‌زمینه بوده است. مدل ممکن است صدای فن را نشانهٔ آن عبارت بگیرد؛ روی داده آموزشی خوب عمل می‌کند ولی روی همان عبارت بدون صدای فن اشتباه می‌کند.

۲.۳.۹ منحنی خطا و توقف زودهنگام

با افزایش Epoch، خطای آموزش معمولاً کم می‌شود؛ خطای اعتبارسنجی نخست کم می‌شود ولی از جایی ممکن است دوباره بالا برود. کمینهٔ آن بهترین نقطه است و افزایش خطای اعتبارسنجی همراه با کاهش خطای آموزش نشانهٔ

بیش‌برازش است. توقف آموزش در این نقطه **توقف زودهنگام** (Early Stopping) نام دارد.



شکل ۱.۹: سه رفتار نوعی در طول آموزش (سه نمودار اول) و رابطهٔ خطا با پیچیدگی مدل (نمودار آخر). مقادیر شبیه‌سازی‌شده‌اند و فقط برای نمایش مفهوم‌اند. (شکل افزوده)

۳.۳.۹ Bias و Variance

	High Bias (کم‌برازش)	High Variance (بیش‌برازش)
نشانه	خطای آموزش و اعتبارسنجی هر دو زیاد و نزدیک به هم	خطای آموزش کم، خطای اعتبارسنجی بسیار بیشتر
راهکار	مدل را پیچیده‌تر کن: لایه و نورون بیشتر، یا معماری مناسب‌تر	داده با کیفیت‌تر، بررسی ناسازگاری برچسب‌ها، متعادل‌کردن داده، Data Augmentation، Regularization

جدول ۳.۹: مقایسهٔ بایاس بالا و واریانس بالا.

تا کجا مدل را پیچیده‌تر کنیم؟

تا جایی که خطای اعتبارسنجی بهتر می‌شود؛ معماری را بر پایهٔ عملکرد تغییر دهید، نه صرفاً با افزودن لایه و نورون.

۴.۳.۹ Regularization

منظم‌سازی (Regularization) هر روشی است که پیچیدگی مؤثر مدل را محدود می‌کند تا تعمیم بهتر شود.

- Dropout: در هر گام آموزش، خروجی تعدادی از نورون‌ها تصادفی صفر می‌شود تا شبکه به مسیر یا ویژگی خاصی بیش‌ازحد تکیه نکند.
- L1 و L2: جملهٔ جریمهٔ وزن‌های بزرگ به خطا افزوده می‌شود، $L_{\text{total}} = L_{\text{task}} + \lambda \sum_i |w_i|$ (L1) یا $L_{\text{task}} + \lambda \sum_i w_i^۲$ (L2) که λ شدت منظم‌سازی است.

پرسش: اگر وزن بزرگ برای یک ویژگی واقعاً خوب باشد چه؟

پاسخ استاد: منظم‌سازی بین وزن مفید و نامفید تمایز مستقیم نمی‌گذارد؛ اگر وزن بزرگی واقعاً لازم باشد، میان کاهش خطا و جریمهٔ وزن مصالحه شکل می‌گیرد و شبکه عمیق با ترکیب ویژگی‌های زیاد عملکرد را حفظ می‌کند. λ را با خطای اعتبارسنجی انتخاب کنید و ویژگی‌ها را هم‌مقیاس (Scaling) کنید، چون جریمهٔ وزن به مقیاس ورودی حساس است.

۴.۹ Embedding ایستا و پویا (بافتی)

Embedding نمایش واژه‌ها یا توکن‌ها با بردارهای عددی چگال است (در برابر بردار تُنُک One-Hot). لایهٔ Embedding دو شاخه دارد: ایستا (Static) و پویا یا بافتی (Contextual).

- **ایستا:** هر روشی که بردار هر واژه تابعی از جمله‌های زمان آموزش باشد. نمونهٔ مهم Word2Vec (CBOW، Skip-gram) است: بردارها با یک Task آموزشی تنظیم می‌شوند و پس از آموزش، بخش پیش‌بینی کنار گذاشته و فقط بردارها نگه داشته می‌شوند. در زمان استفاده، واژه تنها و بدون دیدن جمله وارد یک **جدول جست‌وجو** (Lookup Table) می‌شود؛ مثلاً «شیر» یک سطر ۳۰۰تایی دارد، چه منظور شیر جنگل باشد چه شیر آب. جمع‌بندی استاد: در آموزش Context-based، در استنتاج Context-independent.
- **پویا:** بردار واژه تابعی از کل جملهٔ فعلی است. جمله وارد شبکه می‌شود و بردار بر اساس رابطهٔ واژه با همسایه‌هایش ساخته می‌شود:

$$\text{ایستا: } E(w) = v_w, \qquad \text{بافتی: } E(w, C) = v_{w,C}, \qquad E(\text{شیر}, C_۱) \neq E(\text{شیر}, C_۲).$$

آنچه دانلود می‌کنیم وزن‌ها و بایاس‌های شبکه است و بردار واژه تا ورود جمله وجود ندارد. پس بردار ایستا را می‌توان جدا ذخیره کرد، ولی برای بردار بافتی باید خود مدل اجرا شود.

	ایستا (Static)	پویا (Contextual)
بردار هر واژه	ثابت، یکی برای هر واژه	وابسته به جمله؛ هر رخداد بردار خودش را دارد
زمان استفاده	جست‌وجو در جدول (بدون شبکه)	اجرای شبکه روی کل جمله
خروجی دانلودی	فایل جدول بردارها	وزن‌های شبکه
نمونه	Word2Vec، GloVe	ELMo، BERT

جدول ۴.۹: مقایسهٔ Embedding ایستا و بافتی.

«شیر» هم‌نویسهٔ TTS نیست

«شیر» در هر سه معنا (جنگل، خوراکی، شیرآب) یک‌جور تلفظ می‌شود (/ʃi:r/)؛ پس مثال خوبی برای چندمعنایی و محدودیت Embedding ایستاست، اما Homograph به‌معنای «هم‌نویسه با تلفظ متفاوت» نیست. برای TTS از «مَرد/مُرد» و «کِرم/کَرَم» استفاده می‌کنیم.

Embedding بافتی فقط برای رفع ابهام معنایی نیست؛ مثلاً در **تشخیص مرجع ضمیر** (Coreference Resolution) («من این کتاب را به علی دادم. او ...») بردار باید «او» را به «علی» ربط دهد. اینکه هر لایه چه اطلاعاتی دارد را با Probing می‌سنجیم (بخش ۸.۹).

۵.۹ راه‌های ساخت Embedding بافتی

مسئلهٔ اصلی: چگونه بردار یک واژه را وابسته به متن پیرامونش بسازیم؟ استاد تأکید کرد که Contextual Embedding را نباید با Transformer یکی دانست؛ ابتدا باید مسئله را فهمید و بعد سراغ معماری رفت. دو رویکرد مطرح شد:

- **نگاه موازی (Self-Attention):** نمایش همهٔ موقعیت‌ها را در اختیار داشته باش؛ ارتباط هر موقعیت با بقیه را حساب کن؛ بر اساس وزن‌های ارتباط اطلاعات را ترکیب کن تا نمایش جدید هر موقعیت ساخته شود. به زبان Value/Key/Query: واژهٔ موردنظر (Query) با Key بقیه مقایسه می‌شود و ترکیب وزن‌دار Valueها بردار جدید را می‌دهد.
- **نگاه ترتیبی (LSTM/RNN):** ورودی‌ها به‌ترتیب پردازش می‌شوند و **حالت پنهان** (Hidden State) خلاصه‌ای از توکن‌های قبلی را به گام بعد می‌برد. LSTM با دروازه‌ها (Gating) وابستگی‌های بلندتر را بهتر نگه می‌دارد و BiLSTM هر دو بافت چپ و راست را به‌کار می‌گیرد.

Attention هم‌ارز Transformer نیست

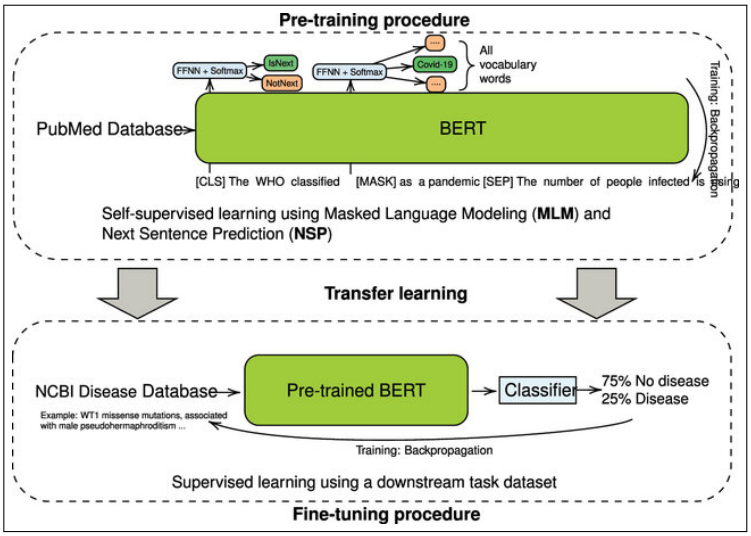
Attention حدود ۲۰۱۴ برای ترجمهٔ ماشینی با شبکه‌های بازگشتی معرفی شد و Transformer (۲۰۱۷) معماری‌ای است که تماماً بر Self-Attention تکیه دارد. سه مفهوم را جدا بدانید: مسئلهٔ ساخت بازنمایی بافتی، سازوکار Attention، و معماری Transformer.

۶.۹ یادگیری خودنظارتی و BERT

یادگیری بازنمایی بافتی به داده بسیار زیاد نیاز دارد و برچسب‌گذاری انسانی گران است. راه‌حل **یادگیری خودنظارتی** (Self-Supervised Learning) است: برچسب از خود داده ساخته می‌شود (در Supervised انسان برچسب می‌زند؛ در Self-supervised مثلاً واژهٔ حذف‌شده از متن اصلی برچسب است). BERT با دو Task پیش‌آموزش می‌شود:

- **مدل‌سازی زبان ماسک‌شده** (Masked Language Modeling, MLM): بخشی از متن پوشانده می‌شود («امروز هوا [MASK] است.») و مدل باید آن را پیش‌بینی کند. چون واژهٔ اصلی را داریم، حقیقت مبنا داریم: خروجی را با واژهٔ واقعی مقایسه، Cross-Entropy حساب، پس‌انتشار و به‌روزرسانی می‌کنیم.
- **پیش‌بینی جملهٔ بعدی** (Next Sentence Prediction, NSP): دو جمله داده می‌شود و مدل می‌گوید آیا جملهٔ دوم ادامهٔ واقعی اول است (نمونهٔ مثبت) یا جملهٔ تصادفی (نمونهٔ منفی)؛ یک دسته‌بندی دودویی. بردار ۷۶۸بعدی توکن [CLS] در یک لایهٔ ۲×۷۶۸ ضرب می‌شود تا دو لاجیت (NotNext/IsNext) به دست آید.

BERT یک Transformer Encoder دوطرفه است. BERT-Base: ۱۲ لایه، بُعد ۷۶۸، حدود ۱۱۰ میلیون پارامتر؛ BERT-Large: ۲۴ لایه، بُعد ۱۰۲۴. برای ورودی با ۷۱ توکن، خروجی هر لایه $H \in \mathbb{R}^{۷۱\times۷۶۸}$ است (یک بردار برای



شکل ۲.۹: فرایند پیش‌آموزش و انتقال یادگیری برای BERT: بالا، پیش‌آموزش خودنظارتی با MLM و NSP (دو سر خروجی روی مدل)؛ پایین، قرار دادن یک دسته‌بند روی BERT پیش‌آموزش‌دیده و آموزش تکمیلی با داده برچسب‌دار Task هدف. (برگرفته از تختهٔ کلاس)

هر توکن). سر MLM روی لایهٔ ۱۲ قرار می‌گیرد: بردار ۱×۷۶۸ موقعیت ماسک با لایهٔ ۷۶۸×۷۶۸ و سپس $۷۶۸ \times V$ به لاجیت‌هایی به‌طول $V = ۳۰۵۲۲$ می‌رسد و Softmax احتمال هر واژهٔ فرهنگ را می‌دهد.

جزئیات دقیق BERT و وضعیت NSP

در MLM حدود ۱۵ درصد توکن‌ها انتخاب می‌شوند (۸۰ درصد با [MASK]، ۱۰ درصد توکن تصادفی، ۱۰ درصد بدون تغییر). پژوهش‌هایی مانند RoBERTa نشان دادند حذف NSP آسیبی نمی‌زند؛ پس NSP ضروری نیست. عدد ۳۰۵۲۲ اندازهٔ واژگان bert-base-uncased است و V به مدل بستگی دارد.

پس از پیش‌آموزش، سر MLM حذف و وزن‌های لایه‌ها نگه داشته می‌شود. دو شیوهٔ استفاده:

۱. **استخراج بردار:** جمله را به شبکه می‌دهیم؛ خروجی لایهٔ ۱۲ برای هر واژه یک بردار ۷۶۸تایی است (Embedding بافتی آن واژه)، و میانگین روی واژه‌ها یک Embedding برای کل جمله می‌دهد.

۲. **انتقال یادگیری** (Transfer Learning): روی شبکه یک دسته‌بند می‌گذاریم و با داده‌ای محدود و مرتبط با Task خود آموزش تکمیلی (Fine-tuning) می‌دهیم.

آیا افزودن لایهٔ بیشتر (Linear یا MLP) همیشه بهتر است؟

نمی‌توان قطعی گفت؛ اگر یک لایهٔ ساده کافی است، پیچیده‌ترکردن لازم نیست، و تصمیم بر اساس خطای آموزش و اعتبارسنجی و بایاس/واریانس گرفته می‌شود.

۷.۹ قیاس برداری (Analogy) در فضای Embedding

اگر روابط معنایی یا ساختاری در فضای Embedding خوب بازتاب یافته باشند، اختلاف بردارهای دو جفت واژهٔ هم‌رابطه تقریباً یکسان است:

$$\vec{v}_{\text{king}} - \vec{v}_{\text{man}} + \vec{v}_{\text{woman}} \approx \vec{v}_{\text{queen}} \quad \Longleftrightarrow \quad \vec{v}_{\text{woman}} - \vec{v}_{\text{man}} \approx \vec{v}_{\text{queen}} - \vec{v}_{\text{king}}.$$

یعنی «جهت» مفهوم زن‌بودن در برابر مردبودن در دو جفت یکی است. استاد توضیح داد چنین الگوهایی نشانهٔ سازمان‌یافتگی مفید فضا هستند اما برای همهٔ واژه‌ها و مدل‌ها تضمین‌شده نیستند.

همین ایده در گفتار هم مطرح است: مقالهٔ «[b] = [d] − [t] + [p]» (چوی و همکاران) گزارش می‌کند که در بازنمایی مدل‌های گفتاری خودنظارتی، جهت‌های خطی متناظر با ویژگی‌های واجی وجود دارد؛ تفاضل $[d] - [t]$ یک «بردار واک‌داری» (Voicing) است و افزودن آن به $[p]$ تقریباً $[b]$ می‌دهد. روی تخته:

$$\vec{v}_{[d]} - \vec{v}_{[t]} + \vec{v}_{[p]} \approx \vec{v}_{[b]}, \qquad \text{یعنی} \qquad \vec{v}_{[d]} - \vec{v}_{[t]} \approx \vec{v}_{[b]} - \vec{v}_{[p]}.$$

کاربردهای مطرح‌شده در کلاس: کشف ویژگی‌های آموخته‌شدهٔ مدل، بررسی لهجه و کاربرد احتمالی در سنتز و Voice Cloning (ایده‌ای قابل بررسی، نه نتیجهٔ قطعی).

محدودیت‌های قیاس برداری

قیاس‌هایی مانند king − man + woman در مثال‌های خوب‌انتخاب‌شده و Embedding ایستا دیده می‌شوند اما همیشه برقرار نیستند و می‌توانند سوگیری داده را منعکس کنند؛ ابزاری شهودی است، نه قانون.

۸.۹ کاوش (Probing) و تفسیرپذیری

درون جعبهٔ سیاه شبکه هر لایه چه اطلاعاتی نگه می‌دارد؟ استاد Probing را به پروب‌زدن در نقاط مختلف یک مدار الکترونیکی تشبیه کرد.

دسته‌بند کاوشگر (Probing Classifier)

Probe یک مدل کوچک و ساده (معمولاً خطی) است که روی خروجی یک لایهٔ مشخص از یک شبکهٔ آموزش‌دیده و منجمدشده آموزش داده می‌شود تا یک ویژگی زبانی یا گفتاری را پیش‌بینی کند. دقت آن نشان می‌دهد آن اطلاعات در آن لایه تا چه حد «قابل استخراج» است.

مراحل: (۱) مدل پیش‌آموزش‌دیده را فریز کن؛ (۲) یک لایه (مثلاً میانی) انتخاب کن؛ (۳) نمایش‌های آن را برای داده‌ای برچسب‌دار (مثلاً Manner of Articulation هر توکن) استخراج کن؛ (۴) یک دسته‌بند کوچک آموزش بده؛ (۵) دقت را روی داده‌ای کنار گذاشته‌شده بسنج. هدف اصلی از نگاه استاد این نیست که ویژگی دقیقاً در کدام لایه آموخته شده، بلکه این است که آیا مدل اساساً آن را یاد گرفته (مثلاً اطلاعات واجی، زبان، گوینده، تفکیک واکه و خیشومی).

برای تجسم Embeddingها از کاهش بُعد (PCA، t-SNE) استفاده می‌شود، ولی استاد تأکید کرد که دیدن دو کلاس جدا در تصویر به‌تنهایی ثابت نمی‌کند مدل آن اطلاعات را خوب یاد گرفته؛ باید یک Task تعریف و عملکرد را کمّی سنجید.

این مباحث در چارچوب **هوش مصنوعی توضیح‌پذیر** (Explainable AI) و **تفسیرپذیری** (Interpretability) قرار می‌گیرند. (Visualization: نمایش هندسی و عمدتاً بصری برای درک شهودی؛ Probing: معیار کمّی مبتنی بر یک Task).

Probing چه چیزی را ثابت می‌کند؟

دقت بالای پروب نشان می‌دهد اطلاعات وجود دارد و قابل استخراج است، نه اینکه مدل از آن برای Task اصلی استفاده می‌کند. پروب را ساده (خطی) می‌گیرند تا خودش Task را یاد نگیرد، و دقت را با یک مبنا (مثلاً مدل با وزن‌های تصادفی) مقایسه می‌کنند.

۹.۹ بازگشت به TTS: تلفظ درست هر واژه

پس از **نرمال‌سازی متن** (Text Normalization)، Front-End باید تلفظ را با **تبدیل نویسه به واج** (Grapheme-to-Phoneme, G2P) مشخص کند. چون در فارسی بسیاری از حرکات کوتاه نوشته نمی‌شوند، دو دشواری داریم: **هم‌نویسه‌ها** (Homograph) (یک نوشتار با تلفظ‌های متفاوت) و **واژه‌های خارج از واژگان** (Out-of-Vocabulary, OOV) (واژه‌ای که در فرهنگ تلفظ نیست).

نوشتار	تلفظ و معنی ۱	تلفظ و معنی ۲	ابزار تفکیک
مرد	/mærd/ «انسان مذکر» (اسم)	/mord/ «درگذشت» (فعل)	نقش دستوری (POS)
کرم	/kerm/ «جانور خاکی»؛ /kerem/ «ماده مرطوب‌کننده»	/kæræm/ «بخشندگی» (مثال افزوده)	معنای بافتی
گرم	/gærm/ «داغ»	/geræm/ «واحد جرم»	معنای بافتی

جدول ۵.۹: نمونه‌هایی از هم‌نویسه‌های فارسی (نمادهای IPA تقریبی‌اند).

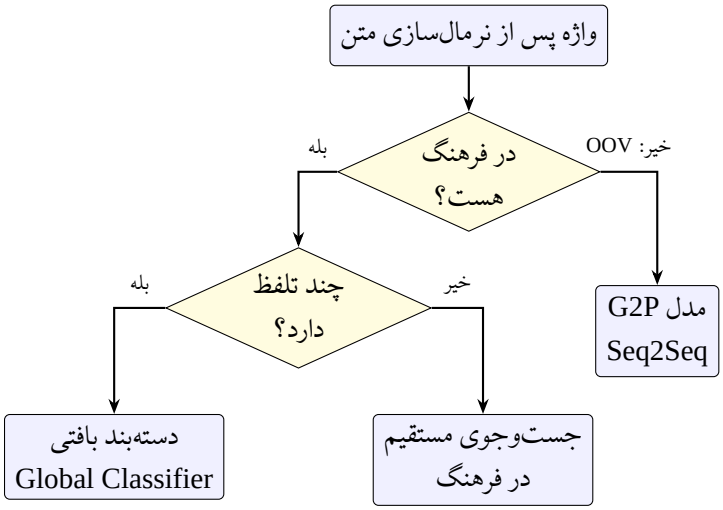
بسیاری از هم‌نویسه‌ها با نقش دستوری قابل تفکیک‌اند («او مُرد» فعل، «آن مَرد رفت» اسم؛ یک برچسب‌زن POS مثل hazm کافی است). اما برای دو واژهٔ هم‌نقش، مثل «کِرم» خاکی و «کَرِم» مرطوب‌کننده که هر دو اسم‌اند، برچسب دستوری کمکی نمی‌کند و به Embedding بافتی نیاز داریم.

۱.۹.۹ طرح مهندسی: از ارزان به گران

مسیر پیشنهادی استاد (شکل ۳.۹): اگر واژه در فرهنگ هست و یک تلفظ دارد، جست‌وجوی مستقیم؛ اگر چند تلفظ دارد، دسته‌بند بافتی؛ اگر نیست (OOV)، شکستن به نویسه‌ها و مدل G2P از نوع Sequence-to-Sequence.

۲.۹.۹ رفع ابهام هم‌نویسه با دسته‌بندی

انتخاب یکی از چند تلفظ متناسب با جمله یک مسئلهٔ دسته‌بندی (و برای بیش از دو تلفظ، چندکلاسه) است. ورودی دسته‌بند Embedding بافتی واژه است: جمله را به مدلی مثل BERT می‌دهیم و بردار موقعیت واژهٔ مبهم را به دسته‌بند



شکل ۳.۹: طرح تصمیم برای یافتن تلفظ: تا جای ممکن از روش‌های ارزان‌تر استفاده می‌شود. (شکل افزوده)

می‌دهیم.

چرا یک دسته‌بند سراسری (دسته‌بند سراسری (Global Classifier)) و نه یکی برای هر هم‌نویسه (مثلاً ۵۰۰ مدل)؟ پرسش کلاسی با دو پاسخ استاد:

۱. **اشتراک ویژگی‌ها:** نشانه‌های لازم (قواعد نحوی، ساختاری، معنایی؛ مثلاً «اگر قبل از کلمه حرف تعریف، ضمیر ملکی یا صفت آمد، کلمه اسم است») میان واژه‌ها مشترک است و یک مدل مشترک آن‌ها را یک بار یاد می‌گیرد.

۲. **کمبود داده:** برخی هم‌نویسه‌ها نمونهٔ کم دارند و مدل جداگانه روی آن‌ها بیش‌برازش می‌شود یا یاد نمی‌گیرد؛ با وزن‌های مشترک، دانش از واژه‌های پرتکرار به کم‌تکرار منتقل می‌شود (Cross-word Transfer Learning).

ماسک‌کردن کلاس‌های نامعتبر: برای اینکه فقط تلفظ‌های معتبر همان واژه انتخاب شوند، پیش از Softmax لاجیت تلفظ‌های نامعتبر را $-\infty$ می‌گذاریم:

$$z'_i = \begin{cases} z_i & \text{اگر تلفظ } i \text{ برای این واژه معتبر باشد،} \\ -\infty & \text{در غیر این صورت،} \end{cases} \qquad P_i = \mathrm{Softmax}(z')_i.$$

روی تخته برای «گرم»: «گرفتن بیشینه فقط روی واج‌های مرتبط». در استنتاج هم Argmax/Greedy به‌کار می‌رود، چون هدف تلفظ درست است و به تنوع نیاز نداریم.

[محتوای افزوده] مثال عددی: ماسک‌کردن

برای «گرم» لاجیت‌ها: garm: ۲٫۰، geram: ۰٫۵ و تلفظ نامعتبر دیگر: ۳٫۰. بدون ماسک احتمال‌ها (۰٫۶۹۰, ۰٫۰۵۷, ۰٫۲۵۴) است و کلاس نامعتبر برنده می‌شود؛ با ماسک فقط دو کلاس معتبر می‌مانند، (۰٫۸۱۸, ۰٫۱۸۲)، و garm انتخاب می‌شود.

۱۰.۹ واژه‌های ناشناخته و G2P از نوع Sequence-to-Sequence

برای واژهٔ OOV جست‌وجوی مستقیم ممکن نیست؛ واژه را به نویسه‌ها می‌شکنیم و مدل با تکیه بر الگوهای دادهٔ آموزشی تلفظ را پیش‌بینی می‌کند. داده را از خود فرهنگ تلفظ می‌سازیم: ورودی دنبالهٔ نویسه‌ها و خروجی دنبالهٔ واج‌ها،

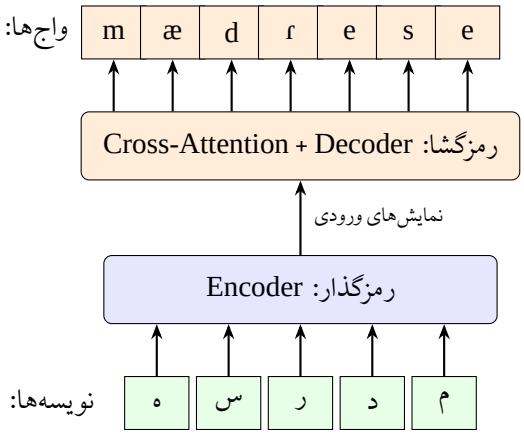
$$[g_1, g_2, \ldots, g_n] \longrightarrow [p_1, p_2, \ldots, p_m], \qquad n \neq m \text{(در حالت کلی)}.$$

نمونه: «مدرسه» ۵ نویسه (م، د، ر، س، ه) ولی ۷ واج (m æ d ɾ e s e) دارد، چون حرکات کوتاه نوشته نمی‌شوند؛ «خواب» ۴ نویسه و ۳ واج (x ɒ b) دارد چون «و» تلفظ نمی‌شود. پس نمی‌توان برای هر نویسه یک واج فرض کرد.

۱.۱۰.۹ چرا Seq2Seq و معماری رمزگذار-رمزگشا؟

دسته‌بندی چندکلاسه یک ورودی را به یکی از کلاس‌های ثابت می‌نگارد، اما در G2P باید دنباله‌ای با طول وابسته به ورودی و از پیش نامعلوم تولید کنیم؛ این مسئلهٔ **دنباله به دنباله** (Sequence-to-Sequence) است.

- **رمزگذار** (Encoder): دنبالهٔ نویسه‌ها را به نمایشی تبدیل می‌کند که اطلاعات لازم برای تولید تلفظ را دارد. به رمزگشا یا یک Context Vector (خلاصهٔ ورودی) می‌دهد یا، با Attention، همهٔ حالت‌های خروجی رمزگذار را در دسترس می‌گذارد.
- **رمزگشا** (Decoder): واج‌ها را گام‌به‌گام تولید می‌کند، با استفاده از ورودی رمزگذاری‌شده، واج‌های قبلی و حالت فعلی خودش.



شکل ۴.۹: مدل G2P با رمزگذار-رمزگشا برای واژهٔ «مدرسه» (۵ نویسه به ۷ واج). (شکل افزوده)

Cross-Attention. در Self-Attention یک دنباله به عناصر خودش توجه می‌کند؛ در Cross-Attention رمزگشا به نمایش‌های دنبالهٔ دیگر (خروجی رمزگذار) توجه می‌کند: Query از رمزگشا و Key و Value از رمزگذار می‌آیند. پس هنگام تولید واج بعدی، رمزگشا به بخش‌های مرتبط ورودی نگاه می‌کند. (در Embedding بافتی هدف نمایش یک عنصر با توجه به متن خودش بود؛ در رمزگذار-رمزگشا رمزگشا به دنبالهٔ ورودی مراجعه می‌کند.)

مسائل دیگر از نوع Seq2Seq: **ترجمهٔ ماشینی** (Machine Translation) و **خلاصه‌سازی انتزاعی** (Abstractive Summarization). برای OOV مدل بایت‌محور ByT5 هم روی تخته ذکر شد.

۱۱.۹ ملاحظات مهندسی G2P و بحث پایانی

پرسش دانشجو: چرا همه‌چیز را با Seq2Seq حل نکنیم؟ پاسخ استاد: یک تصمیم مهندسی است و روش‌ها از نظر هزینه، داده و پیچیدگی فرق دارند. ترتیب پیشنهادی: (۱) فرهنگ برای واژه‌های با تلفظ مشخص (بسیار کم‌هزینه)؛ (۲) دسته‌بند برای هم‌نویسه‌ها؛ (۳) G2P برای OOV. باید از راه‌حل ارزان‌تر شروع کرد («اصفهانی‌بودن در مهندسی»).

آیا همیشه باید از فرهنگ شروع کنیم؟

خیر؛ قاعدهٔ مهندسی است، نه الزام. اگر فرهنگ مناسبی نیست یا متن پر از واژه‌های جدید و محاوره‌ای است، استفادهٔ مستقیم از G2P منطقی است.

ذخیره‌خروجی OOV

نتیجهٔ G2P را می‌توان ذخیره (Cache) کرد تا هزینهٔ استنتاج کم شود، ولی اگر تلفظ به بافت وابسته باشد ذخیرهٔ تلفظ ثابت مناسب نیست. ذخیره به‌معنای آموزش مجدد یا به‌روزرسانی وزن‌ها نیست و تلفظ خودکار پیش از افزودن دائمی به فرهنگ باید بازبینی شود (پیشنهاد افزوده).

۱۲.۹ جمع‌بندی

لایهٔ خروجی و خطا را بر اساس نوع مسئله انتخاب می‌کنیم؛ آموزش (با حقیقت مبنا) با استنتاج (Greedy، Top-k، Top-p، Temperature) فرق دارد. Embedding ایستا یک جدول جست‌وجوست و بافتی تابعی از کل جمله (Self-Attention یا LSTM؛ پیش‌آموزش خودنظارتی BERT). در TTS: فرهنگ برای واژه‌های معمول، دسته‌بند سراسری با ماسک برای هم‌نویسه‌ها، و G2P رمزگذار-رمزگشا برای واژه‌های ناشناخته.

نکات مهم برای مرور و امتحان

۱. معماری و لایهٔ خروجی را بر اساس Task طراحی کنید و بدون توجه به عملکرد لایه نیفزایید؛ خطای آموزش کافی نیست، خطای اعتبارسنجی و بایاس/واریانس را هم ببینید.

۲. ایستا = جدول جست‌وجو (فایل بردارها)؛ بافتی = وزن‌های شبکه، بردار فقط پس از دادن جمله. Contextual Embedding را با Transformer یکی نگیرید (Attention، LSTM).

۳. به Visualization اکتفا نکنید؛ Probing شواهد کمّی می‌دهد.

۴. در TTS، هم‌نویسه‌ها و OOV دو چالش متفاوت‌اند و با روش‌های متفاوت حل می‌شوند.

۵. دلایل دسته‌بند سراسری برای هم‌نویسه‌ها: اشتراک ویژگی‌ها و کمبود داده؛ در استنتاج کلاس‌های نامعتبر ماسک می‌شوند و Argmax به کار می‌رود.

۶. G2P برای OOV از نوع Seq2Seq است چون طول دنبالهٔ واج‌ها لزوماً برابر طول دنبالهٔ نویسه‌ها نیست.

۷. تا جای ممکن از فرهنگ و روش‌های ساده‌تر (ارزان‌تر) شروع کنید و مدل‌های پیچیده را فقط در صورت نیاز وارد کنید.

فصل ۱۰

کدگذاری موقعیت

۱.۱۰ جایگاه این بحث در درس

پس از پایان بحث Embedding و معرفی معماری Sequence-to-Sequence برای G2P، پیش از ادامهٔ آن معماری باید یکی از مشکلات مهم Embedding پویا (بافتی) و راه‌حل آن را بشناسیم: **کدگذاری موقعیت** (Positional Encoding). مفاهیم Query، Key، Value و Self-Attention را در فصل قبل دیدیم و اینجا فقط مرور می‌کنیم.

نکتهٔ روی تخته

کدگذاری موقعیت فقط در *Embedding* پویا معنا پیدا می‌کند؛ Embedding ایستا مستقل از بافت است و مسئلهٔ «نقش کلمه نسبت به کلمه‌های دیگر» در آن مطرح نیست.

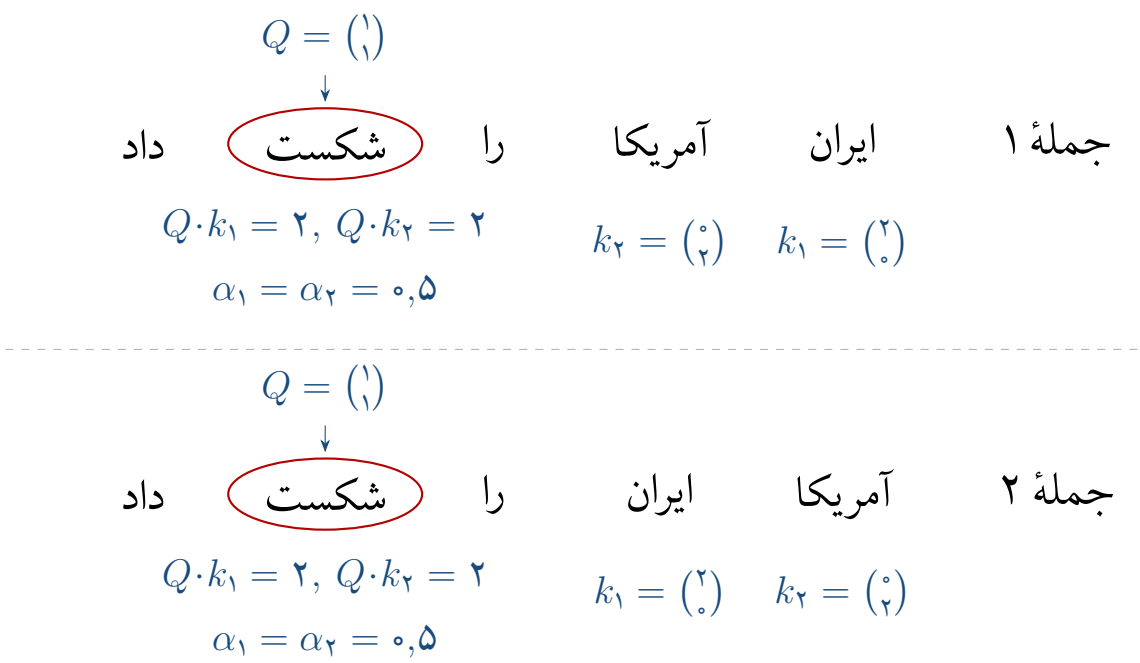
۲.۱۰ مسئلهٔ ترتیب در Attention

دو جملهٔ «ایران آمریکا را شکست داد» و «آمریکا ایران را شکست داد» کلمه‌های یکسان ولی معنای کاملاً متفاوتی دارند. نمایش بافتی «شکست» در این دو جمله باید متفاوت باشد. در Self-Attention کلمهٔ هدف نقش Query را دارد، دیگر کلمه‌ها Key و Value دارند، وزن‌های توجه α_i از مقایسهٔ Query با Keyها ساخته می‌شوند و بردار بافت ترکیب وزن‌دار Valueهاست:

$$\text{Context Vector} = \sum_i \alpha_i V_i.$$

مثال عددی کلاس. با $q = (۱, ۱)$ و $k_۱ = (۲, ۰)$، $k_۲ = (۰, ۲)$ داریم $q \cdot k_۱ = q \cdot k_۲ = ۲$، پس $\alpha_۱ = \alpha_۲ = ۰{,}۵$ و اگر Value هر دو ۱ باشد، $C = ۰{,}۵ \times ۱ + ۰{,}۵ \times ۱ = ۱$. با جابه‌جایی دو کلمه، Key و Value هر کلمه عوض نمی‌شود و جمع وزن‌دار دقیقاً همان ۱ را می‌دهد؛ یعنی مدل نمی‌تواند بفهمد کدام کلمه زودتر آمده است.

پرسش استاد: در دو جمله چه چیزی تغییر کرده است؟ پاسخ: موقعیت کلمه‌ها. در رویکرد موازی مدل فقط



شکل ۱۰.۱: مسئلهٔ ترتیب: کلمهٔ «شکست» (دایره‌شده) در هر دو جمله همان $Q = (۱, ۱)$ را دارد و Key کلمه‌های دیگر هم یکسان است؛ فقط جای آن‌ها عوض شده است. در هر دو جمله $Q \cdot k_۱ = Q \cdot k_۲ = ۲$ و وزن‌ها برابر می‌شوند، پس بدون اطلاعات موقعیت مدل تفاوتی نمی‌بیند. (بازسازی‌شده از تختهٔ کلاس)

«مجموعه‌ای» از نمایش کلمه‌ها را می‌بیند و ترتیب را صریحاً نمی‌داند. راه‌حل، افزودن اطلاعات موقعیت به نمایش هر کلمه است.

کدگذاری موقعیت (Positional Encoding)

افزودن اطلاعات «این عنصر چندمین عنصر دنباله است» به نمایش هر عنصر، تا مدل علاوه بر اینکه بداند هر کلمه چیست، بداند کجا قرار گرفته است. مثلاً در «ایران آمریکا را شکست داد»: «ایران» موقعیت ۱، «آمریکا» ۲، «را» ۳ و «شکست» ۴.

دقت: «بی‌توجه به ترتیب» یعنی چه؟

Self-Attention بدون کدگذاری موقعیت **هم‌متغیر نسبت به جایگشت** (Permutation-Equivariant) است: بردار بافت یک Query نسبت به جابه‌جایی فهرست Value/Keyها ثابت می‌ماند. این به معنای «Attention بافت را نمی‌فهمد» نیست؛ کلمه‌ها محتوای هم را می‌بینند و تنها اطلاعات ترتیب از دست می‌رود.

۳.۱۰ آیا مدل‌های بازگشتی هم به کدگذاری موقعیت نیاز دارند؟

بحث کنید (روی تخته)

بحث کنید که آیا در روش بازگشتی هم به پوزیشن انکدینگ نیاز داریم؟

پاسخ کلاس: خیر. در LSTM/RNN عنصرها به‌ترتیب پردازش می‌شوند و ترتیب در خودِ محاسبه نهفته است. مثلاً اگر حرف «ت» دو بار در یک دنبالهٔ نویسه‌ای بیاید، حالت پنهان هنگام دیدن «ت» دوم با «ت» اول فرق دارد، چون اطلاعات نویسه‌های قبلی را حمل می‌کند. در مقابل، در رویکرد موازی همهٔ عنصرها هم‌زمان پردازش می‌شوند و ترتیب خودبه‌خود وارد Attention نمی‌شود.

جدول ۱.۱۰: منشأ اطلاعات ترتیب در دو رویکرد ساخت Embedding بافتی.

	ترتیبی (LSTM/RNN)	موازی (Self-Attention)
نحوهٔ پردازش	گام‌به‌گام	همهٔ عنصرها هم‌زمان
منشأ اطلاعات ترتیب	خودِ بازگشت (حالت پنهان)	باید صریحاً افزوده شود
نیاز به کدگذاری موقعیت	خیر (در بحث کلاس)	بله

۴.۱۰ سه پرسش طراحی

مسئله در کلاس به سه پرسش شکسته شد:

۱. **محل**: کدگذاری موقعیت را در کدام بخش معماری قرار دهیم؟

۲. **نحوهٔ اعمال**: اطلاعات موقعیت را چگونه به Embedding متصل کنیم؟ (جمع یا کانکت)

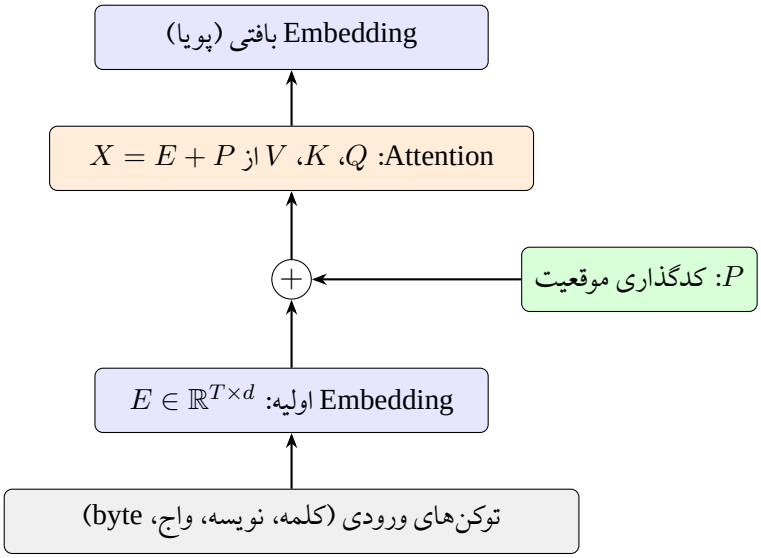
۳. **نحوهٔ مقداردهی**: مقدارها را چگونه تعیین کنیم؟ (یادگیری یا فرمول)

۱.۴.۱۰ محل قرارگیری در معماری

اطلاعات موقعیت باید بعد از *Embedding* اولیه و پیش از ورود به محاسبات *Attention* اضافه شود، چون هنگام مقایسهٔ Query و Key مدل باید تفاوت جایگاه عنصرها را ببیند.

انعطاف معماری

کدگذاری موقعیت یک ماژول است و محل و شیوهٔ استفاده از آن به معماری وابسته است. استاد اشاره کرد ممکن است در امتحان سؤال طراحی معماری بیاید، مثلاً اینکه اطلاعات موقعیت را در کدام بخش یک شبکه وارد می‌کنیم.



شکل ۲.۱۰: جای کدگذاری موقعیت در معماری: پس از Embedding اولیه و پیش از Attention. (شکل افزوده)

۲.۴.۱۰ نحوهٔ اعمال: کانکت یا جمع

کانکت: بردار موقعیت جداگانه‌ای (مثلاً ۱۰ بعدی) به انتهای Embedding ۵۱۲ بعدی چسبانده می‌شود ($= ۱۰ + ۵۱۲$ ۵۲۲)؛ مشکل: ابعاد نمایش بزرگ می‌شود، در حالی که ابعاد Embedding یک تصمیم مهم طراحی است. **جمع:** بردار موقعیت هم‌اندازهٔ Embedding است و ابعاد ثابت می‌ماند. این روش در کلاس انتخاب شد:

$$\boxed{X \;=\; E + P}$$

۳.۴.۱۰ ماتریس کدگذاری موقعیت

اگر ابعاد Embedding برابر ۵۱۲ باشد و موقعیت‌ها تا طول ۱۰۰ پوشش داده شوند:

$$\boxed{P \in \mathbb{R}^{۱۰۰ \times ۵۱۲}}, \qquad X_{pos} = E_{token} + P_{pos}.$$

هر سطر یک موقعیت و هر ستون یک بعد است؛ برای کلمهٔ موقعیت دهم، سطر دهم P با Embedding همان کلمه جمع می‌شود. (روی تخته ترانهادهٔ این نمایش کشیده شده بود؛ فقط قرارداد است.) مقدارهای P را دو راه می‌توان ساخت: یادگرفتن یا فرمول ثابت.

۵.۱۰ روش اول: کدگذاری موقعیت یادگرفتنی

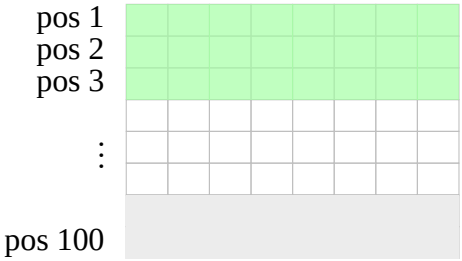
ماتریس P مجموعه‌ای از پارامترهای قابل‌آموزش است (Learnable Position Embedding Matrix) و مقدارهایش در آموزش یاد گرفته می‌شود، همان ایدهٔ Embedding قابل‌آموزش در برابر One-Hot با قاعدهٔ ثابت. در مثال کلاس ۵۱,۲۰۰ $= ۵۱۲ \times ۱۰۰$ پارامتر اضافه می‌شود.

لایهٔ خطی نیست. روی تخته: «اکتیویشن نداریم، ضرب ماتریسی نداریم (با لایهٔ خطی اشتباه نشود)». P مستقیماً به Embedding اضافه می‌شود؛ Bias، فعال‌ساز یا ضرب ماتریسی ندارد، چون فقط می‌خواهیم برای هر موقعیت یک بردار داشته باشیم.

دقت: جدول جست‌وجو

در پیاده‌سازی، P یک **جدول جست‌وجو** (Lookup Table) است (مثل ماتریس Embedding کلمه‌ها): شمارهٔ موقعیت، سطر مربوط را برمی‌گرداند؛ از نظر ریاضی معادل ضرب One-Hot موقعیت در P است بدون اجرای واقعی ضرب.

آموزش با پس‌انتشار. مثل بقیهٔ پارامترها: خروجی $X = E + P$ وارد بقیهٔ شبکه می‌شود، Loss نسبت به خروجی نهایی و هدف همان مسئله حساب می‌شود (نه نسبت به خود Embedding)، و گرادیان با قاعدهٔ زنجیره‌ای به E و P می‌رسد. چون $X_t = E_{token_t} + P_t$، داریم $\frac{\partial L}{\partial P_t} = \frac{\partial L}{\partial X_t}$. نتیجه مهم: فقط سطرهایی از P که در آموزش استفاده شده‌اند گرادیان می‌گیرند.



شکل ۳.۱۰: اگر دادهٔ آموزشی فقط توالی‌هایی تا طول ۳ داشته باشد، فقط سه سطر نخست P گرادیان می‌گیرند. (شکل افزوده)

در حالت یادگرفتنی شرط صریحی برای متمایز بودن سطرهای P نمی‌گذاریم و انتظار داریم داده، تابع خطا و ابعاد زیاد مدل را به نمایش مناسب برسانند (استاد گفت تضمین دقیق آن را می‌شود بیشتر بررسی کرد).

۶.۱۰ روش دوم: کدگذاری موقعیت ثابت (فرمولی)

نمایش موقعیت‌های مختلف باید قابل‌تمایز باشد (مثلاً برای «شکارچی پلنگ را زد» در برابر «پلنگ شکارچی را زد»). هر خانهٔ ماتریس به دو چیز وابسته است: شمارهٔ موقعیت (pos) و شمارهٔ بعد (j)، یعنی $P(pos, j) = f(pos, j)$. روی تخته $PE(pos, j) = \sin\big(g(pos, j)\big)$ نوشته شد که g زاویه‌ای ساخته‌شده از موقعیت و بعد است. چون $-۱ \le \sin(x) \le ۱$ (و همین برای کسینوس)، مقدارها کراندار هستند. استاد تأکید را روی منطق گذاشت، نه حفظ فرمول.

فرمول استاندارد (Vaswani et al., 2017)

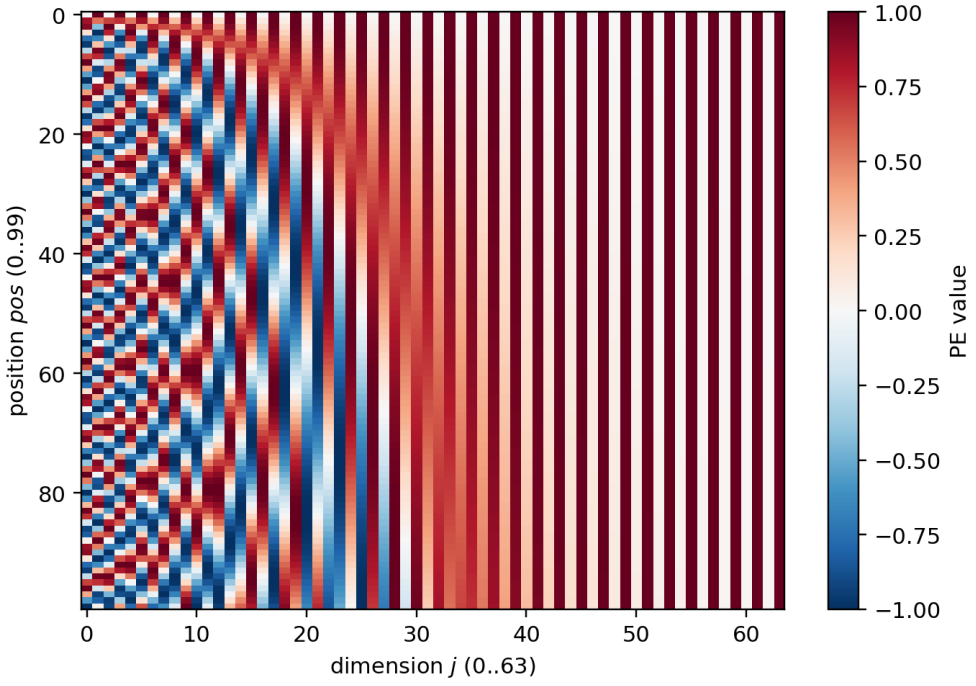
برای $i = ۰, ۱, \ldots, d/۲ - ۱$:

$$PE(pos,\ ۲i) = \sin\left(\frac{pos}{۱۰۰۰۰^{۲i/d}}\right), \qquad PE(pos,\ ۲i+۱) = \cos\left(\frac{pos}{۱۰۰۰۰^{۲i/d}}\right).$$

بعدها دوبه‌دو (سینوس، کسینوس) با فرکانس $\omega_i = ۱۰۰۰۰^{-۲i/d}$ جفت می‌شوند؛ بعدهای کم‌شماره موج‌های سریع (تمایز موقعیت‌های نزدیک) و بعدهای پرشماره موج‌های کند (تمایز موقعیت‌های دور) می‌سازند.

فرمول کلاس نسخهٔ ساده‌شده است

فرمول $\sin(g(pos, j))$ کلاس نسخهٔ ساده‌شدهٔ فرمول استاندارد است (در نسخهٔ کامل بعدهای فرد کسینوس می‌گیرند). همچنین یادداشت «هیچ دو خانه‌ای زاویه یکسان ندارند» دقیق نیست (مثلاً با $d = ۵۱۲$ زاویهٔ $pos = ۱۰$، بعد $i + ۶۴$) برابر زاویهٔ ($pos = ۱$، بعد i) است)؛ آنچه مهم است متفاوت‌بودن بردار کامل هر موقعیت است.



شکل ۴.۱۰: ماتریس PE سینوسی استاندارد با $d = ۶۴$ و ۱۰۰ موقعیت (محور افقی: بعد، محور عمودی: موقعیت). بعدهای کم‌شماره (چپ) سریع نوسان می‌کنند و بعدهای پرشماره کندتر. (شکل افزوده)

[محتوای افزوده] ویژگی‌های فرمول سینوسی

بدون پارامتر آموزشی، و **قابل محاسبه برای هر موقعیت** (حتی دیده‌نشده در آموزش). همچنین $PE(pos + k)$ یک تبدیل خطی ثابت (دوران در هر جفت بعد) از $PE(pos)$ است و ضرب داخلی دو بردار موقعیت فقط به فاصلهٔ آن‌ها بستگی دارد.

۷.۱۰ مقایسهٔ دو روش

جدول ۲.۱۰: مقایسهٔ کدگذاری موقعیت یادگرفتنی و ثابت.

ویژگی	یادگرفتنی (Learned)	ثابت (Fixed)
تعیین مقدارها	از طریق آموزش	با فرمول مشخص
پارامتر قابل‌آموزش	دارد (۵۱۲ × ۱۰۰ در مثال)	ندارد
وابستگی به دادهٔ آموزشی	زیاد	کم
موقعیت‌های دیده‌نشده	ممکن است خوب یاد گرفته نشده باشند	با فرمول قابل محاسبه‌اند
چالش اصلی	پوشش موقعیت‌ها در دادهٔ آموزشی	انتخاب قاعدهٔ مناسب

۸.۱۰ سؤال مفهومی مهم استاد: دادهٔ آموزشی کوتاه

دو مدل داریم: موقعیت در مدل اول با فرمول محاسبه می‌شود و در مدل دوم یاد گرفته می‌شود. اگر دادهٔ آموزشی عمدتاً جملهٔ کوتاه باشد، برای موقعیت‌های بلندتر کدام انتخاب بهتر است؟

پاسخ کلاس. کدگذاری ثابت. فرض کنید ماتریس یادگرفتنی ۱۰۰ سطر دارد ($P \in \mathbb{R}^{۱۰۰\times۵۱۲}$) ولی دادهٔ آموزشی فقط توالی‌هایی تا طول ۳ دارد. گرادیان فقط به سطرهای ۱ تا ۳ می‌رسد و سطرهای مثلاً ۵۰ یا ۸۰ آموزش مؤثری نمی‌بینند؛ در آزمون با توالی به طول ۵۰ مدل از نمایش‌هایی استفاده می‌کند که هرگز یاد نگرفته و عملکرد افت می‌کند. در روش ثابت، بردار موقعیت ۵۰ با فرمول محاسبه می‌شود و لازم نیست در دادهٔ آموزشی دیده شده باشد.

نکات روش‌شناختی این سؤال

- موضوع فقط تعداد نمونه‌ها نیست، بلکه پوشش موقعیت‌ها است: دادهٔ بسیار بزرگ ولی همگی کوتاه، تجربهٔ کافی دربارهٔ موقعیت‌های بالاتر نمی‌دهد؛ اگر دادهٔ آموزشی همهٔ موقعیت‌ها را پوشش دهد، روش یادگرفتنی هم خوب کار می‌کند.
- پاسخ «اندازهٔ ماتریس را کوچک بگیریم» فرض مسئله را عوض می‌کند: ظرفیت ۱۰۰ موقعیت است، دادهٔ آموزشی تا طول ۳، و اندازه تغییر نمی‌کند. استاد گفت در امتحان فرض‌ها را دقیق بیان خواهد کرد.
- **صورت پیشنهادی امتحان:** «دو مدل داریم که هر دو برای توالی‌هایی با حداکثر طول ۱۰۰ طراحی شده‌اند؛ مدل اول کدگذاری ثابت و مدل دوم یادگرفتنی دارد. اگر تمام دادهٔ آموزشی فقط شامل توالی‌هایی با طول حداکثر ۳ باشد، کدام روش برای موقعیت‌های بلندتر مناسب‌تر است و چرا؟»

دقت: «ثابت بهتر است» تضمین کامل نیست

مزیت روش ثابت این است که خودِ نمایش موقعیت به آموزش هر سطر وابسته نیست؛ اما وزن‌های Attention هم فقط روی موقعیت‌های کوتاه آموزش دیده‌اند و در عمل مدل‌های سینوسی هم روی طول‌های بلندتر از آموزش اغلب افت می‌کنند. پس روش ثابت مناسب‌تر است، نه اینکه مشکل را کاملاً حل کند.

۹.۱۰ کدگذاری موقعیت به توالی وابسته است، نه به «جمله»

کدگذاری موقعیت ذاتاً به مفهوم «جمله» وابسته نیست. عنصرهای توالی می‌توانند کلمه، نویسه، واج یا بایت باشند و کدگذاری موقعیت فقط مشخص می‌کند هر عنصر چندمین عنصر توالی ورودی است: در ورودی نویسه‌ای موقعیت پنجم یعنی نویسهٔ پنجم، و در ورودی کلمه‌ای یعنی کلمهٔ پنجم. این به طراحی معماری و Tokenization بستگی دارد.

۱۰.۱۰ طول زمینه (Context Length)

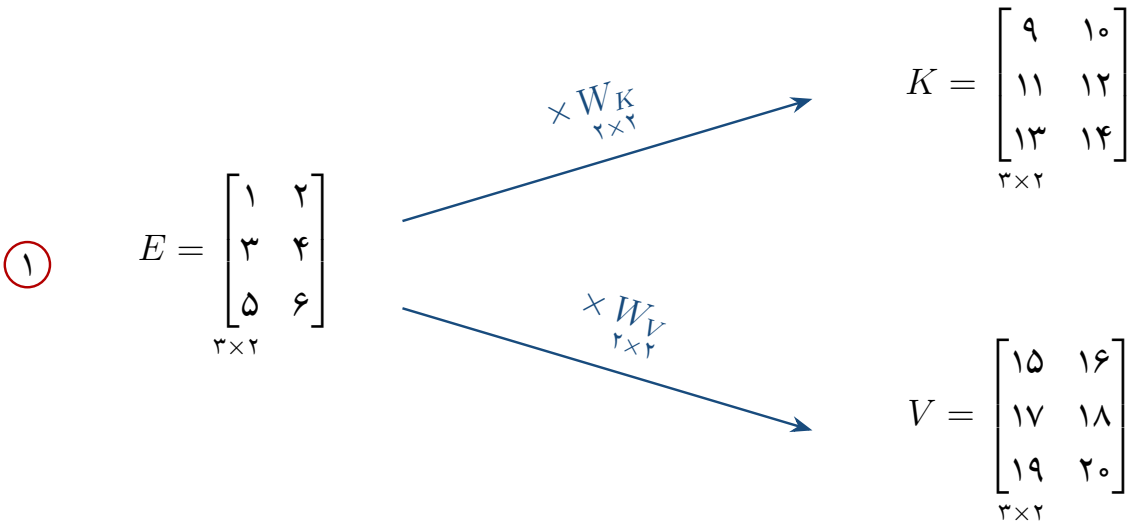
اگر توالی ۱۱۰ عنصر باشد ولی ماتریس موقعیت فقط ۱۰۰ موقعیت داشته باشد چه می‌شود؟

- حداکثر طول ورودی یک تصمیم طراحی است؛ برای توالی‌های بلندتر می‌توان ورودی را به بخش‌های کوچک‌تر شکست و از پنجره (Context Window) استفاده کرد.
- اندازهٔ پوشش موقعیت به مدل و Task بستگی دارد؛ مثلاً مدل نویسه‌ای معمولاً به موقعیت‌های بیشتری از مدل کلمه‌ای نیاز دارد.
- در روش یادگرفتنی موقعیت ۱۰۱ سطری ندارد؛ در روش فرمولی می‌توان $PE(۱۰۱)$ را حساب کرد، ولی کیفیت آن تضمین‌شده نیست.

۱۱.۱۰ مثال عددی کامل: Attention در رمزگشا

استاد روی تخته مثال عددی دست‌نویسی از Attention در معماری رمزگذار-رمزگشا (همان G2P) حل کرد: ورودی رمزگذار و رمزگشا هر دو Embedding نویسه (CE) به‌علاوهٔ PE هستند و Query رمزگشا با Value/Key رمزگذار بردار بافت C را می‌سازد.

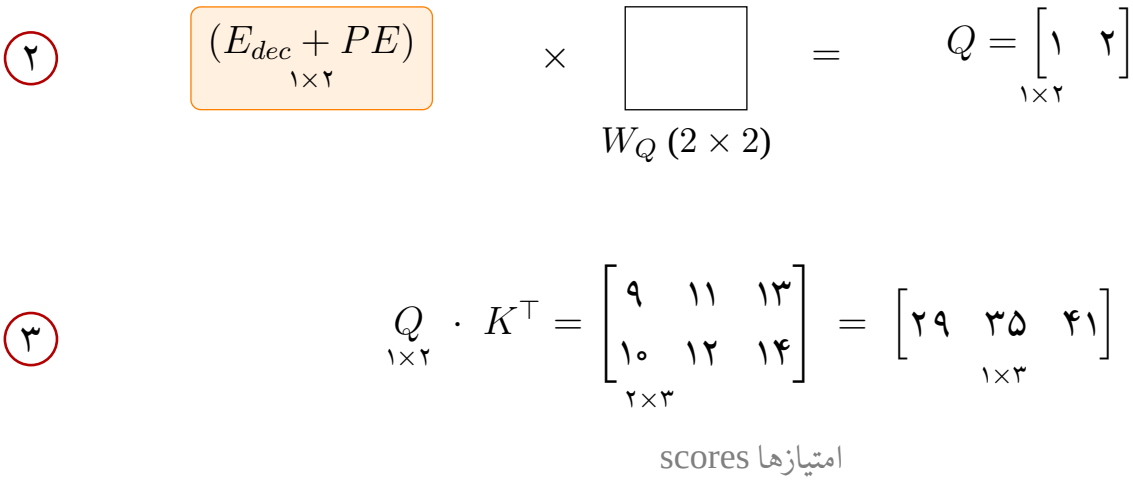
گام ۱: Key و Value. $E \in \mathbb{R}^{۳\times۲}$ (سه توکن) با ضرب در W_K و W_V (هر دو ۲×۲) به K و V (۳×۲) تبدیل می‌شود:



شکل ۵.۱۰: گام ۱: E (۲ × ۳) در W_K و W_V (۲ × ۲) ضرب می‌شود و K و V (۲ × ۳) به دست می‌آیند. روی تخته W_K و W_V فقط به‌صورت قاب‌های خالی کشیده شده بودند و مقدارشان نوشته نشده بود. (بازسازی‌شده از تختهٔ کلاس)

گام ۲: Query. توکن رمزگشا پس از جمع با کدگذاری موقعیت در W_Q ضرب می‌شود: $Q = (E_{dec} + P_{pos})\, W_Q \in \mathbb{R}^{۱\times۲}$؛ یعنی موقعیت پیش از ساخت Q وارد نمایش می‌شود.

گام ۳: امتیازها. $\text{scores} = QK^\top \in \mathbb{R}^{۱\times۳}$، ابعاد (۱ × ۲) · (۲ × ۳).



شکل ۶.۱۰: گام‌های ۲ و ۳: توکن رمزگشا با Embedding و PE جمع و در W_Q ضرب می‌شود تا Q ساخته شود (بالا)؛ سپس $QK^\top$ امتیازها را می‌دهد (پایین). مقدارهای Q و امتیازها دست‌خط به‌سختی خوانایی بودند و در اینجا بر پایهٔ خوانش توضیح‌داده‌شده در متن آمده‌اند. (بازسازی‌شده از تختهٔ کلاس)

نکتهٔ خوانایی و Softmax

اعداد دست‌نویس Q و امتیازها روی تخته ناخوانا بود؛ خوانش سازگار $Q = (۱, ۲)$ و $QK^\top = (۲۹, ۳۵, ۴۱)$ است (منطق محاسبه از مقدار دقیق آن‌ها مستقل است). همچنین امتیاز خام ضریب توجه نیست: پیش از ضرب در V باید با Softmax (معمولاً پس از تقسیم بر $\sqrt{d_k}$) به وزن‌هایی با مجموع ۱ تبدیل شود. ضرب مستقیم امتیازهای خام در V مقدار بی‌معنی $(۱۸۰۹, ۱۹۱۴)$ می‌دهد.

گام ۴: بردار بافت. $C = \sum_{i=۱}^{۳} \alpha_i V_i \in \mathbb{R}^{۱\times ۲}$. با امتیازهای بالا

$$\text{softmax}(۲۹, ۳۵, ۴۱) \approx (۰{,}۰۰۰۰۰۶;\ ۰{,}۰۰۲۵;\ ۰{,}۹۹۷۵), \qquad C \approx (۱۸{,}۹۹۵;\ ۱۹{,}۹۹۵)$$

(توجه «تیز»؛ تقسیم بر $\sqrt{d_k}$ آن را نرم‌تر می‌کند).

گام ۵: لجیت. $\text{logits} = C\,W + b$ با $W \in \mathbb{R}^{۲\times ۵}$ و $b \in \mathbb{R}^{۱\times ۵}$ (واژگان مثال ۵ عضو دارد)، و سپس Softmax روی واژگان احتمال هر توکن بعدی را می‌دهد.

ماسک علّی. در رمزگشا $QK^\top$ برای همهٔ موقعیت‌ها محاسبه و مثلث بالاراست (توکن‌های آینده) با $-\infty$ پیش از Softmax ماسک می‌شود تا وزن آن‌ها صفر شود؛ هر توکن فقط به خودش و توکن‌های قبلی نگاه می‌کند:

$$\text{mask} = \begin{bmatrix} ۰ & -\infty & -\infty \\ ۰ & ۰ & -\infty \\ ۰ & ۰ & ۰ \end{bmatrix}, \qquad \alpha = \text{softmax}\big(QK^\top/\sqrt{d_k} + \text{mask}\big).$$

یادداشت‌های پایانی روی تخته

روی تخته دو یادداشت آمده بود: همان پرسش بحث دربارهٔ نیاز روش بازگشتی به کدگذاری موقعیت (بخش ۳.۱۰) و «مدل‌های اتورگرسیو (Autoregressive) و Teacher Forcing در زمان آموزش» که هنوز تدریس نشد و موضوع جلسهٔ بعد است.

۱۲.۱۰ جمع‌بندی

- Self-Attention موازی بدون اطلاعات موقعیت نسبت به ترتیب بی‌اطلاع است؛ RNN ترتیب را ضمناً از بازگشت می‌گیرد.
- کدگذاری موقعیت پس از Embedding اولیه و پیش از Attention با $X = E + P$ اعمال می‌شود؛ جمع ابعاد را ثابت نگه می‌دارد.
- P را می‌توان یاد گرفت (جدول جست‌وجو، فقط سطرهای دیده‌شده گرادیان می‌گیرند) یا با فرمول سینوسی ساخت (بدون پارامتر، برای هر موقعیت قابل محاسبه).

- موقعیت به توالی ورودی مربوط است نه لزوماً «جمله»؛ حداکثر طول یک تصمیم طراحی است.

نکات مهم برای مرور و امتحان

۱. چرا Self-Attention بدون کدگذاری موقعیت دو جملهٔ «ایران آمریکا را شکست داد» و «آمریکا ایران را شکست داد» را اشتباه می‌گیرد؟ چرا RNN این مشکل را ندارد؟

۲. محل کدگذاری موقعیت (پس از Embedding و پیش از Attention) و دلیل آن.

۳. کانکت در برابر جمع؛ $X = E + P$ و $P \in \mathbb{R}^{۱۰۰\times ۵۱۲}$؛ تفسیر سطر و ستون.

۴. یادگرفتنی: پارامتر قابل‌آموزش، Backprop، بدون فعال‌ساز و ضرب ماتریسی (لایهٔ خطی نیست).

۵. ثابت: ورودی‌های فرمول (pos و j)، کران $[-۱, ۱]$ سینوس و کسینوس.

۶. سؤال امتحانی مهم: دادهٔ آموزشی کوتاه (طول ۳) و ماتریس ۱۰۰ موقعیتی؛ چرا کدگذاری ثابت مناسب‌تر است؟ فرض‌ها را دقیق بنویسید.

۷. ممکن است سؤال طراحی بیاید: اطلاعات موقعیت را در کجای یک شبکهٔ داده‌شده وارد می‌کنید؟

۸. مثال عددی Attention: ابعاد هر گام ($E, K, V : ۳ \times ۲$، $Q : ۱ \times ۲$، $QK^\top : ۱ \times ۳$، $C : ۱ \times ۲$، لجیت ۵×۱).