پردازش گفتار

از آواشناسی و ویژگی‌های آکوستیکی تا سامانه‌های تبدیل متن به گفتار

دکتر زینب آقاهادی

دانشگاه علم و صنعت ایران

پاییز ۱۴۰۵

Spoken Language Processing

From Phonetics and Acoustic Features to Text-to-Speech Systems

Zeinab Aghahadi

Assistant Professor

School of Computer Engineering

Iran University of Science and Technology (IUST)

Fall 2026

Draft Version 0.2 (sessions 1–10)

چکیده

پردازش گفتار شاخه‌ای کاربردی از پردازش سیگنال و هوش مصنوعی است که به تحلیل، درک و تولید گفتار انسان می‌پردازد. این جزوه با معرفی وظایف پایین‌دستی در پردازش زبان، گفتار و بینایی و ترکیب آن‌ها در محصولات واقعی آغاز می‌شود. سپس تصویر کلی علوم زبان و آواشناسی تولیدی را مرور می‌کند و به آواشناسی آکوستیکی می‌رسد: تبدیل فوریه، هارمونیک‌ها، اسپکتروگرام، مدل منبع-فیلتر و فرمنت‌ها. در ادامه، کار عملی با نرم‌افزار Praat و فضای واکه‌ای، ویژگی‌های الهام‌گرفته از شنوایی انسان مانند مقیاس مل و ضرایب MFCC، و ویژگی‌های پروسودیک گفتار بررسی می‌شوند. فصل‌های پایانی به سامانه‌های تبدیل متن به گفتار می‌پردازند: نرمال‌سازی متن، رفع ابهام کلمات هم‌نگاشت، تبدیل نویسه به واج، مدل آکوستیکی و وکودر، و نیز بازنمایی متن با embeddingهای ایستا و زمینه‌مند و افزودن اطلاعات ترتیب به آن‌ها با کدگذاری موقعیت.

کلیدواژه‌ها: پردازش گفتار، آواشناسی، اسپکتروگرام، فرمنت، MFCC، پروسودی، تبدیل متن به گفتار، embedding زمینه‌مند، کدگذاری موقعیت

Abstract

Speech processing is an applied branch of signal processing and artificial intelligence concerned with analysing, understanding and generating human speech. This booklet opens with downstream tasks in language, speech and vision, and shows how they combine into real products. It then reviews the big picture of the language sciences and articulatory phonetics, and moves on to acoustic phonetics: the Fourier transform, harmonics, spectrograms, the source–filter model and formants. Next come hands-on work with Praat and the vowel space, features inspired by human hearing such as the Mel scale and MFCCs, and the prosodic features of speech. The final chapters cover text-to-speech systems: text normalisation, homograph disambiguation, grapheme-to-phoneme conversion, acoustic models and vocoders, and text representation with static and contextual embeddings, together with positional encoding for injecting word order.

Keywords: speech processing, phonetics, spectrogram, formants, MFCC, prosody, text-to-speech, contextual embeddings, positional encoding

دربارهٔ این پیش‌نویس

این جزوه پیش‌نویسی موقت از درس پردازش گفتار است و بر پایهٔ یادداشت‌های صوتی جلسات و محتوای تختهٔ کلاس تهیه شده است. چون درس هنوز ادامه دارد، فقط جلسات اول تا نهم را پوشش می‌دهد. محتوای یادداشت‌ها بررسی و در صورت لزوم اصلاح شده است. هر جا مطلبی خارج از گفته‌های کلاس اضافه شده باشد، در کادر مخصوص «محتوای افزوده» آمده است.

راهنمای کادرها:

تعریف

تعریف‌ها و مفاهیم کلیدی درس.

نکتهٔ استاد / امتحان

نکته‌هایی که استاد بر آن‌ها تأکید کرده است، اطلاعات ارزشیابی و امتحان، تمرین‌ها و نکته‌های جانبی کلاس.

اصلاح یا دقت علمی

جاهایی که گفته‌های کلاس یا یادداشت‌ها نیاز به اصلاح یا دقیق‌تر شدن داشته‌اند.

هشدار / خطای رایج

اشتباه‌های رایج و نکته‌هایی که باید با احتیاط به کار بروند.

تمرین و پروژه

تمرین‌ها و فعالیت‌های عملی که در کلاس مطرح شده‌اند.

[محتوای افزوده] مثال یا توضیح

مثال‌های عددی، شکل‌ها و توضیح‌هایی که در کلاس گفته نشده‌اند و برای فهم بهتر اضافه شده‌اند.

فهرست مطالب

۱ **آشنایی با درس و وظایف پایین‌دستی (Downstream Tasks)** ۱

۱.۱ معرفی درس ۱

۲.۱ مفهوم وظیفهٔ پایین‌دستی ۴

۳.۱ وظایف پردازش زبان طبیعی ۶

۴.۱ وظایف پردازش گفتار ۱۵

۵.۱ وظایف بینایی و ارتباط آن‌ها با درس ۲۰

۶.۱ ساخت محصول با ترکیب وظایف ۲۰

۷.۱ جدول جمع‌بندی وظایف ۲۳

۸.۱ جمع‌بندی ۲۳

۲ **تصویر کلی علوم زبان و آواشناسی تولیدی** ۲۷

۱.۲ مرور جلسهٔ قبل و تغییر رویکرد ۲۷

۲.۲ تصویر کلی: جایگاه پردازش گفتار در علوم زبان ۲۸

۳.۲ نظریهٔ زایشی چامسکی (۱۹۵۷) ۳۰

۴.۲ ورود به آواشناسی ۳۲

۵.۲ آناتومی تولید گفتار ۳۳

۶.۲ حنجره و تارهای صوتی ۳۶

۷.۲ زنجیرهٔ گفتار ۴۰

۸.۲ واج، همخوان، واکه و هجا ۴۳

۹.۲ واکه‌ها و نقشهٔ جایگاه زبان ۴۳

۱۰.۲ همخوان‌ها و ویژگی‌های تولیدی آن‌ها ۴۶

۱۱.۲ کاربرد آواشناسی در هوش مصنوعی ۴۹

۱۲.۲ جمع‌بندی ۵۲

۳ آواشناسی آکوستیکی: موج صوتی، طیف، اسپکتروگرام و مدل منبع-فیلتر ۵۳

۱.۳ توضیحات کلاس دربارهٔ ارزشیابی ۵۳
۲.۳ مرور جلسهٔ قبل و طرح مسئله ۵۳
۳.۳ موج صوتی، فرکانس پایه و زیر و بمی ۵۴
۴.۳ تحلیل فرکانسی و تبدیل فوریه ۵۷
۵.۳ هارمونیک‌ها ۶۰
۶.۳ اسپکتروگرام ۶۲
۷.۳ مدل منبع-فیلتر ۶۴
۸.۳ فرمنت‌ها ۶۷
۹.۳ اسپکتروگرام باند باریک و باند پهن ۷۲
۱۰.۳ پرسش و پاسخ ۷۵
۱۱.۳ کاربردهای اسپکتروگرام و تمرین ۷۵
۱۲.۳ جمع‌بندی ۷۷

۴ فرمنت‌ها، نرم‌افزار Praat و فضای واکه‌ای ۷۹

۱.۴ مرور کوتاه: از فرکانس پایه تا فرمنت ۷۹
۲.۴ نگاشت ویژگی‌های آکوستیکی به ویژگی‌های تولیدی ۸۱
۳.۴ کار عملی با Praat ۸۲
۴.۴ ساخت پیکرهٔ گفتاری برای یک جامعهٔ آماری خاص ۸۵
۵.۴ فضای واکه‌ای ۸۸
۶.۴ همخوان‌ها در اسپکتروگرام ۹۳
۷.۴ کاربردهای فضای واکه‌ای ۹۴
۸.۴ جمع‌بندی ۹۸

۵ ادراک شنیداری، مقیاس مل و ضرایب MFCC ۱۰۱

۱.۵ چرا باید ادراک شنیداری انسان را در نظر بگیریم؟ ۱۰۱
۲.۵ نقشهٔ تونوتوپیک حلزون گوش ۱۰۲
۳.۵ مرور سه ویژگی Pitch، Formant و Intensity در Praat ۱۰۵

۴.۵ کم‌شنوایی فرکانس‌های بالا با افزایش سن ۱۰۶
۵.۵ مقیاس مل ۱۰۶
۶.۵ بانک فیلتر مل ۱۰۸
۷.۵ ادراک غیرخطی بلندی صدا و لگاریتم ۱۱۱
۸.۵ افزونگی ویژگی‌ها و تبدیل کسینوسی گسسته ۱۱۳
۹.۵ کپستروم و روایت تاریخی تحلیل کپسترال ۱۱۵
۱۰.۵ مسیر کامل استخراج MFCC ۱۱۷
۱۱.۵ کاربردهای MFCC ۱۲۱
۱۲.۵ MFCC در یادگیری ماشین و یادگیری عمیق ۱۲۱
۱۳.۵ جمع‌بندی ۱۲۳

۶ پروسودی و ویژگی‌های زبرزنجیری گفتار ۱۲۵
۱.۶ مرور کوتاه جلسهٔ قبل ۱۲۵
۲.۶ پروسودی چیست؟ ۱۲۷
۳.۶ مؤلفهٔ اول: شدت صدا ۱۲۹
۴.۶ مؤلفهٔ دوم: فرکانس و زیر و بمی ۱۳۴
۵.۶ مؤلفهٔ سوم: زمان، ریتم و مکث ۱۳۷
۶.۶ پروسودی در تبدیل متن به گفتار ۱۳۹
۷.۶ پژوهش: اطمینان و صداقت ادراک‌شده از روی پروسودی ۱۴۰
۸.۶ کاربردهای عملی تحلیل پروسودی ۱۴۴
۹.۶ جمع‌بندی ۱۴۵

۷ تبدیل متن به گفتار: مسئله و معماری خط‌لولهٔ TTS ۱۴۷
۱.۷ از تحلیل گفتار تا تولید گفتار ۱۴۷
۲.۷ دو رویکرد کلی: خط‌لوله و سرتاسری ۱۴۹
۳.۷ معماری کلی یک سامانهٔ TTS ۱۵۰
۴.۷ مرحلهٔ اول: نرمال‌سازی متن ۱۵۲
۵.۷ مرحلهٔ دوم: رفع ابهام هم‌نویسه‌ها ۱۵۷
۶.۷ تبدیل نویسه به واج (G2P) ۱۶۰
۷.۷ مرحلهٔ دوم سامانه: تولید گفتار از روی واج‌ها ۱۶۵

۸.۷ مدل آکوستیکی ۱۶۶
۹.۷ وکودر: از طیف‌نگار به موج ۱۶۹
۱۰.۷ جمع‌بندی خط‌لولهٔ TTS ۱۷۱
۱۱.۷ جمع‌بندی ۱۷۲

۸ بازنمایی متن در TTS: از One-Hot تا بازنمایی وابسته به بافت ۱۷۵
۱.۸ مروری بر معماری سامانه‌های تبدیل متن به گفتار ۱۷۵
۲.۸ بازنمایی متن برای شبکه‌های عصبی ۱۷۶
۳.۸ مروری بر مبانی شبکه‌های عصبی ۱۸۰
۴.۸ مسئلهٔ هم‌نویسه در TTS ۱۸۶
۵.۸ Embedding ایستا و Word2Vec ۱۸۷
۶.۸ گردش کار تشخیص تلفظ در یک سامانهٔ TTS ۱۹۰
۷.۸ محدودیت Embedding ایستا در تشخیص هم‌نویسه ۱۹۰
۸.۸ چرا همهٔ تلفظ‌ها را از ابتدا برچسب نمی‌زنیم؟ ۱۹۲
۹.۸ Embedding وابسته به بافت (پویا) ۱۹۳
۱۰.۸ استفاده از Attention برای ساخت Embedding وابسته به بافت ۱۹۵
۱۱.۸ پرسش و پاسخ پایان کلاس ۱۹۷
۱۲.۸ آنچه در جلسهٔ بعد ادامه می‌یابد ۱۹۸
۱۳.۸ جمع‌بندی ۱۹۸

۹ آموزش شبکه، Embedding بافتی و تبدیل نویسه به واج ۲۰۱
۱.۹ مرور فرایند آموزش شبکهٔ عصبی ۲۰۱
۲.۹ آموزش در برابر استنتاج ۲۰۴
۳.۹ تعمیم‌پذیری: کم‌برازش، بیش‌برازش و پیچیدگی مدل ۲۰۶
۴.۹ Embedding ایستا و پویا (بافتی) ۲۱۰
۵.۹ راه‌های ساخت Embedding بافتی ۲۱۳
۶.۹ یادگیری خودنظارتی و BERT ۲۱۴
۷.۹ قیاس برداری (Analogy) در فضای Embedding ۲۱۷
۸.۹ کاوش (Probing) و تفسیرپذیری ۲۱۹
۹.۹ بازگشت به TTS: تلفظ درست هر واژه ۲۲۱

۱۰.۹ واژه‌های ناشناخته و G2P از نوع Sequence-to-Sequence ۲۲۳
۱۱.۹ ملاحظات مهندسی G2P و بحث پایانی ۲۲۶
۱۲.۹ جمع‌بندی ۲۲۷

۱۰ کدگذاری موقعیت ۲۲۹
۱.۱۰ جایگاه این بحث در درس ۲۲۹
۲.۱۰ مسئلهٔ ترتیب در Attention ۲۲۹
۳.۱۰ آیا مدل‌های بازگشتی هم به کدگذاری موقعیت نیاز دارند؟ ۲۳۲
۴.۱۰ سه پرسش طراحی ۲۳۲
۵.۱۰ روش اول: کدگذاری موقعیت یادگرفتنی ۲۳۶
۶.۱۰ روش دوم: کدگذاری موقعیت ثابت (فرمولی) ۲۳۷
۷.۱۰ مقایسهٔ دو روش ۲۴۱
۸.۱۰ سؤال مفهومی مهم استاد: دادهٔ آموزشی کوتاه ۲۴۱
۹.۱۰ کدگذاری موقعیت به توالی وابسته است، نه به «جمله» ۲۴۲
۱۰.۱۰ طول زمینه (Context Length) ۲۴۳
۱۱.۱۰ مثال عددی کامل: Attention در رمزگشا ۲۴۳
۱۲.۱۰ جمع‌بندی ۲۴۹

فصل ۱

آشنایی با درس و وظایف پایین‌دستی (Downstream Tasks)

۱.۱ معرفی درس

۱.۱.۱ پردازش گفتار و پردازش سیگنال دیجیتال

درس «پردازش گفتار» با درس «پردازش سیگنال دیجیتال» (Digital Signal Processing - DSP) تفاوت اساسی دارد. پردازش سیگنال حوزه‌ای بنیادی و گسترده است و در رادار، مخابرات، تبدیل فوریه و تحلیل انواع سیگنال‌ها کاربرد دارد. پردازش گفتار را می‌توان یکی از شاخه‌های تخصصی و کاربردی پردازش سیگنال دانست که بر گفتار انسان متمرکز است.

جدول ۱.۱: مقایسهٔ رویکرد دو درس

درس	رویکرد
DSP	بنیادی، سیگنالی و ریاضیاتی
پردازش گفتار	کاربردی و مبتنی بر هوش مصنوعی؛ تمرکز بر تحلیل، درک و تولید گفتار انسان

ممکن است در داده‌های گفتاری صداهای دیگری مانند بوق، آژیر آمبولانس یا نویز محیط هم وجود داشته باشد، اما هدف اصلی پردازش گفتار انسان است. بنابراین این درس تکرار مباحث DSP نیست و قرار نیست وارد همهٔ مباحث پردازش سیگنال‌های صوتی شود. تأکید درس بر ریاضیات پردازش سیگنال، مانند درس DSP، نیست و بخش مهمی از آن به مدل‌ها و معماری‌ها اختصاص دارد.

۲.۱.۱ مرجع، روش تدریس و ارتباط با دانشجویان

مرجع اصلی درس، درس Spoken Language Processing (CS224S) دانشگاه استنفورد است. ترتیب مباحث عمدتاً مطابق سیلابس همین درس (نسخهٔ ۲۰۲۵) خواهد بود. جلسهٔ اول تا حدی خارج از ترتیب سیلابس است، چون هدف آن آشنایی با اصطلاحات و مفاهیم پایه است تا دانشجویان از جلسات بعد ادبیات مشترکی داشته باشند.

- اسلایدهای استنفورد برای مطالعهٔ تکمیلی و رفع ابهام در دسترس‌اند.
- تدریس اصلی روی تختهٔ دیجیتال Excalidraw انجام می‌شود و محتوای تخته به‌تدریج تکمیل می‌شود.
- تصاویر و فایل‌های تخته با دانشجویان به اشتراک گذاشته می‌شود.
- کلاس‌ها ضبط می‌شوند و فایل ضبط‌شده از طریق سامانه‌ای که در کلاس معرفی شد در دسترس خواهد بود. به همین دلیل استاد هنگام تدریس بیشتر روی تخته متمرکز است و ممکن است تماس چشمی کمتری با دانشجویان داشته باشد.

مبنای سؤالات امتحانی

مبنای اصلی سؤالات امتحانی، مباحثی است که **روی تختهٔ کلاس** مطرح می‌شود. اسلایدهای استنفورد مرجع مطالعهٔ تکمیلی هستند و اگر مطلبی در کلاس مبهم ماند به آن‌ها مراجعه می‌شود.

اطلاعات تماس و کانال‌های درس

- استاد: دکتر زینب آقاهادی (استادیار هوش مصنوعی؛ زمینهٔ پژوهشی: علوم شناختی محاسباتی، پردازش زبان طبیعی، پردازش گفتار، و کاربرد مدل‌های محاسباتی علوم شناختی در متن و صوت)؛ ایمیل: Aghahadi@iust.ic.ir
- دستیار آموزشی: آقای روح‌الله ایزدی؛ شناسه در پیام‌رسان: @rohamizadidoost
- اطلاع‌رسانی‌ها، فایل‌ها و تصاویر تخته در گروه درس در پیام‌رسان «بله» قرار می‌گیرد؛ شناسهٔ کانال: @slp_iust_aghahadi، پیوند عضویت: ble.ir/join/62SeuysFcA. همهٔ دانشجویان باید عضو گروه شوند.

۳.۱.۱ ارزیابی درس

ارزیابی به‌صورت مستمر خواهد بود و می‌تواند شامل میان‌ترم، پایان‌ترم، تمرین‌ها و پروژه‌های عملی باشد. جزئیات دقیق و وزن هر بخش در جلسهٔ اول اعلام نشد. استاد بر مشارکت فعال دانشجویان تأکید کرد و از آن‌ها خواست هنگام وجود ابهام سؤال بپرسند. در این جلسه تمرین مشخصی با مهلت تحویل اعلام نشد.

۴.۱.۱ پیش‌نیازها

بسیاری از دانشجویان با مفاهیمی مانند یادگیری عمیق، Transformer و Embedding آشنا هستند. این آشنایی مفید است، اما درس طوری ارائه می‌شود که دانشجویان بدون تسلط کامل بر آن‌ها هم بتوانند مباحث را دنبال کنند: هرجا از

Transformer استفاده شود، مفهوم موردنیاز توضیح داده می‌شود، ولی یک جلسهٔ کامل به آموزش این معماری از ابتدا اختصاص نمی‌یابد. بخش‌های ابتدایی درس، به‌ویژه آواشناسی (Phonetics)، با درس‌های رایج یادگیری عمیق تفاوت دارند.

۵.۱.۱ جایگاه پردازش گفتار در هوش مصنوعی

سرعت تغییر مدل‌ها در هوش مصنوعی زیاد است؛ مدلی که امروز جدید است ممکن است ترم بعد «کلاسیک» شمرده شود. استاد اعلام کرد در صورت تغییرات مهم در روش‌ها و مدل‌های سیلابس، به آن‌ها اشاره خواهد کرد.

در دوره‌هایی توجه پژوهشی و کاربردی بیشتر روی بینایی ماشین و سپس پردازش متن بوده است. اکنون بسیاری از کاربردهای متنی به سطح مناسبی از عملکرد رسیده‌اند و تعامل طبیعی‌تر انسان با سامانه‌ها از راه صوت اهمیت زیادی یافته است؛ بنابراین پردازش گفتار ظرفیت بالایی برای توسعهٔ محصولات جدید دارد.

هوش مصنوعی لبه (Edge AI)

هوش مصنوعی لبه (Edge AI) یعنی اجرای مدل‌ها روی دستگاه محلی، بدون اینکه برای هر درخواست لازم باشد پردازش در سرور ابری (Cloud) انجام شود. مثلاً یک دستیار صوتی روی دستگاه هوشمند باید فرمان کاربر را تشخیص دهد و بدون ارسال دائمی داده به سرور پاسخ مناسب بدهد. در چنین شرایطی این ملاحظات مهم می‌شوند:

۱. **تأخیر** (Latency): پاسخ باید با تأخیر کم داده شود.
۲. **دقت** (Accuracy): تشخیص و اجرای فرمان باید به‌اندازهٔ کافی دقیق باشد.
۳. منابع محاسباتی محدود دستگاه و در نتیجه نیاز به **مدل‌های کوچک و سبک** (Model Size).
۴. **توزیع داده** (Data Distribution): داده‌های واقعی دستگاه ممکن است با داده‌های آموزشی متفاوت باشند.

گفتار چندزبانه، زبان‌های کم‌منبع و لهجه

معماری‌های جدید معمولاً چندزبانه توسعه می‌یابند؛ یعنی به‌جای طراحی معماری جداگانه برای هر زبان، یک معماری برای زبان‌های مختلف به‌کار می‌رود. با این حال برخی زبان‌ها، از جمله فارسی در بعضی مجموعه‌داده‌ها، در دستهٔ **زبان‌های کم‌منبع** (Low-resource Languages) قرار می‌گیرند و مسئلهٔ اصلی کمبود داده است. لهجه هم عامل دیگری است: سامانه ممکن است گفتار معیار را خوب تشخیص دهد ولی در برابر یک لهجهٔ خاص ضعیف‌تر عمل کند. در عمل تمرکز بر تهیه و انتخاب داده و سازگار کردن مدل با آن است.

آیا پردازش گفتار «حل‌شده» است؟

اینکه امروز می‌توان با دستیارهای صوتی و مدل‌های هوش مصنوعی به‌راحتی گفت‌وگو کرد، به معنای حل شدن همهٔ مسائل نیست. استاد میان موفقیت در کاربردهای عمومی و حل مسائل تخصصی تفاوت گذاشت: مدلی که در مکالمهٔ

روزمره عالی است، ممکن است در یک سازمان صنعتی با واژگان تخصصی یا لهجهٔ خاص کارکنان دقت مناسبی نداشته باشد؛ یا سازمانی به دلیل محدودیت سخت‌افزاری نتواند مدل بزرگ به‌کار ببرد و نیاز به یک مدل زبانی کوچک (Small Language Model - SLM) محلی داشته باشد. در این موارد مهندس هوش مصنوعی باید بتواند:

- مسئلهٔ تخصصی را دقیق تعریف کند،
- داده جمع‌آوری کند و دستورالعمل برچسب‌گذاری (Annotation) بنویسد،
- مدل مناسب را انتخاب یا از ابتدا توسعه دهد و با داده‌های حوزه سازگار کند،
- عملکرد را ارزیابی و خطاها را تحلیل کند.

مثال چالشی کلاس

یک دستیار صوتی در محیطی است که هم کاربر صحبت می‌کند و هم رادیو روشن است. سیستم باید تشخیص دهد کدام گفتار واقعاً خطاب به دستیار بوده است. توانایی تبدیل صوت به متن به‌تنهایی برای حل این مسئله کافی نیست. (ایده‌هایی مانند تشخیص کلمهٔ فعال‌ساز و بازشناسی گوینده، که در ادامهٔ همین فصل معرفی می‌شوند، به این مسئله مربوط‌اند.)

۲.۱ مفهوم وظیفهٔ پایین‌دستی

۱.۲.۱ سه خانواده‌وظایف

بخش اصلی جلسه به آشنایی با **وظایف پایین‌دستی** (Downstream Tasks) اختصاص داشت. این وظایف در سه خانواده بررسی شدند:

- **وظایف زبانی** (Language Tasks): متن و زبان،
- **وظایف گفتاری** (Speech/Voice Tasks): گفتار و صوت،
- **وظایف بینایی** (Vision Tasks): تصویر و ویدئو.

هنگام طراحی یک محصول هوش مصنوعی ابتدا نیازمندی‌ها بررسی می‌شود؛ سپس مشخص می‌شود برای پاسخ‌گویی به آن‌ها کدام وظایف و مدل‌ها لازم است. مثلاً در دستیار صوتی ممکن است لازم باشد گفتار تشخیص داده شود، قصد کاربر مشخص شود، اطلاعاتی استخراج شود و پاسخ صوتی تولید شود؛ هر کدام از این مراحل یک وظیفهٔ پایین‌دستی مستقل است. نمودار مرکزی تخته (شکل ۹.۱) همین ایده را نشان می‌دهد: وظایف سه حوزه با هم ترکیب می‌شوند و محصول می‌سازند.

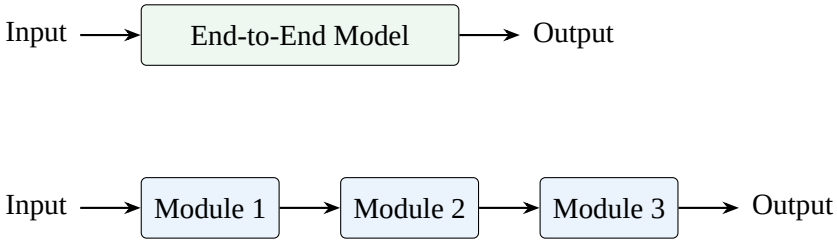
وظیفهٔ پایین‌دستی

یک مسئلهٔ مشخص و کاربردی با ورودی و خروجی تعریف‌شده (مثل ترجمه، تشخیص گفتار یا تشخیص قصد کاربر) که یک مدل یا ماژول باید حل کند و می‌تواند به‌عنوان یک جزء در یک محصول بزرگ‌تر قرار بگیرد. استاد تأکید کرد دانشجو باید با شنیدن نام یک وظیفه بتواند **ورودی، خروجی و نوع مسئلهٔ** آن را بگوید.

۲.۲.۱ دو رویکرد طراحی: سرتاسری و خط لوله

در ساخت سامانه‌های هوش مصنوعی دو رویکرد کلی مقایسه شد:

- **سرتاسری** (End-to-End): یک مدل یکپارچه ورودی را می‌گیرد و مستقیماً خروجی نهایی را تولید می‌کند؛ مدل برای بهینه‌سازی عملکرد نهایی آموزش می‌بیند و اجزای درونی آن مشترکاً بهینه می‌شوند.
- **خط لوله** (Pipeline): چند ماژول مستقل پشت سر هم قرار می‌گیرند و خروجی هر ماژول ورودی ماژول بعدی است. مثلاً مترجم صوتی: Speech → Speech-to-Text → Translation → Text-to-Speech.



شکل ۱.۱: رویکرد سرتاسری (بالا) در برابر خط لوله (پایین). در خط لوله خروجی هر ماژول ورودی ماژول بعدی است (شکل افزوده).

جدول ۲.۱: مقایسهٔ رویکرد سرتاسری و خط لوله

معیار	سرتاسری	خط لوله
دقت	امکان بهینه‌سازی یکپارچه برای هدف نهایی	وابسته به دقت هر مرحله
انتشار خطا	آموزش مشترک می‌تواند آن را کاهش دهد	خطای مراحل اولیه به مراحل بعد منتقل می‌شود
استفادهٔ مجدد	معمولاً تخصصی‌تر برای یک هدف	استفاده از ماژول‌ها و کتابخانه‌های موجود (مثلاً OCR)
تفسیرپذیری	یافتن منشأ خطا دشوارتر است	عیب‌یابی هر مرحله ساده‌تر است
هزینهٔ توسعه	معمولاً به آموزش و داده اختصاصی بیشتری نیاز دارد	استفاده از مدل‌های آماده ممکن است

انتشار خطا. اگر ماژول اول خروجی اشتباه تولید کند، ماژول دوم حتی با عملکرد خوب ممکن است پاسخ نادرست بدهد، چون ورودی‌اش اشتباه است.

تفسیرپذیری. در مترجم صوتی با خط لوله می‌توان فهمید مشکل از تبدیل گفتار به متن بوده یا از ترجمه؛ در مدل یکپارچه یافتن منشأ خطا دشوارتر است.

نکتهٔ استاد

هیچ‌یک از دو رویکرد در همهٔ مسائل برتری قطعی ندارد؛ انتخاب به نوع مسئله، دقت موردنیاز، هزینه و محدودیت‌ها بستگی دارد. آشنایی با وظایف پایین‌دستی حتی هنگام استفاده از مدل‌های سرتاسری برای طراحی و تحلیل سامانه‌ها ضروری است.

۳.۱ وظایف پردازش زبان طبیعی

نمایی از وظایف زبانی روی تخته در شکل ۲.۱ آمده است. استاد وظایف را بر اساس شکل ورودی و خروجی دسته‌بندی کرد: وظایف تبدیل توالی به توالی، طبقه‌بندی (تک‌جمله‌ای و دوجمله‌ای)، برچسب‌گذاری توالی، مدل‌سازی زبان و خوشه‌بندی. منبع پیشنهادی برای آشنایی با وظایف، مجموعه‌داده‌ها و شیوهٔ تعریف آن‌ها، وب‌سایت NLP Progress است.

۱.۳.۱ تبدیل توالی به توالی (Seq2Seq)

خلاصه‌سازی متن (Text Summarization)

ورودی یک متن و خروجی نسخهٔ کوتاه‌تری از آن است که اطلاعات اصلی را حفظ کرده باشد. از نظر مدل‌سازی، ورودی و خروجی هر دو توالی متنی‌اند و وظیفه از نوع Sequence-to-Sequence است.

ترجمهٔ ماشینی (Machine Translation)

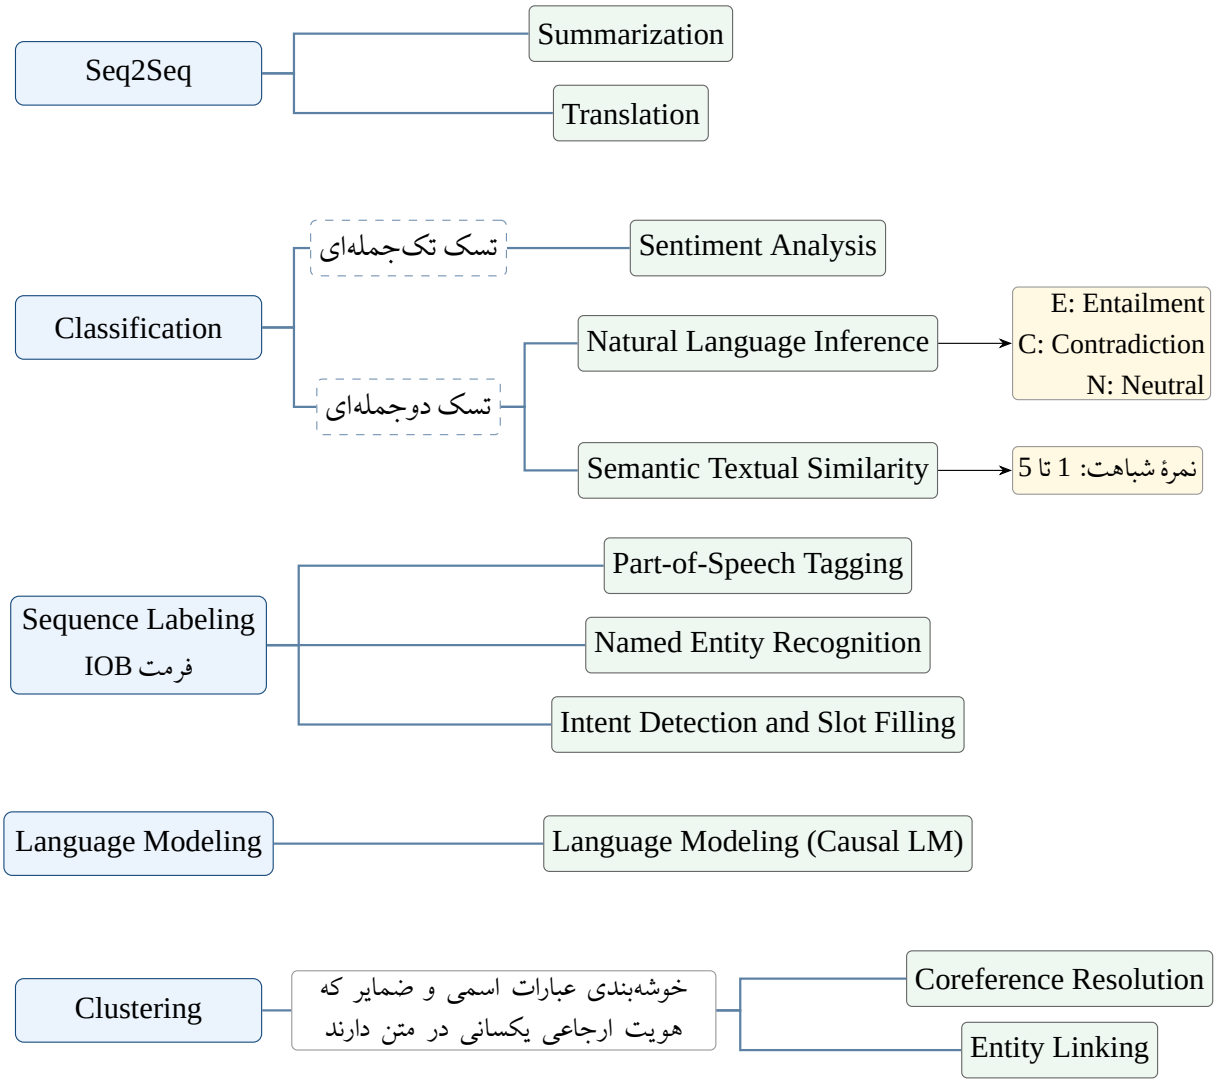
متن زبان مبدأ ورودی و متن معادل در زبان مقصد خروجی است. این وظیفه نیز Seq2Seq است. معماری پایه‌ای که برای این دو وظیفه مطرح شد Encoder-Decoder است: Encoder ورودی را به بازنمایی تبدیل می‌کند و Decoder از روی آن خروجی را می‌سازد (شکل ۳.۱).

۲.۳.۱ طبقه‌بندی (Classification)

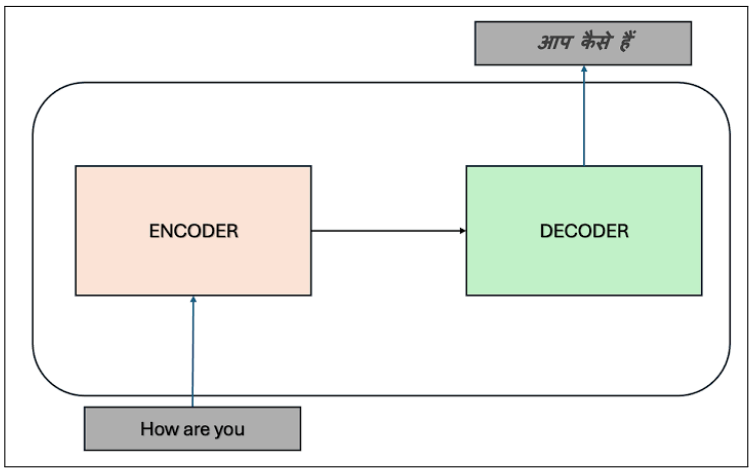
در طبقه‌بندی، خروجی یکی از کلاس‌های از پیش‌تعریف‌شده است. استاد وظایف طبقه‌بندی را به دو گروه «تک‌جمله‌ای» و «دوجمله‌ای» تقسیم کرد.

تحلیل احساسات (Sentiment Analysis)

وظیفهٔ تک‌جمله‌ای: مدل احساس یا جهت‌گیری متن را تشخیص می‌دهد. تعداد کلاس‌ها به تعریف مسئله بستگی دارد؛ مثلاً سه‌کلاسه (مثبت، منفی، خنثی) یا پنج‌کلاسه: Strong Negative، Negative، Neutral، Positive، Strong



شکل ۲.۱: دسته‌بندی وظایف زبانی بر اساس شکل ورودی و خروجی: تبدیل توالی به توالی، طبقه‌بندی (تک‌جمله‌ای و دوجمله‌ای)، برچسب‌گذاری توالی، مدل‌سازی زبان و خوشه‌بندی. برای NLI سه کلاس و برای STS نمره‌ای از ۱ تا ۵ در نظر گرفته می‌شود. (بازسازی‌شده از تختهٔ کلاس)



شکل ۳.۱: معماری Encoder-Decoder در ترجمه: جملهٔ انگلیسی How are you وارد رمزگذار می‌شود و رمزگشا معادل هندی آن را تولید می‌کند. (برگرفته از تختهٔ کلاس)

.Positive

استنتاج زبان طبیعی (NLI)

Natural Language Inference وظیفه‌ای دوجمله‌ای است. استاد تأکید کرد که نام وظایف در NLP معنای قراردادی دارد و صرفاً فهمیدن معنای لغوی نام برای شناخت دقیق وظیفه کافی نیست. در NLI دو متن به مدل داده می‌شود: **مقدمه** (Premise) و **فرضیه** (Hypothesis). مدل باید رابطهٔ آن‌ها را در یکی از سه کلاس قرار دهد:

جدول ۳.۱: سه کلاس NLI

کلاس	مفهوم
Entailment (استلزام)	فرضیه از مقدمه قابل نتیجه‌گیری است.
Contradiction (تناقض)	فرضیه با مقدمه تناقض دارد.
Neutral (خنثی)	از مقدمه نمی‌توان درستی یا نادرستی فرضیه را نتیجه گرفت.

مثال کلاس. مقدمه: «سامانهٔ راداری یک پهپاد ناشناس را شناسایی کرده است؛ به واحد پدافند ابلاغ شده که تا زمان شناسایی قطعی توسط گشت، از شلیک خودداری کند.»

- الف) «واحد پدافند در حال حاضر دستور عدم درگیری را اجرا می‌کند.» برچسب موردنظر در کلاس: Entailment
- ب) «واحد پدافند دستور دارد بلافاصله هر شیء متحرک در آسمان را با آتش سنگین منهدم کند.» برچسب: Contradiction
- ج) «پهپاد حامل محموله غیرمجاز است.» برچسب: Neutral، زیرا مقدمه دربارهٔ نوع محموله اطلاعاتی نمی‌دهد.

برچسب فرضیهٔ «الف» وابسته به دستورالعمل برچسب‌گذاری است

از نظر استنتاج منطقی سخت‌گیرانه، «دستور خودداری از شلیک داشتن» لزوماً به معنای «در حال حاضر در حال اجرای دستور عدم درگیری بودن» نیست؛ این فرضیه در بسیاری از دستورالعمل‌ها می‌تواند Neutral یا استلزامِ ضعیف (به‌معنای «محتملاً درست») تلقی شود. در مجموعه‌داده‌های NLI معمولاً از برچسب‌گذار خواسته می‌شود فرض کند مقدمه درست است و بپرسد «آیا یک انسان معقول فرضیه را نتیجه می‌گیرد؟». برچسب بالا مطابق بیان استاد حفظ شده و نشان می‌دهد چرا تعریف دقیق دستورالعمل مهم است.

اهمیت درک معنایی. در مجموعه‌داده‌های ساده و قدیمی‌تر، گاهی رابطهٔ دو جمله با شباهت‌های واژگانی ساده قابل تشخیص بود. در مسائل پیچیده‌تر مدل باید بازنویسی‌های مختلف یک مفهوم را بفهمد؛ مثلاً «خودداری از شلیک» و «عدم درگیری» در یک بافت مشخص مفهوم نزدیکی دارند. در کاربردهای تخصصی نمی‌توان فرض کرد همهٔ مدل‌های عمومی چنین روابطی را درست تشخیص می‌دهند.

شباهت معنایی متون (STS)

Semantic Textual Similarity نیز دوجمله‌ای است: ورودی دو جمله یا قطعه متن و خروجی یک امتیاز شباهت است. هدف بررسی یکسان بودن کلمات نیست، بلکه سنجش نزدیکی معنایی دو متن است. در مثال کلاس، امتیاز در بازهٔ ۱ تا ۵ تعریف شد (نزدیک ۱: شباهت کم؛ نزدیک ۵: شباهت زیاد). اگر خروجی فقط مقادیر گسستهٔ ۱ تا ۵ باشد و هر عدد یک کلاس تلقی شود، مسئله **طبقه‌بندی** (Classification) است؛ اگر خروجی مقادیر پیوسته مانند ۲٫۵ یا ۳٫۷ بگیرد، مسئله **رگرسیون** (Regression) است. بنابراین نوع مسئله به نحوهٔ تعریف برچسب‌های مجموعه‌داده بستگی دارد.

بازه نمره STS

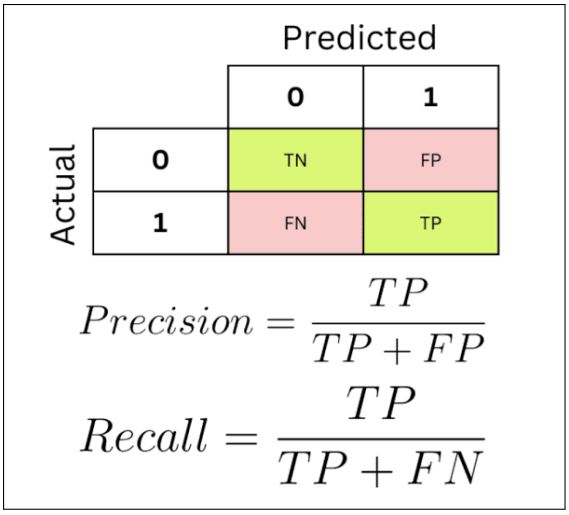
بازهٔ ۱ تا ۵ مثال کلاس است. در مجموعه‌داده‌های معروف STS (مثل STS Benchmark) نمره معمولاً پیوسته و در بازهٔ ۰ تا ۵ است و بیشتر به‌صورت رگرسیون مدل می‌شود.

۳.۳.۱ ارزیابی طبقه‌بندی: ماتریس درهم‌ریختگی و معیارها

چهار حالت پایه

در طبقه‌بندی دودویی هر پیش‌بینی در یکی از چهار حالت زیر قرار می‌گیرد (شکل ۴.۱):

- **مثبت درست** (True Positive, TP): نمونهٔ مثبت را مثبت تشخیص داده‌ایم.
- **منفی درست** (True Negative, TN): نمونهٔ منفی را منفی تشخیص داده‌ایم.
- **مثبت کاذب** (False Positive, FP): نمونهٔ منفی را به‌اشتباه مثبت تشخیص داده‌ایم.
- **منفی کاذب** (False Negative, FN): نمونهٔ مثبت را به‌اشتباه منفی تشخیص داده‌ایم.



شکل ۴.۱: ماتریس درهم‌ریختگی (ردیف‌ها: برچسب واقعی، ستون‌ها: پیش‌بینی) و فرمول‌های دقت (Precision) و بازیابی (Recall). (برگرفته از تختهٔ کلاس)

در مثال کلاس برای سادگی، کلاس Neutral حالت «منفی» و دو کلاس Entailment و Contradiction حالت «مثبت» گرفته شدند. در مسائل چندکلاسه، تعریف مثبت و منفی به نحوهٔ ارزیابی بستگی دارد و هر کلاس را می‌توان جداگانه در برابر بقیه سنجید.

دقت، بازیابی و F1

معیارهای ارزیابی

$$\text{Precision} = \frac{TP}{TP + FP}, \qquad \text{Recall} = \frac{TP}{TP + FN}, \qquad F_۱ = ۲ \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Precision: از میان آنچه مثبت پیش‌بینی کرده‌ایم، چه کسری واقعاً مثبت است. Recall: از میان نمونه‌های واقعاً مثبت، چه کسری را پیدا کرده‌ایم. F1 میانگین هارمونیک این دو است.

[محتوای افزوده] مثال عددی: محاسبهٔ دقت، بازیابی و F1

فرض کنید یک آشکارساز کلمهٔ فعال‌ساز روی ۱۰۰۰ قطعهٔ صوتی آزمایش شده است. ۶۰ قطعه واقعاً حاوی کلمهٔ فعال‌ساز بوده‌اند. ماتریس درهم‌ریختگی چنین است:

	پیش‌بینی: مثبت	پیش‌بینی: منفی
واقعی: مثبت	$TP = ۴۰$	$FN = ۲۰$
واقعی: منفی	$FP = ۱۰$	$TN = ۹۳۰$

$$\text{Precision} = \frac{۴۰}{۴۰ + ۱۰} = ۰/۸۰, \qquad \text{Recall} = \frac{۴۰}{۴۰ + ۲۰} \approx ۰/۶۶۷,$$

$$F_۱ = ۲ \cdot \frac{۰/۸۰ \times ۰/۶۶۷}{۰/۸۰ + ۰/۶۶۷} \approx ۰/۷۲۷ \quad \left(\text{یا } F_۱ = \frac{۲TP}{۲TP+FP+FN} = \frac{۸۰}{۱۱۰}\right).$$

دقتِ کلی (Accuracy) برابر $\frac{۴۰+۹۳۰}{۱۰۰۰} = ۰/۹۷$ است، یعنی عددی بسیار بالا، در حالی که یک‌سوم کلمات فعال‌ساز تشخیص داده نشده‌اند. این نشان می‌دهد چرا در داده‌های نامتوازن Accuracy به‌تنهایی گمراه‌کننده است و چرا Precision، Recall و F1 لازم‌اند.

هزینهٔ خطا در کاربردهای مختلف

استاد دو مثال برای اهمیت نوع خطا مطرح کرد:

- **سامانهٔ دفاعی:** مثبت کاذب (مثلاً تشخیص اشتباه یک شیء بی‌خطر به‌عنوان تهدید) می‌تواند به اقدام خطرناک منجر شود؛ پس نسبت به FP حساسیت ویژه لازم است (دقت اهمیت بالایی دارد).
- **غربالگری بیماری:** از دست دادن یک فرد بیمار (منفی کاذب) می‌تواند پیامد جدی داشته باشد؛ پس کاهش

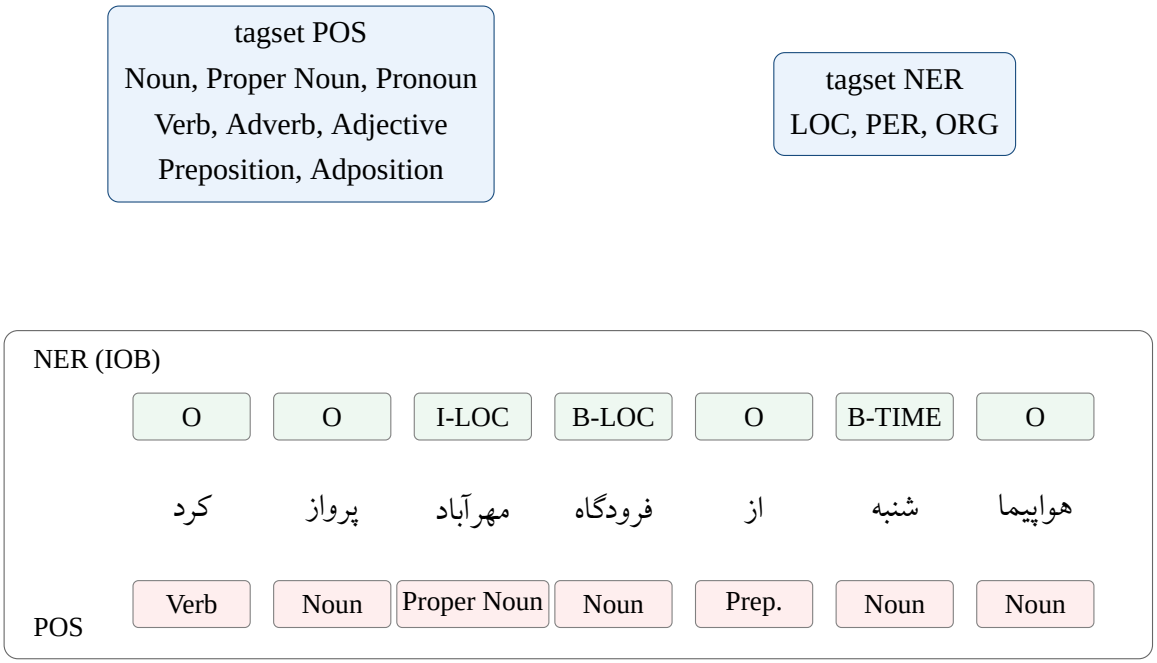
FN و افزایش Recall مهم است.

نتیجهٔ مهم

معیار ارزیابی را نباید صرفاً با یک عدد عمومی انتخاب کرد؛ باید با نیازمندی و حساسیت کاربرد هماهنگ باشد. معمولاً بالا بردن دقت و بازیابی هم‌زمان دشوار است و میان آن‌ها مصالحه (trade-off) وجود دارد.

۴.۳.۱ برچسب‌گذاری توالی (Sequence Labeling)

در برچسب‌گذاری توالی، ورودی توالی‌ای از توکن‌هاست و برای هر توکن یک برچسب تولید می‌شود. روی تخته دو مجموعهٔ برچسب (tagset) و یک جملهٔ نمونه نوشته شده است (شکل ۵.۱).



شکل ۵.۱: مجموعهٔ برچسب‌های POS و NER و برچسب‌گذاری جملهٔ نمونهٔ «هواپیما شنبه از فرودگاه مهرآباد پرواز کرد»: برچسب‌های NER با قالب IOB بالای جمله (سبز) و برچسب‌های POS زیر آن (قرمز) آمده‌اند؛ کلمات از راست به چپ خوانده می‌شوند. روی تخته برچسب‌ها به‌صورت اختصاری (N، V، P، B-LOC، I-LOC، ...) نوشته شده بود. (بازسازی‌شده از تختهٔ کلاس)

برچسب‌گذاری نقش واژگانی (POS Tagging)

برای هر کلمه، دستهٔ دستوری آن (Noun، Proper Noun، Pronoun، Verb، Adjective، Adverb، Preposition یا Adposition) مشخص می‌شود. استاد تأکید کرد POS Tagging با تعیین نقش نحوی (فاعل، مفعول و ...) فرق دارد: یک اسم خاص در یک جمله فاعل و در جمله‌ای دیگر مفعول است، ولی دستهٔ واژگانی‌اش همچنان «اسم خاص» است.

قالب IOB و شناسایی موجودیت‌های نام‌دار (NER)

وقتی چند کلمهٔ متوالی به یک موجودیت تعلق دارند، مرز عبارت با قالب IOB مشخص می‌شود:

- B (Beginning): شروع یک عبارت برچسب‌دار،
- I (Inside): ادامهٔ عبارت،
- O (Outside): خارج از هر عبارت موردنظر.

شناسایی موجودیت نام‌دار (Named Entity Recognition - NER) موجودیت‌های مهم متن را پیدا و دسته‌بندی می‌کند. دسته‌های رایج: شخص (PER)، مکان (LOC)، سازمان (ORG) و زمان/تاریخ. تعداد و نوع دسته‌ها به مسئله بستگی دارد؛ مثلاً در یک پروژهٔ تخصصی ممکن است هدف شناسایی نام حیوانات یا گیاهان باشد. این انتخاب به مفاهیم و رده‌بندی‌ای که کارفرما نیاز دارد وابسته است و به مفهوم **هستی‌شناسی** (Ontology) مربوط می‌شود.

در کلاس دربارهٔ کلمهٔ «شنبه» و فعل مرکب «پرواز کرد» بحث شد. برچسب‌گذاری چنین مواردی باید طبق دستورالعمل مشخص مجموعه‌داده باشد؛ مثلاً ممکن است یک نظام برچسب‌گذاری برای اجزای فعل مرکب برچسب‌های جدا بگذارد. بنابراین برچسب‌های شکل ۵.۱ نمونه‌ای مطابق بحث کلاس‌اند و تنها برچسب‌گذاری معتبر نیستند.

ارزیابی NER

می‌توان از Precision، Recall و F1 استفاده کرد. در بحث کلاس، O حالت «منفی» در نظر گرفته شد: اگر کلمه‌ای در داده مرجع O باشد ولی مدل آن را مکان تشخیص دهد، یک مثبت کاذب رخ داده است.

ارزیابی در سطح توکن یا در سطح موجودیت

در ارزیابی استاندارد NER (مثل conlleval و seqeval) معمولاً یک موجودیت تنها وقتی درست شمرده می‌شود که هم نوع و هم مرز آن کاملاً درست باشد (مثلاً «فرودگاه مهرآباد» باید با هر دو توکن و برچسب‌های B-LOC، I-LOC پیدا شود). اگر فقط توکن‌ها شمرده شوند، چون اکثر توکن‌ها O هستند، دقت کلی بسیار بالا و گمراه‌کننده می‌شود؛ به همین دلیل F1 در سطح موجودیت گزارش می‌شود.

دستورالعمل برچسب‌گذاری (Annotation Guideline)

در پروژه‌های واقعی، مهندس هوش مصنوعی لزوماً مسئول همهٔ جزئیات زبان‌شناختی نیست و ممکن است برای طراحی دقیق برچسب‌ها از یک زبان‌شناس کمک بگیرد. مراحل کار:

۱. تعیین هدف پروژه و اطلاعات موردنیاز،

۲. تعریف مجموعهٔ برچسب‌ها (Tag Set)،

۳. تدوین دستورالعمل برچسب‌گذاری با کمک متخصص زبان،

۴. آموزش برچسب‌گذاران،

۵. برچسب‌گذاری داده‌ها بر اساس دستورالعمل مشترک،

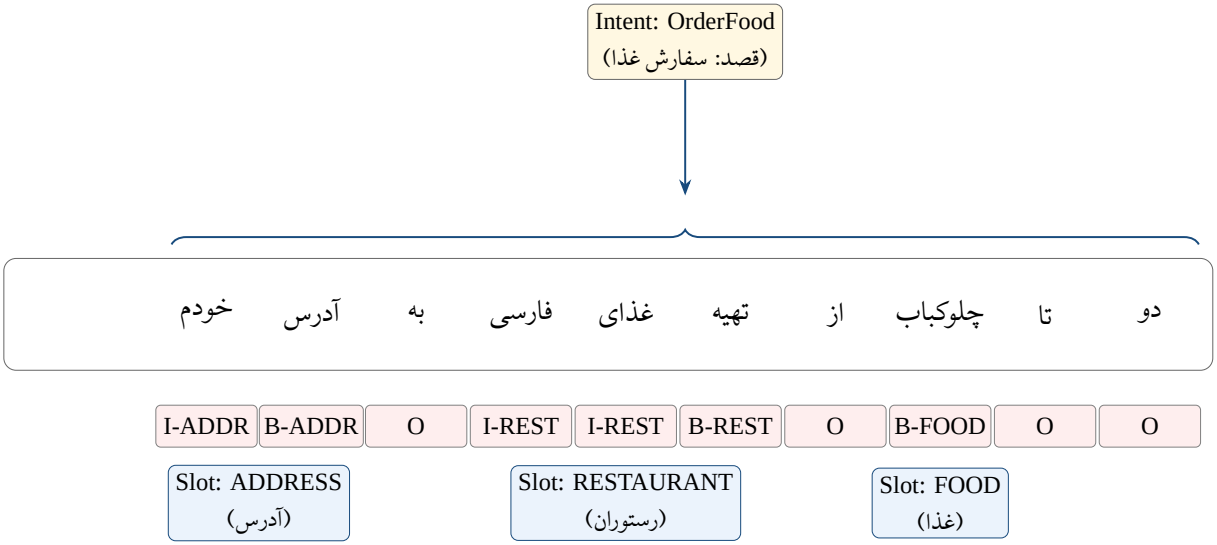
۶. بررسی سازگاری و کیفیت برچسب‌ها.

همین دستورالعمل می‌تواند مبنای Prompt برای برچسب‌گذاری با مدل‌های زبانی هم باشد. بنابراین طراحی یک مجموعه‌داده فقط انتخاب مدل نیست؛ تعریف دقیق برچسب‌ها و قواعد استفاده از آن‌ها نیز اهمیت دارد.

۵.۳.۱ تشخیص قصد و پر کردن جایگاه‌ها (Intent Detection and Slot Filling)

این دو وظیفه در سامانه‌های مکالمه‌ای و دستیارهای صوتی با هم به‌کار می‌روند:

- **تشخیص قصد** (Intent Detection): کل جمله در یک کلاس (مثل سفارش غذا، درخواست تاکسی، خرید، کنترل وسایل هوشمند) قرار می‌گیرد؛ پس طبقه‌بندی در سطح جمله است.
- **پر کردن جایگاه** (Slot Filling): استخراج اطلاعات لازم برای اجرای قصد (مثلاً نوع غذا، نام رستوران، آدرس تحویل). Slot Filling معمولاً به‌صورت برچسب‌گذاری توالی (با قالب IOB) مدل می‌شود.



شکل ۶.۱: جملهٔ نمونهٔ «دو تا چلوکباب از تهیه‌غذای فارسی به آدرس خودم» (خوانش از راست به چپ): کل جمله یک قصد (Intent) دارد و هر توکن با قالب IOB برچسب جایگاه (Slot) می‌گیرد. روی تخته جایگاه‌ها با حرف اختصاری (N برای غذا، R برای رستوران و A برای آدرس) نوشته شده بودند. (بازسازی‌شده از تختهٔ کلاس)

مثال کلاس. جملهٔ «دو تا چلوکباب از تهیه‌غذای فارسی به آدرس خودم» با قصد OrderFood در شکل ۶.۱ برچسب‌گذاری شده است: «چلوکباب» نام غذا (B-FOOD)، «تهیه‌غذای فارسی» نام رستوران (B-REST و دو I-REST) و «آدرس خودم» آدرس تحویل (B-ADDR، I-ADDR) است و بقیهٔ توکن‌ها O هستند. در این مثال فرض شده مجموعهٔ جایگاه‌ها فقط نام غذا، رستوران و آدرس است، پس «دو تا» برچسب O گرفته است؛ اگر تعداد غذا هم مهم باشد، می‌توان جایگاه جداگانه‌ای مثل Quantity تعریف کرد. یعنی برچسب‌گذاری به طرح داده (Data Schema) و نیازمندی‌ها وابسته است.

قصد و جایگاه

قصد (Intent): هدف کاربر از جمله. **جایگاه** (Slot): پارامترهای لازم برای اجرای آن هدف. مثلاً قصد «خرید بلیت» جایگاه‌های مبدأ، مقصد و ساعت دارد.

پرسش و پاسخ: اگر کاربر قصدش را مستقیم نگوید؟ مثلاً به‌جای «کولر را روشن کن» بگوید «هوا خیلی گرم است». اینکه مدل این جمله را قصد روشن کردن کولر بداند به داده‌های آموزشی و تعریف مسئله بستگی دارد: اگر در داده‌ها شکایت از گرما در آن بافت به‌معنای درخواست روشن کردن کولر باشد، مدل می‌تواند آن را یاد بگیرد؛ در این حالت قصد به کل جمله نسبت داده می‌شود، نه فقط کلمهٔ «گرم». اگر جمله جایگاه‌های لازم را نداشته باشد، سیستم می‌تواند وارد گفت‌وگو شود و اطلاعات ناقص را بپرسد:

کاربر: «می‌خوام غذا سفارش بدم.» سیستم: «چه غذایی می‌خواهید؟ از کدام رستوران؟»

۶.۳.۱ مدل‌سازی زبان و سه الگوی معماری

مدل‌سازی زبان علّی

در مدل‌سازی زبان (Language Modeling - Causal LM) مدل توالی‌ای از توکن‌ها را می‌گیرد و توکن بعدی را پیش‌بینی می‌کند؛ با تکرار این کار متن کامل تولید می‌شود:

$$P(x_t \mid x_1, x_2, \ldots, x_{t-1}).$$

به این شیوه «علّی» (Causal) گفته می‌شود، چون مدل هنگام پیش‌بینی فقط به توکن‌های قبلی تکیه می‌کند.

انواع معماری Transformer

- **Encoder-only**: برای درک و استخراج بازنمایی از ورودی؛ مناسب وظایف طبقه‌بندی مانند تحلیل احساسات و برچسب‌گذاری.
- **Decoder-only**: تولید خودبازگشتی (autoregressive) توکن‌ها؛ مناسب مدل‌سازی زبان و تولید متن (مانند خانوادهٔ GPT).
- **Encoder-Decoder**: بازنمایی ورودی و تولید خروجی جدید؛ مناسب وظایف Seq2Seq مانند ترجمه و خلاصه‌سازی.

پرسش و پاسخ: آیا Decoder-only یعنی مدل ورودی را نمی‌فهمد؟ خیر. Decoder-only یعنی معماری یک Encoder مجزا مانند Encoder-Decoder ندارد؛ ولی مدل با لایه‌های خود ورودی و زمینهٔ آن را پردازش می‌کند و بر اساس آن خروجی می‌سازد. Prompt همان ورودی متنی مدل است که در پردازش و تولید پاسخ نقش دارد. جزئیات Transformer در جلسات بعد بررسی می‌شود.

نکتهٔ تکمیلی دربارهٔ معماری‌ها

تقسیم‌بندی بالا نمای کلی و ساده‌شده است. مدل‌های Encoder-only (مانند BERT) معمولاً با هدف «مدل‌سازی زبان پوشیده» (Masked LM) آموزش می‌بینند، نه پیش‌بینی توکن بعدی؛ و مدل‌های Decoder-only امروزه با Prompt طبقه‌بندی و برچسب‌گذاری را هم انجام می‌دهند. پس این وظایف را «مناسب» هر معماری می‌دانیم، نه «منحصر» به آن.

۷.۳.۱ هم‌ارجاعی، پیوند موجودیت و خوشه‌بندی

تشخیص هم‌ارجاعی (Coreference Resolution)

باید عبارت‌هایی که به یک موجودیت مشترک اشاره دارند شناسایی شوند. ورودی یک متن یا سند و خروجی گروه‌هایی از عبارت‌های هم‌ارجاع است. مثلاً اگر ابتدا نام «علی» بیاید و بعد «آقای احمدی» یا «او»، مدل باید بفهمد همه به یک شخص اشاره می‌کنند:

- **خوشهٔ ۱:** علی، آقای احمدی، او
- **خوشهٔ ۲:** کتاب، این اثر، آن

از نظر ساختار خروجی، این مسئله به **خوشه‌بندی** (Clustering) شباهت دارد، چون تعداد خوشه‌ها و اعضای هر خوشه از پیش معلوم نیست (در تخته: «خوشه‌بندی عبارات اسمی و ضمایر که هویت ارجاعی یکسانی در متن دارند»).

پیوند موجودیت (Entity Linking)

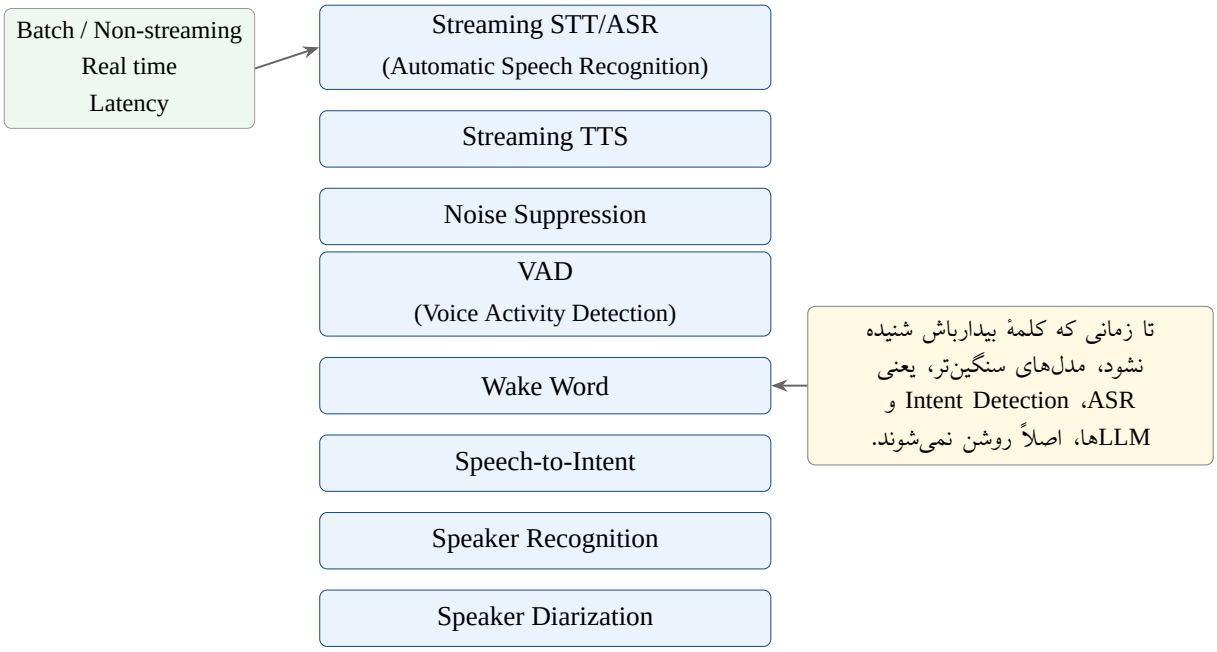
در کلاس تفاوت چنین بیان شد: هم‌ارجاعی درون یک سند و Entity Linking ایجاد ارتباط میان اشاره‌ها در اسناد مختلف.

تعریف دقیق Entity Linking

بیان کلاس ساده‌سازی است. در تعریف رایج، **پیوند موجودیت** (Entity Linking) یعنی نگاشت هر اشاره (mention) در متن به یک موجودیت مشخص در یک پایگاه دانش (مثل ویکی‌پدیا یا Wikidata). مثلاً «مهرآباد» در یک متن به مدخل «فرودگاه بین‌المللی مهرآباد» وصل می‌شود، نه به مکانی هم‌نام. هم‌ارجاعی میان‌اسنادی (Cross-document Coreference) مسئلهٔ نزدیک ولی جداست.

۴.۱ وظایف پردازش گفتار

تأکید اصلی درس بر وظایف گفتاری و مدل‌های آن‌ها خواهد بود. فهرست این وظایف روی تخته در شکل ۷.۱ آمده است.



شکل ۷.۱: فهرست وظایف گفتاری روی تخته. کادر سبز: تفاوت حالت دسته‌ای (Batch/Non-streaming) و بلادرنگ (Real-time) و اهمیت تأخیر (Latency) در بازشناسی گفتار؛ کادر زرد: یادداشت استاد دربارهٔ روشن نشدن مدل‌های سنگین پیش از شنیدن کلمهٔ بیدارباش. (بازسازی‌شده از تختهٔ کلاس)

۱.۴.۱ بازشناسی خودکار گفتار (ASR)

بازشناسی خودکار گفتار (Automatic Speech Recognition - ASR)، یا Speech-to-Text (STT)، گفتار را به متن تبدیل می‌کند: ورودی سیگنال صوتی و خروجی متن. مثلاً «چراغ اتاق را خاموش کن.»

حالت غیرجریانی و جریانی

- **غیرجریانی (دسته‌ای)** (Non-streaming / Batch): ابتدا بخش کامل گفتار (مثلاً یک فایل ضبط‌شده) دریافت و سپس پردازش می‌شود. چون مدل به کل گفتار دسترسی دارد، معمولاً زمینهٔ بیشتری برای تشخیص دارد.
- **جریانی** (Streaming / Real-time): سیستم هم‌زمان با دریافت گفتار شروع به پردازش می‌کند و منتظر پایان جمله نمی‌ماند. در دستیارهای صوتی و کاربردهای بلادرنگ مهم است.

در شرایط مشابه، پردازش غیرجریانی با استفاده از زمینهٔ کامل معمولاً به دقت بهتری می‌رسد، در حالی که حالت جریانی برای کاهش تأخیر طراحی می‌شود. روی تخته سه واژهٔ «Batch / Non-streaming»، «real time» و «Latency» کنار هم نوشته شده است.

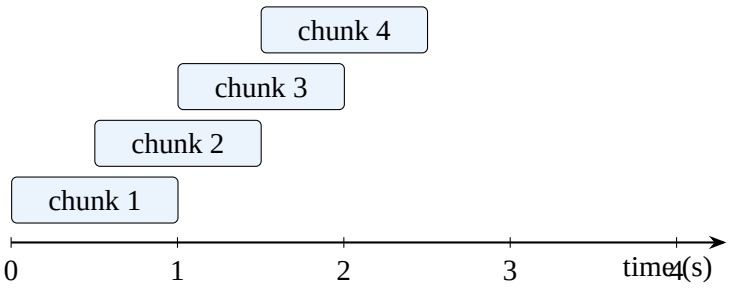
قطعه‌بندی (Chunking) در داده‌های جریانی

در حالت غیرجریانی ممکن است کل جمله یک نمونهٔ ورودی باشد؛ اما مدل جریانی باید سیگنال را به قطعات کوچک به نام **چانک** (Chunk) تقسیم کند. فرض کنید می‌خواهیم قصد کاربر را هنگام دریافت جملهٔ «چراغ اتاق را خاموش

جدول ۴.۱: مقایسهٔ حالت جریانی و غیرجریانی

ویژگی	جریانی	غیرجریانی
شروع پردازش	هنگام دریافت صوت	پس از دریافت بخش کامل
تأخیر پاسخ	معمولاً کمتر	معمولاً بیشتر
زمینهٔ در دسترس	محدودتر	بیشتر
پیچیدگی طراحی	بیشتر	معمولاً کمتر
کاربرد	تعامل زنده	پردازش فایل‌های ضبط‌شده

کن» تشخیص دهیم. در هر مرحله فقط بخشی از جمله در دسترس است: چانک ۱: «چراغ»؛ چانک ۲: «چراغ اتاق را»؛ چانک ۳: «چراغ اتاق را خاموش کن». برای ساخت داده می‌توان قطعاتی از گفتار ساخت و در یک طراحی مشخص برچسب Intent جملهٔ کامل را به آن‌ها هم داد. البته در مراحل اولیه مدل اطلاعات کافی ندارد: با شنیدن «چراغ اتاق را...» هنوز معلوم نیست قصد روشن کردن است یا خاموش کردن. استاد به **هم‌پوشانی** (Overlap) میان قطعات هم اشاره کرد: بخشی از صوت در چند چانک متوالی تکرار می‌شود تا پیوستگی اطلاعات حفظ شود؛ این کار می‌تواند مؤثر باشد ولی باید با طراحی مناسب داده و مدل همراه باشد.



شکل ۸.۱: چانک‌های یک‌ثانیه‌ای با گام نیم‌ثانیه‌ای؛ هر چانک ۵۰٪ با چانک قبلی هم‌پوشانی دارد (شکل افزوده).

[محتوای افزوده] مثال عددی: تعداد چانک‌ها

فرض کنید طول چانک $L = ۱$ ثانیه، گام (hop) برابر $H = ۰/۵$ ثانیه (هم‌پوشانی ۵۰٪) و طول گفتار $T = ۴$ ثانیه باشد. تعداد چانک‌های کامل

$$N = \left\lfloor \frac{T - L}{H} \right\rfloor + ۱ = \left\lfloor \frac{۴ - ۱}{۰/۵} \right\rfloor + ۱ = ۷.$$

بدون هم‌پوشانی ($H = L$) فقط ۴ چانک داریم. مدل جریانی ناچار است دست‌کم یک چانک (در اینجا ۱ ثانیه) صبر کند، پس تأخیرِ حداقلی سیستم به طول چانک وابسته است؛ چانک کوچک‌تر تأخیر را کم، ولی زمینه و معمولاً دقت را کمتر می‌کند.

۲.۴.۱ تبدیل متن به گفتار (TTS)

تبدیل متن به گفتار (Text-to-Speech - TTS) معکوس ASR است: ورودی متن (مثلاً «سلام، حال شما چطور است؟») و خروجی سیگنال گفتار. در **TTS جریانی** (Streaming TTS) تولید گفتار تدریجی انجام می‌شود و سیستم

پیش از آماده شدن کل پاسخ می‌تواند صوت را پخش کند؛ این برای سامانه‌های مکالمه‌ای بلادرنگ مهم است.

۳.۴.۱ حذف نویز (Noise Suppression)

ورودی صوت نویزی و خروجی نسخهٔ بهبودیافتهٔ آن است. در مدل ساده‌ای که در کلاس بحث شد، گفتار اصلی حفظ و نویز کم می‌شود و طول فایل تغییر نمی‌کند: گفتار ۱۰ ثانیه‌ای با نویز محیط، به سیگنال ۱۰ ثانیه‌ای با نویز کمتر تبدیل می‌شود. این وظیفه (که به‌طور کلی Speech Enhancement نام دارد) معمولاً از مراحل اولیهٔ خط لولهٔ پردازش گفتار است.

۴.۴.۱ تشخیص فعالیت گفتاری (VAD)

تشخیص فعالیت گفتاری (Voice Activity Detection - VAD) مشخص می‌کند در کدام بازه‌های سیگنال گفتار وجود دارد. در ساده‌ترین شکل یک طبقه‌بندی دودویی است: 0 یعنی گفتار نیست و 1 یعنی گفتار هست. مثلاً اگر در پنج ثانیهٔ اول کسی صحبت نکند و بعد کاربر شروع کند، VAD باید این تغییر وضعیت را تشخیص دهد.

کاربرد: صرفه‌جویی در منابع. دستیار صوتی دائماً صدای محیط را دریافت می‌کند، ولی لازم نیست مدل‌های سنگین همیشه فعال باشند. می‌توان ابتدا VAD را اجرا کرد و فقط با تشخیص فعالیت گفتاری مراحل بعدی را فعال کرد:

$$\text{Audio} \rightarrow \text{Noise Suppression} \rightarrow \text{VAD} \rightarrow \text{Speech Processing}.$$

۵.۴.۱ تشخیص کلمهٔ فعال‌ساز (Wake Word Detection)

وظیفهٔ شناسایی یک کلمه یا عبارت مشخص برای فعال‌سازی سیستم است؛ کاربر از قبل می‌داند باید آن عبارت را بگوید (مثلاً «سلام»). سیستم ابتدا آن را تشخیص می‌دهد و بعد پردازش اصلی را آغاز می‌کند. روی تخته یادداشت شده: تا زمانی که کلمهٔ بیداری‌باش شنیده نشود، مدل‌های سنگین‌تر (ASR، Intent Detection و LLMها) اصلاً روشن نمی‌شوند.

جدول ۵.۱: تفاوت VAD و Wake Word

VAD	Wake Word Detection
وجود گفتار را تشخیص می‌دهد.	وجود یک عبارت مشخص را تشخیص می‌دهد.
به محتوای دقیق جمله وابسته نیست.	به کلمه یا عبارت هدف وابسته است.
برای شناسایی بازه‌های گفتاری به‌کار می‌رود.	برای فعال‌سازی دستیار به‌کار می‌رود.

هر دو می‌توانند از اجرای دائمی مدل‌های پرهزینه جلوگیری کنند.

۶.۴.۱ تشخیص مستقیم قصد از گفتار (Speech-to-Intent)

ورودی گفتار و خروجی برچسب قصد است و لزومی ندارد تبدیل صوت به متن در یک مرحلهٔ مستقل انجام شود. دو رویکرد قابل مقایسه‌اند:

$$\text{Speech} \rightarrow \text{ASR} \rightarrow \text{Text} \rightarrow \text{Intent Detection}$$

در برابر

$$\text{Speech} \rightarrow \text{Speech-to-Intent} \rightarrow \text{Intent}.$$

این ماژول می‌تواند در بخش‌های ابتدایی سیستم، به‌عنوان تصمیم‌گیرندهٔ سبک به‌کار رود: اگر کاربر فقط بگوید «چراغ را خاموش کن»، لازم نیست مدل زبانی بزرگ فعال شود و فرمان مستقیماً اجرا می‌شود. این رویکرد برای Edge AI و کاربردهایی که مصرف منابع مهم است مفید است.

۷.۴.۱ بازشناسی گوینده (Speaker Recognition)

هدف شناسایی گوینده از روی ویژگی‌های صدای اوست. مثال استاد: دستیار صوتی که فقط باید به دستور افراد مشخصی پاسخ دهد، در حالی که ممکن است رادیو روشن باشد یا شخص دیگری حرف بزند. روند:

۱. نمونهٔ صدای کاربران مجاز ثبت می‌شود.

۲. سیستم صدای جدیدی دریافت می‌کند.

۳. مدل ویژگی‌های گوینده را بررسی می‌کند.

۴. در صورت تطابق با کاربر مجاز، پردازش اصلی ادامه می‌یابد.

بدین ترتیب این وظیفه می‌تواند جزئی از کنترل دسترسی یا شخصی‌سازی دستیار باشد.

تشخیص هویت و تأیید هویت

بازشناسی گوینده معمولاً دو حالت دارد: **تأیید گوینده** (Speaker Verification) (آیا این صدا مال همان کسی است که ادعا می‌کند؟ تصمیم دودویی) و **شناسایی گوینده** (Speaker Identification) (این صدا مال کدام‌یک از افراد ثبت‌شده است؟). مثال دستیار صوتی بالا بیشتر به تأیید نزدیک است.

۸.۴.۱ تفکیک گویندگان (Speaker Diarization)

تفکیک گویندگان (Speaker Diarization) مشخص می‌کند چه کسی در چه زمانی صحبت کرده است. خروجی یک ASR معمولی برای یک جلسه فقط می‌تواند متن «سلام، جلسه شروع شد. مدارک کجاست؟ فرستادم خدمتتون.» باشد؛ ولی در Diarization گفتار افراد جدا می‌شود و بازه‌های زمانی هم مشخص می‌گردد:

استاد این وظیفه را از جهتی شبیه Coreference Resolution دانست: همان‌طور که عبارت‌های دارای مرجع مشترک در یک خوشه قرار می‌گیرند، در Diarization هم بخش‌های صوتیِ متعلق به یک گوینده در یک گروه قرار می‌گیرند؛ پس می‌توان آن را از نظر گروه‌بندی قطعات گفتار، مسئلهٔ Clustering نیز دانست.

جدول ۶.۱: نمونهٔ خروجی Diarization همراه با ASR (مثال کلاس)

گوینده	زمان	متن
گوینده ۱ (علی)	00:01	سلام، جلسه شروع شد.
گوینده ۲ (رضا)	00:03	مدارک کجاست؟
گوینده ۱ (علی)	00:05	فرستادم خدمتتون.

جدول ۷.۱: تفاوت بازشناسی گوینده و تفکیک گویندگان

ویژگی	Speaker Recognition	Speaker Diarization
پرسش اصلی	این صدا متعلق به چه کسی است؟	چه کسی در چه زمانی صحبت کرده است؟
نیاز به کاربران از پیش شناخته‌شده	در کاربرد کلاس، بله	الزاماً خیر
خروجی	هویت یا نتیجهٔ تطابق	بازه‌های زمانی تفکیک‌شده بر اساس گوینده
کاربرد	کنترل دسترسی صوتی	تحلیل جلسات و مکالمات چندنفره

۵.۱ وظایف بینایی و ارتباط آن‌ها با درس

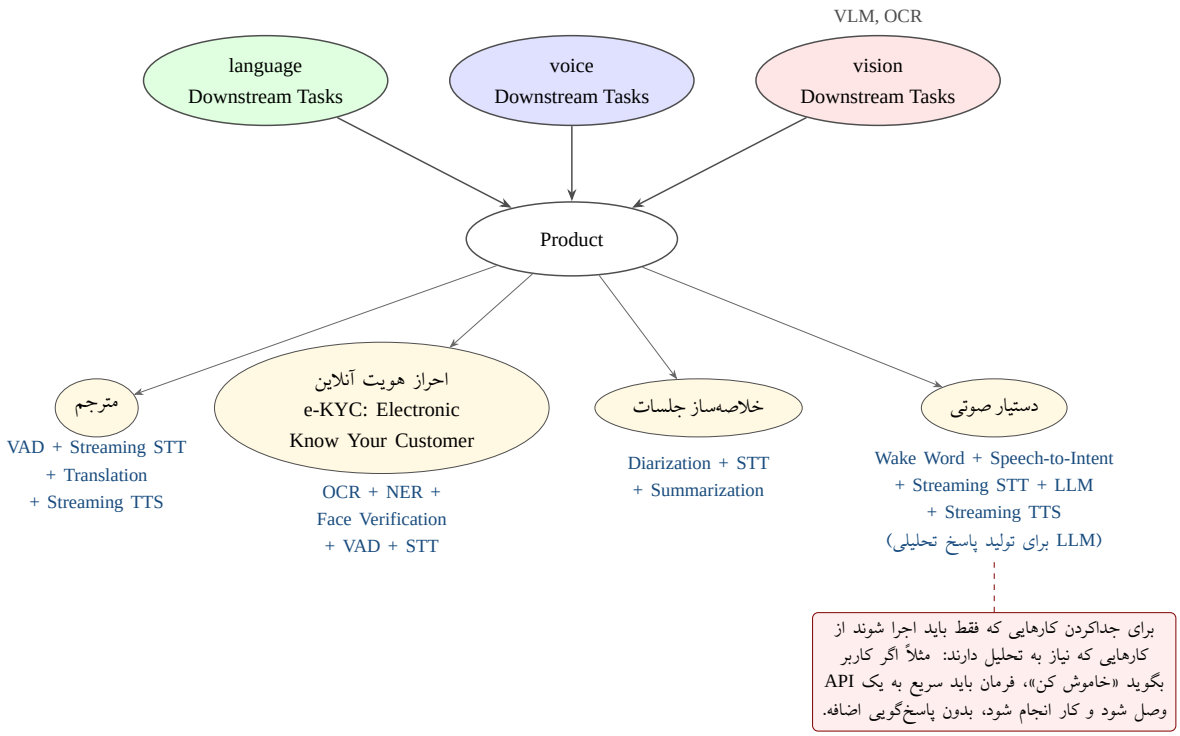
تمرکز اصلی درس بر مدل‌ها و وظایف گفتار است، اما در طراحی محصولات واقعی ممکن است به مدل‌های متن و تصویر هم نیاز باشد. دو مفهوم بینایی در کلاس معرفی شد:

- **مدل‌های بینایی-زبان** (Vision-Language Models - VLM): اطلاعات تصویری و متنی را با هم پردازش می‌کنند؛ مثلاً تصویری را می‌گیرند و به پرسش‌هایی دربارهٔ آن پاسخ می‌دهند. در برخی معماری‌ها ویدئو هم در کنار تصویر و متن پردازش می‌شود.
- **بازشناسی نوری نویسه** (Optical Character Recognition - OCR): استخراج متن از تصویر؛ ورودی تصویر حاوی متن و خروجی متن قابل پردازش. مثلاً استخراج متن کارت شناسایی یا سند اسکن‌شده؛ خروجی می‌تواند به مدل‌های NLP داده شود.

در یک خط لوله، استفاده از OCR موجود (کتابخانه یا مدل آماده) معمولاً بهتر از ساختن مدل OCR جدید است.

۶.۱ ساخت محصول با ترکیب وظایف

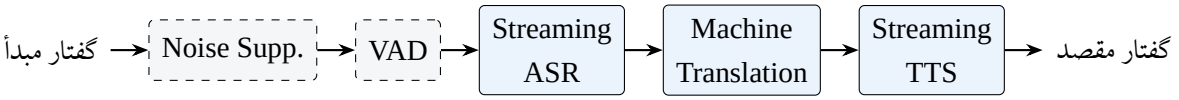
در بخش پایانی، استاد چند محصول مطرح کرد و از دانشجویان خواست ماژول‌های لازم را مشخص کنند؛ هدف تبدیل دانش وظایف مستقل به توانایی طراحی سیستم کامل بود (شکل ۹.۱).



شکل ۹.۱: وظایف سه حوزهٔ زبانی، گفتاری و بینایی به «محصول» می‌رسند. محصولات نمونه: مترجم، دستیار صوتی، احراز هویت آنلاین (e-KYC) و خلاصه‌ساز جلسات، هر کدام با ماژول‌های لازم زیر آن؛ کادر قرمز یادداشت استاد دربارهٔ دستیار صوتی است. (بازسازی‌شده از تختهٔ کلاس)

۱.۶.۱ مترجم صوتی

ماژول‌های اصلی: ASR/Speech-to-Text → Machine Translation → Text-to-Speech. روی تخته: VAD + Streaming STT + Translation + Streaming TTS. در ابتدای خط لوله می‌توان Noise Suppression هم قرار داد، و بسته به شیوهٔ تعامل کاربر ممکن است VAD یا Wake Word لازم باشد. سیستم می‌تواند هم جریانی و هم غیرجریانی باشد: در مترجم هم‌زمان مکالمه حالت جریانی مهم‌تر است و در ترجمهٔ یک فایل ضبط‌شده حالت غیرجریانی کافی است.



شکل ۱۰.۱: خط لولهٔ مترجم صوتی؛ ماژول‌های خط‌چین اختیاری‌اند (شکل افزوده).

۲.۶.۱ احراز هویت آنلاین (e-KYC)

e-KYC (Electronic Know Your Customer) سامانه‌ای است که از کاربر می‌خواهد: تصویر کارت ملی ارائه دهد، از چهرهٔ خود تصویر یا ویدئو بگیرد و جمله‌ای مشخص را با صدای بلند بگوید. ماژول‌های نوشته‌شده روی تخته: OCR + NER + Face Verification + VAD + STT.

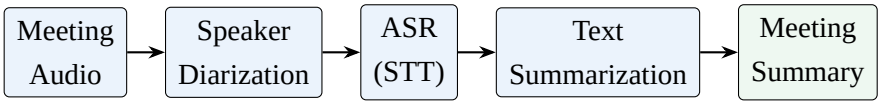
۱. **استخراج اطلاعات از کارت:** OCR روی تصویر کارت اجرا می‌شود و اطلاعاتی مانند نام، شمارهٔ شناسایی و تاریخ تولد استخراج می‌شود. اگر جای این اطلاعات روی کارت ثابت و مشخص باشد، استخراج بر اساس ساختار ثابت ممکن است؛ در غیر این صورت می‌توان از NER برای تشخیص نوع فیلدها استفاده کرد. سپس اطلاعات با داده‌های یک سامانهٔ مرجع مقایسه می‌شود.

۲. **بررسی چهره:** تصویر چهرهٔ روی کارت با تصویر یا ویدئوی جدید کاربر مقایسه می‌شود (**تأیید چهره** Face Verification): آیا چهرهٔ مشاهده‌شده با چهرهٔ ثبت‌شده در مدرک مطابقت دارد؟

۳. **بررسی جملهٔ گفته‌شده:** یکی از دانشجویان Speaker Recognition را پیشنهاد کرد، اما استاد توضیح داد هدف اصلی در اینجا الزاماً تشخیص هویت گوینده از روی نمونهٔ صدای ثبت‌شده نیست، بلکه بررسی این است که کاربر جملهٔ خواسته‌شده را گفته است یا نه. یک راه‌حل: Speech → ASR → Recognized Text → Text Comparison؛ یعنی گفتار به متن تبدیل و با جملهٔ مرجع مقایسه می‌شود. به امکان بررسی هماهنگی حرکت لب و گفتار (Lip Sync) هم اشاره شد. انتخاب ماژول به هدف دقیق مرحلهٔ احراز هویت بستگی دارد.

۳.۶.۱ خلاصه‌ساز جلسات

اگر فقط از ASR و Summarization استفاده شود، متن جلسه استخراج و خلاصه می‌شود ولی معلوم نیست هر جمله را چه کسی گفته است. راه‌حل استاد: ابتدا گویندگان تفکیک شوند. خط لوله (روی تخته: Diarization + STT + Summarization):

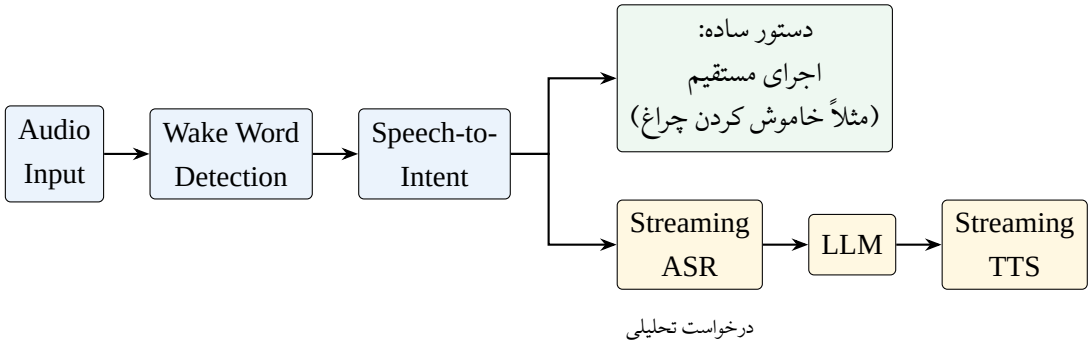


ترکیب ASR و Diarization علاوه بر محتوای صحبت‌ها، نسبت گفتار به گویندگان را هم مشخص می‌کند و خروجی ساختاریافته‌تری می‌دهد.

۴.۶.۱ دستیار صوتی هوشمند

فرض کنید دستیار باید هم فرمان‌های ساده مانند روشن و خاموش کردن وسایل را اجرا کند و هم به پرسش‌های تحلیلی پاسخ دهد. اگر همهٔ درخواست‌ها مستقیم به یک مدل زبانی بزرگ بروند، هزینه و مصرف منابع بالا می‌رود. پیشنهاد استاد: با Speech-to-Intent درخواست‌ها ابتدا بر اساس نوع تفکیک شوند. ماژول‌های روی تخته: Wake Word + Speech-to-Intent + Streaming STT + LLM (برای تولید پاسخ تحلیلی) + Streaming TTS. یادداشت استاد: برای جدا شدن کارهایی که فقط اجرا می‌خواهند و تحلیل نمی‌خواهند، مثلاً وقتی می‌گوید «خاموش کن»، این فرمان باید سریع به یک API وصل شود و کار انجام شود، بی‌خود حرف اضافه نزند.

- **مسیر ۱: فرمان ساده.** با «چراغ را خاموش کن»، Speech-to-Intent فرمان را تشخیص می‌دهد و بدون فعال کردن مدل زبانی بزرگ اجرا می‌شود.
- **مسیر ۲: پرسش تحلیلی.** گفتار به متن تبدیل می‌شود، متن به مدل زبانی می‌رود و پاسخ در صورت نیاز با TTS به گفتار تبدیل می‌شود.



شکل ۱۱.۱: دستیار صوتی با مسیر سبک برای فرمان‌های ساده (بالا) و مسیر سنگین برای پرسش‌های تحلیلی (پایین) (شکل افزوده).

همهٔ درخواست‌ها نباید لزوماً از یک مسیر پردازشی یکسان عبور کنند؛ طراحی هوشمندانهٔ خط لوله هزینه، تأخیر و مصرف منابع را کم می‌کند.

[محتوای افزوده] مثال عددی: صرفه‌جویی ناشی از مسیر سبک

فرض کنید ۷۰٪ درخواست‌ها فرمان ساده‌اند، مسیر سبک ۰٫۱ ثانیه و مسیر سنگین (ASR + LLM + TTS) ۲ ثانیه طول بکشد. اگر همه از مسیر سنگین بروند، میانگین تأخیر ۲ ثانیه است. با تفکیک اولیه:

$$۰٫۷ \times ۰٫۱ + ۰٫۳ \times ۲٫۰ = ۰٫۶۷ \text{ ثانیه}$$

(با چشم‌پوشی از هزینهٔ خود Speech-to-Intent). یعنی حدود ۶۶٪ کاهش میانگین تأخیر و کاهش مشابه در مصرف منابع LLM. اعداد فرضی‌اند و فقط منطق طراحی را نشان می‌دهند.

۷.۱ جدول جمع‌بندی وظایف

جدول زیر وظایف معرفی‌شده را بر اساس ورودی، خروجی و نوع مسئله کنار هم می‌گذارد.

۸.۱ جمع‌بندی

جلسهٔ اول به‌جای ورود به جزئیات مدل‌ها، واژگان مشترک درس را ساخت: وظایف پایین‌دستی در سه حوزهٔ زبان، گفتار و بینایی؛ دو رویکرد سرتاسری و خط لوله؛ معیارهای ارزیابی طبقه‌بندی؛ و نحوهٔ ترکیب وظایف برای ساخت محصولاتی مانند مترجم صوتی، e-KYC، خلاصه‌ساز جلسات و دستیار صوتی. جلسات بعد از آواشناسی و سیگنال گفتار شروع می‌کنند و به مدل‌ها می‌رسند.

جدول ۸.۱: وظایف پایین‌دستی معرفی‌شده در جلسه

وظیفه	ورودی	خروجی	نوع مسئله
Summarization	متن	متن خلاصه‌شده	Seq2Seq
Translation	متن	متن زبان مقصد	Seq2Seq
Sentiment Analysis	متن	کلاس احساس	Classification
NLI	دو متن	رابطهٔ معنایی (سه کلاس)	Classification
STS	دو متن	امتیاز شباهت	Regression یا Classification
POS Tagging	توالی توکن‌ها	برچسب هر توکن	Sequence Labeling
NER	متن	موجودیت‌های نام‌دار	Sequence Labeling
Intent Detection	متن	قصد کاربر	Classification
Slot Filling	متن	جایگاه‌های استخراج‌شده	Sequence Labeling
Language Modeling	توکن‌های قبلی	توکن بعدی	Next-token Prediction
Coreference	سند	خوشه‌های هم‌ارجاع	Clustering
ASR	گفتار	متن	Speech-to-Text
TTS	متن	گفتار	Speech Generation
Noise Suppression	صوت نویزی	صوت بهبودیافته	Speech Enhancement
VAD	صوت	بازه‌های دارای گفتار	Detection
Wake Word	صوت	تشخیص عبارت فعال‌ساز	Detection
Speech-to-Intent	گفتار	قصد کاربر	Classification
Speaker Recognition	صوت	هویت یا تطابق گوینده	Recognition / Verification
Speaker Diarization	صوت چندگوینده	بازه‌ها و گروه‌های گوینده	Diarization / Clustering
OCR	تصویر	متن	Text Recognition
VLM	تصویر و متن	پاسخ وابسته به وظیفه	Multimodal

نکات مهم برای مرور و امتحان

- سؤالات امتحانی بر اساس مطالب تخته‌اند؛ برای هر وظیفه ورودی، خروجی و نوع مسئله را بدانید (جدول بالا).
- تفاوت Pipeline و End-to-End از نظر دقت، انتشار خطا، استفادهٔ مجدد، تفسیرپذیری و هزینه.
- تعریف TP/FP/TN/FN، فرمول Precision، Recall، F1 و اینکه کدام در کدام کاربرد مهم‌تر است.
- سه کلاس NLI؛ تفاوت STS در حالت طبقه‌بندی و رگرسیون؛ POS در برابر نقش نحوی؛ قالب IOB.
- Intent (سطح جمله) در برابر Slot (سطح توکن)؛ نقش Annotation Guideline.
- تفاوت جریانی و غیرجریانی، Chunking و هم‌پوشانی؛ تفاوت VAD و Wake Word؛ تفاوت Speaker Recognition و Diarization.
- توانایی طراحی ماژول‌های یک محصول (مترجم، دستیار صوتی، e-KYC، خلاصه‌ساز جلسه) و دلیل استفاده از VAD، Wake Word و Speech-to-Intent برای صرفه‌جویی منابع.

فصل ۲

تصویر کلی علوم زبان و آواشناسی تولیدی

۱.۲ مرور جلسهٔ قبل و تغییر رویکرد

در جلسهٔ نخست مسئلهٔ پردازش زبان و گفتار را با رویکرد **بالابه‌پایین** (Top-Down) بررسی کردیم: ابتدا تسک‌های اصلی زبان (مانند POS Tagging، NER، Intent Detection، Slot Filling، Language Modeling و Coref-erence Resolution) و گفتار (مانند STT، TTS، Voice Activation، Speaker Recognition و Speaker Diarization) معرفی شدند و سپس دیدیم که چگونه این تسک‌ها در یک Pipeline کنار هم قرار می‌گیرند و محصولاتی مانند خلاصه‌ساز جلسات یا سامانهٔ احراز هویت آنلاین می‌سازند. در آن جلسه هنوز وارد جزئیات داده و مدل‌ها نشدیم.

از این جلسه مسیر را برعکس می‌کنیم و رویکرد **پایین‌به‌بالا** (Bottom-Up) را در پیش می‌گیریم:

۱. ابتدا خود **داده** را بشناسیم: داده‌ای که می‌خواهیم پردازش کنیم از چه جنسی است و چگونه به وجود می‌آید؟

۲. سپس به مفهوم **بازنمایی** (Representation) برسیم: چگونه داده را به شکلی درآوریم که کامپیوتر بتواند پردازش کند؟ این بازنمایی‌ها می‌توانند **دست‌ساز** (Handcrafted)، **یادگرفته‌شده** (Learned) یا **یادگرفته‌شده با خودنظارتی** (Learned Self-Supervised) باشند.

۳. در پایان، با داشتن داده و بازنمایی مناسب، به سراغ مدل‌های پیچیده‌تر و عمیق‌تر برویم.

۱.۱.۲ گفتار و متن: دو جنس متفاوت از داده

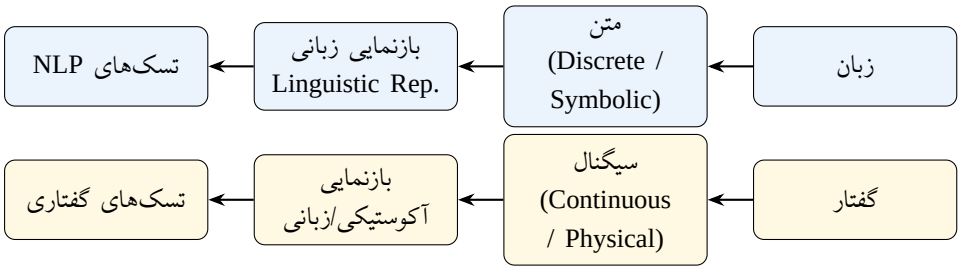
نکتهٔ کلیدی این است که جنس دادهٔ گفتاری و متنی یکسان نیست. متن دنباله‌ای از نمادهاست، اما گفتار یک پدیدهٔ فیزیکی است که در هوا منتشر می‌شود.

بر همین اساس، دو مسیر پردازش موازی داریم (شکل ۱.۲). در مسیر متن، زبان ابتدا به متن (دنبالهٔ نمادهای گسسته) تبدیل می‌شود، سپس بازنمایی زبانی از آن ساخته می‌شود و در نهایت تسک‌های NLP روی آن اجرا می‌گردند. در مسیر گفتار، موج صوتی ابتدا به‌شکل سیگنال دیجیتال درمی‌آید، سپس بازنمایی آکوستیکی یا زبانی از آن استخراج می‌شود و در نهایت تسک‌های گفتاری انجام می‌شوند.

بنابراین در این جلسه ابتدا روی ماهیت داده گفتاری تمرکز می‌کنیم: موج صوتی چیست، چگونه ایجاد می‌شود و انسان

جدول ۱.۲: مقایسهٔ ماهیت داده در متن و گفتار

گفتار (Speech)	**متن** (Text)
ماهیت فیزیکی دارد	ماهیت نمادین دارد
به‌صورت موج صوتی منتقل می‌شود	از نمادها و نشانه‌ها تشکیل شده است
در زمان پیوسته است	در سطح توالی نمادها گسسته است



شکل ۱.۲: دو مسیر موازی پردازش زبان: متن (گسسته و نمادین) و گفتار (پیوسته و فیزیکی). بازترسیم نمودار تخته (شکل افزوده)

چگونه صحبت می‌کند. پس از شناخت داده، گام بعدی (جلسات بعد) تبدیل آن به بازنمایی مناسب پردازش رایانه‌ای است.

۲.۲ تصویر کلی: جایگاه پردازش گفتار در علوم زبان

برای اینکه بدانیم این درس در کجای نقشهٔ علم قرار می‌گیرد، باید جایگاه **زبان‌شناسی** (Linguistics) را ببینیم. زبان‌شناسی در کنار علومی مانند فیزیک، ریاضی، روان‌شناسی و جامعه‌شناسی یکی از علوم مرتبط با موضوع ماست و خود شاخه‌های متعددی دارد (شکل ۲.۲).

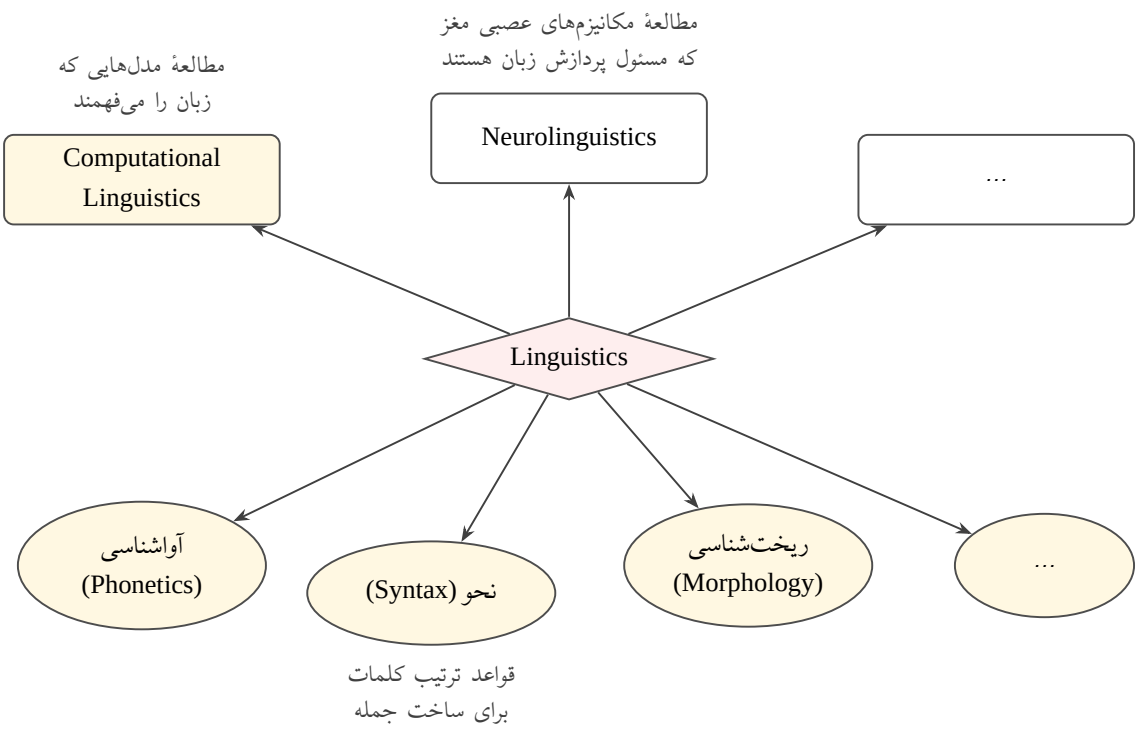
۱.۲.۲ شاخه‌های اصلی زبان‌شناسی

آواشناسی (Phonetics) مطالعهٔ صداهای گفتاری انسان: چگونه تولید می‌شوند، چه ویژگی‌های فیزیکی دارند و چگونه شنیده می‌شوند. این شاخه محور اصلی این جلسه و جلسات بعدی است.

نحو (Syntax) قواعد ترتیب و چینش کلمات برای ساختن جمله. در NLP بسیار با آن سروکار داریم.

ریخت‌شناسی یا صرف (Morphology) ساختار درونی کلمات و تغییر شکل آن‌ها. برای نمونه صرف فعل «رفتن» (رفتم، رفتی، رفت، رفتیم، ...) یا واژه‌سازی: «دانش» + «ـمند» ← «دانشمند» که در آن افزودن پسوند واژهٔ تازه‌ای می‌سازد.

شاخه‌های دیگر روی تخته با «...» نشان داده شده‌اند؛ مثلاً معناشناسی و کاربردشناسی.



شکل ۲.۲: نقشهٔ شاخه‌های زبان‌شناسی و علوم میان‌رشته‌ای مرتبط با آن. شاخه‌های درونی (بیضی‌ها) شامل آواشناسی، نحو و ریخت‌شناسی‌اند و علوم میان‌رشته‌ای (مستطیل‌ها) شامل زبان‌شناسی رایانشی و عصب‌زبان‌شناسی. (بازسازی‌شده از تختهٔ کلاس)

[محتوای افزوده] آواشناسی در برابر واج‌شناسی

آواشناسی (Phonetics) خود صداها را به‌صورت فیزیکی (تولید، انتقال، ادراک) بررسی می‌کند، در حالی که **واج‌شناسی** (Phonology) به نظام صداها در یک زبان می‌پردازد: کدام صداها در آن زبان معنا را تغییر می‌دهند و صداها چگونه کنار هم می‌نشینند. در این جلسه بیشتر با آواشناسی کار داریم؛ اما مفهوم «واج» که در ادامه می‌آید، از واج‌شناسی آمده است.

۲.۲.۲ علوم میان‌رشته‌ای

زبان‌شناسی رایانشی (Computational Linguistics) در تقاطع زبان‌شناسی، علوم کامپیوتر و هوش مصنوعی قرار دارد و به مدل‌سازی محاسباتی زبان (مدل‌هایی که زبان را پردازش، «می‌فهمند» یا تولید می‌کنند) می‌پردازد. درس ما، **پردازش زبان گفتاری** (Spoken Language Processing)، در همین چارچوب قرار می‌گیرد.

عصب‌زبان‌شناسی (Neurolinguistics) در تقاطع زبان‌شناسی و علوم اعصاب است و سازوکارهای عصبی مغز را که مسئول پردازش زبان‌اند مطالعه می‌کند.

نگاه مهندسی به زبان‌شناسی

هدف ما به‌عنوان مهندس هوش مصنوعی ارائهٔ نظریهٔ تازه در همهٔ شاخه‌های زبان‌شناسی نیست؛ مفاهیم و دسته‌بندی‌های موردنیاز را از این علوم می‌شناسیم و در ساخت مدل‌های محاسباتی از آن‌ها بهره می‌گیریم. (بخش‌های بعدی نشان می‌دهد این دانش چگونه به کار می‌آید.)

۳.۲ نظریهٔ زایشی چامسکی (۱۹۵۷)

یکی از مباحث مهم در تاریخ زبان‌شناسی که ارتباط نزدیکی با علوم شناختی و هوش مصنوعی دارد، **نظریهٔ زایشی** (Generative Theory) نوآم چامسکی است. تخته این نظریه را با سال ۱۹۵۷ نشان داده است. (چامسکی در همان سال کتاب Syntactic Structures را منتشر کرد.)

نظریهٔ زایشی چامسکی
۱۹۵۷

دیدگاه اولیه: یادگیری زبان از طریق تقلید و تکرار
رد این دیدگاه با نظریهٔ زایشی: جملات جدیدی که کودک می‌سازد؛ پس درون ذهن انسان مکانیسم‌هایی وجود دارد (کمک به شکل‌گیری علوم شناختی)

زبان خطی نیست، بلکه سلسله‌مراتبی و درختی است

انسان از بدو تولد قواعد زبانی جهان‌شمول Universal Grammar دارد و بعد از تولد، طبق محیط، پارامترها را تنظیم می‌کند.
یادگیری زبان به صورت آماری و توزیعی است: با قرارگیری در محیط و دیدن نمونه‌های زیاد، قواعد را یاد می‌گیرد.

شکل ۳.۲: خلاصهٔ نظریهٔ زایشی چامسکی: رد دیدگاه تقلیدی (سیاه)، ساختار سلسله‌مراتبی و درختی زبان (سبز) و دو دیدگاه دربارهٔ منشأ قواعد زبان (قرمز): دستور جهانی با تنظیم پارامترها، در برابر یادگیری آماری و توزیعی. (بازسازی‌شده از تختهٔ کلاس)

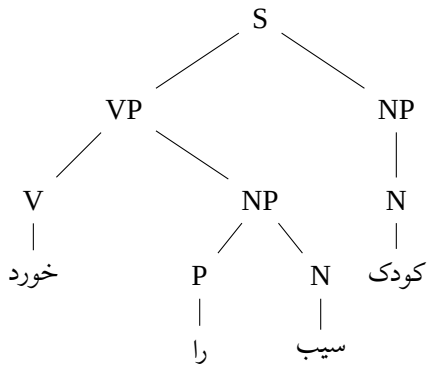
۱.۳.۲ دیدگاه تقلیدی و نقد آن

در دیدگاه قدیمی‌تر، یادگیری زبان عمدتاً حاصل **تقلید و تکرار** دانسته می‌شد: کودک جمله‌ای را از اطرافیان می‌شنود، حفظ می‌کند و در موقعیت مشابه آن را تکرار می‌کند. چامسکی این نگاه را با این استدلال رد کرد که کودکان به‌طور مرتب **جمله‌های جدیدی** می‌سازند که هرگز نشنیده‌اند؛ حتی کلمه‌های تازه می‌سازند یا کلمات را در ساختارهایی به کار می‌برند که پیش‌تر آن ترکیب را ندیده‌اند. پس توانایی زبانی چیزی بیش از حفظ جمله‌هاست و باید در ذهن انسان

سازوکارهایی وجود داشته باشد که جمله‌های تازه را «تولید» (generate) کند. همین ایده بعدها به شکل‌گیری علوم شناختی کمک کرد.

۲.۳.۲ زبان خطی نیست، سلسله‌مراتبی است

بر اساس این نظریه، جمله فقط دنبالهٔ خطی کلمات نیست، بلکه ساختاری **سلسله‌مراتبی** (Hierarchical) و درختی دارد (شکل ۴.۲). کلمات به گروه‌هایی (مانند گروه اسمی و گروه فعلی) سازمان می‌یابند و گروه‌ها در هم تو در تو می‌شوند.



شکل ۴.۲: نمونهٔ ساده‌شدهٔ درخت ساختار سلسله‌مراتبی برای جملهٔ «کودک سیب را خورد». S: جمله، NP: گروه اسمی، VP: گروه فعلی، N: اسم، V: فعل، P: حرف اضافه (نشانهٔ «را»). (شکل افزوده)

[محتوای افزوده] چرا ساختار درختی لازم است؟ دو مثال

- **ابهام ساختاری:** جملهٔ «مرد دختر را با دوربین دید» دو معنی دارد (دوربین در دست مرد است یا دختر دوربین دارد). کلمات یکی‌اند؛ تنها درخت تحلیل متفاوت است. دنبالهٔ خطی کلمات برای تمایز این دو کافی نیست.
- **جملهٔ معروف چامسکی:** "Colorless green ideas sleep furiously" از نظر دستوری درست اما بی‌معناست، و نشان می‌دهد درستیِ ساختار با احتمال کلمات یا معنا یکی نیست.

۳.۳.۲ دستور جهانی در برابر یادگیری آماری

پرسش اصلی این است: چه مقدار از توانایی زبانی از ابتدا در ذهن وجود دارد و چه مقدار از تجربه و داده یاد گرفته می‌شود؟ دو دیدگاه روی تخته آمده است:

۱. **دستور جهانی (دستور جهانی** (Universal Grammar)): انسان از بدو تولد صاحب اصول و قواعد زبانیِ جهان‌شمول است و پس از تولد، متناسب با محیط زبانی خود «پارامترها» را تنظیم می‌کند. کودکی که در محیط فارسی‌زبان رشد می‌کند فارسی و کودک انگلیسی‌زبان، انگلیسی را فرا می‌گیرد. (در کلاس این ایده با تنظیم پارامترهای یک مدل مقایسه شد: ساختار اولیه وجود دارد و تجربهٔ محیطی شکل نهایی عملکرد آن را تعیین می‌کند.)

۲. **یادگیری آماری و توزیعی (یادگیری توزیعی** (Distributional / Statistical Learning)): یادگیری زبان آماری است؛ انسان با قرارگرفتن در محیط و دیدن نمونه‌های بسیار، قواعد را از الگوهای آماری داده یاد می‌گیرد.

برای پرسش «اگر کودک از ابتدا ساختاری دارد، دقیقاً چه چیزی را می‌داند و چه چیزی را یاد می‌گیرد؟» مقایسه با یادگیری عمیق مفید است: در یک شبکهٔ عصبی، معماری از پیش تعیین شده، اما الگوها و روابط را از داده می‌آموزد. می‌توان پرسید آیا در انسان هم ساختار عصبی اولیه وجود دارد ولی قواعد خاص هر زبان از تجربه فرا گرفته می‌شود؟ نقدهایی که به تفسیر سخت‌گیرانهٔ دستور جهانی وارد می‌شود عبارت‌اند از:

- تفاوت‌های ساختاری میان زبان‌های مختلف؛
- شواهد یادگیری الگوهای جدید صرفاً از مواجهه با داده؛
- ابهام دربارهٔ اینکه دقیقاً کدام ویژگی‌های زبانی فطری‌اند.

جمع‌بندی کلاس: ایدهٔ زایشی و سلسله‌مراتبی‌بودن زبان همچنان اهمیت دارد، اما ادعای وجود مجموعه‌ای مشخص از قواعد دستوری مادرزادی محل بحث و نقد است. میزان فطری‌بودن زبان همچنان موضوعی پژوهشی و مورد اختلاف است.

دقت تاریخی و فنی دربارهٔ نظریهٔ چامسکی

- سال ۱۹۵۷ سال انتشار Syntactic Structures است که نحو صوری و زایشی را بنیان نهاد؛ هستهٔ استدلال علیه رویکرد «تقلیدی/رفتارگرا» (نقد چامسکی بر کتاب Verbal Behavior اسکینر) در سال ۱۹۵۹ منتشر شد. صورت‌بندی «اصول و پارامترها» که در تخته آمده، بعدتر (دههٔ ۱۹۸۰) پدید آمد؛ بنابراین بهتر است آن را بخشی از تحول بعدی نظریه بدانیم، نه محتوای دقیق مقالهٔ ۱۹۵۷.
- استدلال اصلی به نفع ساختار فطری معمولاً «فقر محرک» (Poverty of the Stimulus) خوانده می‌شود: داده‌ای که کودک می‌شنود برای تعیین یکتای قواعد کافی نیست. مخالفان (رویکردهای مبتنی بر کاربرد و یادگیری آماری) نشان می‌دهند کودکان و حتی نوزادان به الگوهای آماری گفتار حساس‌اند.
- دو دیدگاه الزاماً دو سر یک طیف‌اند، نه دو گزینهٔ کاملاً ناسازگار: بسیاری از پژوهشگران امروز بر ترکیبی از سوگیری‌های شناختی ذاتی و یادگیری از داده تأکید می‌کنند.

[محتوای افزوده] ارتباط با مدل‌های زبانی امروزی

مدل‌های زبانی بزرگ، که تنها از توزیع آماری متن آموخته می‌شوند، در عمل تا حد زیادی ساختارهای نحوی را بازتولید می‌کنند. این موضوع به مناظرهٔ دستور جهانی در برابر یادگیری توزیعی دامن زده است؛ اما اینکه این مدل‌ها «شبیه کودک» یاد می‌گیرند یا نه، پرسشی باز است (مقدار داده‌ای که مدل‌ها می‌بینند چندین مرتبه بیشتر از داده‌ای است که کودک دریافت می‌کند).

۴.۲ ورود به آواشناسی

آواشناسی (Phonetics) به مطالعهٔ صداهای گفتاری انسان می‌پردازد و دو بخش اصلی دارد:

آواشناسی تولیدی (Articulatory Phonetics) مطالعهٔ اینکه بدن انسان چگونه صدا می‌سازد؛ مثلاً برای تولید یک

صدای مشخص، لب‌ها، زبان، فک و تارهای صوتی چه کاری انجام می‌دهند. موضوع این جلسه است.

آواشناسی آکوستیکی (Acoustic Phonetics) بررسی خود موج صوتی و ویژگی‌های فیزیکی آن، بدون تمرکز بر اندام تولیدکننده. موضوع جلسهٔ بعد است.

هدف نهایی این است که پس از شناخت دادهٔ گفتاری، آن را به یک بازنمایی مناسب پردازش رایانه‌ای تبدیل کنیم.

۱.۴.۲ مثال آرتیکولاتور مکانیکی

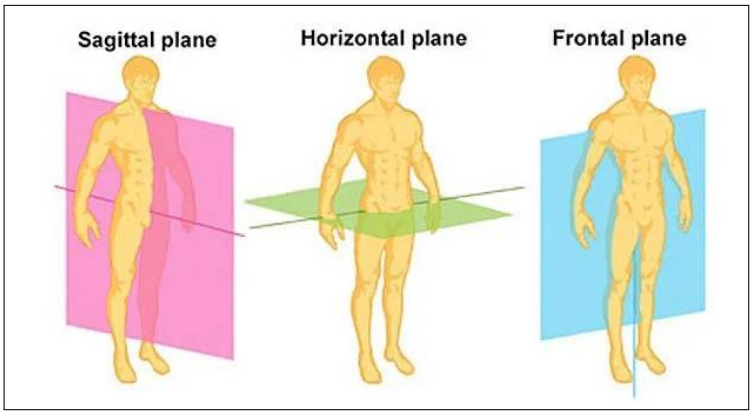
برای روشن‌شدن معنای واژهٔ articulation از دستگاه **آرتیکولاتور مکانیکی** (Articulator Mechanical) که در دندان‌پزشکی استفاده می‌شود مثال زده شد: این دستگاه حرکات فک و تماس دندان‌ها را شبیه‌سازی می‌کند و قالب دندان بیمار روی آن قرار می‌گیرد تا ببینند هنگام حرکت فک چه اتفاقی می‌افتد. در گفتار نیز **آرتیکولیشن** یعنی نحوهٔ حرکت و هماهنگی اندام‌های گفتاری برای ساختن صداها.

دقت در تشبیه

این مثال فقط برای ایجاد شهود دربارهٔ واژهٔ articulate (به‌معنای «مفصل‌بندی») و حرکت اجزای متصل به هم) است. در آواشناسی، articulators به خود اندام‌های متحرک (لب‌ها، زبان، فک، نرم‌کام و ...) گفته می‌شود و ربطی به دستگاه دندان‌پزشکی ندارد.



(آ) آرتیکولاتور مکانیکی



(ب) صفحات حرکتی بدن

شکل ۵.۲: آرتیکولاتور مکانیکی دندان‌پزشکی و سه صفحهٔ مرجع آناتومی. (برگرفته از تختهٔ کلاس)

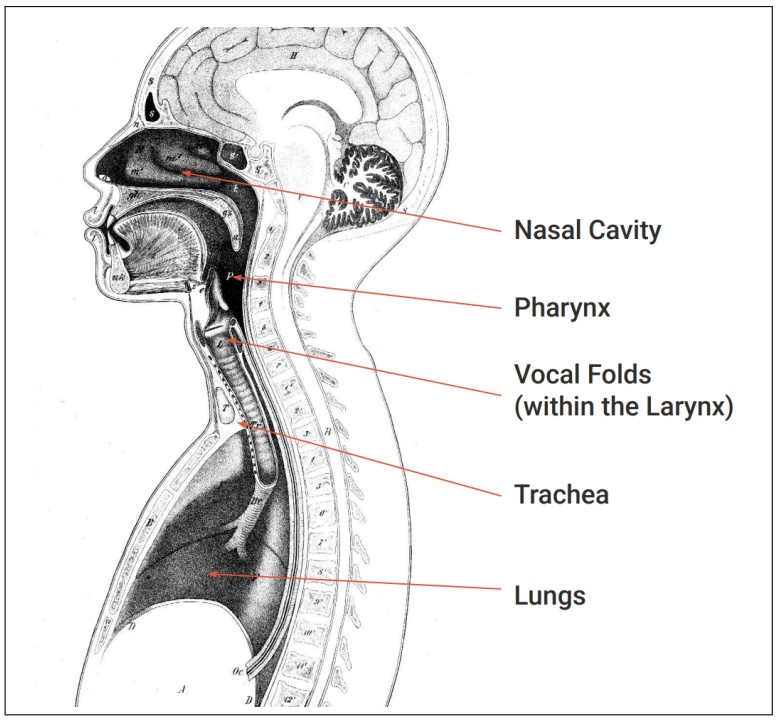
۵.۲ آناتومی تولید گفتار

۱.۵.۲ صفحات آناتومیکی

در آناتومی، بدن را با سه صفحهٔ مرجع از جهت‌های مختلف بررسی می‌کنند (شکل ۵.۲):

- **صفحهٔ ساجیتال** (Sagittal): بدن را به دو نیمهٔ چپ و راست تقسیم می‌کند (نمای از پهلو)؛
- **صفحهٔ فرونتال (پیشانی)** (Frontal / Coronal): بدن را به بخش جلویی و پشتی تقسیم می‌کند؛
- **صفحهٔ افقی** (Horizontal / Transverse): بدن را به بخش بالایی و پایینی تقسیم می‌کند.

برای مطالعهٔ حنجره، نای، دهان و مسیر عبور هوا، **نمای ساجیتال** بیشترین کاربرد را دارد، چون همهٔ این اجزا از پهلو در یک برش دیده می‌شوند (شکل ۶.۲).



شکل ۶.۲: برش ساجیتال مجرای صوتی: حفرهٔ بینی، حلق، تارهای صوتی (درون حنجره)، نای و ریه‌ها. (برگرفته از تختهٔ کلاس)

۲.۵.۲ اندام‌های اصلی

روی تخته تأکید شد که تارهای صوتی **زیر حلق** و در ابتدای نای، درون حنجره قرار دارند.

[محتوای افزوده] سه زیرسامانهٔ تولید گفتار

می‌توان اندام‌های بالا را در سه گروه دید: (۱) **سامانهٔ تنفسی** (ریه، دیافراگم، نای) که انرژی و فشار هوا را فراهم می‌کند؛ (۲) **حنجره** که با ارتعاش تارهای صوتی «منبع صدا» را می‌سازد؛ (۳) **مجرای صوتی** (حلق، دهان و بینی) که با شکل‌های مختلف خود صدای منبع را فیلتر و شکل‌دهی می‌کند. این تصویر ساده‌ترین شکل مدل «منبع-فیلتر» است که در جلسهٔ بعد، هنگام بررسی فرمنت‌ها، به آن برمی‌گردیم.

جدول ۲.۲: اندام‌های اصلی دخیل در تولید گفتار

اندام	معادل انگلیسی	نقش
ریه‌ها	Lungs	منبع جریان هوا (تأمین فشار)
دیافراگم	Diaphragm	ماهیچهٔ اصلی دم؛ کمک به تنفس
نای	Trachea	مسیر عبور هوا از ریه به حنجره
حنجره	Larynx	محل قرارگیری تارهای صوتی
تارهای صوتی	Vocal Folds	تولید صوت واک‌دار از راه ارتعاش
حلق	Pharynx	بخشی از مجرای صوتی بالای حنجره
حفرهٔ بینی (پشت بینی)	Nasal Cavity	مشارکت در تولید صداهای خیشومی
دهان، زبان، لب‌ها، فک، دندان‌ها	Oral Articulators	شکل‌دهی و تمایز صداهای گفتاری

۳.۵.۲ دم و بازدم و ارتباط آن با گفتار

تنفس در اصل برای ادامهٔ حیات است: با دم، هوا به ریه‌ها وارد می‌شود تا اکسیژن لازم تأمین شود و با بازدم، دی‌اکسیدکربن خارج می‌گردد. اما انسان از همین سامانه برای ساخت گفتار هم استفاده می‌کند.

دم (Inhalation) دیافراگم منقبض می‌شود و به‌سمت پایین می‌رود. حجم قفسهٔ سینه زیاد و فشار درون ریه کم می‌شود و هوا به ریه می‌آید. تارهای صوتی در تنفس معمولی باز (از هم دور) هستند تا هوا با کم‌ترین مقاومت عبور کند.

بازدم (Exhalation) دیافراگم به حالت استراحت برمی‌گردد و هوا از ریه‌ها خارج می‌شود. این جریان هوا را می‌توان به‌عنوان «منبع انرژی» برای گفتار به کار گرفت: در گفتار واک‌دار هوا هنگام عبور از حنجره تارهای صوتی را به ارتعاش درمی‌آورد و صدای حاصل در بخش‌های بالاتر مجرا شکل می‌گیرد. (در تخته: «دیافراگم در دم فعال است و در بازدم ریلکس.»)

دقت دربارهٔ بازدم در هنگام گفتار

«دیافراگم در بازدم ریلکس است» دربارهٔ تنفس آرام درست است، اما در **گفتار** بازدم کاملاً منفعل نیست. اگر ریه فقط به‌حال خود رها شود، فشار هوا هنگام پر بودن ریه زیاد و هنگام خالی‌شدن آن کم می‌شود. برای اینکه فشار زیر حنجره در طول جمله تقریباً ثابت بماند (حدود ۵ تا ۱۰ سانتی‌متر آب برای گفتار معمولی)، سامانهٔ عصبی-عضلانی دائماً مداخله می‌کند: در ابتدای جمله عضلات دمی بازدم را «ترمز» می‌کنند و در انتها عضلات بازدمی (مانند بین‌دنده‌ای‌های داخلی و شکمی) هوا را به بیرون می‌رانند. به همین دلیل مکث‌های گفتار معمولاً با دم‌های کوتاه و سریع و بازدم‌های بلند و کنترل‌شده همراه است.

پرسش کلاسی: اگر هوا هنگام دم هم از تارهای صوتی می‌گذرد، چرا معمولاً هنگام بازدم صحبت می‌کنیم؟
جمع‌بندی بحث چنین است:

- در دم آرام تارهای صوتی باز هستند و هوا بدون ارتعاش از بین آن‌ها می‌گذرد؛ برای تولید صدای واک‌دار باید تارها به هم نزدیک شوند و در معرض جریان هوا با فشار کافی قرار گیرند.

- گفتار هنگام دم غیرممکن نیست: برخی افراد (و در برخی آوازها و تمرین‌های صوتی) می‌توانند در دم هم صدا یا گفتار تولید کنند، و گاهی در گفتار محاوره‌ای برخی زبان‌ها واژه‌هایی کوتاه (مانند «بله») با هوای دمی ادا می‌شوند. اما الگوی غالب گفتار در همهٔ زبان‌ها استفاده از هوای بازدمی است.

[محتوای افزوده] چرا بازدم؟

دلیل‌های عملی ترجیح بازدم عبارت‌اند از: (۱) در بازدم می‌توان فشار هوا را برای مدت طولانی و با دقت کنترل کرد، در حالی که دم باید کوتاه و سریع باشد تا گفتار قطع نشود؛ (۲) ریه‌ها به‌طور طبیعی با بازگشت ارتجاعی هوا را بیرون می‌دهند، پس منبع فشار آمادهٔ بازدم وجود دارد، ولی در دم باید با کار ماهیچه‌ای هوا را به درون کشید. صدای تولیدشده در دم معمولاً ضعیف‌تر و کم‌کنترل‌تر است. این‌ها توضیح‌های تکمیلی‌اند، نه تمام ماجرا.

۴.۵.۲ نای: چرا حلقه‌حلقه است؟

نای (Trachea) لولهٔ حدود ۱۰ تا ۱۲ سانتی‌متری است که هوا را از حنجره به ریه‌ها می‌برد. دیوارهٔ آن **حلقه‌های غضروفی** (حدود ۱۶ تا ۲۰ حلقه‌ی C-شکل) دارد. این ساختار دو نقش دارد:

۱. **باز نگه‌داشتن مجرا:** هنگام دم فشار درون نای کمتر از فشار بیرون آن می‌شود. اگر دیواره نرم و بدون ساختار نگه‌دارنده بود، مانند یک نی نرم که هنگام مکیدن پهن می‌شود، تحت اختلاف فشار روی هم می‌خوابید و مسیر هوا بسته می‌شد.

۲. **انعطاف‌پذیری:** با اینکه لوله باز نگه داشته می‌شود، فاصلهٔ میان حلقه‌ها به نای (و گردن) اجازهٔ خم‌شدن، کشیده‌شدن و حرکت می‌دهد.

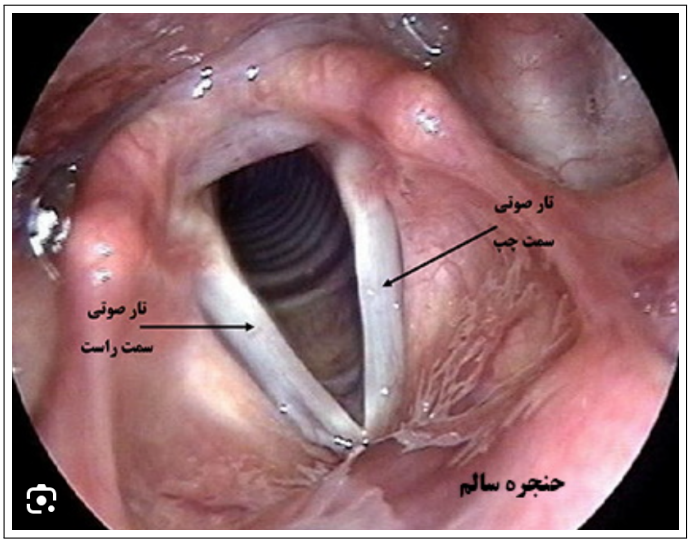
بنابراین نای باید **همیشه باز** بماند؛ برخلاف تارهای صوتی که قرار است مرتب باز و بسته شوند.

[محتوای افزوده] جزئیات تکمیلی درباره‌ٔ نای

حلقه‌های غضروفی کامل نیستند و در دیوارهٔ پشتی که به مری چسبیده، به‌شکل «C» باز می‌مانند و این بخش را یک ماهیچهٔ صاف و غشای نرم می‌پوشاند. این طراحی به مری اجازه می‌دهد هنگام بلع غذا کمی به‌سمت نای برآمده شود.

۶.۲ حنجره و تارهای صوتی

هوای خروجی ریه‌ها هنگام بازدم به حنجره می‌رسد. در حنجره جفت **تار صوتی** (Vocal Folds) قرار دارد که می‌تواند به هم نزدیک یا از هم دور شود (شکل ۷.۲). فضای میان دو تار **چاکنای** (Glottis) نام دارد. در تنفس آرام این فاصله باز است و هنگام تولید صدای واک‌دار تارها به هم نزدیک می‌شوند و وارد چرخهٔ ارتعاش می‌شوند.



شکل ۷.۲: نمای افقی (از بالا) از حنجرهٔ سالم با دوربین درون‌بین. دو تار صوتی (راست و چپ) و فاصلهٔ باز میان آن‌ها (چاکنای) دیده می‌شود؛ درون فضای تیره حلقه‌های نای قابل مشاهده است. (برگرفته از تختهٔ کلاس)

«تار» یا «چین»؟

واژهٔ رایج «تارهای صوتی» ترجمهٔ تحت‌اللفظی vocal cords است و تصویر نادرستی از رشته یا سیم کشیده‌شده می‌دهد. اصطلاح علمی امروزی vocal folds (چین‌های صوتی) است: هر تار صوتی توده‌ای از بافت ماهیچه‌ای و مخاطی است که در دو طرف مجرای حنجره از جلو (غضروف تیروئید) تا پشت (غضروف‌های آریتنوئید) امتداد دارد و با چرخش غضروف‌های آریتنوئید به هم نزدیک یا از هم دور می‌شود. در این جزوه، به‌دلیل رواج، همان «تارهای صوتی» را به کار می‌بریم. طول تارها در مردان بزرگسال حدود ۱۷ تا ۲۵ و در زنان حدود ۱۲ تا ۱۷ میلی‌متر است.

۱.۶.۲ چرا تارها فقط یک بار باز نمی‌شوند؟ اصل برنولی

پرسش: وقتی هوا از ریه‌ها بیرون می‌آید و از میان تارها می‌گذرد، چرا تارها یک بار باز نمی‌شوند و همان‌طور باز نمی‌مانند؟ چرا مرتب باز و بسته می‌شوند؟

برای پاسخ، **اصل برنولی** (Bernoulli's Principle) مطرح شد: در یک سیال در حال جریان، هرجا سرعت زیادتر باشد، فشار (ایستا) کمتر است. روی تخته: «شاره‌ای که سریع‌تر حرکت می‌کند فشار کمتری خواهد داشت.»

اصل برنولی

برای جریان پایا، تراکم‌ناپذیر و بدون اصطکاک در امتداد یک خط جریان:

$$p + \tfrac{1}{2}\rho v^2 + \rho g h = \text{ثابت}$$

که p فشار ایستا، ρ چگالی سیال، v سرعت و h ارتفاع است. در ارتفاع ثابت، افزایش سرعت (v) به‌معنای کاهش فشار ایستا (p) است.

آزمایش دو بطری. اگر دو بطری سبک (خالی) را نزدیک هم بگذاریم و میان آن‌ها هوا بدمیم، برخلاف انتظار اولیه، بطری‌ها از هم دور نمی‌شوند بلکه به هم نزدیک می‌شوند. دلیل این است که سرعت هوا در فاصلهٔ میان بطری‌ها زیاد می‌شود، فشار آن ناحیه از فشار محیط بیرون کمتر می‌شود و اختلاف فشار بطری‌ها را به هم نزدیک می‌کند.

ارتباط با تارهای صوتی. روایت ساده‌شدهٔ کلاس از چرخهٔ ارتعاش:

۱. تارها نزدیک هم‌اند و مجرا بسته است؛ فشار هوای زیر تارها بالا می‌رود.

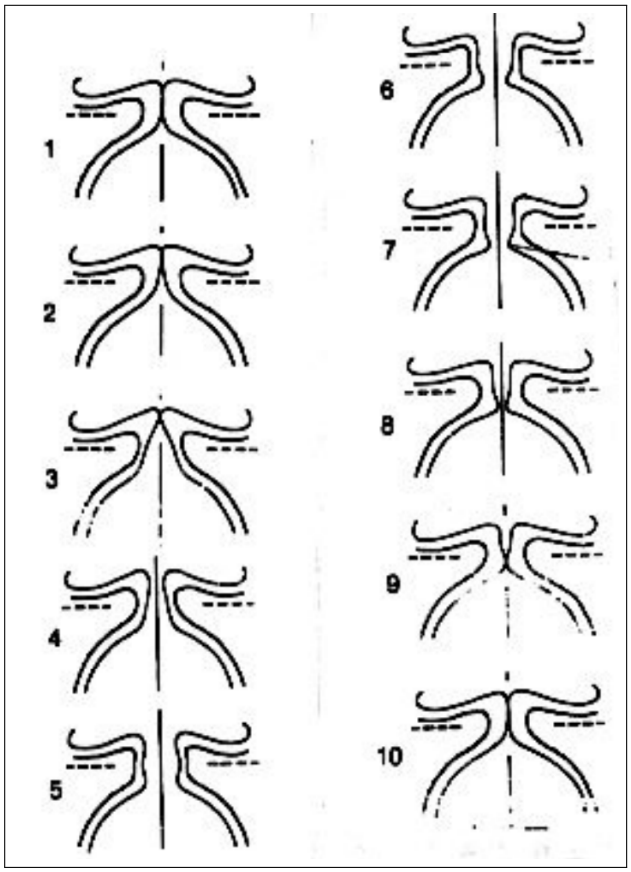
۲. فشار زیر حنجره از حدی بیشتر می‌شود و تارها را از هم باز می‌کند.

۳. هوا با سرعت زیاد از شکاف باریک میان تارها عبور می‌کند.

۴. طبق اصل برنولی فشار در شکاف کم می‌شود و همراه با نیروی ارتجاعی بافت، تارها دوباره به هم نزدیک می‌شوند و مجرا بسته می‌شود.

۵. چرخه تکرار می‌شود و ارتعاش دوره‌ای هوا موج صوتی می‌سازد.

از آنجا که این حرکت تکرارشونده است، می‌توان برای آن **فرکانس** تعریف کرد؛ همان **فرکانس پایه** (Fundamental Frequency, F0) که به‌صورت زیر یا بم‌بودن صدا ادراک می‌شود.



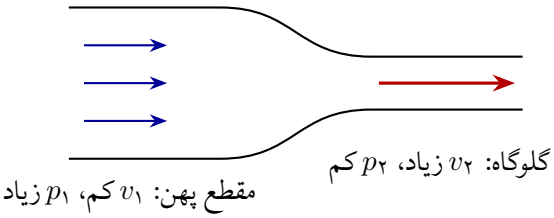
شکل ۸.۲: ده برش پیشانی (کرونال) متوالی از حنجره در یک چرخهٔ ارتعاش، از بسته‌بودن کامل تارها تا بازشدن و دوباره بسته‌شدن. دیده می‌شود که لبهٔ پایینی تارها زودتر از لبهٔ بالایی از هم جدا و زودتر به هم نزدیک می‌شود. (برگرفته از تختهٔ کلاس)

اصل برنولی تنها توضیح ارتعاش نیست

توضیح کلاس مدلی ساده‌شده بود. نظریهٔ پذیرفته‌شده برای تولید صدا **نظریهٔ ماهیچه‌ای-ارتجاعی-آیرودینامیکی** (Myoelastic-Aerodynamic Theory) است (ون دن‌برگ، ۱۹۵۸). بر اساس آن:

- ماهیچه‌های حنجره تارها را به هم نزدیک و کشش لازم را فراهم می‌کنند (*myo*). مادامی که تارها بسته‌اند، فشار زیر چاکنا بالا می‌رود.
- فشار زیرحنجره‌ای تارها را از هم باز می‌کند و هوا می‌گذرد (*aerodynamic*).
- نیروی ارتجاعی (بازگشتی) بافت تارها و نیروی کاهش فشار ناشی از افزایش سرعت جریان (اثر برنولی) و نیز کاهش فشار پایین‌دست آن‌ها را دوباره می‌بندد (*elastic*).

اثر برنولی تنها یکی از نیروهای دخیل است. برای تداوم ارتعاش هم لازم است در هر چرخه انرژی از جریان هوا به بافت منتقل شود؛ این کار با تفاوت فاز میان لبهٔ پایینی و بالایی تارها (شکل ۸.۲) و تغییر شکل شکاف از همگرا به واگرا انجام می‌شود.



شکل ۹.۲: نمایش ساده‌شدهٔ اصل برنولی: در گلوگاه سرعت جریان افزایش و فشار ایستا کاهش می‌یابد؛ شکاف باریک میان تارهای صوتی نقش این گلوگاه را دارد. (شکل افزوده)

۲.۶.۲ فرکانس ارتعاش و موج حنجره‌ای

در هر چرخه، تارها یک بار باز و یک بار بسته می‌شوند و در نتیجه هوا به‌صورت پالس‌های متناوب وارد مجرای صوتی می‌شود (شکل ۱۰.۲). تعداد چرخه‌ها در هر ثانیه همان F_0 است و دورهٔ تناوب آن $T_0 = ۱/F_0$.

[محتوای افزوده] مثال عددی: گلوگاه برنولی و فرکانس پایه

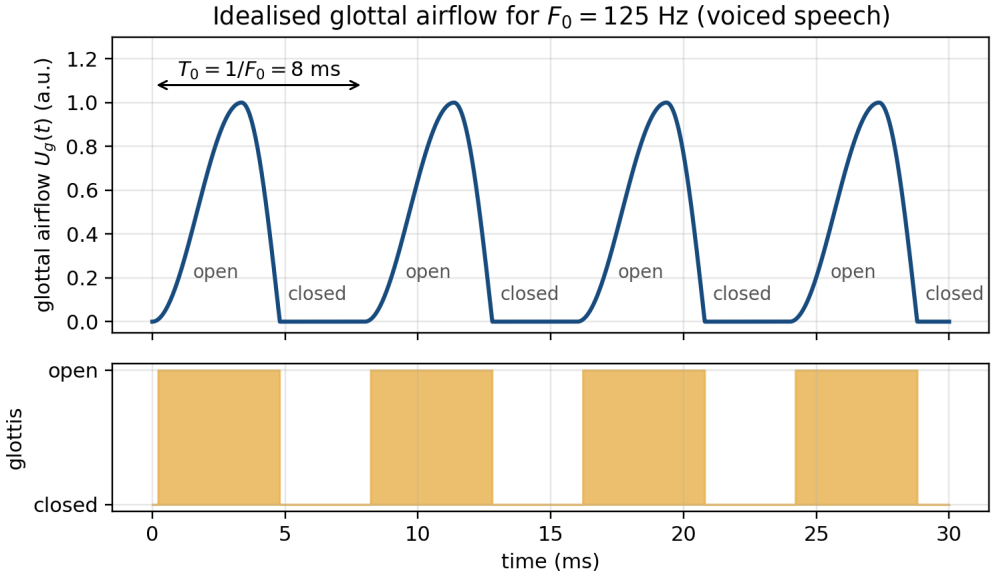
(الف) فشار در شکاف. فرض کنید جریان هوای $۲۰۰\ \mathrm{cm^۳/s}$ از نای با سطح مقطع $۲٫۵\ \mathrm{cm^۲}$ به چاکنایی با سطح مقطع $۰٫۱\ \mathrm{cm^۲}$ می‌رسد. سرعت‌ها:

$$v_۱ = \frac{۲۰۰}{۲٫۵} = ۸۰\ \mathrm{cm/s} = ۰٫۸\ \mathrm{m/s}, \qquad v_۲ = \frac{۲۰۰}{۰٫۱} = ۲۰۰۰\ \mathrm{cm/s} = ۲۰\ \mathrm{m/s}.$$

با چگالی هوا $\rho \approx ۱٫۲\ \mathrm{kg/m^۳}$:

$$p_۱ - p_۲ = \tfrac{۱}{۲}\rho\,(v_۲^۲ - v_۱^۲) \approx ۰٫۵ \times ۱٫۲ \times (۴۰۰ - ۰٫۶۴) \approx ۲۴۰\ \mathrm{Pa} \approx ۲٫۴\ \mathrm{cmH_۲O}.$$

یعنی فشار در شکاف حدود ۲۴۰ پاسکال کمتر از فشار در نای است؛ مقداری قابل توجه در مقایسه با فشار زیرحنجره‌ای ۵۰۰ تا ۱۰۰۰ پاسکال (اعداد تقریبی و صرفاً برای نشان‌دادن مرتبهٔ بزرگی).



شکل ۱۰.۲: شکل ایده‌آل‌شدهٔ جریان هوای عبوری از چاکنای برای صدایی با $F_0 = ۱۲۵$ هرتز؛ تارها در هر ۸ میلی‌ثانیه یک بار باز و بسته می‌شوند. (شکل افزوده)

(ب) دوره تناوب. صدای مردانه با $F_0 \approx ۱۰۰$ هرتز: $T_0 = ۱۰$ میلی‌ثانیه؛ صدای زنانه با $F_0 \approx ۲۰۰$ هرتز: $T_0 = ۵$ میلی‌ثانیه؛ صدای کودک با $F_0 \approx ۳۰۰$ هرتز: $T_0 \approx ۳/۳$ میلی‌ثانیه. برای $F_0 = ۱۲۵$ هرتز در شکل بالا $T_0 = ۱/۱۲۵ = ۸$ میلی‌ثانیه است. به‌طور تقریبی، F_0 مردان بزرگسال ۸۵ تا ۱۸۰ و زنان ۱۶۵ تا ۲۵۵ هرتز است؛ تارهای کوتاه‌تر و نازک‌تر، فرکانس بالاتری دارند.

۷.۲ زنجیرهٔ گفتار

تا اینجا بخش فیزیکی تولید صدا را دیدیم. اما یک پرسش مهم باقی است: یک مفهوم ذهنی چگونه به فرمان عضلانی، صدا و در نهایت جمله‌ای قابل‌فهم برای مخاطب تبدیل می‌شود؟ مدل **زنجیرهٔ گفتار** (Speech Chain) (دنس و پینسون، ۱۹۶۳) این مسیر را از مغز گوینده تا مغز شنونده توصیف می‌کند (شکل ۱۱.۲ و ۱۲.۲).

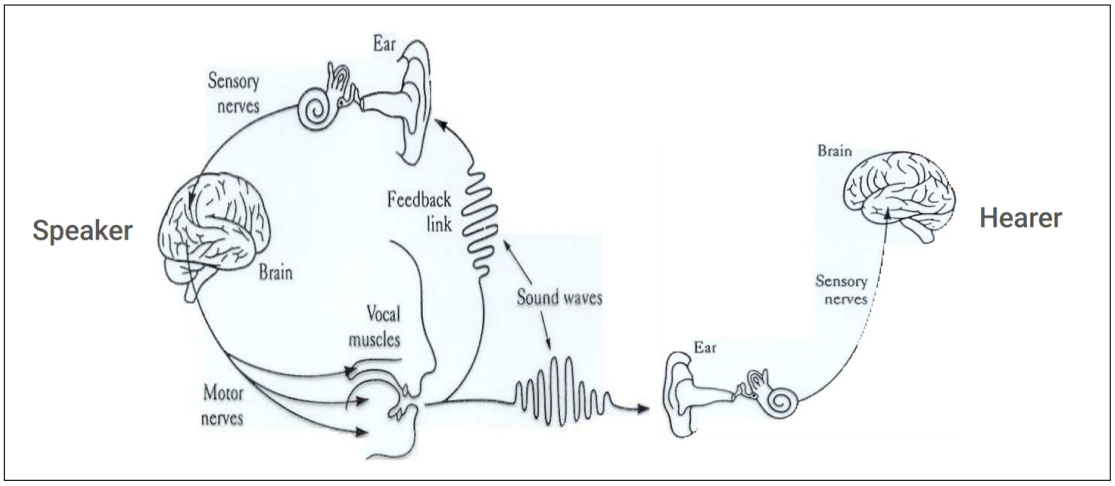
۱.۷.۲ مراحل زنجیره

۱. **مغز گوینده:** شکل‌گیری مفهوم و قصد بیان آن.

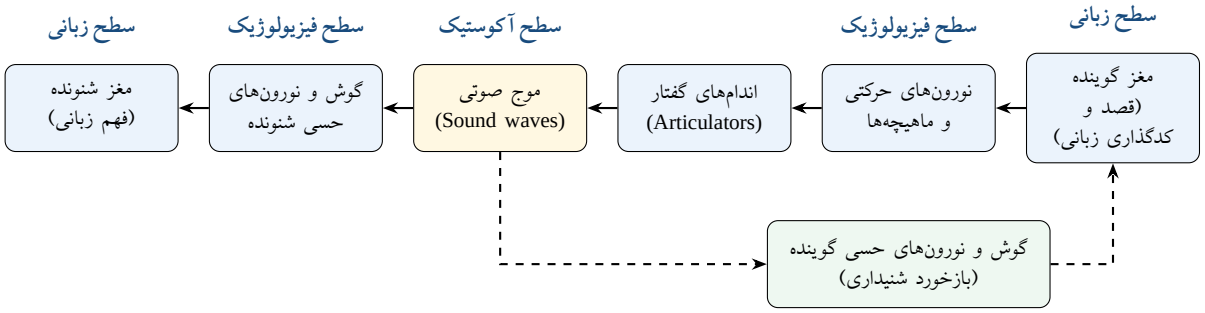
۲. **نورون‌های حرکتی (نورون حرکتی** (Motor Neuron)**):** ارسال فرمان به ماهیچه‌ها؛ این نورون‌ها «هدایت و کنترل ماهیچه‌ها» را بر عهده دارند.

۳. **اندام‌های گفتار:** حرکت هماهنگ زبان، لب‌ها، فک، نرم‌کام، حنجره و دیگر اندام‌ها برای شکل‌دادن به جریان هوا.

۴. **موج صوتی:** انتقال گفتار در محیط (هوا).



شکل ۱۱.۲: زنجیرهٔ گفتار: مغز گوینده، اعصاب حرکتی، ماهیچه‌های صوتی، موج صوتی، گوش و اعصاب حسی شنونده، و پیوند بازخورد شنیداری برای خود گوینده. (برگرفته از تختهٔ کلاس)



شکل ۱۲.۲: بازترسیم زنجیرهٔ گفتار با سه سطح زبانی، فیزیولوژیک و آکوستیک. فلش‌های خط‌چین: بازخورد شنیداری گوینده. (شکل افزوده)

۵. **گوش و نورون‌های حسی شنونده (نورون حسی** (Sensory Neuron)): تبدیل محرک خارجی (ارتعاش هوا) به جریان داخلی (سیگنال عصبی) و ارسال آن به مغز.

۶. **مغز شنونده:** ادراک و فهم پیام.

افزون بر این، **خود گوینده هم صدای خود را می‌شنود**؛ پس یک حلقهٔ **بازخورد** (Feedback) شنیداری وجود دارد که مغز می‌تواند از آن برای کنترل و اصلاح گفتار استفاده کند.

۲.۷.۲ نمونه: ادای کلمهٔ «سیب» و تشبیه به پیانو

فرض کنید می‌خواهیم کلمهٔ «سیب» را بگوییم. مفهوم این کلمه در ذهن ماست و تصمیم می‌گیریم آن را بیان کنیم؛ نورون‌های حرکتی فرمان‌هایی به ماهیچه‌ها می‌فرستند تا زبان، لب‌ها و دیگر اندام‌ها در هر لحظه در وضعیت درست قرار گیرند. در کلاس این کار به نواختن پیانو تشبیه شد (فشردن کلیدهای مختلف با انگشتان). اما این تشبیه محدودیتی دارد.

۳.۷.۲ هم‌تولیدی (Coarticulation)

حرکات اندام‌های گفتاری مثل نواختن نت‌های پیانو مرحله‌ای و جدا از هم نیست؛ هنگام گفتن «سیب» هر واج را مستقل تولید نمی‌کنیم و سپس سراغ واج بعدی برویم. حرکات واج‌های مجاور تا حدی **هم‌پوشانی** دارند: هنگام تولید یک واج، اندام‌ها از همان لحظه برای تولید واج بعدی آماده می‌شوند. این پدیده **هم‌تولیدی** (Coarticulation) نام دارد.

[محتوای افزوده] مثال از هم‌تولیدی

در «سو» (/su/) لب‌ها از همان لحظهٔ تولید /s/ گرد می‌شوند، چون واکهٔ بعدی گرد است، ولی در «سی» (/si/) لب‌ها کشیده‌اند. در نتیجه صدای /s/ در این دو کلمه از نظر آکوستیکی اندکی تفاوت دارد. همین علت است که مدل‌های دقیق تشخیص گفتار سنتی به‌جای واج منفرد از واج‌های وابسته به بافت (مانند triphone) استفاده می‌کردند.

اهمیت هم‌تولیدی در پردازش گفتار

گفتار فرایندی پیوسته و هماهنگ است، نه توالی حرکات کاملاً مجزا. بنابراین نمی‌توان فرض کرد که در سیگنال صوتی همهٔ واج‌ها مرزهای کاملاً مشخص و مستقل دارند.

۸.۲ واج، همخوان، واکه و هجا

واج

واج (Phoneme) یکی از کوچک‌ترین واحدهای تمایزدهندهٔ معنایی در نظام آوایی یک زبان است؛ یعنی اگر در یک واژه یک واج را با واج دیگر جایگزین کنیم، ممکن است معنی تغییر کند. مثال: «بار» و «پار» فقط در واج آغازین (/b/ و /p/) تفاوت دارند و دو کلمهٔ متفاوت‌اند؛ همین‌طور «سیر» و «زیر» (/s/ و /z/). چنین جفت‌هایی **جفت کمینه** (Minimal Pair) نام دارند.

واج‌ها به دو دستهٔ اصلی تقسیم می‌شوند: **همخوان (صامت)** (Consonant) و **واکه (مصوت)** (Vowel). با کنار هم قرار گرفتن واج‌ها، واحدهای بزرگ‌تر یعنی هجا و سپس کلمه ساخته می‌شود.

[محتوای افزوده] واج و آوا

خود صدای فیزیکی که تولید می‌شود **آوا** (Phone) نام دارد و واج یک رده یا «برچسب» انتزاعی برای مجموعه‌ای از آواهای معادل است. برای نمونه، /k/ در «کار» و /k/ در «کیف» در فارسی با نقطهٔ تماس اندکی متفاوت تلفظ می‌شوند، اما برای گویشور یک واج‌اند.

۱.۸.۲ هجا

هجا (Syllable) واحدی است که از ترکیب واج‌ها ساخته می‌شود و حول یک واکه (هستهٔ هجا) سازمان می‌یابد. برای نمایش الگوی هجا از نمادهای C (Consonant) و V (Vowel) استفاده می‌شود. مثلاً «کتاب» دو هجا دارد: «کِ» (CV) و «تاب» (CVC).

[محتوای افزوده] ساختار هجا در فارسی

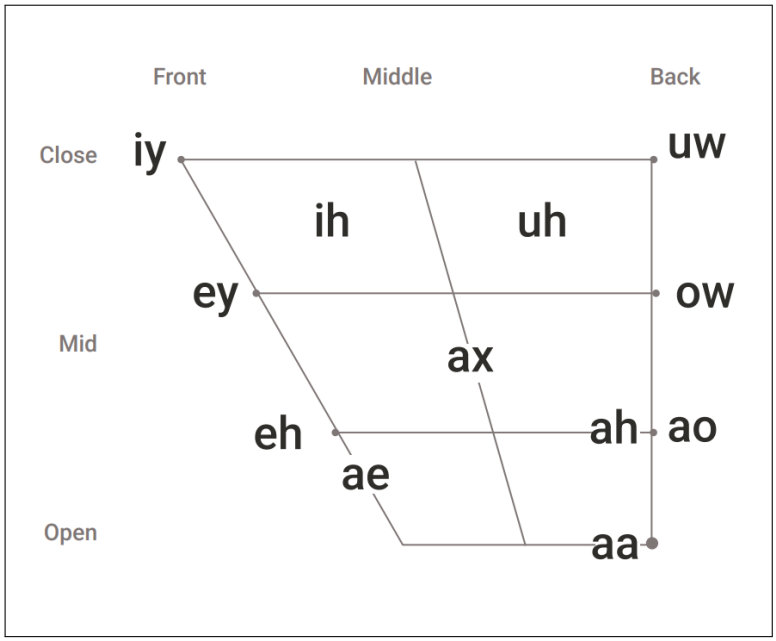
در فارسی معیار هجا همیشه با همخوان آغاز می‌شود (اگر واژه با واکه شروع شود، یک همزهٔ چاکنایی /ʔ/ در آغاز تلفظ می‌شود) و سه الگوی CV، CVC و CVCC را داریم؛ مانند «نِ» (CV)، «نان» (CVC) و «دوست» (CVCC).

۹.۲ واکه‌ها و نقشهٔ جایگاه زبان

برای تولید هر واکه، زبان (و فک و لب‌ها) در موقعیت مشخصی از فضای دهان قرار می‌گیرد. این موقعیت‌ها را در نمودار **نقشهٔ واکه‌ها** (Vowel Chart) نمایش می‌دهند (شکل ۱۳.۲). دو بُعد اصلی عبارت‌اند از:

۱. **جلو یا عقب بودن زبان** (Front / Central / Back)؛

۲. **ارتفاع زبان** (بالا-میانه-پایین؛ High / Mid / Low) که در نمودار با واژه‌های بسته-میانه-باز (Close / Mid / Open) هم نشان داده می‌شود.



شکل ۱۳.۲: نقشهٔ جایگاه زبان برای واکه‌های انگلیسی (۱۲ واکه) با نمادهای ARPAbet. محور افقی: جلو، میانه و عقب؛ محور عمودی: بسته (بالا)، میانه و باز (پایین). (برگرفته از تختهٔ کلاس)

تعداد و نوع واکه‌ها از زبانی به زبان دیگر فرق می‌کند. نمودار انگلیسی کلاس ۱۲ واکه دارد، در حالی که در **فارسی معیار شش واکهٔ اصلی** در نظر می‌گیریم؛ پس نقشهٔ واکه‌های فارسی با نقشهٔ انگلیسی یا زبان‌های دیگر متفاوت است. همچنین ممکن است در تلفظ گویندگان مختلف تفاوت‌های جزئی دیده شود.

نمادهای نمودار واکه و مفهوم «بالا»

- نمادهای روی نمودار انگلیسی نمادهای **آرپابت** (ARPAbet) هستند که در پردازش گفتار پرکاربردند، نه الفبای آوایی بین‌المللی (IPA). معادل‌ها در جدول زیر آمده است.
- ey و ow در واقع واکهٔ مرکب (دوتایی) هستند و در نمودار در جایگاه نقطهٔ آغازشان ترسیم شده‌اند.
- «بسته/بالا» یعنی زبان به سقف دهان نزدیک است و فک تقریباً بسته؛ «باز/پایین» یعنی زبان پایین و فک باز است.

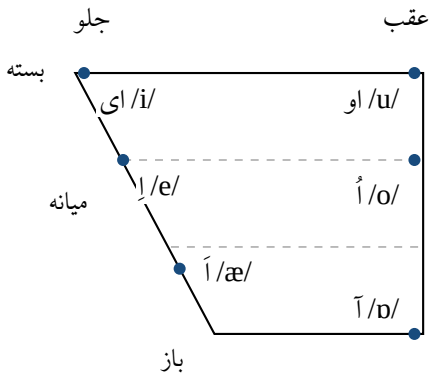
ARPAbet	iy	ih	ey	eh	ae	aa	ao	ah	ax	uh	uw	ow
IPA	i	ɪ	eɪ	ɛ	æ	ɑ	ɔ	ʌ	ə	ʊ	u	oʊ

۱.۹.۲ واکه‌های فارسی

شش واکهٔ فارسی در جدول زیر آمده‌اند. (جایگاه‌ها تقریبی‌اند و به لهجه و گوینده بستگی دارند.)

جدول ۳.۲: واکه‌های فارسی معیار و جایگاه تقریبی زبان

واکه	نماد IPA	نمونه	جلو/عقب	ارتفاع زبان
ای	/i/	دیر	جلو	بالا (بسته)
اِ	/e/	دل	جلو	میانه
اَ	/æ/	در	جلو	پایین (باز)
آ	/ɒ/ یا /ɑ/	آب	عقب	پایین (باز)
اُ	/o/	گل	عقب	میانه
او	/u/	دور	عقب	بالا (بسته)



شکل ۱۴.۲: نقشهٔ تقریبی واکه‌های فارسی روی ذوزنقهٔ واکه‌ها (جلو در سمت چپ، مطابق قرارداد IPA). (شکل افزوده)

تمرین کلاسی: رسم نقشهٔ واکه‌های فارسی

با توجه به جایگاه زبان هنگام تلفظ، جایگاه شش واکهٔ فارسی را روی نمودار واکه‌ها مشخص کنید. برای انجام تمرین هر واکه را به‌تنهایی تلفظ کنید و هم‌زمان به حرکت زبان توجه کنید: «او» را بگویید (زبان بالا و عقب است) و سپس «آ» (زبان پایین است و به‌سمت عقب)، و به همین ترتیب «ای» و «اَ». دربارهٔ جایگاه «آ»، «اَ» و «او» در کلاس بحث شد. هدف تمرین، درک تجربی این نکته بود که واکه‌ها با تغییر شکل و جایگاه اندام‌های گفتار از هم متمایز می‌شوند. (شکل ۱۴.۲ پاسخ تقریبی را نشان می‌دهد.)

[محتوای افزوده] ابعاد تکمیلی واکه‌ها

افزون بر دو بُعد جایگاه زبان، **گردی لب‌ها** (Rounding) بُعد سوم توصیف واکه‌هاست: در فارسی /u/، /o/ و /ɒ/ گرد هستند و /i/، /e/ و /æ/ ناگرد. همچنین سنت دستور فارسی سه واکه را «بلند» (آ، ای، او) و سه واکه را «کوتاه» (اَ، اِ، اُ) می‌نامد؛ در فارسی امروز تفاوت اصلی بیشتر از جنس کیفیت (جایگاه زبان) است تا طول. برخی منابع دو واکهٔ مرکب /ej/ و /ow/ را نیز می‌شمارند. در جلسهٔ بعد می‌بینیم که این جایگاه‌ها با فرمنت‌های اول و دوم (F_1 و F_2) ارتباط مستقیم دارند: ارتفاع زبان با F_1 و جلو/عقب‌بودن با F_2.

۲.۱۰ همخوان‌ها و ویژگی‌های تولیدی آن‌ها

همخوان‌ها را معمولاً با سه ویژگی توصیف می‌کنیم: **محل تولید** (Place of Articulation)، **شیوه‌تولید** (Manner of Articulation) و **واک‌داری** (Voicing). در کلاس هر ویژگی با یک تمرین عملی (تکرار صداها و حس‌کردن اندام‌ها) همراه بود.

۲.۱۰.۱ محل تولید

محل تولید مشخص می‌کند که مسدودشدن یا تنگ‌شدن جریان هوا در کدام بخش دستگاه گفتار رخ می‌دهد.

- «ب» و «پ»: دو لب به هم نزدیک می‌شوند و لحظه‌ای مسیر هوا را می‌بندند ← **دولبی** (Bilabial).
- «ف» و «و» (/v/): لب پایین و دندان‌های بالا ← **لبی‌دندانی** (Labiodental).
- «ه» (روی تخته: «ح»): در ناحیهٔ چاکنای (حنجره) ← **چاکنایی** (Glottal).
- «س» و «ز»: زبان نزدیک لثه ← **لثوی** (Alveolar).

درباره‌ «و» و «ح»

در فارسی معیار، حرف «و» در جایگاه همخوان به‌صورت /v/ (لبی‌دندانی، مانند «ورزش») تلفظ می‌شود و /w/ دولبی-نرم‌کامی (مانند w انگلیسی در water) واج فارسی نیست؛ همچنین «ح» و «ه» هر دو به یک واج /h/ (چاکنایی) تلفظ می‌شوند.

۲.۱۰.۲ شیوه‌تولید

شیوهٔ تولید مشخص می‌کند جریان هوا چگونه کنترل می‌شود.

انسدادی (Stop / Plosive) جریان هوا لحظه‌ای کاملاً بسته و سپس رها می‌شود؛ رهایش را می‌توان به‌شکل یک ضربهٔ کوچک روی دست جلوی دهان حس کرد. (تمرین: دست خود را جلوی دهان بگیرید و «پ...پ...پ» را تکرار کنید.) مثال: «پ»، «ب»، «ت»، «د»، «ک»، «گ».

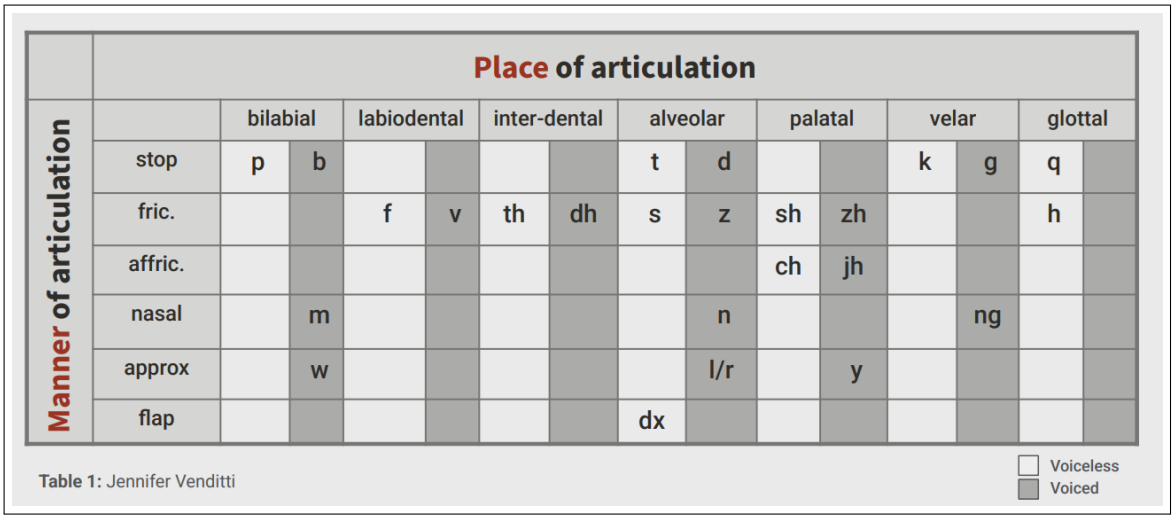
سایشی (Fricative) هوا ناگهانی و انفجاری رها نمی‌شود؛ از مجرایی باریک می‌گذرد و صدای سایشی ایجاد می‌کند. (تمرین: «ففففف...».) مثال: «ف»، «س»، «ز»، «ش».

خیشومی (Nasal) جریان هوا از مسیر بینی عبور می‌کند (در گفتار روزمره «تودماغی»). (تمرین: «مممممم...».) مثال: «م» و «ن».

دقت درباره‌ همخوان‌های خیشومی

در همخوان خیشومی مانند /m/، هوا از بینی می‌گذرد چون **نرم‌کام** (Velum) پایین می‌آید و مسیر بینی باز می‌شود؛ در عین حال در دهان یک انسداد کامل وجود دارد (برای /m/ دو لب، برای /n/ زبان روی لثه). بنابراین خیشومی‌ها

از نظر انسداد شبیه انسدادی‌ها هستند و تفاوتشان در مسیر خروج هوا از بینی است. برای مقایسه: اگر بینی خود را بگیرید، «م» تقریباً تولید نمی‌شود، اما «ب» می‌شود.



Manner of articulation	Place of articulation															
	bilabial		labiodental		inter-dental		alveolar		palatal		velar		glottal	
stop	p	b					t	d			k	g	q	
fric.			f	v	th	dh	s	z	sh	zh			h	
affric.									ch	jh				
nasal		m						n				ng		
approx		w						l/r		y				
flap							dx							

Table 1: Jennifer Venditti

Voiceless
Voiced

شکل ۱۵.۲: جدول همخوان‌های انگلیسی بر حسب محل تولید (ستون‌ها) و شیوهٔ تولید (ردیف‌ها). هر ستون به دو زیرستون بی‌واک (سفید) و واک‌دار (خاکستری) تقسیم شده است. نمادها آرپابت‌اند. (برگرفته از تختهٔ کلاس)

نکاتی دربارهٔ جدول انگلیسی

- نماد q در ستون چاکنایی همان انسدادی چاکنایی /ʔ/ است (نه /q/). سایر معادل‌ها در جدول زیر آمده است.
- ch و jh (و sh، zh) در جدول «کامی» (palatal) آمده‌اند؛ دقیق‌تر آن‌ها **پس‌لثوی** هستند.
- w و l/r نیز ساده‌شده‌اند: /w/ در واقع دولبی-نرم‌کامی است و /ɹ/ انگلیسی تقریباً پس‌لثوی.

ARPAbet	sh	zh	ch	jh	th	dh	ng	y	dx
IPA	ʃ	ʒ	tʃ	dʒ	θ	ð	ŋ	j	ɾ

۳.۱۰.۲ جدول همخوان‌های فارسی

فارسی معیار حدود ۲۳ همخوان دارد. جدول زیر آن‌ها را بر اساس محل و شیوهٔ تولید و واک‌داری دسته‌بندی می‌کند؛ در هر خانه، ابتدا همخوان بی‌واک و سپس واک‌دار می‌آید.

[محتوای افزوده] جدول همخوان‌های فارسی (مطابق محل، شیوه و واک‌داری)

شیوه \ محل	دولبی	لبی‌دندانی	لثوی	پس‌لثوی	کامی	نرم‌کامی	ملازی	چاکنایی
انسدادی	p b		t d			k g	ɢ	ʔ
انسدادی-سایشی				tʃ dʒ				
سایشی		f v	s z	ʃ ʒ		x		h
خیشومی	m		n					
روان کناری			l					
زنشی			ɾ					
غلت (نیم‌واکه)					j			

نمادها و حروف: /p/ پ، /b/ ب، /t/ ت‌ط، /d/ د، /k/ ک، /g/ گ، /ɢ/ ق‌غ، /ʔ/ ء‌ع، /tʃ/ چ، /dʒ/ ج، /f/ ف، /v/ و، /s/ س‌ص‌ث، /z/ ذ‌ض‌ظ، /ʃ/ ش، /ʒ/ ژ، /x/ خ، /h/ ه‌ح، /m/ م، /n/ ن، /l/ ل، /ɾ/ ر، /j/ ی. ردهٔ ملازی /ɢ/ در تلفظ تهرانی گاهی به‌صورت سایشی [ɣ] هم تحقق می‌یابد (به‌ویژه بین دو واکه). همچنین /k/ و /g/ پیش از واکه‌های جلو غالباً کامی ([c] و [ɟ]) تلفظ می‌شوند. فهرست و برچسب‌گذاری برخی واج‌ها (مثلاً /x/ نرم‌کامی یا ملازی) در منابع مختلف کمی متفاوت است.

۴.۱۰.۲ واک‌داری

واک‌داری

در صداهای **واک‌دار** (Voiced) تارهای صوتی هنگام تولید ارتعاش دوره‌ای دارند (مانند «ز»، «ب»، «د»، «م» و همهٔ واکه‌ها)؛ در صداهای **بی‌واک** (Voiceless) چنین ارتعاش دوره‌ایِ تارها وجود ندارد (مانند «س»، «پ»، «ت»، «ف»).

تمرین کلاسی: «س» و «ز»

دست خود را روی ناحیهٔ حنجره (گلو) بگذارید و ابتدا «سسسس» و سپس «زززز» را کشیده تلفظ کنید. هنگام «ز» ارتعاش تارها را حس می‌کنید، اما هنگام «س» نه. همین مقایسه را برای «ب» و «پ» هم انجام دهید.

جدول ۴.۲: جفت‌های مشابه از نظر محل و شیوه که فقط در واک‌داری تفاوت دارند

ویژگی	/s/ س	/z/ ز
محل تولید	لثوی	لثوی
شیوهٔ تولید	سایشی	سایشی
واک‌داری	بی‌واک	واک‌دار
ویژگی	**/p/ پ**	**/b/ ب**
محل تولید	دولبی	دولبی
شیوهٔ تولید	انسدادی	انسدادی
واک‌داری	بی‌واک	واک‌دار

پس دو همخوان می‌توانند در محل و شیوه یکسان باشند و فقط در واک‌داری تفاوت داشته باشند. این ویژگی‌ها برای

خطاهای بازشناسی اهمیت ویژه دارند (بخش بعد).

واک‌داری و «ارتعاش» همیشه یکی نیستند

تعریف «واک‌دار = ارتعاش تارها» ساده‌شده است. در عمل، تمایز /p/ و /b/ (مثلاً در آغاز واژه در فارسی و انگلیسی) بیشتر با **زمان آغاز واک** (Voice Onset Time, VOT) و دمیدگی مشخص می‌شود و گاهی /b/ در آغاز واژه به‌طور کامل واک‌دار نیست. این موضوع را در بخش‌های آکوستیکی بررسی می‌کنیم؛ برای شروع همان تعریف ارتعاش تارها کافی است. نکتهٔ دیگر: در زمزمه (whisper) واک‌داری وجود ندارد اما گفتار همچنان فهمیده می‌شود.

۱۱.۲ کاربرد آواشناسی در هوش مصنوعی

پرسش اصلی کلاس: «این همه مطلب دربارهٔ زبان، تارهای صوتی و آواشناسی به چه درد ما به‌عنوان مهندس هوش مصنوعی می‌خورد؟» در محیط‌های غیرمهندسی (مانند گفتاردرمانی و آموزش لهجه و تلفظ) کاربرد مستقیم‌تر است، اما برای ما کاربرد اصلی «ویژگی‌های زبانی» (Linguistic features) است. در کلاس چند کاربرد مطرح شد. تصویر کلی روی تخته چنین است:

$$\text{Raw speech} \rightarrow \text{Acoustic features} + \text{Articulatory/phonetic features} \rightarrow \text{Smaller model}$$

۱.۱۱.۲ مدل‌های ساده‌تر برای تسک‌های مشخص

در سیستم‌های امروزی مانند STT مبتنی بر یادگیری عمیق، لازم نیست ویژگی‌های آوایی را دستی وارد کنیم؛ دادهٔ صوتی را به مدل می‌دهیم و مدل ویژگی‌های لازم را خودش یاد می‌گیرد. اما برای هر مسئله به مدل عمیق و بزرگ نیازی نیست: اگر تسک ساده‌ای داشته باشیم و ثابت کنیم که مثلاً تنها با Place of Articulation می‌توان کلاس‌ها را تفکیک کرد، شاید یک طبقه‌بند ساده با چند ویژگی کافی باشد. شرط مهم: باید ابتدا بررسی و اثبات کنیم این ویژگی‌ها واقعاً توان تفکیک دارند.

۲.۱۱.۲ کمبود داده (Low-Resource)

وقتی داده برای آموزش مدل عمیق کافی نیست (مسئله‌های Low-Resource)، ویژگی‌های آواشناسی دانش مفیدی دربارهٔ ساختار داده فراهم می‌کنند: به‌جای اینکه مدل همهٔ روابط را از نمونه‌ها کشف کند، می‌توان محل تولید، شیوهٔ تولید یا واک‌داری را در اختیارش گذاشت تا با داده کمتر به عملکرد مناسب برسد.

۳.۱۱.۲ افزودن دانش به داده (Knowledge Injection)

ویژگی‌های آواشناسی را می‌توان به‌صورت برچسب یا ویژگی به داده اضافه کرد. مثلاً برای واج /p/ علاوه بر خود نمونه، اطلاعات زیر را هم می‌دهیم:

واج	Place	Manner	Voicing
/p/	Bilabial	Stop	Voiceless

تفاوت Knowledge Injection و Data Cleaning

استاد تأکید کرد: در **پاک‌سازی داده** (Data Cleaning) داده‌های نامناسب، خراب یا دارای خطا را اصلاح می‌کنیم؛ اما در **تزریق دانش** (Knowledge Injection) اطلاعاتی را که نمایانگر دانش پیشین ما دربارهٔ مسئله است به داده یا فرایند آموزش می‌افزاییم. این دو یکی نیستند.

۴.۱۱.۲ مدل‌های سبک‌تر

اگر بخشی از مدل بزرگ وظیفهٔ استخراج ویژگی‌هایی را دارد که از قبل دربارهٔ آن‌ها دانش داریم، گاهی می‌توان آن ویژگی‌ها را مستقیم به مراحل بعدی داد و یادگیری مجدد بخشی از اطلاعات را کم کرد؛ نتیجه ممکن است مدلی سبک‌تر باشد (شبیه کاهش ابعاد مسئله).

افزودن ویژگی، مدل را خودکار کوچک نمی‌کند

صرف افزودن ویژگی باعث کوچک‌شدن مدل نمی‌شود؛ برای رسیدن به مدل کوچک‌تر باید معماری و روش آموزش هم متناسب طراحی شوند. همچنین در مدل‌های سرتاسری امروزی (مانند مدل‌های خودنظارتی) ویژگی‌های آوایی معمولاً به‌صورت ضمنی در بازنمایی‌های میانی یادگرفته می‌شوند؛ بنابراین ارزش تزریق صریح دانش بیشتر در شرایط کمبود داده، منابع محدود یا نیاز به کنترل و تفسیرپذیری است.

۵.۱۱.۲ تحلیل خطا و تفسیرپذیری

به نظر استاد، یکی از مهم‌ترین کاربردها، تحلیل خطا و **تفسیرپذیری** (Interpretability) است. فرض کنید برای یک مدل STT معیار **نرخ خطای کلمه** (Word Error Rate, WER) برابر ۱۲ درصد گزارش شده است. این عدد تنها می‌گوید مدل خطا دارد، نه اینکه چه نوع خطاهایی بیشتر رخ می‌دهد.

برای تحلیل دقیق‌تر، خروجی مدل (Prediction) را با مرجع صحیح (Ground Truth) مقایسه و ویژگی‌های واجی واج‌های اشتباه‌شده را بررسی می‌کنیم: از نظر محل، شیوه یا واک‌داری چه شباهت یا تفاوتی دارند؟ مثلاً اگر مدل «ب» و «پ» را زیاد با هم اشتباه بگیرد:

ویژگی	/b/	/p/
Place	Bilabial	Bilabial
Manner	Stop	Stop
Voicing	Voiced	Voiceless

محل و شیوه یکی است و تفاوت اصلی در واک‌داری است. به‌جای «۱۲ درصد خطا» می‌توان گفت چه سهمی از خطاها به واک‌داری، چه سهمی به محل تولید و ... مربوط است. روی تخته جمع‌بندی شد: **بخش قابل‌توجهی از خطاها بین واج‌هایی رخ می‌دهد که از نظر ویژگی‌های آرتیکولاتوری مشابه‌اند.**

پس از شناسایی الگوی خطا می‌توان تصمیم گرفت: داده‌های آموزشی برخی واج‌ها را زیاد کرد، کیفیت و تنوع داده را بهبود داد، ویژگی‌های مرتبط را به مدل افزود یا معماری و روش آموزش را تغییر داد. پس ویژگی‌های آواشناسی نه‌تنها برای فهم سازوکار تولید گفتار، بلکه ابزاری برای بررسی نقاط ضعف مدل‌ها هستند.

[محتوای افزوده] مثال عددی: تحلیل خطای واجی با ویژگی‌ها

(الف) محاسبهٔ WER. WER برابر است با

$$\mathrm{WER} = \frac{S + D + I}{N}$$

که S تعداد جایگزینی‌ها، D حذف‌ها، I درج‌ها و N تعداد کلمات مرجع است. اگر $N = ۵۰$، $S = ۴$، $D = ۱$ و $I = ۱$ باشد، $\mathrm{WER} = ۶/۵۰ = ۱۲٪$ (همان عدد ۱۲٪ کلاس).

(ب) فاصلهٔ ویژگی‌ها. هر همخوان را با یک بردار دودویی از ویژگی‌ها نمایش می‌دهیم: (دولبی، لثوی، انسدادی، سایشی، واک‌دار):

$$\mathrm{b} = (1,0,1,0,1),\quad \mathrm{p} = (1,0,1,0,0),\quad \mathrm{s} = (0,1,0,1,0),\quad \mathrm{z} = (0,1,0,1,1)$$

فاصلهٔ همینگ برابر تعداد ویژگی‌های متفاوت است: $d(b,p) = ۱$ (فقط واک‌داری)، $d(s,z) = ۱$، اما $d(b,s) = ۵$ و $d(b,z) = ۴$. اگر مدل «ب» را با «پ» اشتباه بگیرد، خطا «نزدیک» و قابل‌انتظار است (فاصله ۱)، ولی اشتباه‌گرفتن «ب» با «س» (فاصله ۵) خطایی جدی‌تر است.

(ج) سهم هر نوع خطا (فرضی). فرض کنید از ۲۰۰ خطای واجی، ۸۰ مورد (۴۰٪) فقط در واک‌داری، ۵۰ مورد (۲۵٪) فقط در محل، ۳۰ مورد (۱۵٪) فقط در شیوه و ۴۰ مورد (۲۰٪) در بیش از یک ویژگی با هم متفاوت باشند. این تحلیل می‌گوید اولویت بهبود (داده یا ویژگی بیشتر) باید تمایز واک‌داری باشد. (اعداد فرضی و صرفاً برای توضیح روش هستند.)

جدول ۵.۲: جمع‌بندی کاربردهای مهندسی دانش آواشناسی

کاربرد	نقش دانش آواشناسی
مدل‌های ساده	استفاده از ویژگی‌های محدود و مشخص به‌جای مدل‌های پیچیده
کمبود داده	کمک به یادگیری با استفاده از دانش قبلی
Knowledge Injection	افزودن ویژگی‌های تولیدی به داده یا مدل
مدل‌های کوچک‌تر	امکان کاهش بخشی از پیچیدگی با طراحی مناسب
تحلیل خطا	مشخص‌کردن انواع و الگوهای خطای مدل
تفسیرپذیری	توضیح‌پذیرتر کردن رفتار مدل
آموزش تلفظ و گفتاردرمانی	شناسایی و آموزش تفاوت‌های تولیدی صداها

۱۲.۲ جمع‌بندی

در این فصل ابتدا رویکرد پایین‌به‌بالای درس را معرفی کردیم و جایگاه پردازش گفتار را در نقشهٔ علوم زبان (آواشناسی، نحو، ریخت‌شناسی، زبان‌شناسی رایانشی و عصب‌زبان‌شناسی) دیدیم. پس از مروری بر نظریهٔ زایشی چامسکی و بحث دستور جهانی در برابر یادگیری آماری، به آواشناسی تولیدی رسیدیم: آناتومی دستگاه گفتار، تنفس، نقش تارهای صوتی و اثر برنولی، زنجیرهٔ گفتار و هم‌تولیدی. سپس واحدهای گفتار (واج، همخوان، واکه، هجا) و توصیف واکه‌ها با جایگاه زبان و همخوان‌ها با محل، شیوه و واک‌داری را بررسی کردیم و در پایان نشان دادیم این دانش چگونه برای طراحی مدل‌های ساده‌تر، تزریق دانش، کمبود داده و به‌ویژه تحلیل خطا و تفسیرپذیری به کار می‌آید. فصل بعد به آواشناسی آکوستیکی و تبدیل موج صوتی به بازنمایی‌های عددی می‌پردازد.

نکات مهم برای مرور و امتحان

- رویکرد این جلسه **پایین‌به‌بالا** است: ابتدا ماهیت داده، سپس بازنمایی، سپس مدل.
- گفتار سیگنالی **فیزیکی و پیوسته** است؛ متن **نمادین و گسسته**. شناخت سازوکار تولید گفتار مقدمهٔ درک ویژگی‌ها و بازنمایی‌های صوتی است.
- درس ما در چارچوب **زبان‌شناسی رایانشی** قرار دارد. هدفمان شناخت مفاهیم زبان‌شناسی برای استفاده در مدل‌هاست، نه کشف دوبارهٔ دسته‌بندی‌ها.
- چامسکی: زبان زایشی و سلسله‌مراتبی است؛ بحث **دستور جهانی** در برابر **یادگیری آماری/توزیعی** هنوز باز است.
- مسیر تولید صدا: ریه (بازدم) ← نای ← حنجره و تارهای صوتی ← مجرای صوتی (حلق، دهان، بینی).
- تارهای صوتی با نیروی فشار هوا و ارتجاع بافت و اثر **برنولی** (سرعت بیشتر، فشار کمتر) به‌طور دوره‌ای باز و بسته می‌شوند. توضیح کامل‌تر: نظریهٔ ماهیچه‌ای-ارتجاعی-آیرودینامیکی.
- نای حلقه‌حلقه است تا هنگام دم زیر اختلاف فشار روی هم نخوابد و در عین حال انعطاف داشته باشد؛ ولی تارهای صوتی باید باز و بسته شوند.
- **زنجیرهٔ گفتار:** مغز گوینده ← نورون حرکتی ← اندام‌ها ← موج صوتی ← گوش و نورون حسی ← مغز شنونده، به‌علاوهٔ بازخورد شنیداری برای خود گوینده.
- **هم‌تولیدی (Coarticulation):** هم‌پوشانی حرکات واج‌های مجاور؛ گفتار مثل نواختن پیانو (نت‌های جدا از هم) نیست.
- واکه‌ها با جایگاه زبان (جلو/عقب و بالا/پایین) توصیف می‌شوند؛ فارسی شش واکه دارد (ای، اِ، اَ، آ، اُ، او).
- همخوان‌ها با سه ویژگی: **Place** (دولبی، لبی‌دندانی، چاکنایی، ...)، **Manner** (انسدادی، سایشی، خیشومی، ...) و **Voicing** (واک‌دار/بی‌واک). مثال‌های کلیدی: «ب/پ» و «س/ز».
- کاربرد در هوش مصنوعی: مدل‌های ساده‌تر، کمبود داده، Knowledge Injection (که با Data Cleaning فرق دارد)، مدل‌های سبک‌تر، تحلیل خطا (به‌جای یک عدد کلی مثل WER، بررسی الگو و علت خطا) و تفسیرپذیری.

فصل ۳

آواشناسی آکوستیکی: موج صوتی، طیف، اسپکتروگرام و مدل منبع-فیلتر

۱.۳ توضیحات کلاس دربارهٔ ارزشیابی

نحوهٔ نمره‌دهی درس (اعلام‌شده در ابتدای جلسه)

نمرهٔ درس از دو بخش تشکیل می‌شود:

- ۱۰ **نمره عملی:** مربوط به فعالیت‌ها و تمرین‌های عملی درس است. برای این بخش احتمالاً لازم است دانشجویان گزارش تحویل دهند؛ استاد اشاره کردند که ممکن است به‌جای گزارش، «ارائه» نیز در نظر گرفته شود.
- ۱۰ **نمره نظری:** مربوط به بخش تئوری و شامل **میان‌ترم** و **پایان‌ترم** است.

سؤالات بخش نظری از همین مطالبی طرح می‌شود که در کلاس توضیح داده می‌شود و مباحث مطرح‌شده در جلسات. همچنین استاد اعلام کردند که **تمرین اول درس دربارهٔ اسپکتروگرام** است؛ به همین دلیل مفاهیم این فصل برای تمرین عملی هم لازم است.

۲.۳ مرور جلسهٔ قبل و طرح مسئله

در جلسهٔ قبل با **آواشناسی تولیدی** (Articulatory Phonetics) آشنا شدیم؛ یعنی اینکه صداهای گفتار چگونه به کمک اندام‌های گفتار ساخته می‌شوند. سه مفهوم اصلی آن جلسه عبارت بودند از:

۱. **نقشهٔ واکه‌ها** (Vowel Chart): توصیف و دسته‌بندی واکه‌ها بر پایهٔ ارتفاع و جلو/عقب‌بودن زبان؛

۲. **محل تولید** (Place of Articulation): اینکه همخوان در کدام ناحیهٔ دستگاه گفتار ساخته می‌شود؛

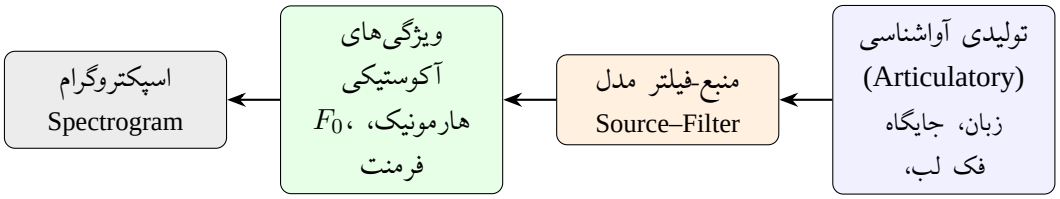
۳. **شیوهٔ تولید** (Manner of Articulation): اینکه جریان هوا هنگام تولید همخوان چگونه کنترل یا محدود

می‌شود.

این مفاهیم رویدادهای داخل دهان را توصیف می‌کنند، اما مسئلهٔ مهمی باقی می‌ماند: **این ویژگی‌های تولیدی در موج فیزیکی صدا چه اثری می‌گذارند؟** مثلاً می‌دانیم هنگام تولید یک واکه زبان در موقعیت مشخصی است؛ باید بفهمیم این موقعیت چگونه در موج خروجی دیده می‌شود. هدف ما یافتن یک **نگاشت** (Mapping) میان دو دسته ویژگی است:

- ویژگی‌های تولیدی: محل زبان، میزان بازشدن دهان، شیوهٔ تولید؛
- ویژگی‌های فیزیکی موج: فرکانس، دامنه و ساختار طیفی.

این نگاشت برای Speech-to-Text (تبدیل گفتار به متن)، Text-to-Speech (تبدیل متن به گفتار) و سایر سامانه‌های پردازش و تحلیل گفتار اهمیت دارد.



شکل ۱.۳: مسیر منطقی این فصل: از حالت اندام‌های گفتار، با واسطهٔ مدل منبع-فیلتر، به ویژگی‌های آکوستیکی و نمایش آن‌ها در اسپکتروگرام می‌رسیم (شکل افزوده).

آواشناسی آکوستیکی (Acoustic Phonetics) به بررسی خصوصیات فیزیکی موج صوتی گفتار می‌پردازد. در این فصل می‌خواهیم ببینیم رویدادهای تارهای صوتی و مجرای صوتی چگونه در ویژگی‌های این موج منعکس می‌شوند.

۳.۳ موج صوتی، فرکانس پایه و زیر و بمی

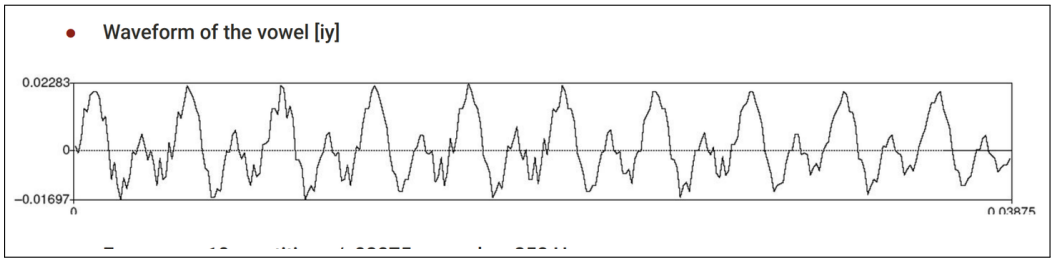
۱.۳.۳ شکل موج

شکل موج (Waveform) نمایش سیگنال در **حوزهٔ زمان** است: محور افقی زمان و محور عمودی دامنه است. دامنه در موج خام صوت، میزان انحراف فشار هوا از حالت عادی (فشار محیط) را نشان می‌دهد. هرچه صوت قوی‌تر باشد، هوا بیشتر فشرده و منبسط می‌شود، اختلاف فشار بیشتر است و قله‌ها بلندتر و درّه‌ها عمیق‌تر می‌شوند. چیزی که میکروفون ثبت می‌کند (و در گوش ما با جابه‌جایی پردهٔ صماخ و ساختارهای بعدی آن متناظر است) همین تغییرات فشار در طول زمان است.

۲.۳.۳ فرکانس و دوره تناوب

فرکانس (Frequency) می‌گوید یک الگوی نوسانی در واحد زمان چند بار تکرار می‌شود. اگر در بازهٔ T ثانیه دقیقاً N چرخهٔ کامل داشته باشیم:

$$f = \frac{N}{T} \text{ (Hz)}$$



شکل ۲.۳: شکل موج واکهٔ [iy]. الگوی تکرارشوندهٔ قله‌ها و درّه‌ها در طول زمان دیده می‌شود؛ مدت یک تکرار کامل، تناوب موج است. (برگرفته از تختهٔ کلاس)

مثلاً ۱۰۰ چرخه در یک ثانیه یعنی ۱۰۰ هرتز. برای یک موج متناوب، **دوره تناوب** (Period) T_0 مدت یک چرخه است و رابطهٔ زیر برقرار است (همان رابطهٔ $f = 1/T$ که روی تخته نوشته شد):

$$F_0 = \frac{1}{T_0}, \qquad T_0 = \frac{1}{F_0}.$$

[محتوای افزوده] مثال عددی: دوره تناوب و فرکانس پایه

- اگر فاصلهٔ دو قلهٔ متوالی یک الگوی تکرارشونده ۱۰ میلی‌ثانیه باشد: $F_0 = 1/0{,}010 = 100$ هرتز (در حد یک صدای مردانهٔ معمولی).
- اگر فاصله ۵ میلی‌ثانیه باشد: $F_0 = 1/0{,}005 = 200$ هرتز (در حد یک صدای زنانهٔ معمولی).
- اگر $F_0 = 120$ هرتز باشد: $T_0 = 1/120 \approx 8{,}33$ میلی‌ثانیه؛ پس در ۱ ثانیه حدود ۱۲۰ بار تارهای صوتی باز و بسته می‌شوند.

این همان محاسبهٔ دست‌نوشتهٔ تخته است: با اندازه‌گرفتن فاصلهٔ زمانی میان دو تکرار مشابه، فرکانس به دست می‌آید.

شمردن قله‌ها همیشه F_0 را نمی‌دهد

در کلاس برای شهود، «تعداد قله‌های تکرارشونده» شمرده شد و در پرسش یکی از دانشجویان نیز این نکته مطرح شد که در موج پیچیده، شمردن همهٔ قله‌های محلی لزوماً فرکانس پایه را نمی‌دهد. دلیل آن است که موج گفتار در هر دوره چند قلهٔ کوچک و بزرگ دارد (اثر فرمنت‌ها، شکل موج بالا را ببینید) و آنچه باید اندازه گرفته شود، مدت تکرار کل الگو است، نه تعداد همهٔ نوسان‌های ریز. در عمل برای تخمین F_0 از الگوریتم‌هایی مانند خودهمبستگی (autocorrelation) روی فریم‌های کوتاه استفاده می‌شود؛ استاد نیز اشاره کردند سیگنال را در بازه‌های کوتاه (Frame) بررسی می‌کنیم و درباره استخراج ویژگی‌ها بعداً بیشتر صحبت خواهد شد.

۳.۳.۳ فرکانس پایه و Pitch

موج حاصل از ارتعاش تارهای صوتی یک **فرکانس پایه** (Fundamental Frequency) دارد که با F_0 نشان داده می‌شود. این فرکانس با ادراک **زیر و بمی** (Pitch) ارتباط نزدیک دارد:

فرکانس پایه	ادراک شنیداری
F_0 بالاتر	صدای زیرتر (High Pitch)
F_0 پایین‌تر	صدای بم‌تر (Low Pitch)

F_0 ویژگی فیزیکی است و Pitch ویژگی ادراکی

در کلاس برای سادگی دو واژه کنار هم به کار رفتند، اما باید فرق را حفظ کرد: F_0 کمیتی است که از سیگنال اندازه می‌گیریم (هرتز)، ولی Pitch آن چیزی است که شنونده می‌شنود. رابطهٔ این دو تقریباً یکنوا است، اما خطی نیست: گوش به نسبت‌های فرکانسی حساس است (مثلاً دو برابرشدن F_0 یک اکتاو بالاتر ادراک می‌شود). همچنین در شرایطی مانند گفتار تلفنی ممکن است خود مؤلفهٔ F_0 ضعیف یا حذف شده باشد و باز هم شنونده همان Pitch را بشنود (پدیدهٔ «فرکانس پایهٔ گم‌شده»).

۴.۳.۳ چرا F_0 افراد متفاوت است؟

در توضیح ساده‌شدهٔ کلاس، ضخامت و جنس تارهای صوتی بر سرعت ارتعاش اثر می‌گذارد: تارهای ضخیم‌تر کندتر و تارهای نازک‌تر سریع‌تر می‌لرزند (مانند طناب کلفت و طناب نازک). برای مثال حدود ۱۰۰ هرتز برای صدای مردانه و ۲۰۰ هرتز برای صدای زنانه بیان شد. این اعداد فقط برای درک تفاوت‌اند و مقدار ثابتی برای همهٔ افراد نیستند.

دقیق‌تر: طول، جرم و کشش تارها

F_0 به طول، جرم و میزان کشش تارهای صوتی (و فشار هوای زیر چاکنای) بستگی دارد، نه فقط «ضخامت». تارهای صوتی مردان بالغ بلندتر و پرجرم‌ترند (تقریباً ۱۷ تا ۲۵ میلی‌متر، در برابر ۱۲ تا ۱۷ میلی‌متر در زنان) و در نتیجه F_0 پایین‌تری دارند. گوینده می‌تواند با تغییر کشش ماهیچه‌های حنجره، F_0 خود را به‌طور ارادی تغییر دهد؛ به همین دلیل می‌توان همان «آ» را بم‌تر یا زیرتر خواند.

[محتوای افزوده] محدوده‌تقریبی F_0 در گفتار عادی

گروه	محدودهٔ رایج F_0 (هرتز)	میانگین تقریبی (هرتز)
مردان بالغ	۸۵ تا ۱۸۰	حدود ۱۲۰
زنان بالغ	۱۶۵ تا ۲۵۵	حدود ۲۱۰
کودکان	۲۵۰ تا ۴۰۰	—

این‌ها مقادیر تقریبی گفتار معمولی‌اند و میان افراد و زبان‌ها اختلاف دارند. خواندن، فریاد زدن و حالت‌های هیجانی می‌توانند F_0 را از این بازه‌ها خارج کنند.

۵.۳.۳ آیا Pitch جنسیت را مشخص می‌کند؟

خیر؛ Pitch به‌تنهایی برای تشخیص جنسیت گوینده کافی نیست. استاد از دانشجویان خواستند صدای «آ» را یک بار عادی و بار دیگر بم‌تر یا زیرتر بگویند و متوجه شوند که با ثابت‌ماندن شکل دهان و موقعیت زبان، فقط نحوهٔ ارتعاش تارها تغییر می‌کند. بنابراین فرد می‌تواند تا حدی Pitch خود را ارادی تغییر دهد. نمونه‌ها: برخی زنان صدای نسبتاً بم و برخی مردان صدای نسبتاً زیر دارند، کودکان معمولاً صدای زیرتری دارند و صداپیشگان با تمرین دامنهٔ زیر و بمی خود را تغییر می‌دهند.

علاوه بر F_0، **طول مجرای صوتی** (Vocal Tract Length) نیز در ویژگی‌های شنیداری مؤثر است؛ مجرای بلندتر فرمنت‌ها را به فرکانس‌های پایین‌تر می‌برد (بخش‌های بعد). پس برای مقایسهٔ گویندگان نباید به F_0 اکتفا کرد. (در یادداشت‌های تخته نیز «ویژگی‌های تعیین‌کنندهٔ جنسیت: F_0، طول مجرای صوتی و ...» آمده است.)

اشتباه رایج: «آلتو» و «زنانه»

واژهٔ «آلتو» (Alto) اشاره به صدایی با فرکانس پایه پایین‌تر از میانگین صدای زنان دارد. وجود چنین صداهایی نشان می‌دهد که صرف F_0 پایین یا بالا، جنسیت را مشخص نمی‌کند.

۴.۳ تحلیل فرکانسی و تبدیل فوریه

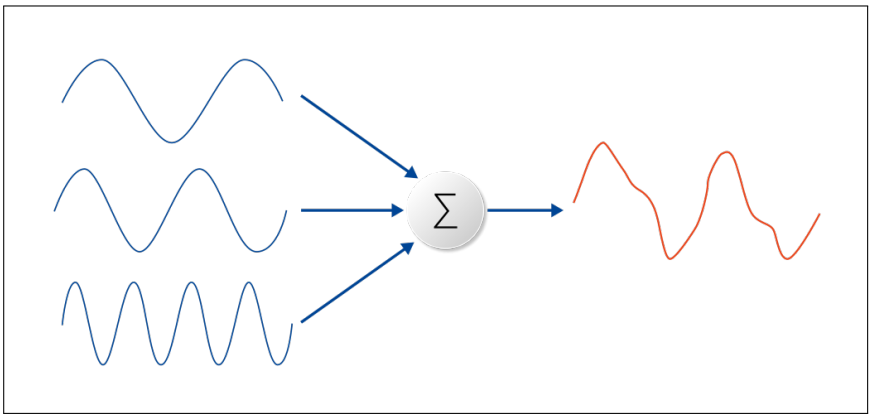
۱.۴.۳ چرا به تبدیل فوریه نیاز داریم؟

تا اینجا موج را در حوزهٔ زمان دیدیم و F_0 را به دست آوردیم. اما موج گفتار فقط یک فرکانس ندارد؛ ترکیبی از مؤلفه‌های فرکانسی مختلف است. اگر تنها یک فرکانس ساده وجود داشت، نمی‌توانستیم تنوع صداها و لحن را توضیح دهیم. به ابزاری نیاز داریم که بگوید چه فرکانس‌هایی در سیگنال هست و هرکدام چه سهمی در موج نهایی دارد: **تبدیل فوریه** (Fourier Transform).

ایدهٔ بنیادی این است که هر سیگنال دلخواه را می‌توان مجموع چند موج سینوسی با فرکانس، دامنه و فاز مناسب دانست. شکل زیر این ایده را نشان می‌دهد: سه سینوسی با فرکانس‌های مختلف جمع می‌شوند و یک موج پیچیده می‌سازند.

۲.۴.۳ شهود ضرب داخلی

استاد برای توضیح شهودی از **ضرب داخلی** (Dot Product) استفاده کردند. فرض کنید می‌خواهیم بدانیم یک موج مبنا در ترکیب سیگنال وجود دارد یا نه. میزان «شباهت» سیگنال با آن موج مبنا را با ضرب داخلی می‌سنجیم: اگر حاصل صفر باشد، آن مؤلفه در سیگنال سهمی ندارد؛ اگر غیرصفر باشد، سهم دارد، و علامت منفی به معنی هم‌راستایی معکوس (اختلاف فاز) است. در کلاس این را با چند بردار عددی نشان دادند (شکل ۴.۳).



شکل ۳.۳: جمع چند موج سینوسی با فرکانس‌های متفاوت یک موج پیچیده می‌سازد. تبدیل فوریه مسئلهٔ معکوس را حل می‌کند: از موج پیچیده، سینوسی‌های سازنده را پیدا می‌کند. (برگرفته از تختهٔ کلاس)

$x = (-1,\ 1,\ -1,\ 1)$

بردار مبنا	ضرب داخلی با x	نتیجه
$b_1 = (1,\ 1,\ 1,\ 1)$	$-1+1-1+1=0$	سهمی ندارد
$b_2 = (-1,\ -1,\ 1,\ 1)$	$1-1-1+1=0$	سهمی ندارد
$b_3 = (1,\ -1,\ 1,\ -1)$	$-1-1-1-1=-4$	سهم کامل (فاز معکوس) ✓

شکل ۴.۳: محاسبهٔ تخته: سیگنال x (درون بیضی) با سه بردار مبنا مقایسه می‌شود؛ ضرب داخلی با دو بردار اول صفر و با بردار سوم -4 است (بازسازی‌شده از تختهٔ کلاس).

[محتوای افزوده] تفسیر مثال ضرب داخلی

b_1 (مؤلفهٔ ثابت) و b_2 سهمی در سیگنال ندارند، ولی b_3 که سریع‌ترین نوسان ممکن را دارد کاملاً با x هم‌خط است و علامت منفی یعنی $x = -b_3$ (فاز معکوس). پس این سیگنال «فقط از یک نوسان سریع» ساخته شده است. تبدیل فوریهٔ گسستهٔ بخش بعد دقیقاً همین کار را با موج‌های مبنای سینوسی/کسینوسی و همهٔ فرکانس‌ها انجام می‌دهد.

۳.۴.۳ تبدیل فوریهٔ گسسته در عمل

در پردازش گفتار، سیگنال به فریم‌های کوتاه تقسیم می‌شود و هر فریم، رشته‌ای از N عدد حقیقی (نمونه‌های دامنه) است. برای هر فرکانس یک موج مبنای مختلط $e^{-j2\pi kn/N}$ داریم و شباهت فریم با آن را با ضرب داخلی می‌سنجیم:

$$X[k] = \sum_{n=0}^{N-1} x[n]\, e^{-j2\pi kn/N}, \qquad k = 0, 1, \ldots, N-1.$$

خروجی برای هر فرکانس یک **عدد مختلط** $X(f) = a + jb$ است. اندازهٔ آن **بزرگی** (Magnitude) نامیده می‌شود:

$$|X(f)| = \sqrt{a^2 + b^2}$$

و می‌گوید آن فرکانس چقدر در ساخت موج ورودی سهم دارد؛ زاویهٔ عدد مختلط، **فاز** (Phase) است. موج‌های مبنا متعامدند و هر کدام باید در بازهٔ فریم تعداد صحیحی چرخهٔ کامل بزنند: کندترین آن‌ها در کل فریم یک چرخه می‌زند و بقیه مضرب صحیحی از آن‌اند.

دو نکته دربارهٔ توضیح تخته

(۱) در توضیح تخته گفته شد «مثلاً نرخ نمونه‌برداری ۵۱۲ باشد، پس ۵۱۲ دامنه داریم». ۵۱۲ در اینجا تعداد نمونه‌های یک فریم ($N = 512$) است، نه نرخ نمونه‌برداری؛ نرخ نمونه‌برداری (مثلاً ۱۶۰۰۰ نمونه در ثانیه) مفهوم جداگانه‌ای است. (۲) در تخته «کندترین موج = Pitch» نوشته شد. کندترین موج مبنا در تبدیل فوریهٔ یک فریم، فرکانس f_s/N دارد و فقط تعیین‌کنندهٔ فاصلهٔ بین نقاط شبکهٔ فرکانسی است، نه زیر و بمی. معنی درست‌تر این است: در یک سیگنال متناوب، کندترین مؤلفهٔ واقعاً موجود در سیگنال، همان فرکانس پایه F_0 است (و بقیه هارمونیک‌ها مضارب صحیح آن‌اند).

[محتوای افزوده] مثال عددی: تفکیک فرکانسی DFT

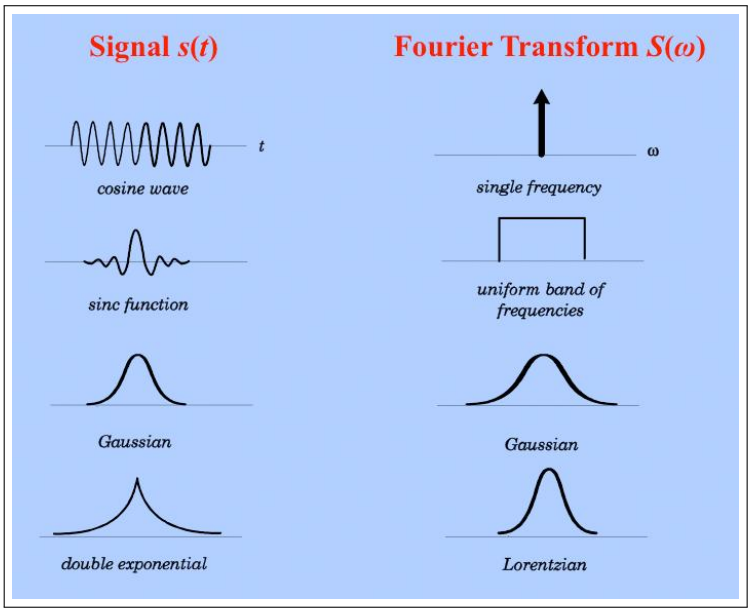
فاصلهٔ نقاط فرکانسی (**وضوح** (Resolution)) برابر $\Delta f = f_s/N = 1/L$ است که در آن $L = N/f_s$ مدت فریم برحسب ثانیه است. اگر $f_s = 16000$ هرتز:

- $N = 512$ (فریم ۳۲ میلی‌ثانیه): $\Delta f = 16000/512 = 31{,}25$ هرتز؛
- $N = 64$ (فریم ۴ میلی‌ثانیه): $\Delta f = 16000/64 = 250$ هرتز؛
- بالاترین فرکانس قابل نمایش (نایکوئیست) $f_s/2 = 8000$ هرتز است و برای $N = 512$ تعداد $N/2 + 1 = 257$ نقطهٔ فرکانسی مستقل داریم.

پس هرچه فریم بلندتر باشد، فرکانس‌های نزدیک‌تر از هم قابل تفکیک‌اند. این دقیقاً سرچشمهٔ تفاوت اسپکتروگرام باند باریک و پهن است.

۴.۴.۳ چند زوج فوریه

تصویر زیر رابطهٔ چند سیگنال حوزهٔ زمان با تبدیل فوریهٔ آن‌ها را نشان می‌دهد: موج کسینوسی خالص یک خط منفرد در فرکانس خودش دارد (صدایی مانند یک بوق ممتد با فرکانس ثابت)، تابع sinc تبدیلی مستطیلی دارد (یک باند یکنواخت از فرکانس‌ها)، و تبدیل گاوسی، گاوسی است.



شکل ۵.۳: زوج‌های سیگنال-تبدیل فوریه: کسینوس ← یک فرکانس منفرد، sinc ← باند یکنواخت از فرکانس‌ها، گاوسی ← گاوسی، نمایی دوطرفه ← لورنتسی. (برگرفته از تختهٔ کلاس)

برای مثال سیگنال $x(t) = A\sin(۲\pi ft)$ در طیف یک‌طرفه تنها یک مؤلفه در f دارد. چنین صدایی نسبت به گفتار ساختار فرکانسی بسیار ساده‌ای دارد. در کلاس دربارهٔ معادل شنیداری سیگنال sinc نیز بحث شد؛ استاد اذعان کردند که دربارهٔ شنیدار دقیق آن مطمئن نیستند، و این بخش بیشتر برای درک ایدهٔ «طیف» بود.

۵.۳ هارمونیک‌ها

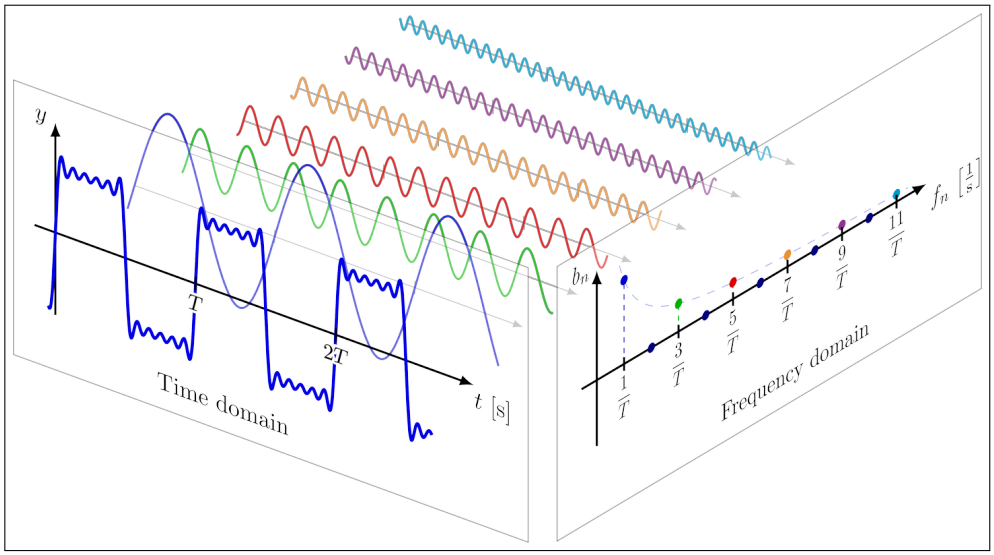
۱.۵.۳ تعریف

هارمونیک

در یک صدای متناوب با فرکانس پایه $F_۰$، مؤلفه‌های طیف در مضارب صحیح $F_۰$ قرار می‌گیرند:

$$F_n = n\,F_۰, \qquad n = ۱, ۲, ۳, \ldots$$

هارمونیک اول همان فرکانس پایه است ($H_۱ = F_۰$)، هارمونیک دوم $H_۲ = ۲F_۰$ و همین‌طور تا آخر. دامنهٔ هر هارمونیک می‌تواند متفاوت باشد.



شکل ۶.۳: نمای سه‌بعدی یک سیگنال: در حوزهٔ زمان، یک موج مربعی؛ در حوزهٔ فرکانس، سهم هر مؤلفهٔ سینوسی (فرکانس‌های $f, 3f, 5f, \ldots$ با دامنه‌های کاهنده). هر دو نمایش، اطلاعات یکسانی را در دو حوزه نشان می‌دهند. (برگرفته از تختهٔ کلاس)

مثال: اگر $F_0 = 100$ هرتز باشد، هارمونیک‌های اول تا پنجم در ۵۰۰, ۴۰۰, ۳۰۰, ۲۰۰, ۱۰۰ هرتز هستند. در طیف مثالی که استاد کشیدند، مؤلفه‌هایی مانند F_0، $3F_0$، $5F_0$ و $7F_0$ دیده می‌شدند تا نشان دهند بعضی هارمونیک‌ها در طیف از بقیه برجسته‌ترند (مثلاً موج مربعی تنها هارمونیک‌های فرد دارد، شکل قبل).

۲.۵.۳ فاصلهٔ هارمونیک‌ها و F_0

فاصلهٔ فرکانسی دو هارمونیک متوالی برابر F_0 است. پس: $F_n - F_{n-1} = F_0$

- هرچه F_0 بزرگ‌تر (صدای زیرتر)، هارمونیک‌ها دورتر از هم‌اند؛
- هرچه F_0 کوچک‌تر (صدای بم‌تر)، هارمونیک‌ها فشرده‌تر و تعدادشان در یک بازهٔ ثابت بیشتر است.

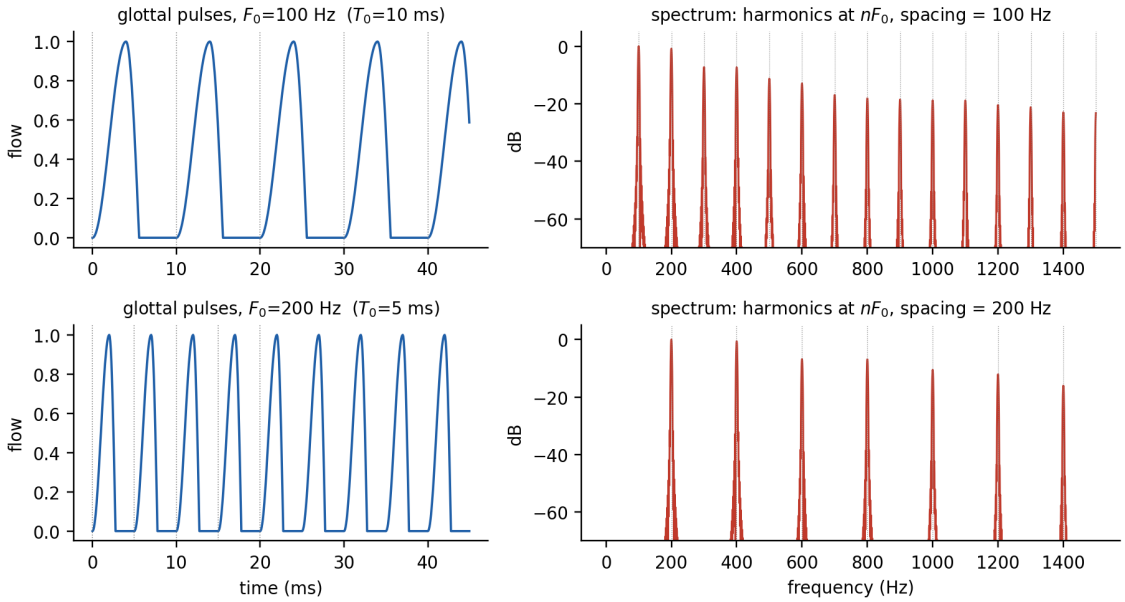
به همین دلیل از فاصلهٔ خطوط هارمونیکی در اسپکتروگرام می‌توان F_0 و تغییرات آن (زیر و بمی) را خواند.

[محتوای افزوده] مثال عددی: تعداد هارمونیک‌ها

در بازهٔ ۰ تا ۴۰۰۰ هرتز:

- برای $F_0 = 100$ هرتز: $4000/100 = 40$ هارمونیک؛
- برای $F_0 = 200$ هرتز: $4000/200 = 20$ هارمونیک.

بنابراین در صدای مردانه‌ای که F_0 پایین‌تری دارد، طیف «پرتراکم‌تر» است.



شکل ۳.۷: بالا: دنبالهٔ تپ‌های ساده‌شدهٔ هوای عبوری از چاکنای با $F_0 = 100$ هرتز و طیف آن. پایین: همان با $F_0 = 200$ هرتز. در هر دو مورد هارمونیک‌ها در مضارب صحیح F_0 ظاهر می‌شوند و فاصلهٔ آن‌ها دقیقاً F_0 است؛ دامنه با افزایش فرکانس به‌تدریج کاهش می‌یابد (شکل افزوده).

۳.۵.۳ چرا کافی نیستند؟

F_0 و هارمونیک‌ها نشان می‌دهند «منبع صدا» چگونه است، اما اینکه چرا «آ» با «ای» تفاوت دارد، با آن‌ها توضیح داده نمی‌شود. برای این به مدل منبع-فیلتر نیاز داریم؛ ولی ابتدا نمایشی از طیف در طول زمان می‌سازیم.

۶.۳ اسپکتروگرام

۱.۶.۳ از طیف به اسپکتروگرام

تبدیل فوریهٔ کل گفتار، یک طیف واحد می‌دهد و اطلاعات زمانی را از دست می‌دهد؛ در حالی که گفتار ایستا نیست و اندام‌ها و محتوای فرکانسی دائم تغییر می‌کنند. **اسپکتروگرام** (Spectrogram) (طیف‌نگاره؛ از Spectro برگرفته از Spectrum یعنی طیف و Gram یعنی نگاره یا ثبت) تغییرات محتوای فرکانسی را در طول زمان نمایش می‌دهد.

۲.۶.۳ مراحل ساخت

۱. سیگنال به پنجره‌ها یا فریم‌های زمانی کوتاه (مثلاً ۲۵ میلی‌ثانیه) بریده می‌شود (Windowing). پنجره‌ها ممکن است هم‌پوشانی (Overlap) داشته باشند یا نداشته باشند.

۲. روی هر فریم تبدیل فوریه اعمال می‌شود و بزرگی طیف هر فریم به دست می‌آید.

۳. این طیف‌ها به‌ترتیب زمان کنار هم چیده می‌شوند و تصویر دوبعدی اسپکتروگرام را می‌سازند.

این روش را **تبدیل فوریهٔ زمان-کوتاه** (Short-Time Fourier Transform, STFT) می‌نامند.

[محتوای افزوده] مثال عددی: تعداد فریم‌ها

برای سیگنالی به طول ۱ ثانیه با $f_s = ۱۶۰۰۰$ هرتز (یعنی ۱۶۰۰۰ نمونه)، پنجره ۲۵ میلی‌ثانیه (۴۰۰ نمونه) و گام ۱۰ میلی‌ثانیه (۱۶۰ نمونه):

$$\text{تعداد فریم‌ها} = ۱ + \left\lfloor \frac{۱۶۰۰۰ - ۴۰۰}{۱۶۰} \right\rfloor = ۱ + ۹۷ = ۹۸.$$

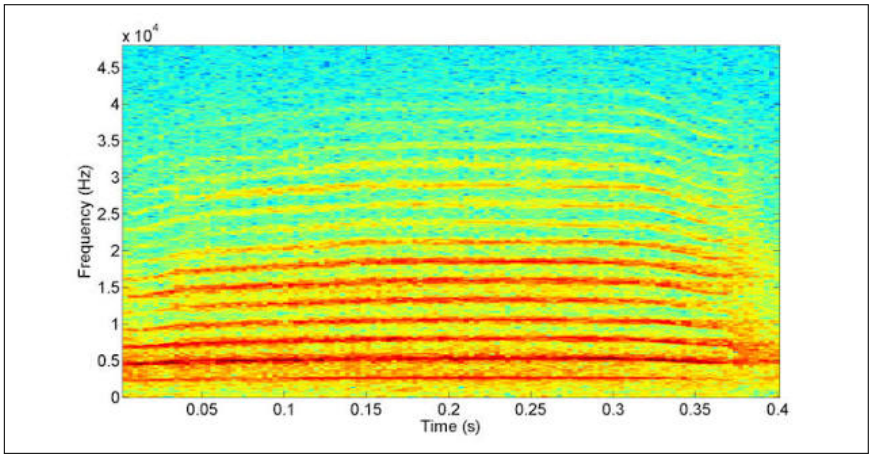
هر فریم یک ستون از اسپکتروگرام است؛ پس این اسپکتروگرام حدود ۹۸ ستون دارد.

۳.۶.۳ محورها و رنگ

در اسپکتروگرام:

- محور افقی: زمان؛
- محور عمودی: فرکانس؛
- رنگ یا روشنایی هر نقطه: بزرگی (انرژی یا توان) آن مؤلفهٔ فرکانسی در آن لحظه.

به بیان تخته: اگر یک تصویر دوبعدی (زمان-دامنه) را به‌صورت فضای سه‌بعدی ببینیم، محور سوم همان فرکانس است و دامنه به شکل رنگ پیکسل‌ها نمایش داده می‌شود. رنگ گرم یعنی بزرگی بالا، یعنی آن فرکانس شباهت زیادی با سیگنال ورودی داشته و معمولاً هارمونیک صدای ورودی است؛ رنگ سرد یعنی بزرگی پایین و شباهت اندک.



شکل ۸.۳: اسپکتروگرام یک صدای تقریباً پایدار با رنگ‌گذاری گرم/سرد: خطوط افقی پررنگ، هارمونیک‌ها هستند و با گذر زمان کمی تغییر می‌کنند. مقیاس محور فرکانس در این تصویر مربوط به همان نمونهٔ منبع است. (برگرفته از تختهٔ کلاس)

مقیاس رنگ معمولاً دسی‌بل است

در اسپکتروگرام‌های رایج، رنگ نشان‌دهندهٔ لگاریتم بزرگی (دسی‌بل: $20 \log_{10} |X|$) است، نه خود بزرگی؛ چرا که دامنهٔ هارمونیک‌های قوی و ضعیف چندین مرتبه با هم فرق دارد و در مقیاس خطی مؤلفه‌های ضعیف دیده نمی‌شوند. همچنین اسپکتروگرام معمولاً فقط بزرگی را نشان می‌دهد و فاز کنار گذاشته می‌شود.

فرکانس و دامنه دو چیز متفاوت‌اند

فرکانس می‌گوید موج با چه سرعتی نوسان می‌کند و دامنه می‌گوید اندازهٔ نوسان چقدر است. قرار داشتن یک مؤلفه در فرکانس بالاتر به این معنی نیست که دامنهٔ بیشتری دارد. این تمایز در پرسش و پاسخ‌های کلاس چند بار مورد تأکید قرار گرفت. در اسپکتروگرام، «ارتفاع» روی محور عمودی فرکانس است و «پررنگی» دامنه.

۷.۳ مدل منبع-فیلتر

۱.۷.۳ مسئلهٔ حل‌نشده

با F_0 و هارمونیک‌ها فقط می‌توانیم «منبع» را بشناسیم. اما وقتی فردی از «آ» به «ای» می‌رود، F_0 را ثابت نگه دارد و فقط شکل دهان و موقعیت زبان را عوض کند، صدا فرق می‌کند. این تغییر از F_0 نمی‌آید. پس مدل کامل‌تری لازم است.

مدل منبع-فیلتر (Source–Filter)

تولید گفتار به دو بخش مستقل (در تقریب مدل) تقسیم می‌شود:

- **منبع (Source):** برای صداهای واک‌دار، ارتعاش تارهای صوتی که موجی دوره‌ای با فرکانس پایه و هارمونیک‌های آن تولید می‌کند؛
- **فیلتر (Filter):** مجرای صوتی (Vocal Tract) که بسته به شکلش بخش‌هایی از طیف را تقویت (تشدید) و بخش‌هایی را تضعیف می‌کند.

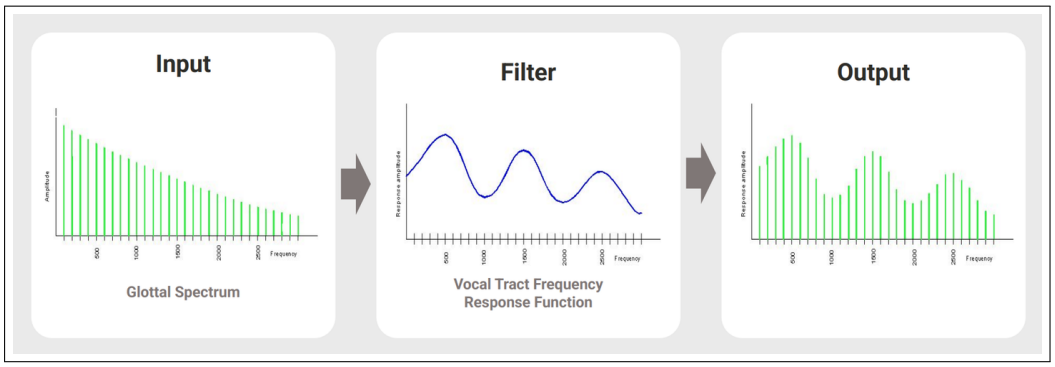
در حوزهٔ فرکانس، خروجی حاصل‌ضرب طیف منبع در پاسخ فرکانسی فیلتر است (همان فرمولی که روی تخته نوشته شد):

$$\text{Output}(f) = \text{Source}(f) \times \text{Filter}(f).$$

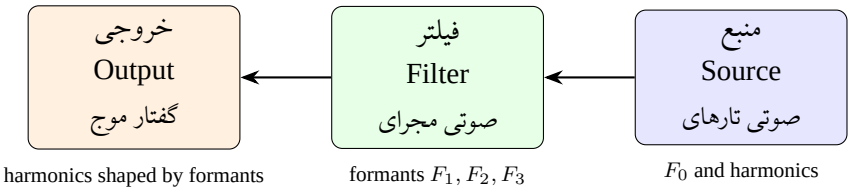
در حوزهٔ زمان، این عمل یک **کانولوشن** (Convolution) است و اگر لگاریتم بگیریم، ضرب به جمع تبدیل می‌شود: $\log|\text{Out}| = \log|\text{Src}| + \log|\text{Filt}|$ (در شکل زیر هم همین است).

۲.۷.۳ مجرای صوتی به‌مثابهٔ لوله

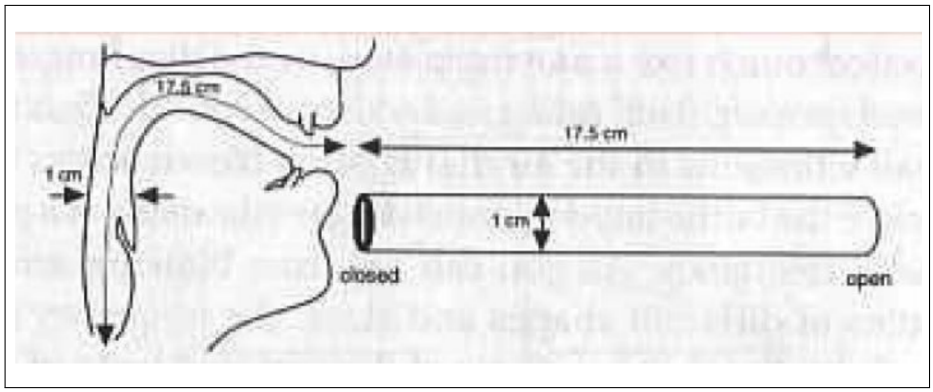
استاد برای سادگی مجرای صوتی را شبیه یک لوله در نظر گرفتند که هر تغییر شکلش بر موجِ عبوری اثر می‌گذارد. عواملی که شکل این فیلتر را تغییر می‌دهند: موقعیت زبان، میزان باز بودن دهان، موقعیت فک، وضعیت لب‌ها و محل تنگ‌شدگی در مسیر هوا. وقتی هنگام صحبت اندام‌ها را حرکت می‌دهیم، در واقع مشخصات فیلتر را تغییر می‌دهیم.



شکل ۹.۳: نمودار ورودی (طیف منبع در تارهای صوتی با هارمونیک‌های کاهنده)، فیلتر (پاسخ فرکانسی مجرای صوتی با قله‌های تشدیدی) و خروجی (طیف هارمونیک‌ها که بر اساس شکل فیلتر قله و درّه یافته است). (برگرفته از تختهٔ کلاس)



شکل ۱۰.۳: نمای سادهشدهٔ مدل منبع-فیلتر برای صداهای واک‌دار (شکل افزوده).



شکل ۱۱.۳: مدل لوله‌ای ساده از مجرای صوتی: لوله‌ای به طول حدود ۱۷٫۵ سانتی‌متر که در سمت چاکنای (تارهای صوتی) بسته و در سمت لب‌ها باز است؛ سطح مقطع حدود ۱ سانتی‌متر مربع. (برگرفته از تختهٔ کلاس)

[محتوای افزوده] مثال عددی: فرمنت‌های یک لولهٔ یک‌سربسته

برای لوله‌ای به طول L که یک سر بسته (چاکنای) و یک سر باز (لب) دارد، فرکانس‌های تشدید برابرند با:

$$F_n = \frac{(۲n-۱)\,c}{۴L}, \qquad n = ۱, ۲, ۳, \ldots$$

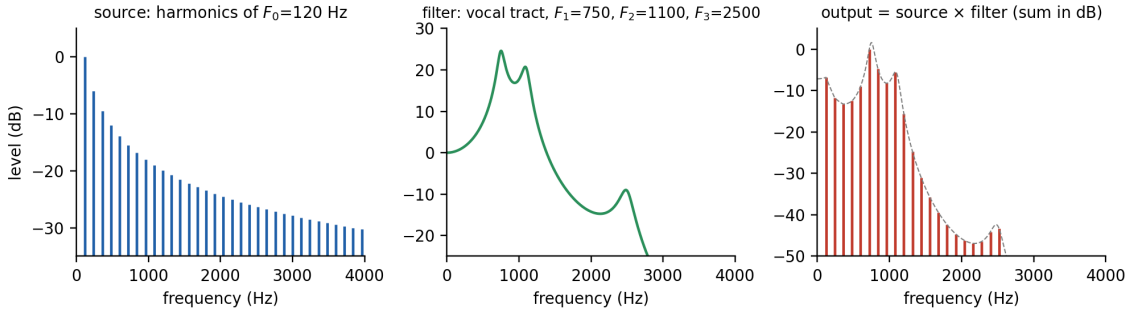
که $c \approx ۳۵۰$ متر بر ثانیه سرعت صوت در هوای گرم دهان است. برای $L = ۱۷/۵$ سانتی‌متر:

$$F_۱ = \frac{۳۵۰۰۰}{۴ \times ۱۷/۵} = ۵۰۰, \qquad F_۲ = ۱۵۰۰, \qquad F_۳ = ۲۵۰۰ \text{ هرتز.}$$

این مجموعه تقریباً فرمنت‌های یک واکهٔ خنثی (شبیه schwa) است. برای مجرای کوتاه‌تر با $L = ۱۵$ سانتی‌متر: $F_۱ \approx ۵۸۳$, $F_۲ \approx ۱۷۵۰$, $F_۳ \approx ۲۹۱۷$ هرتز؛ یعنی فرمنت‌ها حدود ۱۷ درصد بالاتر می‌روند. این توضیح می‌دهد چرا فرمنت‌های گویندگان با مجرای کوتاه‌تر (زنان و کودکان) بالاتر است.

۳.۷.۳ کار فیلتر: تشدید و تضعیف

مهم‌ترین نقش فیلتر، تقویت (تشدید) و تضعیف نواحی مختلف طیف است. منبع مجموعه‌ای از هارمونیک‌ها تولید می‌کند و با تغییر شکل دهان، بعضی هارمونیک‌ها تقویت و بعضی تضعیف می‌شوند. این همان پیوندی است که از ابتدای جلسه دنبال می‌کردیم: تغییر وضعیت اندام‌ها ← تغییر قابل مشاهده در طیف موج.



شکل ۱۲.۳: نمونهٔ عددی مدل منبع-فیلتر با $F_۰ = ۱۲۰$ هرتز: (الف) هارمونیک‌های منبع با افت تدریجی دامنه؛ (ب) پاسخ فرکانسی مجرا با فرمنت‌های $F_۱ = ۷۵۰$، $F_۲ = ۱۱۰۰$ و $F_۳ = ۲۵۰۰$ هرتز؛ (ج) خروجی که از جمع دو منحنی در مقیاس دسی‌بل به دست می‌آید. خط‌چین، پوش طیفی خروجی را نشان می‌دهد و هارمونیک‌ها نمونه‌هایی از همین پوش‌اند (شکل افزوده).

وضعیت دقیق «استقلال» منبع و فیلتر

مدل منبع-فیلتر یک تقریب است: فرض می‌کند منبع و فیلتر تقریباً مستقل‌اند، یعنی تغییر $F_۰$ فرمنت‌ها را جابه‌جا نمی‌کند و تغییر شکل مجرا، $F_۰$ را عوض نمی‌کند. این فرض برای بیشتر تحلیل‌ها خوب کار می‌کند و به همین دلیل می‌توانیم در سیگنال خروجی $F_۰$ را از فرمنت‌ها جدا بخوانیم. در واقعیت بازتاب‌هایی میان مجرا و چاکنای (برهم‌کنش منبع و مجرا) و اثر تابش از لب‌ها نیز وجود دارد که در مدل ساده نادیده گرفته می‌شود. در نمودار منبع، افت هارمونیک‌ها حدود ۱۲ دسی‌بل بر اکتاو است (شکل ناشی از تپ‌های هوای چاکنای) و تابش از لب‌ها حدود

۶ دسی‌بل بر اکتاو آن را جبران می‌کند؛ در شکل افزودهٔ بالا برای سادگی فقط شیب نهایی (حدود ۶− دسی‌بل بر اکتاو) رسم شده است.

۴.۷.۳ آیا همهٔ صداها از تارهای صوتی می‌آیند؟

خیر. همخوان‌های بی‌واک مانند «س» بدون ارتعاش تارهای صوتی تولید می‌شوند. در آن‌ها منبع، نویز آشفتگی جریان هوا در یک تنگنا است (نه سری از تپ‌های متناوب)، پس هارمونیک ندارند و طیف آن‌ها پیوسته است. فیلتر مجرای صوتی (بخش جلوی تنگنا) همچنان طیف این نویز را شکل می‌دهد. بنابراین مدل «منبع = ارتعاش تارها» تنها برای صداهای واک‌دار است و تمرکز این جلسه هم بر همین حالت بود.

۸.۳ فرمنت‌ها

۱.۸.۳ تعریف

فرمنت (Formant)

فرمنت‌ها نواحی تشدید مجرای صوتی هستند؛ نواحی از فرکانس که فیلتر آن‌ها را تقویت می‌کند. در طیف، فرمنت به‌صورت یک قلهٔ پهن در پوش طیف و در اسپکتروگرام باند پهن به‌صورت نوار یا توده‌ای پررنگ دیده می‌شود.

نکتهٔ مهم: فرمنت یک هارمونیک منفرد نیست؛ یک ناحیهٔ فرکانسی است که دامنهٔ چند هارمونیک مجاور را هم‌زمان بالا می‌برد. فرمنت‌ها مربوط به فیلتر هستند: مجرای صوتی خواص تشدیدی خود را دارد، چه منبع در حال تحریک باشد و چه نباشد. همچنین ما هنگام تحلیل، فرمنت‌ها را نمی‌سازیم؛ آن‌ها نتیجهٔ تشدیدهای مجرا هستند و در تحلیل، اثرشان را روی موج شناسایی می‌کنیم.

۲.۸.۳ فرمنت اول، دوم و سوم

فرمنت‌ها بر اساس ترتیب فرکانسی نام‌گذاری می‌شوند:

$$F_۱ < F_۲ < F_۳ < F_۴ < \cdots$$

یعنی $F_۱$ پایین‌ترین ناحیهٔ تشدیدی است (در اسپکتروگرام از فرکانس‌های پایین شروع می‌کنیم و اولین ناحیهٔ تشدیدی را $F_۱$ می‌نامیم). این ترتیب، ترتیب فرکانسی است و ربطی به ترتیب زمانی تولید ندارد.

۳.۸.۳ ارتباط فرمنت‌ها با نقشهٔ واکه‌ها

مهم‌ترین ارتباط جلسه این است که همان ویژگی‌های نقشهٔ واکه‌ها که جلسهٔ پیش دیدیم، در موقعیت فرمنت‌ها دیده می‌شوند:

ویژگی تولیدی	ویژگی آکوستیکی مرتبط
ارتفاع زبان / میزان بازشدگی دهان	$F_۱$
جلو یا عقب بودن زبان	$F_۲$

- $F_۱$: برای واکه‌های بازتر (زبان پایین‌تر، دهان بازتر) بالاتر و برای واکه‌های بسته‌تر پایین‌تر است. «آ» $F_۱$ بالاتری از «ای» دارد.
- $F_۲$: برای واکه‌های جلویی بالاتر و برای واکه‌های عقبی پایین‌تر است.

در تخته توضیحی نیز نوشته شده بود: وقتی زبان به جلو می‌آید، محفظهٔ جلوی دهان کوچک‌تر می‌شود و $F_۲$ بالا می‌رود؛ و تنگ‌شدن محفظهٔ حلق (مانند «آ») $F_۱$ را بالا می‌برد.

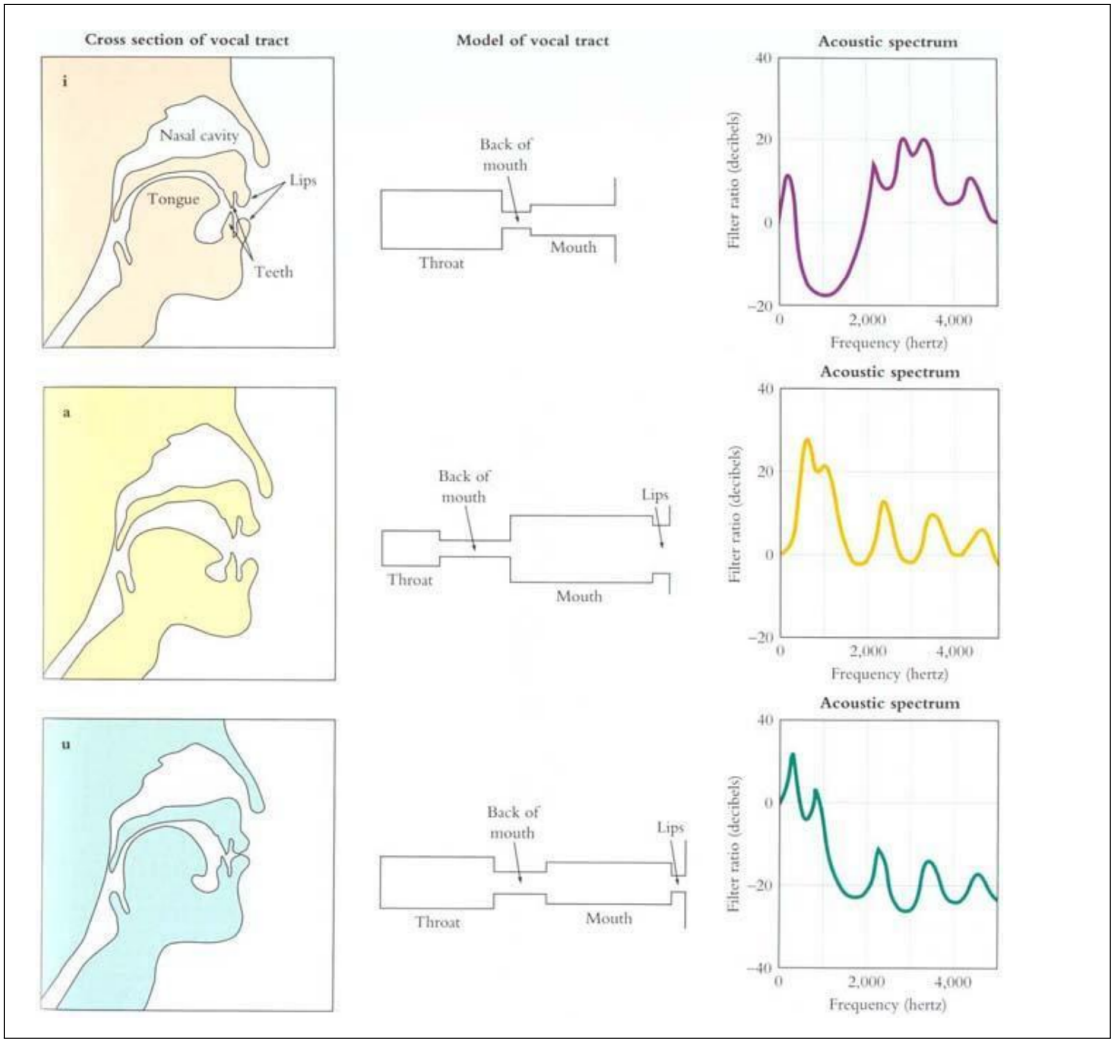
[محتوای افزوده] مقادیر نوعی فرمنت واکه‌ها (مردان بالغ، تقریبی)

واکه	$F_۱$ (هرتز)	$F_۲$ (هرتز)	$F_۳$ (هرتز)
/i/ (مانند «ای»)	۲۷۰	۲۲۹۰	۳۰۱۰
/a/ (مانند «آ»)	۷۳۰	۱۰۹۰	۲۴۴۰
/u/ (مانند «او»)	۳۰۰	۸۷۰	۲۲۴۰

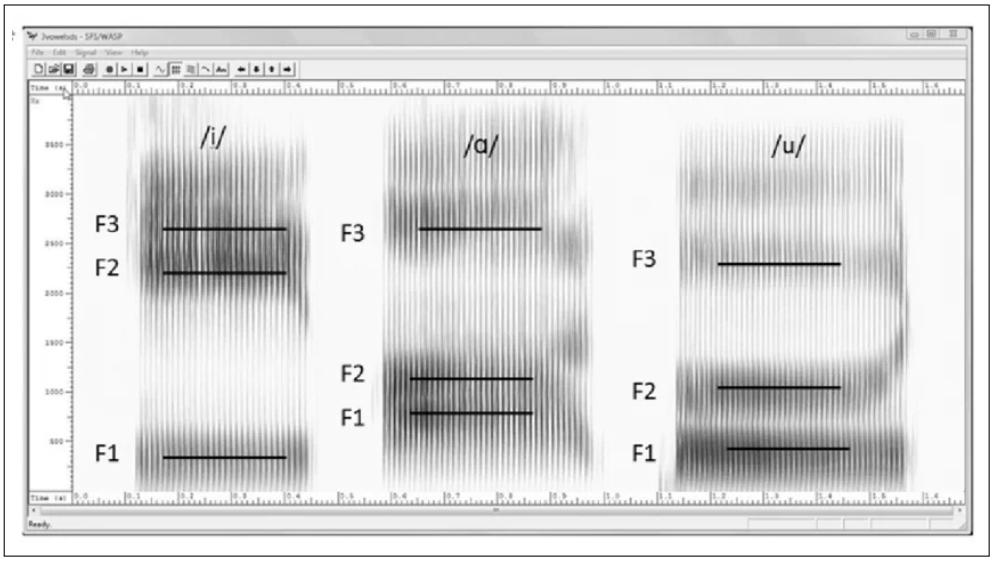
این اعداد میانگین‌های واکه‌های انگلیسی مطالعهٔ کلاسیک پترسون و بارنی (۱۹۵۲) هستند و فقط برای نشان‌دادن الگو آورده شده‌اند؛ مقادیر واکه‌های فارسی و گویندگان مختلف کمی فرق دارد. الگوی کلی مطابق کلاس است: $F_۱$ در «ای» و «او» کم و در «آ» زیاد، و $F_۲$ در «ای» خیلی بالا و در «او» پایین است.

۴.۸.۳ فرمنت‌ها و طول مجرای صوتی

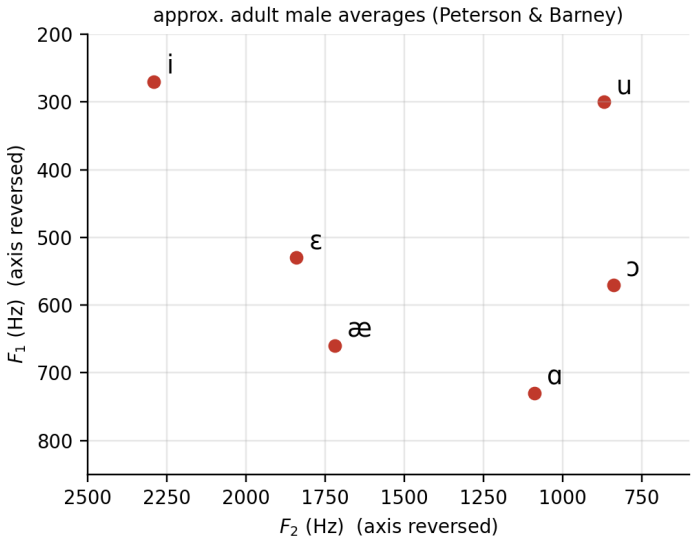
طول مجرای صوتی (که ویژگی فیلتر است، نه منبع) بر محدودهٔ فرکانسی فرمنت‌ها اثر دارد: هرچه مجرا بلندتر، فرمنت‌ها پایین‌تر (به سمت فرکانس‌های بم‌تر) می‌روند و هرچه کوتاه‌تر، فرمنت‌ها بالاتر می‌روند. معمولاً مجرای مردان بلندتر است. این یکی از دلایلی است که $F_۰$ به‌تنهایی جنسیت را مشخص نمی‌کند.



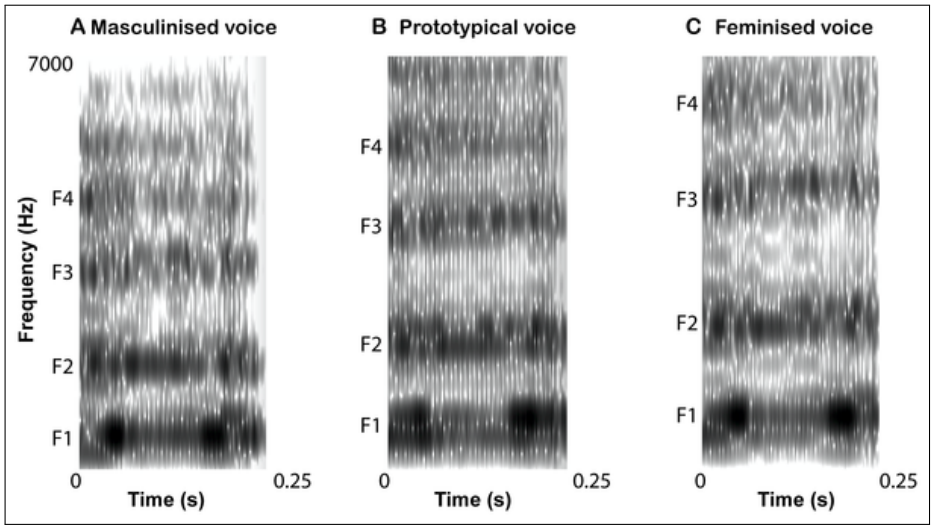
شکل ۱۳.۳: برای سه واکهٔ i، a و u: برش مجرای صوتی (چپ)، مدل لوله‌ای ساده آن (وسط) و طیف آکوستیکی یا پاسخ فرکانسی فیلتر (راست). با تغییر شکل مجرا، قله‌های تشدیدی (فرمنت‌ها) جابه‌جا می‌شوند. (برگرفته از تختهٔ کلاس)



شکل ۱۴.۳: اسپکتروگرام سه واکهٔ /i/، /a/ و /u/ با خطوط افقی که موقعیت F_1 تا F_3 را نشان می‌دهند. در /i/ فاصلهٔ F_1 و F_2 بسیار زیاد است؛ در /a/ فرمنت اول بالاتر از دو واکهٔ دیگر است؛ در /u/ هر دو فرمنت اول و دوم پایین‌اند. (برگرفته از تختهٔ کلاس)



شکل ۱۵.۳: نقشهٔ آکوستیکی واکه‌ها در صفحهٔ F_2-F_1 (با محورهای معکوس). این نمودار شبیه نقشهٔ واکه‌ها در آواشناسی تولیدی است: واکه‌های جلویی و بسته بالا و چپ، واکه‌های بازتر پایین‌تر، و واکه‌های عقبی سمت راست قرار می‌گیرند (شکل افزوده).



شکل ۱۶.۳: اسپکتروگرام یک واکه برای سه نسخه از صدا: مردانه‌شده، نمونه، و زنانه‌شده. با حرکت از صدای مردانه به زنانه، فرمنت‌های F_1 تا F_4 به سمت فرکانس‌های بالاتر جابه‌جا می‌شوند. (برگرفته از تختهٔ کلاس)

۵.۸.۳ هارمونیک در برابر فرمنت

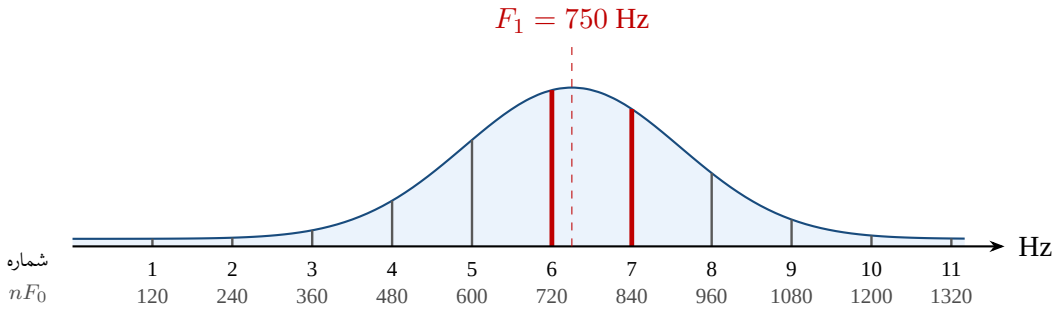
ویژگی	هارمونیک (Harmonic)	فرمنت (Formant)
منشأ اصلی	تناوب منبع صوتی (تارها)	تشدیدهای مجرای صوتی
نوع نمایش	مؤلفه‌ای در فرکانس مشخص	ناحیه یا قلهٔ تشدیدی در پوش طیف
ارتباط با F_0	مضارب صحیح F_0	لزوماً مضرب صحیح F_0 نیست
کاربرد در بحث	بررسی ساختار منبع و Pitch	بررسی ویژگی‌های تولیدی و واکه‌ها

[محتوای افزوده] مثال عددی: کدام هارمونیک‌ها تقویت می‌شوند؟

فرض کنید $F_0 = ۱۲۰$ هرتز و $F_1 = ۷۵۰$ هرتز باشد. هارمونیک‌ها عبارت‌اند از:

n	۱	۲	۳	۴	۵	۶	۷	۸
nF_0 (هرتز)	۱۲۰	۲۴۰	۳۶۰	۴۸۰	۶۰۰	۷۲۰	۸۴۰	۹۶۰

فاصلهٔ آن‌ها تا ۷۵۰ هرتز: H_6: ۳۰، H_7: ۹۰، H_5: ۱۵۰، H_8: ۲۱۰ هرتز. پس هارمونیک‌های ششم و هفتم (۷۲۰ و ۸۴۰) بیشترین تقویت را می‌گیرند و ششم از همه به فرمنت نزدیک‌تر است. میزان دقیق تقویت به شکل و پهنای قلهٔ تشدیدی بستگی دارد؛ همین است که فرمنت در اسپکتروگرام یک ناحیهٔ پررنگ است، نه یک خط. این همان مثالی است که روی تخته با فهرست ۱۳۲۰ , ۲۴۰, . . . , ۱۲۰ هرتز بررسی شد (شکل ۱۷.۳).



شکل ۱۷.۳: مثال تخته: با $F_0 = ۱۲۰$ هرتز و $F_1 = ۷۵۰$ هرتز، هارمونیک‌ها در ۱۲۰، ۲۴۰، ۳۶۰، ...هرتز قرار دارند و شمارهٔ هرکدام زیر آن نوشته شده است. هارمونیک‌های نزدیک به قلهٔ تشدیدی (ششم و هفتم، ۷۲۰ و ۸۴۰ هرتز، با رنگ قرمز) بیشترین تقویت را می‌گیرند؛ منحنی آبی شکل کلی فیلتر مجرای صوتی است (منحنی افزوده) (بازسازی‌شده از تختهٔ کلاس).

۹.۳ اسپکتروگرام باند باریک و باند پهن

۱.۹.۳ مبادله میان وضوح زمانی و فرکانسی

کلید فهم دو نوع اسپکتروگرام، یک مبادله (trade-off) بنیادی است:

- پنجرهٔ **کوتاه**: تغییرات سریع در زمان بهتر دیده می‌شوند، اما توان تفکیک فرکانس‌های نزدیک کم می‌شود.
- پنجرهٔ **بلند**: فرکانس‌های نزدیک بهتر تفکیک می‌شوند، اما تغییرات سریع زمانی محو می‌شوند.

وضوح فرکانسی تقریباً با معکوس طول پنجره متناسب است ($\Delta f \sim ۱/L$).

باند پهن در برابر باند باریک

باند پهن (Wideband): پنجرهٔ کوتاه، حدود ۳ تا ۵ میلی‌ثانیه (استاد مثال ۵ میلی‌ثانیه زدند). وضوح زمانی بالا، وضوح فرکانسی پایین؛ هارمونیک‌ها در هم ادغام می‌شوند و بیشتر پوش طیفی، یعنی فرمنت‌ها، دیده می‌شود.
باند باریک (Narrowband): پنجرهٔ بلندتر، حدود ۲۰ تا ۵۰ میلی‌ثانیه (در ابزار کلاس ۳۰ میلی‌ثانیه). وضوح فرکانسی بالا، وضوح زمانی پایین؛ هارمونیک‌ها به‌صورت خطوط افقی باریک و مجزا دیده می‌شوند.

ویژگی	باند پهن	باند باریک
طول پنجره	کوتاه	بلند
وضوح زمانی	بالا	پایین
وضوح فرکانسی	پایین	بالا
نمایش مناسب‌تر	فرمنت‌ها	هارمونیک‌ها

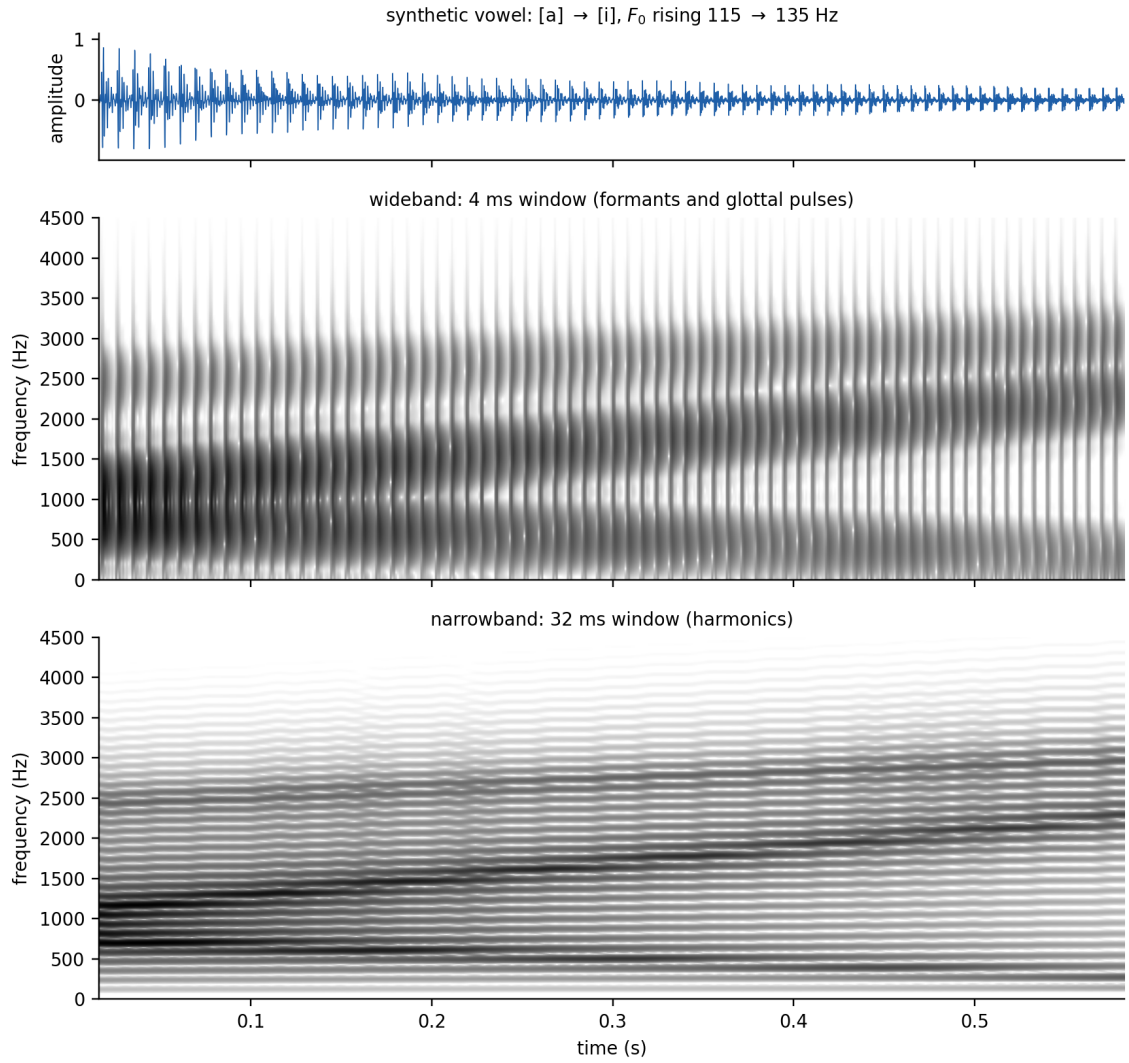
نکتهٔ مهم استاد: این دو نوع اسپکتروگرام مربوط به دو سیگنال متفاوت نیستند؛ هر دو از یک سیگنال با تفاوت تنظیم پنجره ساخته می‌شوند. به بیان تخته: اگر دقت زمانی (رزولوشن زمانی) می‌خواهیم و به فرمنت‌ها علاقه‌مندیم ⇐ wideband؛ اگر دقت زمانی را قربانی می‌کنیم و رزولوشن فرکانسی (هارمونیک‌ها) می‌خواهیم ⇐ narrowband.

[محتوای افزوده] مثال عددی: پهنای باند تحلیل

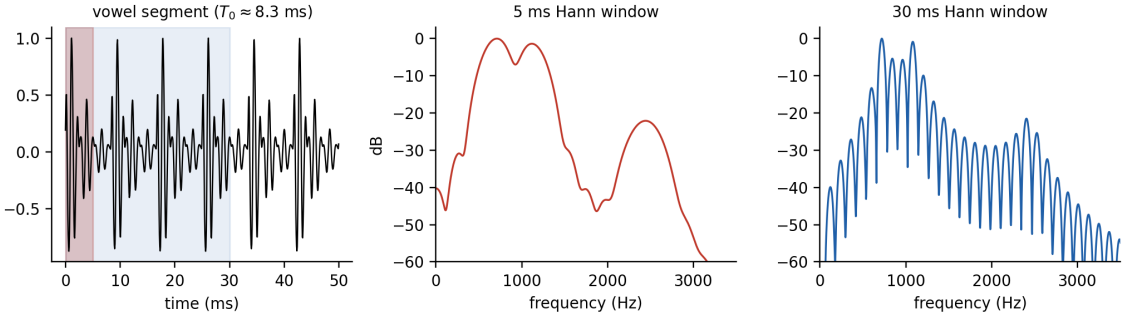
پهنای باند مؤثر یک پنجرهٔ هان تقریباً $۱٫۵/L$ است. اگر $F_۰ = ۱۲۰$ هرتز:

- پنجره ۴ میلی‌ثانیه: $۱٫۵/۰٫۰۰۴ \approx ۳۷۵$ هرتز. از آنجا که از فاصلهٔ هارمونیک‌ها (۱۲۰ هرتز) بیشتر است، هارمونیک‌ها در هم می‌روند. فقط پوش (فرمنت) می‌ماند. چون پنجره از یک دورهٔ تناوب (۸٫۳ میلی‌ثانیه) کوتاه‌تر است، هر تپ چاکنایی جداگانه دیده می‌شود (خطوط عمودی).
- پنجره ۳۲ میلی‌ثانیه: $۱٫۵/۰٫۰۳۲ \approx ۴۷$ هرتز. این از ۱۲۰ هرتز کمتر است، پس هر هارمونیک جداگانه دیده می‌شود. این پنجره حدود ۴ دورهٔ تناوب را پوشش می‌دهد.

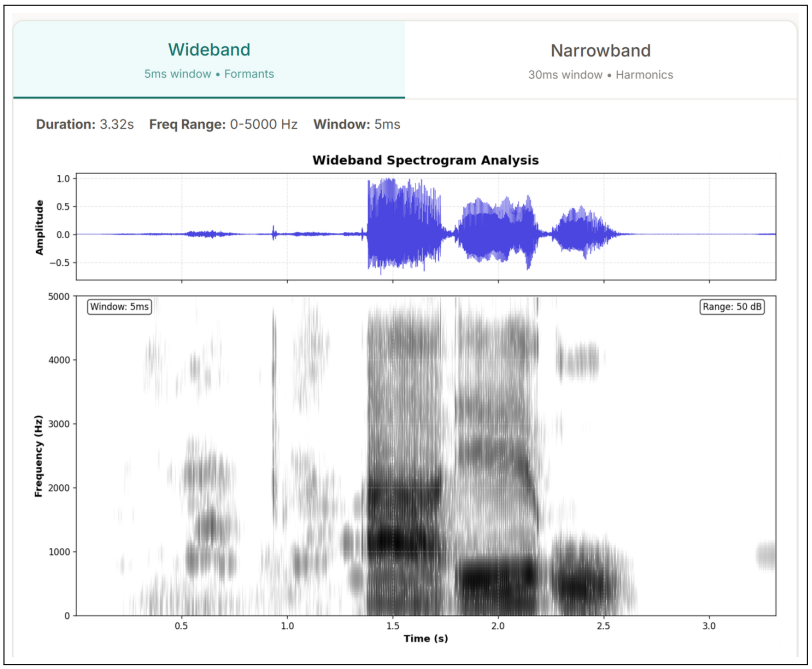
قاعدهٔ سرانگشتی: برای باند باریک پنجره باید چند دورهٔ تناوب $T_۰$ را بپوشاند و برای باند پهن حدود یک دوره یا کمتر.



شکل ۱۸.۳: اسپکتروگرام باند پهن (پنجرهٔ ۴ میلی‌ثانیه) و باند باریک (پنجرهٔ ۳۲ میلی‌ثانیه) از یک واکهٔ ترکیبی که به‌تدریج از «آ» به «ای» می‌رود و $F_۰$ آن اندکی بالا می‌رود. باند پهن نوارهای فرمنتی ($F_۱$ پایین‌رونده، $F_۲$ بالارونده) و خطوط عمودی تپ‌های چاکنایی را نشان می‌دهد؛ باند باریک خطوط افقی هارمونیک‌ها را نشان می‌دهد که با افزایش $F_۰$ اندکی شیب می‌گیرند (شکل افزوده).



شکل ۱۹.۳: طیف یک فریم از یک واکهٔ پایدار ($F_0 = ۱۲۰$ هرتز) با دو طول پنجره. چپ: بخش‌هایی از موج که توسط پنجره‌ها پوشانده می‌شوند. وسط: پنجرهٔ ۵ میلی‌ثانیه که هارمونیک‌ها را محو و فقط پوش فرمنتی را نشان می‌دهد. راست: پنجرهٔ ۳۰ میلی‌ثانیه که هارمونیک‌ها را مجزا نشان می‌دهد (شکل افزوده).



شکل ۲۰.۳: خروجی ابزار پایتونی کلاس برای یک کلمه: زبانهٔ باند پهن (پنجرهٔ ۵ میلی‌ثانیه، مناسب فرمنت‌ها) و زبانهٔ باند باریک (پنجرهٔ ۳۰ میلی‌ثانیه، مناسب هارمونیک‌ها). بالا شکل موج و پایین اسپکتروگرام است. (برگرفته از تختهٔ کلاس)

۲.۹.۳ چرا باند پهن برای فرمنت‌ها مناسب‌تر است؟

فرمنت‌ها با تغییر وضعیت زبان و دهان تغییر می‌کنند و این تغییرات در بازه‌های بسیار کوتاه رخ می‌دهد؛ پس برای ردگیری آن‌ها وضوح زمانی خوب لازم است. در باند پهن علاوه بر این، به‌دلیل ادغام هارمونیک‌ها، پوش فرمنتی به‌صورت نوار پیوسته دیده می‌شود. در باند باریک تمرکز بر تفکیک دقیق هارمونیک‌هاست.

۱۰.۳ پرسش و پاسخ

آیا می‌توان هارمونیک‌ها و فرمنت‌ها را کاملاً جدا کرد؟
خیر. استاد تأکید کردند که این دو در سیگنال نهایی مستقل از هم دیده نمی‌شوند: فیلتر مجرا روی طیف منبع اثر گذاشته و هر دو در سیگنال حضور دارند. با تغییر نوع اسپکتروگرام می‌توان یکی از دو ساختار را بهتر دید، ولی دیگری از سیگنال حذف نمی‌شود.

اگر دهان ثابت بماند، آیا فرمنت‌ها حذف می‌شوند؟
خیر. استاد ابتدا برای سادگی از ضعیف‌شدن بعضی فرمنت‌ها گفتند ولی بعد روشن کردند که حتی برای یک «آ»ی ثابت هم اثر تشدید مجرا وجود دارد. اگر شکل مجرا ثابت بماند، مشخصات فیلتر تقریباً ثابت می‌ماند اما فیلتر همچنان هست. به بیان دیگر، فرمنت‌ها در اسپکتروگرام به‌صورت نوارهای افقی نسبتاً ثابت دیده می‌شوند.

آیا با تغییر فرمنت‌ها Pitch از بین می‌رود؟
خیر. فیلتر بر دامنهٔ هارمونیک‌ها اثر می‌گذارد، نه بر فرکانس پایه. ممکن است برخی هارمونیک‌ها بسیار ضعیف شوند، ولی ساختار تناوبی همچنان وجود دارد. باید بین تغییر Pitch (منبع) و تغییر ویژگی‌های طیفی (فیلتر) تفاوت گذاشت.

آیا با دیدن اسپکتروگرام می‌توان زن و مرد را تشخیص داد؟
در کلاس چند نمونه اسپکتروگرام نمایش داده شد و از دانشجویان خواسته شد گوینده را حدس بزنند. نشانه‌ها عبارت‌اند از فاصلهٔ هارمونیک‌ها (F_0) و محدودهٔ فرمنت‌ها (طول مجرا). ولی همان‌طور که گفته شد، Pitch به‌تنهایی تعیین‌کننده نیست.

آیا فرمنت‌ها را می‌توان به‌صورت عددی استخراج کرد؟
بله؛ می‌توان به‌جای مشاهدهٔ بصری، مقادیر $F_1, F_2, \ldots$ را الگوریتمی استخراج کرد و به‌عنوان ویژگی‌های عددی در تحلیل‌های بعدی به کار برد. جزئیات الگوریتم‌های استخراج فرمنت در این جلسه بررسی نشد.

آیا تشخیص فرمنت یعنی «ساختن» آن؟
خیر، ما در تحلیل، فرمنت‌ها را از سیگنال استخراج می‌کنیم؛ آن‌ها پیش‌تر در فرایند تولید ساخته شده‌اند.

۱۱.۳ کاربردهای اسپکتروگرام و تمرین

استاد توضیح دادند که اسپکتروگرام فقط ابزاری آموزشی برای نمایش فرکانس‌ها نیست. برای مثال در **تشخیص احساس از گفتار** (Speech Emotion Recognition) می‌توان اطلاعات طیفی را برای تحلیل یا دسته‌بندی ویژگی‌های

احساسی صدا به کار برد. استاد به مقاله‌ای در سال ۲۰۲۶ اشاره کردند که (به گفتهٔ ایشان) از نمایش اسپکتروگرام در یک مسئلهٔ تشخیص احساس استفاده کرده بود؛ عنوان یا اطلاعات دقیق مقاله در جلسه ذکر نشد. هدف، نشان‌دادن کاربرد اسپکتروگرام در سامانه‌های واقعی و رویکردهای سبک‌تر پردازشی بود. در جلسات آینده نمونه‌هایی از مدل‌های یادگیری که از این ویژگی‌ها استفاده می‌کنند بررسی خواهد شد.

در بخش عملی نیز استاد ابزاری پایتونی (مبتنی بر پردازش سیگنال، نه یادگیری ماشین) را نشان دادند که اسپکتروگرام یک کلمه («سیب») را نمایش می‌داد و کاربردهایی در گفتاردرمانی دارد. در اولین نمایش خطوط هارمونیکی واضح‌تر بودند و سؤال این بود که چگونه نمایش را تغییر دهیم تا فرمنت‌ها بهتر دیده شوند؛ پاسخ، تنظیم اندازهٔ پنجره (باند پهن) بود. نام دقیق ابزار در یادداشت‌ها مشخص نیست.

تمرین اول: اسپکتروگرام

استاد اعلام کردند که تمرین اول درس با اسپکتروگرام مرتبط است. جزئیات اجرایی و صورت دقیق تمرین در این جلسه بیان نشد. بر اساس مطالب این فصل، مفاهیم لازم برای تمرین عبارت‌اند از:

- بررسی شکل موج (Waveform) گفتار؛
- شناخت F_0 و هارمونیک‌ها؛
- تبدیل فوریه و پنجره‌بندی؛
- تولید و تحلیل اسپکتروگرام؛
- تفاوت باند پهن و باند باریک؛
- مشاهده و تفسیر فرمنت‌ها.

[محتوای افزوده] مثال کد: رسم دو نوع اسپکتروگرام (برای آمادگی تمرین)

```
import numpy as np, matplotlib.pyplot as plt
from scipy.io import wavfile
fs, x = wavfile.read("sib.wav")        # fs e.g. 16000 Hz
x = x.astype(float)
for ms, title in [(5, "wideband"), (30, "narrowband")]:
    L = int(fs * ms / 1000)            # window length in samples
    plt.figure()
    plt.specgram(x, NFFT=L, Fs=fs, noverlap=L - L // 8,
                 window=np.hanning(L), cmap="gray_r")
    plt.title(f"{title}: {ms} ms window")
    plt.xlabel("time (s)"); plt.ylabel("frequency (Hz)")
plt.show()
```

اگر $f_s = ۱۶۰۰۰$ باشد، ۵ میلی‌ثانیه برابر ۸۰ نمونه و ۳۰ میلی‌ثانیه برابر ۴۸۰ نمونه است. فایل sib.wav فرضی است.

۱۲.۳ جمع‌بندی

این فصل از موج صوتی در حوزهٔ زمان شروع شد و به ویژگی‌هایی رسید که ویژگی‌های تولیدی گفتار را در سیگنال آکوستیکی نشان می‌دهند:

مفهوم	تعریف و نقش
شکل موج	دامنهٔ سیگنال (انحراف فشار هوا) در طول زمان
فرکانس پایه $F_۰$	$۱/T_۰$؛ مرتبط با Pitch؛ به طول، جرم و کشش تارها وابسته
تبدیل فوریه	تجزیهٔ سیگنال به مؤلفه‌های فرکانسی (بزرگی و فاز)
هارمونیک‌ها	مضارب صحیح $F_۰$، با فاصلهٔ برابر $F_۰$
اسپکتروگرام	بزرگی STFT؛ تغییرات محتوای فرکانسی در طول زمان
منبع	ارتعاش تارها (واک‌دار) که هارمونیک‌ها را می‌سازد
فیلتر	مجرای صوتی؛ طیف منبع را تقویت/تضعیف می‌کند
فرمنت‌ها	نواحی تشدید مجرا ($F_۱ < F_۲ < F_۳$)
$F_۲$ / $F_۱$	ارتفاع زبان یا بازشدگی دهان / جلو-عقب‌بودن زبان
باند پهن	پنجرهٔ کوتاه؛ وضوح زمانی بالا؛ فرمنت‌ها
باند باریک	پنجرهٔ بلند؛ وضوح فرکانسی بالا؛ هارمونیک‌ها

رابطه با جلسهٔ قبل: آواشناسی تولیدی وضعیت زبان، دهان و اندام‌ها را توصیف می‌کند؛ مدل منبع-فیلتر آن را به تحریک تارها و فیلتر مجرا ترجمه می‌کند؛ ویژگی‌های آکوستیکی ($F_۰$، هارمونیک‌ها، فرمنت‌ها) آثار قابل‌اندازه‌گیری آن هستند و اسپکتروگرام ابزار مشاهده و تحلیل آن‌ها است.

نکات مهم برای مرور و امتحان

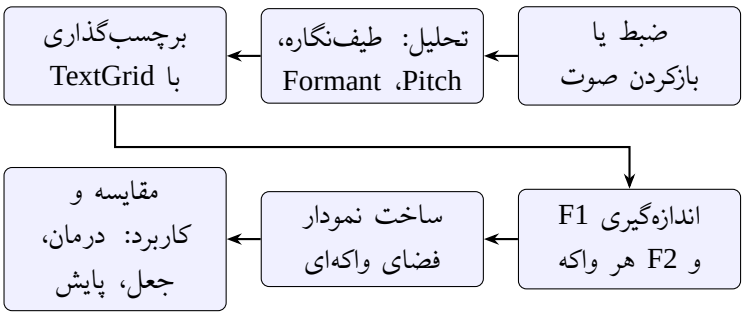
- نمره: ۱۰ عملی (گزارش یا ارائه) + ۱۰ نظری (میان‌ترم و پایان‌ترم)؛ تمرین اول دربارهٔ اسپکتروگرام است.
- $F_۰$ ویژگی فیزیکی و Pitch ویژگی ادراکی است؛ $F_۰$ بالاتر یعنی صدای زیرتر. $F_۰$ و Pitch به‌تنهایی جنسیت را تعیین نمی‌کنند؛ طول مجرای صوتی نیز مؤثر است.
- هارمونیک‌ها در $nF_۰$ هستند و فاصلهٔ آن‌ها $F_۰$ است؛ $F_۰$ بزرگ‌تر یعنی هارمونیک‌های دورتر از هم.
- تبدیل فوریه نشان می‌دهد چه فرکانس‌هایی در سیگنال هستند؛ اسپکتروگرام = پنجره‌بندی + فوریه برای هر پنجره + کنار هم چیدن (محور افقی زمان، عمودی فرکانس، رنگ بزرگی).
- فرکانس و دامنه متفاوت‌اند.
- مدل منبع-فیلتر: $\text{Output}(f) = \text{Source}(f) \times \text{Filter}(f)$. منبع = تارهای صوتی (برای صداهای واک‌دار)، فیلتر = مجرای صوتی.
- فرمنت یک ناحیهٔ تشدیدی مجراست نه یک هارمونیک؛ $F_۱$ با ارتفاع/بازشدگی و $F_۲$ با جلو/عقب بودن زبان مرتبط است. مجرای بلندتر، فرمنت‌های پایین‌تر.
- باند پهن (پنجرهٔ کوتاه، مثلاً ۵ میلی‌ثانیه) ← فرمنت‌ها و وضوح زمانی؛ باند باریک (پنجرهٔ بلند، مثلاً ۳۰ میلی‌ثانیه) ← هارمونیک‌ها و وضوح فرکانسی؛ هر دو از یک سیگنال‌اند.

- هارمونیک‌ها و فرمنت‌ها در خروجی از هم مستقل دیده نمی‌شوند؛ فرمنت‌ها در تحلیل «شناسایی» می‌شوند، نه «ساخته».
- مثال کلاسی: $F_0 = ۱۲۰$ و $F_1 = ۷۵۰$ هرتز ⇐ هارمونیک‌های ششم (۷۲۰) و هفتم (۸۴۰) بیشتر تقویت می‌شوند.

فصل ۴

فرمنت‌ها، نرم‌افزار Praat و فضای واکه‌ای

در جلسهٔ پیش، سیگنال گفتار را به مؤلفه‌های فرکانسی تجزیه کردیم و با هارمونیک‌ها، اسپکتروگرام و مدل منبع-فیلتر آشنا شدیم. هدف این جلسه گام بعدی است: چگونه از روی سیگنال صوتی، ویژگی‌های **آکوستیکی** (Acoustic) مانند F1 و F2 را اندازه بگیریم و آن‌ها را به ویژگی‌های **تولیدی** (Articulatory) مانند ارتفاع و جلو یا عقب‌بودن زبان نگاشت کنیم. ابزار عملی این کار نرم‌افزار Praat است و نتیجهٔ کار، **فضای واکه‌ای** (Vowel Space) است که در گفتاردرمانی، تشخیص صدای جعلی و پایش بیماری‌های عصبی به کار می‌رود.



شکل ۱.۴: زنجیرهٔ مفهومی جلسه: از ضبط صوت تا کاربردهای فضای واکه‌ای (شکل افزوده).

۱.۴ مرور کوتاه: از فرکانس پایه تا فرمنت

جزئیات فوریه، هارمونیک‌ها، اسپکتروگرام و مدل منبع-فیلتر در فصل ۳ آمده است. این‌جا فقط نکته‌هایی را که در ابتدای این جلسه برای پاسخ به پرسش‌ها مرور شد، فشرده می‌آوریم.

- **فرکانس پایه.** اگر یک موج تناوبی در هر T ثانیه یک دورهٔ کامل بزند، $f_0 = 1/T$ است. برای تشخیص زیروبمی (Pitch) به جای همهٔ نوسان‌های ریز، تکرار قله‌های اصلی، یعنی کندترین الگوی تناوبی، را در نظر می‌گیریم. در مدل منبع-فیلتر، f_0 به منبع (چین‌های صوتی) و فرمنت‌ها به فیلتر (مجرای صوتی) مربوط‌اند.
- **ضریب فوریه.** خروجی تبدیل فوریه برای هر مؤلفهٔ فرکانسی یک عدد مختلط $X = a + jb$ است. اندازهٔ آن $|X| = \sqrt{a^2 + b^2}$ میزان مشارکت آن فرکانس در سیگنال (Magnitude) و زاویهٔ آن فاز است.

- **دامنه و Magnitude.** دامنه (Amplitude) مقدار سیگنال در حوزهٔ زمان است؛ در اسپکتروگرام محور افقی زمان، محور عمودی فرکانس و رنگ، Magnitude (یا توان) هر مؤلفه است. این دو را نباید یکی دانست، هرچند به هم مرتبط‌اند. رنگ گرم‌تر یعنی مقدار طیفی بیشتر.
- **تعامد.** موج‌های مبنا باید نسبت به هم متعامد باشند تا هر کدام مؤلفه‌ای مستقل را بسنجند: ضرب داخلی دو موج در بازه صفر باشد، یعنی $\int_0^T x_1(t)x_2(t)\,dt = 0$ یا در حالت گسسته $\sum_{n=0}^{N-1} x_1[n]x_2[n] = 0$. موج‌هایی که در بازهٔ T تعداد صحیحی دوره می‌زنند (فرکانس‌های $1/T,\ 2/T,\ 3/T, \ldots$) چنین مجموعه‌ای می‌سازند.
- **هارمونیک‌ها.** فرکانس‌های هارمونیک $f_n = nf_0$ هستند، اما ضریب برخی از آن‌ها می‌تواند صفر یا ناچیز باشد. مثال کلاس موج مربعی با چرخهٔ کاری ۵۰ درصد بود که فقط هارمونیک‌های فرد ($f_0, 3f_0, 5f_0, \ldots$) را دارد؛ نبودن هارمونیک زوج یعنی ضریبش صفر است، نه این‌که از مجموعهٔ فرکانس‌های مبنا بیرون باشد.

پرسش و پاسخ: آیا تعداد هارمونیک‌ها بی‌نهایت است؟

از نظر ریاضی مضرب‌های صحیح f_0 بی‌پایان‌اند، اما در عمل بالاترین فرکانس قابل تحلیل را نرخ نمونه‌برداری (حداکثر نصف آن، قضیهٔ نایکویست) و هدف تحلیل محدود می‌کند. در تحلیل گفتار فقط بخشی از طیف که برای مسئله اطلاعات مفید دارد بررسی می‌شود. برای تعیین «هارمونیک‌های مهم» می‌توان بر اندازهٔ ضرایب آستانه گذاشت.

۱.۱.۴ هارمونیک در برابر فرمنت

هارمونیک‌ها ویژگی سیگنال تناوبی (منبع) هستند، در حالی که **فرمنت‌ها** (Formants) نواحی تشدید مجرای صوتی (فیلتر) را توصیف می‌کنند و به صورت برآمدگی‌های پوش طیفی دیده می‌شوند. با نگاه به هارمونیک‌ها تنها نمی‌توان فهمید زبان در کجاست؛ برای تحلیل نحوهٔ تولید واکه باید فرمنت‌ها را استخراج کرد. یکی از روش‌های رایج تخمین فرمنت، **کدگذاری پیش‌بینی خطی** (Linear Predictive Coding (LPC)) است؛ روش‌های دیگری هم وجود دارند که از محدودهٔ این بخش بیرون‌اند.

جدول ۱.۴: مقایسهٔ اسپکتروگرام پهن‌باند و باریک‌باند

ویژگی	Wideband	Narrowband
طول پنجرهٔ تحلیل	کوتاه‌تر (حدود ۵ میلی‌ثانیه)	بلندتر
تفکیک زمانی	بیشتر	کمتر
تفکیک فرکانسی	کمتر	بیشتر
ظاهر طیف	نواحی پهن انرژی؛ فرمنت‌ها و تغییرات سریع دیده می‌شوند	خطوط هارمونیکی جداگانه
کاربرد	دنبال‌کردن فرمنت‌ها و حرکت اندام‌ها	بررسی هارمونیک‌ها و f_0

وضوح زمانی مهم است چون زبان و سایر اندام‌های گفتار سریع جابه‌جا می‌شوند و برای نگاشت آکوستیک به تولید باید این تغییرات را دنبال کرد. به همین دلیل برای مشاهدهٔ فرمنت‌ها از نمای پهن‌باند استفاده می‌کنیم.

۲.۴ نگاشت ویژگی‌های آکوستیکی به ویژگی‌های تولیدی

در آواشناسی تولیدی (فصل ۲) واکه‌ها را با موقعیت زبان توصیف می‌کنیم: بالا یا پایین (بسته یا باز)، جلو یا عقب، و گرد یا غیرگرد بودن لب‌ها. در پردازش گفتار معمولاً موقعیت واقعی زبان را مستقیم اندازه نمی‌گیریم؛ در عوض ویژگی‌های آکوستیکی را از صوت استخراج و برای توصیف فضای واکه‌ای استفاده می‌کنیم. دو فرمنت اول بیشترین نقش را دارند.

نگاشت F1 و F2 به ویژگی‌های تولیدی

- **فرمنت اول** (F1): رابطهٔ معکوس با ارتفاع زبان. زبان بالاتر (واکهٔ بسته) ⇐ F1 کمتر؛ زبان پایین‌تر (واکهٔ باز) ⇐ F1 بیشتر.
- **فرمنت دوم** (F2): مرتبط با جلو یا عقب بودن زبان. زبان جلوتر ⇐ F2 بیشتر؛ زبان عقب‌تر ⇐ F2 کمتر.
- **گرد شدن لب** (Lip Rounding): باعث افت F2 می‌شود.

جدول ۲.۴: رابطهٔ جایگاه واکه با F1 و F2

جایگاه واکه	F1	F2
زبان بالا (بسته)	کم	بسته به جلو یا عقب‌بودن
زبان پایین (باز)	زیاد	بسته به جلو یا عقب‌بودن
زبان جلو	بسته به ارتفاع	زیاد
زبان عقب (و/یا لب گرد)	بسته به ارتفاع	کم

در جلسهٔ ۳ با دو مثال شهودی هم آشنا شدیم: جلو آوردن زبان محفظهٔ جلوی دهان را کوچک می‌کند و F2 بالا می‌رود، و طول مجرای صوتی روی دامنهٔ فرمنت‌ها اثر دارد (مجرای بلندتر، فرمنت‌های پایین‌تر).

دقت در رابطهٔ «ارتفاع زبان = F1»

قواعد فوق تقریبی هستند، نه قانونی دقیق. فرمنت‌ها تشدیدهای کل مجرای صوتی‌اند و به شکل مجموع سطح مقطع مجرا، از چین‌های صوتی تا لب‌ها، بستگی دارند، نه یک «حفرهٔ» مشخص. F1 علاوه بر ارتفاع زبان به باز بودن فک و تنگی حلق نیز حساس است (واکهٔ باز: دهان باز و حلق تنگ‌تر، F1 بالا). F2 به جلو یا عقب بودن زبان و گردی لب‌ها وابسته است. به همین دلیل واکهٔ عقبی گرد مانند /u/ هم F1 هم F2 پایین دارد. پرسش دانشجویی «آیا این رابطه قانون ثابت است؟» با همین نگاه پاسخ داده شد: رابطهٔ F1 با ارتفاع و F2 با جلوآمدگی یک قاعدهٔ کلی آواشناختی است، نه رابطه‌ای بدون استثنا برای همهٔ واکه‌ها و همهٔ افراد. هنگام بررسی یک گروه جدید این رابطه را از پیش «تعریف» نمی‌کنیم؛ مقادیر واقعی را اندازه می‌گیریم و تفاوت‌ها را تفسیر می‌کنیم.

[محتوای افزوده] مثال عددی: لولهٔ یکنواخت و اثر طول مجرا

مجرای صوتی در حالت خنثی را می‌توان با لولهٔ یک‌سر بسته (چین‌های صوتی) و یک‌سر باز (لب‌ها) مدل کرد. فرمنت‌ها در این مدل برابرند با

$$F_n = \frac{(۲n - ۱)\, c}{۴L}, \qquad n = ۱, ۲, ۳, \ldots$$

که $c \approx ۳۵۰۰۰$ سانتی‌متر بر ثانیه سرعت صوت در هوای گرم و مرطوب مجرا و L طول مجرا است. برای مرد

بزرگسال با $L \approx ۱۷٫۵$ سانتی‌متر:

$$F_۱ = \frac{۳۵۰۰۰}{۴ \times ۱۷٫۵} = ۵۰۰\ \text{Hz}, \quad F_۲ = ۱۵۰۰\ \text{Hz}, \quad F_۳ = ۲۵۰۰\ \text{Hz}.$$

برای مجرایی کوتاه‌تر با $L = ۱۱$ سانتی‌متر (مثلاً کودک): $F_۱ \approx ۷۹۵$ و $F_۲ \approx ۲۳۸۶$ هرتز. این همان دلیلی است که مقادیر فرمنت زنان و کودکان بالاتر از مردان است و فضای واکه‌ای باید برای هر گروه جداگانه ساخته شود. این مدل فقط تقریب مرتبهٔ اول است و اثر شکل زبان را در نظر نمی‌گیرد.

۳.۴ کار عملی با Praat

Praat نرم‌افزار رایگان و متن‌باز تحلیل و برچسب‌گذاری گفتار است که توسط Paul Boersma و David Weenink در دانشگاه آمستردام توسعه یافته است. استاد آن را برای پل زدن میان ویژگی‌های آکوستیکی و تولیدی معرفی کرد. در این جلسه تمرکز بر دو کار بود: استخراج فرمنت‌ها و برچسب‌گذاری (Annotation).

۱.۳.۴ ضبط یا بازکردن صوت و محیط تحلیل

استاد چند واکه («ای»، «آ»، «او») را ضبط کرد و با نام Test ذخیره کرد. در محیط تحلیل Praat سه لایه روی هم دیده می‌شود:

- **شکل موج** در بالا.
- **طیف‌نگاره** (Spectrogram) در پس‌زمینه.
- منحنی آبی‌رنگ Pitch (فرکانس پایه) و نقطه‌ها یا خطوط قرمز Formants که روی طیف‌نگاره رسم می‌شوند.

با کلیک روی هر لحظه از سیگنال، مقدار فرمنت‌ها در همان لحظه نمایش داده می‌شود. نمونهٔ نمایش‌داده‌شده در کلاس در یک لحظه چنین بود: F1 حدود ۳۴۰ هرتز، F2 حدود ۲۰۰۰ هرتز، F3 حدود ۳۰۰۰ هرتز و F4 نیز قابل نمایش است. این اعداد فقط یک اندازه‌گیری لحظه‌ای هستند (الگوی آن شبیه واکهٔ بسته و جلویی /i/ است) و برای همهٔ واکه‌ها ثابت نیستند. واحد فرمنت‌ها هرتز است.

[محتوای افزوده] راهنمای گام‌به‌گام Praat

۱. **ضبط:** در پنجرهٔ اشیا (Objects) از منوی New → Record mono Sound... استفاده کنید؛ پس از ضبط Save to list را بزنید. فایل موجود را با Open → Read from file... بخوانید. برای ضبط با کیفیت، میکروفون نزدیک و محیط ساکت و نرخ نمونه‌برداری ۴۴۱۰۰ یا ۱۶۰۰۰ هرتز مناسب است.

۲. **نمایش:** شیء Sound را انتخاب و دکمهٔ View & Edit را بزنید.

۳. **لایه‌های تحلیل** در منوهای ویرایشگر: Spectrum → Show spectrogram، Pitch → Show pitch، Intensity → Show intensity، Formant → Show formants. هر منو یک گزینهٔ settings ... برای

تنظیم پارامترها دارد.

۴. **پرسش مقدار:** نشانگر را روی نقطه‌ای بگذارید یا یک بازه را انتخاب کنید و از Formant → Get first formant یا Get second formant و مشابه آن‌ها (برای Pitch و Intensity هم گزینهٔ Get وجود دارد) استفاده کنید. برای بازهٔ انتخاب‌شده معمولاً میانگین گزارش می‌شود.

تنظیمات مهم

[محتوای افزوده] مقادیر پیش‌فرض و تنظیم‌های پیشنهادی Praat

مقادیر زیر پیش‌فرض‌های متداول ویرایشگر Praat هستند (ممکن است در نسخه‌های مختلف اندکی تفاوت داشته باشند).

- **طیف‌نگاره:** بازهٔ نمایش (View range) ۰ تا ۵۰۰۰ هرتز؛ طول پنجره (Window length) ۰٫۰۰۵ ثانیه، یعنی پهن‌باند؛ بازهٔ پویا (Dynamic range) ۷۰ دسی‌بل. افزایش طول پنجره (مثلاً ۰٫۰۳ ثانیه) نمای باریک‌باند می‌دهد.
- **Pitch:** کف جست‌وجو حدود ۷۵ هرتز و سقف حدود ۵۰۰ تا ۶۰۰ هرتز. توصیهٔ مرسوم: مردان ۷۵ تا ۳۰۰ و زنان ۱۰۰ تا ۵۰۰ هرتز. بازهٔ نادرست باعث پرش یک اکتاو (نصف یا دو برابر شدن f_0) می‌شود.
- **Formant:** سقف فرمنت (Maximum formant) پیش‌فرض ۵۵۰۰ هرتز؛ تعداد فرمنت‌ها (Number of formants) برابر ۵؛ طول پنجره ۰٫۰۲۵ ثانیه؛ پیش‌تأکید (Pre-emphasis) از ۵۰ هرتز.
- **Intensity:** بازهٔ نمایش حدود ۵۰ تا ۱۰۰ دسی‌بل؛ روش میانگین‌گیری (Averaging method) بر پایهٔ انرژی؛ گزینهٔ Subtract mean pressure فعال.

سقف فرمنت (Maximum formant) را بر حسب گوینده تنظیم کنید

Praat فرمنت‌ها را با روش Burg (نوعی LPC) تخمین می‌زند و برای این کار سیگنال را تا دو برابر «سقف فرمنت» نمونه‌برداری مجدد می‌کند. اگر سقف مناسب گوینده نباشد، یک فرمنت واقعی از قلم می‌افتد یا فرمنت اضافی ساخته می‌شود. راهنمای معمول: حدود ۵۰۰۰ **هرتز برای مردان بزرگسال**، ۵۵۰۰ **هرتز برای زنان بزرگسال** (مقدار پیش‌فرض نرم‌افزار) و مقادیر بالاتر (مثلاً از ۶۰۰۰ هرتز به بالا) برای کودکان، با ۵ فرمنت. همیشه خروجی را با نگاه به طیف‌نگاره بازبینی کنید؛ تخمین LPC خودکار است و می‌تواند اشتباه کند (جابه‌جایی F1 و F2، ادغام دو فرمنت نزدیک، یا انتخاب هارمونیک به جای فرمنت وقتی f_0 بالا است، مانند صدای زنان و کودکان).

۲.۳.۴ اندازه‌گیری در یک بازه

لازم نیست فرمنت‌ها فقط در یک نقطه خوانده شوند. می‌توان بازهٔ مربوط به یک واکه را انتخاب کرد و از Praat میانگین فرمنت مورد نظر را خواست:

۱. بازهٔ زمانی واکهٔ «آ» را انتخاب می‌کنیم.

۲. میانگین F1 را درخواست می‌کنیم.

۳. میانگین F2 را نیز می‌گیریم.

۴. نتایج را برای تحلیل‌های بعدی ذخیره می‌کنیم.

[محتوای افزوده] نکتهٔ روش‌شناختی: کجا اندازه بگیریم؟

در پژوهش‌ها معمولاً فرمنت‌ها در میانهٔ واکه، مثلاً در ۵۰ درصد مدت آن، یا به صورت میانگین قسمت میانی (مثلاً ۲۰ تا ۸۰ درصد) خوانده می‌شوند، تا اثر گذار از همخوان‌های مجاور (هم‌تولیدی) کم شود. روش اندازه‌گیری باید در گزارش پژوهش دقیقاً بیان شود.

۳.۳.۴ برچسب‌گذاری گفتار با TextGrid

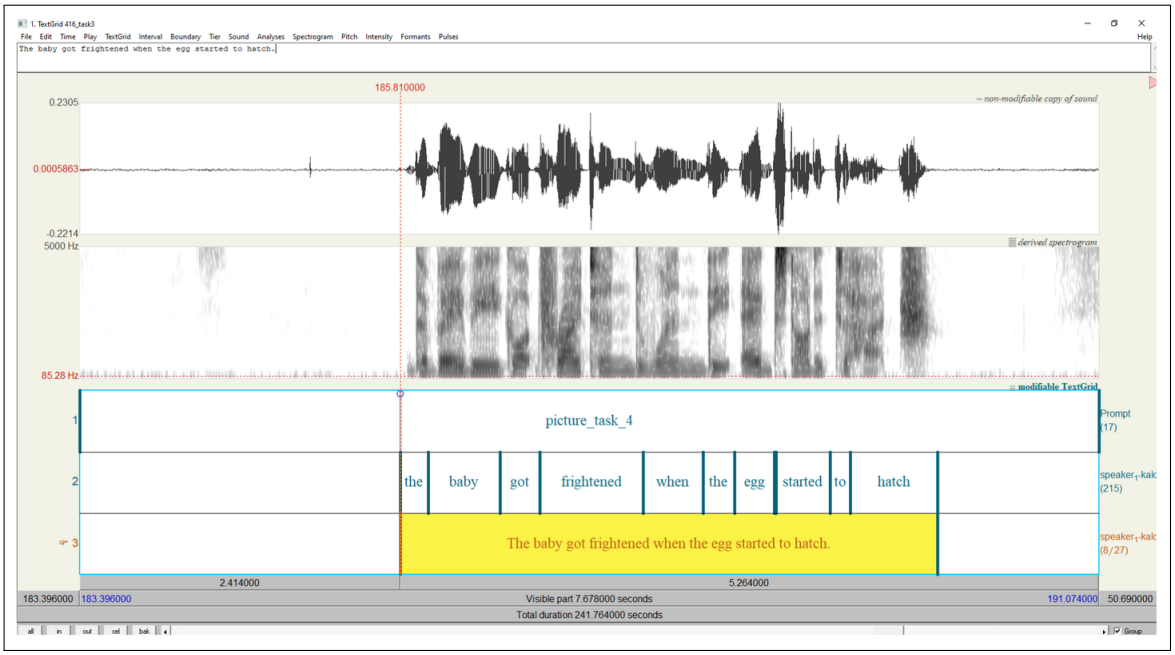
مهم‌ترین کاربرد Praat در این جلسه قابلیت Annotation بود: مشخص‌کردن مرزهای زمانی و برچسب‌زدن بخش‌های یک فایل صوتی. ساختار آن TextGrid نام دارد و از چند لایه (Tier) تشکیل می‌شود. استاد سه سطح را مثال زد:

لایه	برچسب‌ها
Word Tier (سطح واژه)	ای آ او
Syllable Tier (سطح هجا)	ای آ او
Phoneme Tier (سطح واج)	/i/ /ɑ/ /u/

در هر لایه مرزهای زمانی واحدها مشخص می‌شود؛ مثلاً در یک جمله، لایهٔ واژه جمله را به واژه‌ها، لایهٔ هجا به هجاها و لایهٔ واج به واج‌ها تقسیم می‌کند. با تعیین بازهٔ هر واکه یا همخوان می‌توان علاوه بر برچسب زبانی، اطلاعات آکوستیکی همان بازه را هم استخراج کرد. نتیجه مجموعه‌داده‌ای است که برای هر بازه می‌گوید چه واجی تولید شده، F1 و F2 آن چقدر بوده، و گوینده به کدام گروه آماری تعلق دارد.

[محتوای افزوده] جزئیات ساخت TextGrid

در Praat ابتدا صوت را انتخاب کنید و از Annotate → To TextGrid... نام لایه‌ها (مثلاً word phoneme) را وارد کنید. سپس هم Sound و هم TextGrid را انتخاب و View & Edit را بزنید. با کلیک در لایه و زدن Enter مرز اضافه می‌شود و با تایپ در بازهٔ بین دو مرز برچسب نوشته می‌شود. خروجی را با Save → Save as text file... ذخیره کنید. برای خودکارسازی اندازه‌گیری روی تعداد زیادی فایل، از اسکریپت‌نویسی Praat یا کتابخانهٔ پایتون Parselmouth (که Praat را از پایتون در دسترس می‌گذارد) استفاده می‌شود.



شکل ۲.۴: نمونهٔ یک TextGrid در Praat: شکل موج، طیف‌نگارهٔ مشتق‌شده و سه لایهٔ برچسب (راهنمای تکلیف، واژه‌ها، جملهٔ کامل) برای جملهٔ «The baby got frightened when the egg started to hatch» از مقالهٔ AusKidTalk. (برگرفته از تختهٔ کلاس)

۴.۴ ساخت پیکرهٔ گفتاری برای یک جامعهٔ آماری خاص

۱.۴.۴ چرا به دادهٔ اختصاصی نیاز داریم؟

استاد دستیار صوتی برای کودکان را مثال زد. سامانهٔ تشخیص گفتاری که برای بزرگسالان خوب کار می‌کند، روی گفتار کودکان بیشتر خطا می‌کند، چون ویژگی‌های آکوستیکی و نحوهٔ تولید گفتار کودکان فرق دارد (مجرای کوتاه‌تر و فرمنت‌های بالاتر؛ مثال لولهٔ یکنواخت بالا). راه‌حل ساخت پیکرهٔ اختصاصی برای همان گروه هدف است. برای دستیار صوتی کودکان فارسی‌زبان:

۱. نمونه‌های صوتی از کودکان جامعهٔ هدف ضبط می‌شود.

۲. فایل‌ها در Praat بررسی می‌شوند.

۳. مرزهای زمانی واژه‌ها و واج‌ها مشخص می‌شود.

۴. واکه‌های مختلف برچسب می‌خورند.

۵. F1 و F2 واکه‌ها استخراج می‌شوند.

۶. دامنهٔ آماری هر واکه در آن گروه به دست می‌آید.

خروجی جدولی است با ستون‌های «واکه»، «دامنهٔ F1» و «دامنهٔ F2» که مقادیر آن حتماً باید از داده‌های واقعی استخراج شود. چنین جدولی را می‌توان جداگانه برای زنان، مردان، کودکان یا گروه‌هایی با ویژگی‌های گفتاری خاص تهیه کرد. هدف نوشته‌شده روی تخته: افزایش دقت دستیار صوتی‌ای که مخاطب اصلی‌اش کودکان‌اند.

۲.۴.۴ نمونهٔ پژوهشی: AusKidTalk

استاد مقاله‌ای از کنفرانس LREC 2026 را نشان داد که دستورالعمل رونویسی گفتار پیوستهٔ کودکان انگلیسی‌زبان استرالیایی در پیکرهٔ AusKidTalk را ارائه می‌کند. نکات این مقاله (مطابق چکیدهٔ آن):

- گفتار با تکلیف داستان‌گویی گرفته شده و به‌طور میانگین ۳٫۵ دقیقه به ازای هر کودک است.
- متن اولیه با ابزارهای ASR تولید و سپس با پروتکلی مشخص (راهنما، رابط ویرایش و معیارهای سازگاری) به‌دست انسان اصلاح شده است؛ نه نفر مصحح، ۲۶۱ داستان کودکان و ۲۵ تکلیف مرجع (ground truth).
- نرخ خطای واژهٔ رونویسی خودکار ۲۳ درصد بود و اصلاح دستی حدود ۱۱ برابر مدت گفتار زمان برد (برای ۳٫۵ دقیقه حدود ۴۰ دقیقه).

در مقدمهٔ همان مقاله ذکر شده که رونویسی دستی کامل با راستی‌آزمایی حدود ۵۰ برابر طول گفتار و رونویسی خودکار با اصلاح دستی حدود ۱۵ برابر طول گفتار زمان می‌برد؛ یعنی استفاده از ASR هزینهٔ تولید پیکره را به‌شدت کاهش می‌دهد.



AusKidTalk: Developing Transcription Guidelines for Continuous Australian English Child Speech

Tünde Szalay[*†], **Zheng Nan**[†], **Renata Huang**[*‡], **Mostafa Shahin**[‡], **Sirojan Tharmakulasingam**[†], **Kirrie Ballard**[*], **Beena Ahmed**[†]
[*]The University of Sydney, [†]University of New South Wales, [‡]Macquarie University
Sydney, Australia
{tuende.szalay, kirrie.ballard}@sydney.edu.au, renata.huang@mq.edu.au
{zheng.nan, m.shahin, s.tharmakulasingam, beena.ahmed}@unsw.edu.au

Abstract

Guidelines are required for accurate and consistent transcription of speech corpora, especially when they contain more challenging, e.g. spontaneous or under-resourced speech. This paper presents a workflow and guidelines for transcribing spontaneous and under-resourced child speech in AusKidTalk, the first Australian English child corpus. Speech samples were elicited using a story-telling task and are 3.5 minutes long per child on average. Orthographic transcriptions were generated using automatic speech recognition (ASR) tools and corrected manually. A novel hand-correction protocol consisting of guidelines, hand-correction interface, and ground truth transcriptions together with consistency metrics were developed. Nine annotators submitted hand-corrections for 261 children's story-telling task, and 25 ground truth tasks. Manual correction was 11-fold of speech time with a 3.5-minute-long story-telling task corrected in approximately 40 minutes. Efficiency is attributed to the quality of automatic transcription with 23% word error rate. Manual correction was accurate with annotators achieving consistent results on 15/25 ground truth submissions. Most inconsistent ground truth submissions were caused by a single, challenging ground truth task. These results show that our workflow yields efficient and accurate transcriptions, although transcriptions of potentially more challenging narrative tasks (e.g., elicited from younger children) might require further corrections.

Keywords: child speech corpus, corpus building, automatic speech recognition (ASR), ASR-assisted transcription

1. Introduction

Speech corpora, the large collections of transcribed and aligned audio recordings, are crucial resources in speech technology and science, required for training automatic speech recognition (ASR) tools and for revealing speech variation in large datasets (Liberman, 2019; Sobti et al., 2024). Developing accurate transcription, a key part of every speech corpora, is resource intensive (Glenn et al., 2010), therefore corpora are often developed using read speech, removing the need for orthographic transcription (e.g., Garofolo et al., 1993; Burnham et al., 2011; Panayotov et al., 2015; Kressner et al., 2024). Spontaneous speech, which provides more life-like samples, requires labour-intensive orthographic transcription prior to its use to train ASR models or conduct more detailed analysis (e.g., phonetic transcription), increasing annotation time and cost (e.g., Pitt et al., 2005; Grønnum, 2009; Schuppler et al., 2017; Mereu and Vietti, 2021).

ASR-assisted transcription augmented by manual correction is a known method to reduce transcription time (Bazillon et al., 2008; Cieri, 2009). For example, the approximate time-need for manual transcription with manual verification is 50× the length of speech time, while automatic transcription with manual verification is 15× the length of speech time depending on the level of detail in the transcription (Cieri, 2009). Yet, details of ASR tools and guidelines of hand-correction are not always reported in detail, introducing challenges for reliability and replicability of orthographic transcription (transcription guidelines not reported: Pitt et al. 2005; Grønnum 2009; Gao et al. 2012; Mereu and Vietti 2021, transcription guidelines reported: Schuppler et al. 2017; Pérez-Espinosa et al. 2020; Rumberg et al. 2022).

This paper addresses this gap by providing guidelines for systematic integration of manual correction with automatically generated orthographic transcriptions, when transcribing semi-spontaneous, continuous child speech in AusKidTalk, the first Australian English (AusE) child corpus (Ahmed et al., 2021). This will enable future researchers to adapt the guidelines for other corpora containing spontaneous speech as well as the techniques to evaluate the quality of both human and automated annotations, offering practical methods to enhance annotation workflows.

1.1. Automatic corpus transcription

When building novel corpora for high resource languages, ASR tools reduce transcription time, and thus costs, by generating orthographic transcription automatically, allowing for manual correction instead of transcription (Bazillon et al., 2008;

Proceedings of the Fifteenth Language Resources and Evaluation Conference (LREC 2026), pages 5794–5804
11–16 May 2026. ©ELRA Language Resources Association (ELRA), 2026

شکل ۳.۴: صفحهٔ نخست مقالهٔ AusKidTalk: Developing Transcription Guidelines for Continuous Australian English Child Speech (LREC 2026) که استاد برای مثال ساخت پیکره با کمک ASR نشان داد. (برگرفته از تختهٔ کلاس)

نرخ خطای واژه (WER)

$$\text{WER} = \frac{S + D + I}{N}$$

که S تعداد جانشینی، D حذف، I درج و N تعداد واژه‌های متن مرجع است.

[محتوای افزوده] مثال عددی: محاسبهٔ WER

مرجع: «the baby got frightened when the egg started to hatch» با $N = ۱۰$ واژه. خروجی ASR: «the baby got frighten when egg started to hatch». واژهٔ frightened به frighten تبدیل شده ($S = ۱$) و یک the حذف شده ($D = ۱$) و درجی نداریم ($I = ۰$):

$$\text{WER} = \frac{۱ + ۱ + ۰}{۱۰} = ۰٫۲۰ = ۲۰٪$$

چون درج‌ها هم شمرده می‌شوند، WER می‌تواند از ۱۰۰ درصد هم بیشتر شود.

چارچوب پیشنهادی: ASR + بازبینی انسانی

فرایند مثال کلاس: (۱) ضبط گفتار کودکان؛ (۲) تولید متن اولیه با یک مدل ASR مانند Whisper؛ (۳) آماده‌سازی TextGrid و هم‌زمان‌سازی متن با صوت؛ (۴) بازبینی انسانی: گوش‌دادن و اصلاح برچسب‌ها و مرزها؛ (۵) ساخت پیکرهٔ نهایی. خروجی ASR خطا دارد، پس برچسب‌زن انسانی (Annotator) باید صوت و برچسب‌ها را بررسی و اصلاح کند. به این ترتیب کار او از برچسب‌گذاری کامل از صفر به «بازبینی و تصحیح خروجی خودکار» تبدیل می‌شود که سریع‌تر و عملی‌تر است.

پس از اصلاح، پیکره را می‌توان برای **تنظیم دقیق** (Fine-tuning) یک مدل تشخیص گفتار مانند Whisper به کار برد تا با ویژگی‌های گفتاری جامعهٔ هدف سازگارتر شود. استاد این را با ایدهٔ استفاده از دادهٔ دشوار، یعنی موارد خطای مدل قبلی، مرتبط دانست.

نکتهٔ پژوهشی: مستندسازی برچسب‌گذاری

در پاسخ به پرسش دانشجو دربارهٔ برچسب‌زن‌های مقاله، استاد گفت جزئیات آن‌ها را بررسی نکرده، اما هنگام انتشار پژوهش باید روش برچسب‌گذاری کاملاً مستند شود: چه کسانی برچسب زده‌اند، تجربه و تحصیلاتشان چه بوده، از چه روش و ابزاری استفاده شده، خطاهای خروجی خودکار چگونه اصلاح شده‌اند و کیفیت نهایی چگونه سنجیده شده است. این اطلاعات برای اعتبار و بازتولیدپذیری پژوهش لازم‌اند.

[محتوای افزوده] توافق میان برچسب‌زن‌ها

برای سنجش کیفیت برچسب‌گذاری معمولاً بخشی از داده را چند نفر مستقل برچسب می‌زنند و میزان توافق را با معیارهایی مانند WER میان برچسب‌زن‌ها یا ضریب Cohen's κ می‌سنجند. در مقالهٔ AusKidTalk هم مصحح‌ها روی ۲۵ تکلیف مرجع ارزیابی شده‌اند: مصحح‌ها در ۱۵ مورد از ۲۵ تکلیف مرجع نتایج سازگار داشتند و بیشتر ناسازگاری‌ها به یک تکلیف دشوار برمی‌گشت.

۵.۴ فضای واکه‌ای

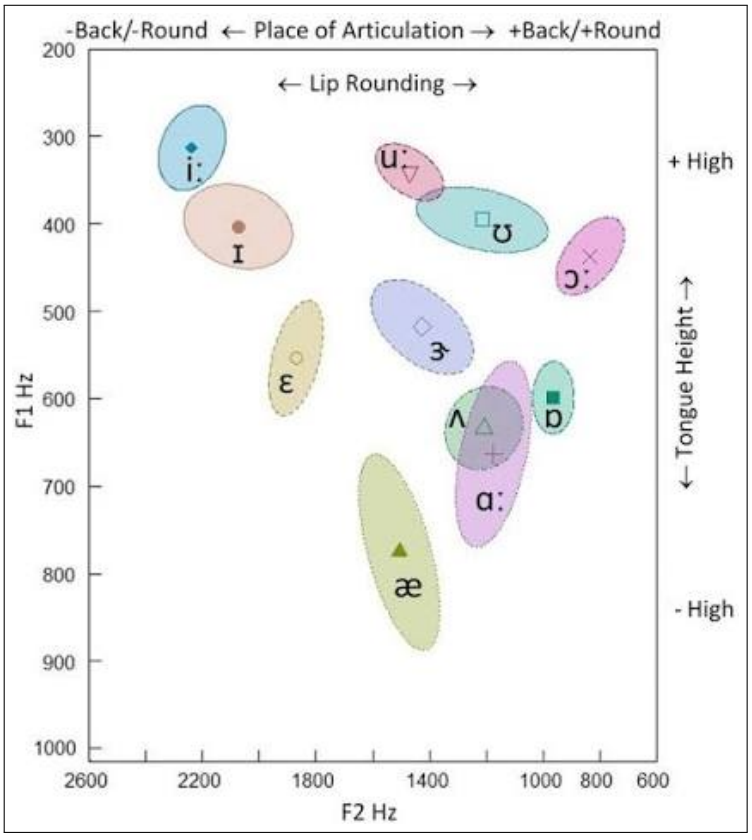
۱.۵.۴ تعریف و نمودارها

فضای واکه‌ای (Vowel Space)

نمایش هندسی جایگاه واکه‌ها بر پایهٔ ویژگی‌های تولیدی (ارتفاع و جلو یا عقب بودن زبان) یا ویژگی‌های آکوستیکی. در نمایش آکوستیکی، هر واکه نقطه‌ای است با مختصات $V = (F_1, F_2)$ و با گردآوری نقطه‌ها از نمونه‌های متعدد، پراکندگی و دامنهٔ هر واکه دیده می‌شود.

دو نقشه روی تخته مقایسه شد: «نقشهٔ استاندارد و تئوریک الفبای بین‌المللی آواشناسی» که صرفاً توصیفی است، و «نقشهٔ اندازه‌گیری‌شده بر اساس داده‌های آکوستیک Praat». هدف درس رسیدن به نقشهٔ دوم است. روی تخته نمونه‌ای از نقشهٔ نظری (با نمادهای ARPAbet مانند iy، ih، aa) و نمودار بیضی‌های واکه‌های انگلیسی ترسیم‌شده با F1 و F2 آمده بود.

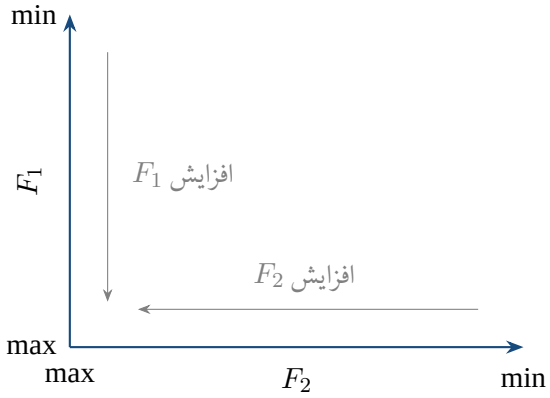
نقشهٔ نظری واکه‌های انگلیسی با نمادهای ARPAbet در شکل ۱۳.۲ (فصل دوم) آمده است؛ شکل ۴.۴ نسخهٔ اندازه‌گیری‌شدهٔ همین واکه‌ها را نشان می‌دهد.



شکل ۴.۴: نقشهٔ اندازه‌گیری‌شدهٔ واکه‌های انگلیسی؛ هر بیضی پراکندگی یک واکه در F1–F2 است. محورها معکوس رسم شده‌اند تا جهت آن با نقشهٔ نظری (بالا = بسته، چپ = جلو) هم‌خوان باشد. (برگرفته از تختهٔ کلاس)

۲.۵.۴ ترسیم نمودار F1–F2

در نمودار متداول، محور F1 (عمودی) معکوس رسم می‌شود: مقدار کم در بالا و زیاد در پایین؛ و محور F2 (افقی) هم معکوس است: مقدار زیاد در چپ و کم در راست. نتیجه این است که نمودار شبیه نقشهٔ تولیدی است: واکه‌های بسته بالا، واکه‌های باز پایین، واکه‌های جلویی چپ و عقبی راست. استاد با نموداری دست‌ساز روی تخته همین نکته را نشان داد: روی محور عمودی F1، کمینه در بالا و بیشینه در پایین؛ روی محور افقی F2، بیشینه در مبدأ (سمت چپ) و کمینه در انتهای راست.



شکل ۵.۴: محورهای معکوس نمودار F1–F2: F1 (کمینه در بالا، بیشینه در پایین) و F2 (بیشینه در سمت چپ و مبدأ، کمینه در سمت راست) (بازسازی‌شده از تختهٔ کلاس)

پرسش و پاسخ: آیا F2 را از F1 حدس می‌زنیم؟

نه. F1 و F2 هر دو جداگانه از سیگنال اندازه‌گیری می‌شوند. پس از اندازه‌گیری هر دو، نقطهٔ واکه روی نمودار قرار می‌گیرد. هر واکه یک زوج $V = (F_1, F_2)$ است و با نمونه‌های بیشتر، پراکندگی و دامنهٔ هر واکه به دست می‌آید.

۳.۵.۴ واکه‌های زبان فارسی

زبان فارسی معیار شش واکهٔ ساده دارد: /i/، /e/، /æ/، /ɑ/، /o/ و /u/. جدول زیر دامنهٔ تقریبی F1 و F2 (بر حسب هرتز) را به تفکیک مردان و زنان نشان می‌دهد؛ این جدول را استاد روی اسلاید نشان داد و منبع آن ذکر نشده است.

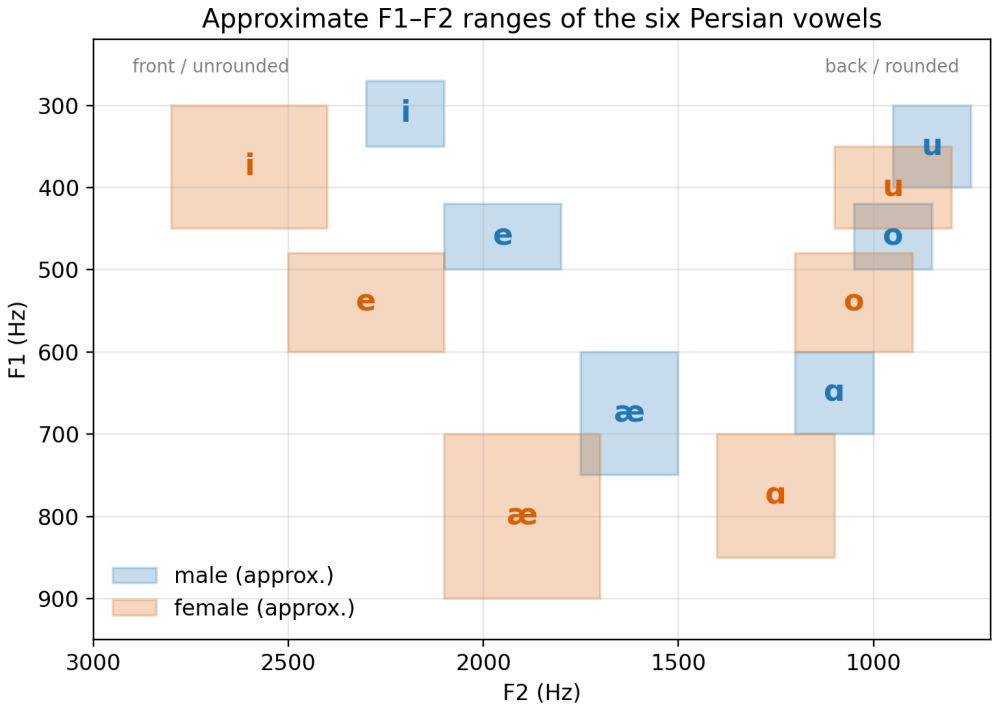
الگوی جدول با نگاشت بالا هم‌خوان است: /i/ و /u/ (بسته) کمترین F1 و /æ/ و /ɑ/ (باز) بیشترین F1 را دارند؛ /i/ با بالاترین F2 جلویی‌ترین و /u/ با کمترین F2 عقبی‌ترین واکه است؛ و مقادیر زنان در همهٔ واکه‌ها بالاتر از مردان‌اند.

دامنه‌ها تقریبی‌اند

مقادیر جدول بالا از نظر ترتیب و مرتبهٔ بزرگی با داده‌های رایج آواشناسی فارسی سازگار است (مثلاً F1 حدود ۳۰۰ تا ۴۰۰ و F2 حدود ۲۲۰۰ برای /i/ در مردان)، اما اعداد دقیق به گویش، گوینده، سبک گفتار (واژه‌های جداگانه یا گفتار پیوسته)، بافت واجی و روش اندازه‌گیری بستگی دارند و از یک پژوهش تا پژوهش دیگر ده‌ها هرتز تفاوت می‌کنند. آن‌ها را به جای مرجع قطعی، نقطهٔ شروع سنجش بدانید. همچنین این جدول مرکز و محدودهٔ هر واکه را می‌دهد؛ برای کودکان باید جدول جداگانه تهیه کرد.

جدول ۳.۴: دامنهٔ تقریبی فرمنت‌های اول و دوم واکه‌های فارسی (هرتز)؛ جدول ارائه‌شده در کلاس

واکه	نشانه و مثال	F1 مردان	F2 مردان	F1 زنان	F2 زنان
/i/	«ای» (سیب)	۲۷۰ تا ۳۵۰	۲۱۰۰ تا ۲۳۰۰	۳۰۰ تا ۴۵۰	۲۴۰۰ تا ۲۸۰۰
/e/	«ـِ» (دل)	۴۲۰ تا ۵۰۰	۱۸۰۰ تا ۲۱۰۰	۴۸۰ تا ۶۰۰	۲۱۰۰ تا ۲۵۰۰
/æ/	«ـَ» (دست)	۶۰۰ تا ۷۵۰	۱۵۰۰ تا ۱۷۵۰	۷۰۰ تا ۹۰۰	۱۷۰۰ تا ۲۱۰۰
/ɑ/	«آ» (باد)	۶۰۰ تا ۷۰۰	۱۰۰۰ تا ۱۲۰۰	۷۰۰ تا ۸۵۰	۱۱۰۰ تا ۱۴۰۰
/o/	«ـُ» (پل)	۴۲۰ تا ۵۰۰	۸۵۰ تا ۱۰۵۰	۴۸۰ تا ۶۰۰	۹۰۰ تا ۱۲۰۰
/u/	«او» (دود)	۳۰۰ تا ۴۰۰	۷۵۰ تا ۹۵۰	۳۵۰ تا ۴۵۰	۸۰۰ تا ۱۱۰۰



شکل ۶.۴: نمودار F1–F2 برای شش واکهٔ فارسی بر پایهٔ دامنه‌های جدول بالا؛ مستطیل‌ها دامنهٔ تقریبی مردان (آبی) و زنان (نارنجی) را نشان می‌دهند. محورها معکوس‌اند. مقادیر تقریبی‌اند (شکل افزوده).

[محتوای افزوده] مقایسه: داده‌های Peterson & Barney برای انگلیسی

پژوهش کلاسیک Peterson & Barney (۱۹۵۲) فرمنت‌های واکه‌های انگلیسی آمریکایی را برای مردان، زنان و کودکان اندازه گرفت. مقادیر تقریبی (F1/F2) برای چهار واکهٔ گوشه (هرتز):

واکه	مردان	زنان	کودکان
/i/	۲۲۹۰ / ۲۷۰	۲۷۹۰ / ۳۱۰	۳۲۰۰ / ۳۷۰
/æ/	۱۷۲۰ / ۶۶۰	۲۰۵۰ / ۸۶۰	۲۳۲۰ / ۱۰۳۰
/ɑ/	۱۰۹۰ / ۷۳۰	۱۲۲۰ / ۸۵۰	۱۳۷۰ / ۱۰۳۰
/u/	۸۷۰ / ۳۰۰	۹۵۰ / ۳۷۰	۱۱۷۰ / ۴۳۰

هر دو الگوی مهم دیده می‌شود: ترتیب واکه‌ها در همهٔ گروه‌ها یکسان است، ولی مقادیر از مردان به زنان و کودکان بالا می‌روند (به علت کوتاه‌تر شدن مجرای صوتی). پس فضای واکه‌ای هر گروه باید جداگانه ساخته شود. اعداد گردشده و تقریبی‌اند.

۴.۵.۴ تفاوت فضای واکه‌ای در گروه‌های مختلف

فضای واکه‌ای برای همهٔ افراد یکسان نیست. می‌توان آن را جداگانه برای کودکان و بزرگسالان، زنان و مردان، گویندگان زبان‌های مختلف و افراد دارای اختلال یا تفاوت گفتاری استخراج کرد. انتظار داریم رابطهٔ کلی «F1 با ارتفاع و F2 با جلوآمدگی» حفظ شود، اما دامنهٔ عددی فرمنت‌ها و پراکندگی واکه‌ها تغییر کند.

[محتوای افزوده] نرمال‌سازی گوینده

چون اندازهٔ مجرا از گوینده‌ای به گوینده‌ای دیگر فرق می‌کند، برای مقایسهٔ بین گویندگان معمولاً فرمنت‌ها نرمال می‌شوند. یک روش رایج نرمال‌سازی Lobanov است: برای هر گوینده و هر فرمنت، مقدار را از میانگین همان گوینده کم و بر انحراف معیار او تقسیم می‌کنند، $z = (F - \mu)/\sigma$. روش‌های دیگر تبدیل به مقیاس‌های ادراکی مانند Bark یا ERB است. در پایش یک فرد در طول زمان (کاربرد زیستی) نیازی به نرمال‌سازی بین‌فردی نیست، چون هر فرد با خودش مقایسه می‌شود.

۵.۵.۴ مساحت فضای واکه‌ای (VSA)

برای تبدیل «گستردگی فضای واکه‌ای» به یک عدد، معمولاً مساحت چندضلعی ساخته‌شده از واکه‌های گوشهٔ نمودار F1–F2 محاسبه می‌شود. تعریف مقالهٔ Sandoval و همکاران (۲۰۱۳) که روی تخته آمده این است: VSA مساحت دوبعدی محدود به خطوط واصل مختصات F1/F2 واکه‌های گوشه است؛ در روش سنتی F1/F2 هر یک از چهار واکهٔ گوشه (یا سه واکهٔ /a, i, u/ برای مثلث) در ۵۰ درصد مدت واکه چندین بار اندازه گرفته و میانگین‌گیری می‌شود. چون F1 با باز بودن فک و F2 با موقعیت زبان مرتبط است، VSA نمایندهٔ آکوستیکی جابه‌جایی‌های اندام‌های گفتار است و در گفتار واضح‌تر و قابل‌فهم‌تر بزرگ‌تر است.



Sandoval *et al.*: JASA Express Letters [http://dx.doi.org/10.1121/1.4826150] Published Online 21 October 2013

Automatic assessment of vowel space area

Steven Sandoval
School of Electrical, Computer and Energy Engineering, Sensor, Signal & Information Processing Center, Arizona State University, Tempe, Arizona 85287
spsandov@asu.edu

Visar Berisha, Rene L. Utianski, and Julie M. Liss
Department of Speech and Hearing Science, Arizona State University, Tempe, Arizona 85287
visar@asu.edu, rutianok@asu.edu, julie.liss@asu.edu

Andreas Spanias
School of Electrical, Computer and Energy Engineering, Sensor, Signal & Information Processing Center, Arizona State University, Tempe, Arizona 85287
spanias@asu.edu

Abstract: Vowel space area (VSA) is an attractive metric for the study of speech production deficits and reductions in intelligibility, in addition to the traditional study of vowel distinctiveness. Traditional VSA estimates are not currently sufficiently sensitive to map to production deficits. The present report describes an automated algorithm using healthy, connected speech rather than single syllables and estimates the entire vowel working space rather than corner vowels. Analyses reveal a strong correlation between the traditional VSA and automated estimates. When the two methods diverge, the automated method seems to provide a more accurate area since it accounts for all vowels.

© 2013 Acoustical Society of America
PACS numbers: 43.72.Ar, 43.71.Gv, 43.71.Sy [DDO]
Date Received: July 22, 2013 **Date Accepted:** September 26, 2013

1. Introduction

Vowel space area (VSA) refers to the two-dimensional area bounded by lines connecting first and second formant frequency coordinates (*F1*/*F2*) of vowels.[1] Estimation of VSA has a long history in the study of vowel identity, speaker characteristics, speech development, speaking style and sociolinguistic factors that influence vowel production.[2–10] Traditional VSA computation methodology is shown in Fig. 1(a). A typical computation involves making static measurements of the *F1*/*F2* values for each of the four corner vowels (or three point vowels, /a, ɪ, u/ for triangle) at 50% vowel duration, for several productions of each vowel. The mean *F1*/*F2* value for each of the four corner vowels is then used to compute the area of the quadrilateral formed by the corner vowels. Since frequencies of the first and second formants roughly relate to the size and shape of the cavities created by jaw opening (*F1*) and tongue position (*F2*), the VSA is an acoustic proxy for the kinematic displacements of the articulators.[11] In general, studies have shown that VSA is larger in speech that is clearer and more intelligible than speech associated with smaller VSAs.[12] This is interpreted as corresponding to greater articulatory excursions and more distinct acoustic-articulatory vowel targets. Thus, the VSA and other derived vowel metrics related to distinctiveness have been quite successful in the study of speaking style, dialects, and languages.[6,7,9]

Because abnormal vowel formant reduction (centralization) is a common feature of speech production deficits, there has been a longstanding interest in using VSA estimations for characterizing speech motor control, including speech development,[10,13] speech disorders,[14–17] and speech interventions.[18] Despite the intuitive appeal of using

شکل ۷.۴: صفحهٔ نخست مقالهٔ Automatic assessment of vowel space area (Sandoval و همکاران، JASA Express Letters، ۲۰۱۳) دربارهٔ تخمین خودکار مساحت فضای واکه‌ای. (برگرفته از تختهٔ کلاس)

محاسبهٔ VSA با فرمول شوله‌یس (Shoelace)

اگر رأس‌های چندضلعی با ترتیب پیرامونی $(F_{۲,k}, F_{۱,k})$ باشند، مساحت برابر است با

$$\mathrm{VSA} = \frac{۱}{۲}\left|\sum_{k=۱}^{n}\left(F_{۲,k}\,F_{۱,k+۱} - F_{۲,k+۱}\,F_{۱,k}\right)\right|,$$

با قرارداد $k = n+۱ \equiv ۱$. واحد آن $\mathrm{Hz}^۲$ است. برای مثلث (i, a, u) فرمول بسته چنین است:

$$\mathrm{VSA}_{\triangle} = \frac{۱}{۲}\left|F_{۱,i}(F_{۲,a}-F_{۲,u}) + F_{۱,a}(F_{۲,u}-F_{۲,i}) + F_{۱,u}(F_{۲,i}-F_{۲,a})\right|.$$

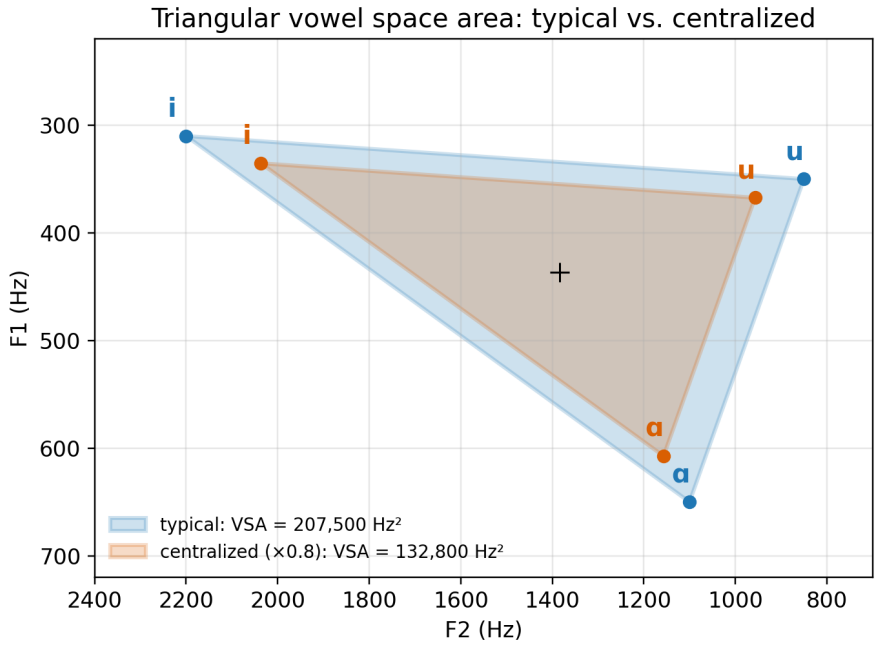
[محتوای افزوده] مثال عددی: VSA مثلثی مردان فارسی‌زبان

مرکز دامنه‌های جدول مردان را به عنوان مختصات هر واکه می‌گیریم: /i/ با $(F_۱, F_۲) = (۳۱۰, ۲۲۰۰)$، /ɑ/ با $(۶۵۰, ۱۱۰۰)$ و /u/ با $(۳۵۰, ۸۵۰)$ هرتز. بنا بر فرمول بسته:

$$\begin{aligned}\mathrm{VSA}_{\triangle} &= \tfrac{۱}{۲}\left|۳۱۰(۱۱۰۰-۸۵۰) + ۶۵۰(۸۵۰-۲۲۰۰) + ۳۵۰(۲۲۰۰-۱۱۰۰)\right| \\ &= \tfrac{۱}{۲}\left|۷۷\,۵۰۰ - ۸۷۷\,۵۰۰ + ۳۸۵\,۰۰۰\right| = \tfrac{۱}{۲}(۴۱۵\,۰۰۰) = ۲۰۷\,۵۰۰\ \mathrm{Hz}^۲.\end{aligned}$$

اگر /æ/ با مختصات $(۶۷۵, ۱۶۲۵)$ را هم به‌عنوان چهارمین گوشه اضافه کنیم، چهارضلعی /i/ → /æ/ → /ɑ/ → /u/ مساحتی برابر $۳۱۰\,۵۰۰\ \mathrm{Hz}^۲$ دارد.

اثر متمرکزشدن. فرض کنید نقاط هر سه واکه ۲۰ درصد به سمت مرکز ثقل خود (۴۳۷F1 =، ۱۳۸۳F2 =) جمع شوند، یعنی هر فاصله در ضریب ۰٫۸ ضرب شود. چون مساحت با مربع ضریب مقیاس تغییر می‌کند، مساحت جدید $0.8^2 \times 207\,500 = 132\,800$ Hz² است، یعنی حدود ۳۶ درصد کاهش، هرچند فاصلهٔ هر نقطه فقط ۲۰ درصد کم شده است. بنابراین VSA حساس به متمرکز شدن واکه‌ها است.



شکل ۸.۴: مثلث /i, ɑ, u/ برای مقادیر مثال بالا (آبی) و حالت متمرکزشدهٔ آن (نارنجی)؛ کوچک‌شدن مساحت از ۲۰۷ ۵۰۰ به ۱۳۲ ۸۰۰ هرتز مربع. اعداد تقریبی‌اند (شکل افزوده).

[محتوای افزوده] شاخص‌های وابسته: VAI و FCR

VSA به اندازهٔ مجرای گوینده حساس است. برای کاهش این وابستگی Sapir و همکاران (۲۰۱۰) نسبت‌هایی را پیشنهاد کردند:

$$\mathrm{VAI} = \frac{F_{2,i} + F_{1,a}}{F_{2,u} + F_{2,a} + F_{1,i} + F_{1,u}}, \qquad \mathrm{FCR} = \frac{F_{2,u} + F_{2,a} + F_{1,i} + F_{1,u}}{F_{2,i} + F_{1,a}} = \frac{1}{\mathrm{VAI}}.$$

با متمرکز شدن واکه‌ها VAI کاهش و FCR افزایش می‌یابد. با مقادیر مثال بالا: $\mathrm{VAI} + 850)/(2200 + 650) = (350 + 310 + 1100 \approx 1{,}09$ و پس از متمرکزشدن (۰٫۸) حدود ۰٫۹۴؛ یا معادلاً FCR از ۰٫۹۲ به ۱٫۰۷ می‌رسد. این شاخص‌ها چون نسبتی‌اند، به مقیاس کلی فرمنت‌ها کمتر وابسته‌اند.

۶.۴ همخوان‌ها در اسپکتروگرام

یکی از دانشجویان پرسید آیا این تحلیل فقط برای واکه‌هاست. پاسخ استاد: همخوان‌ها هم ویژگی‌های آکوستیکی خاص خود را دارند و در اسپکتروگرام قابل بررسی‌اند، ولی تمرکز فعلی درس روی واکه‌ها و فضای واکه‌ای است و همخوان‌ها

موضوع مطالعهٔ بیشتر است.

تمرین پیشنهادی استاد

بررسی کنید همخوان‌ها (Consonants) چگونه در اسپکتروگرام دیده می‌شوند و آیا اسپکتروگرام با آنچه در آواشناسی تولیدی گفتیم هماهنگ است. روی تخته نوشته شده: «بله، با **سکوت** (شیوهٔ تولید) و نحوهٔ **خم‌شدن و جهش فرمنت‌ها** و **مرکز فرکانسی نویز** (جایگاه تولید)، حرکات فیزیکی اندام‌های گفتاری را کدگذاری می‌کند.» به‌خصوص این موارد را بررسی کنید:

- سکوت یا انسداد پیش از برخی همخوان‌ها؛
- انفجار (Burst) در همخوان‌های انسدادی مانند /b/ و /p/؛
- تغییر شکل فرمنت‌ها هنگام گذار از همخوان به واکه (Formant Transitions)؛
- تفاوت الگوهای زمانی و فرکانسی همخوان‌ها.

[محتوای افزوده] راهنمای خوانش همخوان‌ها در طیف‌نگاره

- **شیوه تولید:** همخوان‌های انسدادی ($/p, t, k, b, d, g/$) یک بازهٔ بسته با انرژی بسیار کم دارند (در واک‌دارها یک نوار فرکانس پایین به نام voice bar)، سپس یک انفجار کوتاه و زمان آغاز واک (VOT). سایشی‌ها ($/s, \int, f/$) نویز پیوسته با انرژی پهن‌باند دارند. خیشومی‌ها فرمنت‌های ضعیف و یک ناحیهٔ ضدتشدید دارند.
- **جایگاه تولید:** در سایشی‌ها مرکز ثقل نویز مهم است: /s/ انرژی را در فرکانس‌های بالا (حدود بالای ۴۰۰۰ هرتز) و /ʃ/ در فرکانس‌های پایین‌تر (حدود ۲۰۰۰ تا ۳۰۰۰ هرتز) دارد. در انسدادی‌ها جهت گذار F2 و F3 به واکهٔ بعد (مثلاً بالارفتن F2 پس از همخوان دولبی) نشان‌دهندهٔ جایگاه تولید است.

۷.۴ کاربردهای فضای واکه‌ای

پس از ساخت فضای واکه‌ای گوینده یا گروه، استاد از دانشجویان پرسید چه کاربردی دارد. پاسخ‌های اولیه (تشخیص واکه، آموزش مدل و پیش‌پردازش) کافی نبود: فضای واکه‌ای قبل از هر چیز ابزار تحلیل ساختار تولید گفتار، مقایسهٔ گروه‌ها و شناسایی الگوهای متفاوت است. روی تخته سه کاربرد اصلی نوشته شده بود.

۱.۷.۴ گفتاردرمانی و بازخورد زیستی تصویری

بیوفیدبک تصویری (Visual Biofeedback): برای کودکان دارای اختلال گفتاری، ناشنوایان یا افراد مبتلا به سندرم داون، نمایشگری زنده نشان داده می‌شود که با حرکت دادن زبان، یک نقطه روی نمودار (F1 و F2) حرکت می‌کند. کودک یاد می‌گیرد چگونه زبانش را بالا ببرد تا نقطه به هدف مشخص‌شده روی نقشه برسد. ایده این است که فضای واکهٔ مرجع را داشته باشیم، گفتار فرد را اندازه بگیریم و اختلاف را نشان دهیم؛ مثلاً اگر واکه‌ای با F1 بالاتر از هدف تولید شود، بازخوردی دربارهٔ تغییر ارتفاع زبان داده شود. مزیت: بازخورد از حالت صرفاً شنیداری و کلامی به شکل دیداری درمی‌آید.

محدودیت‌های عملی

چنین بازخوردی را باید با توجه به ویژگی‌های واکه و شرایط فرد تفسیر کرد. در گفتار کودکان و زنان که f_0 بالا است و هارمونیک‌ها از هم دور هستند، تخمین فرمنت دشوار و ناپایدار است و نقطهٔ نمایش‌داده‌شده ممکن است بپرد. بهتر است هدف را یک ناحیه (بیضی دامنهٔ واکه) در نظر بگیریم، نه نقطه، و فرمنت‌ها را هموار کنیم.

۲.۷.۴ تشخیص صدای جعلی (Deepfake)

مدل‌های تولید گفتار می‌توانند صدایی بسازند که برای گوش انسان طبیعی است، اما طبیعی‌بودن شنیداری به معنای یکسان‌بودن همهٔ ویژگی‌های آکوستیکی و تولیدی با گفتار واقعی نیست. ایده: فرمنت‌های واکه‌ها را برای نمونهٔ واقعی و نمونهٔ سنتزشده استخراج و فضای واکه‌ای آن‌ها را مقایسه کنیم؛ اگر تفاوت معنادار و قابل‌اتکایی وجود داشته باشد، می‌توان از آن‌ها به‌عنوان ویژگی تشخیص جعل استفاده کرد. به گفتهٔ روی تخته: گفتار سنتزشده در مقایسه با گفتار واقعی ناهماهنگی‌هایی در هندسه و تغییر شکل مجرای صوتی نشان می‌دهد؛ و «تفاوت‌های بیومکانیکی در تلفظ مصوت‌ها بهترین ردپای مصنوعی‌بودن صدا هستند». استاد همچنین به هم‌بستگی (Correlation) میان ویژگی‌های آکوستیکی گفتار واقعی و تولیدی اشاره کرد: می‌توان بررسی کرد آیا الگوی تغییر F1 و F2 در واکه‌های مختلف با گفتار طبیعی سازگار است. روی تخته نام «Siwei Lyu» (پژوهشگر شناخته‌شدهٔ حوزهٔ تشخیص دیپ‌فیک) نیز در همین بخش آمده است.

استاد مقاله‌ای را نشان داد که از ویژگی‌های مرتبط با تولید و شکل مجرای صوتی برای تشخیص گفتار مصنوعی استفاده می‌کند.

«اثبات» جعل؟

عبارت روی تخته دربارهٔ «اثبات جعل در محیط‌های جرم‌شناسی» باید با احتیاط خوانده شود. روش‌های مبتنی بر فضای واکه‌ای یا شکل مجرا شواهد آماری تولید می‌کنند، نه اثبات قطعی. نمودار روی تخته هم نشان می‌دهد در بسیاری از واکه‌ها بیضی‌های واقعی و جعلی هم‌پوشانی زیادی دارند و فقط در برخی واکه‌ها یا گویندگان جابه‌جایی دیده می‌شود. خود مقالهٔ نشان‌داده‌شده (چکیدهٔ آن) می‌گوید بهبود حاصل با الگوهای سازگار با کاهش تغییرپذیری تولیدی وابسته به گوینده هم‌خوان است، اما نتایج نشان نمی‌دهد که صرف اطلاعات قد گوینده علت بهبود باشد. استاد هم تأکید کرد گزارهٔ کلی «فرمنت‌ها فرق دارند» برای پژوهش علمی کافی نیست؛ باید معلوم شود:

۱. دقیقاً کدام ویژگی آکوستیکی تفاوت دارد؟

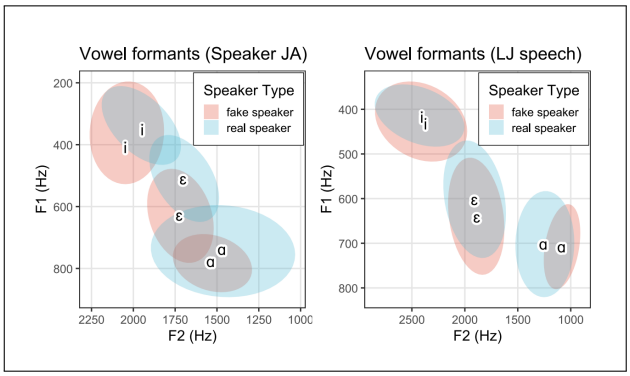
۲. چگونه اندازه‌گیری می‌شود؟

۳. آیا در نمونه‌های مختلف تکرارپذیر است؟

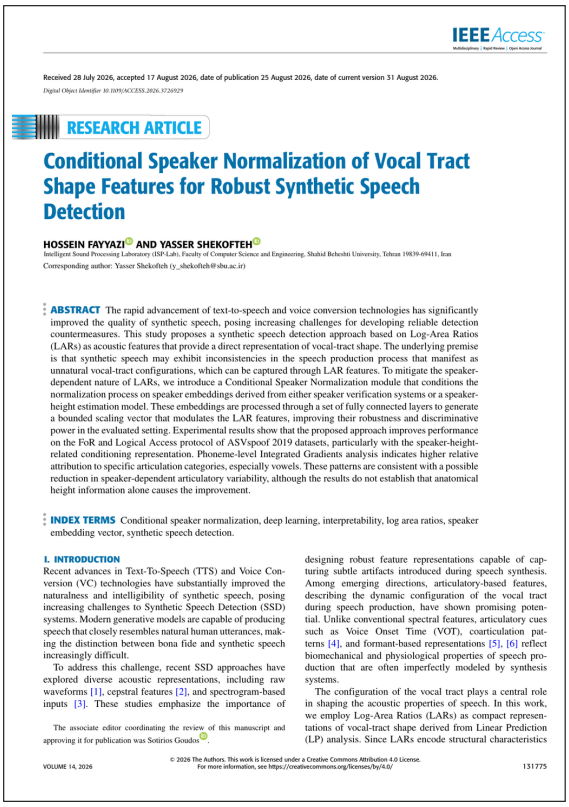
۴. آیا می‌توان با آن گفتار واقعی و مصنوعی را قابل‌اعتماد تفکیک کرد؟

مقاوم‌سازی مدل (Robustness)

استاد پرسید اگر نقاط ضعف یک مدل را شناسایی کردیم، چگونه آن را مقاوم‌تر کنیم؟ پاسخ: استفادهٔ هدفمند از داده‌هایی که مدل در آن‌ها ضعف دارد؛ مثلاً اگر مدل در برخی واکه‌ها ضعیف‌تر است، از همان واکه‌ها دادهٔ بیشتر جمع و به مجموعهٔ



بیضی‌های F1–F2 برای چند واکه در صدای واقعی (آبی) و جعلی (قرمز) برای دو گوینده/پیکره.



IEEE Access

Received 28 July 2026, accepted 17 August 2026, date of publication 25 August 2026, date of current version 31 August 2026.

Digital Object Identifier 10.1109/ACCESS.2026.3726929

RESEARCH ARTICLE

Conditional Speaker Normalization of Vocal Tract Shape Features for Robust Synthetic Speech Detection

HOSSEIN FAYYAZI AND YASSER SHEKOFTEH

Intelligent Sound Processing Laboratory (ISP-Lab), Faculty of Computer Science and Engineering, Shahid Beheshti University, Tehran 19839-69411, Iran

Corresponding author: Yasser Shekofteh (y_shekofteh@sbu.ac.ir)

ABSTRACT The rapid advancement of text-to-speech and voice conversion technologies has significantly improved the quality of synthetic speech, posing increasing challenges for developing reliable detection countermeasures. This study proposes a synthetic speech detection approach based on Log-Area Ratios (LARs) as acoustic features that provide a direct representation of vocal-tract shape. The underlying premise is that synthetic speech may exhibit inconsistencies in the speech production process that manifest as unnatural vocal-tract configurations, which can be captured through LAR features. To mitigate the speaker-dependent nature of LARs, we introduce a Conditional Speaker Normalization module that conditions the normalization process on speaker embeddings derived from either speaker verification systems or a speaker-height estimation model. These embeddings are processed through a set of fully connected layers to generate a bounded scaling vector that modulates the LAR features, improving their robustness and discriminative power in the evaluated setting. Experimental results show that the proposed approach improves performance on the FoR and Logical Access protocol of ASVspoof 2019 datasets, particularly with the speaker-height-related conditioning representation. Phoneme-level Integrated Gradients analysis indicates higher relative attribution to specific articulation categories, especially vowels. These patterns are consistent with a possible reduction in speaker-dependent articulatory variability, although the results do not establish that anatomical height information alone causes the improvement.

INDEX TERMS Conditional speaker normalization, deep learning, interpretability, log area ratios, speaker embedding vector, synthetic speech detection.

I. INTRODUCTION

Recent advances in Text-To-Speech (TTS) and Voice Conversion (VC) technologies have substantially improved the naturalness and intelligibility of synthetic speech, posing increasing challenges to Synthetic Speech Detection (SSD) systems. Modern generative models are capable of producing speech that closely resembles natural human utterances, making the distinction between bona fide and synthetic speech increasingly difficult.

To address this challenge, recent SSD approaches have explored diverse acoustic representations, including raw waveforms [1], cepstral features [2], and spectrogram-based inputs [3]. These studies emphasize the importance of designing robust feature representations capable of capturing subtle artifacts introduced during speech synthesis. Among emerging directions, articulatory-based features, describing the dynamic configuration of the vocal tract during speech production, have shown promising potential. Unlike conventional spectral features, articulatory cues such as Voice Onset Time (VOT), coarticulation patterns [4], and formant-based representations [5], [6] reflect biomechanical and physiological properties of speech production that are often imperfectly modeled by synthesis systems.

The configuration of the vocal tract plays a central role in shaping the acoustic properties of speech. In this work, we employ Log-Area Ratios (LARs) as compact representations of vocal-tract shape derived from Linear Prediction (LP) analysis. Since LARs encode structural characteristics

The associate editor coordinating the review of this manuscript and approving it for publication was Sotirios Goudos.

© 2026 The Authors. This work is licensed under a Creative Commons Attribution 4.0 License.
For more information, see https://creativecommons.org/licenses/by/4.0/

مقالهٔ Conditional Speaker Normalization of Vocal Tract Shape Features for Robust Synthetic Speech Detection، IEEE Access) ۲۰۲۶).

شکل ۹.۴: نمونهٔ استفاده از فضای واکه‌ای و شکل مجرا برای تشخیص گفتار جعلی (برگرفته از تختهٔ کلاس)

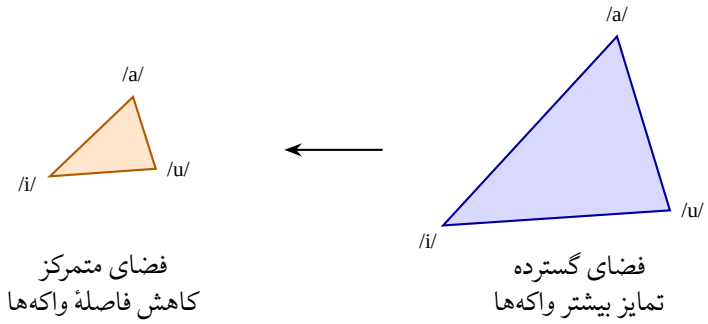
آموزش اضافه شود. روش‌های مرتبط: Data Augmentation (افزایش و متنوع‌سازی دادهٔ آموزشی)، Hard Example Mining (تمرکز بر نمونه‌های دشوار) و Adversarial Training. پیش‌شرط این کار دانستن این است که مدل دقیقاً کجا ضعف دارد، و تحلیل فضای واکه‌ای می‌تواند یکی از راه‌های شناسایی چنین نقاطی باشد.

۳.۷.۴ نشانگر زیستی دیجیتال (Digital Biomarker)

نشانگر زیستی دیجیتال

ویژگی قابل‌اندازه‌گیری‌ای که با ابزارهای دیجیتال به دست می‌آید و دربارهٔ وضعیت یا تغییرات یک فرایند زیستی یا بالینی اطلاعات می‌دهد. ویژگی‌های آکوستیکی گفتار می‌توانند تغییر توانایی تولید گفتار را در طول زمان نشان دهند.

روی تخته: «شاخص بیومارکر دیجیتال برای تعیین پیشرفت بیماری‌های نورولوژیک درگیرکنندهٔ کنترل حرکتی گفتار مثل دمانس یا پارکینسون». در این بیماری‌ها مقادیر فرمنت اول و دوم به سمت مرکز فضای صوتی جمع می‌شوند (**متمرکزشدن** (Centralization)) و مساحت فضای واکه‌ای کوچک می‌شود. وقتی فرد بتواند واکه‌ها را متمایز تولید کند، نقاط واکه‌های مختلف در فضای F1–F2 از هم فاصله دارند؛ با دشوارشدن تمایزهای تولیدی، واکه‌ها به ناحیهٔ مرکزی نزدیک می‌شوند. اندازه‌گیری مکرر در طول زمان می‌تواند تغییراتی را نشان دهد که شنوندهٔ عادی هنوز نمی‌شنود.



شکل ۱۰.۴: نمایش شماتیک متمرکزشدن فضای واکه‌ای: مثلث واکه‌ها کوچک می‌شود و به مرکز نزدیک می‌شود (شکل افزوده).

پایش تغییرات گفتار برای تشخیص زودهنگام

هدف نوشته‌شده روی تخته «تخمین تمام خودکار فضای واکه‌ای» و «اندازه‌گیری کمّی و تشخیص زودهنگام» بود. مقالهٔ Sandoval و همکاران (۲۰۱۳) الگوریتمی خودکار برای تخمین VSA از گفتار پیوستهٔ سالم، به‌جای هجاهای جدا، ارائه می‌کند که کل «فضای کاری» واکه‌ها را در نظر می‌گیرد و همبستگی بالایی با VSA سنتی دارد؛ در موارد اختلاف، روش خودکار دقیق‌تر ارزیابی شده چون همهٔ واکه‌ها را به حساب می‌آورد. روند پایش پیشنهادی:

۱. از فرد خواسته می‌شود هر چند وقت یک بار مجموعه‌ای از واکه‌ها یا جملات مشخص را ضبط کند.

۲. فرمنت‌ها استخراج می‌شوند.

۳. فضای واکه‌ای ساخته می‌شود.

۴. گستردگی و پراکندگی واکه‌ها اندازه‌گیری می‌شود.

۵. با نمونه‌های قبلی همان فرد مقایسه می‌شود.

۶. در صورت تغییر قابل‌توجه، بررسی تخصصی پیشنهاد می‌شود.

استاد ایدهٔ ساخت سامانه‌ای را مطرح کرد که از طریق **تلفن همراه** نمونه‌های گفتار را در طول زمان دریافت و تحلیل کند و تغییرات احتمالی را اعلام کند.

نشانگر زیستی دیجیتال ابزار تشخیص قطعی نیست

شواهد پژوهشی کاهش VSA یا VAI در برخی افراد مبتلا به بیماری پارکینسون و سایر دیزآرتری‌های حرکتی را نشان می‌دهند (از جمله مطالعهٔ Sapir و همکاران ۲۰۱۰ دربارهٔ FCR). اما اثر آن در همهٔ بیماران، همهٔ مراحل و همهٔ واکه‌ها یکسان نیست، و برای دمانس شواهد غیرمستقیم‌تر و ضعیف‌تر است. عبارت «مساحت به شدت کوچک می‌شود» روی تخته را باید حالت شدید بیماری دانست، نه قاعدهٔ عمومی. این شاخص‌ها به‌تنهایی ابزار قطعی تشخیص پارکینسون یا دمانس نیستند و کاربرد بالینی آن‌ها به اعتبارسنجی بالینی و تفسیر متخصص نیاز دارد. همچنین عواملی مانند سن، جنس، خستگی، کیفیت میکروفون تلفن و نویز محیط می‌توانند VSA را تغییر دهند و باید کنترل شوند. متن پیاده‌شدهٔ جلسه در همین بحث، پیش از تکمیل جملهٔ پایانی استاد، قطع می‌شود.

۸.۴ جمع‌بندی

هدف این جلسه فقط استخراج فرکانس از سیگنال نبود: با اندازه‌گیری F1 و F2 در Praat می‌توان بازنمایی‌ای از الگوی تولید واکه‌ها ساخت. F1 با ارتفاع زبان رابطهٔ معکوس و F2 با جلو یا عقب بودن زبان (و گردی لب) رابطه دارد. با برچسب‌گذاری TextGrid و بازهٔ هر واکه، جدول فرمنت‌ها برای هر گروه ساخته می‌شود و در نمودار F1–F2 با محورهای معکوس فضای واکه‌ای شکل می‌گیرد. برای ساخت پیکرهٔ جامعهٔ خاص (مثلاً کودکان) می‌توان از ASR برای متن اولیه و از بازبینی انسانی برای اصلاح بهره برد. مساحت فضای واکه‌ای و شاخص‌هایی مانند VAI مقدار عددی گستردگی فضا را می‌دهند. این بازنمایی امکان مقایسهٔ گویندگان و گروه‌ها، گفتاردرمانی تصویری، تشخیص صدای مصنوعی و پایش تغییرات گفتار (نشانگر زیستی دیجیتال) را فراهم می‌کند؛ اما همهٔ این کاربردها نیاز به اعتبارسنجی دقیق و تفسیر محتاطانه دارند.

نکات مهم برای مرور و امتحان

مفهوم	نکتهٔ اصلی
فرکانس پایه	فرکانس تکرار دورهٔ اصلی سیگنال تناوبی؛ $f_0 = 1/T$؛ مربوط به منبع
Magnitude	اندازهٔ ضریب فوریه و نه دامنهٔ زمانی سیگنال
تعامد	صفرشدن ضرب داخلی دو سیگنال؛ لازم برای موج‌های مبنا
هارمونیک‌ها	مضرب‌های صحیح f_0؛ در موج مربعی فقط مضرب‌های فرد
فرمنت‌ها	ناحیه‌های تشدید مجرا (فیلتر)؛ تخمین با LPC
Wideband / Narrowband	تفکیک زمانی (فرمنت) در برابر تفکیک فرکانسی (هارمونیک)
F1	رابطهٔ معکوس با ارتفاع زبان
F2	رابطهٔ مستقیم با جلو آمدن زبان؛ گردشدن لب‌ها F2 را کاهش می‌دهد
Praat	ضبط، تحلیل (Pitch، Formant، Spectrogram، Intensity)، برچسب‌گذاری
TextGrid	لایه‌های Word، Syllable، Phoneme
فضای واکه‌ای	نمودار F1–F2 با هر دو محور معکوس؛ برای هر گروه جداگانه
ASR + بازبینی انسانی	ساخت سریع‌تر پیکره؛ مستندسازی برچسب‌گذاری ضروری
VSA	مساحت چندضلعی واکه‌های گوشه در F1–F2؛ کوچک‌شدن = متمرکزشدن
کاربردها	گفتاردرمانی (بیوفیدبک تصویری)، تشخیص جعل، نشانگر زیستی دیجیتال

زنجیرهٔ جلسه: سیگنال صوتی ← استخراج ویژگی‌های آکوستیکی (Pitch، طیف، فرمنت) ← اندازه‌گیری F2/F1 در Praat ← ساخت فضای واکه‌ای ← مقایسه با الگوی مرجع یا گروه‌های دیگر ← کاربردهای پژوهشی و عملی.

فصل ۵

ادراک شنیداری، مقیاس مل و ضرایب MFCC

در جلسات پیشین، سیگنال گفتار را از دید فیزیکی و آکوستیکی بررسی کردیم: شکل موج، تبدیل فوریه، هارمونیک‌ها، فرمنت‌ها، فضای واکه‌ای و رابطهٔ ویژگی‌های تولیدی با ویژگی‌های آکوستیکی. در همهٔ آن تحلیل‌ها با طیفی سروکار داشتیم که همهٔ فرکانس‌ها را به یک چشم می‌دید. در این جلسه یک گام جلوتر می‌رویم: ویژگی‌های **سیستم شنوایی انسان** (Human Auditory System) را وارد فرایند استخراج ویژگی می‌کنیم. حاصل این کار مقیاس مل، بانک فیلتر مل، لگاریتم‌گیری از انرژی‌ها و در نهایت **ضرایب کپسترال فرکانس مل** (Mel-Frequency Cepstral Coefficients) یا به‌اختصار MFCC است؛ ویژگی‌ای که تا امروز در بخش بزرگی از سامانه‌های گفتاری به کار می‌رود و در جلسات بعد نیز بارها به آن بازخواهیم گشت.

نقشهٔ راه جلسه

مسیر منطقی جلسه به این صورت است: (۱) چرا باید شنوایی انسان را مدل کنیم؟ (۲) نقشهٔ تونوتوپیک حلزون گوش و مرور Praat؛ (۳) مقیاس مل و بانک فیلتر مثلثی؛ (۴) لگاریتم برای ادراک غیرخطی بلندی؛ (۵) افزونگی ویژگی‌ها و تبدیل کسینوسی گسسته (DCT) و پیدایش ضرایب MFCC؛ (۶) روایت تاریخی کپستروم؛ (۷) کاربردها و رابطهٔ MFCC با یادگیری ماشین و یادگیری عمیق.

۱.۵ چرا باید ادراک شنیداری انسان را در نظر بگیریم؟

تا اینجا، تبدیل فوریه به ما می‌گفت هر مؤلفهٔ فرکانسی چه سهمی در سیگنال دارد، بدون آنکه بپرسد انسان کدام فرکانس‌ها را بهتر تشخیص می‌دهد. اما سیستم شنوایی انسان همهٔ فرکانس‌ها و همهٔ شدت‌ها را یکسان پردازش نمی‌کند. اگر بخواهیم سامانه‌ای بسازیم که رفتارش به ادراک انسان نزدیک باشد (و در عمل، چون گفتار برای شنیده‌شدن توسط انسان تکامل یافته است، بیشترِ اطلاعات مهم آن در همان محدوده‌هایی است که گوش به آن‌ها حساس است)، باید محدودیت‌ها و ویژگی‌های شنوایی را بشناسیم.

۱.۱.۵ محدوده شنوایی

انسان جوان و سالم معمولاً صداهایی را در محدودهٔ تقریبی ۲۰ **هرتز تا** ۲۰ **کیلوهرتز** می‌شنود. فرکانس‌های پایین‌تر از این محدوده (مادون‌صوت) و بالاتر از آن (فراصوت) به‌صورت صدا ادراک نمی‌شوند. اما نشنیدن یک ارتعاش به معنای نبودن آن نیست؛ برای نمونه ممکن است یک ارتعاش مکانیکی شدید را با بدن احساس کنیم بی‌آنکه آن را «بشنویم». پس دو چیز را باید از هم جدا کرد:

- **وجود فیزیکی ارتعاش**: پدیده‌ای که طبق قوانین فیزیک رخ می‌دهد.
- **ادراک شنیداری ارتعاش**: فرایندی که طی آن ارتعاش از بخش‌های مختلف دستگاه شنوایی می‌گذرد و در نهایت در مغز پردازش و به تجربهٔ شنیدن تبدیل می‌شود.

برای روشن‌شدن این تفاوت می‌توان به سیستم بینایی مراجعه کرد. اگر چراغی با فرکانس مشخصی چشمک بزند، روشن‌وخاموش‌شدن آن را می‌بینیم؛ اما اگر فرکانس چشمک‌زدن بسیار زیاد شود، دیگر چشمک‌های جداگانه را تشخیص نمی‌دهیم و چراغ را پیوسته روشن می‌بینیم، هرچند از نظر فیزیکی همچنان خاموش و روشن می‌شود. سیستم شنوایی نیز محدودیت‌های مشابهی دارد.

نتیجهٔ کلیدی

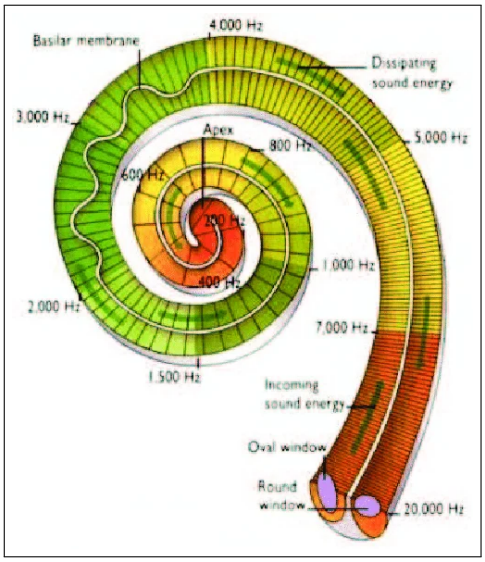
در پردازش گفتار، دانستن مشخصات فیزیکی سیگنال کافی نیست؛ باید بدانیم انسان این مشخصات را چگونه درک می‌کند.

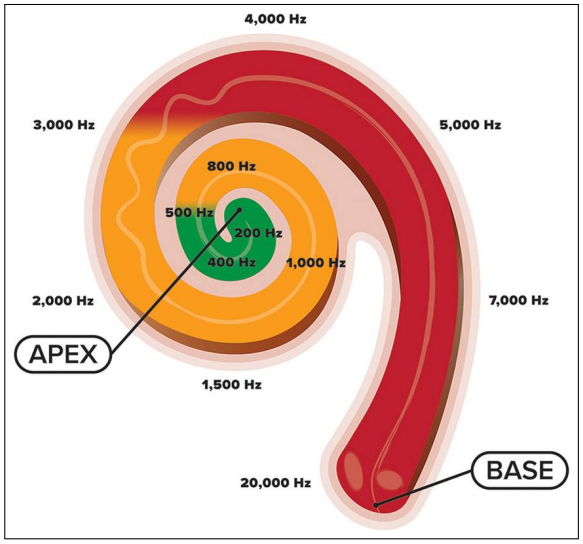
[محتوای افزوده] محدوده شنوایی و گفتار

محدودهٔ ۲۰ هرتز تا ۲۰ کیلوهرتز مربوط به شنوندهٔ جوان است و با افزایش سن (بخش ۴.۵) حد بالایی آن پایین می‌آید. بیشترِ انرژی و اطلاعات گفتار در زیر حدود ۸ کیلوهرتز قرار دارد؛ به همین دلیل در سامانه‌های تشخیص گفتار معمولاً با نرخ نمونه‌برداری 16 kHz کار می‌کنند (طبق قضیهٔ نایکوییست، فرکانس‌ها تا ۸ کیلوهرتز را نمایش می‌دهد) و در تلفن سنتی با 8 kHz (فرکانس‌ها تا ۴ کیلوهرتز؛ پهنای باند مؤثر خط تلفن حدود ۳۰۰ تا ۳۴۰۰ هرتز است).

۲.۵ نقشهٔ تونوتوپیک حلزون گوش

برای فهم چگونگی پردازش فرکانس در گوش، باید به گوش داخلی و بخش مهم آن یعنی **حلزون گوش** (Cochlea) نگاه کنیم. صدا پس از عبور از گوش خارجی و میانی، از طریق دریچهٔ بیضی (oval window) به مایع درون حلزون منتقل می‌شود و در درون حلزون موجی روی **غشای پایه** (Basilar Membrane) پدید می‌آید. نکتهٔ مهم این است که نقاط مختلف این غشا به فرکانس‌های مختلف حساس‌اند. به این سازمان‌دهی فرکانسی، **نقشهٔ تونوتوپیک** (Tonotopic Map) می‌گویند (از ریشهٔ tonos به معنای «آهنگ/نغمه» و topos به معنای «مکان»).





شکل ۱.۵: نقشهٔ تونوتوپیک حلزون گوش. رأس حلزون (Apex) مربوط به فرکانس‌های بم و قاعدهٔ آن (Base) نزدیک دریچه‌های بیضی و گرد مربوط به فرکانس‌های زیر است. اعداد روی تصویر فرکانس تقریبی نقاط مختلف را نشان می‌دهند. (برگرفته از تختهٔ کلاس)

۱.۲.۵ سازمان‌دهی فرکانسی

- **قاعده یا Base**: ناحیهٔ ابتدایی حلزون که صدا نخست به آن می‌رسد؛ به فرکانس‌های بالا (زیر) حساس است.
- **رأس یا Apex**: انتهای مارپیچ حلزون؛ به فرکانس‌های پایین (بم) حساس است.
- هر بخش از غشای پایه به یک محدودهٔ فرکانسی معین حساس‌تر است؛ بنابراین توزیع فرکانس‌ها در دستگاه شنوایی تصادفی نیست و یک «نقشه» دارد.

دقت در خواندن شکل

نمودار حلزون در شکل ۱.۵ ساده‌شده است: عدد نوشته‌شده نزدیک رأس (حدود ۲۰۰ هرتز) حد پایین واقعی شنوایی نیست؛ شنوایی انسان تا حدود ۲۰ هرتز ادامه دارد و ناحیهٔ بسیار کوچک رأس به همین فرکانس‌های خیلی بم مربوط می‌شود. همچنین فاصلهٔ مکانی روی غشای پایه با فرکانس رابطهٔ خطی ندارد، بلکه تقریباً با لگاریتم فرکانس متناسب است (رابطهٔ تجربی گرین‌وود): نیمهٔ رأسی حلزون به‌تنهایی مربوط به فرکانس‌های زیر حدود ۱٫۵ تا ۲ کیلوهرتز است و فرکانس‌های بالاتر در نیمهٔ دیگر فشرده شده‌اند. همین فشردگی ریشهٔ فیزیولوژیک بحث مقیاس مل در ادامه است.

۲.۲.۵ تفکیک نابرابر فرکانس‌های بم و زیر

نتیجهٔ مهم این سازمان‌دهی آن است که ادراک تغییرات فرکانسی خطی نیست. دو تغییر زیر را مقایسه کنید:

$$۱۰۰ \rightarrow ۲۰۰\ \text{Hz} \qquad \text{و} \qquad ۵۱۰۰ \rightarrow ۵۲۰۰\ \text{Hz}.$$

در هر دو، اختلاف فرکانس ۱۰۰ هرتز است؛ اما تغییر اول برای گوش بسیار چشمگیر و تغییر دوم تقریباً نامحسوس است. یعنی میزان تفاوت ادراکی فقط به اختلاف عددی بستگی ندارد، بلکه به محدودهٔ فرکانسی بستگی دارد. دو مثال شهودی

که در کلاس مطرح شد:

- **صدای موتور:** مؤلفه‌های غالب فرکانس پایین‌اند و تغییر نسبتاً کوچکی در آن‌ها (مثلاً هنگام تغییر دور موتور) به‌سادگی شنیده می‌شود.
- **صدای سوت:** فرکانس بالایی دارد و اگر فرکانسش کمی تغییر کند، تشخیص تفاوت دو صدا دشوارتر است.

به بیان کلاس: گوش ما در فرکانس‌های پایین (زیر حدود ۱۰۰۰ هرتز) بسیار دقیق است، اما در فرکانس‌های بالا (بالای حدود ۴۰۰۰ هرتز) تفاوت‌ها را به‌خوبی تشخیص نمی‌دهد.

دقت علمی درباره «تفاضل مهم نیست، نسبت مهم است»

جمع‌بندی دقیق‌تر این است که توان تفکیک فرکانسی گوش (کوچک‌ترین تفاوت قابل‌تشخیص، JND) در فرکانس‌های زیر حدود ۵۰۰ تا ۱۰۰۰ هرتز در حد چند هرتز است و در فرکانس‌های بالاتر تقریباً با خود فرکانس بزرگ می‌شود (یعنی نسبت‌محور است). بنابراین تغییر ۱۰۰ هرتز در ۵ کیلوهرتز برای شنوندهٔ آموزش‌دیده در آزمایشگاه هنوز قابل‌تشخیص است؛ نکتهٔ درست این است که برای گوش، آن تغییر بسیار کوچک‌تر از تغییر ۱۰۰ به ۲۰۰ هرتز به‌نظر می‌رسد (در مقیاس ادراکی). این همان چیزی است که مقیاس مل می‌خواهد مدل کند.

[محتوای افزوده] مقایسهٔ عددی دو تغییر ۱۰۰ هرتزی

اگر تغییر فرکانس را به‌صورت «نسبت» بسنجیم، تغییر ۱۰۰ به ۲۰۰ هرتز یک اکتاو کامل است (نسبت ۲، یعنی ۱۲۰۰ سنت)، اما تغییر ۵۱۰۰ به ۵۲۰۰ هرتز فقط نسبت ۱٫۰۱۹۶ ≈ ۵۲۰۰/۵۱۰۰ است:

$$۱۲۰۰ \log_۲ \frac{۵۲۰۰}{۵۱۰۰} \approx ۳۳٫۶ \text{ سنت} \qquad (\text{حدود } \tfrac{۱}{۳۶} \text{ اکتاو}).$$

در مقیاس مل (بخش بعد) همین دو تغییر به‌ترتیب حدود ۱۳۲٫۷ و ۱۹٫۳ مل‌اند؛ یعنی تغییر اول از نظر ادراکی بیش از ۶ برابر بزرگ‌تر است.

۳.۲.۵ پیامد برای طراحی ویژگی

اگر بخواهیم ویژگی‌هایی متناسب با شنوایی انسان بسازیم، نباید همهٔ بازه‌های فرکانسی را با دقت یکسان نمایش دهیم. می‌خواهیم:

- در فرکانس‌های پایین تفکیک بیشتر (بازه‌های باریک) داشته باشیم؛
- در فرکانس‌های بالا بازه‌های گسترده‌تری را در یک گروه جمع کنیم؛
- ویژگی‌ها را طوری بسازیم که به ساختار ادراک شنیداری نزدیک‌تر باشند.

این ایده مبنای مقیاس مل است.

۳.۵ مرور سه ویژگی Pitch، Formant و Intensity در Praat

پیش از رفتن به سراغ مل، استاد با نمایش یک سیگنال گفتاری در نرم‌افزار Praat سه ویژگی مهم را مرور کرد. در نمایش پیش‌فرض این نرم‌افزار، روی اسپکتروگرام خاکستری، مسیر فرمنت‌ها با نقطه‌های قرمز، مسیر pitch با خط آبی و منحنی شدت صوت با خط زرد نشان داده می‌شود.

- **فرمنت** (Formant): نواحی تشدید طیفی که در بررسی واکه‌ها اهمیت دارند و با F_1، F_2 و F_3 نشان داده می‌شوند. در جلسات قبل از آن‌ها برای ساخت فضای واکه‌ای استفاده کردیم.
- **پیچ** (Pitch): ادراک زیر و بمی صدا که با فرکانس پایه (F_0، تناوب سیگنال) ارتباط نزدیک دارد، اما با آن یکی نیست: F_0 کمیتی فیزیکی است و pitch کمیتی ادراکی.
- **شدت** (Intensity): معیاری از «قدرت» کلی صوت در هر لحظه. برخلاف طیف که انرژی هر فرکانس را جداگانه نشان می‌دهد، منحنی intensity تغییر شدت کلی را در طول زمان نمایش می‌دهد (فریادزدن شدت زیاد، صحبت آرام شدت کم).

جدول ۱.۵: تمایز کمیت‌های فیزیکی و ادراکی که باید از هم جدا نگه داشته شوند.

کمیت فیزیکی	کمیت ادراکی متناظر	توضیح
فرکانس پایه (F_0)	زیر و بمی (Pitch)	تناوب موج در برابر احساس زیر/بم
شدت (Intensity)	بلندی (Loudness)	توان فیزیکی در برابر بلندی احساس‌شده
فرمنت‌ها / شکل طیف	رنگ صدا (Timbre) و کیفیت واکه	تشدیدهای مجرای صوتی

زیر و بمی با بلندی یکی نیست: یک فرد می‌تواند با صدای زیر ولی بسیار آرام صحبت کند یا با صدای بم و پرشدت. این دو بُعد باید جداگانه بررسی شوند، و این تمایز میان «شدت فیزیکی» و «بلندی ادراک‌شده» در بخش لگاریتم دوباره مهم می‌شود.

محاسبهٔ دقیق شدت صوت

در کلاس گفته شد که شدت را می‌توان به‌صورت شهودی «تجمیع انرژی مؤلفه‌های فرکانسی در یک لحظه» دید. این شهود درست است، ولی محاسبهٔ دقیق جمع سادهٔ مقدارهای اندازه (magnitude) طیف نیست. شدت بر پایهٔ مربع دامنه (توان) محاسبه می‌شود و (طبق رابطهٔ پارسوال) جمع مربعات اندازهٔ طیف با میانگین مربع موج در حوزهٔ زمان برابر است. در Praat شدت از مربع نمونه‌های سیگنال در یک پنجرهٔ زمانی هموارکننده به دست می‌آید و بر حسب دسی‌بل نسبت به فشار مرجع 2×10^{-5} پاسکال گزارش می‌شود.

پرسش و پاسخ: چرا خط pitch بالاتر از نقطه‌های فرمنت دیده می‌شود؟

یکی از دانشجویان پرسید چرا در تصویر Praat گاهی خط آبی pitch بالاتر از نقطه‌های قرمز فرمنت است، در حالی که F_0 همواره از F_1 پایین‌تر است. پاسخ: این نمودارها با محورهای مختلف رسم می‌شوند؛ مقیاس pitch

در یک سمت تصویر و مقیاس فرمنت‌ها در سمت دیگر نمایش داده می‌شود و بنابراین بالاتر بودن خط روی صفحه دلیلی بر بزرگ‌تر بودن مقدار فرکانسی آن نیست. تنظیمات نمایش pitch را نیز می‌توان در Praat تغییر داد. چگونگی محاسبهٔ کانتور این ویژگی‌ها در جلسهٔ بعد بیشتر بررسی می‌شود.

۴.۵ کم‌شنوایی فرکانس‌های بالا با افزایش سن

یکی از پیامدهای نقشهٔ تونوتوپیک این است که چون ناحیهٔ قاعدهٔ حلزون به فرکانس‌های بالا مربوط است، آسیب به همین ناحیه موجب کاهش توان شنیدن صداهای زیر می‌شود. کم‌شنوایی فرکانس‌های بالا در سنین بالا بسیار رایج است؛ این پدیده را **پیرگوشی** (Presbycusis) می‌نامند. به بیان تختهٔ کلاس: وقتی پایهٔ حلزون تحلیل می‌رود، شنونده برای تفکیک و درک گفتارهای دارای فرکانس زیر باید انرژی و تلاش بیشتری صرف کند.

دلیل مطرح‌شده در کلاس این بود که سلول‌های ناحیهٔ Base در «خط مقدم» ضربه‌های مکانیکی‌اند، سریع‌تر کار می‌کنند، خون‌رسانی آسیب‌پذیرتری دارند و دفاع آنتی‌اکسیدانی کمتری دارند؛ به همین دلیل در نقشهٔ تونوتوپیک نخستین جایی هستند که با گذر سن تحلیل می‌روند.

دقت علمی دربارهٔ علل پیرگوشی

الگوی کلی (افت شنوایی تدریجی، دوطرفه و عمدتاً در فرکانس‌های بالا) درست است. ولی علت آن چندعاملی است و نباید به یک توضیح ساده تقلیل یابد: از دست رفتن سلول‌های مویی حلزون، تحلیل رگ‌های نوار عروقی (stria vascularis)، کاهش نورون‌های عصب شنوایی، استرس اکسایشی، سابقهٔ مواجهه با نویز، عوامل ژنتیکی و داروهای آسیب‌رسان به گوش. یکی از دلایل شایعی که برای حساسیت ناحیهٔ قاعده بیان می‌شود این است که هر صدایی، صرف‌نظر از فرکانس، ابتدا از ناحیهٔ قاعده عبور می‌کند و آن ناحیه بیشترین بار مکانیکی و متابولیکی را تحمل می‌کند. توضیح تختهٔ کلاس (مکانیکی، خون‌رسانی، دفاع آنتی‌اکسیدانی) در همین چارچوب قابل‌فهم است؛ با این حال، آن را باید «مجموعه‌ای از سازوکارهای محتمل» دانست نه یک علت قطعی.

[محتوای افزوده] پیامد عملی برای گفتار

بسیاری از همخوان‌های بی‌واک مانند /s/، /f/ و /sh/ انرژی عمده‌شان در فرکانس‌های بالا (چند کیلوهرتز) است؛ به همین دلیل افراد دچار پیرگوشی معمولاً در تفکیک این همخوان‌ها و درک گفتار (به‌ویژه در محیط پرنویز) مشکل بیشتری دارند، هرچند صدا را «بلند» می‌شنوند. این مثالی است از اینکه حساسیت شنوایی نه‌تنها در فرکانس‌های مختلف یکسان نیست، بلکه با سن و شرایط فیزیولوژیک نیز تغییر می‌کند.

۵.۵ مقیاس مل

تا اینجا دیدیم که گوش تفاوت فرکانس‌ها را به‌صورت خطی درک نمی‌کند. برای وارد کردن این ویژگی در پردازش گفتار از **مقیاس مل** (Mel Scale) استفاده می‌کنیم.

مقیاس مل

مقیاس مل یک **نگاشت غیرخطی** از فرکانس فیزیکی (بر حسب هرتز) به یک مقیاس ادراکی (بر حسب مل) است که فرکانس‌های بالا را «فشرده» می‌کند تا فاصله‌های برابر روی این محور تقریباً با تفاوت‌های ادراکی برابر در زیر و بمی متناظر باشند. نام «مل» از واژهٔ melody (آهنگ) گرفته شده است.

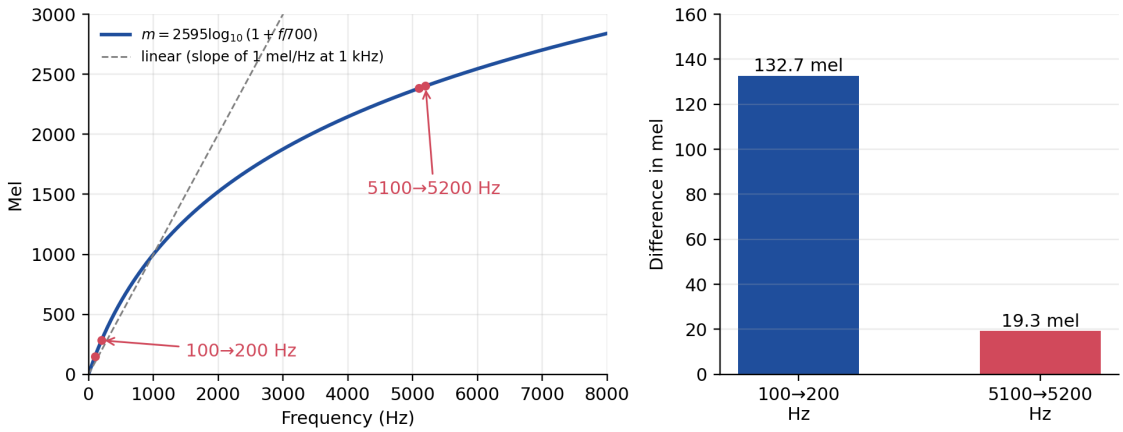
فرمول مقیاس مل

مقیاس مل را استیونز، فولکمن و نیومن در سال ۱۹۳۷ از آزمایش‌های قضاوت زیر و بمی شنوندگان معرفی کردند. در پردازش گفتار، رایج‌ترین تقریب تحلیلی آن (که در کلاس به‌صورت عددی بیان نشد) چنین است:

$$m = ۲۵۹۵ \log_{۱۰}\left(۱ + \frac{f}{۷۰۰}\right) \qquad \Longleftrightarrow \qquad f = ۷۰۰\left(۱۰^{m/۲۵۹۵} - ۱\right).$$

نسخهٔ طبیعی‌لگاریتمی آن $m = ۱۱۲۷ \ln(۱ + f/۷۰۰)$ است (هر دو یکی‌اند). نگاشت ۱۰۰۰ هرتز به ۱۰۰۰ مل با همین ثابت‌ها برقرار می‌شود. قراردادهای دیگری (مثلاً نسخهٔ اسلینی: خطی در زیر ۱ کیلوهرتز و لگاریتمی در بالاتر) نیز وجود دارند؛ بنابراین خروجی کتابخانه‌های مختلف ممکن است اندکی با هم تفاوت داشته باشد.

رفتار این تابع دو بخش دارد: در فرکانس‌های پایین (زیر حدود ۱ کیلوهرتز) تقریباً خطی است و در فرکانس‌های بالاتر شیب آن کاهش می‌یابد (رشد لگاریتمی).



شکل ۲.۵: چپ: منحنی تبدیل هرتز به مل؛ شیب منحنی در فرکانس‌های بالا کم می‌شود. راست: همان دو تغییر ۱۰۰ هرتزی مثال کلاس در مقیاس مل؛ تغییر ۱۰۰ به ۲۰۰ هرتز بسیار بزرگ‌تر از تغییر ۵۱۰۰ به ۵۲۰۰ هرتز است. (شکل افزوده)

[محتوای افزوده] مثال عددی: تبدیل هرتز به مل

با فرمول $m = ۲۵۹۵ \log_{۱۰}(۱ + f/۷۰۰)$ برای چند فرکانس:

f (هرتز)	۱۰۰	۲۰۰	۵۰۰	۱۰۰۰	۲۰۰۰	۴۰۰۰	۵۱۰۰	۸۰۰۰
m (مل)	۱۵۰٫۵	۲۸۳٫۲	۶۰۷٫۴	۱۰۰۰٫۰	۱۵۲۱٫۴	۲۱۴۶٫۱	۲۳۸۳٫۱	۲۸۴۰٫۰

نمونه:

$$m(۱۰۰۰) = ۲۵۹۵ \log_{۱۰}\left(۱ + \frac{۱۰۰۰}{۷۰۰}\right) = ۲۵۹۵ \times ۰٫۳۸۵۳ \approx ۱۰۰۰.$$

برای عکس مسئله، فرکانس متناظر ۱۵۰۰ مل برابر است با

$$f = ۷۰۰ \left(۱۰^{۱۵۰۰/۲۵۹۵} - ۱\right) = ۷۰۰ \times (۳٫۷۸۵ - ۱) \approx ۱۹۴۹ \text{ هرتز}.$$

توجه کنید بازهٔ ۰ تا ۸ کیلوهرتز فقط به حدود ۲۸۴۰ مل نگاشت می‌شود و نیمی از این بازهٔ مل (۰ تا ۱۴۲۰ مل) در زیر حدود ۱۷۶۰ هرتز قرار دارد؛ یعنی مقیاس مل به فرکانس‌های پایین «فضای بیشتری» می‌دهد.

۱.۵.۵ مسئلهٔ طیف خطی

فرض کنید طیفی داریم که برای هر فرکانس انرژی (یا اندازهٔ) مشخصی دارد. در نمایش معمول، فرکانس‌ها روی محوری خطی چیده شده‌اند، در حالی که تفکیک گوش خطی نیست. هدف این است که:

- اطلاعات فرکانس‌های پایین را با تفکیک بیشتر نگه داریم؛
- فرکانس‌های بالا را در بازه‌های پهن‌تر گروه‌بندی کنیم؛
- از تعداد زیادی مقدار فرکانسی، مجموعهٔ کوچک‌تری از ویژگی‌های مناسب گفتار بسازیم.

ابزار انجام این کار، **بانک فیلتر مل** است.

۶.۵ بانک فیلتر مل

بانک فیلتر مل (Mel Filterbank) مجموعه‌ای از فیلترهای مثلثی است که روی محور فرکانس چیده می‌شوند. هر فیلتر یک بازهٔ فرکانسی را پوشش می‌دهد و از اطلاعات آن بازه یک عدد استخراج می‌کند: انرژی آن باند.

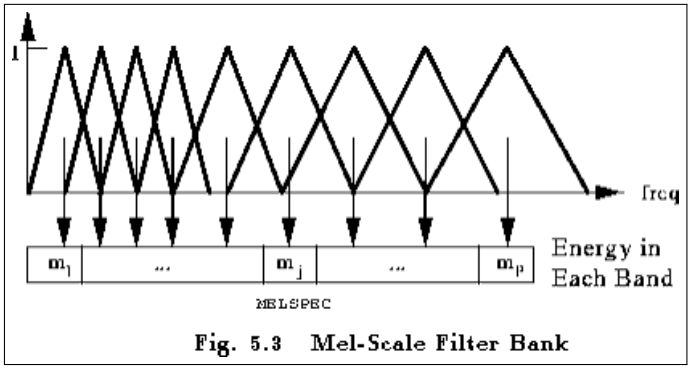


Fig. 5.3 Mel-Scale Filter Bank

شکل ۳.۵: بانک فیلتر مثلثی مل: فیلترها پشت سر هم و هم‌پوشان چیده شده‌اند و خروجی هر فیلتر انرژی باند متناظر را (Energy in Each Band) می‌دهد. با رفتن به فرکانس‌های بالاتر، مثلث‌ها پهن‌تر می‌شوند. (برگرفته از تختهٔ کلاس)

۱.۶.۵ وزن‌دهی مثلثی

هر فیلتر سه بخش دارد: ابتدای بازه که وزن نزدیک صفر است، مرکز بازه که وزن به بیشینه (معمولاً ۱) می‌رسد، و انتهای بازه که وزن دوباره به صفر می‌رسد. بنابراین فرکانس‌های نزدیک مرکز فیلتر سهم بیشتری دارند. مقدار طیفی هر فرکانس در وزن متناظر ضرب و حاصل‌ها جمع می‌شوند:

$$S_m = \sum_k H_m[k]\, P[k],$$

که در آن $P[k]$ طیف توان (یا اندازه) در پایهٔ kام و $H_m[k]$ وزن فیلتر mام است. خروجی هر فیلتر یک عدد است که اطلاعات طیفی بازهٔ زیر پوشش خود را خلاصه می‌کند.

مثال عددی کلاس: خروجی یک فیلتر

فرض کنید فیلتری سه مؤلفهٔ طیفی با مقدارهای ۴، ۸ و ۶ و وزن‌های ۰٫۵، ۱ و ۰٫۵ دریافت کند (اعداد صرفاً آموزشی‌اند). خروجی برابر است با

$$M_1 = (۴ \times ۰٫۵) + (۸ \times ۱) + (۶ \times ۰٫۵) = ۲ + ۸ + ۳ = ۱۳.$$

یعنی به‌جای نگه‌داشتن سه مقدار جداگانه، یک عدد داریم. این کار برای همهٔ فیلترهای بانک تکرار می‌شود.

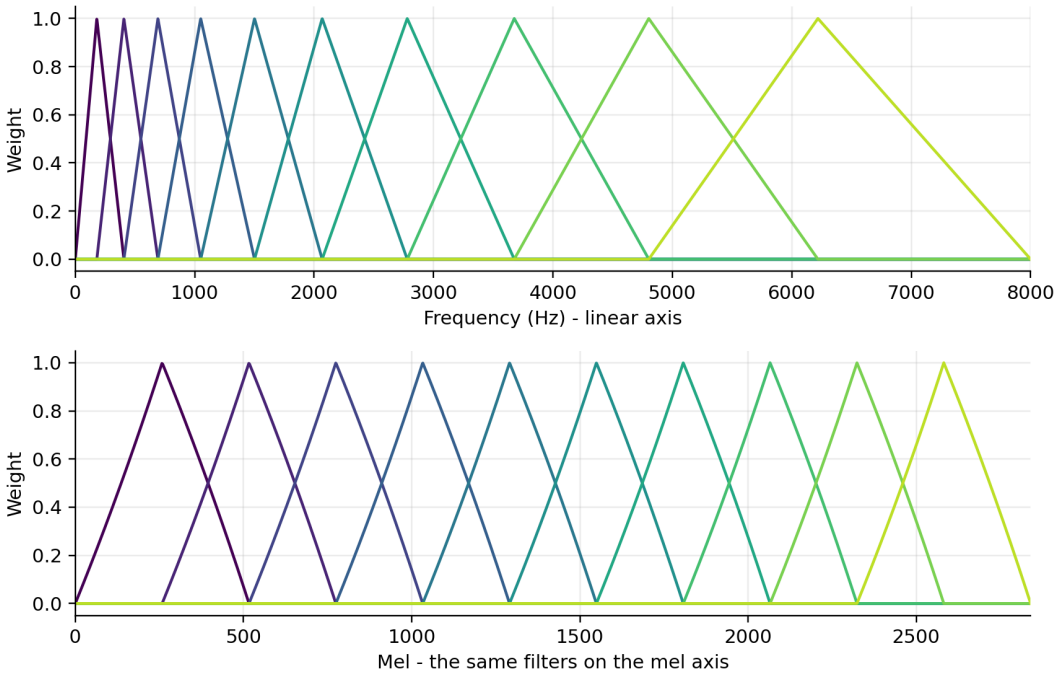
۲.۶.۵ چرا فیلترها هم‌پوشان‌اند؟

فیلترهای مجاور هم‌پوشانی دارند؛ یعنی یک فرکانس ممکن است در محاسبهٔ خروجی دو فیلتر مجاور مشارکت کند. دلیل آن این است که اطلاعات فرکانس‌های نزدیک به مرز دو باند ناگهان حذف یا دچار تغییر پرشی نشود. در طراحی استاندارد، قلهٔ هر مثلث دقیقاً روی نقطهٔ صفر مثلث قبلی و بعدی قرار می‌گیرد؛ در نتیجه مجموع وزن همهٔ فیلترها در هر نقطه (جز دو لبهٔ محور) برابر ۱ است و حساسیت کلی روی محور فرکانس صاف و پیوسته می‌ماند.

مثال تختهٔ کلاس برای فهم ضرورت هم‌پوشانی: فرض کنید مرز دو باند روی ۳۰۰ هرتز باشد و فیلترها مستطیلی و بدون هم‌پوشانی باشند. اگر گوینده فقط ۱ هرتز تغییر کند (مثلاً از ۲۹۹ به ۳۰۱)، آن مؤلفه ناگهان از یک فیلتر خارج و وارد فیلتر دیگر می‌شود و خروجی‌ها پرش می‌کنند. با مثلث‌های هم‌پوشان، همین تغییر کوچک فقط تغییر هموار و کوچکی در خروجی‌ها ایجاد می‌کند.

۳.۶.۵ چرا عرض فیلترها یکسان نیست؟

مهم‌ترین نکتهٔ بانک فیلتر مل: روی محور خطی فرکانس، عرض فیلترها یکسان نیست. فیلترها در فرکانس‌های پایین باریک و در فرکانس‌های بالا پهن‌اند (در کلاس: هرچه به فرکانس‌های بالاتر می‌رویم عرض مثلث‌ها، یعنی Bandwidth، بیشتر می‌شود و این یعنی دقت در فرکانس‌های بالا کمتر است). دلیل آن است که فیلترها روی محور مل یکسان و هم‌فاصله‌اند و وقتی به هرتز برگردانده می‌شوند، در فرکانس‌های بالا پهن می‌شوند. این همان ایدهٔ نقشهٔ تونوتوپیک است.



شکل ۴.۵: نمونهٔ یک بانک ده‌فیلتری برای بازهٔ ۰ تا ۸ کیلوهرتز. بالا: روی محور خطی هرتز، فیلترها به‌تدریج پهن می‌شوند. پایین: همان فیلترها روی محور مل، مثلث‌هایی یکسان و هم‌فاصله‌اند. در هر دو نمودار قلهٔ هر فیلتر روی صفر فیلترهای مجاور است. (شکل افزوده)

[محتوای افزوده] ساختن بانک فیلتر: الگوریتم و اعداد

برای ساخت M فیلتر بین $f_{\min}$ و $f_{\max}$: (۱) هر دو را به مل ببرید؛ (۲) $M+۲$ نقطهٔ هم‌فاصله روی محور مل بگذارید؛ (۳) نقاط را به هرتز برگردانید؛ (۴) فیلتر m با لبه‌های $f_{m-۱}$ و $f_{m+۱}$ و قلهٔ f_m تعریف می‌شود:

$$H_m[k] = \begin{cases} ۰ & f[k] < f_{m-۱} \\ \dfrac{f[k]-f_{m-۱}}{f_m - f_{m-۱}} & f_{m-۱} \le f[k] \le f_m \\ \dfrac{f_{m+۱}-f[k]}{f_{m+۱}-f_m} & f_m \le f[k] \le f_{m+۱} \\ ۰ & f[k] > f_{m+۱}. \end{cases}$$

مثال: برای $M=۴۰$ و بازهٔ ۰ تا ۸۰۰۰ هرتز (۲۸۴۰ مل)، فاصلهٔ نقاط $۲۸۴۰/۴۱ \approx ۶۹٫۳$ مل است. فیلتر اول لبه‌های ۰، ۴۴ و ۹۲ هرتز (عرض $\approx$ ۹۲ هرتز) و فیلتر چهلم لبه‌های حدود ۶۹۹۴، ۷۴۸۱ و ۸۰۰۰ هرتز (عرض $\approx$ ۱۰۰۰ هرتز) دارد؛ یعنی عرض فیلتر آخر بیش از ۱۰ برابر فیلتر اول است. با تبدیل فوریهٔ ۵۱۲ نقطه‌ای در 16 kHz (فاصلهٔ پایه‌ها ۳۱٫۲۵ هرتز) فیلتر اول فقط روی ۲ ــ ۳ پایه و فیلتر آخر روی حدود ۳۲ پایه سوار است.

۴.۶.۵ تعداد فیلترها

در کلاس گفته شد که در بسیاری از پیاده‌سازی‌ها حدود ۴۰ فیلتر مل به کار می‌رود؛ خروجی هر فریم یک بردار ۴۰تایی است:

$$\mathbf{M} = [M_۱, M_۲, \ldots, M_{۴۰}].$$

استاد تأکید کرد که عدد ۴۰ یک مقدار تجربی و متداول است نه ثابت اجباری؛ بسته به مسئله می‌توان آن را تغییر داد.

[محتوای افزوده] مقادیر رایج

تعداد فیلتر در ابزارهای مختلف متفاوت است: در HTK برای گفتار 16 kHz معمولاً ۲۶ فیلتر، در Kaldi حدود ۲۳ فیلتر (برای MFCC)، و در مدل‌های عصبی (log-mel) رایج است ۴۰، ۸۰ یا ۱۲۸ فیلتر به کار رود (مثلاً Whisper از ۸۰ و نسخهٔ جدیدتر آن از ۱۲۸ کانال مل استفاده می‌کند).

طیف توان یا اندازه؟

در کلاس گفته شد که اندازهٔ (magnitude) خروجی فوریه در مثلث‌ها ضرب می‌شود. هر دو روش در عمل دیده می‌شوند، اما در تعریف استاندارد MFCC فیلترها روی طیف توان (مربع اندازه، انرژی) اعمال می‌شوند؛ چون عنوان «انرژی هر باند» مدنظر است. اگر اندازه استفاده شود، ضرایب نهایی با مقیاس متفاوتی به دست می‌آیند.

پرسش و پاسخ: آیا با ادغام فرکانس‌ها اطلاعات را از دست نمی‌دهیم؟

چرا، عمداً اطلاعات را خلاصه می‌کنیم. هدف نگه‌داشتن طیف اصلی بدون تغییر نیست؛ هدف ساختن نمایشی مناسب‌تر برای گفتار است. تفکیک ریز فرکانس‌های بالا از دید ادراک شنوایی اهمیت کمتری دارد، پس می‌توان بازه‌های بزرگ‌تری را در آن ناحیه ادغام کرد، و هم‌پوشانی فیلترها از حذف ناگهانی اطلاعات مرزی جلوگیری می‌کند. این همان ایدهٔ «فشرده‌سازی مطابق ادراک» است.

۷.۵ ادراک غیرخطی بلندی صدا و لگاریتم

گوش علاوه بر غیرخطی بودن در فرکانس، در شدت نیز غیرخطی است: بلندی ادراک‌شده با افزایش خطی شدت فیزیکی صوت به‌صورت خطی تغییر نمی‌کند. اگر شدت فیزیکی صدای یک گوینده ۱۰۰ برابر شود، احساس نمی‌کنیم صدا ۱۰۰ برابر بلندتر شده است، بلکه فقط چند برابر. این ویژگی (که به‌صورت محافظت از گوش و گسترهٔ پویای وسیع آن نیز تعبیر می‌شود) به سیستم شنوایی اجازه می‌دهد با گسترهٔ بسیار وسیعی از شدت‌ها کار کند.

۱.۷.۵ راه‌حل: لگاریتم

برای وارد کردن این ویژگی، از خروجی هر فیلتر مل لگاریتم می‌گیریم:

$$L_i = \log(M_i), \qquad \mathbf{L} = [\log M_۱, \log M_۲, \ldots, \log M_{۴۰}].$$

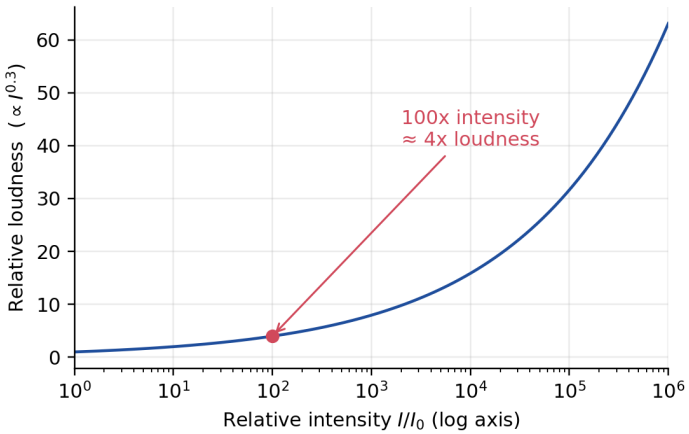
لگاریتم تغییرات بسیار بزرگ را فشرده می‌کند:

$$\log_{۱۰}(۱۰) = ۱, \quad \log_{۱۰}(۱۰۰) = ۲, \quad \log_{۱۰}(۱۰۰۰) = ۳.$$

ورودی از ۱۰ تا ۱۰۰۰ (۱۰۰ برابر) رشد کرده، ولی خروجی فقط از ۱ به ۳ رسیده است. در کلاس تأکید شد که در این مرحله فقط روی شدت لگاریتم گرفته می‌شود و به زیر و بمی کاری نداریم.

لگاریتم، تقریبی از بلندی؛ نه خود بلندی

لگاریتم یک مدل ساده و مناسب از فشردگی بلندی است، نه رابطهٔ دقیق آن. آزمایش‌های روان‌فیزیکی (قانون توانی استیونز) نشان می‌دهند بلندی تقریباً با $I^{۰/۳}$ متناسب است: به‌ازای هر ۱۰ دسی‌بل افزایش تراز، بلندی حدود دو برابر می‌شود. پس اگر شدت ۱۰۰ برابر (۲۰ دسی‌بل) شود، بلندی حدود $۱۰۰^{۰/۳} \approx ۴$ برابر می‌شود، نه ۱۰۰ برابر. لگاریتم و توان ۰٫۳ هر دو منحنی‌هایی با شیب کاهنده‌اند و در عمل لگاریتم مناسب و ساده‌تر است. به‌علاوه، گسترهٔ پویای گوش از آستانهٔ شنوایی تا آستانهٔ درد حدود $۱۰^{۱۲}$ برابر توان (۱۲۰ دسی‌بل) است؛ مقیاس دسی‌بل خود یک مقیاس لگاریتمی است.



شکل ۵.۵: بلندی نسبی ($\propto I^{۰/۳}$) در برابر شدت نسبی. با ۱۰۰ برابر شدن شدت فیزیکی، بلندی حدود ۴ برابر می‌شود؛ منحنی روی محور لگاریتمی شدت رسم شده است. (شکل افزوده)

لگاریتم صفر!

اگر خروجی یک فیلتر دقیقاً صفر باشد (مثلاً در سکوت دیجیتال)، $\log ۰ = -\infty$ می‌شود. در پیاده‌سازی عملی یک مقدار کوچک ε (مثلاً $۱۰^{-۱۰}$) به انرژی اضافه یا کف مناسبی برای آن در نظر گرفته می‌شود: $L_i = \log(M_i + \varepsilon)$.

[محتوای افزوده] مزیت‌های دیگر لگاریتم

افزون بر ادراک، لگاریتم یک مزیت پردازشی هم دارد: ضرب را به جمع تبدیل می‌کند. اگر سیگنال x از کانالی (میکروفون، اتاق) با پاسخ فرکانسی h عبور کند، در حوزهٔ طیف $|Y| = |X||H|$ و در حوزهٔ لگاریتم $\log|Y| = \log|X| + \log|H|$؛ یعنی اثر کانال به‌صورت یک مقدار ثابت جمع‌شونده در می‌آید و با تکنیک‌هایی مانند حذف میانگین کپسترال (CMN) قابل حذف است.

۲.۷.۵ جمع‌بندی دو مرحلهٔ نخست

جدول ۲.۵: دو ادراک غیرخطی شنوایی و راه‌حل‌های متناظر آن‌ها در MFCC.

مسئله	راه‌حل
ادراک غیرخطی تفاوت فرکانس‌ها	مقیاس مل و بانک فیلتر مل
ادراک غیرخطی تغییرات شدت صوت	تبدیل لگاریتمی

۸.۵ افزونگی ویژگی‌ها و تبدیل کسینوسی گسسته

پس از بانک فیلتر مل و لگاریتم، برای هر فریم گفتار ۴۰ عدد داریم. اما این ۴۰ عدد کاملاً مستقل نیستند: فیلترهای مجاور هم‌پوشان‌اند و اطلاعات طیفی مجاور را می‌بینند، پس خروجی بسیاری از آن‌ها شباهت و هم‌بستگی زیاد (Correlation) دارد؛ اطلاعات بخشی از آن‌ها تکراری یا کم‌اهمیت‌تر است. می‌خواهیم تعداد ویژگی‌ها را کم کنیم، به شکلی که بخش مهم اطلاعات حفظ شود.

۱.۸.۵ یک تبدیل دیگر روی دنباله

ایدهٔ مرحلهٔ بعد این است که روی همین دنبالهٔ ۴۰تایی یک تبدیل دیگر اعمال کنیم. در تختهٔ کلاس این مرحله چنین توضیح داده شد: «یک فوریهٔ مجدد (DCT) به این ۴۰ عدد می‌زنیم تا عصارهٔ آن‌ها را بکشیم». از خروجی این تبدیل، ۱۲ یا ۱۳ ضریب اول نگه داشته می‌شوند و همین‌ها MFCC نام دارند. استاد این مرحله را به‌صورت شهودی «انجام یک تبدیل فوریهٔ دیگر» توضیح داد و گفت این ۱۲ــ۱۳ عدد «خالص‌ترین شناسهٔ شکل دهان و واج‌های گفتار» هستند و حجم داده را هم برای مدل‌ها بسیار کم می‌کنند.

تبدیل کسینوسی گسسته (**تبدیل کسینوسی گسسته** (Discrete Cosine Transform, DCT)) دنبالهٔ ورودی را به ترکیبی از کسینوس‌هایی با فرکانس‌های رو به افزایش تجزیه می‌کند. برای M مقدار لگاریتمی $L_۱, \ldots, L_M$:

$$c_n = \sum_{m=۱}^{M} L_m \cos\Big(\frac{\pi n\,(m-\frac{۱}{۲})}{M}\Big), \qquad n = ۰, ۱, \ldots, ۱۲.$$

اینجا دنبالهٔ L_m را مانند یک «سیگنال» می‌بینیم که متغیر مستقل آن به‌جای زمان، شمارهٔ فیلتر (فرکانس) است. ضرایب پایین‌تر (n کوچک) تغییرات کند و کلی شکل طیف (پوش طیف) را توصیف می‌کنند و ضرایب بالاتر تغییرات سریع و ریز را.

چرا DCT هم‌بستگی را کم می‌کند؟

دلیل دقیق: لگاریتم انرژی فیلترهای مجاور به‌سبب هم‌پوشانی و هموار بودن پوش طیف بسیار هم‌بسته است. پایه‌های DCT (کسینوس‌ها) متعامدند و برای دنباله‌های هموار و به‌شدت هم‌بسته (مانند فرایند مارکوف مرتبهٔ اول با هم‌بستگی بالا) تقریب بسیار خوبی از تبدیل **کارونن‌لوو** (Karhunen-Loève Transform) (همان PCA)

هستند؛ یعنی بیشترِ انرژی در چند ضریب نخست جمع می‌شود و ضرایب خروجی تقریباً ناهم‌بسته‌اند. این ناهم‌بستگی در تاریخِ تشخیص گفتار مهم بود، چون مدل‌های GMM با ماتریس کوواریانس قطری را روی MFCC امکان‌پذیر می‌ساخت.

[محتوای افزوده] مثال عددی: فشردگی انرژی با DCT

دنبالهٔ هموار شش‌تایی زیر (شبیه دنبالهٔ نوشته‌شده روی تخته) را در نظر بگیرید که دو سطح تقریباً ثابت دارد:

$$\mathbf{x} = [۵,\ ۵٫۲,\ ۴٫۹,\ ۸,\ ۸٫۱,\ ۷٫۹].$$

DCT متعامد آن (نسخهٔ DCT-II با نرمال‌سازی متعامد) برابر است با

$$\mathbf{c} \approx [۱۵٫۹۶,\ -۳٫۲۶,\ ۰٫۰۰,\ ۱٫۲۷,\ -۰٫۲۳,\ -۰٫۹۸].$$

مجموع مربعات هر دو دنباله برابر ۲۶۸٫۰۷ است (پایستگی انرژی)، ولی دو ضریب اول به‌تنهایی حدود ۹۹٪ انرژی را دارند. اگر فقط این دو ضریب را نگه داریم و دنباله را بازسازی کنیم، به دنبالهٔ

$$\hat{\mathbf{x}} \approx [۴٫۷,\ ۵٫۲,\ ۶٫۰,\ ۷٫۰,\ ۷٫۹,\ ۸٫۳]$$

می‌رسیم که شکل کلی (پایین در ابتدا، بالا در انتها) را حفظ کرده است. این دقیقاً منطق نگه‌داشتن ۱۲ ــ ۱۳ ضریب اول از ۴۰ مقدار است.

۲.۸.۵ چرا ۱۲ یا ۱۳ ضریب؟

دلیل انتخاب این تعداد تجربی است؛ در کاربردهای متداول گفتار دیده شده که چند ضریب اول اطلاعات مفید کافی را دارند. این به معنای بهینه بودن ۱۲ یا ۱۳ در همهٔ مسائل نیست؛ تعداد فیلترها (حدود ۴۰) و تعداد ضرایب (۱۲ یا ۱۳؛ ممکن است ۵ یا بیشتر هم امتحان شود) هر دو **ابرپارامتر** (Hyperparameter)اند و باید بر اساس عملکرد سیستم تنظیم شوند.



شکل ۶.۵: کاهش ابعاد از ۴۰ مقدار به ۱۳ ضریب (حدود ۳۲٫۵٪ ابعاد اولیه). (شکل افزوده)

پرسش و پاسخ: آیا انتخاب ۱۲ یا ۱۳ ضریب اثبات ریاضی دارد؟

خیر؛ این انتخاب تجربی است. تعداد ضرایب یک ابرپارامتر است و می‌توان آن را بر اساس عملکرد سیستم در مسئلهٔ موردنظر انتخاب کرد.

۹.۵ کپستروم و روایت تاریخی تحلیل کپسترال

۱.۹.۵ واژهٔ «کپستروم»

واژهٔ **کپستروم** (Cepstrum) از جابه‌جایی چهار حرف نخست واژهٔ Spectrum ساخته شده است. مفهوم آن در کلاس چنین بیان شد: «از یک طیف (اسپکتروم) یک طیف دیگر گرفته شد». بر همین قیاس، محور مستقل کپستروم **کوفرنسی** (Quefrency) (از Frequency) نام دارد و واحد آن از جنس زمان است.

۲.۹.۵ روایت تاریخی

استاد برای توضیح ایدهٔ تبدیل مجدد اطلاعات طیفی به روایتی از دوران جنگ سرد اشاره کرد: برای ایالات متحده مسئلهٔ مهم این بود که از روی امواج ثبت‌شده تشخیص دهد یک رویداد زلزله بوده یا آزمایش هستهٔ شوروی. هر دو امواج لرزه‌ای ایجاد می‌کنند، اما ویژگی‌های آن‌ها یکسان نیست. در توضیح کلاس، انفجار منبعی متمرکزتر دارد، در حالی که زلزله حاصل فرایندهای گسترده‌تری است، و اعمال تبدیل دوم روی اطلاعات طیفی الگوهایی را آشکار می‌کند که در طیف اولیه به‌آسانی قابل‌استفاده نبود. نکتهٔ اصلی برای ما این است: گاهی با تبدیل‌کردن دوبارهٔ یک نمایش طیفی، اطلاعاتی آشکار می‌شود که در نمایش اولیه دیده نمی‌شود.

دقت تاریخی (تأیید روایت)

اصل روایت درست است و در منابع تاریخ پردازش سیگنال هم آمده است. مفهوم کپستروم را Bogert، Healy و Tukey در مقاله‌ای با عنوان

“The Quefrency Alanysis of Time Series for Echoes: Cepstrum, Pseudo-Autocovariance, Cross-Cepstrum and Saphe Cracking”

در سال ۱۹۶۳ معرفی کردند (مجموعه‌مقالات سمپوزیوم تحلیل سری‌های زمانی، ویراستار M. Rosenblatt). موضوع آن تشخیص پژواک (echo) در رکوردهای لرزه‌نگاری بود، و انگیزهٔ این پژوهش‌ها با تفکیک زلزله از انفجار و نظارت بر آزمایش‌های هسته‌ای مرتبط دانسته می‌شود. نکتهٔ مهم برای دقت: این قیاس به‌معنی استفادهٔ مستقیم از MFCC در لرزه‌شناسی نبود؛ MFCC بعدها (۱۹۸۰) توسط Davis و Mermelstein برای تشخیص گفتار معرفی شد. این روایت در جزئیات (مثلاً «منظم‌تر بودن الگوی منبع متمرکز») بازگویی ساده‌شده است.

[محتوای افزوده] واژه‌های بازی‌گونهٔ تحلیل کپسترال

نویسندگان آن مقاله (بوگرت، هیلی و توکی) بازی با حروف را برای مفاهیم دیگر نیز ادامه دادند:

spectrum	→	cepstrum
frequency	→	quefrency
analysis	→	alanysis
phase	→	saphe
filtering	→	liftering
harmonic	→	rahmonic

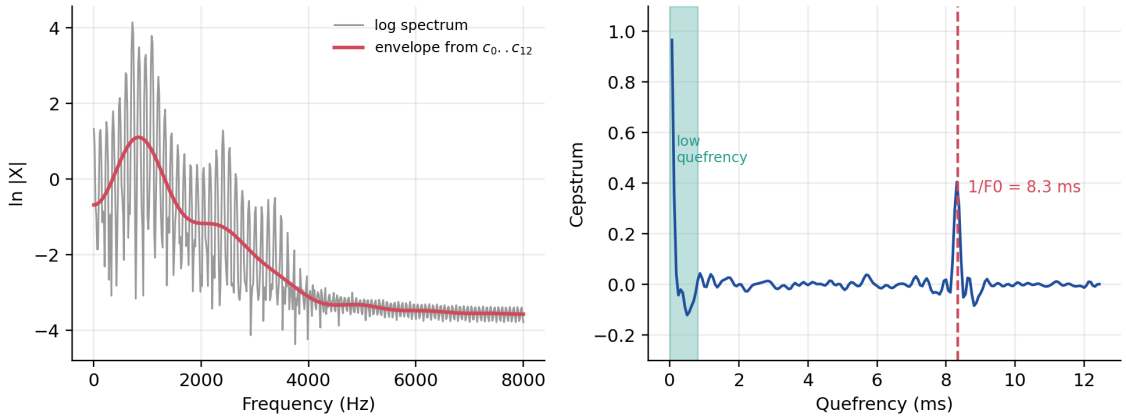
از میان این‌ها هنوز cepstrum، quefrency و lifter/liftering در پردازش گفتار به کار می‌رود.

۳.۹.۵ کپستروم چه می‌کند؟ شهود پژواک و هارمونیک

تعریف کپستروم حقیقی:

$$c[n] = \mathrm{IDFT}\Big\{ \log \big|\mathrm{DFT}\{x[n]\}\big| \Big\}.$$

شهود: اگر یک سیگنال پژواک داشته باشد، لگاریتم طیف آن یک «موج‌دار» تناوبی می‌شود و تبدیل دوم این تناوب را به یک قلهٔ تیز تبدیل می‌کند که جایش تأخیر پژواک را نشان می‌دهد. دقیقاً همین رخداد در گفتار واک‌دار روی می‌دهد: هارمونیک‌های F_0 در لگاریتم طیف مانند موج‌هایی با فاصلهٔ F_0 دیده می‌شوند و در کپستروم قله‌ای در کوفرنسی $1/F_0$ ایجاد می‌کنند، در حالی که پوش طیف (اثر مجرای صوتی و فرمنت‌ها) که کند تغییر می‌کند در کوفرنسی‌های پایین می‌ماند. به این ترتیب منبع (تارهای صوتی) و فیلتر (مجرا) از هم جدا می‌شوند.



شکل ۷.۵: کپستروم یک واکهٔ مصنوعی با $F_0 = 120$ هرتز و فرمنت‌های حدود ۷۳۰، ۱۰۹۰ و ۲۴۴۰ هرتز. چپ: لگاریتم طیف (هارمونیک‌های ریز) و پوش حاصل از ۱۳ ضریب نخست کپستروم. راست: کپستروم با قلهٔ کوفرنسی $1/F_0$ (حدود 8.3 ms) و ناحیهٔ کوفرنسی پایین مربوط به پوش طیف. (شکل افزوده)

کپستروم کلاسیک و DCT در MFCC یکسان نیستند

DCT در MFCC نسخه‌ای از همان ایدهٔ کپستروم است، نه دقیقاً همان عمل: در کپستروم کلاسیک از لگاریتم طیف کامل با IDFT تبدیل می‌گیریم، اما در MFCC ابتدا طیف را روی محور مل و با بانک فیلتر فشرده می‌کنیم، سپس لگاریتم می‌گیریم و از DCT استفاده می‌کنیم. (چون لگاریتم طیف توان حقیقی و متقارن است، IDFT آن عملاً به یک تبدیل کسینوسی تبدیل می‌شود و DCT همین کار را روی دنبالهٔ کوتاه‌تر مل انجام می‌دهد.) با نگه‌داشتن فقط ضرایب اول، عملاً پوش طیف ــ و نه جزئیات ریز هارمونیک‌ها ــ حفظ می‌شود؛ برای همین MFCC بیشتر شکل مجرای صوتی (واج) را کد می‌کند و کمتر به F_0 حساس است.

دنبالهٔ مثال تخته

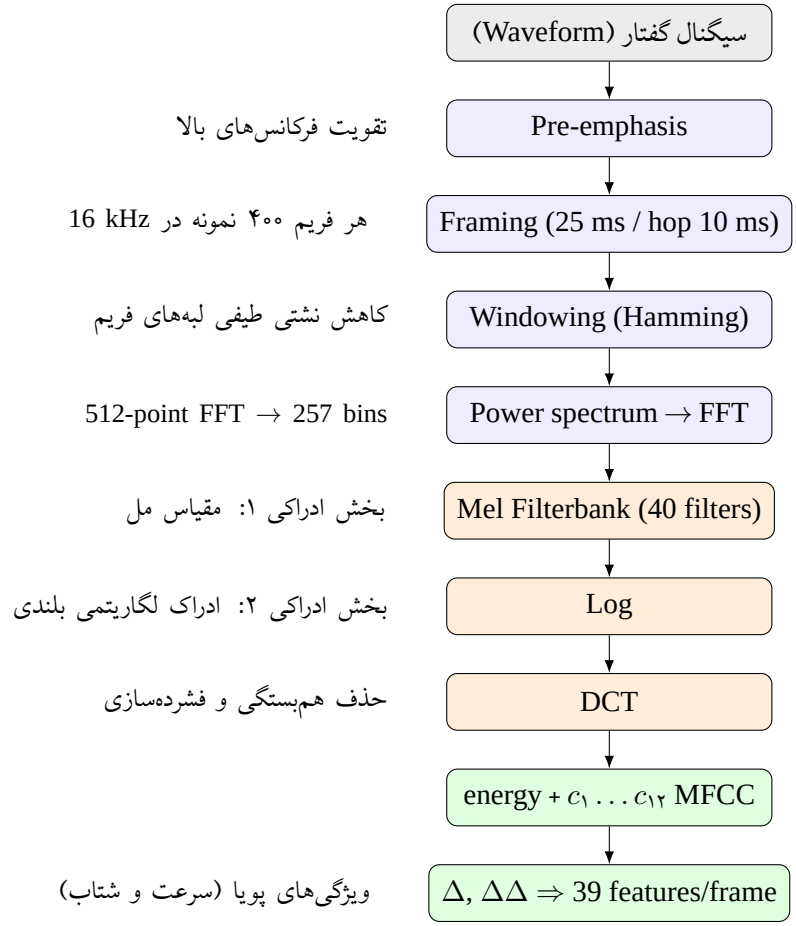
روی تخته دنبالهٔ

$$[۵,\ ۵/۲,\ ۴/۹,\ ۸,\ ۸/۱,\ ۷/۹, \ldots]$$

نوشته شد؛ منظور مثالی از یک «دنبالهٔ عددی» است که می‌توان آن را مانند یک سیگنال دید و روی آن تبدیل گرفت (مثلاً همین ۴۰ مقدار لگاریتمی مل). اینکه چنین دنبالهٔ هموار بیشتر انرژی‌اش در ضرایب اول جمع می‌شود در مثال عددی بالا دیده شد.

۱۰.۵ مسیر کامل استخراج MFCC

در کلاس مسیر مفهومی چنین بود: سیگنال گفتار ← تبدیل فوریه (طیف) ← بانک فیلتر مل ← لگاریتم ← DCT ← انتخاب ضرایب اول. در پیاده‌سازی واقعی، چند مرحلهٔ پیش‌پردازش نیز (که در جلسهٔ اسپکتروگرام با پنجره‌های زمانی آشنا شدیم) به ابتدا و انتهای این زنجیره افزوده می‌شود. شکل زیر مسیر کامل و استاندارد را نشان می‌دهد.



شکل ۸.۵: نمودار بلوکی استخراج MFCC از سیگنال گفتار تا بردار ویژگی هر فریم. بلوک‌های نارنجی بخش‌هایی هستند که در این جلسه تدریس شد. (شکل افزوده)

۱.۱۰.۵ مراحل به‌تفصیل

۱. **پیش‌تأکید (Pre-emphasis)**: یک فیلتر بالاگذر ساده $y[n] = x[n] - \alpha\, x[n-1]$ با $\alpha \approx ۰/۹۵$-۰/۹۷ که شیب نزولی طیف گفتار (انرژی کمتر در فرکانس‌های بالا) را جبران می‌کند.

۲. **فریم‌بندی (Framing)**: گفتار شبه‌ایستاست؛ پس سیگنال به فریم‌های کوتاه حدود ۲۵ میلی‌ثانیه (۴۰۰ نمونه در 16 kHz) با گام (hop) ۱۰ میلی‌ثانیه (۱۶۰ نمونه) بریده می‌شود، یعنی فریم‌ها ۱۵ میلی‌ثانیه هم‌پوشانی دارند.

۳. **پنجره‌گذاری (Windowing)**: ضرب هر فریم در پنجرهٔ همینگ $w[n] = ۰/۵۴ - ۰/۴۶ \cos\!\left(\frac{۲\pi n}{N-۱}\right)$ برای کاهش نشتی طیفی ناشی از بریدگی ناگهانی لبه‌ها.

۴. **تبدیل فوریه و طیف توان:** FFT (معمولاً با ۵۱۲ نقطه با صفرگذاری) و $P[k] = |X[k]|^۲/N$.

۵. **بانک فیلتر مل:** ۴۰ (یا ۲۶ و مانند آن) فیلتر مثلثی هم‌پوشان.

۶. **لگاریتم** انرژی هر فیلتر.

۷. **DCT** و نگه‌داشتن ضرایب $c_۱, \ldots, c_{۱۲}$ و افزودن یک ویژگی انرژی (لگاریتم انرژی فریم، یا $c_۰$).

۸. **مشتق‌ها (Delta):** برای ثبت تغییرات زمانی، ضرایب delta و delta-delta هم محاسبه می‌شوند:

$$\Delta c_t = \frac{\sum_{n=۱}^{N} n\,(c_{t+n} - c_{t-n})}{۲\sum_{n=۱}^{N} n^۲}, \qquad N = ۲.$$

حاصل ۱۳ ضریب + ۱۳ دلتا + ۱۳ دلتا–دلتا = بردار ۳۹ بعدی برای هر فریم است.

مراحل پیش‌پردازش در کلاس

فهرست شش‌مرحله‌ای کلاس فقط هستهٔ ادراکی MFCC (طیف، مل، لگاریتم، DCT، انتخاب ضرایب) را نشان می‌دهد. پیش‌تأکید، فریم‌بندی، پنجره‌گذاری و ویژگی‌های دلتا نیز به طور استاندارد جزو همین زنجیره‌اند؛ دو مورد از آن‌ها (فریم‌بندی و پنجره‌گذاری) پیش‌تر در بحث اسپکتروگرام آمده بود. همچنین در بسیاری از کتاب‌ها «MFCC ۱۲تایی» به معنی $c_۱$ تا $c_{۱۲}$ و «۱۳تایی» به معنی افزودن $c_۰$ (یا انرژی) است؛ این تفاوت علت دوگانهٔ «۱۲ یا ۱۳» در جملات استاد است.

[محتوای افزوده] مثال عددی: تعداد فریم‌ها و تفکیک فرکانسی

تعداد فریم‌ها. سیگنال ۱ ثانیه‌ای با نرخ 16 kHz شامل $L = ۱۶۰۰۰$ نمونه است؛ طول فریم $N = ۴۰۰$ و گام $H = ۱۶۰$ نمونه. تعداد فریم‌های کامل:

$$T = ۱ + \left\lfloor \frac{L - N}{H} \right\rfloor = ۱ + \left\lfloor \frac{۱۶۰۰۰ - ۴۰۰}{۱۶۰} \right\rfloor = ۱ + \lfloor ۹۷٫۵ \rfloor = ۹۸.$$

یعنی حدود ۱۰۰ فریم در ثانیه؛ ماتریس MFCC ۱۳ ضریبی ابعاد ۱۳×۹۸ و با دلتاها ۳۹×۹۸ دارد. برای سیگنال ۳٫۵ ثانیه‌ای شکل ۱۰.۵ این تعداد ۳۴۸ فریم است.

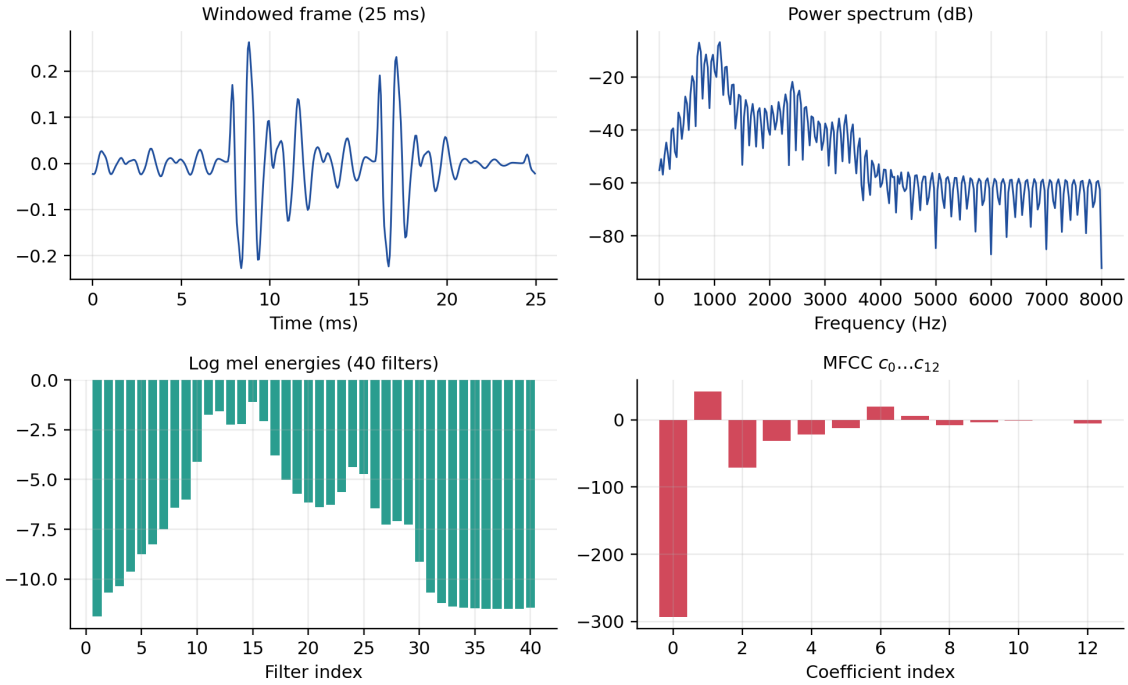
تفکیک فرکانسی. با FFT پانصد و دوازده نقطه‌ای: $\Delta f = \frac{f_s}{N_{\text{FFT}}} = \frac{۱۶۰۰۰}{۵۱۲} = ۳۱٫۲۵$ هرتز و تعداد پایه‌های مفید $۵۱۲/۲ + ۱ = ۲۵۷$ (از صفر تا ۸ کیلوهرتز). تفکیک واقعی به طول پنجره بستگی دارد: پنجرهٔ ۲۵ میلی‌ثانیه‌ای تفکیک حدود $۱/۰٫۰۲۵ = ۴۰$ هرتز دارد (صفرگذاری فقط نمونه‌برداری طیف را متراکم می‌کند). بنابراین هارمونیک‌های یک صدای با $F_۰ = ۱۲۰$ هرتز در طیف هر فریم تفکیک‌پذیرند، اما این جزئیات به‌دلیل فیلترهای مل و برش کپسترال حذف می‌شوند.

جمع‌بندی سه مسئله و راه‌حل در تخته

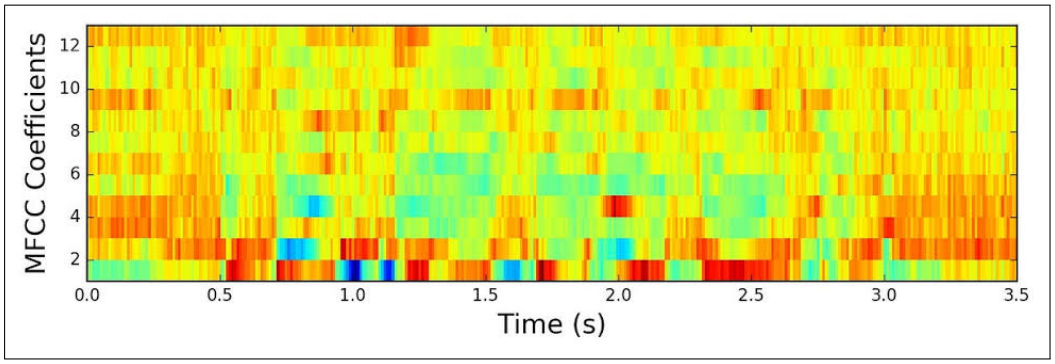
۱. **بانک فیلتر مل:** مسئلهٔ ادراک غیرخطی فرکانس ⇐ مقیاس مل (نگاشت غیرخطی که فرکانس‌های فیزیکی را «فشرده» می‌کند).

۲. **لگاریتم:** مسئلهٔ ادراک غیرخطی بلندی (۱۰۰ برابر بلندتر را فقط چند برابر بلندتر حس می‌کنیم) ⇐ لگاریتم از انرژی مل.

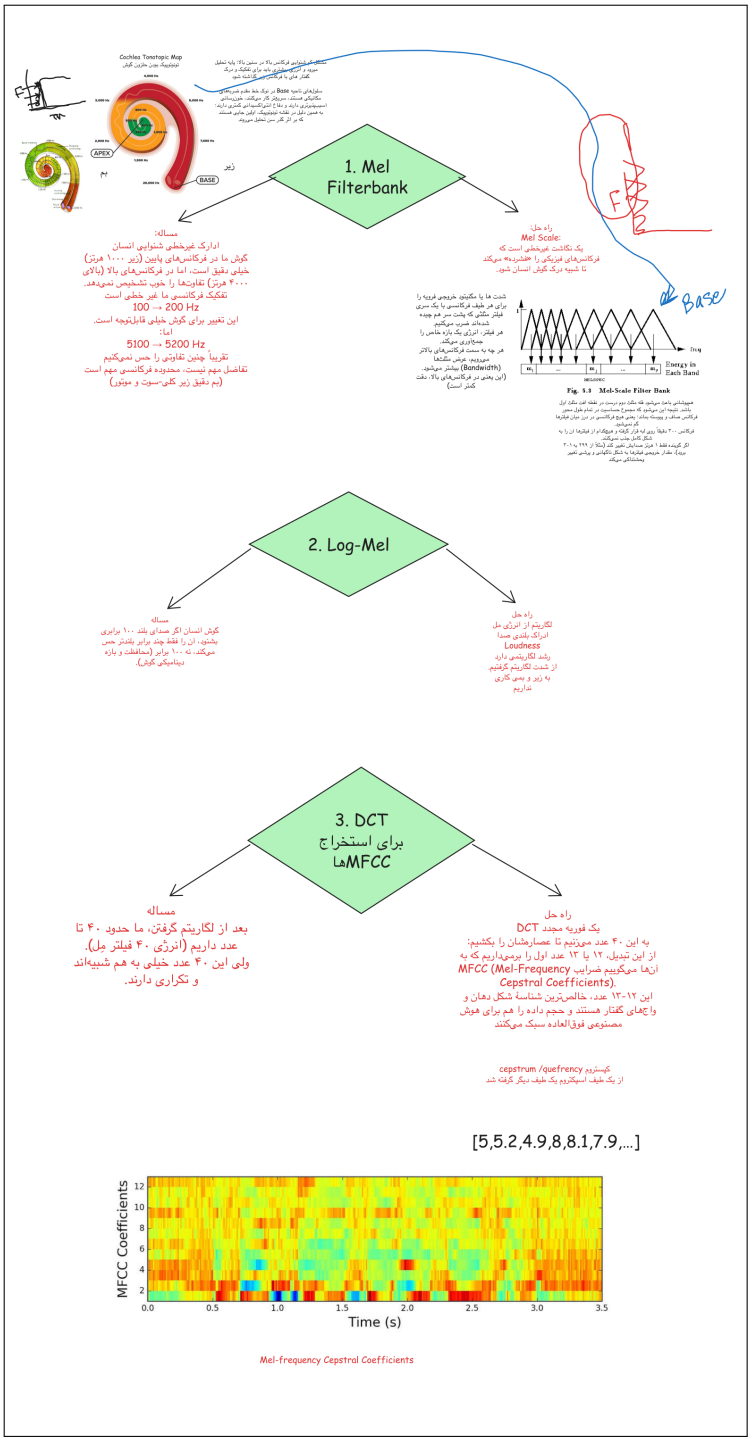
۳. **DCT:** مسئلهٔ ۴۰ عدد بسیار شبیه و تکراری ⇐ DCT و برداشتن ۱۲ تا ۱۳ ضریب اول.



شکل ۹.۵: خروجی مراحل MFCC روی یک فریم ۲۵ میلی‌ثانیه‌ای از یک واکهٔ مصنوعی ($F_0 = ۱۲۰$ هرتز): فریم پنجره‌گذاری‌شده، طیف توان، لگاریتم انرژی ۴۰ فیلتر مل و ۱۳ ضریب MFCC (ضریب c_0 بزرگ و منفی است چون به لگاریتم انرژی کلی بستگی دارد). مراحل بالا انبوهی از جزئیات طیف را به ۱۳ عدد تبدیل می‌کنند. (شکل افزوده)



شکل ۱۰.۵: نمایش ماتریسی MFCC: محور افقی زمان و محور عمودی شمارهٔ ضریب (۱ تا ۱۳) است؛ رنگ مقدار هر ضریب را در هر فریم نشان می‌دهد. (برگرفته از تختهٔ کلاس)



شکل ۱۱.۵: خلاصهٔ تختهٔ جلسه: سه مرحلهٔ بانک فیلتر مل، لگاریتم و DCT؛ در هر مرحله «مسئله» (سمت چپ) و «راه‌حل» (سمت راست) نوشته شده است. در بخش پایین، ماتریس MFCC نمایش داده شده است. (برگرفته از تختهٔ کلاس)

۱۱.۵ کاربردهای MFCC

پس از استخراج، به‌جای نمایش‌های حجیم‌تر سیگنال می‌توان از ماتریس MFCC (برای هر فریم زمانی یک بردار ضریب) برای تحلیل و مقایسهٔ گفتار استفاده کرد. کاربردهایی که در کلاس مطرح شد:

- **مقایسهٔ سیگنال‌ها:** می‌توان MFCC دو سیگنال را استخراج و شباهتشان را (مثلاً با هم‌بستگی، Correlation) سنجید.
- **تحلیل صدای سرفه:** اگر دو گروه نمونه داشته باشیم، مثلاً سرفهٔ افراد مبتلا به یک بیماری تنفسی (مانند کووید-۱۹) و سرفهٔ سایرین، می‌توان از هر نمونه MFCC گرفت و الگوها را مقایسه یا یک طبقه‌بند آموزش داد. این مثال نشان می‌دهد MFCC فقط به تشخیص کلمات محدود نیست.
- **تبدیل گفتار به متن:** به‌جای دادن موج خام، ویژگی‌های آکوستیکی مانند MFCC به مدل داده می‌شود. اگر ویژگی دیگری مانند pitch لازم باشد، می‌توان آن را جداگانه استخراج کرد؛ چون MFCC جایگزین همهٔ ویژگی‌ها نیست.

هشدار درباره برداشت‌های سریع

استخراج MFCC یا مشاهدهٔ یک هم‌بستگی به‌تنهایی برای تشخیص بیماری کافی نیست؛ این کار نیازمند داده‌های معتبر و متوازن، آموزش و ارزیابی دقیق مدل است. همچنین مقایسهٔ مستقیم MFCC دو سیگنال با طول‌های متفاوت یا سرعت گفتار متفاوت نیازمند هم‌ترازسازی زمانی (مثلاً DTW) یا خلاصه‌سازی آماری (میانگین/واریانس ضرایب روی زمان) است.

۱۲.۵ MFCC در یادگیری ماشین و یادگیری عمیق

۱.۱۲.۵ آیا استخراج MFCC یادگیری ماشین است؟

استاد تأکید کرد که استخراج MFCC در حالت متداول خودش یک فرایند یادگیری ماشین نیست: مجموعه‌ای از عملیات ثابت پردازش سیگنال (طیف، بانک فیلتر، لگاریتم، DCT، انتخاب ضرایب) با پارامترهای مشخص است و برای محاسبهٔ آن نیازی به آموزش روی داده‌های برچسب‌دار نیست. البته خروجی آن را می‌توان به یک مدل یادگیری ماشین داد.

۲.۱۲.۵ مقایسه با PCA

دانشجویی پرسید آیا کاهش ویژگی در MFCC با PCA قابل‌مقایسه است. پاسخ: از نظر هدف کلی (نمایش فشرده‌تر) شباهت دارند، اما مسیر محاسباتی‌شان متفاوت است.

در کلاس مطرح شد که پس از لگاریتم انرژی‌های مل می‌توان به‌جای DCT از PCA هم استفاده کرد؛ اما آنگاه دیگر با تعریف متداول MFCC کار نمی‌کنیم. MFCC یک مسیر مشخص و شناخته‌شده برای ویژگی آکوستیکی گفتار است.

جدول ۳.۵: مقایسهٔ مفهومی MFCC و PCA (طبق بحث کلاس).

ویژگی	MFCC	PCA
هدف	استخراج ویژگی آکوستیکی مناسب گفتار	کاهش بُعد و استخراج مؤلفه‌های اصلی
نوع روش	زنجیرهٔ تبدیل‌های پردازش سیگنال	روش آماری مبتنی بر داده
نیاز به یادگیری از داده	در استخراج متداول، خیر	بله؛ مؤلفه‌ها از داده برآورد می‌شوند
ورودی	سیگنال صوتی یا نمایش طیفی	بردارهای ویژگی
خروجی	ضرایب کپسترال	مؤلفه‌های اصلی

ارتباط DCT و PCA

مقایسهٔ دانشجو نکتهٔ دقیقی را لمس می‌کند: DCT را می‌توان تقریبی «ثابت و مستقل از داده» از PCA روی لگاریتم انرژی‌های مل دانست (به همان دلیل که در بخش DCT گفته شد). تفاوت اصلی این است که PCA پایه‌ها را از داده می‌آموزد (و برای هر مجموعه‌داده متفاوت است)، در حالی که پایه‌های DCT ثابت‌اند.

۳.۱۲.۵ MFCC در مدل‌های یادگیری عمیق

حتی هنگام استفاده از یادگیری عمیق می‌توان MFCC را به مدل داد؛ چون نمایشی ساختاریافته و فشرده از اطلاعات آکوستیکی است و مدل را از مواجهه با موج خام بی‌نیاز می‌کند. انتخاب میان موج خام، طیف، MFCC و نمایش‌های دیگر به مسئله و عملکرد تجربی بستگی دارد.

روند امروز: log-mel به‌جای MFCC در شبکه‌های عمیق

در عمل، مدل‌های عصبی امروزی (از جمله بسیاری از سامانه‌های تشخیص گفتار مانند Whisper) بیشتر از لگاریتم انرژی‌های مل (log-mel filterbank یا log-mel spectrogram) استفاده می‌کنند و مرحلهٔ DCT را حذف می‌کنند، چون شبکه خودش می‌تواند هم‌بستگی‌ها را بیاموزد، و DCT ترتیب فرکانسی (مناسب برای لایه‌های کانولوشنی) را به هم می‌ریزد. برخی مدل‌های جدید (مانند wav2vec 2.0) نیز مستقیماً از موج خام شروع می‌کنند. MFCC همچنان در مدل‌های کلاسیک (GMM-HMM)، مدل‌های سبک و داده‌های کم کاربرد دارد.

جدول ۴.۵: نمایش‌های ورودی رایج برای سامانه‌های گفتاری (جمع‌بندی افزوده).

نمایش	بُعد تقریبی هر فریم	کاربرد معمول
موج خام	۱۶۰ نمونه در هر ۱۰ میلی‌ثانیه	مدل‌های سرتاسری جدید (wav2vec 2.0)
طیف‌نگاره (STFT)	۲۵۷	تحلیل، برخی مدل‌های بهبود گفتار
log-mel	۴۰ تا ۱۲۸	بیشتر شبکه‌های عصبی تشخیص گفتار
MFCC (+ دلتا)	۱۳ (۳۹)	مدل‌های کلاسیک، سامانه‌های سبک

۱۳.۵ جمع‌بندی

در این جلسه تحلیل آکوستیکی صرف را به سمت ویژگی‌هایی که با شنوایی انسان سازگارند گسترش دادیم. گوش فرکانس‌ها را غیرخطی درک می‌کند (نقشهٔ تونوتوپیک حلزون، تفکیک بیشتر در فرکانس‌های بم) و شدت را نیز غیرخطی درک می‌کند. برای مدل‌کردن اولی از مقیاس مل و بانک فیلتر مثلثی هم‌پوشان با عرض‌های رشدیابنده استفاده کردیم و برای دومی از لگاریتم. سپس چون ۴۰ انرژی لگاریتمی مل بسیار هم‌بسته‌اند، با DCT آن‌ها را به ضرایب کپسترال تبدیل و ۱۲ تا ۱۳ ضریب اول را نگه داشتیم. زنجیرهٔ مفهومی جلسه:

$$\text{Speech Signal} \to \text{Spectrum} \to \text{Mel Filters} \to \log \to \text{DCT} \to \text{MFCC}.$$

نتیجهٔ اصلی: در MFCC به‌جای استفاده از همهٔ اطلاعات طیفی، نمایشی فشرده و مناسب گفتار می‌سازیم که ویژگی‌های ادراکی گوش انسان در طراحی آن لحاظ شده است. ادامهٔ بررسی جزئیات برخی ویژگی‌های صوتی (مانند نحوهٔ محاسبهٔ کانتور pitch) به جلسه‌های بعد موکول شد.

نکات مهم برای مرور و امتحان

۱. تفاوت فرکانس فیزیکی (F_0) با ادراک زیر و بمی (Pitch) را بدانید.

۲. تفاوت شدت فیزیکی با بلندی ادراک‌شده را توضیح دهید.

۳. نقشهٔ تونوتوپیک حلزون (قاعده ⇔ فرکانس بالا، رأس ⇔ فرکانس پایین) و پیامد آن (کم‌شنوایی فرکانس بالا با سن) را بشناسید.

۴. توضیح دهید چرا ادراک انسان از تغییرات فرکانس خطی نیست (مثال ۱۰۰ تا ۲۰۰ در برابر ۵۱۰۰ تا ۵۲۰۰ هرتز).

۵. دلیل استفاده از مقیاس مل و بانک فیلتر مثلثی را بدانید؛ فرمول $m = ۲۵۹۵ \log_{۱۰}(۱ + f/۷۰۰)$.

۶. بدانید چرا عرض فیلترهای مل در فرکانس‌های بالا بیشتر می‌شود.

۷. مفهوم هم‌پوشانی فیلترها و وزن‌دهی مثلثی را توضیح دهید و بتوانید خروجی یک فیلتر را محاسبه کنید (مثال $M_۱ = ۱۳$).

۸. دلیل لگاریتم از انرژی فیلترهای مل را توضیح دهید.

۹. نقش DCT (کاهش هم‌بستگی و فشرده‌سازی) و دلیل نگه‌داشتن ۱۲ یا ۱۳ ضریب را بدانید.

۱۰. مسیر استخراج MFCC را از سیگنال تا ضرایب نهایی شرح دهید.

۱۱. بدانید تعداد فیلترها (حدود ۴۰) و تعداد ضرایب (۱۲ یا ۱۳) ابرپارامترند و ثابت و اجباری نیستند.

۱۲. تفاوت MFCC (زنجیرهٔ ثابت پردازش سیگنال) با PCA (یادگیری از داده) را بدانید.

۱۳. معنای واژهٔ کپستروم (جابه‌جایی حروف Spectrum) و ارتباط آن با «طیفِ طیف» را بدانید.

فصل ۶

پروسودی و ویژگی‌های زبرزنجیری گفتار

در جلسات پیشین، گفتار را عمدتاً از دید «چه گفته شد؟» بررسی کردیم: واج‌ها، فرمنت‌ها، طیف و ضرایب MFCC. این جلسه به پرسش مکمل می‌پردازد: «چگونه گفته شد؟». دو گوینده می‌توانند دقیقاً یک دنبالهٔ واجی را بگویند، اما یکی آن را به‌صورت خبر و دیگری به‌صورت پرسش، با اطمینان یا با تردید، سریع یا آهسته ادا کند. این لایهٔ دوم را **پروسودی** (Prosody) یا نوای گفتار می‌نامیم. فصل با مروری کوتاه بر جلسهٔ قبل آغاز می‌شود و سپس سه مؤلفهٔ اصلی پروسودی (شدت، فرکانس پایه و زمان)، مشکلات پروسودی در تبدیل متن به گفتار، یک مقالهٔ پژوهشی دربارهٔ اطمینان و صداقت ادراک‌شده و کاربردهای عملی را بررسی می‌کنیم.

۱.۶ مرور کوتاه جلسهٔ قبل

۱.۱.۶ مراحل استخراج MFCC

جلسهٔ قبل (فصل پنجم) دیدیم که برای استخراج ضرایب MFCC چند گام پشت سر هم روی هر قاب کوتاه از سیگنال انجام می‌شود:

۱. تبدیل فوریه و محاسبهٔ طیف دامنه یا توان قاب؛

۲. عبور طیف از یک **بانک فیلتر مل** (Mel Filterbank) و محاسبهٔ انرژی خروجی هر فیلتر؛

۳. گرفتن لگاریتم از انرژی‌ها؛

۴. اعمال یک تبدیل دیگر برای کاهش هم‌بستگی میان مقادیر؛

۵. نگه‌داشتن تعداد محدودی از ضرایب نخست (مثلاً ۱۲ ضریب) به‌عنوان بردار ویژگی.

فیلترهای مل در فرکانس‌های پایین باریک و در فرکانس‌های بالا پهن‌ترند؛ یعنی جزئیات طیف را در فرکانس‌های پایین دقیق‌تر و در فرکانس‌های بالا «از دورتر و کلی‌تر» می‌بینیم. تشبیه کلاس: مثل عکس‌برداری از مجموعه‌ای از اشیا که بعضی را از نزدیک و با جزئیات و بعضی را از فاصلهٔ دورتر ثبت می‌کنیم.

گام چهارم MFCC تبدیل فوریهٔ دوباره نیست

در توضیح شفاهی کلاس از «تبدیل مجدد» (و در جزوه از «تبدیل فوریه مجدد») سخن رفت. در روش استاندارد، این گام **تبدیل کسینوسی گسسته** (DCT) است که روی لگاریتم انرژی‌های بانک فیلتر اعمال می‌شود. خروجی DCT ضرایبی کم‌هم‌بسته‌تر می‌دهد و بیشتر انرژی اطلاعات در ضرایب نخست متمرکز می‌شود.

۲.۱.۶ پرسش کلاس: عددهای ۴۰ و ۱۲ از کجا می‌آیند؟

تعداد خروجی‌های بانک فیلتر برابر تعداد فیلترهایی است که طراح انتخاب می‌کند؛ اگر ۴۰ فیلتر بگذاریم، ۴۰ انرژی لگاریتمی خواهیم داشت. اینکه پس از DCT چند ضریب نگه داریم (مثلاً ۱۲ یا ۱۳) انتخاب جداگانه‌ای در طراحی ویژگی است. پس تعداد فیلترها و تعداد ضرایب نهایی الزاماً برابر نیستند. نگه‌داشتن ضرایب نخست، نمایش را فشرده می‌کند و عملاً تنها شکل کلی (پوش) طیف را نگه می‌دارد.

۳.۱.۶ MFCC و مدل منبع-فیلتر

در مدل **منبع-فیلتر** (Source–Filter) تولید گفتار دو بخش دارد: منبع (برای گفتار واک‌دار، ارتعاش تارهای صوتی با فرکانس پایهٔ F_0) و فیلتر (کل مجرای صوتی). نکتهٔ مورد تأکید کلاس: فیلتر فقط دهان، فک و دندان نیست؛ کل مجرای صوتی از حنجره تا لب را شامل می‌شود. MFCC عمدتاً شکل طیفی و ویژگی‌های فیلتر را نگه می‌دارد و اطلاعات دقیق منبع، مانند F_0 و زیر و بمی، در آن تضعیف یا حذف می‌شود. به همین دلیل MFCC برای کاربردهایی مثل تشخیص واج و طبقه‌بندی مناسب است (مثلاً ورودی طبقه‌بند یا تصویر ورودی به یک CNN)، اما برای مطالعهٔ آهنگ جمله کافی نیست. این همان انگیزهٔ ورود به بحث پروسودی است.

نمونهٔ کاربرد مطرح‌شده: طبقه‌بندی نمونه‌های صوتی مرتبط با بیماری (مانند سرفه یا گفتار بیماران کرونا) از نمونه‌های سالم. چون بیماری می‌تواند هم تارهای صوتی و هم مجرای صوتی را تغییر دهد، تغییرات بخش فیلتر ممکن است در ویژگی‌های طیفی دیده شود. این به معنی تشخیص قطعی بیماری با MFCC نیست؛ فقط نشان می‌دهد این ویژگی‌ها می‌توانند ورودی مفیدی برای مدل یادگیری ماشین باشند.

[محتوای افزوده] چرا F_0 از MFCC حذف می‌شود؟ یک محاسبهٔ عددی

فرض کنید گفتار با نرخ نمونه‌برداری ۱۶ kHz ضبط شده و $F_0 = 100\,\text{Hz}$ است. دورهٔ تناوب ارتعاش تارها برابر $1/100 = 10\,\text{ms}$ یعنی ۱۶۰ نمونه است. در ظرافت‌های طیف، F_0 به شکل «ساختار هارمونیک» (قله‌هایی با فاصلهٔ ۱۰۰ Hz) دیده می‌شود. بانک فیلتر مل با پهنای فیلترهای صدها هرتزی این قله‌ها را هموار می‌کند، و نگه‌داشتن فقط ۱۲ ضریب اول DCT یعنی نگه‌داشتن تغییرات کند طیف (پوش). بنابراین اطلاعات مربوط به F_0 عملاً در MFCC باقی نمی‌ماند.

۴.۱.۶ مرور دو واکهٔ «آ» و «اَ»

پرسش جلسهٔ قبل: تفاوت صدای دو واکهٔ «آ» /ɑ/ و «اَ» /æ/ مربوط به منبع است یا فیلتر؟ پاسخ: **فیلتر**. هر دو واکه واک‌دارند و منبع یکسانی دارند (ارتعاش تارها)؛ اما موقعیت زبان و شکل مجرا فرق می‌کند و در نتیجه فرمنت‌ها جابه‌جا می‌شوند.

جدول ۱.۶: مقایسهٔ موقعیت زبان و فرمنت‌ها در دو واکهٔ «آ» و «اَ».

ویژگی	«آ» /ɑ/	«اَ» /æ/
ارتفاع زبان	پایین (باز)	پایین (نسبتاً باز)
موقعیت افقی زبان	عقب	جلو
F_1	نسبتاً بالا	نسبتاً بالا
F_2	پایین‌تر	بالاتر

دو قاعدهٔ کلیدی: هرچه زبان پایین‌تر باشد F_1 بالاتر است؛ و هرچه زبان جلوتر باشد F_2 بالاتر است. تفاوت اصلی این دو واکه در F_2 است.

نکتهٔ امتحانی

باید بتوانید با استفاده از F_1 و F_2 دربارهٔ ارتفاع و موقعیت افقی زبان هنگام تولید واکه‌ها توضیح بدهید (مثلاً چرا «آ» و «اَ» با اینکه منبع یکسان دارند متفاوت شنیده می‌شوند).

[محتوای افزوده] مقادیر تقریبی فرمنت‌ها

مقادیر دقیق به گوینده و پیکرهٔ گفتاری بستگی دارد؛ اما برای یک گوینده مرد، به‌طور تقریبی می‌توان انتظار داشت: برای /ɑ/ حدود $F_1 \approx 650$ تا ۷۵۰ Hz و $F_2 \approx 1000$ تا ۱۲۰۰ Hz، و برای /æ/ حدود $F_1 \approx 600$ تا ۷۵۰ Hz و $F_2 \approx$ ۱۵۰۰ تا ۱۸۰۰ Hz. اختلاف F_2 حدود ۵۰۰ Hz یا بیشتر است و همین اختلاف قابل‌شنیدن است، در حالی که F_1 تقریباً مشابه می‌ماند.

۲.۶ پروسودی چیست؟

۱.۲.۶ تعریف و ایدهٔ اصلی

پروسودی (نوای گفتار)

پروسودی (Prosody) مجموعهٔ ویژگی‌هایی از گفتار است که روی دنبالهٔ آواها و واژه‌ها «سوار» می‌شوند و به آن‌ها آهنگ، ریتم، تکیه و الگوی زمانی می‌دهند. پروسودی نشان می‌دهد **چگونه** گفته شده است، نه فقط **چه** گفته شده است.

مثال: واژهٔ «رفتی» را می‌توان به سه شکل گفت: «رفتی.» (خبری)، «رفتی؟» (پرسشی) و «رفتی!» (تعجب یا تأکید). واج‌ها یکسان‌اند، اما معنا و نیت گوینده فرق می‌کند. علائم نگارشی مانند علامت سؤال یا ویرگول بخشی از این اطلاعات را در متن نشان می‌دهند، ولی تصویر کامل پروسودی در متن نیست؛ برای بررسی دقیق آن باید سیگنال صوتی (موج، اسپکتروگرام و کانتور ویژگی‌ها) را تحلیل کرد.

۲.۲.۶ قیاس با عروض در شعر سنتی

برای نشان دادن «لایه‌ای» بودن پروسودی، استاد به عروض اشاره کرد. در شعر سنتی، علاوه بر واژه‌ها و معنا، شعر روی یک الگوی وزنی سوار شده است و همین الگوست که احساس آهنگ ایجاد می‌کند. علم عروض هجاهای کوتاه (⏑) و بلند (—) را مشخص می‌کند و از ترتیب آن‌ها وزن شعر را به دست می‌آورد. پس در زبان‌شناسی، همان‌طور که عروض «چگونه گفتن» شعر را بررسی می‌کند، پروسودی نیز علاوه بر «چه گفتن»، «چگونه گفتن» را بررسی می‌کند.

هجاها	«بِ نا مِ»	«خُ دا وَنْ»	«دِ جا نُ»	«خِ رَد»
خط عروضی	— — ⏑	— — ⏑	— — ⏑	— ⏑
رکن	فَعولُنْ	فَعولُنْ	فَعولُنْ	فَعَلْ

«خیزید و خز آرید که هنگام خزان است»

مفعولُ مفاعیلُ مفاعیلُ فَعولُنْ

شکل ۱.۶: دو مثال عروضی روی تخته. بالا: تقطیع مصراع «به نام خداوند جان و خرد» با الگوی هجایی — — ⏑ که سه بار و سپس — ⏑ تکرار می‌شود («فعولن فعولن فعولن فعل»). پایین: مصراعی از منوچهری با الگوی «مفعولُ مفاعیلُ مفاعیلُ فعولن». (بازسازی‌شده از تختهٔ کلاس)

نکتهٔ مهم این است که برای تحلیل وزن، معنای واژه‌ها اهمیتی ندارد؛ دو عبارت با معنا و واج‌های کاملاً متفاوت می‌توانند وزن یکسانی داشته باشند. یعنی لایهٔ ریتمیک مستقل از هویت واج‌ها و معنا قابل بررسی است. در گفتار عادی نیز وضع همین است: واژه‌ها و واج‌ها یک لایه‌اند و نحوهٔ بیان آن‌ها لایهٔ دیگر.

[محتوای افزوده] تحلیل مصراع‌های تخته

در مصراع «به نام خداوند جان و خرد»، هجاها به این شکل تقطیع می‌شوند: «بِ‌نام» — — ⏑ ، «خُداوَنْ» ⏑ — — ، «دِجانُ» — — ⏑ ، «خِرَد» — ⏑. به این وزن (**متقارب مثمن محذوف**) می‌گویند. همچنین مصراع «خیزید و خز آرید که هنگام خزان است» با الگوی «مفعولُ مفاعیلُ مفاعیلُ فعولن» (هزج مثمن اخرب مکفوف محذوف) سروده شده است. در جلسه، تقطیع مصراع دوم چند بار در گفت‌وگو اصلاح شد و فقط الگوی نهایی روی تخته معتبر است.

دو نکتهٔ تکمیلی: ۱) وزن شعر فارسی **کمّی** (Quantitative) است، یعنی بر مبنای کوتاهی و بلندی هجاهاست؛ در مقابل، وزن بسیاری از اشعار انگلیسی بر مبنای تکیه (stress) است. ۲) این مثال فقط یک قیاس برای فهم پروسودی است و درس وارد تقطیع شعر نمی‌شود.

۳.۲.۶ ویژگی‌های زبرزنجیری

پروسودی را **ویژگی‌های زبرزنجیری** (Suprasegmental Features) نیز می‌نامند. پیشوند Supra یعنی «فراتر/بالا» و Segment یعنی «قطعه» (واج یا آوا). تصویر کلاس: پروسودی مثل چتری است که از بالا روی قطعات گسترده شده است. دو پیامد مهم:

- تحلیل در سطح کل جمله یا عبارت انجام می‌شود، نه فقط یک پنجرهٔ کوتاه یا یک واج. در فصل‌های قبل سیگنال را به پنجره‌های حدود ۲۵ میلی‌ثانیه تقسیم می‌کردیم؛ برای پروسودی باید چند هجا یا یک جمله کامل را با هم دید.
- آنچه اهمیت دارد افت و خیزها نسبت به بخش‌های قبل و بعد است، نه مقدار مطلق در یک لحظه. مثلاً برای فهمیدن اینکه روی کدام کلمه تأکید شده، شدت و آهنگ آن کلمه باید با کلمات اطراف مقایسه شود.

به همین دلیل، در پروسودی مفهوم **کانتور** (Contour) اهمیت بالایی دارد: کانتور یعنی تغییرات یک ویژگی در طول زمان. به‌جای یک مقدار لحظه‌ای از شدت یا فرکانس، مسیر تغییر آن را در کل عبارت بررسی می‌کنیم.

۴.۲.۶ سه مؤلفهٔ اصلی

وقتی از دانشجویان پرسیده شد چه چیزهایی در گفتار پروسودیک است، مواردی مثل پرسشی یا خبری بودن، احساسات، سرعت، مکث و بلندی صدا مطرح شد. در پردازش گفتار باید این مفاهیم را به کمیت‌های قابل اندازه‌گیری تبدیل کنیم؛ مثلاً «عصبانیت» خود یک کمیت صوتی نیست، بلکه باید ببینیم چه چیزهایی در سیگنال تغییر کرده که شنونده آن را عصبانی درک می‌کند. این کمیت‌ها در سه گروه جای می‌گیرند که نقشه‌اش روی تختهٔ کلاس آمده است.

جدول ۲.۶: سه مؤلفهٔ اصلی پروسودی، کمیت فیزیکی و ادراک متناظر آن‌ها. (جدول افزوده)

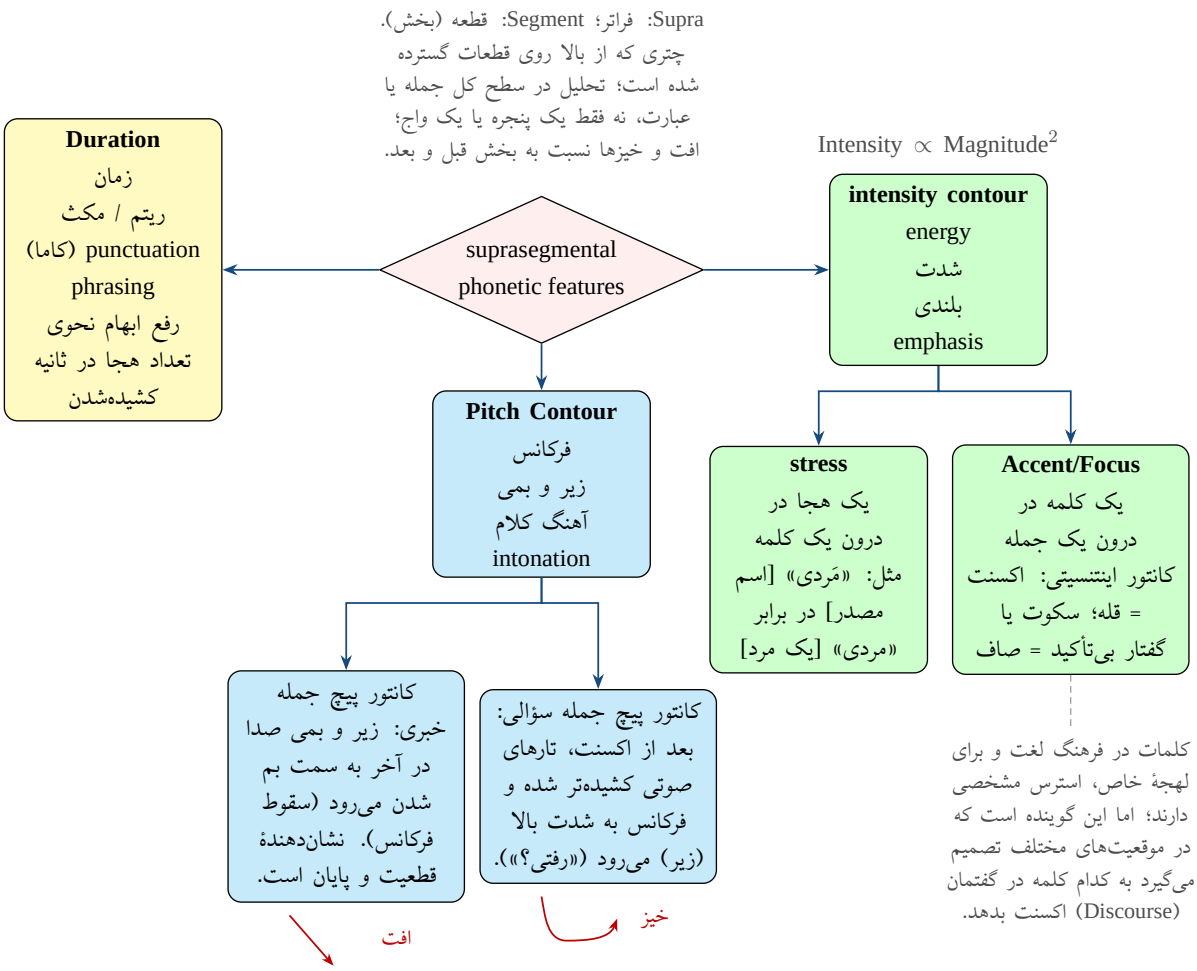
مؤلفه	کمیت فیزیکی	ادراک شنونده	واحد/ابزار رایج
فرکانس	فرکانس پایه (F_0)	زیر و بمی (Pitch)	هرتز، نیم‌پرده؛ کانتور F_0
شدت	دامنه، انرژی، شدت	بلندی (Loudness)	دسی‌بل؛ کانتور شدت
زمان	مدت آوا/هجا، مکث	سرعت، ریتم، کشش	میلی‌ثانیه، هجا در ثانیه

۳.۶ مؤلفهٔ اول: شدت صدا

۱.۳.۶ واژگان مرتبط

در این شاخه اصطلاحاتی مثل Intensity، Energy، Loudness، Amplitude و Magnitude آمده است. استاد تأکید کرد که این‌ها از نظر علمی دقیقاً هم‌معنا نیستند، ولی در این جلسه برای دسته‌بندی کلی در یک گروه قرار گرفته‌اند. رابطهٔ نوشته‌شده روی تخته چنین است:

$$\text{Intensity} \propto \text{Magnitude}^2$$



شکل ۲.۶: نقشهٔ ذهنی ویژگی‌های زبرزنجیری: سه شاخهٔ زمان (Duration)، زیر و بمی (Pitch Contour) و شدت (Intensity Contour). شاخهٔ شدت به تکیهٔ واژگانی (stress) و تأکید (Accent/Focus) تقسیم شده است؛ شاخهٔ زیر و بمی به کانتور جملهٔ خبری و پرسشی. فلش‌های قرمز افت (خبری) و خیز (پرسشی) انتهای کانتور را نشان می‌دهند. (بازسازی‌شده از تختهٔ کلاس)

یعنی شدت (توان در واحد سطح) با مربع دامنه متناسب است. بلندی (Loudness) کمیتی **ادراکی** است و الزاماً با شدت فیزیکی برابر نیست.

۲.۳.۶ دسی‌بل

انسان نسبت‌های شدت را (نه تفاضل‌ها را) حس می‌کند و بازهٔ شدت‌هایی که می‌شنود بسیار گسترده است. به همین دلیل از مقیاس لگاریتمی **دسی‌بل** (dB) استفاده می‌شود.

تراز شدت و تراز فشار صوت

$$L_I = ۱۰ \log_{۱۰}\left(\frac{I}{I_۰}\right) \text{ dB}, \qquad I_۰ = ۱۰^{-۱۲} \text{ W/m}^۲$$

$$L_p = \text{SPL} = ۲۰ \log_{۱۰}\left(\frac{p}{p_۰}\right) \text{ dB}, \qquad p_۰ = ۲۰\ \mu\text{Pa}$$

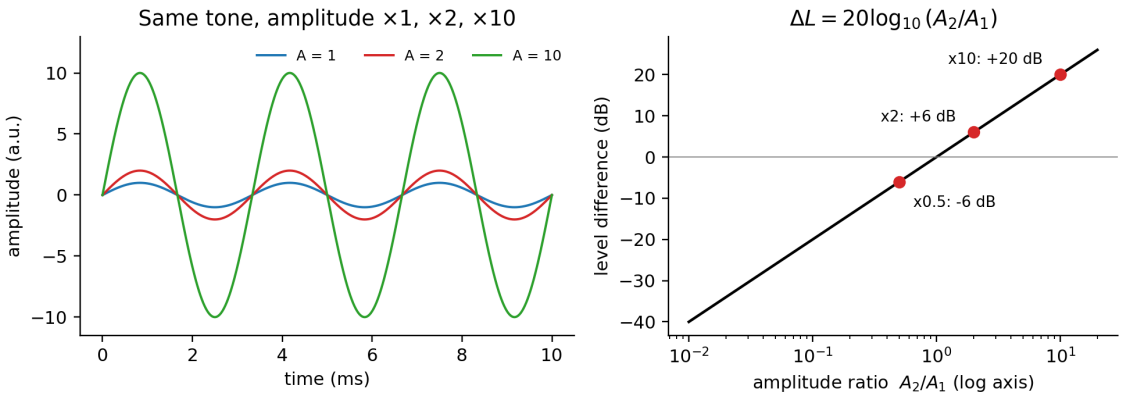
چون شدت متناسب با مربع فشار (یا دامنه) است ($I \propto p^۲$)، ضریب لگاریتم برای دامنه ۲۰ و برای توان یا شدت ۱۰ است. نسبت دو دامنه $A_۲/A_۱$ معادل اختلاف تراز $۲۰ \log_{۱۰}(A_۲/A_۱)$ دسی‌بل است.

[محتوای افزوده] مثال‌های عددی دسی‌بل

- دو برابر شدن **دامنه**: $+۶٫۰۲$ dB $\approx ۲۰ \log_{۱۰} ۲$ (یعنی تقریباً ۶ دسی‌بل). نصف شدن دامنه: -۶ dB.
- دو برابر شدن **توان یا شدت**: $+۳٫۰۱$ dB $\approx ۱۰ \log_{۱۰} ۲$.
- ده برابر شدن شدت: $+۱۰$ dB؛ ده برابر شدن دامنه (=صد برابر شدن شدت): $+۲۰$ dB.
- فشار صوت $p = ۰٫۰۲$ Pa: $L_p = ۲۰ \log_{۱۰} \frac{۰٫۰۲}{۲\times۱۰^{-۵}} = ۲۰ \log_{۱۰}(۱۰۰۰) = ۶۰$ dB SPL، که در حد گفت‌وگوی معمولی است.
- دو گوینده که هر یک با تراز ۶۰ dB و مستقل از هم صحبت می‌کنند: توان‌ها جمع می‌شوند و تراز کل $۶۰ + ۱۰ \log_{۱۰} ۲ \approx ۶۳$ dB است، نه ۱۲۰.
- در سیگنال دیجیتال، تراز نسبت به بیشینهٔ مقیاس (dBFS) سنجیده می‌شود: اگر مقدار مؤثر (RMS) سیگنال ۰٫۱ بیشینهٔ مقیاس باشد، $۲۰ \log_{۱۰} ۰٫۱ = -۲۰$ dBFS.

[محتوای افزوده] کانتور شدت چگونه محاسبه می‌شود؟

برای هر قاب (مثلاً به طول ۲۵ میلی‌ثانیه و گام ۱۰ میلی‌ثانیه) انرژی میانگین $E = \frac{۱}{N}\sum_n x^۲[n]$ را حساب می‌کنیم و $۱۰ \log_{۱۰}(E + \varepsilon)$ را رسم می‌کنیم (ε عدد بسیار کوچکی برای جلوگیری از لگاریتم صفر است). دنبالهٔ این مقادیر در طول زمان همان کانتور شدت است؛ نرم‌افزار Praat نیز چنین چیزی (با پنجره‌ای نسبتاً بلندتر) نشان می‌دهد. همین مقدار همان ضریب c0 در MFCC را به ذهن می‌آورد که انرژی کل قاب را نشان می‌دهد.



شکل ۳.۶: سمت چپ: یک تن خالص با دامنه‌های ۱، ۲ و ۱۰. سمت راست: رابطهٔ لگاریتمی دسی‌بل با نسبت دامنه؛ دو برابر شدن دامنه حدود ۶+ دسی‌بل و ده برابر شدن آن ۲۰+ دسی‌بل است. (شکل افزوده)

بلندی با شدت یکی نیست

بلندی ادراک‌شده تابع شدت، فرکانس و مدت صوت است. دو صدا با شدت یکسان ولی فرکانس متفاوت بلندی یکسان ندارند؛ گوش در حدود ۲ تا ۵ کیلوهرتز حساس‌ترین است (منحنی‌های هم‌بلندی). قاعدهٔ سرانگشتی روان‌شناسی صوت: افزایش حدود ۱۰ دسی‌بل تقریباً بلندی را دو برابر می‌کند. به همین دلیل گاهی از وزن‌دهی A برای نزدیک‌تر کردن اندازه‌گیری به ادراک استفاده می‌شود.

۳.۳.۶ تکیهٔ واژگانی و تأکید

شاخهٔ شدت روی تخته به دو مفهوم تقسیم شده است که نباید با هم اشتباه شوند.

Stress در برابر Accent

تکیهٔ واژگانی (Lexical Stress): برجستگی یک **هجا درون یک واژه**. هر واژه در فرهنگ لغت (و برای هر زبان یا لهجهٔ مشخص) الگوی تکیهٔ معینی دارد.

تأکید (Accent/Focus): برجسته‌کردن یک **واژه درون جمله**. این گوینده است که در موقعیت‌های گوناگون تصمیم می‌گیرد به کدام واژه در گفتمان (Discourse) تأکید بدهد. در کانتور شدت، تأکید به‌صورت یک **قله** دیده می‌شود، و بخش‌های سکوت یا گفتار بی‌تأکید تقریباً صاف‌اند.

مثال‌های کلاس: در «من گفتم که این کار را بکن» تأکید روی «من» است و در «کتاب را بردار» روی «کتاب».

اشتباه رایج: «اکسنت» در فارسی دو معنا دارد

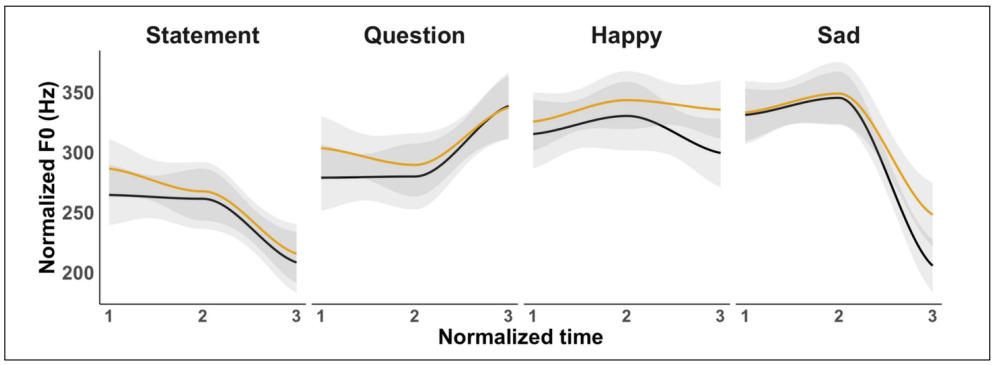
واژهٔ accent در این درس یعنی «تأکید روی یک واژه در جمله». اما در گفتار روزمره «اکسنت» را برای **لهجه** (regional/foreign accent، مثلاً لهجهٔ شیرازی یا لهجهٔ انگلیسی) هم به کار می‌برند. در این فصل، منظور همان معنای اول است. همچنین واژهٔ stress را با «استرس روانی» اشتباه نگیرید؛ در اینجا یعنی «تکیه».

جدول ۳.۶: مقایسهٔ تکیهٔ واژگانی و تأکید.

ویژگی	Stress (تکیه)	Accent (تأکید)
سطح بررسی	درون واژه (هجا)	درون جمله یا عبارت (واژه)
نقش	بخشی از الگوی تلفظ واژه	برجسته‌سازی اطلاعات مورد نظر گوینده
وابستگی	به واژه، زبان و لهجه	به قصد گوینده و بافت
تغییر در جمله	الگوی پایه معمولاً حفظ می‌شود	می‌تواند بین واژه‌ها جابه‌جا شود

رابطهٔ Accent با Stress

نکته‌ای که استاد چند بار بر آن تأکید کرد: هنگامی که روی یک واژه تأکید می‌کنیم، برجستگی روی همان هجایی قرار می‌گیرد که تکیهٔ واژگانی دارد. یعنی تأکید بیشتر، محل تکیهٔ واژه را عوض نمی‌کند؛ فقط برجستگی هجای تکیه‌دار را تقویت می‌کند. به عبارت تخته: «روی هر کلمه‌ای که تمرکز شود، استرس به قوت خود باقی است و نمی‌توان روی هجایی اکسنت گذاشت که استرس ندارد.» این ایده با **شبکهٔ متریک** (Metrical Grid) نمایش داده می‌شود: هر سطح، یک سطح برجستگی است و تأکید می‌تواند فقط به هجایی برسد که در سطح تکیه حضور دارد. استاد گفت این مبحث بیشتر در تحلیل‌های زبان‌شناختی و روان‌شناختی مطرح است و در این درس قرار نیست از آن استفاده تخصصی شود.



شکل ۴.۶: شبکهٔ متریک برای واژه‌های انگلیسی vitamins و California. هر هجا یک x در سطح پایین دارد؛ هجاهای دارای واکهٔ کامل و سپس هجای تکیه‌دار در سطح‌های بالاتر آمده‌اند و تأکید جمله (accented syll) فقط می‌تواند روی هجای تکیه‌دار قرار گیرد. (برگرفته از تختهٔ کلاس)

در این مثال، در vitamins هجای نخست و در California هجای سوم (for) تکیه دارند و تأکید جمله فقط به این هجاها می‌رسد. هجای Ca واکهٔ کامل دارد ولی تکیهٔ اصلی ندارد.

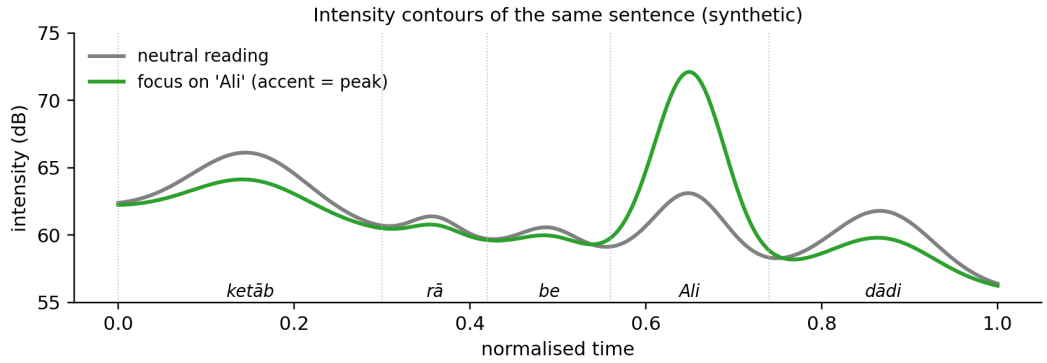
دقت دربارهٔ تکیه در فارسی

در زبان فارسی، تکیهٔ واژگانی اغلب قابل‌پیش‌بینی است: در اسم‌ها و صفت‌ها معمولاً بر **هجای پایانی** (مثلاً «کتاب») قرار می‌گیرد و پسوندهای تصریفی یا ربطی (مانند کسرهٔ اضافه و ضمایر متصل) معمولاً تکیه نمی‌گیرند؛ در فعل‌ها اغلب بر هجای نخست (پیشوند صرفی مانند «می» یا «نه») است. با این حال، جزئیات (به‌ویژه در مورد پسوندها) در منابع واج‌شناسی محل بحث است. روی تخته برای نشان دادن اینکه محل تکیه می‌تواند معنا را عوض کند، مثال «مَردی» (اسم مصدر، به معنی مردانگی) در برابر «مردی» (یک مرد) آمده است؛ جایگاه دقیق تکیه در

این دو صورت را در اینجا قطعی نمی‌کنیم. نکتهٔ روشن این است که در فارسی، تکیه برخلاف انگلیسی کمتر برای تمایز معنایی میان واژه‌ها به کار می‌رود و نقش آهنگ جمله (و نه تکیه) در مثال‌های کلاس مهم‌تر است.

نشانگرهای صوتی تأکید فقط شدت نیستند

کلاس تأکید را در شاخهٔ «شدت» جای داد و آن را با قله در کانتور شدت شناخت؛ این درست است ولی ناقص. در پژوهش‌های آوایی، نشانگرهای تکیه و تأکید معمولاً ترکیبی‌اند: افزایش F_0 یا تغییر شکل آن، افزایش مدت هجا و کامل‌تر ادا شدن واکه، و در مرتبهٔ بعد افزایش شدت. در بسیاری از آزمایش‌ها شدت ضعیف‌ترین نشانهٔ مستقل از میان این‌هاست. پس در عمل باید هم‌زمان کانتور شدت، F_0 و مدت را بررسی کرد، چنان‌که خود استاد در ادامه به آن اشاره کرد.



شکل ۵.۶: کانتور شدت برای جملهٔ «کتاب را به علی دادی» در خوانش خنثی (خاکستری) و در حالتی که روی «علی» تأکید شده است (سبز): تأکید به‌صورت قله روی هجای تکیه‌دار آن واژه دیده می‌شود. داده‌ها مصنوعی و فقط برای توضیح مفهوم‌اند. (شکل افزوده)

تمرین پیشنهادی با Praat

استاد پیشنهاد کرد این بحث را با Praat آزمایش کنید: یک واژه (یا جمله) را یک بار عادی و یک بار با تأکید یا لحن عصبانی ضبط کنید و کانتور شدت و کانتور F_0 آن‌ها را مقایسه کنید. بررسی کنید که افزایش شدت و کشش در همان هجای تکیه‌دار رخ می‌دهد یا نه، و محل تکیهٔ واژه تغییر می‌کند یا نه.

۴.۶ مؤلفهٔ دوم: فرکانس و زیر و بمی

۱.۴.۶ F_0، Pitch و آهنگ

مفاهیم این شاخه عبارت‌اند از Pitch، Fundamental Frequency، Pitch Contour و Intonation. این‌ها دقیقاً هم‌معنا نیستند، اما به یک حوزهٔ مرتبط اشاره دارند.

- **فرکانس پایه** (F_0): کمیتی **فیزیکی**، یعنی تعداد دورهٔ ارتعاش تارهای صوتی در ثانیه (هرتز).

- **زیر و بمی** (Pitch): کمیتی **ادراکی**؛ آنچه شنونده به‌صورت «زیر» یا «بم» حس می‌کند. در بیشتر موارد با F_0 هم‌ارزی نزدیک دارد و در عمل این دو را یکی می‌گیرند.
- **کانتور زیر و بمی** (Pitch Contour): تغییر F_0 در طول یک جمله یا عبارت.
- **آهنگ جمله** (Intonation): الگوی منظم و معنادار این تغییرات، که نقش زبانی (مثلاً تمایز خبر و پرسش) دارد.

[محتوای افزوده] دامنهٔ F_0 و نیم‌پرده؛ مثال عددی

F_0 در مردان بزرگسال معمولاً حدود ۸۵ تا ۱۸۰ هرتز و در زنان حدود ۱۶۵ تا ۲۵۵ هرتز است (مقادیر تقریبی). شنوایی انسان زیر و بمی را تقریباً لگاریتمی حس می‌کند، پس برای مقایسهٔ گویندگان و تغییرات، واحد **نیم‌پرده** (Semitone) مفیدتر است:

$$\Delta = ۱۲ \log_۲ \frac{f_۲}{f_۱} \quad \text{(نیم‌پرده)}.$$

مثلاً از ۲۰۰ به ۴۰۰ هرتز دقیقاً یک اکتاو (۱۲ نیم‌پرده) است؛ از ۲۰۰ به ۲۵۰ هرتز برابر $۱۲ \log_۲ ۱٫۲۵ \approx ۳٫۹$ نیم‌پرده؛ و افت F_0 از ۲۰۰ به ۱۵۰ هرتز برابر $-۵ \approx ۱۲ \log_۲ ۰٫۷۵$ نیم‌پرده است. همین ۱۰۰ هرتز تفاضل در ۱۰۰ تا ۲۰۰ هرتز (۱۲ نیم‌پرده) با ۳۰۰ تا ۴۰۰ هرتز (حدود ۵ نیم‌پرده) بسیار فرق دارد.

[محتوای افزوده] F_0 را چگونه از سیگنال درمی‌آوریم؟

روش‌های رایج (مثل خودهمبستگی در Praat) دنبال تناوب سیگنال در پنجره‌های کوتاه می‌گردند. چند نکتهٔ عملی: ۱) F_0 فقط برای قطعات **واک‌دار** تعریف می‌شود، پس کانتور در بی‌واک‌ها و سکوت‌ها «پاره» است. ۲) خطاهای دو برابر یا نصف شدن (F_0 octave errors) رایج‌اند. ۳) برای مقایسهٔ گویندگان، F_0 را معمولاً نسبت به میانگین یا دامنهٔ خود گوینده نرمال می‌کنند (چنان‌که در نمودارهای این فصل نیز دیده می‌شود).

۲.۴.۶ کانتور جملهٔ خبری و پرسشی

دو الگوی اصلی روی تخته:

- **جملهٔ خبری**: زیر و بمی صدا در پایان به سمت بم‌شدن می‌رود (سقوط فرکانس)؛ نشان‌دهندهٔ **قطعیت و پایان** است.
- **جملهٔ پرسشی**: بعد از اکسنت، تارهای صوتی کشیده‌تر می‌شوند و فرکانس به شدت بالا (زیر) می‌رود (مثال: «رفت؟؟؟»).

در جملهٔ پرسشی، افزایش کشش تارهای صوتی (با عمل ماهیچه‌های حنجره) و افزایش فشار هوای زیر تارها باعث بالا رفتن F_0 می‌شود. در شکل زیر همین الگوها روی داده‌های واقعی دیده می‌شود.

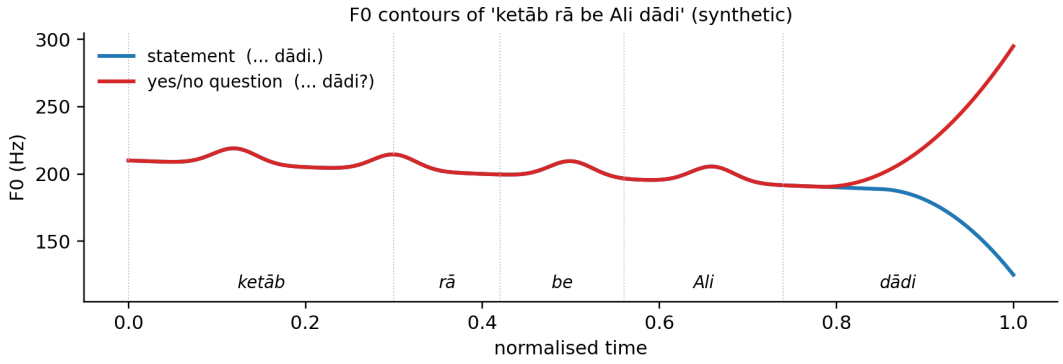
«خبری = افت، پرسشی = خیز» یک گرایش است، نه قانون

الگوی افت پایانی در جملهٔ خبری و خیز پایانی در پرسش‌های بله/خیر در بسیاری از زبان‌ها (از جمله فارسی) رایج است، اما قاعدهٔ مطلق نیست. پرسش‌های دارای واژهٔ پرسشی (چرا، کجا، چه) اغلب با آهنگ افتان گفته می‌شوند.

(x)					(x)		(accented syll)
x					x		stressed syll
x			x		x		full vowels
x	x	x	x	x	x	x	syllables
vi	ta	mins	Ca	li	for	nia	

شکل ۶.۶: کانتور F_0 نرمال‌شده (برحسب هرتز) در طول زمان نرمال‌شده برای چهار حالت Statement، Question، Happy و Sad. جملهٔ خبری در پایان افت می‌کند، پرسشی در پایان بالا می‌رود، حالت شاد در سطح بالاتر و تقریباً هموار است و حالت غمگین ابتدا بالا و سپس با افت شدید تمام می‌شود. دو منحنی رنگی (سیاه و نارنجی) با نوارهای اطمینان خاکستری دو گروه یا شرایط را نشان می‌دهند؛ تعریف آن‌ها در اسلاید ذکر نشده است. (برگرفته از تختهٔ کلاس)

در فارسی گفتاری، پرسش بله/خیر اغلب بدون «آیا» و فقط با آهنگ ساخته می‌شود («رفتی؟» در برابر «رفتی.»)، و به همین دلیل آهنگ نقش تعیین‌کننده دارد. شکل دقیق کانتور به گوینده، زبان، نوع پرسش و تأکید هم بستگی دارد. در زبان‌های تونال (مثل چینی ماندارین) زیر و بمی در سطح واژه معنای واژگانی دارد؛ فارسی تونال نیست.



شکل ۷.۶: کانتور مصنوعی F_0 برای همان واژه‌ها در دو حالت: جملهٔ خبری با افت پایانی و پرسش بله/خیر با خیز پایانی. هر دو یک «شیب کلی رو به پایین» (declination) و قله‌های کوچک روی هجاهای تکیه‌دار دارند. (شکل افزوده)

۳.۴.۶ مثال «کتاب را به علی دادی؟»

استاد جملهٔ «کتاب را به علی دادی؟» را چند بار با لحن‌های گوناگون گفت. در حالت پرسشی انتظار داریم F_0 در پایان جمله بالا برود؛ در حالت خبری («کتاب را به علی دادی.») زیر و بمی در پایان پایین می‌آید و قطعیت بیشتری منتقل می‌شود. هنگام اجرا، استاد متوجه شد خیز پایانی یکی از دفعات پرسشی به اندازهٔ انتظار روشن نبود. این نشان می‌دهد یک الگوی پروسودیک همیشه یک‌شکل تولید نمی‌شود و در تحلیل باید شمار زیادی نمونه را بررسی کرد.

۴.۴.۶ رابطهٔ زیر و بمی با تأکید

اگر بخواهیم در همین جمله روی «علی» تأکید کنیم، در ناحیهٔ «علی» علاوه بر تغییر شدت، تغییر محسوسی در کانتور F_0 هم دیده می‌شود. بنابراین با بررسی هم‌زمان کانتور شدت و کانتور زیر و بمی می‌توان دربارهٔ محل برجستگی اطلاعات بهتر قضاوت کرد. در کلاس گفته شد پس از بخش تأکیدی، کانتور فرکانس ممکن است به سمت بالا یا پایین حرکت کند؛ پس محل تأکید و ادامهٔ مسیر F_0 به هم مرتبط‌اند.

[محتوای افزوده] اصطلاحات زبان‌شناختی آهنگ

در زبان‌شناسی، آهنگ را اغلب با چند «برجستگی» و «مرز» توصیف می‌کنند: **تکیهٔ زیر و بمی** (Pitch Accent) حرکتی از F_0 روی هجای تکیه‌دار واژهٔ مورد تأکید است، و **نغمهٔ مرزی** (Boundary Tone) خیز یا افت در مرز عبارت. روش‌های برچسب‌گذاری مانند ToBI بر همین دو مفهوم استوارند. چنین برچسب‌هایی در سامانه‌های TTS و پژوهش‌های پروسودی کاربرد دارند.

۵.۴.۶ جمله‌های دستوری، مؤدبانه و احساسی

استاد دربارهٔ جمله‌های دستوری نیز صحبت کرد. در دستور قاطع ممکن است افت پایانی شدیدتر از جملهٔ خبری معمولی باشد؛ اما وقتی جمله حالت درخواست مؤدبانه دارد («بفرمایید، بشینید.») الگوی فرکانس متفاوت است و لحن ملایم‌تر می‌شود. حالت‌های احساسی مثل شادی و غم هم کانتور و سطح متفاوتی دارند (شکل کانتورهای Happy و Sad بالا). نکتهٔ مهم: الگوی زیر و بمی فقط به کلمات وابسته نیست؛ شیوهٔ بیان، قصد ارتباطی و شرایط گفتار هم در آن مؤثرند.

۵.۶ مؤلفهٔ سوم: زمان، ریتم و مکث

۱.۵.۶ ویژگی‌های زمانی

جدول ۴.۶: ویژگی‌های زمانی گفتار (شاخهٔ Duration در نقشهٔ کلاس).

ویژگی	توضیح
Duration	مدت‌زمان بیان یک آوا، هجا، واژه یا عبارت
Speech Rate	سرعت گفتار؛ ساده‌ترین معیار «تعداد هجا در ثانیه» است
Rhythm	الگوی زمانی و ریتمیک گفتار
Pause	مکث و سکوت
Lengthening	کشیده‌شدن آواها
Phrasing	تقسیم گفتار به گروه‌ها و عبارت‌های آهنگین

[محتوای افزوده] محاسبهٔ سرعت گفتار؛ مثال عددی

جملهٔ «مادر کتاب را روی میز اتاق گذاشت و پنجره را باز کرد.» ۱۹ هجا دارد (مادَر، کِتاب، را، رویِ، میز، اوتاق، گوزاشت، و، پَنجِرِ، را، باز، کَرد). فرض کنید ادای آن ۴٫۵ ثانیه طول بکشد که ۰٫۵ ثانیه آن مکث است. آنگاه

$$\text{speech rate} = \frac{۱۹}{۴٫۵} \approx ۴٫۲ \text{ syll/s}, \qquad \text{articulation rate} = \frac{۱۹}{۴٫۰} \approx ۴٫۷۵ \text{ syll/s}.$$

سرعت گفتار (Speech Rate) مکث‌ها را در زمان کل حساب می‌کند و **سرعت تلفظ** (Articulation Rate) فقط زمان گفتار واقعی را. این دو را نباید با هم اشتباه گرفت.

۲.۵.۶ نقش مکث و علائم نگارشی

مکث می‌تواند معنای نحوی یا ارتباطی جمله را تغییر دهد. اگر جمله‌ای را بدون مکث بگوییم، شنونده ممکن است آن را یک عبارت پیوسته بشنود؛ با قرار دادن مکث در نقطه‌ای مشخص، مرز دو عبارت روشن می‌شود. بخشی از علائم نگارشی (ویرگول، دونقطه، نقطه) نشانهٔ محل مکث یا تغییر بخش‌بندی‌اند؛ اما همهٔ علائم زمانی نیستند. علامت سؤال، برای مثال، به ویژگی آهنگی جمله مربوط است.

۳.۵.۶ رفع ابهام نحوی

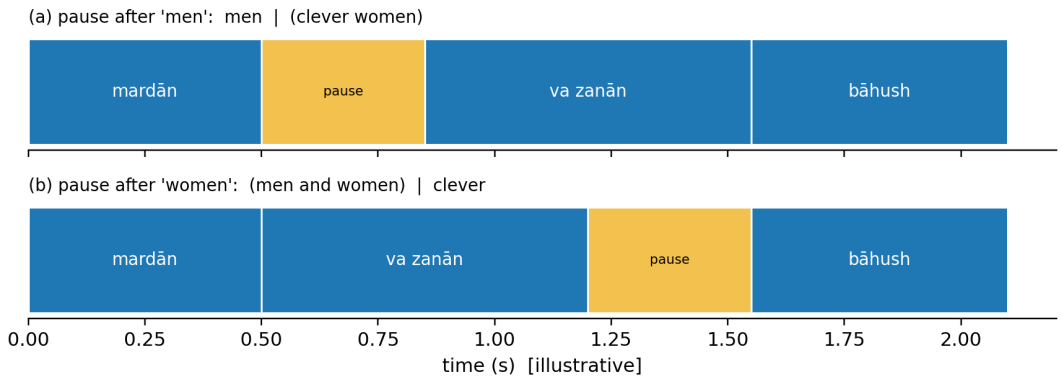
یک کاربرد مهم ویژگی‌های زمانی، **رفع ابهام نحوی** (Syntactic Disambiguation) است. گاهی جمله در متن بیش از یک تفسیر دارد، اما در گفتار، محل مکث‌ها، کشش آواها و گروه‌بندی زمانی به شنونده نشان می‌دهد ساختار مورد نظر چیست.

[محتوای افزوده] مثال: «مردان و زنان باهوش»

عبارت «مردان و زنان باهوش» دو معنا دارد: «(مردان) و (زنان باهوش)» یا «(مردان و زنان) باهوش». در گفتار، مکث پس از «مردان» تفسیر اول و مکث پس از «زنان» تفسیر دوم را برجسته می‌کند. در شکل زیر، فقط جای مکث عوض شده است. (این مثال در کلاس نبود و برای توضیح مفهوم افزوده شده است.)

[محتوای افزوده] کشش پایان عبارت

در بسیاری از زبان‌ها، هجای پایانی یک عبارت کشیده‌تر ادا می‌شود (phrase-final lengthening) و گاهی پیش از مرز عبارت مکث می‌آید. بنابراین مدت یک هجا هم از تکیه تأثیر می‌گیرد و هم از جایگاه آن در عبارت؛ در تحلیل پروسودی باید این دو را از هم جدا کرد.



شکل ۸.۶: دو گروه‌بندی ممکن برای «مردان و زنان باهوش» که فقط در جای مکث تفاوت دارند. مدت‌ها فرضی و برای توضیح‌اند. (شکل افزوده)

۶.۶ پروسودی در تبدیل متن به گفتار

استاد در ادامه چند نمونه خروجی از یک سامانهٔ فارسی تبدیل متن به گفتار و شبیه‌سازی صدا را پخش کرد تا اهمیت پروسودی در طبیعی بودن گفتار روشن شود.

۱.۶.۶ نمونهٔ اول

متن ورودی: «مادر کتاب را روی میز اتاق گذاشت و پنجره را باز کرد.» در خروجی، مکث و گروه‌بندی کلمات طبیعی نبود. برای مثال، نحوهٔ بیان بخش‌هایی مثل «مادر کتاب» یا «روی میز اتاق» می‌توانست مرزهای عبارتی را درست نشان ندهد. مشکل اصلی این بود که مدل واج‌ها را ساخته بود اما پروسودی مناسب جمله را بازسازی نکرده بود.

۲.۶.۶ نمونهٔ دوم

در نمونهٔ دیگر، جمله‌ای دربارهٔ شرکت Anthropic پخش شد. سامانه در به‌کارگیری کسرهٔ اضافه و اتصال کلمات مشکل داشت و در بعضی بخش‌ها کسره‌های نامناسب تولید می‌کرد؛ سرعت گفتار خروجی هم نسبتاً بالا بود. استاد دربارهٔ اینکه داده‌های آموزشی آن سامانه دقیقاً چه بوده اظهار اطمینان نکرد؛ بنابراین از این نمونه‌ها نمی‌توان دربارهٔ شیوهٔ آموزش آن نتیجهٔ قطعی گرفت.

۳.۶.۶ چه چیزهایی را یک سامانهٔ TTS باید درست تولید کند؟

کیفیت TTS فقط به تلفظ درست واج‌ها وابسته نیست. سامانه باید این‌ها را هم درست تولید کند:

- محل مکث‌ها و مرز عبارت‌ها؛
- طول هجاها و واژه‌ها؛

- ریتم جمله؛
- الگوی تأکید؛
- اتصال طبیعی واژه‌ها (مانند کسرهٔ اضافه در فارسی)؛
- آهنگ و زیر و بمی.

[محتوای افزوده] چرا پروسودی در TTS دشوار است؟

متن یک جمله می‌تواند با چندین پروسودی درست خوانده شود؛ یعنی نگاشت متن به پروسودی «یک‌به‌چند» است و چیزهایی مثل قصد گوینده، تأکید و احساس در متن نیامده‌اند. به همین دلیل، سامانه‌های TTS امروزی علاوه بر واج‌ها، صراحتاً مدت، F_0 و انرژی هر هجا یا واج را پیش‌بینی (یا از مرجع تقلید) می‌کنند؛ جزئیات معماری در فصل TTS آمده است. ارزیابی طبیعی بودن معمولاً با آزمون‌های شنیداری (مثلاً امتیاز میانگین نظر، MOS) انجام می‌شود.

۷.۶ پژوهش: اطمینان و صداقت ادراک‌شده از روی پروسودی

۱.۷.۶ مسئله و طراحی آزمایش

در بخش پایانی جلسه، استاد این پرسش را به‌عنوان تمرین طراحی آزمایش مطرح کرد.

تمرین طراحی آزمایش

آزمایشی طراحی کنید که نشان دهد صداقت و اطمینان یک گوینده، در نحوهٔ بیان او و ویژگی‌های پروسودیک گفتارش، الگوهای مشترکی دارند.

نکتهٔ مهم: باید میان دو موضوع فرق گذاشت. (۱) میزان اطمینان یا صداقتی که **شنونده** از صدای فرد برداشت می‌کند؛ (۲) اطمینان یا صداقت **واقعی** گوینده (راست یا دروغ بودن گفته‌اش). آزمایش ادراکی کلاس مستقیماً موضوع اول را می‌سنجد. وجود یک الگوی پروسودیک، صداقت واقعی فرد را ثابت نمی‌کند.

فرضیه‌های اولیهٔ کلاس

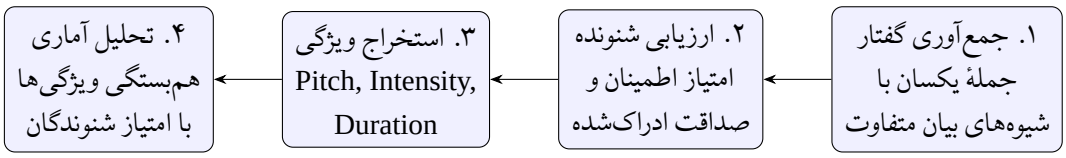
از دانشجویان خواسته شد پیش‌بینی کنند گوینده‌ای که مطمئن صحبت می‌کند چه ویژگی‌هایی دارد.

- **شدت:** حدس این بود که شدت بیشتر یا تأکید واضح‌تر احساس تسلط و اطمینان ایجاد می‌کند. اما بلندی صدای افراد یکسان نیست و ممکن است کسی ذاتاً آرام صحبت کند؛ پس مقایسهٔ مقدار مطلق شدت دو فرد درست نیست. استاد پیشنهاد کرد ابتدا ویژگی‌های معمول هر گوینده را به‌عنوان **خط پایه** (Baseline) در نظر بگیریم و تغییرات همان فرد را بررسی کنیم.
- **زیر و بمی:** بر اساس بحث کانتور، افت F_0 در پایان عبارت می‌تواند قطعیت را منتقل کند و با اطمینان ادراک‌شده مرتبط باشد.

- **زمان و مکث:** حدس این بود که مکث‌های متعدد در میانهٔ جمله تردید را نشان می‌دهد. یکی از دانشجویان گفت مکث در ابتدا یا انتهای صحبت ممکن است به‌جای تردید، متانت و سنجیدگی را منتقل کند. استاد پذیرفت که **محل** مکث هم اهمیت دارد، نه فقط تعداد یا جمع زمان آن‌ها.

این‌ها فرضیه‌های قابل آزمون‌اند، نه قواعد قطعی دربارهٔ شخصیت یا صداقت افراد.

طرح آزمایش پیشنهادی



مثلاً از یک گوینده بخواهیم جملهٔ «من مطمئنم که این کار درسته.» را با شیوه‌های مختلف بگوید، نمونه‌ها را برای شنوندگان پخش کنیم و بپرسیم کدام مطمئن‌تر یا صادقانه‌تر به نظر می‌رسد؛ سپس ویژگی‌های صوتی هر نمونه را استخراج کنیم و رابطهٔ آن‌ها با امتیازها را بسنجیم.

۲.۷.۶ هم‌بستگی

هم‌بستگی (Correlation)

هم‌بستگی مثبت: با افزایش یک متغیر، متغیر دیگر نیز تمایل به افزایش دارد (مثلاً شدت بیشتر همراه با امتیاز اطمینان بیشتر). **هم‌بستگی منفی:** با افزایش یک متغیر، دیگری تمایل به کاهش دارد (مثلاً مدت طولانی‌تر همراه با امتیاز اطمینان کمتر). نزدیک صفر یعنی رابطهٔ خطی ضعیف است. ضریب هم‌بستگی (پیرسون) بین -۱ و $+۱$ است.

هم‌بستگی به‌تنهایی رابطهٔ علت و معلولی را ثابت نمی‌کند.

۳.۷.۶ مقاله‌ای که بررسی شد

مقالهٔ نشان‌داده‌شده روی تخته (برگ نخست آن در شکل زیر) با عنوان زیر در سال ۲۰۲۱ در مجلهٔ Nature Communications (جلد ۱۲، شمارهٔ مقاله ۸۶۱) منتشر شده است:

Listeners' perceptions of the certainty and honesty of a speaker are associated with a common prosodic signature

نویسندگان: Louise Goupil، Emmanuel Ponsot، Daniel Richardson، Gabriel Reyes و Jean-Julien Aucouturier.



nature COMMUNICATIONS

ARTICLE

https://doi.org/10.1038/s41467-020-20649-4 OPEN

Listeners' perceptions of the certainty and honesty of a speaker are associated with a common prosodic signature

Louise Goupil[1,2✉], Emmanuel Ponsot[3,4], Daniel Richardson[5], Gabriel Reyes[6] & Jean-Julien Aucouturier[1,7]

The success of human cooperation crucially depends on mechanisms enabling individuals to detect unreliability in their conspecifics. Yet, how such epistemic vigilance is achieved from naturalistic sensory inputs remains unclear. Here we show that listeners' perceptions of the certainty and honesty of other speakers from their speech are based on a common prosodic signature. Using a data-driven method, we separately decode the prosodic features driving listeners' perceptions of a speaker's certainty and honesty across pitch, duration and loudness. We find that these two kinds of judgments rely on a common prosodic signature that is perceived independently from individuals' conceptual knowledge and native language. Finally, we show that listeners extract this prosodic signature automatically, and that this impacts the way they memorize spoken words. These findings shed light on a unique auditory adaptation that enables human listeners to quickly detect and react to unreliability during linguistic interactions.

[1] STMS UMR 9912 (CNRS/IRCAM/SU), Paris, France. [2] University of East London, London, UK. [3] Laboratoire des Systèmes Perceptifs, Département d'Études Cognitives, École Normale Supérieure, PSL University, CNRS, Paris, France. [4] Hearing Technology - WAVES, Department of Information Technology, Ghent University, Ghent, Belgium. [5] University College London, London, UK. [6] Universidad del Desarrollo, Santiago, Chile. [7] FEMTO-ST (FEMTO-ST UMR 6174, CNRS/UBFC/ENSMM/UTBM, Besançon, France. ✉email: lougoupil@gmail.com

NATURE COMMUNICATIONS | (2021)12:861 | https://doi.org/10.1038/s41467-020-20649-4 | www.nature.com/naturecommunications 1

شکل ۹.۶: برگ نخست مقالهٔ مورد بحث (Goupil et al., Nature Communications, 2021). چکیده می‌گوید قضاوت شنوندگان دربارهٔ اطمینان و صداقت گوینده بر یک «امضای پروسودیک مشترک» تکیه دارد. (برگرفته از تختهٔ کلاس)

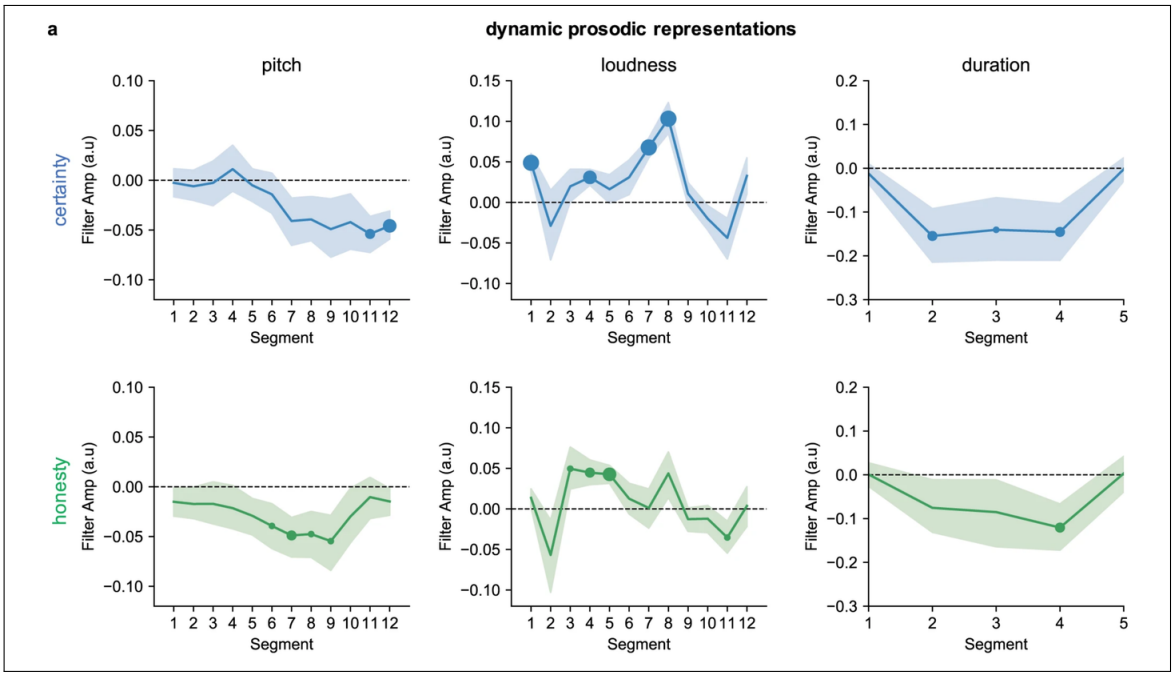
[محتوای افزوده] آزمایش اصلی مقاله با آنچه روی تخته آمد یکی نیست

روی تخته، آزمایش به‌صورت «دو نفر جملهٔ «من مطمئنم که این کار درست است» را با پروسودی متفاوت می‌گویند و شنونده انتخاب می‌کند کدام مطمئن‌تر است» ترسیم شده بود. این فقط خلاصهٔ آموزشی ایدهٔ کلی است. در مقاله (مطالعهٔ اول) طبق گزارش‌های منتشرشده: محرک‌ها **شبه‌واژه**‌های فرانسوی بودند که با الگوریتم‌های پردازش سیگنال، F_0، بلندی و مدت آن‌ها به‌صورت تصادفی تغییر داده شده بود؛ هر آزمایه شامل دو نسخه از یک شبه‌واژه با پروسودی تصادفی متفاوت بود و شنونده انتخاب می‌کرد کدام نسخه «مطمئن‌تر» (در یک جلسه) یا «صادق‌تر» (در جلسهٔ دیگر) به نظر می‌رسد. از روی انتخاب‌ها، با روش **هم‌بستگی معکوس** (Reverse Correlation)، «هستهٔ پروسودیک» هر قضاوت به دست می‌آید: برای هر نقطهٔ زمانی، میانگین مقدار ویژگی در محرک‌های انتخاب‌شده منهای (یا در برابر) محرک‌های ردشده. F_0 و بلندی در ۱۲ نقطه و مدت در ۵ قطعهٔ زمانی نمونه‌برداری شدند. دقیق‌ترین جزئیات (تعداد شرکت‌کنندگان، آزمون‌های آماری و مطالعات بعدی دربارهٔ تأثیر زبان مادری و حافظه) در متن مقاله آمده است و باید از خود مقاله بازبینی شود.

۴.۷.۶ خواندن نمودارهای مقاله

نمودارهای زیر از همان مقاله‌اند. ردیف بالا مربوط به **اطمینان** (certainty، آبی) و ردیف پایین مربوط به **صداقت** (honesty، سبز) است؛ ستون‌ها سه ویژگی pitch، loudness و duration را نشان می‌دهند. محور افقی «قطعه» (Segment) است: بازهٔ زمانی هر محرک به ۱۲ قطعهٔ مساوی برای F_0 و بلندی و ۵ قطعه برای مدت تقسیم شده است،

یعنی قطعه‌ها **بخش‌های یک محرک کوتاه** (نه بخش‌های یک جملهٔ بلند) هستند. محور عمودی (Filter Amp (a.u. دامنهٔ هستهٔ هم‌بستگی معکوس به واحد دلخواه است؛ خط خطچین صفر یعنی «بدون اثر»، نوار سایه‌دار بازهٔ عدم‌قطعیت، و دایره‌های بزرگ‌تر قطعه‌هایی‌اند که به‌طور معنادار از صفر فاصله دارند (اندازهٔ دایره بر اساس سطح معناداری است؛ استاد در کلاس حدس زده بود اندازهٔ دایره نشان‌دهندهٔ وزنی است و تعریف دقیق آن را نداشت).



شکل ۱۰.۶: هسته‌های پروسودیک اطمینان (ردیف بالا) و صداقت (ردیف پایین) برای pitch، loudness و duration در برابر قطعهٔ زمانی. مقدار مثبت یعنی ویژگی در آن قطعه با انتخاب «مطمئن‌تر/صادق‌تر» همراه بوده؛ مقدار منفی یعنی عکس؛ نزدیک صفر یعنی بی‌اثر. (مقاله: Goupil et al., 2021) (برگرفته از تختهٔ کلاس)

برداشت کلاس (که با نتیجهٔ مقاله هم‌خوان است):

جدول ۵.۶: خلاصهٔ الگوهای نمودار.

ویژگی	الگوی دیده‌شده	برداشت
Pitch	هسته در ابتدا نزدیک صفر و در نیمهٔ دوم منفی (اطمینان: قطعه‌های ۱۱-۱۲؛ صداقت: قطعه‌های ۶-۹)	فرکانس پایین‌تر در بخش پایانی (افت آهنگ) با اطمینان و صداقت ادراک‌شدهٔ بیشتر همراه است
Loudness	مثبت در چند قطعه (ابتدا و قطعه‌های ۷-۸ برای اطمینان؛ قطعه‌های ۳-۵ برای صداقت)	شدت بیشتر در این بخش‌ها با اطمینان یا صداقت بیشتر همراه است
Duration	منفی در قطعه‌های میانی و نزدیک صفر در دو سر	طولانی‌تر بودن (کندتر) با اطمینان و صداقت کمتر همراه است

نکات تفسیری استاد: (۱) در پایان جمله، F_0 هم‌بستگی منفی با تأیید صداقت دارد: «فرکانس پایین‌تر، صداقت بیشتر». (۲) تأکید صوتی (بلندی) در میانهٔ جمله با درک قطعیت مرتبط است. (۳) برای مدت، هم‌بستگی «کلاً منفی» است: وقتی مدت یا مکث بیشتر شود، رأی به قطعیت و صداقت کمتر می‌شود («هم‌بستگی معکوس»). (۴) مقدار مثبت در

نمودار F_0 یعنی در آن قطعه F_0 بالاتر با انتخاب «مطمئن‌تر» همراه است؛ مقدار منفی یعنی F_0 پایین‌تر؛ و نزدیک صفر یعنی آن تغییر در تصمیم شنونده اثر مشخصی نداشته است. این چهار نکته را می‌توان از شکل بالا تأیید کرد.

دقت در تفسیر نمودار

- **«مکث» یا «مدت»؟** نمودار سوم به مدت قطعه‌ها (در نتیجه سرعت گفتار) مربوط است، نه به «مکث» در معنای سکوت. در مقاله، سرعت گفتار بیشتر (مدت کوتاه‌تر) با اطمینان ادراک‌شدهٔ بیشتر همراه است. حدس کلاس دربارهٔ مکث‌های میانی با نتایج هم‌جهت است، اما برای نتیجه‌گیری دربارهٔ مکث باید ویژگی مکث جداگانه سنجیده شود.
- **«قسمت جمله»:** قطعه‌ها بخش‌های یک محرک کوتاه‌اند؛ تعبیر «ابتدا، میانه و انتهای جمله» در کلاس را باید «ابتدا، میانه و انتهای واژه/محرک» خواند.
- **علامت مقادیر:** در شکل، علامت طوری است که با خلاصهٔ نتیجهٔ مقاله هم‌خوان است: افت F_0 در بخش پایانی، بلندی بیشتر در بخش‌های ابتدایی/میانی و مدت کوتاه‌تر با اطمینان و صداقت بیشتر همراه‌اند. قرارداد علامت (نتیجه منهای مقابل آن) را اگر در سند اصلی لازم است، باید از متن مقاله بازبینی کرد.
- **میانگین یا شکل؟** ایدهٔ مقاله این است که «شکل» کانتور (مثلاً افت یا خیز) مهم است، نه فقط میانگین F_0. پس عبارت «فرکانس پایین‌تر» را نباید به‌معنای «صدای بم‌تر به‌طور کلی» خواند، بلکه به‌معنای افت زیر و بمی در بخش پایانی است.
- **هم‌بستگی، علیت نیست؛** و این نتیجه دربارهٔ **برداشت شنونده** است، نه صداقت واقعی گوینده. الگو مربوط به شرکت‌کنندگان مقاله است و قانون عمومی برای همهٔ افراد و موقعیت‌ها نیست.

[محتوای افزوده] نتیجهٔ کلی مقاله

طبق چکیدهٔ مقاله، قضاوت دربارهٔ اطمینان و صداقت هر دو بر یک «امضای پروسودیک مشترک» تکیه دارند که مستقل از دانش مفهومی و زبان مادری شنونده است؛ شنوندگان این امضا را به‌طور خودکار استخراج می‌کنند و بر نحوهٔ به‌خاطر سپردن واژه‌ها اثر می‌گذارد. گزارش نویسندگان از الگوی «غیرقابل‌اطمینان»: آهنگ خیزان، شدت کمتر در آغاز، سرعت کمتر، و تغییرپذیری بیشتر F_0 و سرعت. جزئیات را از متن مقاله بازبینی کنید.

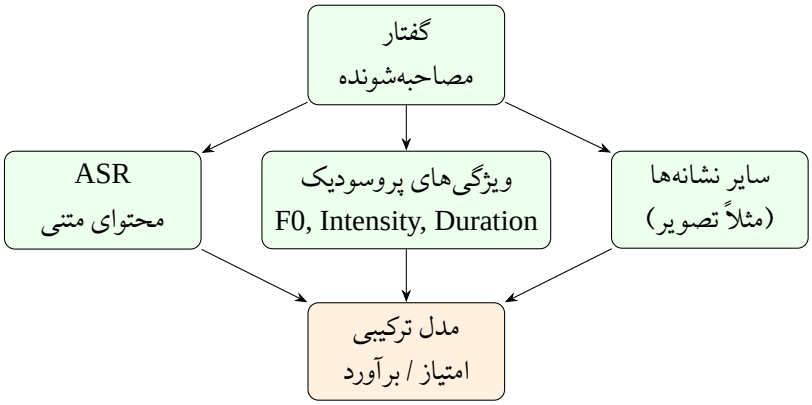
۸.۶ کاربردهای عملی تحلیل پروسودی

استاد در خلال بحث مقاله به کاربردهای تحلیل پروسودی در سامانه‌های هوشمند اشاره کرد. یک نمونه ارزیابی نحوهٔ بیان افراد در موقعیت‌هایی مانند **مصاحبهٔ شغلی** است. چنین سامانه‌ای می‌تواند چند منبع اطلاعات را ترکیب کند:

۱. **تحلیل محتوا:** با ASR، گفتار به متن تبدیل و تحلیل می‌شود (مثلاً پاسخ به یک پرسش).

۲. **تحلیل نحوه‌بیان:** شدت، فرکانس و سرعت گفتار برای تحلیل نشانه‌های مرتبط با اطمینان ادراک‌شده، روانی گفتار یا نحوهٔ ارائهٔ پاسخ.

۳. **تحلیل چندوجهی:** ترکیب اطلاعات متنی، صوتی و (در بعضی سامانه‌ها) تصویری برای ارائهٔ امتیاز یا برآورد.



احتیاط در استفاده

چنین امتیازهایی لزوماً بیانگر شخصیت واقعی، تخصص واقعی یا صداقت فرد نیستند. اعتبار آن‌ها نیازمند ارزیابی مستقل و کنترل تفاوت‌های فردی، زبانی و موقعیتی است. پروسودی با خلق، سبک ارتباطی، زبان و فرهنگ و حتی ویژگی‌های فیزیکی گوینده تغییر می‌کند.

[محتوای افزوده] کاربردهای دیگر پروسودی

علاوه بر ارزیابی گفتار: تشخیص احساس از گفتار، تشخیص نوع جمله و مرز عبارت‌ها (و بازسازی علائم نگارشی در خروجی ASR)، مدیریت نوبت‌گیری در گفت‌وگو، یادگیری زبان دوم و ارزیابی تلفظ، تشخیص و پایش بیماری‌های گفتاری، و سنتز گفتار طبیعی و گویا.

۹.۶ جمع‌بندی

پروسودی لایه‌ای از گفتار است که «چگونه گفتن» را توصیف می‌کند و تمام اطلاعات آن در متن نوشتاری نیست. سه مؤلفهٔ آن عبارت‌اند از زیر و بمی (F_0 و کانتور آن)، شدت و زمان؛ و چون این ویژگی‌ها زبرزنجیری‌اند، باید آن‌ها را روی بازه‌های بلندتر و به‌صورت کانتور در طول زمان بررسی کرد. شدت در دسی‌بل (با رابطهٔ $20 \log_{10}$ برای دامنه) سنجیده می‌شود و در تأکید نقش دارد؛ آهنگ جمله (خبری و پرسشی) عمدتاً در کانتور F_0 دیده می‌شود؛ و ویژگی‌های زمانی در گروه‌بندی و رفع ابهام نحوی مؤثرند. کیفیت TTS به پروسودی وابسته است. در پژوهش اطمینان و صداقت ادراک‌شده دیدیم که اثر ویژگی‌ها به جایگاه زمانی آن‌ها بستگی دارد. در نهایت، تحلیل طیفی به‌تنهایی کافی نیست و برای درک نحوهٔ بیان، تأکید و ریتم باید ویژگی‌های پروسودیک را نیز بررسی کرد.

نکات مهم برای مرور و امتحان

۱. MFCC بیشتر برای نمایش ویژگی‌های طیفی و فیلتر مجرای صوتی است؛ اطلاعات F_0 در آن عملاً حذف می‌شود.

۲. خروجی بانک فیلتر مل به تعداد فیلترها بستگی دارد؛ تعداد ضرایب نهایی (مثلاً ۱۲) می‌تواند کمتر باشد. گام تبدیل پس از لگاریتم DCT است.

۳. اختلاف «آ» و «اَ» مربوط به فیلتر است. F_1 با ارتفاع زبان (زبان پایین‌تر، F_1 بالاتر) و F_2 با موقعیت

جلو/عقب زبان (جلوتر، F_2 بالاتر) مرتبط است.

۴. پروسودی لایه‌ای از گفتار است که ریتم، آهنگ و تأکید را توصیف می‌کند و تمام آن در متن نیست.

۵. سه مؤلفهٔ پروسودی: Pitch/Frequency، Intensity، Time/Duration.

۶. ویژگی‌های پروسودیک زبرزنجیری‌اند: باید یک عبارت یا دنبالهٔ گفتاری و کانتور آن را بررسی کرد.

۷. Stress: تکیه درون واژه؛ Accent: برجسته‌سازی واژه در جمله؛ تأکید روی همان هجای تکیه‌دار قرار می‌گیرد.

۸. کانتور شدت می‌تواند ناحیه‌های تأکیدی را نشان دهد، اما F_0 و مدت نیز در تأکید نقش دارند. شدت متناسب با مربع دامنه است؛ $L_p = ۲۰ \log_{۱۰}(p/p_۰)$ و $L_I = ۱۰ \log_{۱۰}(I/I_۰)$.

۹. کانتور جملهٔ پرسشی اغلب با خیز و جملهٔ خبری با افت پایانی همراه است.

۱۰. ویژگی‌های زمانی: سرعت گفتار، مدت هجا، ریتم، مکث و کشش؛ در Phrasing و رفع ابهام نحوی نقش دارند.

۱۱. برای بررسی پروسودی اطمینان/صداقت: جمع‌آوری گفتار، ارزیابی شنونده، استخراج ویژگی، تحلیل هم‌بستگی.

۱۲. جایگاه زمانی ویژگی مهم است؛ هم‌بستگی منفی/مثبت/نزدیک صفر را بتوانید در نمودار تفسیر کنید.

فصل ۷

تبدیل متن به گفتار: مسئله و معماری خط‌لولهٔ TTS

۱.۷ از تحلیل گفتار تا تولید گفتار

۱.۱.۷ مرور جلسات گذشته

تا این جلسه، محور درس **تحلیل سیگنال گفتار** بود: یک موج صوتی (waveform) از پیش در اختیار ما بود و می‌کوشیدیم نمایش‌ها و ویژگی‌های گوناگونی از آن استخراج کنیم. موضوعاتی که تاکنون دیده‌ایم عبارت‌اند از:

- **طیف‌نگار** (Spectrogram): نمایش محتوای فرکانسی سیگنال در طول زمان؛
- MFCC: ویژگی‌های صوتی فشرده بر پایهٔ مقیاس مل؛
- **پروزودی** (Prosody) و دو نمونهٔ آن، **کانتور گام** (Pitch Contour) و **کانتور شدت** (Intensity Contour)؛
- **فرمنت‌ها** (Formants) و نقش آن‌ها در تمایز آواها؛
- محل و شیوهٔ تولید آوا (Place/Manner of Articulation) و پدیدهٔ **هم‌تولیدی** (Coarticulation).

در همهٔ این مباحث «سیگنال» ورودی بود و «اطلاعات» خروجی. از این جلسه به بعد وارد سامانه‌های اصلی پردازش گفتار و زبان می‌شویم: تبدیل متن به گفتار (Text-to-Speech یا TTS)، سامانه‌های گفت‌وگو (Dialogue Systems) و تبدیل گفتار به متن (Speech-to-Text یا STT). موضوع این جلسه **تبدیل متن به گفتار** (Speech Synthesis) است.

۲.۱.۷ صورت مسئله

در TTS جهت مسئله معکوس می‌شود:

$$\text{Text} \longrightarrow \text{Speech Waveform}$$

یک متن داریم و باید از روی آن موجی بسازیم که شنونده آن را گفتار طبیعی و قابل فهم بداند. دو مشکل بنیادی در این مسیر وجود دارد.

شکاف حجم اطلاعات

متن در مقایسه با موج صوتی بسیار کم‌حجم است. اگر موج با نرخ نمونه‌برداری $f_s = ۲۴\,۰۰۰$ هرتز تولید شود، هر ثانیه گفتار ۲۴ هزار نمونه دارد؛ در مقابل، جملهٔ متناظر فقط چند ده نویسه یا واج است. پس پرسش اصلی این است: چگونه از یک نمایش بسیار کوتاه، توالی‌ای با ده‌ها هزار مقدار عددی بسازیم؟

کم‌گویی متن

متن همهٔ اطلاعات لازم برای گفتار طبیعی را در خود ندارد. برای نمونه معلوم نیست:

- گوینده با چه لحنی صحبت کند؛
- کدام بخش جمله تأکید بگیرد؛
- سرعت بیان چقدر باشد و کجا مکث رخ دهد؛
- صدا متعلق به چه نوع گوینده‌ای باشد (جنسیت، سن، لهجه، ویژگی‌های صدای او).

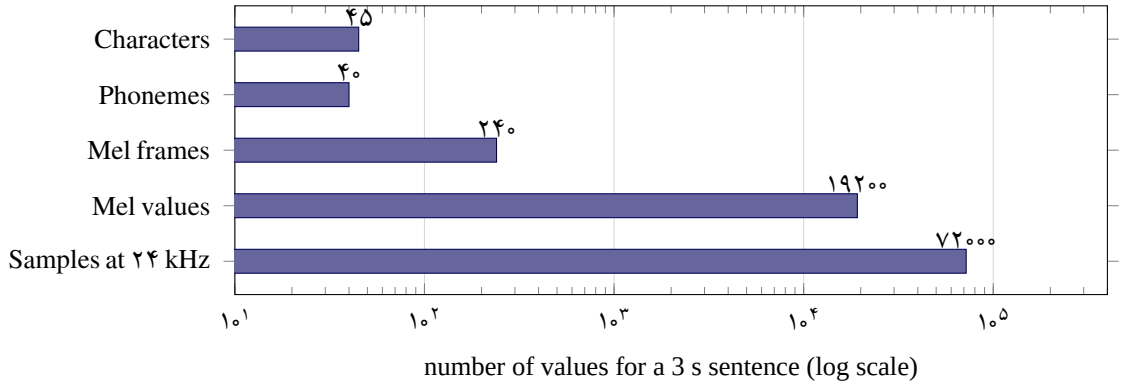
بنابراین مدل تولید گفتار ناچار است بخشی از این اطلاعات را از دادهٔ آموزشی و بافت متن **استنتاج یا تولید** کند. به بیان دیگر، نگاشت متن به گفتار یک‌به‌یک نیست؛ یک متن را می‌توان به شیوه‌های بی‌شماری خواند (نگاشت یک‌به‌چند).

[محتوای افزوده] مثال عددی: شکاف نرخ‌ها برای یک جملهٔ سه‌ثانیه‌ای

جمله‌ای معمولی را در نظر بگیرید که حدود ۳ **ثانیه** طول می‌کشد و ۴۰ واج و حدود ۴۵ نویسه دارد. مقدارهای زیر را می‌توان با رابطهٔ $N = f_s \times T$ (تعداد نمونه = نرخ نمونه‌برداری × مدت) و با نرخ قاب‌بندی طیف‌نگار حساب کرد. فرض می‌کنیم طیف‌نگار مل ۸۰ بعدی با گام (hop) ۳۰۰ نمونه در ۲۴ کیلوهرتز ساخته شده باشد (که با گام ۱۲٫۵ میلی‌ثانیه برابر است).

نمایش	تعداد مقدار در ۳ ثانیه	نرخ بر ثانیه
نویسه‌ها	≈ ۴۵	≈ ۱۵
واج‌ها	۴۰	$\approx ۱۳٫۳$
قاب‌های طیف‌نگار مل	$۷۲۰۰۰/۳۰۰ = ۲۴۰$	۸۰
مقدارهای طیف‌نگار مل	$۲۴۰ \times ۸۰ = ۱۹\,۲۰۰$	۶۴۰۰
نمونه‌های موج (۲۴ کیلوهرتز)	$۲۴۰۰۰ \times ۳ = ۷۲\,۰۰۰$	۲۴ ۰۰۰

هر واج به‌طور میانگین $۷۵ \text{ ms}/۴۰ = ۳$ میلی‌ثانیه طول دارد؛ یعنی حدود ۶ قاب طیف‌نگار و حدود $۷۲۰۰۰/۴۰ = ۱۸۰۰$ نمونهٔ موج. همچنین موج خام ۱۶ بیتی تک‌کاناله در ۲۴ کیلوهرتز حدود $۳۸۴ = ۱۶ \times ۲۴۰۰۰$ کیلوبیت بر ثانیه است؛ ۳ ثانیه یعنی حدود ۱٫۱۵ مگابیت. در سوی دیگر، اگر هر یک از ۴۰ واج را با دست‌بالا $\log_۲ ۴۰ \approx ۵٫۳$ بیت کدگذاری کنیم، به حدود ۲۱۳ بیت می‌رسیم. نسبت این دو ($۵۴۰۰ \approx$ برابر) نشان می‌دهد مدل باید چه حجم عظیمی از «جزئیات» را بسازد.



شکل ۱.۷: تعداد مقدارهای لازم برای نمایش یک جملهٔ سه‌ثانیه‌ای در سطح‌های مختلف؛ محور افقی لگاریتمی است و بین متن و موج چند مرتبهٔ بزرگی فاصله است. (شکل افزوده)

۲.۷ دو رویکرد کلی: خط‌لوله و سرتاسری

برای ساخت یک سامانهٔ TTS دو رویکرد کلی وجود دارد.

رویکرد خط‌لوله‌ای (Pipeline-Based). مسئله به چند بخش کوچک‌تر تقسیم می‌شود. هر ماژول وظیفهٔ مشخصی دارد و خروجی‌اش ورودی ماژول بعدی است. مزیت این ساختار آن است که هر بخش را می‌توان جداگانه بررسی، آموزش، اصلاح یا جایگزین کرد.

رویکرد سرتاسری (End-to-End). هدف این است که یک مدل (یا مجموعه‌ای یکپارچه از لایه‌ها) متن را مستقیماً به گفتار تبدیل کند. در این حالت لزوماً همهٔ مراحل میانی به‌صورت ماژول‌های مستقل و قابل مشاهده وجود ندارند.

نکتهٔ تأکیدی استاد

رویکرد End-to-End **لزوماً بهترین گزینه برای همهٔ کاربردها نیست**. گاهی به‌دلیل محدودیت‌هایی مانند تأخیر پردازش (Latency) یا ویژگی‌های دامنهٔ کاربرد، استفاده از ماژول‌های کلاسیک یا یک خط‌لوله مناسب‌تر است. برای مثال ممکن است در یک کاربرد مشخص مرحلهٔ نرمال‌سازی متن بسیار حساس باشد و بخواهیم آن را مستقل از مدل تولید صوت بسازیم و تنظیم کنیم. در این جلسه تمرکز بر رویکرد خط‌لوله است؛ جزئیات معماری مدل‌ها و یک جلسهٔ جداگانه برای رویکردهای سرتاسری به جلسات بعد موکول شده است.

«سرتاسری» یک طیف است

واژهٔ End-to-End در ادبیات TTS همیشه یک معنا ندارد. برخی مدل‌ها فقط بخش «واج/نویسه به طیف‌نگار» را سرتاسری یاد می‌گیرند و برای ساخت موج هنوز به یک وکودر جدا نیاز دارند (مثلاً Tacotron 2). مدل‌هایی هم مانند VITS متن (یا واج) را در یک مدل یکپارچه به موج می‌رسانند. حتی در این حالت معمولاً یک بخش پیش‌پردازش متن (نرمال‌سازی و G2P) بیرون از مدل باقی می‌ماند. پس انتخاب «خط‌لوله یا سرتاسری» دوگانهٔ مطلق نیست و بیشتر پرسش این است که مرز ماژول‌ها کجا کشیده شود.

[محتوای افزوده] نگاهی گذرا به تاریخچه و مثال‌ها

سامانه‌های کلاسیک TTS (ترکیب پیوندی concatenative/unit selection و ترکیب آماری مبتنی بر HMM) نیز خط‌لوله‌ای بودند. در دورهٔ شبکه‌های عصبی، Tacotron 2 (۲۰۱۷-۲۰۱۸) متن نویسه‌ای را با یک مدل دنباله‌به‌دنباله و توجه (attention) به طیف‌نگار مل تبدیل می‌کرد و یک وکودر WaveNet آن را به موج می‌رساند. FastSpeech (۲۰۱۹) مدل آکوستیکی غیرخودهمبسته و سریع‌تری ارائه داد. HiFi-GAN (۲۰۲۰) یک وکودر مبتنی بر GAN سریع و باکیفیت است و VITS (۲۰۲۱) یک مدل سرتاسری است که از متن/واج مستقیماً موج می‌سازد. جزئیات این مدل‌ها در جلسات بعد می‌آید.

۳.۷ معماری کلی یک سامانهٔ TTS

سامانهٔ TTS را می‌توان به دو بخش اصلی تقسیم کرد.

بخش اول: Front-End یا تحلیل متن (Text Analysis). ورودی هنوز متن است و هدف، آماده‌سازی آن برای تولید گفتار است: به عبارتی تعیین اینکه «چه باید گفته شود» (what to say). خروجی این بخش یک نمایش میانی، یعنی توالی واج‌ها (و در صورت نیاز اطلاعات پروزودی)، است.

بخش دوم: Back-End یا تولید گفتار (Speech/Waveform Synthesis). نمایش واجی به نمایش آکوستیکی و سپس به موج تبدیل می‌شود: تعیین اینکه «چگونه گفته شود» (saying it).

مسیر کلی پردازش چنین است:

$$\text{Text} \rightarrow \text{Text Normalization} \rightarrow \text{Homograph Disambiguation} \rightarrow \text{G2P} \rightarrow \text{Phonemes}$$
$$\rightarrow \text{Acoustic Model} \rightarrow \text{(Mel-)Spectrogram} \rightarrow \text{Vocoder} \rightarrow \text{Waveform}$$

۱.۳.۷ خلاصهٔ نقش ماژول‌ها

۱. **نرمال‌سازی متن** (Text Normalization): تبدیل متن خام به متنی که بتوان آن را درست خواند (گسترش عدد، تاریخ، ساعت، واحد پول و اختصار به صورت کلمه).

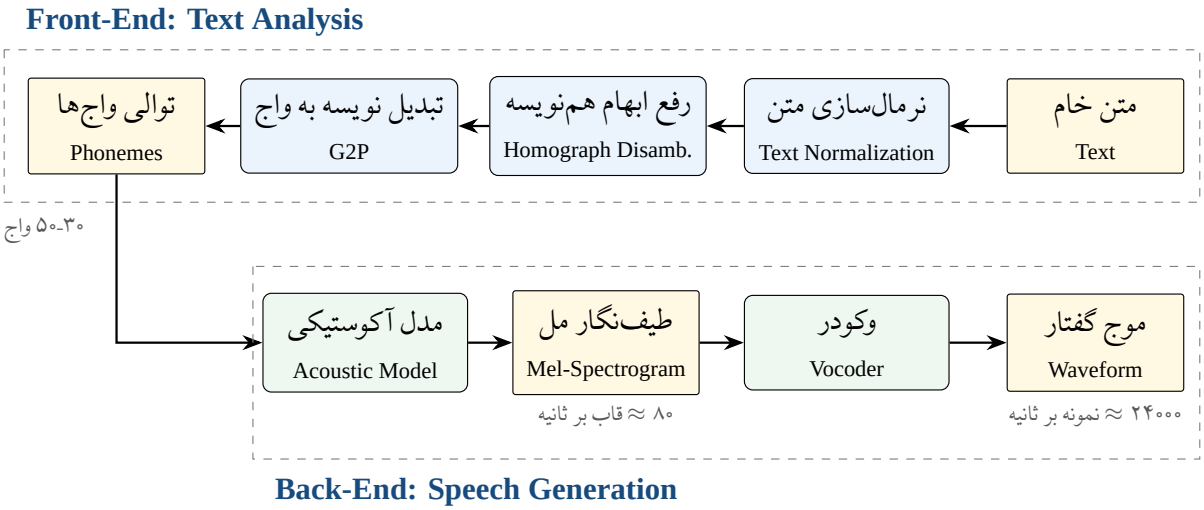
۲. **رفع ابهام هم‌نویسه** (Homograph Disambiguation): تعیین تلفظ درست کلماتی که نوشتار یکسان و تلفظ متفاوت دارند، با توجه به متن اطراف.

۳. **تبدیل نویسه به واج** (Grapheme-to-Phoneme, G2P): تبدیل نمایش نوشتاری به نمایش واجی.

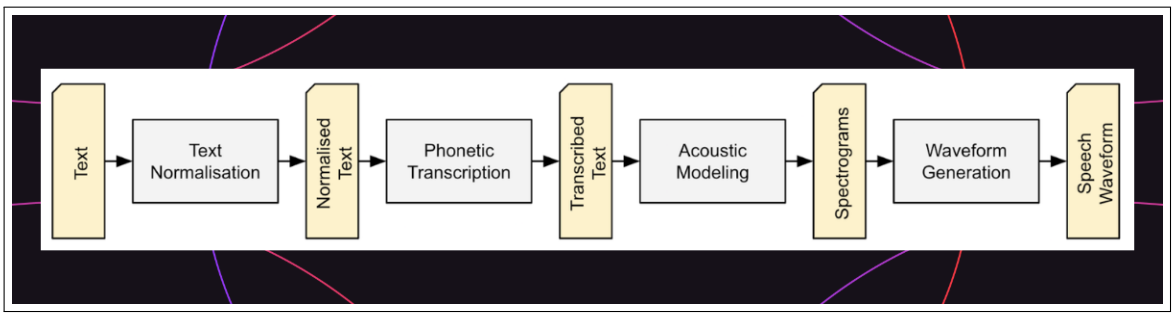
۴. **مدل آکوستیکی** (Acoustic Model): تبدیل توالی واج‌ها به یک نمایش آکوستیکی مانند طیف‌نگار مل.

۵. **وکودر** (Vocoder): تبدیل نمایش آکوستیکی به موج صوتی.

مراحل ۱ تا ۳ بخش Front-End و مراحل ۴ و ۵ بخش Back-End را می‌سازند. بسته به معماری انتخاب‌شده ممکن است ترتیب، تفکیک یا ادغام برخی از این اجزا تفاوت کند.



شکل ۲.۷: نمودار بلوکی خط‌لولهٔ TTS: بخش تحلیل متن (بالا، جهت جریان از راست به چپ) و بخش تولید گفتار (پایین، از چپ به راست). مستطیل‌های زرد نمایش‌های دادهٔ میانی و مستطیل‌های رنگی ماژول‌های پردازشی‌اند. (شکل افزوده)



شکل ۳.۷: خط‌لولهٔ استاندارد TTS در قالب ماژول‌های پردازشی و نمایش‌های میانی: متن، متن نرمال‌شده، متن آوانگاری‌شده، طیف‌نگار و موج گفتار. (برگرفته از تختهٔ کلاس)

۴.۷ مرحلهٔ اول: نرمال‌سازی متن

۱.۴.۷ چرا متن خام مستقیماً خواندنی نیست؟

متن واقعی پر از عدد، تاریخ، ساعت، واحد پول، علامت اختصاری و عبارت‌هایی است که شکل نوشتاری‌شان با شکل گفتاری‌شان فرق دارد. در کلاس جملهٔ نمونه‌ای روی تخته نوشته شد که تقریباً همهٔ این پدیده‌ها را در خود داشت.

در تاریخ [1] ۱۴۰۲/۱۰/۱۵ ساعت [2] ۱۶:۳۰، آن [3] مرد پس از مدت‌ها بیماری در بیمارستان [4] مرد و [5] سرم را از دستش کشیدند. [6] خواهرم گفت «[7] سرم به شدت درد می‌کند». حدود [8] ۲/۵ [9] تن گندم به ارزش [10] ۱۲۵ میلیون و [11] ۵۰۰ هزار [12] تومان با [13] ۳۰٪ تخفیف فروخته شد.

شماره‌نشانه	نوع	شکل نوشتاری	شکل گفتاری (یادداشت استاد)
۱	تاریخ	۱۴۰۲/۱۰/۱۵	پانزدهم دی‌ماه هزار و چهارصد و دو
۲	ساعت	۱۶:۳۰	چهار و نیم (بعدازظهر) یا شانزده و سی دقیقه
۳	هم‌نویسه (اسم)	مرد	mard (انسان مذکر)
۴	هم‌نویسه (فعل)	مرد	mord (فوت کرد)
۵	هم‌نویسه	سرم	sorom (محلول تزریقی)
۶	واژهٔ دارای ضمیر پیوسته	خواهرم	خواهر + ـم (یادداشت حاشیه ناخوانا)
۷	هم‌نویسه	سرم	saram (سرِ من)
۸	عدد اعشاری	۲/۵	دو و نیم
۹	واحد اندازه‌گیری	تن	تن
۱۰-۱۱	عدد	۱۲۵ و ۵۰۰	صد و بیست و پنج میلیون و پانصد هزار
۱۲	واحد پول	تومان	تومان (در گفتار محاوره‌ای: تومن)
۱۳	درصد	٪۳۰	سی درصد

شکل ۴.۷: جملهٔ نمونهٔ روی تخته و نشانه‌گذاری‌های استاد: تاریخ، ساعت، عددها، واحد پول، درصد، و دو هم‌نویسهٔ «مرد» و «سرم» که در جمله دو بار با تلفظ‌های متفاوت آمده‌اند. (بازسازی‌شده از تختهٔ کلاس)

برای خواندن این جمله، سامانه باید بداند که ۱۴۰۲/۱۰/۱۵ یک تاریخ شمسی است و باید به‌شکل «پانزدهم دی‌ماه هزار و چهارصد و دو» خوانده شود؛ ۱۶:۳۰ ساعت است و به‌شکل «شانزده و سی دقیقه» یا «چهار و نیم بعدازظهر» بیان می‌شود (هر دو یک زمان‌اند اما سبک بیانشان فرق دارد و سامانه باید آن را متناسب با کاربرد و سبک گفتار انتخاب کند)؛ ۲/۵ در کنار «تن» یک عدد اعشاری است و «دو و نیم» خوانده می‌شود؛ ٪۳۰ یعنی «سی درصد». همچنین اگر سامانه برای گفتار محاوره‌ای ساخته شده باشد ممکن است «تومان» را «تومن» بخواند؛ این هم به سبک گفتار مطلوب بستگی دارد.

هدف نرمال‌سازی در TTS

متن ورودی باید به شکلی تبدیل شود که سامانه بتواند آن را **درست و طبیعی بخواند**. به‌عبارتی، نرمال‌سازی در TTS یعنی ساختن «شکل گفتاری» (spoken form) از «شکل نوشتاری» (written form).

۲.۴.۷ نرمال‌سازی در TTS با نرمال‌سازی در NLP فرق دارد

استاد تأکید کرد که مفهوم نرمال‌سازی وابسته به هدف است. همیشه باید پرسید: «متن را نسبت به چه هدفی نرمال می‌کنیم؟»

در پردازش متن برای وظایف معمول NLP، نرمال‌ساز (مثلاً در کتابخانهٔ Hazm) معمولاً **کاهنده** (Reductive) است؛ یعنی تنوع نوشتاری را کم می‌کند تا متن برای فهم معنا یکدست شود. کارهای معمول آن:

- تبدیل «ي» عربی به «ی» فارسی و «ك» عربی به «ک» فارسی؛
- اصلاح فاصله و نیم‌فاصله، مثلاً چسباندن پیشوندهای فعلی (تبدیل «می روم» به «می‌روم»)؛
- حذف تکرارهای غیرعادی حروف (مثلاً «سلاااام» به «سلام»)؛
- آماده‌سازی برای نشانه‌گذاری (tokenization) و دیگر پردازش‌ها.

این کارها در کاربردهای زیر اهمیت دارند:

۱. **موتور جست‌وجو و بازیابی اطلاعات**: اگر کاربر «کتاب» را جست‌وجو کند، باید همهٔ شکل‌های نوشتاری آن (با «ک» عربی یا فارسی) یافت شود.

۲. **دسته‌بندی متن و تحلیل احساسات**: کاهش اندازهٔ واژگان تا مدل برای «می روم»، «میروم» و «می‌روم» سه بردار جدا نسازد.

۳. **استخراج موجودیت‌های نامدار (NER) و برچسب‌گذاری اجزای کلام (POS Tagging)**: پیشوندها و پسوندها باید به بن واژه متصل باشند (مثلاً «می» جدا از «روم» نباشد).

اما در TTS هدف دیگری داریم: متن باید **خواندنی** شود. بسیاری از اطلاعاتی که نرمال‌سازِ NLP دور می‌ریزد باید حفظ شوند و حتی اطلاعات تازه‌ای باید به متن اضافه شود تا خواندنش ممکن گردد. برای نمونه حذف **واژه‌های ایست** (Stopword) که در بعضی مراحل NLP مفید است، برای TTS نامناسب است، چون باید همهٔ محتوای جمله خوانده شود. به همین دلیل روی تخته دو نوع نرمال‌ساز مقابل هم قرار گرفتند: «کاهنده» در برابر «گسترش‌دهنده و آواشناسی‌محور» (Expansive & Phonetic).

دو نرمال‌ساز با یک نام

نرمال‌ساز Hazm و نرمال‌ساز لازم برای گفتار هدف‌های متفاوتی دارند: اولی **کاهنده** است و تنوع نوشتار را برای فهم معنا کم می‌کند؛ دومی **گسترش‌دهنده** است و متن را برای خواندن آماده می‌کند (عدد را به کلمه تبدیل می‌کند و اطلاعات تلفظی را روشن می‌کند). این دو را با هم اشتباه نگیرید.

تضاد مطلق نیست

دوگانهٔ «کاهنده/گسترش‌دهنده» تصویری مفید اما کمی ساده‌شده است. یک سامانهٔ TTS هم به یکدست‌سازی املایی نیاز دارد: وقتی تلفظ کلمات را در فرهنگ تلفظ جست‌وجو می‌کنیم، «ي/ی»، «ك/ک» و نیم‌فاصله‌های نادرست جست‌وجو را به‌هم می‌ریزند. تفاوت اصلی این است که TTS علاوه بر آن به «گسترش» نیاز دارد و حق ندارد اطلاعاتی را که روی خواندن اثر می‌گذارند حذف کند؛ مثلاً علائم نگارشی (ویرگول و علامت سؤال) نشانه‌هایی برای مکث و آهنگ‌اند و نباید مثل بعضی پیش‌پردازش‌های NLP حذف شوند.

۳.۴.۷ کلمات غیراستاندارد (NSW)

هستهٔ نرمال‌سازی در TTS، برخورد با **کلمات غیراستاندارد** (Non-Standard Words, NSW) است؛ توکن‌هایی که با نوشتارشان نمی‌توان تلفظشان را از روی قواعد معمول حدس زد. دسته‌های اصلی آن‌ها عبارت‌اند از: اعداد، تاریخ، ساعت، واحد پول، درصد، اختصارات، شماره‌ها و شناسه‌ها، و شکل‌های غیررسمی و عامیانهٔ نوشتار. روی تخته جمله‌ای نوشته شده بود که اصل کار را خلاصه می‌کند: «باید بفهمیم جزو چه دسته‌ای است؛ مثلاً عدد، واحد پول، تاریخ.»

List of Text Normalization Categories

Cardinal	Date
Decimal	Ordinal
Fraction	Time
Currency	Unit (Measure)
Address	Acronym/Initialism
ISBN	Biological Classification
Roman Numeral	Telephone
Sports Score	Mathematical Expression
Symbol	Abbreviations
Chemical Formula	Legal Reference
Vehicle/Product Code	Geographic Coordinates
Version Number	License/Serial Number
Musical Notation	Stock Ticker
Electronic (URL/Email)	

Table 1: List of 27 text normalization categories used for multilingual data construction.

شکل ۵.۷: جدولی از ۲۷ دستهٔ نرمال‌سازی که روی تخته به‌عنوان نمونه نشان داده شد؛ مانند Cardinal، Date، Time، Currency، Telephone، Abbreviations و URL/Email. (برگرفته از تختهٔ کلاس)

۴.۴.۷ خواندن عدد بر اساس نوع آن

یک توالی از ارقام را نمی‌توان با یک قاعدهٔ ثابت به کلمه تبدیل کرد؛ ابتدا باید **نوع و نقش** آن مشخص شود. در انگلیسی، مثلاً ۱۹۷۶ اگر سال باشد دو بخش «نوزده» و «هفتاد و شش» خوانده می‌شود، اما در یک شناسه ممکن است رقم‌به‌رقم یا به‌شکل دیگری خوانده شود. در فارسی هم این مسئله هست:

نوع	نمونه	شکل گفتاری
عدد اصلی	۱۲۵	صد و بیست و پنج
سال	۱۴۰۲	هزار و چهارصد و دو
تاریخ	۱۴۰۲/۱۰/۱۵	پانزدهم دی‌ماه هزار و چهارصد و دو
ساعت	۱۶:۳۰	شانزده و سی دقیقه، یا چهار و نیم بعدازظهر
عدد اعشاری	۲/۵ (در کنار «تن»)	دو و نیم
مبلغ	۱۲۵ میلیون و ۵۰۰ هزار تومان	صد و بیست و پنج میلیون و پانصد هزار تومان
درصد	٪۳۰	سی درصد
شناسه یا شماره تلفن	رشتهٔ ارقام	رقم‌به‌رقم یا گروه‌گروه، مثلاً «صفر نه یک دو ...»

یک نویسه، چند نقش

علامت «/» در جملهٔ نمونه سه نقش دارد: در ۱۴۰۲/۱۰/۱۵ جداکنندهٔ اجزای تاریخ است، در ۲/۵ ممیز اعشاری است (در همین قالب ممکن بود یک تاریخ یا یک کسر باشد) و در متن‌های دیگر ممکن است «یا» باشد. تنها نشانهٔ تفکیک، بافت است: واژهٔ «تن» پس از ۲/۵ قرینهٔ خوانش اعشاری است. ابهام مشابهی در سال (۱۴۰۲ به‌صورت «هزار و چهارصد و دو» و نه «چهارده و صفر دو») و در خوانش‌های دیگر دیده می‌شود.

۵.۴.۷ روش کلاسیک پیاده‌سازی

برای پیاده‌سازی این مرحله، یک الگوی کلاسیک دو بخشی پیشنهاد شد:

۱. **طبقه‌بندی توکن** (Token Classification): مشخص می‌کنیم هر توکن به کدام دسته تعلق دارد (عدد، تاریخ، ساعت، پول و ...).

۲. **مبدل** (Converter): پس از تعیین دسته، مبدل مخصوص آن دسته توکن را به شکل گفتاری تبدیل می‌کند.

Input Token → Token Classification → Category-Specific Converter → Spoken Form

برای طبقه‌بندی می‌توان از عبارت‌های باقاعده (Regular Expression)، قواعد دستی، کتابخانه‌های آماده یا مدل‌های یادگیری ماشین استفاده کرد. در کلاس به کتابخانهٔ num2fawords اشاره شد که عدد را به حروف فارسی درمی‌آورد؛ برای نمونه خروجی تابع)۱۷۰words) برابر است با «یکصد و هفتاد». استاد تأکید کرد که این کتابخانه فقط برای دستهٔ **اعداد** است و برای تاریخ، ساعت یا اختصارها باید مبدل جدا داشت. اگر برای یک دسته کتابخانه یا قاعدهٔ آماده وجود نداشته باشد، می‌توان دادهٔ آموزشی تهیه کرد، یک طبقه‌بند ساخت و خروجی آن را به مبدل همان دسته داد.

```
>>> from num2fawords import HUNDREDS
>>> words(170)
'یکصد و هفتاد'
```

شکل ۶.۷: نمونهٔ استفاده از کتابخانهٔ num2fawords: تبدیل عدد ۱۷۰ به حروف. (برگرفته از تختهٔ کلاس)

[محتوای افزوده] مثال عددی: مبدل اعداد کمتر از هزار

قاعدهٔ مبدل برای عدد $n < ۱۰۰۰$ را می‌توان با سه جدول نوشت: صدگان (صد، دویست، سیصد، چهارصد، پانصد، ششصد، هفتصد، هشتصد، نهصد)، دهگان (بیست، سی، ... ، نود، و دهه‌های ده تا نوزده به‌صورت واژه‌های جدا) و یکان. سپس اجزای ناصفر با «و» به هم وصل می‌شوند.

- ۱۲۵ ← صدگان: «صد»، دهگان: «بیست»، یکان: «پنج» ⇐ «صد و بیست و پنج».
- ۵۰۰ ← «پانصد».
- ۱۴۰۲ ← «هزار» + ۴۰۲ ⇐ «هزار و چهارصد و دو» (و نه «چهارده صد و دو»؛ خوانش دورقمی‌دورقمی مخصوص سال در انگلیسی است).
- ۱۲۵ ۵۰۰ ۰۰۰ ← «صد و بیست و پنج میلیون و پانصد هزار».

آنچه در متن «۱۲۵ میلیون و ۵۰۰ هزار تومان» آمده در واقع مجموع دو گروه است: $۱۲۵ \times ۱۰^۶ + ۵۰۰ \times ۱۰^۳ =$ ۱۲۵ ۵۰۰ ۰۰۰. مبدل باید «میلیون» و «هزار» را به‌عنوان واحدهای مقیاس بشناسد و ضرایبشان را جداگانه تبدیل کند.

[محتوای افزوده] پیاده‌سازی مبتنی بر WFST

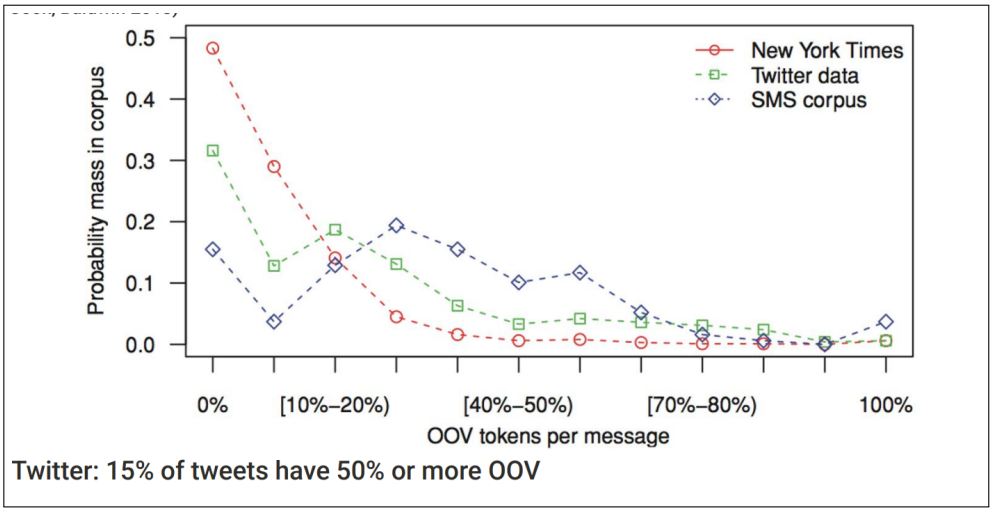
در سامانه‌های صنعتی، قاعده‌های نرمال‌سازی اغلب با **مبدل‌های متناهی وزن‌دار** (Weighted Finite-State Transducer, WFST) نوشته می‌شوند. هر دستهٔ توکن یک دستور زبان (گرامر) مبدل دارد؛ مثلاً یک مبدل رقم را به واژه تبدیل می‌کند و مبدل دیگری قالب تاریخ را می‌شناسد. این مبدل‌ها را می‌توان ترکیب (composition) کرد و وزن‌ها (هزینه‌ها) برای انتخاب میان چند خوانش ممکن (مثلاً «شانزده و سی» در برابر «چهار و نیم») به کار می‌روند. سامانه‌هایی مانند Kestrel/Sparrowhawk از این رویکرد استفاده می‌کنند. مزیت: قاعده‌ها قابل‌بازرسی و کنترل‌اند و تأخیر کم است؛ عیب: نوشتن و نگهداری قاعده‌ها برای زبان و دامنهٔ جدید پرزحمت است و پوشش بافت‌های پیچیده محدود می‌ماند.

۶.۴.۷ اهمیت دامنهٔ کاربرد

فراوانی کلمات غیراستاندارد در متن‌های مختلف یکسان نیست. در کلاس سه نوع داده با هم مقایسه شد: متن خبری رسمی (New York Times)، متن شبکه‌های اجتماعی (Twitter) و پیام‌های کوتاه (SMS). نمودار روی تخته، توزیع نسبت توکن‌های خارج از واژگان (OOV) در هر پیام را نشان می‌دهد.

نتیجه‌ای که روی تخته نوشته شد: هرچه به ارتباطات غیررسمی (توییتر و SMS) نزدیک‌تر شویم، NSWها (اختصارها، املای غیررسمی و اصطلاحات عامیانه) شایع‌تر می‌شوند. هیچ‌یک از این پیکره‌ها ۱۰۰ درصد غیراستاندارد نیست؛ در متن خبری احتمال نبودن OOV بسیار بالاست، در حالی که در توییتر با احتمال خوبی نیمی از توکن‌ها غیراستانداردند.

اهمیت این مشاهده برای طراحی سامانه: اگر شکل صحیح خواندن یک عبارت تشخیص داده نشود، گفتار تولیدشده غیرطبیعی یا حتی غلط می‌شود (مثلاً خواندن یک تاریخ مثل چند عدد جدا). این یکی از مزیت‌های خط‌لوله است: **اهمیت و پیچیدگی هر ماژول به دامنه وابسته است.** اگر سامانه برای پیام‌های کوتاه یا شبکه‌های اجتماعی طراحی می‌شود باید روی نرمال‌سازی بیشتر سرمایه‌گذاری کرد؛ اگر ورودی عمدتاً متن رسمی و استاندارد است، این مرحله را می‌توان ساده‌تر گرفت.



شکل ۷.۷: احتمال دیدن پیامی با نسبت معین از توکن‌های OOV در سه پیکره. در متن خبری بیشتر پیام‌ها (حدود ۴۸ درصد) هیچ توکن OOV ندارند؛ در توییتر حدود ۳۱ درصد و در SMS فقط حدود ۱۵ درصد. زیرنویس تصویر: «در توییتر ۱۵ درصد توییت‌ها ۵۰ درصد یا بیشتر OOV دارند.» (مقدارهای تقریبی خوانده‌شده از نمودار) (برگرفته از تختهٔ کلاس)

OOV و NSW یکی نیستند

نمودار شمارش توکن‌های «خارج از واژگان» (OOV) را نشان می‌دهد، در حالی که NSW توکنی است که تلفظش از نوشتارش مستقیماً به دست نمی‌آید. این دو هم‌پوشانی زیادی دارند (عددها، اختصارها، املای عامیانه معمولاً در فرهنگ واژگان نیستند) اما یکسان نیستند: مثلاً اشتباه تایپی هم OOV است ولی لزوماً NSW نیست. در کلاس OOV به‌عنوان شاخصی برای فراوانی NSW به کار رفت و برای نتیجهٔ کلی همین کافی است.

۵.۷ مرحلهٔ دوم: رفع ابهام هم‌نویسه‌ها

پس از نرمال‌سازی، مسئلهٔ مهم دیگری باقی است: برخی کلمات نوشتار یکسان اما تلفظ متفاوت دارند. این کلمات **هم‌نویسه** (Homograph) نام دارند. (Grapheme به نویسه، یعنی واحد نوشتاری، اشاره دارد؛ پس هم‌نویسه یعنی «نویسه‌های یکسان».)

هم‌نویسه (Homograph)

دو یا چند واژه که املای (نویسهٔ) یکسان دارند ولی تلفظشان فرق می‌کند، و معمولاً معنی‌شان نیز فرق دارد. در TTS هدف از **رفع ابهام هم‌نویسه** (Homograph Disambiguation) انتخاب تلفظ درست با توجه به بافت جمله است.

۱.۵.۷ نمونه‌های فارسی

ریشهٔ بسیاری از هم‌نویسه‌های فارسی این است که مصوت‌های کوتاه (a، e، o) در نوشتار معمولی نشان داده نمی‌شوند.

نوشتار	تلفظ‌های ممکن (IPA)	معنی
مرد	[mord] / [mærd]	انسان مذکر (اسم) / فوت کرد (فعل)
کرم	[kerem] / [kerm]	کرم خاکی / کرم مرطوب‌کننده؛ همچنین [kæræm] (بخشش)
سرم	[særæm] / [serom]	محلول پزشکی / «سرِ من»

در جملهٔ نمونهٔ روی تخته، «مرد» در یک جمله دو بار با دو تلفظ آمده بود («آن مَرد ... در بیمارستان مُرد») و «سرم» نیز دو بار: «سِرُم را از دستش کشیدند» و «سَرَم به شدت درد می‌کند». خواننده با نقش دستوری و معنی جمله به‌سادگی تلفظ را درمی‌یابد؛ سامانه باید همین توانایی را به دست آورد.

۲.۵.۷ دو راه برای رفع ابهام

راه اول: اطلاعات نحوی (Syntactic Information). گاهی نقش دستوری واژه تلفظ درست را مشخص می‌کند. ابزار این کار **برچسب‌گذاری اجزای کلام** (Part-of-Speech Tagging) یا POS Tagging است که برای هر کلمه نقش اسم، فعل، صفت، قید، ضمیر و ... را تعیین می‌کند. در تخته نمونه‌ای با Hazm دیده شد: برای جملهٔ «ما بسیار کتاب می‌خوانیم» برچسب‌ها به‌ترتیب ضمیر (PRO)، قید (ADV)، اسم (N) و فعل (V) است.

```
>>> tagger = POSTagger(model='resources/pos_tagger.model')
>>> tagger.tag(word_tokenize('ما بسیار کتاب می‌خوانیم'))
[('ما', 'PRO'), ('بسیار', 'ADV'), ('کتاب', 'N'), ('می‌خوانیم', 'V')]
```

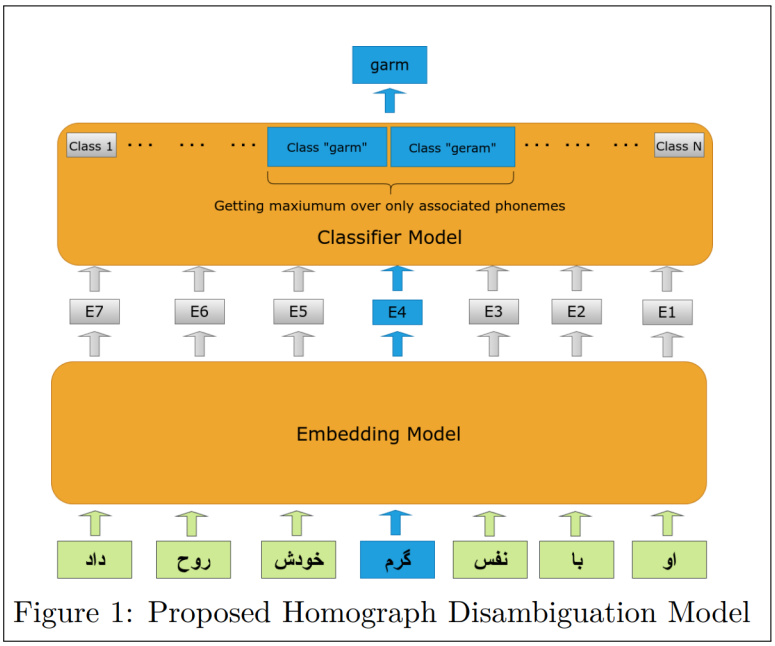
شکل ۸.۷: برچسب‌گذاری اجزای کلام با Hazm: ما (ضمیر)، بسیار (قید)، کتاب (اسم)، می‌خوانیم (فعل). (برگرفته از تختهٔ کلاس)

بنابراین در جملهٔ «آن مَرد رفت» برچسب‌گذار «مرد» را اسم می‌شناسد و در «او مُرد» فعل. این تفاوت نحوی تلفظ را روشن می‌کند.

راه دوم: بافت و معنا (Context). اگر دو واژه نقش دستوری یکسان داشته باشند (مثلاً «کِرم» خاکی و «کِرِم» مرطوب‌کننده هر دو اسم‌اند)، برچسب‌گذاری کمکی نمی‌کند و باید معنای جمله، یعنی کلمات پیش و پس و مفهوم کلی، به کار گرفته شود. یک راه یادگیری ماشینی، استفاده از **نمایش بافتی** (Contextual Embedding) است: بردار هر کلمه با توجه به جملهٔ اطراف ساخته می‌شود، پس یک کلمه در دو جملهٔ متفاوت می‌تواند دو بردار متفاوت داشته باشد. (جزئیات این نمایش‌ها در جلسات بعد می‌آید.)

۳.۵.۷ مدلی برای رفع ابهام هم‌نویسه

روی تخته یک مدل نمونه برای رفع ابهام هم‌نویسه نشان داده شد. جملهٔ ورودی («او با نفس گرم خودش روح داد») کلمه به کلمه از یک مدل Embedding می‌گذرد؛ نمایش کلمهٔ هدف («گرم»، با بردار E4) به یک طبقه‌بند داده می‌شود و طبقه‌بند فقط میان تلفظ‌های **مرتبط با همان کلمه** (در شکل: garm و geram) بیشینه می‌گیرد.



شکل ۹.۷: مدل نمونهٔ رفع ابهام هم‌نویسه: مدل Embedding بردار بافتی هر واژه را می‌سازد و طبقه‌بند، تنها میان تلفظ‌های نامزد کلمهٔ هدف («گَرم» یا «گِرِم») بیشینه می‌گیرد. (برگرفته از تختهٔ کلاس)

یک طبقه‌بند مشترک در برابر طبقه‌بند جدا برای هر کلمه. روی تخته توضیح داده شده بود که چرا یک طبقه‌بند سراسری (Global Classifier) برای همهٔ هم‌نویسه‌ها بهتر از یک طبقه‌بند جدا برای هر کلمه است. خلاصه:

- هم‌نویسه‌ها در قواعد نحوی، ساختاری و معنایی زبان مشترک‌اند؛ مثلاً: «اگر قبل از کلمه حرف تعریف، ضمیر ملکی یا صفت آمد، یا کلمه در جایگاه فاعل/مفعول نشست، این کلمه اسم است؛ پس نامزدی را فعال کن که برچسب اسمی دارد.»
- اگر برای هر کلمه یک طبقه‌بند جدا بود، روی کلمات کم‌تکرار بیش‌برازش (Overfit) رخ می‌داد یا اصلاً چیزی یاد نمی‌گرفت.
- با وزن‌های مشترک (Shared Weights)، مدل توانایی تشخیص فاعل، مفعول، حرف اضافه و ساختار زبان را از کلمات پرتکرار یاد می‌گیرد و همان دانش را مستقیماً روی کلمات کم‌تکرار به کار می‌برد؛ این همان **یادگیری انتقالی میان‌کلمه‌ای** (Cross-word Transfer Learning) است.

[محتوای افزوده] «بیشینه گرفتن فقط روی تلفظ‌های مرتبط» یعنی چه؟

فرض کنید طبقه‌بند سراسری N کلاس (تلفظ) دارد و برای کلمهٔ هدف w تنها زیرمجموعهٔ $C(w)$ از آن‌ها مجاز

است. احتمال هر کلاس بر پایهٔ نمرهٔ خام (logit) z_c چنین ساخته می‌شود:

$$p(c \mid w, \text{بافت}) = \frac{e^{z_c}}{\sum_{c' \in C(w)} e^{z_{c'}}}, \qquad c \in C(w),$$

و تلفظ نهایی $\hat{c} = \arg\max_{c \in C(w)} p(c \mid \cdot)$ است. مثلاً اگر $C(\text{گرم}) = \{\text{garm}, \text{geram}\}$ و $z_{\text{garm}} = ۲$ و $z_{\text{geram}} = ۰$، آنگاه $p(\text{garm}) = e^{۲}/(e^{۲} + e^{۰}) \approx ۰٫۸۸$ و تلفظ انتخابی «garm» است. کلاس‌های نامربوط (مثلاً تلفظ‌های کلمات دیگر) هرگز انتخاب نمی‌شوند.

پرسش روی تخته: «اینجا Argmax یا تصادفی؟»

در نمودار مدل، استاد پرسید خروجی نهایی با argmax انتخاب شود یا به‌صورت تصادفی. در رفع ابهام هم‌نویسه هدف یافتن تلفظ **درست و قطعی** است، پس انتخاب معمول argmax روی نامزدهای مجاز است؛ نمونه‌برداری تصادفی بیشتر برای تنوع در خروجی‌های تولیدی (مثلاً پروزودی) مطرح می‌شود.

۴.۵.۷ ارتباط با WSD

این مسئله به **رفع ابهام معنایی واژه** (Word Sense Disambiguation, WSD) نزدیک است. در WSD می‌خواهیم معنای درست واژه در جمله را تعیین کنیم؛ مثلاً «شیر» می‌تواند جانور، نوشیدنی یا شیر آب باشد. رفع ابهام هم‌نویسه نیز از بافت و معنا استفاده می‌کند، اما هدفش مشخص‌تر است: تعیین **تلفظ** درست.

هر ابهام معنایی ابهام تلفظی نیست

هر سه معنای «شیر» در فارسی [ʃir] تلفظ می‌شوند. پس «شیر» یک ابهام معنایی (WSD) است ولی برای TTS هم‌نویسه محسوب نمی‌شود: تلفظ یکسان است و ابهام معنایی تأثیری در تولید گفتار ندارد (واژه‌هایی که املا و تلفظ یکسان و معنی متفاوت دارند «هم‌آوا-هم‌نویسه» یا homonym هستند). بنابراین رفع ابهام هم‌نویسه فقط به آن بخشی از WSD نیاز دارد که به تفاوت تلفظ می‌انجامد. اطلاعات معنایی ابزاری است برای رسیدن به تلفظ صحیح.

۶.۷ تبدیل نویسه به واج (G2P)

پس از نرمال‌سازی و رفع ابهام، باید متن را به نمایشی تبدیل کنیم که برای تولید صوت مناسب باشد. تا اینجا ورودی ما توالی نویسه‌ها (Grapheme) بود؛ برای تولید گفتار به **واج** (Phoneme) نیاز داریم. این تبدیل را **نویسه‌به‌واج** (Grapheme-to-Phoneme, G2P) می‌نامند: نگاشت نویسه‌های نرمال‌شده به واج‌ها.

۱.۶.۷ نویسه و واج

نویسه و واج

نویسه (Grapheme): واحد تمایزدهندهٔ نظام نوشتاری یک زبان، مانند حروف الفبا («س»، «ل»، a، b).
واج (Phoneme): کوچک‌ترین واحد صوتی تمایزدهنده در نظام آوایی زبان؛ صداهایی که با الفبای آوانگاری مانند IPA یا ARPAbet نوشته می‌شوند.

نویسه «معنادار» نیست

روی تخته نویسه «کوچک‌ترین واحد معنادار خط» توصیف شده بود. دقیق‌تر آن است که بگوییم نویسه کوچک‌ترین واحد **متمایزکننده**نظام نوشتاری است؛ «معنادار بودن» ویژگی **تکواژ** (Morpheme) است، نه نویسه. حرف «س» به‌تنهایی معنایی ندارد؛ فقط با حرف‌های دیگر واژه‌ای را از واژهٔ دیگر جدا می‌کند.

۲.۶.۷ آیا نگاشت نویسه به واج یک‌به‌یک است؟

نه. در بعضی زبان‌ها رابطهٔ نوشتار و تلفظ منظم‌تر است و در بعضی استثنا بیشتر. انگلیسی هم نگاشت یک‌به‌یک ندارد (مثلاً tion که «ʃən» خوانده می‌شود). در فارسی هم نیاز به G2P روشن است:

- مصوت‌های کوتاه در نوشتار معمولی نمایش داده نمی‌شوند، اما هنگام تلفظ وجود دارند و باید در نمایش واجی بیایند؛ استاد روی تخته «کتاب» را به‌صورت ketab و «شب» را به‌صورت ʃab نوشت.
- پدیده‌هایی مانند تشدید (که واج را تکرار می‌کند) و سکون و نیز استثناهای املایی که نوشتار با تلفظ تطابق ندارد باید در نظر گرفته شوند.
- بعضی نویسه‌ها چند تلفظ دارند (مثلاً «و» می‌تواند /v/، /u/، /o/ یا /ow/ باشد) و بعضی واج‌ها چند نویسه /s/) با «س»، «ص»، «ث»؛ /z/ با «ز»، «ذ»، «ض»، «ظ»).

۳.۶.۷ پیش‌نیازهای طراحی یک سامانهٔ G2P

روی تخته سه پرسش اساسی طرح شده بود:

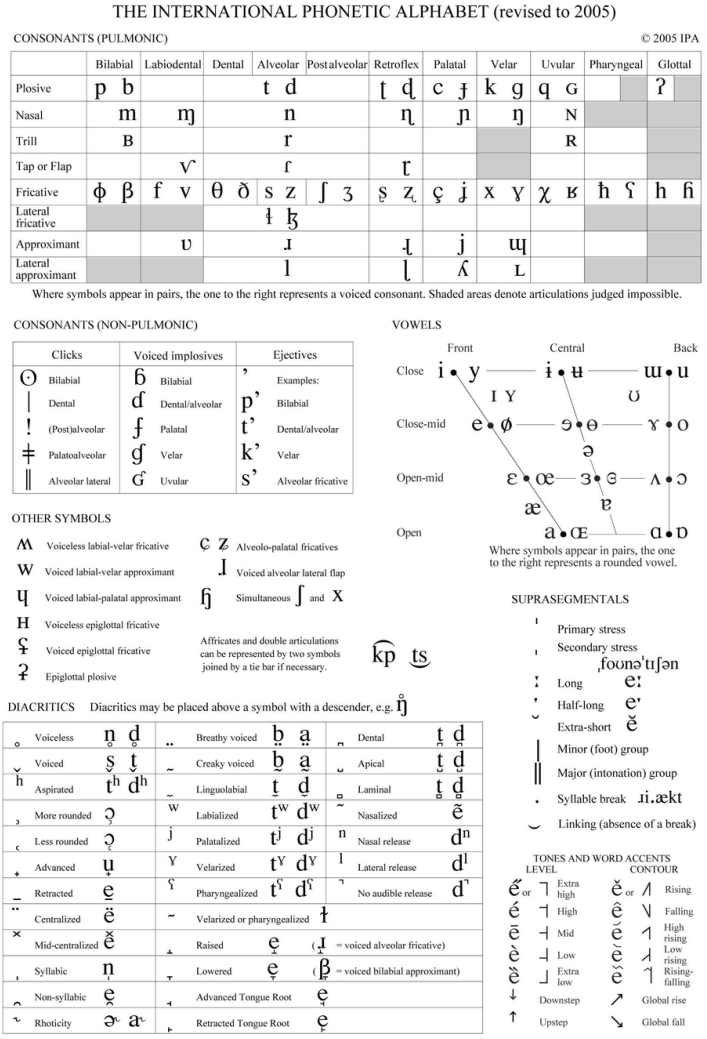
۱. **با چه نمادهایی تلفظ را نشان دهیم؟** انتخاب **الفبای آوانگاری** (Phonetic Alphabet)؛ مثلاً IPA.

۲. **برای هر واژه چه تلفظی ثبت شده است؟** انتخاب **فرهنگ تلفظ** (Pronunciation Dictionary)؛ منبعی که نوشتار را به تلفظ نگاشت می‌کند و هم برای یادگیری و هم برای سنجش خروجی مدل به کار می‌رود.

۳. **چگونه از روی نوشتار تلفظ را پیش‌بینی کنیم؟** انتخاب **مدل G2P**؛ مثلاً مدل‌های دنباله‌به‌دنبالهٔ رمزگذار-رمزگشا (Encoder–Decoder) که توالی نویسه‌ها را می‌گیرند و توالی واج‌ها را تولید می‌کنند. معماری این مدل‌ها بعداً بررسی می‌شود.

۴.۶.۷ الفبای آوایی بین‌المللی (IPA)

IPA (International Phonetic Alphabet) بر این اصل بنا شده که برای هر صدای متمایز گفتاری یک نماد جدا وجود داشته باشد («یک صدا، یک نماد»؛ One sound, one symbol). جدول IPA نمادها را بر پایهٔ همان ویژگی‌های تولیدی‌ای که در جلسات پیشین دیدیم سازمان می‌دهد: ردیف‌های جدول شیوهٔ تولید (انسدادی، خیشومی، سایشی، ...) و ستون‌هایش محل تولید (دولبی، دندانی، لثوی، نرم‌کامی، ...) است. بخش مصوت‌ها نیز بر پایهٔ ارتفاع و پیشین/پسین‌بودن زبان چیده شده، که همان فضای مصوت و فرمنت‌های F1 و F2 است. البته همهٔ خانه‌های جدول در فارسی وجود ندارد. همچنین هم‌تولیدی باعث می‌شود تولید واقعی یک آوا از آواهای مجاورش اثر بپذیرد، پس نمایش واجی توصیف دقیق همهٔ جزئیات آوایی نیست.



شکل ۱۰.۷: جدول الفبای آوایی بین‌المللی (IPA، بازبینی‌شده در ۲۰۰۵) که در کلاس نمایش داده شد.

نوشتار	نمایش واجی (IPA)	نکته
کتاب	ketab	مصوت‌های کوتاه در نوشتار نیامده‌اند
شب	ʃab	«ش» با نماد ʃ نمایش داده می‌شود

جدول ۱.۷: دو نمونهٔ نگاشت نوشتار به واج که استاد در حاشیهٔ جدول IPA نوشت. (بازسازی‌شده از تختهٔ کلاس)

۵.۶.۷ ابزارها و منابع

- phonemizer: بستهٔ پایتونی که متن را به واج‌های IPA تبدیل می‌کند (برای نمونه خروجی عبارت hello world برابر است با həloʊ wɜːld).
- KaamelDict: فرهنگ تلفظ فارسی (Persian G2P Dictionary) روی Hugging Face که هر ورودی آن یک نویسه‌رشته و توالی واجی‌اش است.
- Persian Phonetic Corpus: پیکره‌ای که متن فارسی را در سطح واژه و سطح جمله با IPA آوانگاری کرده است.

```
$ echo "hello world" | phonemize
həloʊ wɜːld
```

شکل ۱۱.۷: ابزار phonemizer: تبدیل متن انگلیسی به واج‌های IPA با یک فرمان. (برگرفته از تختهٔ کلاس)

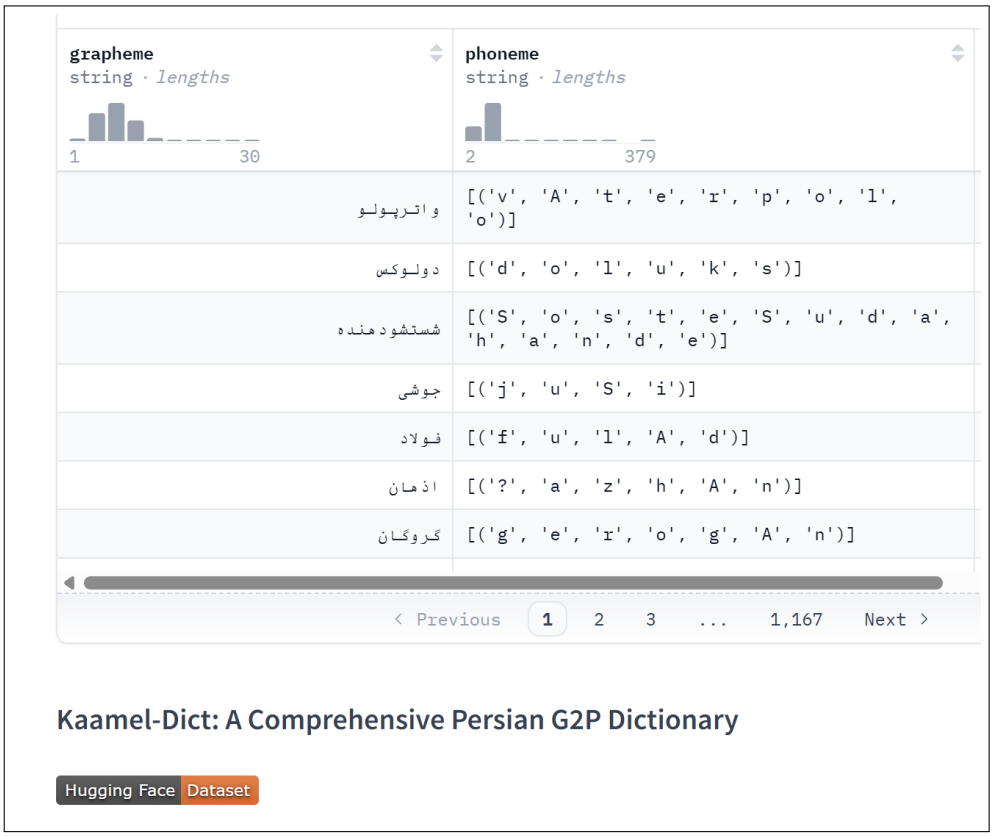
۶.۶.۷ طرح عملی پیشنهادی: چه موقع از کدام روش استفاده کنیم؟

روی تخته یک نمودار تصمیم برای کل بخش نویسه‌به‌واج رسم شده بود. کلمهٔ ورودی ابتدا از جهت OOV بودن بررسی می‌شود:

- **اگر در فرهنگ تلفظ نباشد (OOV)**: از یک مدل رمزگذار-رمزگشا که در سطح بایت کار می‌کند (ByT5) استفاده می‌شود. این مدل بر روی تلفظ کلمات فرهنگ آموزش می‌بیند و نوشتار را در سطح بایت‌های UTF-8، یعنی کاراکتر به کاراکتر، می‌خواند؛ پس از قید «یک کلمه» آزاد می‌شود. وابستگی‌اش به واژه شکسته می‌شود و توان تعمیم به کلمات دیده‌نشده پیدا می‌کند: انتظار داریم قواعد پنهان آوایی زبان را یاد بگیرد (مثلاً در انگلیسی tion را «ʃən» بخواند، حتی اگر بخشی از واژه OOV باشد).
- **اگر در فرهنگ باشد**: بررسی می‌شود که هم‌نویسه است یا نه؛ اگر هست، طبقه‌بند سراسری رفع ابهام تلفظ درست را برمی‌گزیند. اگر نیست، تلفظ ثبت‌شده در فرهنگ (یا قواعد دستی/کتابخانه‌های آماده) به کار می‌رود.

[محتوای افزوده] چرا مدل در سطح بایت؟

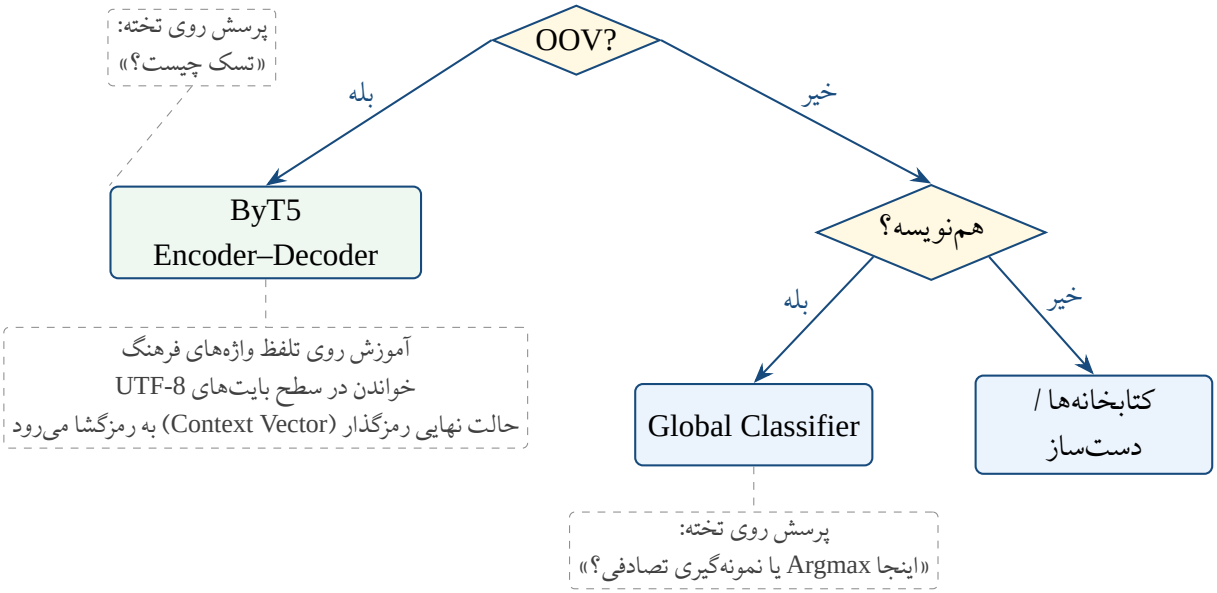
هر حرف فارسی در UTF-8 معمولاً ۲ بایت است و هر حرف لاتین ۱ بایت. مدلی که بایت‌ها را می‌خواند واژگان بسیار کوچکی (کمتر از ۳۰۰ نماد) دارد و هرگز با «کلمهٔ ناشناخته» روبه‌رو نمی‌شود؛ چون در این سطح همهٔ رشته‌ها قابل نمایش‌اند. این برخلاف مدل‌های سطح واژه است که برای هر واژهٔ نادیده فقط یک نشانهٔ «ناشناخته» دارند.



شکل ۱۲.۷: نمونه‌ای از فرهنگ KaamelDict: هر سطر یک واژهٔ فارسی (نویسه) و فهرست واج‌های متناظرش را دارد؛ این فرهنگ نمادهای ASCII‌ـمحور برای واج‌ها به کار می‌برد (برای مثال S به‌جای ʃ و A برای مصوت بلند /ɑː/، بر پایهٔ ورودی‌های نمایش‌داده‌شده). (برگرفته از تختهٔ کلاس)

Persian Phonetic Corpus – Sentence Level Annotation		
ID	PERSIAN	IPA
00001	اغلب ما فکر می‌کنیم که عصر روبات‌ها موضوع داستان‌های علمی-تخیلی است و بحث اخلاق روباتی موضوعی مربوط به آینده دور.	æɢlæb e mɑː fekr miːkoniːm ke æsr e robɑːthɑː mowzuːʔ e dɑːstɑnhɑː je elmiː tæχæjjoliː æst væ bæhs e æχlɑːɢ e robɑːtiː mowzuːʔiː mærbuːt be ɑːjænde je duːr

شکل ۱۳.۷: پیکرهٔ آوانگاری‌شدهٔ فارسی در سطح جمله؛ تلفظ پیوستهٔ یک جملهٔ کامل با IPA. (برگرفته از تختهٔ کلاس)



شکل ۱۴.۷: نمودار تصمیم برای بخش تلفظ: کلمهٔ OOV به مدل ByT5 (رمزگذار-رمزگشا) می‌رود؛ کلمهٔ هم‌نویسه به طبقه‌بند سراسری؛ در غیر این صورت از کتابخانه/فرهنگ دست‌ساز استفاده می‌شود. دو پرسش مطرح‌شده روی تخته نیز با کادر خط‌چین نشان داده شده است. (بازسازی‌شده از تختهٔ کلاس)

مدل ByT5 (۲۰۲۱) نسخهٔ بایتی T5 است. به همین دلیل برای G2P روی کلمات OOV گزینهٔ مناسبی است.

پایان بخش تحلیل متن

در پایان G2P خروجی ما یک **توالی واجی** است. در این نقطه بخش Text Analysis (Front-End) پایان می‌یابد و وارد مرحلهٔ تولید صوت (Back-End) می‌شویم.

۷.۷ مرحلهٔ دوم سامانه: تولید گفتار از روی واج‌ها

ورودی این بخش مجموعه‌ای از واج‌هاست و خروجی‌اش موج گفتار. سه چالش اصلی پیش رو است.

۱.۷.۷ چالش اول: اطلاعات پروزودی

متن لحن و آهنگ گفتار را به‌طور کامل مشخص نمی‌کند. در جلسهٔ گذشته دیدیم که پروزودی لایهٔ مهمی از گفتار است. مثلاً جملهٔ «سلام» می‌تواند عادی، پرسشی، همراه با تعجب یا با تأکید و احساس خاص گفته شود؛ کلمات یکسان‌اند اما خروجی صوتی متفاوت است. بخشی از این اطلاعات را می‌توان از نشانه‌های نگارشی (مثلاً علامت سؤال) یا بافت جمله به دست آورد، اما همیشه کافی نیست. بنابراین مدل باید بخشی از پروزودی را استنتاج کند یا امکان دریافت آن را به‌صورت کنترل‌های جدا داشته باشد (نوع صدا، سبک، حالت بیان). هدف آن است که صدا طبیعی‌تر شود و حالت رباتی نداشته باشد.

۲.۷.۷ چالش دوم: اختلاف نرخ و ابعاد نمایش‌ها

فرض کنید خروجی G2P برای یک جمله ۳۰ واج باشد و بخواهیم یک موج سه‌ثانیه‌ای با نرخ نمونه‌برداری ۲۴ کیلوهرتز بسازیم. تعداد نمونه‌های خروجی:

$$N = f_s \times T = ۲۴۰۰۰ \times ۳ = ۷۲\,۰۰۰.$$

یعنی «۳۰ واج ورودی ← ۷۲ ۰۰۰ نمونهٔ صوتی خروجی» (روی تخته: جملهٔ معمولی ۳۰ تا ۵۰ فونیم دارد). این اختلاف نشان می‌دهد که تولید گفتار نیازمند افزایش شدید وضوح زمانی است. در کلاس به این مسئله «Upsampling» گفته شد. اما مسئله فقط زیادکردن تعداد نمونه نیست؛ مدل باید مقدار هر نمونه را هم به‌گونه‌ای تعیین کند که گفتار طبیعی و قابل فهم شود.

نرخ ۲۴ کیلوهرتز و واژهٔ «Upsampling»

(الف) نرخ نمونه‌برداری «استاندارد» واحدی برای گفتار وجود ندارد: تلفن ۸ کیلوهرتز، تشخیص گفتار معمولاً ۱۶ کیلوهرتز، و در پژوهش‌های TTS رایج‌ترین نرخ‌ها ۲۲٫۰۵ و ۲۴ کیلوهرتز (و در محصولات تجاری تا ۴۴٫۱ یا ۴۸ کیلوهرتز) است. عدد ۲۴ کیلوهرتز مثال معقولی است؛ Tacotron 2 روی ۲۴ کیلوهرتز کار می‌کند و HiFi-GAN و VITS روی دادهٔ ۲۲٫۰۵ کیلوهرتزی.

(ب) «Upsampling» در این معنا یک اصطلاح تقریبی است: در عمل افزایش طول در دو جا رخ می‌دهد؛ ابتدا گسترش **واج به قاب** (چند قاب برای هر واج، با مدل‌سازی مدت) و سپس افزایش **قاب به نمونه** (هر قاب مل به‌اندازهٔ گام، یعنی چند صد نمونه، گسترش می‌یابد؛ این بخش upsampling به معنای دقیق پردازش سیگنال با لایه‌های کانولوشن تراگذار است).

۳.۷.۷ چالش سوم: تطابق زمانی (Temporal Alignment)

فرض کنید ۳۰ واج داریم. باید مشخص کنیم:

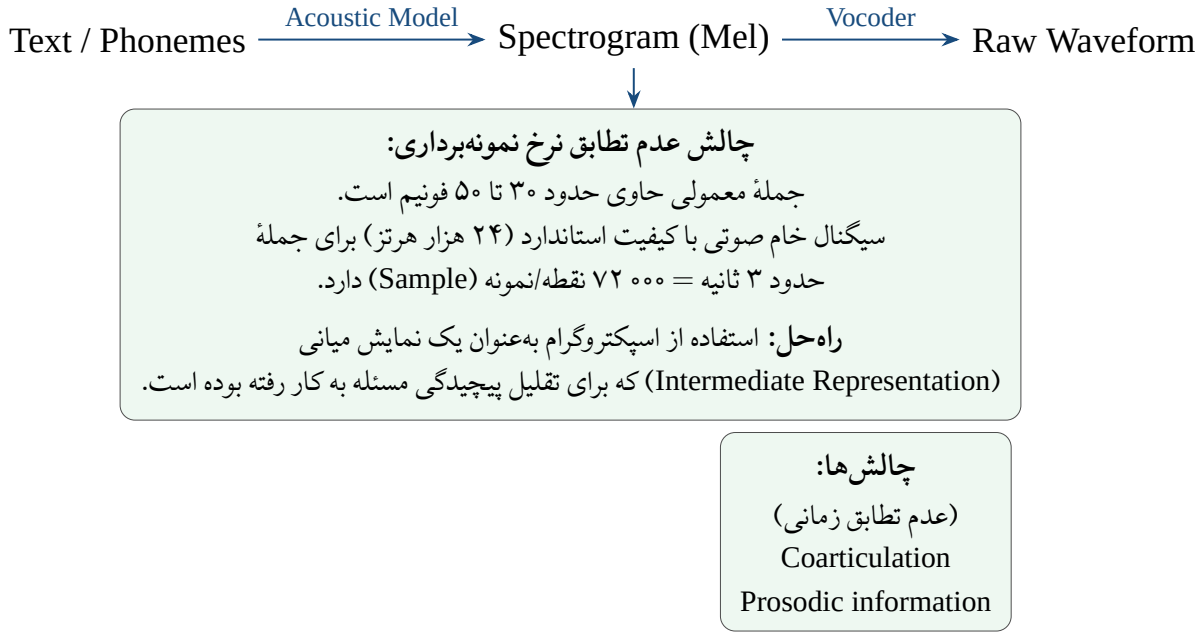
- هر واج چه زمانی شروع شود و چه مدت ادامه یابد؛
- مرز دو واج کجاست؛
- کدام واج‌ها بر یکدیگر اثر می‌گذارند (هم‌تولیدی).

این موضوع به **مدل‌سازی مدت** (Duration Modeling) و **هم‌ترازی زمانی** (Temporal Alignment) مربوط است. همهٔ واج‌ها مدت یکسان ندارند (برخی کوتاه‌تر و برخی کشیده‌ترند) و به‌دلیل هم‌تولیدی مرز آواها هرگز کاملاً مجزا و مستقل نیست. پس سامانهٔ تولید گفتار علاوه بر ترتیب واج‌ها باید زمان‌بندی مناسب آن‌ها را نیز یاد بگیرد.

۸.۷ مدل آکوستیکی

برای ساده‌کردن مسئله، تولید گفتار به دو مرحله تقسیم می‌شود:

$$\text{Phonemes} \xrightarrow{\text{Acoustic Model}} \text{Mel-Spectrogram} \xrightarrow{\text{Vocoder}} \text{Waveform}$$



شکل ۱۵.۷: چالش‌های بخش Back-End: مسیر «واج ← طیف‌نگار مل ← موج»، چالش اختلاف نرخ نمونه‌برداری و راه‌حل «نمایش میانی»، و فهرست چالش‌ها: عدم تطابق زمانی، هم‌تولیدی و اطلاعات پروزودی. (بازسازی‌شده از تختهٔ کلاس)

مدل آکوستیکی (Acoustic Model) از روی واج‌ها یک نمایش آکوستیکی (مانند طیف‌نگار مل) می‌سازد. در این مرحله باید زمان‌بندی، ویژگی‌های آکوستیکی و در صورت لزوم ویژگی‌های پروزودی در تولید نمایش خروجی لحاظ شود.

۱.۸.۷ چرا طیف‌نگار به‌عنوان نمایش میانی؟

پرسش طبیعی: چرا مستقیماً از واج به موج نرویم؟ پاسخ مطرح‌شده در کلاس این است که یک نمایش میانی **پیچیدگی مسئلهٔ یادگیری را کاهش می‌دهد**. به‌جای آنکه مدل مجبور باشد همهٔ جزئیات موج را در یک گام بسازد، ابتدا نمایشی ساختاریافته‌تر از ویژگی‌های صوتی تولید می‌کند و سپس ماژول دیگری آن را به موج برمی‌گرداند.

مثال استاد: مسیر تهران تا مشهد

فرض کنید فقط می‌دانیم کسی از تهران به مشهد رفته و مسافت مشخصی را طی کرده است. می‌خواهیم مسیر دقیقش را بازسازی کنیم. از مبدأ، مقصد و مسافت می‌توان اطلاعاتی گرفت، اما هنوز جزئیات بسیاری معلوم نیست: از کدام شهرها گذشته؟ کدام جاده‌ها را رفته؟ در تولید گفتار هم دانستن توالی واج‌ها برای مشخص‌شدن همهٔ جزئیات موج کافی نیست. اگر در میانهٔ راه «نقاط عطف» داشته باشیم (مثل شهرهای بین راه)، بازسازی مسیر ساده‌تر می‌شود. طیف‌نگار نقش همین نقاط عطف را دارد: اطلاعات بیشتری برای مرحلهٔ بعد فراهم می‌کند و بازسازی موج را ساده‌تر می‌سازد.

[محتوای افزوده] چرا دقیقاً طیف‌نگار مل؟

چند دلیل فنی این انتخاب را رایج کرده است:

- **کاهش طول:** با نرخ ۲۲٫۰۵ کیلوهرتز و گام ۲۵۶ نمونه (hop length)، نرخ قاب‌ها $\approx 22050/256$ ۸۶٫۱ قاب بر ثانیه است، یعنی ۲۵۶ بار کمتر از نرخ نمونه. برای ۳ ثانیه: $\lfloor 3 \times 86.13 \rfloor = 258$ قاب در برابر ۶۶ ۱۵۰ نمونه.
- **فشردگی بعد فرکانسی:** طیف‌نگار خطی با پنجرهٔ ۱۰۲۴ نقطه‌ای ۵۱۳ مقدار برای هر قاب دارد، اما مل با ۸۰ فیلتر تنها ۸۰ مقدار (مقیاس مل بر پایهٔ ادراک شنوایی؛ جلسهٔ پیشین).
- **هموار و قابل پیش‌بینی بودن:** طیف‌نگار مل، برخلاف موج، ساختاری دارد که مدل می‌تواند آن را یاد بگیرد (هارمونیک‌ها، فرمنت‌ها، مرز واج‌ها).
- **جداسازی وظایف:** وکودر را می‌توان جدا از متن و روی داده‌های گفتاری بدون متن آموزش داد؛ همان وکودر برای مدل‌های آکوستیکی مختلف قابل استفاده است.

۲.۸.۷ نقش Embedding در مدل آکوستیکی

در کلاس مثال زده شد که برای هر واج می‌توان یک بردار **تعبیه** (Embedding) در نظر گرفت؛ مثلاً هر واج با یک بردار ۵۱۲ بعدی. این عدد فقط مثالی از ابعاد Embedding است. در آموزش، مدل نمایش‌هایی می‌آموزد که اطلاعات مربوط به هر واج و ارتباطش با واج‌های قبل و بعد را در خود دارند. در نتیجه مدل فقط به هویت یک واج مستقل محدود نیست و می‌تواند با استفاده از بافت مجاور، بخشی از اطلاعات لازم برای تولید طبیعی آن را بیاموزد. این موضوع به‌ویژه در پدیدهٔ هم‌تولیدی اهمیت دارد.

[محتوای افزوده] تصویر ذهنی از جدول Embedding

Embedding یک جدول جست‌وجو است: اگر واژگان V واج داشته باشد و بعد تعبیه $d = 512$ باشد، جدول $E \in \mathbb{R}^{V \times 512}$ است و واج شمارهٔ i به بردار سطر iام ($e_i \in \mathbb{R}^{512}$) نگاشته می‌شود. با $V \approx 40$ واج فارسی، فقط $40 \times 512 = 20\,480$ پارامتر داریم. این بردارها در آموزش و همراه با بقیهٔ شبکه یاد گرفته می‌شوند. برای نمونه، در Tacotron 2 نیز نویسه‌ها به بردار ۵۱۲ بعدی نگاشت می‌شوند. اثر بافت (مثلاً هم‌تولیدی) در لایه‌های بعدی شبکه، مانند LSTM دوسویه یا بلوک‌های Transformer، وارد می‌شود: خروجی این لایه‌ها برای واج i تابعی از واج‌های همسایه نیز هست.

۳.۸.۷ مدل آکوستیکی و پروزودی

استاد تأکید کرد که «تولید طیف‌نگار» و «پیش‌بینی پروزودی» دقیقاً یک مسئله نیستند. برای یک محتوای زبانی ثابت می‌توان حالت‌های پروزودی گوناگونی در نظر گرفت. بنابراین در بعضی معماری‌ها از مؤلفه‌های جدا برای پیش‌بینی ویژگی‌های پروزودی و تولید نمایش آکوستیکی استفاده می‌شود. مثلاً می‌توان برای یادگیری پروزودی یک تابع هزینه (Loss) و برای خروجی آکوستیکی تابع هزینهٔ دیگری تعریف کرد تا مدل هم «چه گفته شود» و هم «چگونه گفته شود» را یاد بگیرد. نحوهٔ دقیق این تفکیک به معماری بستگی دارد.

[محتوای افزوده] مثال معماری‌ها

FastSpeech 2 نمونه‌ای از این تفکیک است: علاوه بر خروجی طیف‌نگار، پیش‌بین‌های جداگانه‌ای برای **مدت**، **گام** (pitch) و **انرژی** دارد که هرکدام تابع هزینهٔ مخصوص خود را دارند. FastSpeech با یک «تنظیم‌کنندهٔ طول» (length regulator) هر واج را به تعداد قاب‌های پیش‌بینی‌شده تکرار می‌کند؛ این همان حل مسئلهٔ هم‌ترازی زمانی به شیوهٔ صریح است. در Tacotron 2، به‌جای مدت‌های صریح، سازوکار توجه (attention) ضمنی هم‌ترازی را یاد می‌گیرد و پروزودی را از داده می‌آموزد.

۹.۷ وکودر: از طیف‌نگار به موج

پس از تولید طیف‌نگار هنوز موج واقعی نداریم. ماژولی که نمایش آکوستیکی را به Waveform تبدیل می‌کند **وکودر** (Vocoder) نام دارد (از «Voice + coder»):

$$\text{Spectrogram} \xrightarrow{\text{Vocoder}} \text{Waveform}.$$

(واژهٔ vocoder به دههٔ ۱۹۳۰ و کارهای آزمایشگاه‌های بل برمی‌گردد؛ در TTS امروزی منظور وکودر عصبی است.)

۱.۹.۷ چرا ساختن موج از طیف‌نگار ساده نیست؟

پاسخ به تبدیل فوریه‌ای برمی‌گردد که در جلسات پیش دیدیم. ضرایب تبدیل فوریه هم **دامنه** دارند و هم **فاز**. اگر یک ضریب را به‌صورت $X = a + jb$ بنویسیم، اندازه و فاز آن چنین‌اند:

$$|X| = \sqrt{a^2 + b^2}, \qquad \phi = \operatorname{atan2}(b, a).$$

طیف‌نگار فقط اندازه (Magnitude) را نگه می‌دارد و فاز را کنار می‌گذارد. پس اگر فقط $|X|$ را داشته باشیم، نمی‌توانیم بدون اطلاعات یا تخمین اضافی، همهٔ جزئیات موج اولیه را بازیابیم. فاز مشخص می‌کند هر مؤلفهٔ فرکانسی کجای زمان قرار دارد و چگونه با بقیهٔ مؤلفه‌ها ترکیب می‌شود. روی تخته این مطلب چنین نوشته شده بود: «زاویه و زمان‌بندی (فاز) دور ریخته شد؛ علامت‌ها و نوسان‌های ریز مثبت/منفی (دامنهٔ لحظه‌ای موج) همه به عددهای مثبتِ "شدت انرژی" تبدیل شدند.»

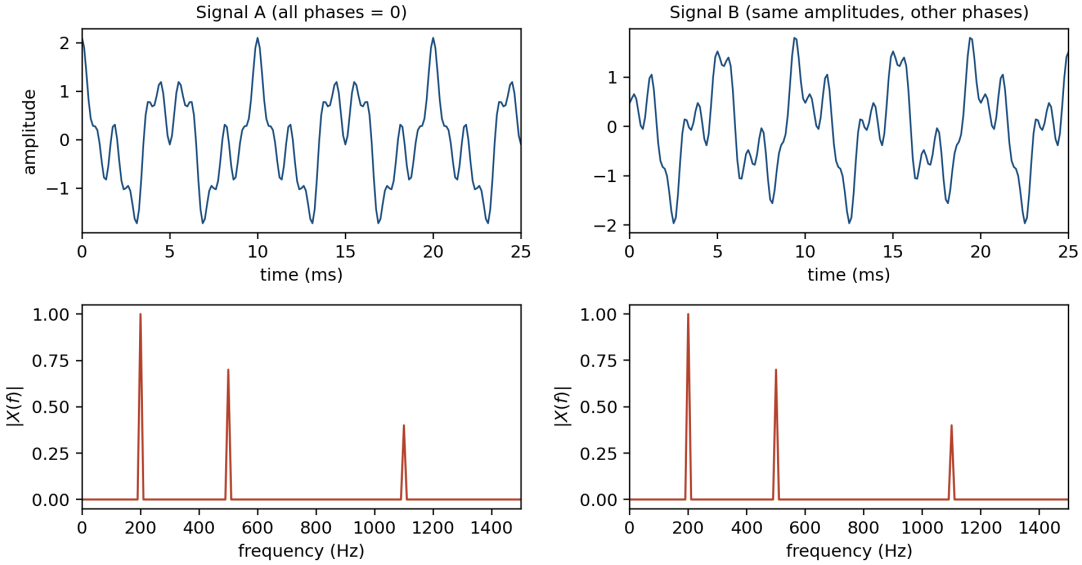
[محتوای افزوده] مثال عددی: اندازه یکسان، فاز متفاوت

دو ضریب مختلط $X_1 = 3 + 4j$ و $X_2 = -3 + 4j$ را در نظر بگیرید.

$$|X_1| = \sqrt{9 + 16} = 5, \qquad \phi_1 = \operatorname{atan2}(4, 3) \approx 53.1^\circ,$$
$$|X_2| = \sqrt{9 + 16} = 5, \qquad \phi_2 = \operatorname{atan2}(4, -3) \approx 126.9^\circ.$$

اندازه‌ها برابرند و تنها فاز آن‌ها متفاوت است؛ پس از روی اندازهٔ 5 نمی‌توانیم بگوییم ضریب اصلی X_1 بوده یا X_2. شکل زیر همین نکته را روی سیگنال نشان می‌دهد: دو سیگنال از سه مؤلفهٔ سینوسی با فرکانس‌های ۲۰۰، ۵۰۰ و ۱۱۰۰ هرتز ساخته شده‌اند که دامنه‌هایشان برابر است و فقط فازشان فرق دارد. طیف اندازهٔ دو سیگنال دقیقاً یکی

است اما شکل موج‌ها کاملاً متفاوت است.



شکل ۱۶.۷: دو سیگنال با طیف اندازهٔ یکسان و فازهای متفاوت: ردیف بالا شکل موج و ردیف پایین طیف اندازه است. طیف اندازه به‌تنهایی شکل موج را مشخص نمی‌کند و باید فاز را بازسازی یا تخمین زد. (شکل افزوده)

۲.۹.۷ مسئلهٔ بازسازی فاز

چون در طیف‌نگار اندازه‌ای فاز وجود ندارد، برای ساختن موج باید راهی برای بازسازی یا تولید یک سیگنال سازگار با آن پیدا کرد. دو دسته راه‌حل را می‌توان نام برد:

- **روش‌های کلاسیک مانند Griffin–Lim**: به‌طور تکراری فاز را حدس می‌زنند تا طیف‌نگار حاصل از سیگنال با طیف‌نگار مفروض سازگار شود. بدون آموزش و ساده‌اند، اما خروجی معمولاً صدایی مصنوعی و «وزوزی» دارد.
- **وکودرهای عصبی**: شبکهٔ عصبی مستقیماً از طیف‌نگار به موج می‌رسد و فاز را ضمنی یاد می‌گیرد. نمونه‌ها: WaveNet (خودهمبستهٔ نمونه‌به‌نمونه و کند)، HiFi-GAN (سریع و مبتنی بر GAN).

فاز «کاملاً» از بین نمی‌رود، اما بازیابی‌اش آسان نیست

جملهٔ «اندازه را که نگه دارید، فاز حذف می‌شود» درست است، ولی دو دقت لازم است. (الف) طیف‌نگار بر پایهٔ پنجره‌های هم‌پوشان ساخته می‌شود، پس افزونگی دارد و می‌توان از ثبات میان قاب‌های متوالی (سازگاری STFT) فاز را تا حد خوبی تخمین زد؛ Griffin–Lim دقیقاً این کار را می‌کند. (ب) طیف‌نگار مل علاوه بر حذف فاز، تفکیک فرکانسی را هم کم می‌کند (بیش از ۵۰۰ نقطه به ۸۰ فیلتر)، پس بازگرداندن به طیف خطی هم تقریبی است. نتیجه: ساخت موج از مل یک مسئلهٔ تقریباً بدوضع‌طرح‌شده است که با یک مدل مولد خوب حل می‌شود.

۳.۹.۷ مدل‌های مولد و GAN

یکی از رویکردهای تولید موج استفاده از **شبکهٔ مولد رقابتی** (Generative Adversarial Network, GAN) است. معماری GAN دو بخش دارد:

- **مولد** (Generator): خروجی مصنوعی (اینجا موج) می‌سازد؛
- **تمایزدهنده** (Discriminator): می‌کوشد خروجی ساخته‌شده را از نمونهٔ واقعی تشخیص دهد.

بازخورد تمایزدهنده به بهتر شدن مولد کمک می‌کند. در پاسخ به پرسشی در کلاس، استاد روشن کرد که لازم نیست مدل GAN یک «فاز» مستقل به‌عنوان خروجی تولید کند؛ می‌تواند مستقیماً موج صوتی بسازد و با تابع‌های هزینه، کیفیت را بهتر کند. هدف نهایی وکودر تولید موجی است که از نظر صوتی با نمایش ورودی سازگار باشد. جزئیات معماری‌های مولد و توابع هزینه به جلسات بعد موکول شد.

[محتوای افزوده] نگاهی گذرا به WaveNet و HiFi-GAN

WaveNet (۲۰۱۶): مدلی خودهمبسته (autoregressive) با کانولوشن‌های علّی و متسع‌شده (dilated causal convolution) که هر نمونه را به‌شرط نمونه‌های پیشین (و شرط‌های ورودی مانند طیف‌نگار مل) پیش‌بینی می‌کند؛ کیفیت خیلی بالا ولی تولید نمونه‌به‌نمونه، بسیار کند است.
HiFi-GAN (۲۰۲۰): مولد کانولوشنی که با لایه‌های کانولوشن تراگذار، طول طیف‌نگار را به طول موج می‌رساند (در پیکربندی رایج با گام ۲۵۶، یعنی ضریب افزایش طول ۲۵۶) و دو دسته تمایزدهنده (چندمقیاسی و چنددوره‌ای) برای ارزیابی اجزای مختلف شکل موج دارد. برخلاف WaveNet همهٔ نمونه‌ها را موازی تولید می‌کند و بسیار سریع‌تر از زمان واقعی است.
مثال ابعاد: برای یک مل ۸۰ بعدی با ۲۵۸ قاب، مولد باید ماتریس $۸۰ \times ۲۵۸ = ۲۰۶۴۰$ مقداری را به بردار $۲۵۸ \times ۲۵۶ = ۶۶۰۴۸$ نمونه تبدیل کند (حدود ۳ ثانیه در ۲۲٫۰۵ کیلوهرتز).
VITS (۲۰۲۱) این دو مرحله را درون یک مدل سرتاسری ترکیب می‌کند و رمزگذار متن، مدل مدت، و یک رمزگشای مشابه HiFi-GAN را با هم آموزش می‌دهد.

۱۰.۷ جمع‌بندی خط‌لولهٔ TTS

جدول زیر خلاصهٔ مسیر را نشان می‌دهد:

مرحله	ورودی	خروجی	وظیفه
Text Normalization	متن خام	متن قابل خواندن	گسترش NSW
Homograph Disamb.	متن دارای هم‌نویسه	تلفظ مشخص‌شده	رفع ابهام بافتی و نحوی
G2P	نویسه‌ها	واج‌ها	تبدیل نوشتار به نمایش واجی
Acoustic Model	توالی واج‌ها	طیف‌نگار (مل)	تولید نمایش آکوستیکی
Vocoder	طیف‌نگار	موج	تولید موج گفتار

دو بخش اصلی: **Front-End** (آماده‌سازی و تحلیل متن تا رسیدن به واج‌ها) و **Back-End** (تولید نمایش آکوستیکی

و موج از واج‌ها).

۱.۱۰.۷ چرا خط‌لوله هنوز مهم است؟

ممکن است گمان کنیم چون مدل‌های End-to-End وجود دارند دیگر نیازی به بررسی خط‌لوله نیست. استاد توضیح داد که این نتیجه‌گیری درست نیست. در برخی کاربردها کنترل مستقل هر بخش اهمیت دارد. برای مثال ممکن است بخواهیم:

- نرمال‌ساز متن را برای یک دامنهٔ خاص تنظیم کنیم؛
- برای کاهش تأخیر از روشی سریع‌تر استفاده کنیم؛
- بخشی از سامانه را با مدل کلاسیک پیاده کنیم؛
- روی یک مشکل مشخص مانند اعداد یا هم‌نویسه‌ها تمرکز بیشتری داشته باشیم.

در خط‌لوله هر بخش مستقل‌تر قابل اصلاح و جایگزینی است. در مقابل، مدل‌های سرتاسری یکپارچه‌ترند و مزیت‌های دیگری در یادگیری و تولید دارند. انتخاب معماری باید بر پایهٔ مسئله و محدودیت‌های کاربرد انجام شود.

۲.۱۰.۷ جلسات آینده و گفت‌وگوی پایانی

هدف این جلسه آشنایی با کل معماری TTS و نقش هر ماژول بود، نه ورود به جزئیات همهٔ مدل‌ها. در جلسات آینده معماری‌های مختلف هر بخش، چه روش‌های کلاسیک و چه مدل‌های یادگیری عمیق، بررسی می‌شوند و یک جلسه به رویکردهای End-to-End اختصاص می‌یابد.

پرسش و پاسخ پایانی و نکات ارزیابی

در پایان کلاس استاد پرسید آیا بهتر است پیش از ورود به مدل‌های اصلی مفاهیمی مانند Transformer، Self-Attention، Cross-Attention، Encoder–Decoder و GAN نیز جداگانه توضیح داده شوند یا هنگام معرفی هر معماری به‌اندازهٔ لازم گفته شوند. پس از گفت‌وگو با دانشجویان قرار شد این مفاهیم به‌اندازهٔ لازم توضیح داده شوند تا هنگام معرفی مدل‌های بعدی بتوان به آن‌ها ارجاع داد. استاد اشاره کرد که مطالب تدریس‌شده می‌توانند در ارزیابی و امتحان مطرح شوند. تکلیف یا تمرین مشخصی در این جلسه اعلام نشد.

۱۱.۷ جمع‌بندی

در این جلسه از تحلیل سیگنال به **تولید** سیگنال رسیدیم. مسئلهٔ TTS از دو جهت دشوار است: متن بسیار کم‌حجم‌تر از موج است و در عین حال اطلاعات پروزودی و گوینده را نیز ندارد. برای مهار این پیچیدگی، سامانه را به دو بخش Front-End (نرمال‌سازی، رفع ابهام هم‌نویسه، G2P) و Back-End (مدل آکوستیکی و وکودر) تقسیم کردیم. در بخش اول، «خواندنی کردن» متن مهم است و با نرمال‌سازی مرسوم در NLP فرق دارد؛ فراوانی NSWها به دامنه وابسته

است و تلفظ هم‌نویسه‌ها به نقش دستوری و بافت. در بخش دوم، طیف‌نگار مل به‌عنوان نمایش میانی، پیچیدگی تبدیل واج به موج را کم می‌کند و وکودر باید فازِ ازدست‌رفته را بازسازی کند. این جلسه چارچوبی ایجاد کرد که معماری‌های دقیق مدل‌ها در جلسات بعد در آن جای می‌گیرند.

نکات مهم برای مرور و امتحان

۱. در TTS مسیر برعکس تحلیل گفتار است: متن ← موج. چالش‌ها: شکاف حجم اطلاعات، کم‌گویی متن، و نگاشت یک‌به‌چند.

۲. دو رویکرد: Pipeline و End-to-End؛ سرتاسری بودن لزوماً بهتر نیست (تأخیر، دامنه، کنترل).

۳. دو بخش: Front-End (متن ← واج) و Back-End (واج ← طیف‌نگار ← موج).

۴. نرمال‌سازی در TTS گسترش‌دهنده و آواشناسی‌محور است، نه کاهنده مانند Hazm برای NLP.

۵. NSW: عدد، تاریخ، ساعت، پول، اختصار و ...؛ اول باید دستهٔ توکن را تشخیص داد، سپس مبدل همان دسته را به کار برد.

۶. فراوانی NSW به دامنه وابسته است (توییتر و SMS بیشتر از متن خبری).

۷. هم‌نویسه‌ها را با اطلاعات نحوی (POS) و بافت (Contextual Embedding) و در پیوند با WSD حل می‌کنیم؛ هر ابهام معنایی ابهام تلفظی نیست.

۸. G2P: تبدیل نویسه به واج؛ سه پیش‌نیاز: الفبای آوایی (IPA)، فرهنگ تلفظ، مدل G2P. نگاشت یک‌به‌یک نیست.

۹. چالش‌های Back-End: پروزودی، اختلاف نرخ (مثلاً ۳۰ واج در برابر ۷۲ ۰۰۰ نمونه)، هم‌ترازی زمانی و هم‌تولیدی.

۱۰. مدل آکوستیکی واج را به طیف‌نگار مل می‌برد؛ دلیل نمایش میانی: کاهش پیچیدگی (مثال تهران-مشهد). تعبیه‌های واجی (مثلاً ۵۱۲ بعدی) اطلاعات بافت را حمل می‌کنند.

۱۱. وکودر طیف‌نگار را به موج می‌برد؛ مشکل اصلی: ازدست‌رفتن فاز (فقط $|X|$ باقی می‌ماند). راه‌حل‌ها: Griffin–Lim و وکودرهای عصبی (WaveNet، HiFi-GAN).

۱۲. زنجیرهٔ اصلی: متن ← نرمال‌سازی ← رفع ابهام هم‌نویسه ← G2P ← واج‌ها ← مدل آکوستیکی ← طیف‌نگار ← وکودر ← موج.

فصل ۸

بازنمایی متن در TTS: از One-Hot تا بازنمایی وابسته به بافت

۱.۸ مروری بر معماری سامانه‌های تبدیل متن به گفتار

در جلسهٔ پیش ساختار کلی سامانه‌های **تبدیل متن به گفتار** (Text-to-Speech) را دیدیم. در این جلسه به‌جای تکرار آن مطالب، یک گام عمیق‌تر برمی‌داریم و بخش متنی سامانه را از دید «مدل» و «معماری» بررسی می‌کنیم. سامانه‌های TTS را می‌توان به دو شکل کلی ساخت:

- **معماری خط‌لوله‌ای** (Pipeline-Based): سامانه از چند ماژول مستقل تشکیل شده و خروجی هر ماژول ورودی ماژول بعدی است.
- **معماری سرتاسری** (End-to-End): بخش‌های مختلف پردازش در قالب یک مدل یکپارچه آموخته می‌شوند.

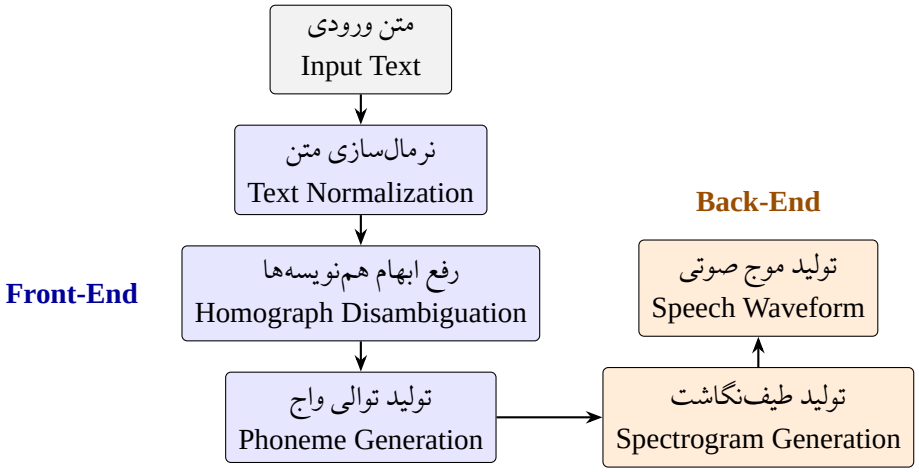
تمرکز فعلی درس بر معماری خط‌لوله‌ای است تا بتوانیم هر ماژول را جداگانه بشناسیم و پیاده‌سازی کنیم. مراحل این خط‌لوله در شکل زیر آمده است.

بخش پیشین و بخش پسین

بخش پیشین (Front-End) همان بخشی است که با متن کار می‌کند: تحلیل و نرمال‌سازی متن، رفع ابهام و استخراج اطلاعات تلفظی. **بخش پسین** (Back-End) با بازنمایی‌های صوتی سروکار دارد و صدای نهایی را تولید می‌کند. این تقسیم‌بندی مربوط به معماری پردازش گفتار است و نباید با مفاهیم هم‌نام در توسعهٔ وب یکسان گرفته شود.

تأکید استاد درباره ماژولار بودن

هر ماژول را باید جداگانه یاد گرفت؛ زیرا ممکن است در یک پروژه به یکی از آن‌ها بیشتر نیاز داشته باشیم یا بخواهیم چند ماژول را با هم ادغام کنیم. مدل‌های بزرگ سرتاسری ممکن است از نظر منابع محاسباتی و **تأخیر** (Latency) محدودیت داشته باشند؛ بنابراین شناخت معماری‌های کوچک‌تر و ماژولار همچنان مهم است. شناخت ماژول‌های مستقل TTS پیش از رسیدن به سامانه‌های یکپارچه هدف این مسیر آموزشی است.



شکل ۱.۸: مراحل معماری خط‌لوله‌ای TTS. سه مرحلهٔ آبی «بخش پیشین» و دو مرحلهٔ نارنجی «بخش پسین» سامانه‌اند (شکل افزوده).

هدف اصلی این جلسه بررسی بخش متنیِ TTS، به‌ویژه تشخیص تلفظ درست **هم‌نویسه‌ها** (Homograph) با استفاده از بازنمایی کلمات و اطلاعات بافت جمله است. برای رسیدن به آن، ابتدا باید بدانیم کلمه چگونه به شبکهٔ عصبی داده می‌شود و شبکهٔ عصبی چگونه آموزش می‌بیند.

۲.۸ بازنمایی متن برای شبکه‌های عصبی

شبکه‌های عصبی مستقیماً با کلمات کار نمی‌کنند؛ آن‌ها به بازنمایی عددی نیاز دارند. پرسشِ «ورودی چگونه نمایش داده می‌شود؟» نخستین پرسش هر مدل زبانی است.

۱.۲.۸ بازنمایی One-Hot

ساده‌ترین روش، بردار **تک‌داغ** (One-Hot) است. اگر واژگان ما V کلمه داشته باشد، هر کلمه با برداری به طول V نمایش داده می‌شود که فقط یک مؤلفهٔ آن ۱ و بقیه صفر است؛ محل عدد ۱ همان اندیس کلمه در واژگان است. برای واژگانی با پنج کلمه:

کلمه	بردار One-Hot
کلمهٔ اول	$(۱, ۰, ۰, ۰, ۰)$
کلمهٔ سوم	$(۰, ۰, ۱, ۰, ۰)$
کلمهٔ پنجم	$(۰, ۰, ۰, ۰, ۱)$

این روش با وجود سادگی چهار محدودیت مهم دارد:

۱. **ابعاد زیاد:** طول بردار برابر اندازهٔ واژگان است؛ هرچه واژگان بزرگ‌تر شود، حافظهٔ بیشتری لازم است.

۲. **پراکنده بودن (Sparse):** بیشتر مؤلفه‌های هر بردار صفرند.

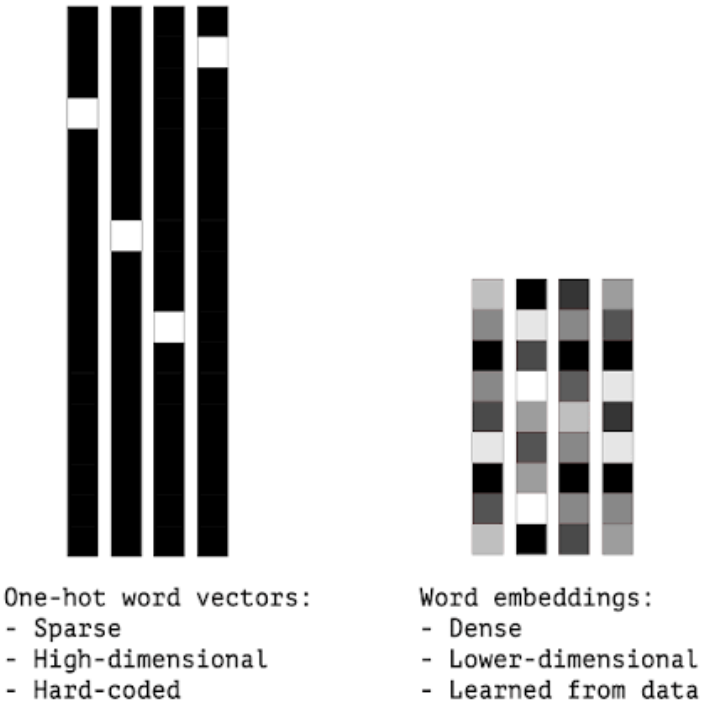
۳. **تعامد (Orthogonality):** ضرب داخلی هر دو بردار One-Hot متعلق به دو کلمهٔ متفاوت صفر است.

۴. **نبود شباهت معنایی:** مثلاً نام دو شهر یا دو کلمهٔ هم‌معنا در این نمایش هیچ نزدیکی عددی ندارند.

ریشهٔ مشکل این است که کلمات در زبان بر اساس **بافت** (Context) و **هم‌وقوعی** (Co-occurrence) با یکدیگر مرتبط‌اند، اما One-Hot هیچ‌یک از این ارتباطات را نشان نمی‌دهد. برای کاربرد ما، یعنی تشخیص تلفظ از روی بافت، این نقص جدی است.

۲.۲.۸ بازنمایی توزیع‌شده: Word Embedding

برای رفع این محدودیت‌ها از **تعبیهٔ کلمه** (Word Embedding) استفاده می‌کنیم. به‌جای آنکه طول بردار به اندازهٔ واژگان باشد، یک بُعد دلخواه (مثلاً ۱۲۸ یا ۳۰۰) انتخاب می‌کنیم و به هر کلمه برداری با همین طول نسبت می‌دهیم. هر مؤلفه یک ویژگی عددی است که در فرایند آموزش یاد گرفته می‌شود و لازم نیست از ابتدا مشخص کنیم هر مؤلفه دقیقاً چه چیزی را نشان می‌دهد.



شکل ۲.۸: مقایسهٔ بردارهای One-Hot (پراکنده، با ابعاد زیاد و از پیش‌تعریف‌شده) و بردارهای Embedding (متراکم، با ابعاد کم‌تر و آموخته‌شده از داده). این تصویر در بخش «ورودی چگونه نمایش داده می‌شود؟» تخته آمده بود.

بازنمایی توزیع‌شده در برابر پراکنده

در بازنمایی پراکنده هر کلمه یک «مختصات» منحصربه‌فرد (یک خانهٔ روشن) است. در بازنمایی **توزیع‌شده** (Distributed) معنای هر کلمه در چند مؤلفه پخش می‌شود و هر مؤلفه در بازنمایی چندین کلمه نقش دارد؛ به همین دلیل فاصله و زاویهٔ میان بردارها معنا پیدا می‌کند.

جدول ۱.۸: مقایسهٔ دو بازنمایی (جمع‌بندی شکل بالا)

ویژگی	One-Hot	Embedding
تراکم	پراکنده (Sparse)	متراکم (Dense)
بُعد	برابر اندازهٔ واژگان	کوچک و دلخواه
چگونگی ساخت	ازپیش‌تعریف‌شده (Hard-coded)	آموخته از داده
شباهت معنایی	ندارد	دارد

[محتوای افزوده] جدول جست‌وجو و رابطه با One-Hot

اگر $E \in \mathbb{R}^{V \times d}$ ماتریس Embedding باشد (هر سطر یک کلمه)، آنگاه ضرب بردار One-Hot کلمهٔ i در این ماتریس دقیقاً سطر iام آن را برمی‌گرداند:

$$\mathbf{e}_i^\top E = E_{i,:}.$$

پس لایهٔ Embedding در عمل یک **جدول جست‌وجو** (Lookup Table) است و لازم نیست ضرب ماتریسی را واقعاً انجام دهیم. تعداد پارامترهای این لایه $V \times d$ است؛ مثلاً برای $V = ۵۰۰۰۰$ و $d = ۳۰۰$ برابر ۱۵ میلیون عدد.

[محتوای افزوده] مثال عددی: ضرب داخلی و شباهت کسینوسی

برای دو بردار One-Hot متفاوت، همیشه $\mathbf{a} \cdot \mathbf{b} = ۰$ است؛ پس «گربه» از دید این بازنمایی به «سگ» و «ماشین» به یک اندازه نزدیک است. حال فرض کنید تعبیه‌های دوبُعدیِ فرضیِ زیر را یک مدل یاد گرفته باشد:

$$\mathbf{v}_{\text{گربه}} = (۰/۹,\ ۰/۸), \quad \mathbf{v}_{\text{سگ}} = (۰/۸,\ ۰/۹), \quad \mathbf{v}_{\text{ماشین}} = (۰/۲,\ -۰/۹).$$

شباهت کسینوسی (Cosine Similarity) به‌صورت $\cos\theta = \dfrac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\|\,\|\mathbf{b}\|}$ تعریف می‌شود. داریم $\|\mathbf{v}_{\text{گربه}}\| = \|\mathbf{v}_{\text{سگ}}\| = \sqrt{۱/۴۵} \approx ۱/۲۰۴$ و $\|\mathbf{v}_{\text{ماشین}}\| \approx ۰/۹۲۲$. بنابراین

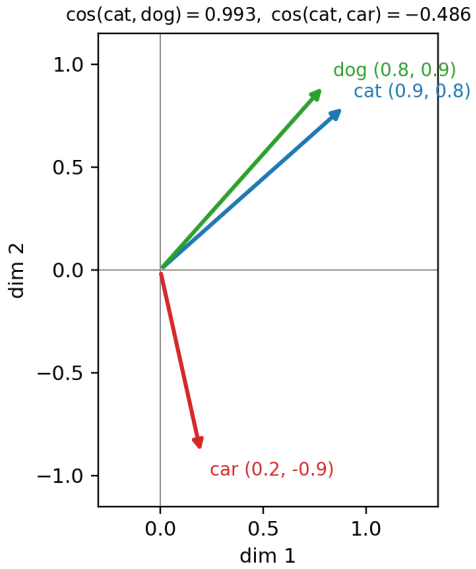
$$\cos(\text{گربه}, \text{سگ}) = \frac{۰/۷۲ + ۰/۷۲}{۱/۴۵} \approx ۰/۹۹۳,$$

$$\cos(\text{گربه}, \text{ماشین}) = \frac{۰/۱۸ - ۰/۷۲}{۱/۲۰۴ \times ۰/۹۲۲} \approx -۰/۴۸۶.$$

مقدار نزدیک به ۱ یعنی جهت‌های تقریباً یکسان (کلمات مشابه) و مقدار منفی یعنی جهت‌های مخالف. این همان شباهتی است که One-Hot نمی‌تواند نشان دهد.

۳.۲.۸ بردارهای Embedding چگونه یاد گرفته می‌شوند؟

بردارها ابتدا به‌صورت تصادفی مقداردهی می‌شوند (Random Initialization). سپس باید یک **وظیفهٔ آموزشی** (Task) تعریف کنیم. هر شبکه برای یادگیری این چرخه را طی می‌کند:



شکل ۳.۸: بردارهای فرضیِ مثال بالا در صفحهٔ دوبُعدی؛ زاویهٔ کوچک میان «cat» و «dog» به شباهت زیاد آن‌ها و زاویهٔ بزرگ نسبت به «car» به تفاوت معنایی اشاره دارد (شکل افزوده).

۱. ورودی را دریافت می‌کند؛

۲. خروجی را پیش‌بینی می‌کند؛

۳. خروجی را با مقدار صحیح (Ground Truth) مقایسه می‌کند؛

۴. خطا را محاسبه می‌کند؛

۵. وزن‌ها را برای کاهش خطا تغییر می‌دهد.

در این میان، بردارهای Embedding نیز پارامتر قابل یادگیری‌اند و به‌روز می‌شوند. پس از پایان آموزش می‌توان فقط بردارها را برداشت و در مدل‌های دیگر به کار برد؛ نیازی به نگه‌داشتن کل شبکهٔ آموزش‌دهنده نیست.

تعریف وظیفه برای یادگیری

یک وظیفهٔ رایج، پنهان‌کردن بخشی از جمله و خواستن پیش‌بینی آن از مدل است:

«من امروز به [MASK] رفتم.»

مدل باید از روی کلمات اطراف حدس بزند که کلمهٔ حذف‌شده چه بوده است. مزیت مهم این روش آن است که به برچسب‌گذاری دستی نیاز ندارد: متن اصلی را داریم، خودمان یک کلمه را پنهان می‌کنیم و بنابراین پاسخ صحیح از قبل معلوم است. این ویژگی برای مجموعه‌داده‌های متنی بسیار بزرگ حیاتی است (بخش ۸.۸).

پیش‌آموزش، تنظیم دقیق و آموزش از صفر

- **پیش‌آموزش** (Pre-training): آموزش مدل روی حجم بزرگی از داده برای یادگیری بازنمایی‌های عمومی زبان.
- **تنظیم دقیق** (Fine-tuning): اگر مدل از قبل آموزش دیده باشد، وزن‌های آن را برمی‌داریم و آموزش را با دادهٔ دامنهٔ موردنظر ادامه می‌دهیم تا با نیاز جدید سازگار شود.
- **آموزش از صفر** (Training from Scratch): شروع از مقداردهی اولیهٔ جدید و بدون استفاده از وزن‌های ازپیش‌آموخته.

اگر دادهٔ ما اصطلاحات تخصصی یا کلمات خارج از واژگان عمومی (Out-of-Vocabulary یا OOV) داشته باشد، بازنمایی‌های آماده به‌تنهایی کافی نیستند و باید دربارهٔ ادامهٔ آموزش، سازگارسازی با دامنه یا آموزش مدل جدید تصمیم گرفت.

نکتهٔ مورد تأکید استاد

صرفاً دانلودکردن یک Embedding آماده همیشه مسئلهٔ یک پروژهٔ تخصصی را حل نمی‌کند. باید بدانیم Embedding چگونه ساخته شده و چگونه می‌توان آن را با نیاز خودمان سازگار کرد.

۳.۸ مروری بر مبانی شبکه‌های عصبی

برای فهم چگونگی آموزش Embeddingها و مدل‌های تشخیص تلفظ باید اصول شبکه‌های عصبی را مرور کنیم. سطح این مرور مقدماتی است و در پایان جلسه قرار شد همین سطح حفظ شود (بخش ۱۱.۸).

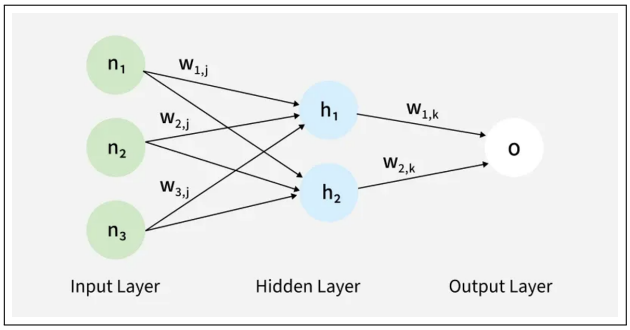
۱.۳.۸ ساختار شبکه

یک شبکهٔ عصبی معمولی از سه بخش ساخته می‌شود:

- **لایهٔ ورودی** (Input Layer): دریافت داده، مانند بردار کلمات؛
- **لایه‌های پنهان** (Hidden Layers): پردازش و یادگیری بازنمایی‌های میانی؛
- **لایهٔ خروجی** (Output Layer): تولید خروجی نهایی، مثل پیش‌بینی یک کلمه یا انتخاب یک کلاس تلفظ.

با افزایش تعداد لایه‌های پنهان، شبکه «عمیق‌تر» می‌شود و می‌تواند بازنمایی‌های پیچیده‌تر و انتزاعی‌تری بیاموزد. استاد سه وظیفه را از این نظر مقایسه کرد:

وظیفه	ماهیت اطلاعات موردنیاز
POS Tagging	اطلاعات نحوی و نقش کلمات
Named Entity Recognition (NER)	شناسایی و دسته‌بندی موجودیت‌های نامدار
Commonsense Reasoning	استدلال بر پایهٔ دانش عمومی و ارتباطات مفهومی



شکل ۴.۸: شبکه‌ای با سه نورون ورودی، دو نورون پنهان و یک نورون خروجی؛ هر یال یک وزن (مانند $w_{۱,j}$) دارد. (برگرفته از تختهٔ کلاس)

قید استاد دربارهٔ مقایسهٔ وظایف

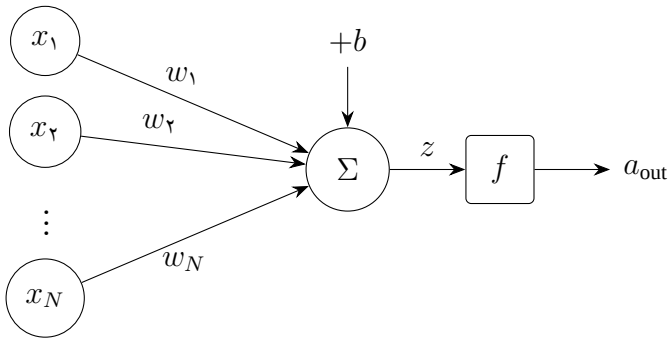
این ترتیب مطلق نیست. برای مثال NER ممکن است فقط چند کلاس رایج داشته باشد یا در یک پروژهٔ تخصصی تعداد بسیار زیادی کلاس و روابط مبتنی بر Ontology را شامل شود. عمق موردنیاز شبکه به تعریف دقیق مسئله بستگی دارد.

۲.۳.۸ نورون: مرحلهٔ پیش‌رو (Feedforward)

هر نورون ورودی‌هایش را در وزن‌ها ضرب می‌کند، با هم جمع می‌کند و یک عدد ثابت (بایاس) به آن می‌افزاید. در شکل برداری، برای ورودی $\mathbf{x}$ داریم

$$\mathbf{z} = W\mathbf{x} + \mathbf{b}, \qquad \mathbf{a} = f(\mathbf{z}),$$

که W ماتریس وزن‌ها، $\mathbf{b}$ بردار بایاس، $\mathbf{z}$ خروجی خطی پیش از تابع فعال‌سازی و f تابع فعال‌سازی است. در شکل تختهٔ کلاس همین رابطه به صورت $y = f(W \cdot x + b)$ نوشته شده بود. وزن‌ها در ابتدا مقدار اولیه می‌گیرند و در آموزش تغییر می‌کنند.



شکل ۵.۸: ساختار یک نورون: جمع وزن‌دار ورودی‌ها به‌علاوهٔ بایاس، $z = b + \sum_i w_i x_i$، و سپس عبور از تابع فعال‌سازی، $a_{\text{out}} = f(z)$ (شکل افزوده).

نقش بایاس

بایاس (Bias) پارامتر قابل‌یادگیری‌ای است که به مدل اجازه می‌دهد خروجی را مستقل از حاصل‌ضرب وزن‌ها و ورودی جابه‌جا کند. استاد برای شهود از «تخمین کرایهٔ تاکسی» مثال زد: حتی اگر سفر لغو شود (مسافت صفر) هنوز یک هزینهٔ پایه وجود دارد. بایاس همین مقدار پایه را یاد می‌گیرد. اگر بایاس را صفر بگیریم، مدلی «عمومی و بدون هیچ پیش‌فرض» فرض کرده‌ایم، در حالی که در دنیای واقعی پیش‌فرض‌هایی هست که مدل باید یاد بگیرد تا دقیق‌تر تنظیم شود. از نظر هندسی بایاس رابطه را از اجبار عبور از مبدأ آزاد می‌کند.

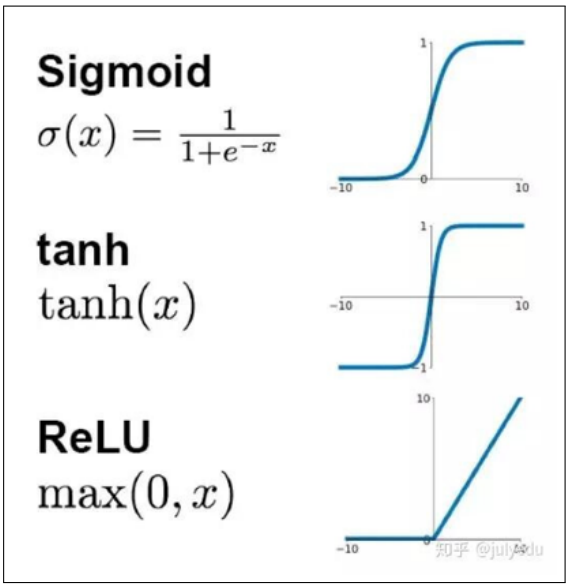
تابع فعال‌سازی

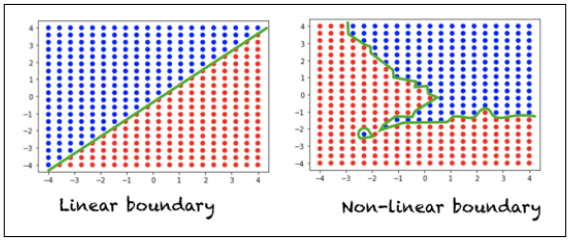
اگر فقط ضرب ماتریسی و جمع بایاس داشته باشیم، ترکیب هر تعداد لایه همچنان یک تبدیل خطی (آفین) است. اما مرزِ بین مفاهیم در دنیای واقعی منحنی، دایره‌ای، پیچ‌درپیچ و چندبُعدی است. **تابع فعال‌سازی** (Activation Function) روی خروجی تک‌تک نورون‌ها اعمال می‌شود و رفتار کل شبکه را نسبت به ورودی از یک خط صاف به یک خط شکسته یا منحنی تبدیل می‌کند:

$$a = f(z).$$

توابع رایج: Sigmoid، tanh و ReLU. تابع Sigmoid و مشتق آن (که در پس‌انتشار لازم می‌شود) چنین است:

$$\sigma(z) = \frac{۱}{۱ + e^{-z}}, \qquad \sigma'(z) = \sigma(z)\big(۱ - \sigma(z)\big).$$





شکل ۸.۶: سمت راست: توابع Sigmoid، tanh و ReLU با نمودارشان. سمت چپ: مرز تصمیم خطی در برابر مرز غیرخطی؛ تابع فعال‌سازی امکان یادگیری مرزهای غیرخطی را فراهم می‌کند. (برگرفته از تختهٔ کلاس)

۳.۳.۸ خروجی و تابع خطا

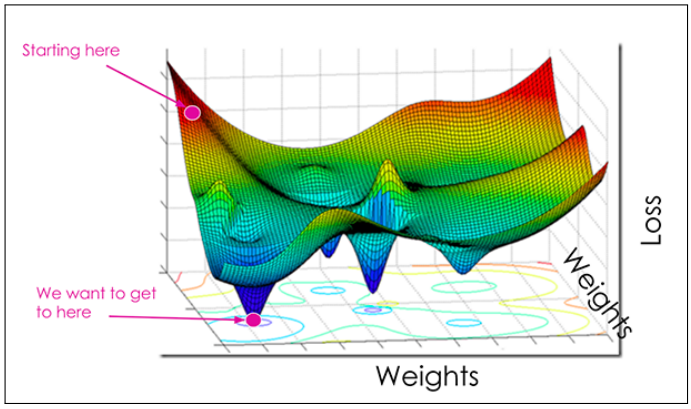
پس از تولید خروجی، آن را با Ground Truth مقایسه می‌کنیم. یکی از توابع خطا، **میانگین مربعات خطا** (Mean Squared Error) است:

$$\text{MSE} = \frac{۱}{n}\sum_{i=۱}^{n}(y_i - \hat{y}_i)^۲,$$

که n تعداد نمونه‌ها یا مؤلفه‌های ارزیابی، y_i مقدار واقعی و $\hat{y}_i$ مقدار پیش‌بینی‌شده است. هدف آموزش کاهش این مقدار است. (طراحی لایهٔ خروجی و انتخاب تابع خطای مناسب هر نوع مسئله در جلسهٔ بعد تکمیل می‌شود.)

۴.۳.۸ چشم‌انداز خطا و کاهش گرادیان

استاد برای توضیح کاهش خطا از مفهوم **چشم‌انداز خطا** (Loss Landscape) استفاده کرد: سطحی که «ارتفاع» آن مقدار خطا و بقیهٔ ابعادش مقادیر وزن‌هاست. با تغییر وزن‌ها، جای ما روی این سطح عوض می‌شود و هدف رسیدن به نواحی با خطای کم‌تر است.



شکل ۷.۸: چشم‌انداز خطا: محورهای افقی وزن‌ها و محور عمودی مقدار خطاست. از نقطهٔ شروع («Starting here») باید به نقطهٔ کمینه («We want to get to here») برسیم. (برگرفته از تختهٔ کلاس)

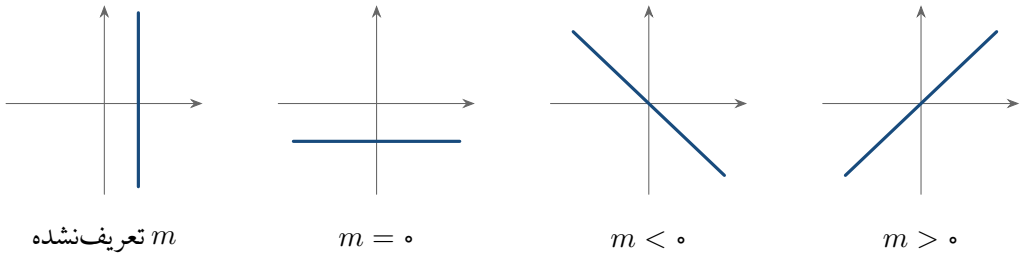
برای تعیین جهت حرکت، مشتق خطا را نسبت به وزن‌ها محاسبه می‌کنیم. اگر مشتق (شیب) مثبت باشد، یعنی با افزایش وزن خطا زیاد می‌شود؛ پس باید در جهت مخالف شیب حرکت کنیم. به بیان استاد: «اگر از لاس مشتق بگیریم و مثبت شد، آن را در منفی ضرب می‌کنیم.» این ایده، مبنای **کاهش گرادیان** (Gradient Descent) است.

قاعده‌به‌روزرسانی و نرخ یادگیری

$$\boxed{w_{\text{new}} = w_{\text{old}} - \eta \frac{\partial E}{\partial w}}$$

در این رابطه η **نرخ یادگیری** (Learning Rate) یا اندازهٔ گام (step size) است:

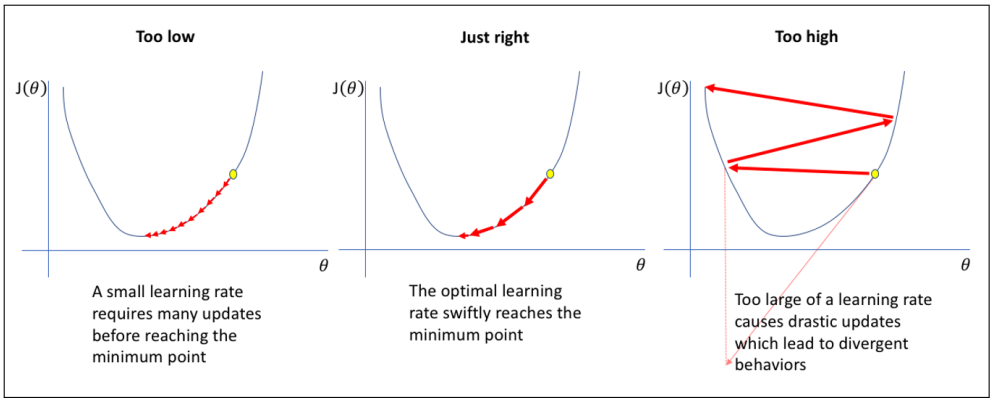
- اگر بسیار کوچک باشد، حرکت به‌سوی کمینه کند است؛



شکل ۸.۸: چهار حالت شیب خط مماس: شیب تعریف‌نشده (خط قائم)، شیب صفر (خط افقی)، شیب منفی و شیب مثبت. علامت شیب جهت لازم برای حرکت به‌سوی کمینه را مشخص می‌کند. (بازسازی‌شده از تختهٔ کلاس)

- اگر مناسب باشد، مدل به‌خوبی همگرا می‌شود؛
- اگر بسیار بزرگ باشد، مدل از ناحیهٔ کمینه می‌پرد و ممکن است همگرا نشود.

استاد افزود: تا زمانی که واقعیت و تخمین مساوی نشده‌اند، یعنی هنوز چیزی برای یادگیری وجود دارد.



شکل ۹.۸: اثر نرخ یادگیری: بسیار کوچک (گام‌های ریز و کند)، مناسب (رسیدن سریع به کمینه) و بسیار بزرگ (نوسان و واگرایی). (برگرفته از تختهٔ کلاس)

[محتوای افزوده] مثال عددی: اثر نرخ یادگیری

تابع ساده $E(w) = w^۲$ را با مشتق $E'(w) = ۲w$ در نظر بگیرید و از $w_۰ = ۴$ شروع کنید. قاعدهٔ به‌روزرسانی چنین می‌شود: $w \leftarrow w - \eta \cdot ۲w = (۱ - ۲\eta)\, w$.

η	$w_۰$	$w_۱$	$w_۲$	رفتار
۰٫۱	۴	۳٫۲	۲٫۵۶	همگرایی کند
۰٫۵	۴	۰	۰	همگرایی یک‌گامی
۱٫۱	۴	−۴٫۸	۵٫۷۶	واگرایی (نوسان با دامنهٔ فزاینده)

۵.۳.۸ پس‌انتشار و قانون زنجیره‌ای

باید بدانیم هر وزن چه سهمی در خطای خروجی داشته است. این کار با مشتق‌گیری و **قانون زنجیره‌ای** (Chain Rule) انجام می‌شود و به آن **پس‌انتشار** (Backpropagation) می‌گویند. استاد با شبکه‌ای ساده نشان داد: ورودی، سپس نورون پنهان با خروجی h، و سپس نورون خروجی که از طریق وزن $w_۵$ به آن وصل است. خروجی خطی و فعال‌شدهٔ آن را چنین می‌گیریم:

$$\text{net} = h\,w_۵ + \cdots, \qquad o = \sigma(\text{net}), \qquad E = \tfrac{۱}{۲}\,(y - o)^۲.$$

برای مشتق خطا نسبت به $w_۵$ زنجیره را باز می‌کنیم:

$$\frac{\partial E}{\partial w_۵} = \frac{\partial E}{\partial o} \cdot \frac{\partial o}{\partial\,\text{net}} \cdot \frac{\partial\,\text{net}}{\partial w_۵}.$$

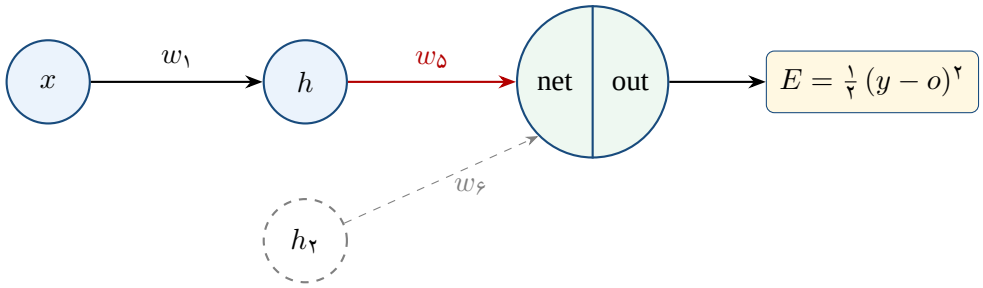
سه جزء عبارت‌اند از

$$\frac{\partial E}{\partial o} = o - y, \qquad \frac{\partial o}{\partial\,\text{net}} = o(۱ - o), \qquad \frac{\partial\,\text{net}}{\partial w_۵} = h,$$

و در نتیجه

$$\boxed{\frac{\partial E}{\partial w_۵} = (o - y)\,o\,(۱ - o)\,h}$$

(در تختهٔ کلاس همین نتیجه به‌صورت $-(y - o) \cdot o(۱ - o) \cdot h$ نوشته شد.)



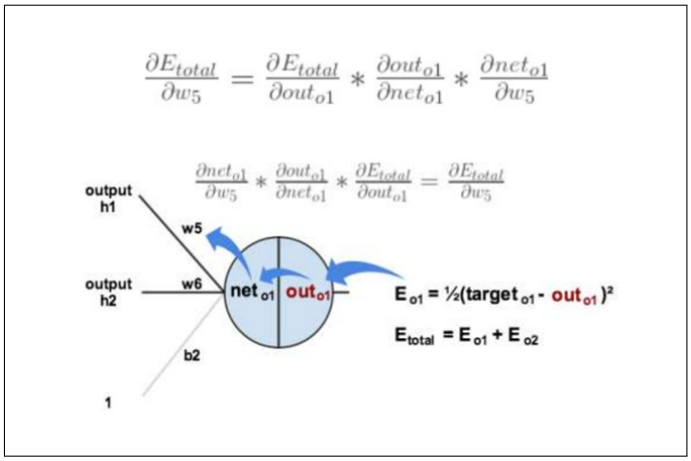
شکل ۱۰.۸: شبکهٔ ساده‌ای که استاد برای پس‌انتشار کشید و محاسبهٔ $\partial E/\partial w_۵$ با قانون زنجیره‌ای (روی تخته نورون خروجی با دو بخش «net» و «out» نمایش داده شده بود). (بازسازی‌شده از تختهٔ کلاس)

دقت در علامت و ضریب مشتق

در توضیح شفاهی کلاس، علامت و ضریب مشتق خطا به‌دقت تثبیت نشد. نتیجهٔ بالا برای تابع خطای $E = \frac{۱}{۲}(y - o)^۲$ است؛ ضریب $\frac{۱}{۲}$ فقط برای ساده‌شدن مشتق گذاشته می‌شود. اگر تابع خطای دیگری (مثلاً MSE با میانگین‌گیری یا Cross-Entropy) به کار رود، جزء $\partial E/\partial o$ و ضریب نهایی تغییر می‌کند و باید مطابق تعریف دقیق تابع خطا محاسبه شود.

[محتوای افزوده] مثال عددی: یک نورون، یک گام پیش‌رو و یک گام یادگیری

نورونی با دو ورودی $\mathbf{x} = (۲, ۱)$، وزن‌های $\mathbf{w} = (۰/۴, -۰/۳)$، بایاس $b = ۰/۱$، تابع فعال‌سازی Sigmoid و هدف $y = ۱$ را در نظر بگیرید.



شکل ۱۱.۸: بسط قانون زنجیره‌ای روی نمودار یک نورون خروجی (جمع net، فعال‌سازی out و خطای $\frac{1}{2}(\text{target} - \text{out})^2$). (برگرفته از تختهٔ کلاس)

پیش‌رو: $z = ۰٫۴۰۲ + (-۰٫۳)\cdot ۰٫۱ + ۰٫۱ = ۰٫۶$ و $o = \sigma(۰٫۶) \approx ۰٫۶۴۶$. خطا: $E = \frac{1}{2}(۱ - ۰٫۶۴۶)^2 \approx ۰٫۰۶۲۸$.

پس‌انتشار: $\delta = (o-y)\,o\,(۱-o) = (-۰٫۳۵۴)(۰٫۶۴۶)(۰٫۳۵۴) \approx -۰٫۰۸۱۱$. پس

$$\frac{\partial E}{\partial w_۱} = \delta\, x_۱ \approx -۰٫۱۶۲, \qquad \frac{\partial E}{\partial w_۲} = \delta\, x_۲ \approx -۰٫۰۸۱, \qquad \frac{\partial E}{\partial b} = \delta \approx -۰٫۰۸۱.$$

به‌روزرسانی با $\eta = ۱$: $w_۱ \approx ۰٫۵۶۲$، $w_۲ \approx -۰٫۲۱۹$ و $b \approx ۰٫۱۸۱$. اکنون $z \approx ۱٫۰۸۶$، $o \approx ۰٫۷۴۸$ و $E \approx ۰٫۰۳۱۸$؛ یعنی خطا تقریباً نصف شد. این چرخهٔ «پیش‌رو، خطا، پس‌انتشار، به‌روزرسانی» بارها تکرار می‌شود.

در مجموع، چرخهٔ آموزش شامل پنج گام است: مقداردهی اولیهٔ تصادفی، Feedforward، تولید خروجی، محاسبهٔ Loss و در نهایت Backpropagation همراه با بهینه‌سازی (به‌روزرسانی وزن‌ها).

۴.۸ مسئلهٔ هم‌نویسه در TTS

اکنون به مسئلهٔ اصلی بازمی‌گردیم: تشخیص تلفظ درست کلماتی که نوشتارشان یکسان است. **هم‌نویسه** (Homograph) کلمه‌ای است که شکل نوشتاری یکسان اما تلفظ (و معمولاً معنای) متفاوت دارد. در فارسی چون بیشتر مصوت‌های کوتاه نوشته نمی‌شوند، این مسئله اهمیت ویژه‌ای دارد.

استاد جملهٔ زیر را (که روی تخته نیز بود) نمونه‌ای از وجود چند هم‌نویسه در یک متن می‌دانست: «آن مرد پس از مدت‌ها بیماری در بیمارستان مرد و سرم را از دستش کشیدند. خواهرم گفت: سرم به شدت درد می‌کند.» در این جمله «مرد» دو بار با دو تلفظ و «سرم» دو بار با دو تلفظ و معنا آمده است.

جدول ۲.۸: نمونه‌های هم‌نویسه در فارسی (آوانویسی تقریبی افزوده شده است)

کلمه	بافت اول	بافت دوم
کرم	کرم مرطوب‌کننده (kerem)	کرم خاکی (kerm)
مرد	آن مرد وارد شد (mard)	او از دنیا مرد (mord)
سرم	سرم به شدت درد می‌کند (saram)	سرم را از دستش کشیدند (serom)

«شیر» هم‌نویسهٔ تلفظی نیست

در کلاس «شیر آب»، «شیر جنگل» و «شیر خوراکی» برای نشان‌دادن مسئله به کار رفت. اما هر سه به یک شکل، یعنی /ʃir/، تلفظ می‌شوند؛ «شیر» یک کلمهٔ چندمعنایی (هم‌آوا و هم‌نویسه، Homonym) است نه هم‌نویسهٔ دارای تلفظ‌های متفاوت. برای TTS فقط مواردی مسئله‌ساز است که تلفظ‌ها متفاوت باشند (مانند «کرم» و «مرد»)؛ با این حال «شیر» مثال بسیار خوبی برای نشان‌دادن محدودیت Embedding ثابت و نیاز به بافت در فهم معناست. در بخش‌های بعد «شیر» را در همین نقش، و «کرم» را برای انتخاب تلفظ به کار می‌بریم.

۱.۴.۸ نقش برچسب‌گذاری نقش دستوری

گاهی **برچسب‌گذاری اجزای کلام** (POS Tagging) برای تشخیص تلفظ کافی است: در «او مُرد» فعل و در «آن مَرد رفت» اسم است و یک برچسب‌زن نحوی با تکیه بر دستور جمله تلفظ درست را مشخص می‌کند. اما همیشه کافی نیست: «کِرم خاکی» و «کِرمِ مرطوب‌کننده» هر دو اسم‌اند و برچسب دستوری کمکی نمی‌کند؛ به اطلاعات معنایی و بافتی، یعنی بازنمایی وابسته به بافت (Contextual Embedding) نیاز است.

۲.۴.۸ چرا Embedding برای رفع ابهام مهم است؟

برای تشخیص تلفظ باید رابطهٔ کلمه با کلمات اطرافش را بدانیم. «کرم خاکی» با واژه‌هایی چون باغچه، خاک و زمین هم‌وقوعی دارد و «کرم مرطوب‌کننده» با پوست، آرایش و محصولات بهداشتی. پس بازنمایی کلمه باید تا حد امکان اطلاعات بافت را در خود داشته باشد؛ این ما را به روش‌های یادگیری Embedding بر پایهٔ بافت می‌رساند.

۵.۸ Embedding ایستا و Word2Vec

الگوریتم Word2Vec (Word2Vec) بر پایهٔ ارتباط هر کلمه با کلمات اطرافش آموزش می‌بیند و دو معماری اصلی دارد: CBOW و Skip-gram. بردارهای حاصل **ایستا** (Static) هستند: برای هر مدخل واژگان یک بردار ثابت.

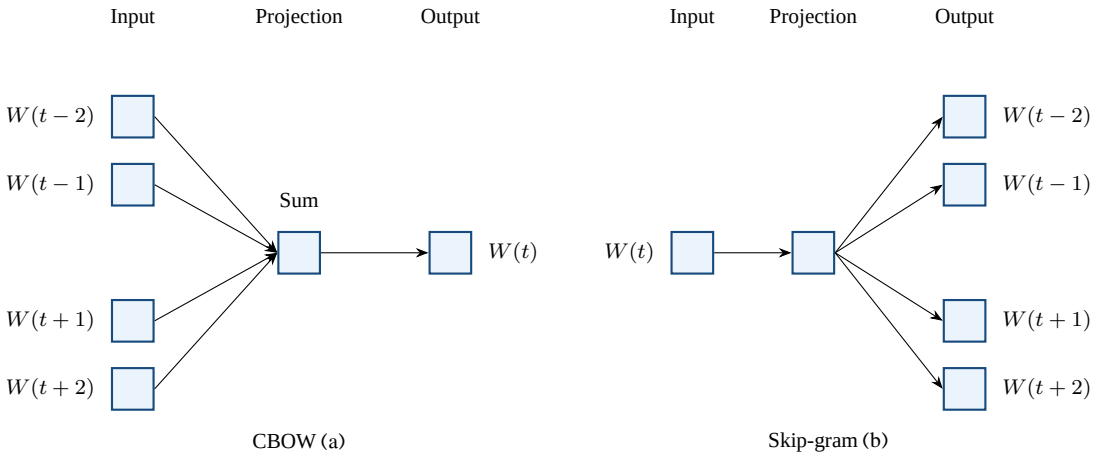
۱.۵.۸ معماری CBOW

در **کیسهٔ کلمات پیوسته** (Continuous Bag of Words) کلمات داخل یک **پنجره‌بافت** (Context Window) به مدل داده می‌شوند و مدل کلمهٔ مرکزی را پیش‌بینی می‌کند. مثلاً از «من، امروز، دانشگاه، رفتم» باید «به» را حدس بزنند. در این معماری بازنمایی کلمات اطراف با هم ترکیب (جمع یا میانگین) می‌شوند.

۲.۵.۸ معماری Skip-gram

در Skip-gram جهت پیش‌بینی برعکس است: کلمهٔ مرکزی ورودی است و مدل کلمات اطراف را پیش‌بینی می‌کند؛ مثلاً از «دکتر» باید «مراجعه، کردم، به، امروز» را حدس بزنند. به بیان کوتاه: CBOW: بافت ← کلمهٔ هدف؛ Skip-gram: کلمهٔ هدف ← بافت.

Word2Vec — Static Embedding: یک بردار ثابت برای هر کلمه
در زمان آموزش: Context-Based model
در زمان استنتاج: Context-independent



هدف: پیش‌بینی کلمهٔ هدف (Target) با استفاده از کلمات پیرامون (Context).

هدف: پیش‌بینی کلمات پیرامون (Context) با دریافت یک کلمهٔ ورودی (Target).

برای کاری که کلمات نادر (Rare words) زیادی دارد کدام بهتر است؟

شکل ۸.۱۲: دو معماری Word2Vec: CBOW و Skip-gram، همراه با یادداشت‌های استاد روی تخته. (بازسازی‌شده از تختهٔ کلاس)

دقت دربارهٔ CBOW

در CBOW بازنمایی کلمات پنجره معمولاً میانگین‌گیری یا جمع می‌شود (در شکل «Sum») و ترتیب کلمات در آن نقشی ندارد؛ از اینجا نام «کیسهٔ کلمات» می‌آید. در نتیجه، همهٔ کلمات اطراف سهم برابر دارند و کلمهٔ بسیار مهم (مثلاً «مریض» برای پیش‌بینی «دکتر» در «من مریض شدم و به دکتر رفتم») نمی‌تواند وزن بیشتری بگیرد. همین

نبودِ وزن‌دهی انگیزهٔ مهمی برای سازوکار Attention است (بخش ۱۰.۸).

۳.۵.۸ پرسش استاد: برای کلمات نادر کدام بهتر است؟

پاسخ مورد تأکید: Skip-gram. دلیل: در CBOW کلمهٔ نادر فقط در جایگاه «هدف» قرار می‌گیرد و چون اطلاعات بافتی چند کلمه در یک بردار ادغام می‌شود، فرصت‌های یادگیری آن کم است. در Skip-gram کلمهٔ نادر خودش ورودی است و هر رخداد آن چند جفت آموزشی (کلمه، همسایه) می‌سازد؛ در نتیجه حتی رخدادهای محدود اطلاعاتی دربارهٔ نقش و همسایگی کلمه به مدل می‌دهند. استاد افزود که اگر داده نویز نداشته باشد، حتی یک رخداد نیز ممکن است اطلاعات مفیدی (مثلاً نقش نحوی) بدهد؛ البته یادگیری از نمونهٔ بسیار اندک همچنان محدود است و بازنمایی ممکن است بیش از حد به همان بافت وابسته شود.

جدول ۳.۸: مقایسهٔ CBOW و Skip-gram

ویژگی	CBOW	Skip-gram
ورودی	کلمات اطراف	کلمهٔ مرکزی
خروجی	کلمهٔ مرکزی	کلمات اطراف
استفاده از بافت	ترکیب اطلاعات کلمات اطراف	پیش‌بینی جداگانهٔ هر کلمهٔ بافت
کلمات نادر	دشوارتر یادگرفته می‌شوند	معمولاً مناسب‌تر است
نوع Embedding نهایی	ایستا	ایستا

۴.۵.۸ پس از پایان آموزش چه می‌کنیم؟

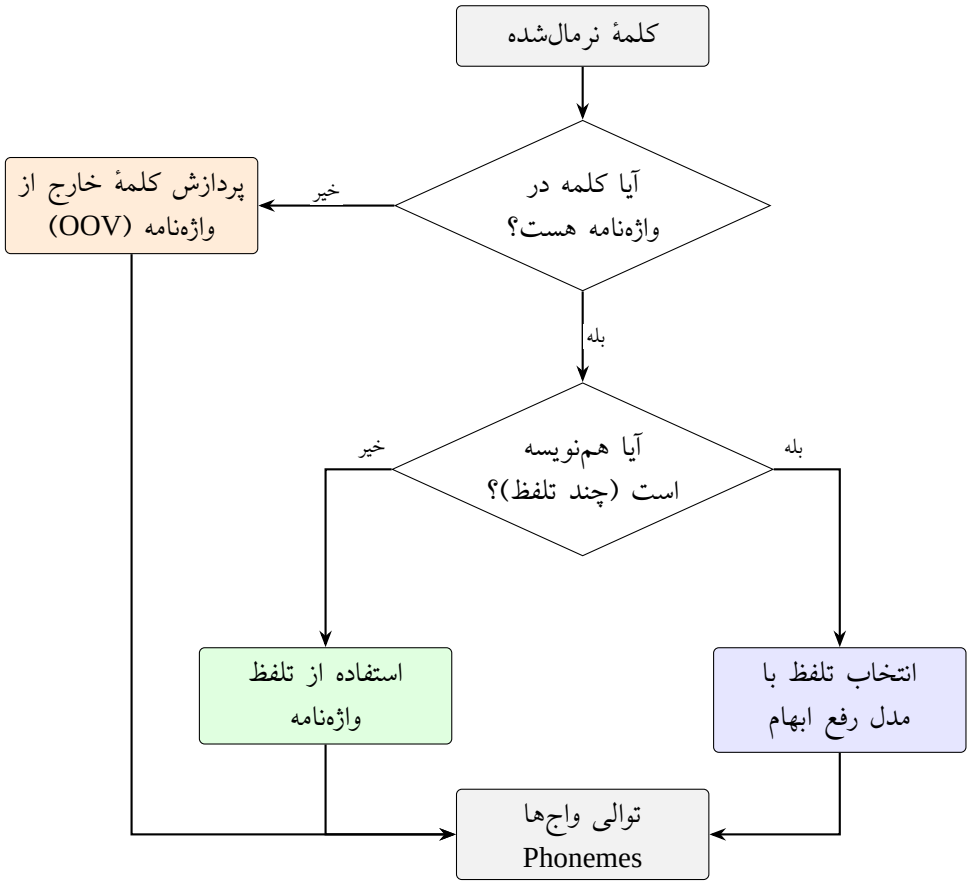
هنگام آموزش، وزن‌های شبکه تغییر می‌کنند و بخشی از آن‌ها همان بازنمایی کلمات است. پس از آموزش لازم نیست کل شبکه را نگه داریم: بردارهای Embedding را استخراج می‌کنیم و در وظایف دیگر NLP (از جمله تشخیص تلفظ) به کار می‌بریم؛ این همان ایدهٔ Embeddingهای ازپیش‌آموزش‌دیده است.

چند نکتهٔ فنی دربارهٔ Word2Vec

(۱) Word2Vec عملاً دو ماتریس دارد (ماتریس ورودی و ماتریس خروجی)؛ بردار مورد استفاده معمولاً از ماتریس ورودی، یعنی همان «جدول جست‌وجو»، برداشته می‌شود. (۲) در عمل برای کاهش هزینهٔ لایهٔ خروجی با واژگان بزرگ از روش‌هایی مانند Negative Sampling یا Hierarchical Softmax استفاده می‌شود. (۳) CBOW معمولاً سریع‌تر آموزش می‌بیند و برای کلمات پرتکرار خوب است، Skip-gram کندتر است ولی برای کلمات نادر بهتر؛ این با توضیح استاد سازگار است.

۶.۸ گردش کار تشخیص تلفظ در یک سامانهٔ TTS

پس از نرمال‌سازی متن، برای هر کلمه باید معلوم کنیم تلفظش از کجا می‌آید. شکل زیر گردش کاری است که استاد روی تخته ترسیم کرد.



شکل ۱۳.۸: گردش کار تعیین تلفظ پس از نرمال‌سازی: کلمات واژه‌نامه‌ای با یک تلفظ مستقیماً از واژه‌نامه خوانده می‌شوند، کلمات چندتلفظی به مدل رفع ابهام سپرده می‌شوند و کلمات OOV مسیر جداگانه دارند (شکل افزوده، بر پایهٔ تختهٔ کلاس).

در این معماری برای کلماتی که چند تلفظ دارند باید مدلی باشد که با نگاه به بافت، تلفظ درست را برگزیند. روش دقیق پردازش OOV در این جلسه توضیح داده نشد و تمرکز بر شاخهٔ رفع ابهام هم‌نویسه‌ها بود.

۷.۸ محدودیت Embedding ایستا در تشخیص هم‌نویسه

مهم‌ترین نکتهٔ جلسه تفاوت میان دو چیز است: Embeddingای که در زمان آموزش بر پایهٔ بافت ساخته شده، و Embeddingای که در زمان استفاده به بافت جملهٔ جدید وابسته است.

۱.۷.۸ مسئله

فرض کنید کلمهٔ «کرم» در دو جمله آمده: «کرم خاکی در باغچه بود» و «کرم مرطوب‌کننده را روی پوست زدم». در Word2Vec برای «کرم» یک بردار ثابت داریم:

$$E(\text{کرم در جملهٔ اول}) = E(\text{کرم در جملهٔ دوم}).$$

بردار ثابت در زمان آموزش تحت تأثیر همهٔ بافت‌های کلمه ساخته شده است (به‌نوعی «میانگین» آن‌ها)، اما در زمان استفاده برای همهٔ رخدادها یکسان است و دیگر به جملهٔ جدید نگاه نمی‌کند. بنابراین نمی‌توان انتظار داشت بردار ثابت به‌تنهایی تلفظ درست را در هر جمله تعیین کند.

۲.۷.۸ راه‌حل با Embedding ثابت: افزودن یک مدل انتخاب تلفظ

استاد پیشنهاد کرد در کنار Embedding ثابت یک مدل انتخاب تلفظ بگذاریم:

۱. Embedding ثابت کلمات را داریم؛

۲. کلمات اطراف هم‌نویسه را نیز به مدل می‌دهیم؛

۳. بخش پیش‌بینی‌کننده را با داده‌های دارای برچسب تلفظ آموزش می‌دهیم؛

۴. مدل بر پایهٔ بافت، تلفظ مناسب را انتخاب می‌کند.

یعنی اطلاعات بافت در مدل طبقه‌بند پردازش می‌شود، نه در خود بردار ثابتِ کلمهٔ هدف.

۳.۷.۸ استفاده از طبقه‌بند و Softmax

فرض کنید برای کلمه‌ای سه تلفظ ممکن $P_۱, P_۲, P_۳$ در واژه‌نامه باشد. مدل برای هر تلفظ یک امتیاز (logit) $\mathbf{z} = (z_۱, z_۲, z_۳)$ می‌دهد و با Softmax آن‌ها را به احتمال تبدیل می‌کنیم، که C اطلاعات بافت است:

$$P(P_i \mid C) = \frac{e^{z_i}}{\sum_j e^{z_j}}, \qquad \hat{P} = \arg\max_i P(P_i \mid C).$$

برای نمونه اگر مدل احتمال‌های ۰٫۱۰، ۰٫۷۵ و ۰٫۱۵ را برگرداند، تلفظ دوم انتخاب می‌شود (این اعداد صرفاً برای توضیح سازوکارند).

[محتوای افزوده] مثال عددی: از امتیاز تا احتمال

فرض کنید امتیازهای مدل برای سه تلفظ $\mathbf{z} = (۰٫۵,\ ۲٫۴,\ ۰٫۹)$ باشد. آنگاه $e^z = (۱٫۶۵,\ ۱۱٫۰۲,\ ۲٫۴۶)$، مجموع $\approx ۱۵٫۱۳$ و

$$P = (۰٫۱۰۹,\ ۰٫۷۲۸,\ ۰٫۱۶۳),$$

که مجموعشان ۱ است و تلفظ دوم برنده است. توجه کنید Softmax تفاوت امتیازها را «تیزتر» می‌کند: اختلاف ۱٫۵ تا ۱٫۹ واحد در امتیاز، نسبت احتمال را حدود ۷ برابر کرده است.

داده‌آموزشی طبقه‌بند

برای آموزش مدل انتخاب تلفظ باید جملاتی داشته باشیم که تلفظ درست کلمه در آن‌ها مشخص باشد (مثلاً جمله‌ای که «کرم» در آن محصول آرایشی است و جمله‌ای که موجود زنده است). مدل از روی این نمونه‌ها یاد می‌گیرد کدام الگوهای بافتی با کدام تلفظ همراه‌اند و در زمان استنتاج برای جملهٔ جدید یکی از گزینه‌های موجود را برمی‌گزینند.

اگر تعداد تلفظ‌ها متفاوت باشد؟

اگر کلمه‌ای دو و کلمهٔ دیگر سه تلفظ داشته باشد، خروجی طبقه‌بند چه شکلی دارد؟ پاسخ استاد: می‌توان در بخش خروجی از یک لایهٔ خطی (Linear Layer) و سپس Softmax استفاده کرد؛ نکتهٔ مهم این است که مجموعهٔ گزینه‌های تلفظ از پیش مشخص باشد و نگاشت خروجی‌ها به گزینه‌ها با معماری سازگار باشد. معماری دقیق مدیریت تعداد متغیر تلفظ‌ها در این جلسه نهایی نشد و قرار شد در جلسهٔ بعد بررسی شود.

۸.۸ چرا همهٔ تلفظ‌ها را از ابتدا برچسب نمی‌زنیم؟

یکی از دانشجویان پیشنهاد کرد از همان ابتدا برای هر تلفظ یک بازنمایی جداگانه داشته باشیم (مثلاً «کرم۱»، «کرم۲»، «کرم۳»)؛ در این صورت مدل برای هر یک Embedding مجزا یاد می‌گیرد. استاد توضیح داد که از نظر مفهومی ممکن است، اما مشکل اساسی آن است: چه کسی باید تمام رخدادهای کلمات چندتلفظی را برچسب بزند؟ برای یک مجموعهٔ بزرگ باید مشخص شود هر کلمه در هر جمله کدام تلفظ را دارد؛ در فارسی ممکن است لازم باشد بخش بزرگی از متن اعراب‌گذاری یا تلفظ کلمات مبهم دستی تعیین شود. این فرایند بسیار پرهزینه است.

تأکید استاد

برچسب‌گذاری (Annotation) یکی از گلوگاه‌های مهم توسعهٔ سامانه‌های هوش مصنوعی است.

۱.۸.۸ راه‌حل: وظایفی که برچسب خودکار دارند

یکی از دلایل موفقیت مدل‌های زبانی بزرگ این بود که توانستند از حجم عظیمی از متن بی‌برچسب استفاده کنند. به‌جای اینکه انسان برای هر جمله برچسب تهیه کند، وظیفه‌ای تعریف می‌کنیم که پاسخش از خود متن به‌دست می‌آید:

- **مدل‌سازی زبان نقاب‌دار** (Masked Language Modeling) (MLM): برخی کلمات پنهان می‌شوند و مدل باید آن‌ها را پیش‌بینی کند؛
- **پیش‌بینی جملهٔ بعدی** (Next Sentence Prediction) (NSP): در مدل اولیهٔ BERT، مدل یاد می‌گیرد آیا یک جمله ادامهٔ جملهٔ دیگری است یا نه.

برای ساخت دادهٔ این وظایف، نیازی به تعیین دستی تلفظ همهٔ کلمات نیست؛ مدل از ساختار و روابط خود متن یاد می‌گیرد.

دقت دربارهٔ NSP

NSP در مقالهٔ اولیهٔ BERT به کار رفت، اما در پژوهش‌های بعدی (مانند RoBERTa) نشان داده شد که حذف آن آسیبی به کیفیت نمی‌زند و بسیاری از مدل‌های جدید فقط از شکلی از MLM یا پیش‌بینی توکن بعدی استفاده می‌کنند. بنابراین MLM را باید وظیفهٔ اصلی و NSP را یک نمونهٔ تاریخی دانست. جزئیات BERT در جلسهٔ بعد می‌آید.

۲.۸.۸ یادگیری خودنظارتی

این نوع آموزش در چارچوب **یادگیری خودنظارتی** (Self-Supervised Learning) قرار می‌گیرد: سیگنال آموزشی از خود داده استخراج می‌شود. نتیجه:

- نیاز به برچسب‌گذاری دستی کاهش می‌یابد؛
- استفاده از داده‌های متنی بسیار بزرگ ممکن می‌شود؛
- مدل بازنمایی‌های عمومی زبان را می‌آموزد؛
- بعداً می‌توان آن را برای وظایف تخصصی تنظیم دقیق کرد.

یادگیری نظارتی در برابر خودنظارتی

در **یادگیری نظارتی** (Supervised Learning) انسان داده را برچسب می‌زند (مثلاً جمله را «مثبت» یا «منفی» می‌کند). در یادگیری خودنظارتی برچسب از خود داده ساخته می‌شود، مثلاً کلمهٔ حذف‌شده از متن اصلی. استاد تأکید کرد یکی از جهش‌های بزرگ مدل‌های زبانی همین استفاده از داده‌های عظیم و وظایف قابل‌استخراج از خود متن بود.

۹.۸ Embedding وابسته به بافت (پویا)

پس از دیدن محدودیت Embedding ایستا، پرسش این است: چگونه Embedding را طوری بسازیم که برای هر جمله و بر پایهٔ بافت همان جمله تغییر کند؟ پاسخ، **Embedding وابسته به بافت** (Contextual Embedding) (یا پویا، Dynamic) است.

۱.۹.۸ مقایسهٔ ایستا و وابسته به بافت

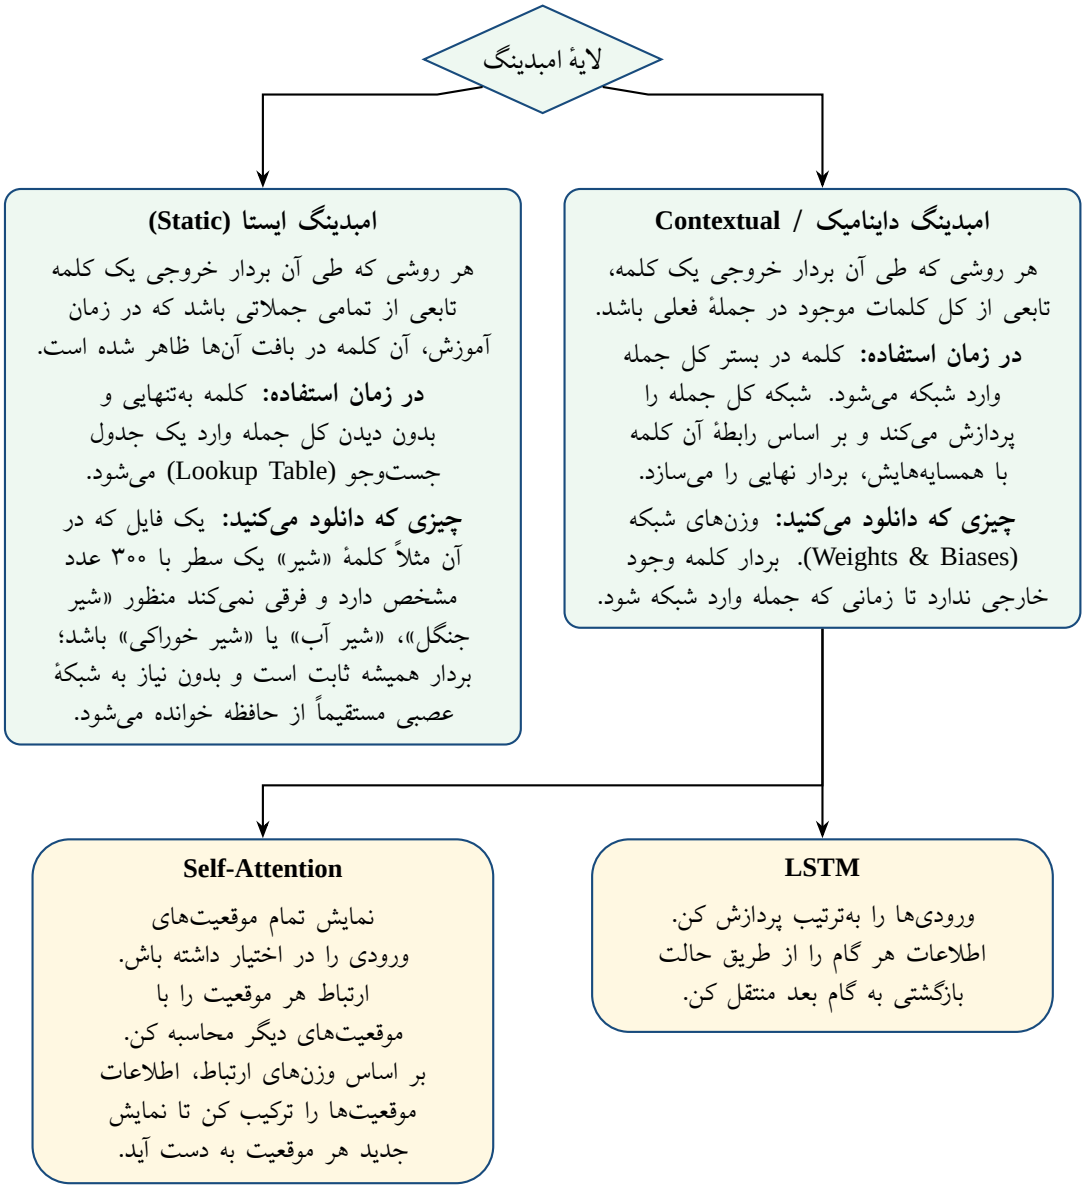
در بازنمایی ایستا

$$E(w) = \mathbf{v}_w,$$

بردار فقط به هویت کلمه بستگی دارد. در بازنمایی وابسته به بافت

$$E(w, C) = \mathbf{v}_{w,C},$$

که C جملهٔ حاوی کلمه است، و ممکن است $E(\text{کرم}, C_۱) \neq E(\text{کرم}, C_۲)$.



شکل ۱۴.۸: دو نوع لایهٔ Embedding. چپ: Embedding ایستا (بردار تابعی از همهٔ جمله‌هایی است که کلمه در زمان آموزش در آن‌ها دیده شده؛ در زمان استفاده فقط یک جدول جست‌وجو). راست: Embedding پویا (بردار تابعی از کل کلمات جملهٔ فعلی است؛ چیزی که دانلود می‌کنید وزن‌های شبکه است). دو بیضی پایین دو راه ساخت آن را نشان می‌دهند: Self-Attention و LSTM. (بازسازی‌شده از تختهٔ کلاس)

۲.۹.۸ هدف

مدل هنگام دریافت یک جمله باید: (۱) کلمات جمله را دریافت کند، (۲) برای ساخت بازنمایی هر کلمه سایر کلمات را در نظر بگیرد، (۳) اهمیت ارتباط هر کلمه با بقیه را بسنجد و (۴) بازنمایی متناسب با همین رخداد را بسازد. مثلاً برای

جدول ۴.۸: مقایسهٔ دو نوع Embedding به روایت تختهٔ کلاس

	ایستا	وابسته به بافت
تعریف	بردار خروجی تابعی از همهٔ جمله‌هایی است که کلمه در زمان آموزش در بافتشان دیده شده	بردار خروجی تابعی از کل کلمات جملهٔ فعلی است
زمان استفاده	کلمه به‌تنهایی وارد جدول جست‌وجو می‌شود	کلمه در بستر جمله وارد شبکه می‌شود و شبکه بر پایهٔ رابطه با همسایه‌ها بردار نهایی را می‌سازد
چیزی که دانلود می‌کنید	فایلی که به‌ازای هر کلمه یک سطر (مثلاً ۳۰۰ عدد) دارد؛ «شیر» در هر معنایی همان بردار است و مستقیماً از حافظه خوانده می‌شود	وزن‌های شبکه (Weights & Biases)؛ بردار کلمه تا ورود جمله به شبکه وجود خارجی ندارد

«کرم» در یک جمله «خاک» و «باغچه» مهم‌اند و در جملهٔ دیگر «پوست» و «مرطوب‌کننده».

۱۰.۸ استفاده از Attention برای ساخت Embedding وابسته به بافت

یکی از راه‌های مهم ساخت بازنمایی وابسته به بافت، **سازوکار توجه** (Attention Mechanism) است. تختهٔ کلاس سه گام آن را چنین خلاصه کرد: (۱) نمایش همهٔ موقعیت‌های ورودی را در اختیار داشته باش؛ (۲) ارتباط هر موقعیت را با موقعیت‌های دیگر محاسبه کن؛ (۳) بر اساس وزن‌های ارتباط، اطلاعات موقعیت‌ها را ترکیب کن تا نمایش جدید هر موقعیت به‌دست آید. (راه دیگر ساخت بازنمایی پویا، پردازش ترتیبی با LSTM است که در تخته آمد و در جلسهٔ بعد بیشتر می‌آید.)

۱.۱۰.۸ ایدهٔ اصلی

به‌جای ترکیب یکسان همهٔ کلمات اطراف (مانند CBOW) مدل مشخص می‌کند هر کلمه چقدر به کلمهٔ موردنظر مرتبط است. مثلاً در جمله‌ای دربارهٔ «کرم خاکی»، ارتباط «کرم» با «خاک» می‌تواند بیش از ارتباط آن با یک کلمهٔ کم‌اهمیت باشد.

۲.۱۰.۸ مفاهیم Query، Key و Value

- **پرس‌وجو** (Query) (Q): نمایندهٔ چیزی که برایش اطلاعات مرتبط می‌جوییم (کلمهٔ هدف).
- **کلید** (Key) (K): برای سنجش میزان ارتباط هر کلمه با پرس‌وجو به کار می‌رود.
- **مقدار** (Value) (V): اطلاعاتی که با توجه به میزان ارتباط در ساخت خروجی شرکت می‌کند.

کلمهٔ هدف به‌عنوان Query با Key کلمات جمله مقایسه می‌شود؛ شباهت Query و Key میزان توجه به هر کلمه را می‌دهد و سپس Valueها با این وزن‌ها ترکیب می‌شوند تا بازنمایی جدید ساخته شود. ماتریس‌های وزنی Q، K و V در آموزش یاد گرفته می‌شوند و در زمان استنتاج ثابت‌اند؛ آنچه با جمله عوض می‌شود بردارهای Q، K و V محاسبه‌شده و در نتیجه بازنمایی خروجی است.

۳.۱۰.۸ نقش ضرب داخلی و فرمول کامل

برای سنجش ارتباط Query و Key از ضرب داخلی استفاده می‌شود: امتیاز $Q \cdot K$ هرچه بزرگ‌تر، سهم آن کلمه بیشتر. استاد تصریح کرد که Attention فقط یک ضرب ساده نیست و در این جلسه هدف درک شهودی بود. فرمول کامل **توجه ضرب داخلیِ مقیاس‌شده** (Scaled Dot-Product Attention) چنین است:

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V,$$

که d_k بُعد بردارهای Key است. تقسیم بر $\sqrt{d_k}$ از بزرگ‌شدن بیش از حد امتیازها در بُعد زیاد (و اشباع Softmax) جلوگیری می‌کند. Softmax امتیازهای هر سطر را به وزن‌های نامنفی با مجموع ۱ تبدیل می‌کند و ضرب در V ترکیب وزن‌دار مقدارها را می‌دهد.

[محتوای افزوده] مثال عددی: Self-Attention با دو توکن

جملهٔ بسیار کوتاه «کرم خاک» را با دو توکن در نظر بگیرید و برای سادگی $X = \begin{pmatrix} ۱ & ۰ \\ ۰ & ۱ \end{pmatrix}$ (سطر اول «کرم»، سطر دوم «خاک»). فرض کنید ماتریس‌های آموخته‌شده چنین باشند:

$$W_Q = \begin{pmatrix} ۱ & ۱ \\ ۰ & ۲ \end{pmatrix}, \quad W_K = \begin{pmatrix} ۲ & ۰ \\ ۰ & ۱ \end{pmatrix}, \quad W_V = \begin{pmatrix} ۱ & ۰ \\ ۱ & ۱ \end{pmatrix}.$$

آنگاه

$$Q = XW_Q = \begin{pmatrix} ۱ & ۱ \\ ۰ & ۲ \end{pmatrix}, \quad K = XW_K = \begin{pmatrix} ۲ & ۰ \\ ۰ & ۱ \end{pmatrix}, \quad V = XW_V = \begin{pmatrix} ۱ & ۰ \\ ۱ & ۱ \end{pmatrix}.$$

امتیازها پیش و پس از تقسیم بر $\sqrt{۲} \approx ۱٫۴۱۴$ چنین‌اند:

$$QK^\top = \begin{pmatrix} ۲ & ۱ \\ ۰ & ۲ \end{pmatrix} \longrightarrow \frac{QK^\top}{\sqrt{۲}} = \begin{pmatrix} ۱٫۴۱۴ & ۰٫۷۰۷ \\ ۰ & ۱٫۴۱۴ \end{pmatrix}.$$

Softmax روی هر سطر: در سطر اول $e^{۱٫۴۱۴} \approx ۴٫۱۱$ و $e^{۰٫۷۰۷} \approx ۲٫۰۳$ است، پس وزن‌ها ۰٫۶۷۰ ≈ $\frac{۴٫۱۱}{۶٫۱۴}$ و ۰٫۳۳۰ می‌شوند؛ در سطر دوم $e^{۰} = ۱$ و $e^{۱٫۴۱۴} \approx ۴٫۱۱$ و وزن‌ها ۰٫۱۹۶ و ۰٫۸۰۴ است. پس

$$A = \begin{pmatrix} ۰٫۶۷۰ & ۰٫۳۳۰ \\ ۰٫۱۹۶ & ۰٫۸۰۴ \end{pmatrix}, \qquad AV = \begin{pmatrix} ۰٫۶۷۰ \cdot (۱, ۰) + ۰٫۳۳۰ \cdot (۱, ۱) \\ ۰٫۱۹۶ \cdot (۱, ۰) + ۰٫۸۰۴ \cdot (۱, ۱) \end{pmatrix} = \begin{pmatrix} ۱٫۰۰ & ۰٫۳۳ \\ ۱٫۰۰ & ۰٫۸۰ \end{pmatrix}.$$

بازنمایی جدید «کرم» سطر اول AV است: ترکیبی با ۶۷٪ سهم از مقدار خودش و ۳۳٪ سهم از مقدار «خاک». اگر در جملهٔ دیگری کنار «کرم» توکنی مانند «پوست» بود، وزن‌های A و در نتیجه بردار خروجی متفاوت می‌شد؛ همین یعنی بازنمایی «وابسته به بافت».

۴.۱۰.۸ Self-Attention

وقتی کلمات یک توالی برای ساخت بازنمایی جدید خودشان به کلمات همان توالی توجه می‌کنند، از **خودتوجهی** (Self-Attention) صحبت می‌کنیم. اگر «کرم» در جمله‌ای با «خاکی» و «باغچه» بیاید، بازنمایی متناسب با موجود زنده ساخته می‌شود و اگر کنار «پوست» و «مرطوب‌کننده» بیاید، بازنمایی دیگری. به این ترتیب بخشی از مشکل Embedding ایستا برطرف می‌شود.

۵.۱۰.۸ ارتباط با Transformer

Self-Attention از اجزای اصلی معماری **ترنسفورمر** (Transformer) است که در ادامهٔ درس به آن می‌رسیم؛ این سازوکار به مدل کمک می‌کند برای هر توکن، اطلاعات سایر توکن‌های جمله را در نظر بگیرد. تفاوت اصلی از نگاه استاد: در Word2Vec بردار نهایی کلمه پس از آموزش ثابت است، اما در مدل مبتنی بر Self-Attention شبکه در زمان استنتاج نیز با هر جملهٔ جدید اجرا می‌شود و بازنمایی همان جمله را حساب می‌کند.

دقت درباره «بردار ثابت» و «بردار پویا»

بازنمایی وابسته به بافت به این معنا نیست که وزن‌های شبکه در استنتاج عوض می‌شوند؛ وزن‌ها ثابت‌اند و فقط خروجی به‌ازای جملهٔ ورودی متفاوت است. همچنین Contextual Embedding با Transformer یکی نیست: LSTM دوسویه (مانند ELMo) نیز بازنمایی وابسته به بافت می‌سازد؛ Attention یکی از راه‌هاست.

۱۱.۸ پرسش و پاسخ پایان کلاس

- **بخش پیشین (Front-End) در TTS دقیقاً چیست؟**
ماژول‌هایی که روی متنِ ورودی کاربر عمل می‌کنند؛ در مقابل، بخش پسین به بازنمایی‌های صوتی و تولید گفتار مربوط است و با مفاهیم هم‌نام در توسعهٔ وب یکی نیست.
- **آیا با Embedding ایستا می‌توان تلفظ هم‌نویسه را تشخیص داد؟**
بله، اما بردار ثابت یک کلمه کافی نیست؛ باید اطلاعات کلمات اطراف نیز به یک مدل پیش‌بینی داده شود که با داده‌های برچسب‌دار یاد بگیرد در هر بافت کدام تلفظ مناسب است.
- **آیا بهتر نیست برای هر تلفظ از ابتدا Embedding مجزا بسازیم؟**
از نظر طراحی می‌شود، ولی به داده‌های برچسب‌خورده و برچسب‌گذاری گستردهٔ پرهزینه نیاز دارد؛ از این رو پیش‌آموزش با یادگیری خودنظارتی اهمیت دارد.
- **طبقه‌بند چگونه تلفظ درست را می‌گزیند؟**
در خروجی برای هر گزینه امتیاز تولید می‌کند، با Linear Layer و Softmax احتمال را می‌سنجد و تلفظ با بیشترین احتمال را برمی‌گزیند؛ یادگیری این تصمیم نیازمند نمونه‌هایی از کلمه در بافت‌های مختلف همراه با تلفظ صحیح است.

- **آیا مباحث شبکهٔ عصبی باید با جزئیات بیشتری تدریس شوند؟**
  استاد از دانشجویان پرسید؛ به موضوعاتی مانند **مومنتوم** (Momentum) (بهینه‌سازی با «حافظهٔ» گام‌های قبلی) اشاره شد و قرار شد فعلاً همین سطح مقدماتی حفظ شود.

۱۲.۸ آنچه در جلسهٔ بعد ادامه می‌یابد

استاد اعلام کرد در جلسهٔ بعد تصمیم‌گیری نهایی مدل انتخاب تلفظ با جزئیات بیشتر بررسی می‌شود. موضوعات اعلام‌شده:

- بررسی دقیق‌تر لایهٔ خروجی برای انتخاب تلفظ؛
- نحوهٔ تصمیم‌گیری مدل با امتیازهای خروجی و Softmax؛
- ادامهٔ معماری‌های مبتنی بر بافت؛
- ورود تدریجی به Transformer و سپس معماری‌های سرتاسری.

۱۳.۸ جمع‌بندی

مسیر مفهومی این جلسه از بازنمایی عددی ساده تا بازنمایی وابسته به بافت بود. کلمه ابتدا با One-Hot نمایش داده می‌شود که پراکنده است و شباهت معنایی ندارد. Embedding متراکم و آموخته‌شده این کمبود را جبران می‌کند، و Word2Vec (CBOW و Skip-gram) آن را از روی هم‌وقوعی کلمات می‌سازد. اما بردار Word2Vec ایستاست و برای کلمه‌ای مانند «کرم» در همهٔ جمله‌ها یکسان می‌ماند؛ بنابراین برای TTS باید یا مدلی روی بافت بگذاریم و با داده‌های برچسب‌دار آموزشش دهیم، یا (راه بنیادی‌تر) از بازنمایی وابسته به بافت بهره بگیریم. چون برچسب‌گذاری دستی گران است، پیش‌آموزش خودنظارتی (مانند MLM) اهمیت می‌یابد و Self-Attention ابزار اصلی ساخت این بازنمایی‌هاست.

نکات مهم برای مرور و امتحان

- تفاوت Pipeline و End-to-End؛ تعریف Front-End و Back-End.
- چهار محدودیت One-Hot و مزایای Embedding (تراکم، بُعد کم، شباهت معنایی، آموخته از داده).
- چرخهٔ آموزش شبکه: مقداردهی تصادفی، Feedforward، خروجی، Loss، Backpropagation و به‌روزرسانی؛ رابطهٔ $w_{\text{new}} = w_{\text{old}} - \eta\, \partial E/\partial w$ و اثر نرخ یادگیری.
- نقش بایاس (مثال کرایهٔ تاکسی) و تابع فعال‌سازی (غیرخطی‌کردن).
- تفاوت CBOW و Skip-gram و اینکه برای کلمات نادر Skip-gram بهتر است.
- Embedding ایستا: در آموزش وابسته به بافت، در استنتاج مستقل از بافت؛ چرا برای هم‌نویسه کافی نیست.
- چرا همهٔ تلفظ‌ها را از ابتدا برچسب نمی‌زنیم (گلوگاه Annotation) و نقش Self-Supervised

جدول ۵.۸: جدول مفاهیم کلیدی جلسه

مفهوم	نکتهٔ اصلی
One-Hot	ساده، پراکنده و فاقد شباهت کلمات
Word Embedding	بازنمایی عددی متراکم و آموخته‌شدهٔ کلمات
Feedforward	محاسبهٔ خروجی با وزن‌ها، بایاس و فعال‌سازی
Backpropagation	محاسبهٔ گرادیان خطا نسبت به پارامترها با قانون زنجیره‌ای
Gradient Descent	تغییر وزن‌ها در خلاف جهت گرادیان با گام η
Skip-gram / CBOW	پیش‌بینی هدف از بافت / پیش‌بینی بافت از هدف؛ Skip-gram برای کلمات نادر بهتر
Homograph	نوشتار یکسان با تلفظ و معنای متفاوت
Static Embedding	بردار ثابت برای هر کلمه در زمان استنتاج
Contextual Embedding	بردار هر کلمه تابعی از جملهٔ فعلی
Self-Attention	ساخت بازنمایی وابسته به بافت با $\mathrm{softmax}(QK^\top/\sqrt{d_k})V$

Learning.

- مفاهیم Value/Key/Query و فرمول Attention.

فصل ۹

آموزش شبکه، Embedding بافتی و تبدیل نویسه به واج

این فصل از سه بخش به‌هم‌پیوسته ساخته شده است. بخش نخست، مرور سریعی بر فرایند آموزش شبکه‌های عصبی است؛ مفاهیم پایه (انتشار روبه‌جلو، تابع خطا، پس‌انتشار و به‌روزرسانی وزن‌ها) در فصل پیش آمده بودند، بنابراین اینجا فقط به آنچه برای ادامه لازم است، یعنی طراحی لایهٔ خروجی، تفاوت آموزش و استنتاج، و پدیدهٔ بیش‌برازش، پرداخته می‌شود. بخش دوم، Embeddingهای بافتی را بررسی می‌کند: از روش‌های ساخت آن‌ها و مدل BERT تا تحلیل فضای Embedding با قیاس برداری (Analogy) و **کاوش** (Probing). بخش سوم به هدف اصلی بازمی‌گردد: سامانهٔ تبدیل متن به گفتار (TTS) باید برای هر واژه تلفظ درست را پیدا کند. در آنجا همین ابزارها برای رفع ابهام هم‌نویسه‌ها (Homograph) و پیش‌بینی تلفظ واژه‌های ناشناخته (G2P) به کار می‌روند.

۱.۹ مرور فرایند آموزش شبکهٔ عصبی

۱.۱.۹ چرخهٔ آموزش

آموزش یک شبکه از مقداردهی تصادفی اولیهٔ وزن‌ها آغاز می‌شود و سپس چهار گام زیر برای هر دسته از داده‌ها تکرار می‌گردد (شکل ۱.۹):

۱. **انتشار روبه‌جلو** (Feedforward): ورودی با کمک وزن‌ها، بایاس‌ها و توابع فعال‌سازی از لایه‌ها عبور می‌کند.

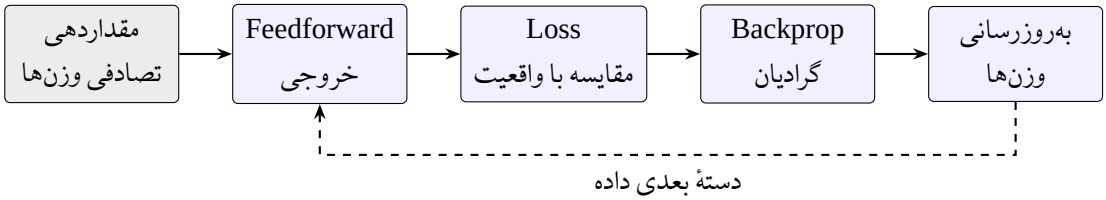
۲. **خروجی**: لایهٔ آخر مقدار پیش‌بینی‌شده (امتیاز، احتمال یا مقدار عددی) را می‌دهد.

۳. **تابع خطا** (Loss): خروجی با مقدار درست، یعنی **حقیقت مبنا** (Ground Truth)، مقایسه می‌شود و یک عدد برای «میزان خطا» به دست می‌آید.

۴. **پس‌انتشار و بهینه‌سازی** (Backpropagation): با قاعدهٔ زنجیره‌ای، سهم هر وزن در خطا (گرادیان) حساب می‌شود و وزن‌ها در خلاف جهت گرادیان و به‌اندازهٔ نرخ یادگیری اصلاح می‌شوند.

جزئیات ریاضی این گام‌ها (از جمله $w_{\text{new}} = w_{\text{old}} - \eta\, \partial E/\partial w$ و مفهوم Loss Landscape) در فصل قبل آمده

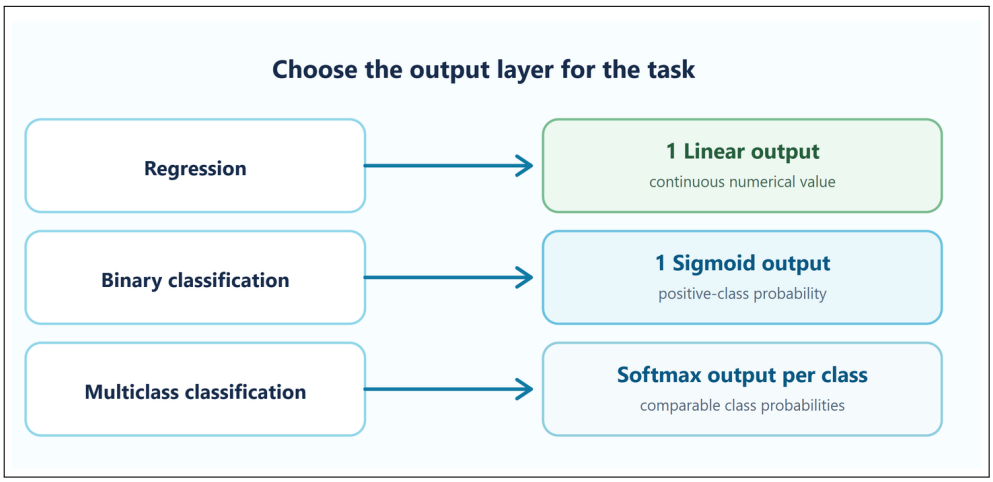
است. استاد این نکته را تکرار کرد که تا وقتی خروجی تخمینی با واقعیت برابر نشده باشد، هنوز چیزی برای یادگرفتن وجود دارد.



شکل ۱.۹: چرخهٔ آموزش شبکهٔ عصبی (شکل افزوده)

۲.۱.۹ طراحی لایهٔ خروجی بر اساس نوع مسئله

نکتهٔ مورد تأکید استاد این بود که خروجی شبکه باید با *Task* هم‌خوان طراحی شود. سه حالت اصلی وجود دارد :



شکل ۲.۹: انتخاب لایهٔ خروجی بر اساس نوع مسئله: رگرسیون با یک خروجی خطی، دسته‌بندی دودویی با یک خروجی سیگموید و دسته‌بندی چندکلاسه با سافت‌مکس. (برگرفته از تختهٔ کلاس)

رگرسیون. فرض کنید بخش پیشین شبکه برداری مانند $X \in \mathbb{R}^{۱\times ۷۶۸}$ ساخته باشد. برای پیش‌بینی یک عدد (مثلاً $F_۰$) کافی است یک لایهٔ خطی با $W \in \mathbb{R}^{۷۶۸\times ۱}$ قرار دهیم:

$$Y = XW + b, \qquad Y \in \mathbb{R}^{۱\times ۱}.$$

اگر مسئله پیچیده‌تر بود، می‌توان به‌جای یک لایه از ساختار Linear → Activation → Linear (یک MLP) استفاده کرد. استاد تأکید کرد که همیشه لازم نیست معماری پیچیده انتخاب شود؛ گاهی یک لایهٔ خطی ساده کافی است و پیچیده‌ترکردن باید بر اساس عملکرد مدل انجام شود.

نوع مسئله	لایهٔ خروجی	تابع خطا		مثال از پردازش گفتار
Regression	یک خروجی خطی (مقدار پیوسته)	MSE		پیش‌بینی مقدار فرکانس پایه در یک لحظه
Binary Classification	یک خروجی Sigmoid و آستانه‌گذاری	Cross-Entropy	Binary	واکدار/بی‌واک، گفتار/سکوت، اسپم یا غیراسپم
Multi-class Classification	Softmax روی K کلاس	Cross-Entropy		تشخیص نوع احساس صدا، موضوع خبر، تلفظ درست یک واژه

جدول ۱.۹: ارتباط نوع مسئله با لایهٔ خروجی و تابع خطا.

دسته‌بندی دودویی. خروجی یک **لاجیت** (Logit) است که از تابع سیگموید می‌گذرد و عددی در $(۰, ۱)$ می‌دهد:

$$\sigma(x) = \frac{۱}{۱ + e^{-x}}.$$

اگر خروجی ۰٫۸ باشد، مدل احتمال کلاس مثبت را ۸۰ درصد برآورد کرده است؛ با تعیین یک آستانه (Threshold) کلاس نهایی مشخص می‌شود. روی تخته نوشته شده بود که سیگموید «برای هر خروجی احتمال مستقل می‌دهد و ترشولد می‌زنیم».

دسته‌بندی چندکلاسه. برای تبدیل K لاجیت $z_۱, \ldots, z_K$ به یک توزیع احتمال از Softmax استفاده می‌شود؛ این تابع «احتمال کلاس‌ها را با هم نرمال می‌کند تا مجموعشان ۱ شود»:

$$P(y = i) = \frac{e^{z_i}}{\sum_{j=۱}^{K} e^{z_j}}, \qquad \sum_{i=۱}^{K} P(y = i) = ۱.$$

در پیش‌بینی توکن بعدی، اگر واژگان V توکن داشته باشد، لایهٔ خروجی بردار ۷۶۸×۱ را با ماتریس $۷۶۸ \times V$ ضرب می‌کند و یک بردار $۱ \times V$ از لاجیت‌ها به دست می‌آید؛ Softmax به هر توکن یک احتمال می‌دهد.

[محتوای افزوده] سیگموید مستقل یا سافت‌مکس؟

در دسته‌بندی چندکلاسهٔ معمولی هر نمونه دقیقاً یک برچسب دارد، پس کلاس‌ها باید با هم رقابت کنند و Softmax مناسب است. اگر هر نمونه بتواند هم‌زمان چند برچسب داشته باشد (Multi-label)، برای هر برچسب یک سیگموید مستقل به کار می‌رود. این همان تفاوتی است که روی تخته با عبارت «احتمال مستقل» و «نرمال‌شده تا مجموع ۱» نشان داده شد.

۳.۱.۹ تابع خطا و مثال پیش‌بینی توکن بعدی

برای دسته‌بندی چندکلاسه با برچسب One-Hot، تابع Cross-Entropy به شکل زیر ساده می‌شود:

$$L = -\sum_{k=۱}^{K} y_k \log \hat{y}_k = -\log \hat{y}_c,$$

که در آن c کلاس درست است؛ یعنی فقط احتمالی که مدل به پاسخ درست داده اهمیت دارد.

کلمه	احتمال مدل	جواب واقعی
خواهم	۰٫۲	۱
خوردم	۰٫۷	۰
بینم	۰٫۱	۰

شکل ۳.۹: مثال استاد: مدل برای واژهٔ «خواهم» احتمال ۰٫۲ را پیش‌بینی کرده و پاسخ درست ۱ است؛ برای «خوردم» و «بینم» پاسخ درست ۰ است. (برگرفته از تختهٔ کلاس)

با احتمال ۰٫۲ برای پاسخ درست، خطا برابر $-\log ۰٫۲ \approx ۱٫۶۱$ است. اگر پس از چند گام اصلاح وزن‌ها، احتمال پاسخ درست به ۰٫۹ برسد، خطا به $-\log ۰٫۹ \approx ۰٫۱۰۵$ کاهش می‌یابد (لگاریتم طبیعی). پس شبکه یاد می‌گیرد به پاسخ درست احتمال بیشتری بدهد.

نوع مسئله	تابع Loss اصلی	فرمول
Regression	MSE	$L = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2$
Binary Classification	Binary Cross-Entropy	$L = -[y\log(p) + (1-y)\log(1-p)]$
Multiclass Classification	Categorical Cross-Entropy	$L = -\sum_{k=1}^{C} y_k \log(p_k)$

شکل ۴.۹: جدول انتخاب تابع خطا بر اساس نوع مسئله: MSE برای رگرسیون، Binary Cross-Entropy برای دسته‌بندی دودویی و Categorical Cross-Entropy برای چندکلاسه (برگرفته از تختهٔ کلاس)

۲.۹ آموزش در برابر استنتاج

در فاز **آموزش** (Training) پاسخ درست را داریم و می‌توانیم خطا را حساب کنیم؛ در فاز **استنتاج** (Inference) پاسخ درست در اختیار نیست و شبکه فقط یک توزیع احتمال تولید می‌کند. پرسش این است که از این توزیع چگونه خروجی نهایی را برداریم. استاد این تفاوت را روی تخته با عنوان «در فاز آموزش یک واقعیت داریم، بررسی می‌کنیم مدل به آن واقعیت چه مقداری داده» در برابر «در فاز اینفرنس» (Greedy+Softmax، یا Sampling+Softmax، یا Softmax+Temperature) نوشته بود.

	آموزش	استنتاج
حقیقت مبنا	در دسترس است	در دسترس نیست
هدف	کمینه‌کردن خطا و اصلاح وزن‌ها	گرفتن خروجی از توزیع احتمال
وزن‌ها	در حال تغییرند	ثابت‌اند
Dropout	فعال	غیرفعال
انتخاب خروجی	لازم نیست؛ خطا روی احتمال پاسخ درست حساب می‌شود	Greedy، Sampling، Top-k، Top-p، Temperature

جدول ۲.۹: مقایسهٔ آموزش و استنتاج (ردیف Dropout افزوده شده است).

۱.۲.۹ Greedy و Sampling

- **رمزگشایی حریصانه** (Greedy Decoding): پراحتمال‌ترین گزینه انتخاب می‌شود، $y = \arg\max_i P(y = i)$. این روش قطعی است؛ برای توزیع (۰٫۶, ۰٫۳, ۰٫۱) همیشه گزینهٔ اول برگزیده می‌شود.
- **نمونه‌گیری** (Sampling): خروجی از روی توزیع احتمال نمونه‌برداری می‌شود، پس گزینه‌های کم‌احتمال‌تر هم شانس انتخاب دارند. این روش وقتی مفید است که تنوع خروجی مطلوب باشد (مثلاً تولید متن خلاقانه).
- **نمونه‌گیری Top-k** (Top-k Sampling): فقط k گزینهٔ پراحتمال نگه داشته می‌شوند (مثلاً ۱۰ توکن برتر) و نمونه‌گیری از میان آن‌ها انجام می‌شود.
- **نمونه‌گیری Top-p** (Nucleus Sampling): توکن‌ها بر اساس احتمال مرتب می‌شوند و کوچک‌ترین مجموعه‌ای که مجموع احتمالش دست‌کم p (مثلاً ۰٫۹) باشد نگه داشته می‌شود؛ نمونه‌گیری از همین مجموعه انجام می‌شود.

در کلاس به جست‌وجوی پرتویی (Beam Search) نیز اشاره شد. این روش نمونه‌گیری نیست، بلکه به‌جای نگه‌داشتن فقط یک گزینه در هر گام، چند دنبالهٔ پراحتمال (پرتو) را هم‌زمان نگه می‌دارد و در پایان محتمل‌ترین دنباله را برمی‌گزیند.

۲.۲.۹ دما (Temperature)

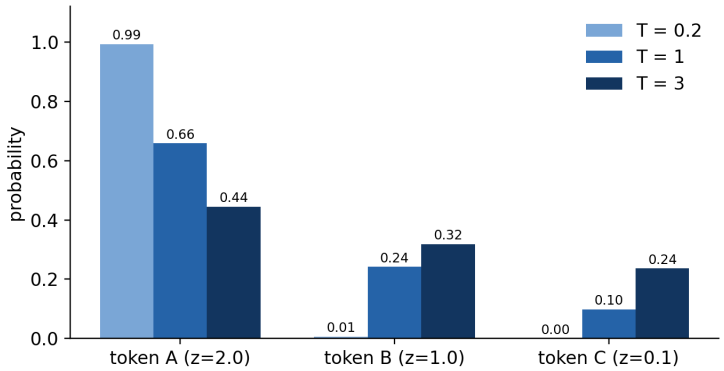
دما میزان «تیزی» توزیع احتمال را تنظیم می‌کند. لاجیت‌ها پیش از Softmax بر T تقسیم می‌شوند:

$$P_i = \frac{e^{z_i/T}}{\sum_j e^{z_j/T}}.$$

با $T = ۱$ همان Softmax معمولی داریم؛ با $T \to ۰$ توزیع بسیار تیز می‌شود و به argmax نزدیک می‌گردد؛ با T بزرگ توزیع هموارتر می‌شود و در حد، به توزیع یکنواخت میل می‌کند. دمای بالا تنوع و تصادفی‌بودن را بیشتر می‌کند و در مقابل احتمال تولید خروجی نامناسب (مثلاً Hallucination) هم بالاتر می‌رود؛ دمای پایین خروجی را تکرارپذیرتر می‌کند. دما لاجیت‌های یادگرفته‌شده را عوض نمی‌کند و فقط روش تبدیل آن‌ها به احتمال را هنگام تولید تغییر می‌دهد.

[محتوای افزوده] مثال عددی: اثر دما روی لاجیت‌ها

فرض کنید لاجیت سه توکن $z = (۲٫۰,\ ۱٫۰,\ ۰٫۱)$ باشد. برای $T = ۱$ داریم $e^{۲} = ۷٫۳۸۹$، $e^{۱} = ۲٫۷۱۸$ و $e^{۰٫۱} = ۱٫۱۰۵$، مجموع ۱۱٫۲۱۲ و احتمال‌ها $(۰٫۶۶,\ ۰٫۲۴,\ ۰٫۱۰)$. برای $T = ۰٫۲$ لاجیت‌ها ضرب در ۵ می‌شوند، یعنی $(۱۰,\ ۵,\ ۰٫۵)$، و احتمال‌ها تقریباً $(۰٫۹۹,\ ۰٫۰۱,\ ۰٫۰۰)$ می‌شود؛ تقریباً Greedy. برای $T = ۳$ لاجیت‌ها به $(۰٫۶۷,\ ۰٫۳۳,\ ۰٫۰۳)$ می‌رسند و احتمال‌ها $(۰٫۴۴,\ ۰٫۳۲,\ ۰٫۲۴)$ می‌شود؛ توزیع به یکنواخت نزدیک‌تر است.



شکل ۵.۹: اثر دما بر احتمال سه توکن فرضی با لاجیت‌های ثابت $(۲٫۰,\ ۱٫۰,\ ۰٫۱)$: دمای کم توزیع را تیز و دمای زیاد آن را هموار می‌کند. (شکل افزوده)

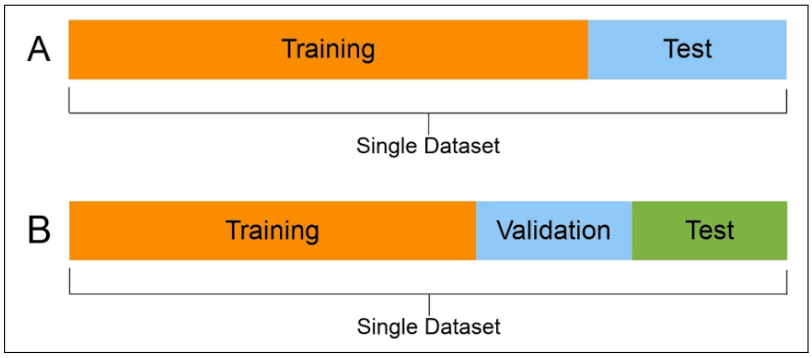
Dropout و استنتاج

در کلاس Dropout فقط به‌عنوان روشی برای کاهش وابستگی بیش‌ازحد به مسیرهای خاص شبکه معرفی شد. باید افزود که Dropout تنها در زمان آموزش اعمال می‌شود؛ در استنتاج همهٔ نورون‌ها فعال‌اند (و مقیاس خروجی‌ها طوری تنظیم می‌شود که میانگین فعالیت تغییر نکند). این یکی از مثال‌هایی است که شبکه در آموزش و استنتاج دقیقاً یکسان رفتار نمی‌کند.

۳.۹ تعمیم‌پذیری: کم‌برازش، بیش‌برازش و پیچیدگی مدل

۱.۳.۹ داده‌های آموزش، اعتبارسنجی و آزمون

برای فهمیدن اینکه مدل «به‌اندازهٔ کافی» آموزش دیده یا نه، تنها دیدن خطای داده‌های آموزشی کافی نیست؛ مدل باید روی داده‌ای ارزیابی شود که در به‌روزرسانی وزن‌ها به‌کار نرفته است. به همین دلیل مجموعه‌دادهٔ واحد را تقسیم می‌کنند (شکل ۶.۹): بخش Training برای یادگیری وزن‌ها، بخش Validation برای پایش آموزش و تصمیم‌هایی مانند توقف یا انتخاب ابرپارامتر، و بخش Test برای گزارش نهایی. استاد روی تخته نوشت: «ارزیابی با داده‌هایی که در آموزش وزن‌ها استفاده نشده‌اند».



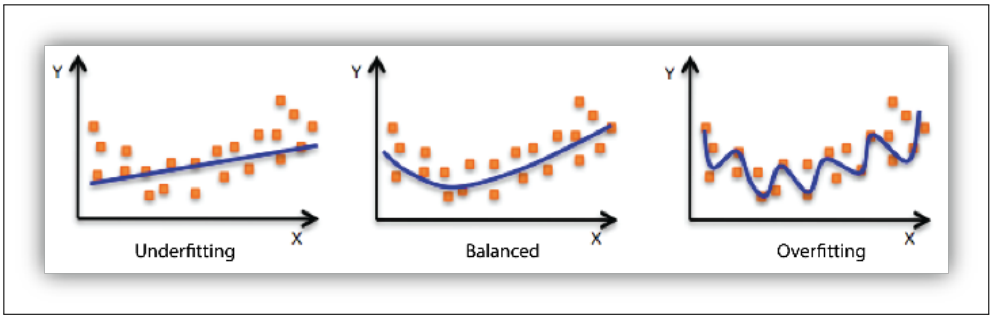
شکل ۶.۹: تقسیم یک مجموعه‌داده: (الف) آموزش و آزمون؛ (ب) آموزش، اعتبارسنجی و آزمون. روی تخته به مجموعه‌دادهٔ LJ Speech به‌عنوان نمونه‌ای از «یک مجموعه‌دادهٔ واحد» ارجاع داده شده بود. (برگرفته از تختهٔ کلاس)

[محتوای افزوده] نکات تقسیم داده در گفتار

LJ Speech مجموعه‌ای تک‌گوینده با حدود ۱۳ ۱۰۰ گفتار کوتاه و نزدیک به ۲۴ ساعت صداست. اگر به‌جای تقسیم تصادفی گفتارها، گفتارهای یک گوینده یا یک جملهٔ تکراری هم در آموزش و هم در آزمون بیایند، خطای آزمون خوش‌بینانه می‌شود؛ در کارهای چندگوینده معمولاً تقسیم بر اساس گوینده انجام می‌شود. مجموعهٔ آزمون نباید برای تنظیم مدل به‌کار برود.

۲.۳.۹ سه وضعیت پس از آموزش

- **کم‌برازش** (Underfitting): مدل حتی داده‌های آموزشی را هم خوب یاد نگرفته است (روی تخته: «مدل حتی داده‌های آموزشی را هم خوب یاد نگرفته است»).
- **برازش مناسب** (Good Fit): الگوهای اصلی مسئله آموخته شده و عملکرد روی داده‌های تازه هم خوب است.
- **بیش‌برازش** (Overfitting): مدل علاوه بر الگوی اصلی، جزئیات نامربوط و نویز داده آموزشی را هم حفظ کرده است («مدل داده‌های آموزشی را خوب یاد گرفته، اما تعمیم نمی‌دهد»).



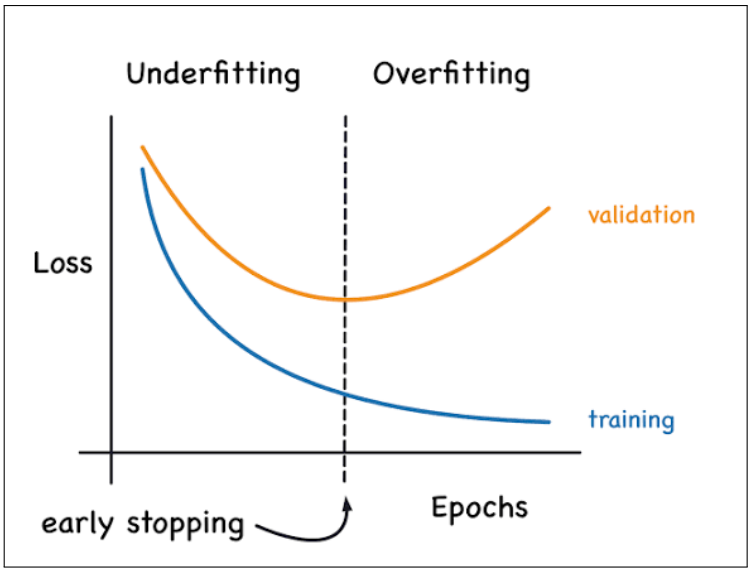
شکل ۷.۹: سه وضعیت برازش روی یک مجموعه نقطه: خط ساده (کم‌برازش)، منحنی هموار (متعادل) و منحنی بسیار نوسانی که از همهٔ نقاط می‌گذرد (بیش‌برازش). (برگرفته از تختهٔ کلاس)

مثال استاد از بیش‌برازش در گفتار

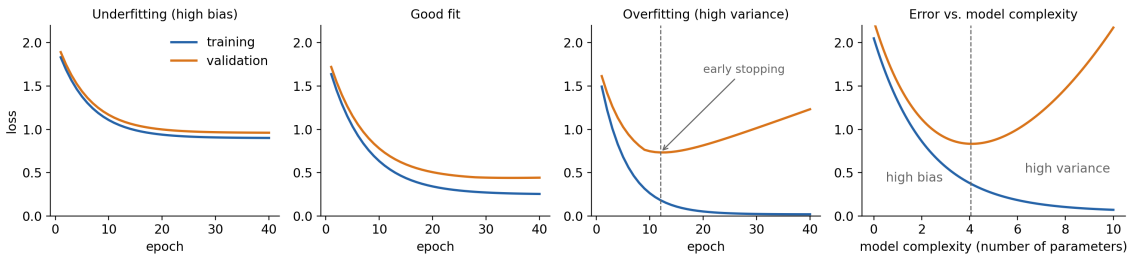
فرض کنید در داده‌های آموزشی یک دستیار صوتی، هر بار که عبارت خاصی گفته شده، صدای فن هم در پس‌زمینه بوده است. مدل ممکن است به‌جای یادگیری الگوی گفتاری، صدای فن را نشانهٔ آن عبارت بگیرد. چنین مدلی روی داده آموزشی خوب عمل می‌کند، اما روی نمونه‌ای که همان عبارت را بدون صدای فن دارد اشتباه می‌کند.

۳.۳.۹ منحنی خطای آموزش و اعتبارسنجی

با افزایش Epoch، خطای آموزش معمولاً کم می‌شود. خطای اعتبارسنجی نخست کم می‌شود، اما از جایی به بعد ممکن است دوباره بالا برود. همان نقطهٔ کمینه بهترین توازن است، و افزایش خطای اعتبارسنجی همراه با کاهش خطای آموزش نشانهٔ بیش‌برازش است. توقف آموزش در این نقطه **توقف زودهنگام** (Early Stopping) نام دارد.



شکل ۸.۹: نمودار خطای آموزش (آبی) و اعتبارسنجی (نارنجی) بر حسب Epoch؛ خط‌چین عمودی محل توقف زودهنگام است. روی تخته زیر محور افقی «model complexity: تعداد پارامترهای بیشتر ↔ کمتر جنرال» هم نوشته شده بود. (برگرفته از تختهٔ کلاس)



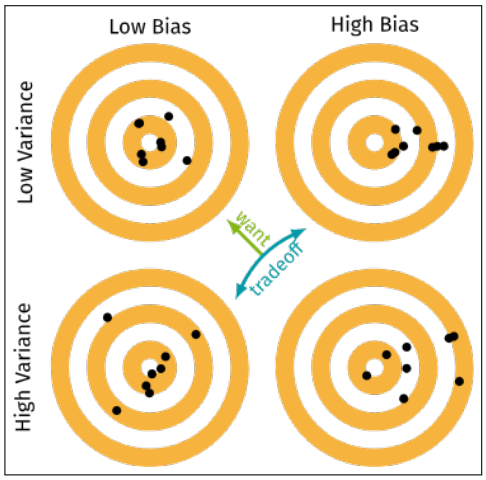
شکل ۹.۹: سه رفتار نوعی در طول آموزش (سه نمودار اول) و رابطهٔ خطا با پیچیدگی مدل (نمودار آخر). مقادیر شبیه‌سازی‌شده‌اند و فقط برای نمایش مفهوم‌اند. (شکل افزوده)

۴.۳.۹ Bias و Variance

دو منبع اصلی خطا در یک مدل، «بایاس» و «واریانس» هستند (نباید بایاس به‌معنای خطا در این بحث را با پارامتر b در $Wx + b$ اشتباه گرفت).

	High Bias (کم‌برازش)	High Variance (بیش‌برازش)
نشانه	خطای آموزش و اعتبارسنجی هر دو زیاد و نزدیک به هم	خطای آموزش کم، خطای اعتبارسنجی بسیار بیشتر
تصویر شهودی	پیش‌بینی‌ها به هم نزدیک‌اند اما از جواب واقعی دورند	پیش‌بینی‌ها پراکنده‌اند؛ مدل با تغییر داده‌ها تغییر می‌کند
راهکار	مدل را پیچیده‌تر کن: لایه و نورون بیشتر، یا معماری مناسب‌تر	داده با کیفیت بیشتر، بررسی ناسازگاری‌های برچسب‌گذاری، متعادل‌کردن داده، Data Augmentation، Regularization (مثل Dropout یا جریمهٔ وزن‌های بزرگ)

جدول ۳.۹: مقایسهٔ بایاس بالا و واریانس بالا بر اساس یادداشت‌های تخته و کلاس.



شکل ۱۰.۹: مثال هدف‌گیری برای چهار ترکیب بایاس و واریانس؛ هدف مطلوب، بایاس و واریانس هر دو پایین است و در عمل میان آن دو مصالحه (Tradeoff) وجود دارد. (برگرفته از تختهٔ کلاس)

از کجا بفهمیم تا کجا مدل را پیچیده‌تر کنیم؟

پرسش تخته‌ای استاد این بود: «تا کجا به آموزش و پیچیده‌ترکردن مدل ادامه دهیم؟» پاسخ: تا جایی که خطای اعتبارسنجی بهتر می‌شود. معماری را باید بر پایهٔ عملکرد مدل تغییر داد، نه صرفاً با افزودن لایه و نورون. برای تشخیص مشکل، خطای آموزش به‌تنهایی کافی نیست و باید خطای اعتبارسنجی و وضعیت بایاس/واریانس هم بررسی شود.

۵.۳.۹ Regularization

منظم‌سازی (Regularization) هر روشی است که پیچیدگی مؤثر مدل را محدود می‌کند تا تعمیم بهتر شود.

- Dropout: در هر گام آموزش، خروجی تعدادی از نورون‌ها به‌طور تصادفی صفر می‌شود. شبکه مجبور می‌شود به مسیر یا ویژگی خاصی بیش‌ازحد تکیه نکند و وابستگی‌های بیش‌ازحد شکل‌گرفته بشکند.
- منظم‌سازی L1 و L2: جمله‌ای به تابع خطا افزوده می‌شود که وزن‌های بزرگ را جریمه کند:

$$L_{\text{total}} = L_{\text{task}} + \lambda \sum_i |w_i| \quad \text{(L1)}, \qquad L_{\text{total}} = L_{\text{task}} + \lambda \sum_i w_i^2 \quad \text{(L2)},$$

که λ شدت منظم‌سازی را تعیین می‌کند.

پرسش: اگر وزن بزرگ برای یک ویژگی واقعاً خوب باشد چه؟

روی تخته پرسیده شده بود: «اگر وزن بزرگ برای فیچر خوب و واقعی باشد چه؟» پاسخ استاد: منظم‌سازی بین وزن مفید و نامفید تمایز مستقیمی نمی‌گذارد و به‌طور کلی اعمال می‌شود. در یک شبکهٔ عمیق اطلاعات معمولاً با ترکیب تعداد زیادی ویژگی نمایش داده می‌شود و با وجود این محدودیت شبکه می‌تواند عملکرد خوبی حفظ کند. اگر وزن بزرگی برای کاهش خطای اصلی واقعاً لازم باشد، میان کاهش خطا و جریمهٔ وزن یک مصالحه شکل می‌گیرد و مدل آن وزن را کاملاً حذف نمی‌کند. بنابراین تضمینی نیست که هیچ ویژگی مفیدی آسیب نبیند؛ شدت λ باید با توجه به عملکرد واقعی روی داده اعتبارسنجی انتخاب شود. در این بحث به اهمیت هم‌مقیاس‌کردن (Scaling) ویژگی‌ها هم اشاره شد، چون جریمهٔ وزن به مقیاس ورودی‌ها حساس است.

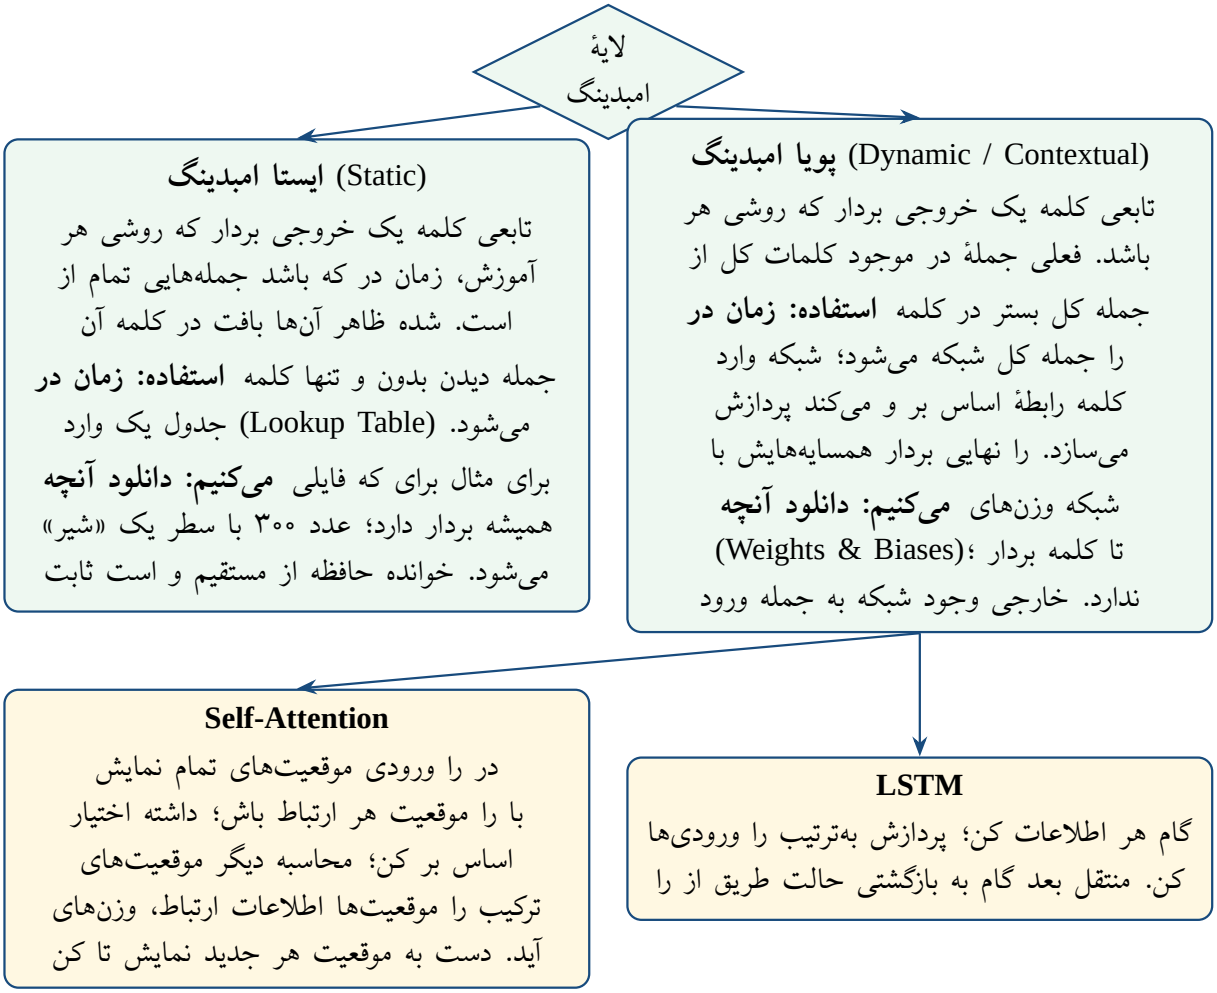
۴.۹ Embedding ایستا و پویا (بافتی)

۱.۴.۹ مرور

Embedding روشی برای نمایش واژه‌ها یا توکن‌ها به‌صورت بردارهای عددی چگال است (در برابر بردار تُنُک و دومقداری One-Hot). روی تخته پرسش «ورودی چگونه نمایش داده می‌شود؟» مطرح بود و لایهٔ Embedding به دو شاخه تقسیم می‌شد: ایستا (Static) و پویا یا بافتی (Contextual).

۲.۴.۹ Embedding ایستا

در تعریف تخته‌ای: «هر روشی که طی آن بردار خروجی یک کلمه تابعی از تمامی جمله‌هایی باشد که در زمان آموزش، آن کلمه در بافت آن‌ها ظاهر شده است». مثال مهم Word2Vec است (با دو روش آموزش CBOW و Skip-gram که در فصل قبل بررسی شد): ابتدا بردارها مقدار اولیه می‌گیرند، سپس با یک Task آموزشی (پیش‌بینی واژهٔ هدف از بافت، یا بافت از واژهٔ هدف) تنظیم می‌شوند، و پس از پایان آموزش بخش پیش‌بینی کنار گذاشته می‌شود و فقط بردارها نگه داشته می‌شوند.



شکل ۱۱.۹: دو شاخهٔ لایهٔ Embedding: ایستا (جدول جست‌وجو) و پویا/بافتی (تابعی از کل جملهٔ فعلی)؛ دو بیضی پایین دو راه ساخت بافتی را نشان می‌دهند: Self-Attention و پردازش ترتیبی با LSTM. (بازسازی‌شده از تختهٔ کلاس)

در زمان استفاده: واژه تنها و بدون دیدن جمله وارد یک **جدول جست‌وجو** (Lookup Table) می‌شود. آنچه دانلود می‌کنیم یک فایل است که مثلاً برای «شیر» یک سطر با ۳۰۰ عدد دارد و فرقی نمی‌کند منظور «شیر جنگل»، «شیر آب» یا «شیر خوراکی» باشد؛ بردار همیشه ثابت است و بدون نیاز به شبکهٔ عصبی مستقیماً از حافظه خوانده می‌شود. استاد این را با جمله‌ای دربارهٔ Word2Vec جمع‌بندی کرد: مدل در زمان آموزش مبتنی بر بافت است (Context-based) و در زمان استنتاج مستقل از بافت (Context-independent).

۳.۴.۹ Embedding پویا (بافتی)

تعریف تخته‌ای: «هر روشی که طی آن بردار خروجی یک کلمه، تابعی از کل کلمات موجود در جملهٔ فعلی باشد». در زمان استفاده کل جمله وارد شبکه می‌شود، شبکه آن را پردازش می‌کند و بر اساس رابطهٔ واژه با همسایه‌هایش بردار نهایی را می‌سازد. در نتیجه:

$$\text{ایستا: } E(w) = v_w, \qquad \text{بافتی: } E(w, C) = v_{w,C}, \qquad E(\text{شیر}, C_۱) \neq E(\text{شیر}, C_۲).$$

چیزی که دانلود می‌کنیم وزن‌ها و بایاس‌های شبکه است، و بردار یک واژه تا زمانی که جمله وارد شبکه نشود وجود خارجی ندارد. این تفاوت عملی مهمی دارد: بردار ایستا را می‌توان جدا ذخیره و مستقل استفاده کرد، ولی برای تولید بردار بافتی باید خود مدل (با همهٔ پارامترهایش) اجرا شود.

	ایستا (Static)	پویا (Contextual)
بردار هر واژه	ثابت، یک بردار برای هر واژه	وابسته به جمله؛ هر رخداد بردار خودش را دارد
زمان استفاده	جست‌وجو در جدول (بدون شبکه)	اجرای شبکه روی کل جمله
خروجی دانلودی	فایل جدول بردارها	وزن‌های شبکه
نمونه	Word2Vec (CBOW، Skip-gram)، GloVe	ELMo، BERT

جدول ۴.۹: مقایسهٔ Embedding ایستا و بافتی.

«شیر» در اینجا دو مسئلهٔ متفاوت را نشان می‌دهد

واژهٔ «شیر» برای سه معنای جنگل، خوراکی و شیرآب هر سه یک‌جور تلفظ می‌شود (/ʃi:r/). بنابراین مثال خوبی برای چندمعنایی و محدودیت Embedding ایستا است، اما یک Homograph به‌معنای «هم‌نویسهٔ با تلفظ متفاوت» نیست. هم‌نویسه‌های واقعی از نوع مورد نیاز برای TTS واژه‌هایی مانند «مَرد/مُرد» یا «کِرم/کَرَم» هستند که تلفظ‌شان فرق می‌کند. به همین دلیل در بخش مربوط به TTS از «کرم»، «مرد» و «گرم» استفاده می‌کنیم.

۴.۴.۹ کاربرد Embedding بافتی فراتر از رفع ابهام معنایی

استاد تأکید کرد که Embedding بافتی فقط برای واژه‌های چندمعنایی نیست. مثلاً در **تشخیص مرجع ضمیر** (Coreference Resolution)، در جمله‌ای مثل «من این کتاب را به علی دادم. او ...» مدل باید ارتباط «او» را با «علی» (و نه «من» یا «کتاب») بتواند تشخیص دهد؛ یعنی بردارها باید تا حدی اطلاعات ارجاعی را هم در خود داشته باشند.

همچنین می‌توان از لایه‌های مختلف شبکه اطلاعات مختلفی بیرون کشید، مانند اطلاعات دستوری و برچسب نقش دستوری (POS)، ویژگی‌های معنایی، روابط وابسته به متن و حتی اطلاعات مرتبط با تلفظ. اینکه کدام اطلاعات در کدام لایه هست به معماری، داده و هدف آموزش بستگی دارد؛ برای بررسی آن از Probing استفاده می‌کنیم (بخش ۸.۹).

۵.۹ راه‌های ساخت Embedding بافتی

مسئلهٔ اصلی این است: چگونه بردار یک واژه را وابسته به متن پیرامونش بسازیم؟ استاد تأکید کرد که نباید Contextual Embedding را با معماری Transformer یکی دانست؛ ابتدا باید مسئله را فهمید و بعد سراغ معماری خاصی رفت. دو رویکرد مطرح شد که روی تخته هم دو بیضی جدا برایشان کشیده شده بود.

۱.۵.۹ نگاه موازی: Self-Attention

مراحل روی تخته چنین بود: نمایش تمام موقعیت‌های ورودی را در اختیار داشته باش؛ ارتباط هر موقعیت را با موقعیت‌های دیگر محاسبه کن؛ بر اساس وزن‌های ارتباط، اطلاعات موقعیت‌ها را ترکیب کن تا نمایش جدید هر موقعیت به دست آید. به زبان Value/Key/Query: واژهٔ موردنظر نقش Query دارد و با Key سایر واژه‌ها مقایسه می‌شود؛ میزان شباهت، وزن توجه را می‌سازد؛ و ترکیب وزن‌دار Valueها بردار جدید را می‌دهد. مثلاً در جمله‌ای دربارهٔ «شیر» و «جنگل»، اطلاعات «جنگل» نقش پررنگ‌تری در بردار نهایی «شیر» خواهد داشت. فرمول کامل در فصل قبل (به‌صورت شهودی) بحث شده است.

۲.۵.۹ نگاه ترتیبی: RNN و LSTM

در یک **شبکهٔ بازگشتی** (Recurrent Neural Network) ورودی‌ها به‌ترتیب پردازش می‌شوند و اطلاعات هر گام از طریق **حالت پنهان** (Hidden State) به گام بعد منتقل می‌شود. حالت پنهان در هر گام، خلاصه‌ای از توکن‌های قبلی را حمل می‌کند. LSTM شکل بهبودیافته‌ای از RNN است که با سازوکار دروازه‌ای (Gating) وابستگی‌های طولانی‌تر را بهتر نگه می‌دارد. در مدل‌های دوطرفه (BiLSTM) یک پردازش چپ‌به‌راست و یک پردازش راست‌به‌چپ انجام می‌شود تا بردار هر واژه از بافت چپ و راست آن ساخته شود.

Attention هم‌ارز Transformer نیست

استاد تأکید کرد که Attention منحصر به Transformer نیست و پیش از آن در معماری‌های دیگر به‌کار می‌رفت. دقیق‌تر: Attention در حدود ۲۰۱۴ برای ترجمهٔ ماشینی با شبکه‌های بازگشتی معرفی شد (بهدانائو و همکاران)، و Transformer (۲۰۱۷) معماری‌ای است که به‌جای بازگشت، تماماً بر Self-Attention تکیه دارد. بنابراین سه مفهوم باید از هم جدا بمانند: «مسئلهٔ ساخت بازنمایی بافتی»، «سازوکار Attention»، و «معماری Transformer».

[محتوای افزوده] ELMo: بافتی‌سازی با BiLSTM

ELMo (پیترز و همکاران، ۲۰۱۸) نمونهٔ مشهور روش ترتیبی است. در آن یک مدل زبانی روبه‌جلو و یک مدل زبانی روبه‌عقب، هر دو با LSTM چندلایه، آموزش داده می‌شوند و بردار هر واژه از ترکیب خروجی لایه‌های آن (با وزن‌هایی که برای هر Task آموخته می‌شود) به دست می‌آید. تفاوت اصلی آن با BERT: در ELMo دو جهت چپ و راست جدا آموزش می‌بینند و بعد ترکیب می‌شوند، ولی BERT هر دو جهت را هم‌زمان در همهٔ لایه‌ها به کار می‌برد.

۶.۹ یادگیری خودنظارتی و BERT

۱.۶.۹ چرا یادگیری خودنظارتی؟

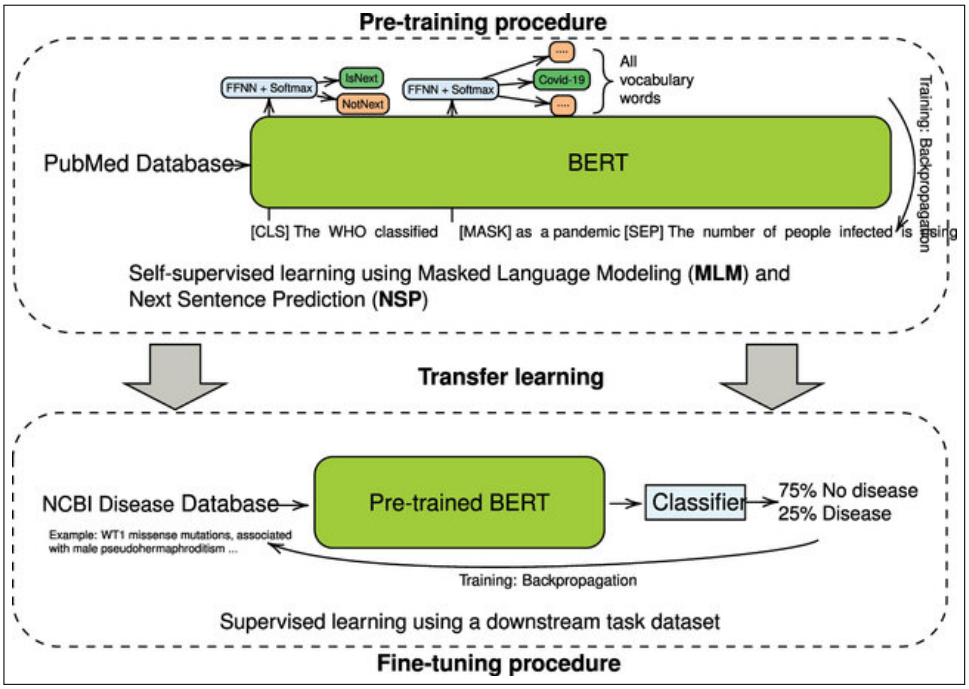
یادگیری بازنمایی بافتی به حجم بسیار زیادی داده نیاز دارد، و برچسب‌گذاری انسانی آن گران است. راه‌حل، **یادگیری خودنظارتی** (Self-Supervised Learning) است: برچسب از خود داده ساخته می‌شود. روی تخته تفاوت چنین بیان شده بود:

- Supervised: انسان داده‌ها را برچسب می‌زند؛ مثلاً جمله را «مثبت» یا «منفی» می‌کند.
- Self-supervised: برچسب را از خود داده تولید می‌کنیم؛ مثلاً واژهٔ حذف‌شده از متن اصلی.

۲.۶.۹ دو Task پیش‌آموزش در BERT

مدل‌سازی زبان ماسک‌شده (Masked Language Modeling, MLM). بخشی از متن پوشانده می‌شود و مدل باید آن را پیش‌بینی کند؛ مثلاً «امروز هوا [MASK] است.» چون واژهٔ اصلی را داریم، حقیقت مبنا هم داریم و می‌توانیم: خروجی مدل را حساب کنیم، با واژهٔ واقعی مقایسه کنیم، Cross-Entropy بگیریم، پس‌انتشار انجام دهیم و پارامترها را به‌روز کنیم.

پیش‌بینی جملهٔ بعدی (Next Sentence Prediction, NSP). دو جمله به مدل داده می‌شود و مدل باید بگوید آیا جملهٔ دوم در متن اصلی ادامهٔ جملهٔ اول بوده یا نه. نمونهٔ مثبت از ادامهٔ واقعی متن و نمونهٔ منفی با جملهٔ تصادفی ساخته می‌شود؛ پس این یک دسته‌بندی دودویی است. روی تخته پرسیده شده بود که ابعاد برای این Task چگونه می‌شود: بردار ۷۶۸بعدی مربوط به توکن ویژهٔ [CLS] در یک لایهٔ خطی با ابعاد ۲ × ۷۶۸ ضرب می‌شود تا دو لاجیت (NotNext/IsNext) به دست آید.



شکل ۱۲.۹: فرایند پیش‌آموزش و انتقال یادگیری برای BERT: بالا، پیش‌آموزش خودنظارتی با MLM و NSP (دو سر خروجی روی مدل)؛ پایین، قرار دادن یک دسته‌بند روی BERT پیش‌آموزش‌دیده و آموزش تکمیلی با داده برچسب‌دار Task هدف. (برگرفته از تختهٔ کلاس)

۳.۶.۹ معماری و ابعاد

BERT یک شبکهٔ Transformer Encoder است که به‌صورت دوطرفه روی دنبالهٔ ورودی کار می‌کند. نسخهٔ پایه (BERT-Base) ۱۲ لایه، بردار پنهان ۷۶۸بعدی، ۱۲ سر توجه و حدود ۱۱۰ میلیون پارامتر دارد؛ نسخهٔ بزرگ (BERT-Large) ۲۴ لایه، بُعد ۱۰۲۴ و حدود ۳۴۰ میلیون پارامتر. ورودی با توکن‌های ویژه ساخته می‌شود: [CLS] در ابتدا، [SEP] بین دو جمله و در انتها، و [MASK] برای جای واژهٔ پوشانده‌شده. برای یک ورودی با مثلاً ۷۱ توکن، خروجی هر لایه ماتریسی $H \in \mathbb{R}^{۷۱\times ۷۶۸}$ است: یک بردار ۷۶۸بعدی برای هر توکن.

برای پیش‌بینی واژهٔ ماسک‌شده، روی خروجی لایهٔ ۱۲ یک لایهٔ خروجی قرار می‌گیرد (روی تخته: «یک لایه خطی روی لایه ۱۲ گذاشته می‌شود»). ابعاد آن روی تخته چنین نوشته شده بود (شکل زیر): بردار ۷۶۸×۱ در موقعیت ماسک، با یک لایهٔ خطی ۷۶۸×۷۶۸ به بردار پنهان ۷۶۸×۱ و سپس با لایهٔ $V \times ۷۶۸$ به لاجیت‌هایی به‌طول $V = ۳۰۵۲۲$ می‌رسد. Softmax روی این لاجیت‌ها احتمال هر واژهٔ فرهنگ را می‌دهد.

$$H_{\text{mask}} \in \mathbb{R}^{۱\times ۷۶۸} \xrightarrow{\text{Linear: } 768\times 768} \text{Hidden} \in \mathbb{R}^{۱\times ۷۶۸} \xrightarrow{\text{Linear: } 768\times 30522} \text{Logits} \in \mathbb{R}^{۱\times ۳۰۵۲۲}$$

شکل ۱۳.۹: ابعاد سر MLM در BERT: بردار موقعیت ماسک با دو لایهٔ خطی به لاجیت‌هایی به‌طول اندازهٔ واژگان تبدیل می‌شود. (بازسازی‌شده از تختهٔ کلاس)

جزئیات دقیق BERT و وضعیت NSP

- در MLM حدود ۱۵ درصد توکن‌های ورودی برای پیش‌بینی انتخاب می‌شوند. از این توکن‌های انتخاب‌شده، ۸۰ درصد با [MASK] جایگزین می‌شوند، ۱۰ درصد با یک توکن تصادفی و ۱۰ درصد بدون تغییر می‌مانند.

دلیل این ترکیب آن است که [MASK] در زمان استفاده هرگز وجود ندارد و مدل نباید فقط بر آن تکیه کند. خطا فقط روی همین توکن‌های انتخاب‌شده حساب می‌شود.

- در NSP، نیمی از نمونه‌ها ادامهٔ واقعی (IsNext) و نیم دیگر جملهٔ تصادفی (NotNext) هستند. بعدها پژوهش‌هایی مانند RoBERTa نشان دادند که حذف NSP آسیبی نمی‌زند (و حتی مفید است)؛ بنابراین NSP بخش ضروری ایدهٔ پیش‌آموزش نیست، هرچند در توضیح BERT اصلی جزو آن بود.
- عدد ۳۰۵۲۲ اندازهٔ واژگان WordPiece در bert-base-uncased (انگلیسی) است. مدل‌های فارسی یا چندزبانه واژگان متفاوتی دارند، پس V به مدل بستگی دارد. توکن‌ها زیرواژه‌اند و همیشه با واژه برابر نیستند.
- دو خروجی MLM و NSP فقط برای پیش‌آموزش‌اند و هنگام استفاده معمولاً کنار گذاشته می‌شوند.

۴.۶.۹ استفاده از BERT: استخراج بردار و انتقال یادگیری

پس از پیش‌آموزش، سر MLM دیگر به کار ما نمی‌آید و حذف می‌شود؛ وزن‌های لایه‌های ۱ تا ۱۲ نگه داشته می‌شوند. دو شیوهٔ استفاده روی تخته آمده بود:

۱. **استخراج بردار:** یک جمله به شبکه می‌دهیم؛ خروجی لایهٔ ۱۲ برای هر واژه یک بردار ۷۶۸ عددی اعشاری است. با برداشتن اندیس واژهٔ موردنظر، Embedding بافتی آن واژه به دست می‌آید؛ و با میانگین‌گیری روی همهٔ واژه‌ها، یک Embedding برای کل جمله ساخته می‌شود.

۲. **انتقال یادگیری** (Transfer Learning): روی کل شبکه یک دسته‌بند می‌گذاریم و با داده‌ای محدود و مرتبط با Task خود، همان لایه (و در صورت نیاز کل شبکه) را آموزش می‌دهیم (Fine-tuning).

[محتوای افزوده] نکته درباره بردار جمله

میانگین‌گیری بردارهای توکن‌ها روشی ساده و رایج برای ساخت بردار جمله است، اما بردار [CLS] یا میانگین لایه‌های مختلف هم گاهی استفاده می‌شود و کیفیت هر روش به Task بستگی دارد. مدل‌هایی که مخصوصاً برای بردار جمله آموزش دیده‌اند معمولاً برای مقایسهٔ شباهت جمله‌ها از میانگین خام BERT بهترند.

پرسش: آیا افزودن لایهٔ بیشتر (Linear یا MLP) همیشه بهتر است؟

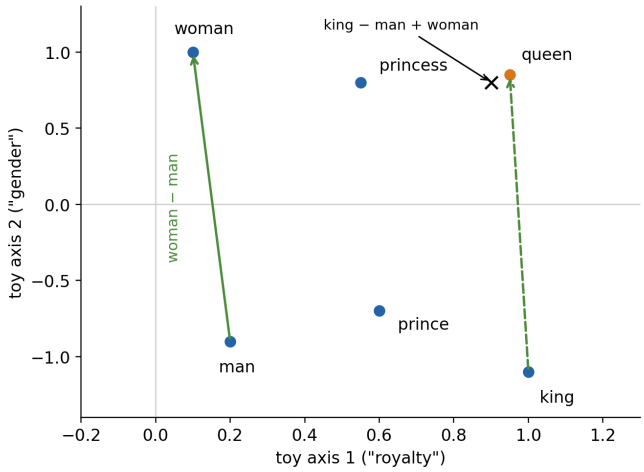
نمی‌توان قطعی گفت که افزودن یک لایه یا MLP به‌طور حتم عملکرد را بهتر یا بدتر می‌کند. اگر یک لایهٔ ساده مسئله را حل می‌کند، دلیلی برای پیچیده‌تر کردن نیست؛ اگر عملکرد خوب نیست، شاید لازم باشد ظرفیت بخش دسته‌بند بیشتر شود. تصمیم باید بر اساس خطای آموزش، خطای اعتبارسنجی و وضعیت بایاس/واریانس گرفته شود. در همین زمینه به نسخه‌های مختلف BERT (پایه و بزرگ) هم اشاره شد.

۷.۹ قیاس برداری (Analogy) در فضای Embedding

اگر روابط معنایی یا ساختاری به‌خوبی در فضای Embedding بازتاب یافته باشند، اختلاف بردارهای دو جفت واژهٔ هم‌رابطه ممکن است تقریباً یکسان باشد. مثال مشهور:

$$\vec{v}_{\text{king}} - \vec{v}_{\text{man}} + \vec{v}_{\text{woman}} \approx \vec{v}_{\text{queen}} \quad \Longleftrightarrow \quad \vec{v}_{\text{woman}} - \vec{v}_{\text{man}} \approx \vec{v}_{\text{queen}} - \vec{v}_{\text{king}}.$$

یعنی «جهت» مفهوم «زن‌بودن در برابر مردبودن» در دو جفت یکی است. استاد توضیح داد که چنین الگوهایی نشانهٔ سازمان‌یافتگی مفید فضای Embedding هستند، اما برای همهٔ واژه‌ها و همهٔ مدل‌ها تضمین‌شده نیستند.



شکل ۱۴.۹: نمودار دوبعدی ساختگی برای قیاس برداری: بردار «زن − مرد» (پیکان پیوسته) تقریباً با «ملکه − شاه» (پیکان خط‌چین) موازی است و king − man + woman نزدیک نقطهٔ ملکه می‌افتد. محورها در فضای واقعی تفسیر ساده ندارند. (شکل افزوده)

[محتوای افزوده] مثال عددی: قیاس برداری با شباهت کسینوسی

فرض کنید در یک فضای دوبعدی ساختگی مختصات واژه‌ها به این صورت باشد: $\text{man} = (۰٫۲, -۰٫۹)$، $\text{woman} = (۰٫۱, ۱٫۰)$، $\text{king} = (۱٫۰, -۱٫۱)$، $\text{queen} = (۰٫۹۵, ۰٫۸۵)$، $\text{prince} = (۰٫۶, -۰٫۷)$ و $\text{princess} = (۰٫۵۵, ۰٫۸)$. بردار هدف:

$$t = \text{king} - \text{man} + \text{woman} = (۱٫۰ - ۰٫۲ + ۰٫۱,\ -۱٫۱ + ۰٫۹ + ۱٫۰) = (۰٫۹,\ ۰٫۸).$$

شباهت کسینوسی $\cos(a,b) = \dfrac{a \cdot b}{\|a\|\,\|b\|}$ را برای ملکه حساب می‌کنیم: $a \cdot b = ۰٫۹ \times ۰٫۹۵ + ۰٫۸ \times ۰٫۸۵ = ۱٫۵۳۵$، $\|t\| = ۱٫۲۰۴$، $\|\text{queen}\| = ۱٫۲۷۵$، پس $\cos \approx ۱٫۵۳۵/(۱٫۲۰۴ \times ۱٫۲۷۵) \approx ۰٫۹۹۹۹$. برای بقیه:

واژه	queen	princess	woman	girl	prince	man
$\cos(t,\cdot)$	۱٫۰۰۰	۰٫۹۷۱	۰٫۷۳۵	۰٫۵۵۲	−۰٫۰۱۸	−۰٫۴۸۶

نزدیک‌ترین واژه به t ملکه است. توجه کنید که در آزمون‌های واقعی واژه‌های ورودی (king، man، woman) از فهرست پاسخ‌ها کنار گذاشته می‌شوند؛ وگرنه معمولاً خود یکی از آن‌ها (مثلاً king) نزدیک‌ترین است.

۱.۷.۹ قیاس در Embedding واج‌ها

همین ایده در گفتار هم مطرح است. استاد به مقاله‌ای با عنوان «[b] = [d] − [t] + [p]: مدل‌های گفتاری خودنظارتی حساب برداری واجی را کشف می‌کنند» (چوی و همکاران) اشاره کرد. بر اساس چکیدهٔ آن مقاله، در فضای بازنمایی مدل‌های گفتاری خودنظارتی جهت‌های خطی متناظر با ویژگی‌های واجی وجود دارد؛ تفاضل $[d] - [t]$ یک «بردار واک‌داری» (Voicing) می‌دهد، افزودن آن به $[p]$ تقریباً $[b]$ را می‌دهد، و مقیاس‌کردن آن، پیوستاری از واک‌داری ایجاد می‌کند. مقاله گزارش می‌دهد که از این بردارها می‌توان برای کنترل سنتز گفتار هم استفاده کرد. روی تخته هم همین مثال آمده بود:

$$\vec{v}_{[d]} - \vec{v}_{[t]} + \vec{v}_{[p]} \approx \vec{v}_{[b]}, \qquad \text{یعنی} \qquad \vec{v}_{[d]} - \vec{v}_{[t]} \approx \vec{v}_{[b]} - \vec{v}_{[p]}.$$

در هر دو جفت، تفاوت اصلی «واک‌داری» است؛ ویژگی‌هایی مانند جایگاه تولید (Place of Articulation) و شیوهٔ تولید (Manner of Articulation) نیز می‌توانند جهت‌های مشابهی داشته باشند.



[b] = [d] − [t] + [p]: Self-supervised Speech Models Discover Phonological Vector Arithmetic

Kwanghee Choi[1], Eunjung Yeo[1], Cheol Jun Cho[2], David Harwath[1], David R. Mortensen[3]
[1]UT Austin, [2]UC Berkeley, [3]CMU

arXiv:2602.18899v4 [eess.AS] 6 Oct 2026

Abstract

Self-supervised speech models (S3Ms) are known to encode rich phonetic information, yet how this information is structured remains underexplored. We conduct a comprehensive study across 96 languages to analyze the underlying structure of S3M representations, with particular attention to phonological vectors. We first show that there exist linear *directions* within the model's representation space that correspond to phonological features. We further demonstrate that the *scale* of these phonological vectors correlate to the degree of acoustic realization of their corresponding phonological features in a continuous manner. For example, the difference between [d] and [t] yields a voicing vector: adding this vector to [p] produces [b], while scaling it results in a continuum of voicing. Together, these findings indicate that S3Ms encode speech using phonologically interpretable and compositional vectors, demonstrating phonological vector arithmetic. All code and interactive demos are available at https://github.com/juice500ml/phonetic-arithmetic.

1 Introduction

The same year that word2vec (Mikolov et al., 2013a), a self-supervised method for distributional dense word representations, was introduced, Mikolov et al. (2013b) showed that these representations encode linguistically meaningful relations through vector arithmetic (fig. 1), *i.e.*,

$$\mathbf{v}_{\text{king}} - \mathbf{v}_{\text{man}} + \mathbf{v}_{\text{woman}} \simeq \mathbf{v}_{\text{queen}}, \quad (1)$$

providing a ready explanation for how word2vec represents semantics.[1] In this paper, we ask: Do self-supervised speech models (S3Ms) represent phonology in an analogous compositional manner?

[1]Many have argued that the analogy test used in Mikolov et al. (2013b), which differs from ours, can be fragile in practice; see § A.1 for details.

Figure 1: Comparing analogies for text and speech. Word representations enable semantic analogies[2], while speech representations enable phonological analogies. Such analogies (§ 3) can be used to control speech synthesis in a phonologically grounded manner (§ 4).

S3Ms, a class of neural networks trained on large quantities of unlabeled speech, have demonstrated strong performance across various downstream tasks, including speech recognition, synthesis, and spoken language understanding (Baevski et al., 2020; Hsu et al., 2021; Chen et al., 2022). Consequently, many studies have sought to understand what properties of S3M representations support this performance.

Early analyses primarily investigated **what** information S3M representations encode (Pasad et al., 2021). Empirical studies have shown that S3Ms organize speech according to relative distances that reflect acoustic similarity (Choi and Yeo, 2022), and that these representations form clusters corresponding to phonetic units (Wells et al., 2022; Choi et al., 2025). However, **how** this information is structured is still underexplored.

Building on prior observations and linguistic intuition, we aim to refine the current understanding of S3Ms. In § 3, we propose a hypothesis: *Phono-*

[2]Word analogies borrowed from Ethayarajh et al. (2019).

شکل ۱۵.۹: صفحهٔ نخست مقالهٔ «[b] = [d] − [t] + [p]». شکل ۱ مقاله قیاس واژه‌ای (king - man + woman) را با قیاس واجی ([b] = [d] - [t] + [p]) مقایسه می‌کند. (برگرفته از تختهٔ کلاس)

۲.۷.۹ کاربردهای مطرح‌شده

در بحث کلاس چند ایده مطرح شد: کشف ویژگی‌های آموخته‌شدهٔ مدل؛ کمک به پیش‌بینی در فضای Embedding؛ سنجش دقت مدل (روی تخته: «میزان دقت مدل را فهمید»)؛ بررسی ویژگی‌های مرتبط با لهجه؛ و کاربرد احتمالی در سنتز گفتار و شبیه‌سازی صدا (Voice Cloning). دربارهٔ لهجه، ایدهٔ استاد این بود که اگر بتوان برداری متناظر با یک ویژگی لهجه پیدا کرد، شاید بتوان آن را برای انتقال آن ویژگی در سنتز به کار برد. این در کلاس یک ایدهٔ قابل بررسی بود، نه نتیجه‌ای قطعی؛ و افزایش تفسیرپذیری بازنمایی‌ها از اهداف دیگر این رویکرد است.

محدودیت‌های قیاس برداری

قیاس‌هایی مانند $\text{king} - \text{man} + \text{woman} \approx \text{queen}$ در مثال‌های خوب‌انتخاب‌شده و برای Embedding ایستا (مانند Word2Vec) به‌خوبی دیده می‌شوند، اما همیشه برقرار نیستند. بسیاری از روابط شکست می‌خورند، نتیجه به کنار گذاشتن واژه‌های ورودی از نامزدها وابسته است، و این روابط می‌توانند سوگیری‌های داده (مثلاً کلیشه‌های جنسیتی) را هم منعکس کنند. در Embedding بافتی هم هر واژه یک بردار ثابت ندارد، بنابراین باید بازنمایی‌ها را به‌شکل مناسبی (مثلاً میانگین روی رخدادها) تعریف کرد. نتیجه: قیاس برداری یک ابزار تحلیل شهودی است، نه قانون.

۸.۹ کاوش (Probing) و تفسیرپذیری

۱.۸.۹ Probing چیست؟

روی تخته پرسش‌های محوری چنین بود: «درون جعبهٔ سیاه یک شبکهٔ عصبی چه می‌گذرد؟ لایه‌های مختلف دقیقاً چه نوع اطلاعاتی را در خود ذخیره می‌کنند؟» استاد Probing را به پروب‌زدن در مدار الکترونیکی تشبیه کرد: در نقاط مختلف مدار اندازه می‌گیریم تا ببینیم چه اتفاقی افتاده است.

دسته‌بند کاوشگر (Probing Classifier)

Probe یک مدل کوچک و ساده (معمولاً یک لایهٔ خطی یا رگرسیون لجستیک) است که روی خروجی یک لایهٔ مشخص از یک شبکهٔ آموزش‌دیده و منجمدشده آموزش داده می‌شود تا یک ویژگی زبانی یا گفتاری را پیش‌بینی کند. دقت این دسته‌بند معیار این است که آن اطلاعات در آن لایه تا چه حد «قابل استخراج» است.

۲.۸.۹ روش انجام

۱. یک مدل پیش‌آموزش‌دیده را انتخاب و وزن‌هایش را فریز (ثابت) می‌کنیم.

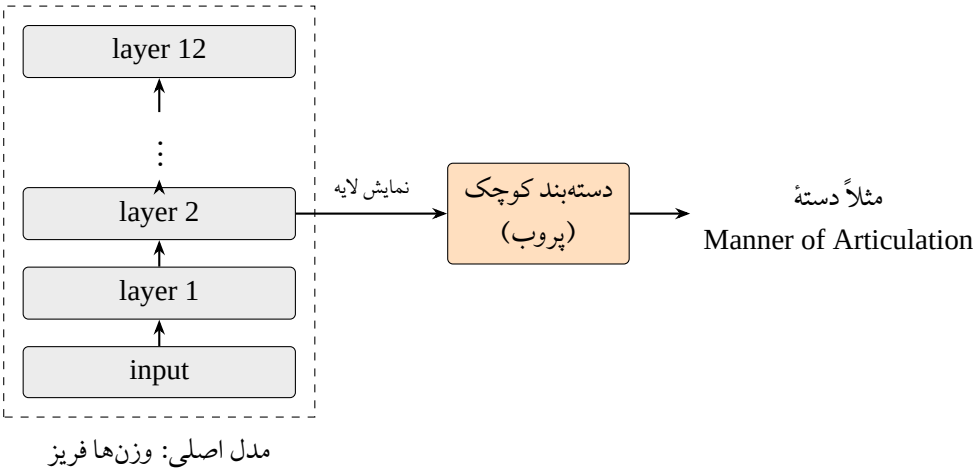
۲. یک لایه (مثلاً یکی از لایه‌های میانی) را برای قرار دادن پروب انتخاب می‌کنیم؛ پرسش تخته‌ای: «کجا پراب بگذارم؟ لایه‌های میانی».

۳. نمایش‌های آن لایه را برای داده‌های برچسب‌دار استخراج می‌کنیم؛ مثلاً برای دنبالهٔ واج ورودی (Task: Phoneme Recognition)، دستهٔ Manner of Articulation هر توکن که پروب باید با یک دسته‌بند در سطح توکن (Token Classification) مشخص کند.

۴. یک دسته‌بند کوچک روی این نمایش‌ها آموزش می‌دهیم.

۵. دقت (Accuracy) را روی داده‌ای کنار گذاشته‌شده می‌سنجیم.

اگر پروب بتواند کلاس‌ها را با دقت خوبی تشخیص دهد، شاهدی داریم که آن اطلاعات در بازنمایی آن لایه وجود دارد. هدف اصلی از نگاه استاد این نیست که صرفاً بپرسیم ویژگی دقیقاً در کدام لایه آموخته شده، بلکه این است که آیا مدل اساساً آن اطلاعات را یاد گرفته یا نه. نمونه‌هایی که در کلاس بررسی شد: اطلاعات واجی، زبان، گوینده، و ویژگی‌هایی مانند شیوهٔ تولید (مثلاً تفکیک واکه‌ها و خیشومی‌ها).



شکل ۱۶.۹: ساختار Probing: فقط پروب آموزش می‌بیند و مدل اصلی ثابت می‌ماند. (شکل افزوده)

۳.۸.۹ تفاوت Visualization و Probing

برای نمایش Embeddingها معمولاً از کاهش بُعد (مانند PCA و t-SNE) استفاده می‌شود. ممکن است در تصویر ببینیم دو کلاس از هم جدا شده‌اند، اما استاد تأکید کرد که این تصویر به‌تنهایی ثابت نمی‌کند مدل آن اطلاعات را به‌خوبی یاد گرفته است؛ برای شواهد دقیق‌تر باید یک Task تعریف کرد و عملکرد آن را کمّی سنجید.

	Visualization	Probing
ماهیت	نمایش هندسی بردارها	ارزیابی اطلاعات قابل استخراج
روش	غالباً مبتنی بر کاهش بُعد	مبتنی بر یک Task مشخص
نتیجه	عمدتاً بصری	معیار کمّی مانند Accuracy
کاربرد	درک شهودی	ارائهٔ شواهد کمّی

جدول ۵.۹: مقایسهٔ تجسم و کاوش.

این مباحث در چارچوب **هوش مصنوعی توضیح‌پذیر** (Explainable AI) و **تفسیرپذیری** (Interpretability) قرار می‌گیرند: تلاش برای فهمیدن اینکه شبکه چه چیزهایی آموخته و چگونه از اطلاعات استفاده می‌کند.



شکل ۱۷.۹: نمایش t-SNE بازنمایی‌های یک مدل گفتاری خودنظارتی برای سه مدل (آموزش‌دیده روی انگلیسی، فرانسوی و هر دو) با رنگ‌بندی بر اساس دستهٔ واج (سایشی، انسدادی، خیشومی، واکه و ...). خوشه‌های نسبتاً جدا دیده می‌شوند، اما این تصویر به‌تنهایی کمیت اطلاعات را اثبات نمی‌کند. (برگرفته از تختهٔ کلاس)

Probing چه چیزی را ثابت می‌کند؟

دقت بالای یک پروب نشان می‌دهد اطلاعات در نمایش وجود دارد و قابل استخراج است، اما ثابت نمی‌کند خود مدل از آن برای حل Task اصلی استفاده می‌کند. همچنین اگر پروب بسیار پیچیده باشد، ممکن است خودش Task را یاد بگیرد و نتیجه دربارهٔ نمایش چیزی نگوید؛ به همین دلیل پروب‌ها را ساده (مثلاً خطی) می‌گیرند و دقت را با یک مبنا (مثلاً مدل با وزن‌های تصادفی یا یک Control Task) مقایسه می‌کنند. در t-SNE نیز فاصله‌ها و اندازهٔ خوشه‌ها همیشه معنای دقیق ندارند و نتیجه به ابرپارامترها حساس است.

۹.۹ بازگشت به TTS: تلفظ درست هر واژه

۱.۹.۹ جایگاه مسئله در خط لولهٔ TTS

در بخش پیشین دیدیم که Front-End در TTS پس از **نرمال‌سازی متن** (Text Normalization) باید تلفظ را مشخص کند. این کار با **تبدیل نویسه به واج** (Grapheme-to-Phoneme, G2P) انجام می‌شود. در فارسی، چون بسیاری از حرکات کوتاه نوشته نمی‌شوند، دو دشواری اصلی داریم: **هم‌نویسه‌ها** (Homograph) (یک شکل نوشتاری با تلفظ‌های متفاوت) و **واژه‌های خارج از واژگان** (Out-of-Vocabulary, OOV) (واژه‌ای که در فرهنگ تلفظ نیست).

نوشتار	تلفظ و معنی ۱	تلفظ و معنی ۲	ابزار تفکیک
مرد	/mærd/ «انسان مذکر» (اسم)	/mord/ «درگذشت» (فعل)	نقش دستوری (POS)
کرم	/kerm/ «جانور خاکی»؛ /kerem/ «ماده مرطوب‌کننده»	/kæræm/ «بخشندگی» (مثال افزوده)	معنای بافتی
گرم	/gærm/ «داغ»	/geræm/ «واحد جرم»	معنای بافتی

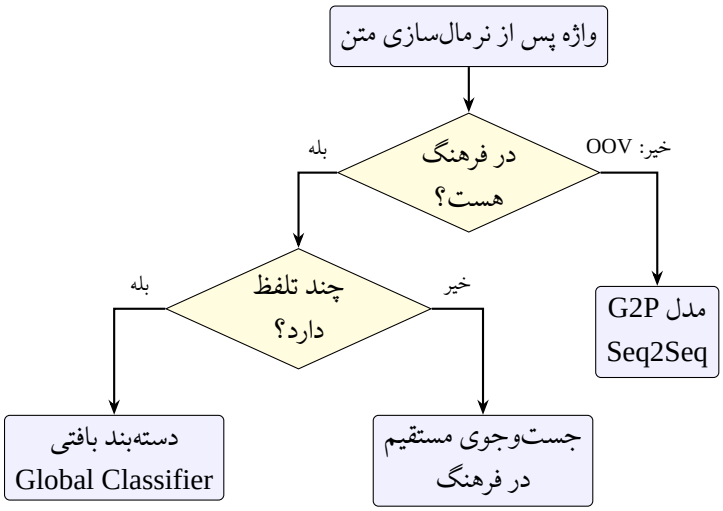
جدول ۶.۹: نمونه‌هایی از هم‌نویسه‌های فارسی (بر اساس مثال‌های کلاس و تخته؛ نمادهای IPA به‌صورت تقریبی‌اند).

روی تخته توضیح داده شده بود که بسیاری از هم‌نویسه‌ها با تشخیص نقش دستوری یا معنای واژه در بافت قابل تفکیک‌اند: در «او مُرد» (فعل) و «آن مَرد رفت» (اسم) یک برچسب‌زن POS (مثلاً hazm) با تکیه بر دستور جمله کافی است. اما

برای دو واژهٔ هم‌نقش، مانند «کِرم» خاکی و «کِرِم» مرطوب‌کننده که هر دو اسم‌اند، برچسب دستوری کمکی نمی‌کند و به بازنمایی بافت معنایی، یعنی Embedding بافتی، نیاز داریم.

۲.۹.۹ طرح مهندسی: از ارزان به گران

استاد مسیر زیر را پیشنهاد کرد (شکل ۱۸.۹): پس از نرمال‌سازی، بررسی کنیم واژه در فرهنگ تلفظ هست یا نه. اگر هست و فقط یک تلفظ دارد، جست‌وجوی مستقیم؛ اگر چند تلفظ دارد، یک دسته‌بند بافتی؛ و اگر نیست (OOV)، واژه را به نویسه‌هایش بشکنیم و با یک مدل G2P از نوع Sequence-to-Sequence تلفظ را پیش‌بینی کنیم.



شکل ۱۸.۹: طرح تصمیم برای یافتن تلفظ: تا جای ممکن از روش‌های ارزان‌تر استفاده می‌شود. (شکل افزوده)

۳.۹.۹ رفع ابهام هم‌نویسه با دسته‌بندی

اگر واژه فقط یک تلفظ ثبت‌شده دارد، همان را برمی‌داریم. اگر چند تلفظ دارد، باید یکی را متناسب با جمله انتخاب کنیم؛ این یک مسئلهٔ دسته‌بندی است، و اگر بیش از دو تلفظ ممکن باشد دسته‌بندی چندکلاسه. ورودی دسته‌بند همان Embedding بافتی واژه است: جمله را وارد یک مدل Embedding (مثلاً BERT) می‌کنیم و بردار خروجی در موقعیت واژهٔ مبهم را به دسته‌بند می‌دهیم.

چرا یک دسته‌بند سراسری؟

پرسش کلاسی: چرا برای هر هم‌نویسه (مثلاً از ۵۰۰ هم‌نویسه) یک دسته‌بند جدا نسازیم؟ استاد دو دلیل برای **دسته‌بند سراسری** (Global Classifier) آورد:

۱. **اشتراک ویژگی‌ها:** نشانه‌های لازم برای تشخیص تلفظ میان واژه‌ها مشترک است؛ مثلاً قواعد نحوی، ساختاری و معنایی زبان. روی تخته نمونه‌قاعده این بود: «اگر قبل از کلمه حرف تعریف، ضمیر ملکی یا صفت آمد، یا کلمه

در جایگاه فاعل یا مفعول نشست، این کلمه اسم است؛ پس کاندیدایی را فعال کن که برچسب اسمی دارد.» یک مدل مشترک می‌تواند چنین ویژگی‌هایی را یک بار یاد بگیرد و برای چند هم‌نویسه به کار ببرد.

۲. **کمبود داده:** برخی هم‌نویسه‌ها نمونهٔ فراوان دارند و برخی کم. دسته‌بند جداگانه روی واژه‌های کم‌تکرار یا بیش‌برازش می‌شود یا اصلاً یاد نمی‌گیرد. با وزن‌های مشترک (Shared Weights)، دانش از واژه‌های پرتکرار به واژه‌های کم‌تکرار منتقل می‌شود (Cross-word Transfer Learning).

دسته‌بند شرطی (ماسک‌کردن کلاس‌های نامعتبر)

اگر دسته‌بند سراسری روی مجموعهٔ بزرگی از تلفظ‌ها لاجیت می‌دهد، باید مطمئن شویم فقط تلفظ‌های معتبرِ همان واژه انتخاب می‌شوند. راه‌حل: پیش از Softmax، لاجیت تلفظ‌های نامعتبر را برابر $-\infty$ می‌گذاریم:

$$z'_i = \begin{cases} z_i & \text{اگر تلفظ } i \text{ باشد، برای این واژه معتبر} \\ -\infty & \text{در غیر این صورت،} \end{cases} \qquad P_i = \mathrm{Softmax}(z')_i.$$

روی تخته هم برای واژهٔ «گرم» (کلاس‌های «garm» و «geram») نوشته شده بود: «گرفتن بیشینه فقط روی واج‌های مرتبط» (Getting maximum over only associated phonemes).

[محتوای افزوده] مثال عددی: ماسک‌کردن کلاس‌ها

فرض کنید برای واژهٔ «گرم» لاجیت‌ها چنین باشند: garm: ۲٫۰، geram: ۰٫۵ و تلفظ نامعتبر دیگری (مربوط به واژهٔ دیگر): ۳٫۰. بدون ماسک، $e^{۲} = ۷٫۳۸۹$، $e^{۰٫۵} = ۱٫۶۴۹$ و $e^{۳} = ۲۰٫۰۸۶$ و مجموع ۲۹٫۱۲۴ است و احتمال‌ها (۰٫۲۵۴, ۰٫۰۵۷, ۰٫۶۹۰) می‌شود؛ یعنی کلاس نامعتبر برنده است. با ماسک، فقط دو کلاس معتبر می‌مانند: مجموع ۹٫۰۳۸ و احتمال‌ها (۰٫۸۱۸, ۰٫۱۸۲)؛ و garm انتخاب می‌شود.

Greedy یا Sampling؟

پرسش استاد (که کنار شکل روی تخته هم نوشته بود: «اینجا Argmax یا تصادفی؟») پاسخ روشنی داشت: Greedy یا Argmax. در اینجا هدف انتخاب تلفظ درست است و برخلاف تولید متن خلاقانه به تنوع نیاز نداریم؛ پس پراحتمال‌ترین تلفظ معتبر انتخاب می‌شود.

۱۰.۹ واژه‌های ناشناخته و G2P از نوع Sequence-to-Sequence

۱.۱۰.۹ مسئله و داده

برای واژه‌ای که در فرهنگ نیست نمی‌توان جست‌وجوی مستقیم کرد. ایده: واژه را به واحدهای کوچک‌تر، یعنی نویسه‌ها (Character) بشکنیم و مدل، با تکیه بر الگوهایی که از دادهٔ آموزشی یاد گرفته، تلفظ را پیش‌بینی کند. داده‌های آموزشی

را از خود فرهنگ تلفظ می‌سازیم: ورودی، دنبالهٔ نویسه‌های واژه و خروجی، دنبالهٔ واج‌های تلفظ درست:

$$[g_۱, g_۲, \ldots, g_n] \longrightarrow [p_۱, p_۲, \ldots, p_m], \qquad n \neq m \text{(در حالت کلی)}.$$

نمونه‌هایی از این نابرابری طول را در فرهنگ تلفظ KaamelDict (شکل ۱۲.۷ در فصل هفتم) می‌توان دید؛ برای نمونه «شستشوهنده» و «واترپولو».

[محتوای افزوده] مثال: چرا $n \neq m$؟ (نمونه‌های فارسی)

واژه	نویسه‌ها	n	واج‌ها (IPA)	m	علت
مدرسه	م، د، ر، س، ه	۵	m æ d ɾ e s e	۷	حرکات کوتاه نوشته نمی‌شوند؛ «ه» پایانی /e/ است
خواب	خ، و، ا، ب	۴	x ɒ b	۳	«و» پس از «خ» تلفظ نمی‌شود
مرد	م، ر، د	۳	m æ ɾ d	۴	واکهٔ کوتاه /æ/ نوشته نمی‌شود

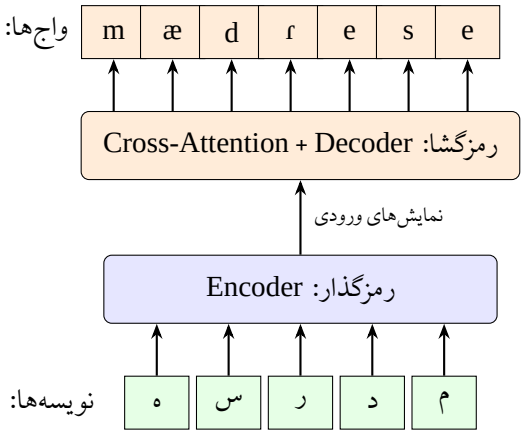
پس نمی‌توان فرض کرد برای هر نویسه دقیقاً یک واج می‌آید. روی تخته هم نوشته شده بود که «در برخی زبان‌ها نگاشت یک به یک است» اما در فارسی استثنا، تشدید و سکون داریم.

۲.۱۰.۹ چرا Seq2Seq؟

دسته‌بندی چندکلاسهٔ ساده یک ورودی را به یک برچسب از میان تعدادی کلاس ثابت می‌نگارد. اما در G2P باید یک دنباله تولید کنیم و طول آن به ورودی بستگی دارد و از پیش معلوم نیست. این مسئله از نوع **دنباله به دنباله** (Sequence-to-Sequence) است: دنبالهٔ ورودی ← دنبالهٔ خروجی.

۳.۱۰.۹ معماری رمزگذار-رمزگشا

- **رمزگذار** (Encoder): دنبالهٔ نویسه‌ها را می‌گیرد و نمایشی از ورودی می‌سازد که اطلاعات لازم برای تولید تلفظ را دارد (این مرحله، همان مفهوم Embedding و درک دنباله است).
- **بردار زمینه** (Context Vector): در توضیح تخته‌ای، آخرین حالت رمزگذار اطلاعات ورودی را خلاصه می‌کند و به رمزگشا می‌دهد. در معماری‌های دارای Attention، رمزگشا به‌جای تکیه بر یک بردار ثابت به همهٔ حالت‌های خروجی رمزگذار دسترسی دارد.
- **رمزگشا** (Decoder): دنبالهٔ واج‌ها را گام‌به‌گام تولید می‌کند. برای واج بعدی از اطلاعات رمزگذاری‌شدهٔ ورودی، واج‌های قبلاً تولیدشده و حالت فعلی خودش استفاده می‌کند.



شکل ۱۹.۹: مدل G2P با رمزگذار-رمزگشا برای واژهٔ «مدرسه» (۵ نویسه به ۷ واج). (شکل افزوده)

۴.۱۰.۹ Cross-Attention

در Self-Attention یک دنباله برای ساخت نمایش خودش به عناصر همان دنباله توجه می‌کند. در Cross-Attention یک دنباله (رمزگشا) به نمایش‌های دنبالهٔ دیگری (خروجی رمزگذار) توجه می‌کند. در G2P، رمزگشا در حال تولید واج‌هاست؛ اطلاعات نویسه‌ها را رمزگذار آماده کرده است؛ و رمزگشا هنگام تولید واج بعدی می‌تواند به بخش‌های مرتبط ورودی توجه کند. تفاوت از نگاه کلاس: در Embedding بافتی هدف ساخت نمایش یک عنصر با توجه به متن خودش بود، ولی در رمزگذار-رمزگشا رمزگشا برای ساخت خروجی به اطلاعات دنبالهٔ ورودی مراجعه می‌کند. در Cross-Attention Query از رمزگشا و Key و Value از خروجی رمزگذار می‌آیند.

[محتوای افزوده] آموزش در برابر استنتاج در رمزگشا

در آموزش، به رمزگشا واج‌های درست قبلی داده می‌شود (روشی به نام Teacher Forcing) و خطای Cross-Entropy برای هر موقعیت خروجی جمع می‌شود. در استنتاج واج درست در دست نیست؛ رمزگشا باید واج‌هایی را که خودش تولید کرده در ورودی بعدی استفاده کند و تا تولید نشانهٔ پایان (<EOS>) ادامه دهد. انتخاب هر واج در این مرحله معمولاً با Greedy یا Beam Search انجام می‌شود، نه نمونه‌گیری تصادفی، چون هدف یک تلفظ درست است.

۵.۱۰.۹ مسائل دیگر از نوع Seq2Seq

این معماری فقط برای G2P نیست؛ دو مثال مطرح‌شده: **ترجمهٔ ماشینی** (Machine Translation) (دنبالهٔ زبان مبدأ به دنبالهٔ زبان مقصد با طول احتمالاً متفاوت) و **خلاصه‌سازی انتزاعی** (Abstractive Summarization) (متن ورودی به یک خلاصهٔ تازه). در هر دو، خروجی دنباله است و طولش از پیش معلوم نیست.

۶.۱۰.۹ سطح بایت: مدل ByT5

روی تخته برای OOV به مدل ByT5 (رمزگذار-رمزگشا) اشاره شده بود: مدلی که متن را در سطح بایت‌های UTF-8 (نویسه‌به‌نویسه) می‌خواند و بنابراین ورودی‌اش به واژه‌های از پیش‌معلوم وابسته نیست. موجودیت واژه در سطح کلمه شکسته می‌شود و توان تعمیم به واژه‌های دیده‌نشده پیدا می‌کند؛ انتظار این است که قواعد پنهان آوایی زبان را یاد بگیرد (مثلاً الگوی tion را حتی اگر بخشی از واژه ناشناخته بود، «شن» بخواند).

[محتوای افزوده] ورودی بایتی برای فارسی

در رمزگذاری UTF-8 هر نویسهٔ فارسی–عربی (مثل «م» یا «ه») دو بایت می‌گیرد و نیم‌فاصله (ZWNJ) سه بایت. پس واژهٔ پنج‌نویسه‌ای «مدرسه» ۱۰ بایت است و ورودی ByT5 برای آن ۱۰ توکن بایتی خواهد بود؛ دنبالهٔ ورودی نسبت به مدل نویسه‌ای طولانی‌تر می‌شود. ByT5 را می‌توان بر روی جفت‌های (نویسه، واج) فرهنگ تلفظ تنظیم دقیق کرد.

۱۱.۹ ملاحظات مهندسی G2P و بحث پایانی

۱.۱۱.۹ چرا از ابتدا همه چیز را با Seq2Seq حل نمی‌کنیم؟

پرسش دانشجو: اگر G2P دنباله‌به‌دنباله می‌تواند تلفظ همهٔ واژه‌ها را پیش‌بینی کند، چرا اصلاً سراغ فرهنگ و دسته‌بند برویم؟ پاسخ استاد: این یک تصمیم مهندسی است؛ روش‌ها از نظر هزینهٔ محاسباتی، نیاز به داده و پیچیدگی تفاوت دارند. ترتیب پیشنهادی:

۱. فرهنگ تلفظ برای واژه‌هایی که تلفظ مشخص دارند (بسیار کم‌هزینه).

۲. دسته‌بند برای هم‌نویسه‌ها.

۳. مدل G2P دنباله‌به‌دنباله برای واژه‌های OOV (آموزش و محاسبات بیشتر).

استاد با یک شوخی دربارهٔ «اصفهانی‌بودن در مهندسی» تأکید کرد که باید از راه‌حل کم‌هزینه‌تر شروع کرد و فقط در صورت نیاز سراغ گزینه‌های گران‌تر رفت.

آیا همیشه باید از فرهنگ شروع کنیم؟

خیر. این ترتیب یک قاعدهٔ مهندسی است، نه الزام. اگر برای پروژهٔ شما فرهنگ مناسبی وجود ندارد یا زبان ورودی پر از واژه‌های جدید، محاوره‌ای و ساختارهای ناشناخته است (مثلاً متن شبکه‌های اجتماعی)، استفادهٔ مستقیم از مدل G2P می‌تواند منطقی باشد. انتخاب معماری به شرایط پروژه بستگی دارد.

۲.۱۱.۹ ذخیره‌خروجی مدل در فرهنگ

پرسش پایانی: وقتی مدل G2P برای یک واژهٔ OOV تلفظی ساخت، آیا لازم است دفعهٔ بعد دوباره مدل را اجرا کنیم؟ راهکار پیشنهادی: نتیجه را ذخیره (Cache) و در مراجعه‌های بعدی استفاده کنیم؛ این کار هزینهٔ استنتاج را کم می‌کند. اما مطرح شد که تلفظ برخی واژه‌ها به بافت وابسته است؛ ذخیرهٔ یک تلفظ ثابت برای همهٔ واژه‌ها همیشه مناسب نیست و اگر تلفظ با جمله تغییر کند، سیستم باید این وابستگی را در نظر بگیرد.

ذخیره‌نتیجه به‌معنای آموزش مجدد نیست

در مرحلهٔ آموزش، مدل G2P با واژه‌هایی که تلفظشان مشخص است آموزش می‌بیند؛ در استنتاج برای واژه‌های جدید تلفظ پیش‌بینی می‌کند. ذخیرهٔ خروجی در فرهنگ یا حافظهٔ نهان یک تصمیم مهندسی جداگانه است و به‌خودی‌خود به معنی آموزش مجدد یا به‌روزرسانی وزن‌های مدل نیست. همچنین تلفظ خودکار ذخیره‌شده ممکن است خطا داشته باشد و بهتر است پیش از افزودن دائمی به فرهنگ بازبینی شود (پیشنهاد افزوده).

۱۲.۹ جمع‌بندی

در این فصل ابتدا لایهٔ خروجی و تابع خطا را بر اساس نوع مسئله (رگرسیون، دودویی، چندکلاسه) مرور کردیم و دیدیم که آموزش و استنتاج رفتار متفاوتی دارند: در آموزش حقیقت مبنا داریم و خطا حساب می‌کنیم، و در استنتاج از توزیع احتمال با روش‌هایی مانند Greedy، Top-k، Top-p و Temperature خروجی می‌گیریم. سپس با مقایسهٔ خطای آموزش و اعتبارسنجی، کم‌برازش (بایاس بالا) و بیش‌برازش (واریانس بالا) را شناختیم و ابزارهایی مانند توقف زودهنگام و منظم‌سازی را دیدیم.

در بخش دوم، Embedding ایستا (جدول جست‌وجو، یک بردار برای هر واژه) را با Embedding بافتی (تابعی از کل جمله و مستلزم اجرای شبکه) مقایسه کردیم. راه‌های ساخت بافتی (RNN/LSTM و Self-Attention) نشان داد که بافتی‌بودن با Transformer هم‌ارز نیست. با یادگیری خودنظارتی (MLM و NSP) BERT آموزش داده می‌شود و بردارهای ۷۶۸بعدی آن برای Taskهای دیگر به کار می‌رود. قیاس برداری و Probing هم روش‌هایی برای فهم اطلاعاتی‌اند که در بازنمایی‌ها ذخیره شده است.

در بخش سوم، این ابزارها به TTS بازگشتند: برای هر واژه ابتدا فرهنگ، برای هم‌نویسه‌ها یک دسته‌بند سراسری با ماسک (و Argmax)، و برای واژه‌های ناشناخته یک مدل G2P رمزگذار-رمزگشا با Cross-Attention.

نکات مهم برای مرور و امتحان

۱. معماری و لایهٔ خروجی را بر اساس Task طراحی کنید؛ لایه و نورون را بدون توجه به عملکرد زیاد نکنید.

۲. برای تشخیص مشکل مدل، خطای آموزش کافی نیست؛ خطای اعتبارسنجی و وضعیت بایاس/واریانس را هم ببینید.

۳. Contextual Embedding را با Transformer یکی نگیرید؛ مسئلهٔ اصلی ساخت نمایش وابسته به متن است و معماری‌های مختلفی (Attention، LSTM) برای آن وجود دارد.

۴. تفاوت ایستا (جدول جست‌وجو، فایل بردارها) و بافتی (وزن‌های شبکه، بردار فقط پس از دادن جمله) را

بدانید.

۵. برای نشان‌دادن اینکه مدل چه اطلاعاتی یاد گرفته، فقط به Visualization اکتفا نکنید؛ Probing و معیارهای کمّی شواهد دقیق‌تری می‌دهند.

۶. در TTS، هم‌نویسه‌ها و واژه‌های OOV دو چالش متفاوت‌اند و با روش‌های متفاوت حل می‌شوند.

۷. دلایل استفاده از دسته‌بند سراسری برای هم‌نویسه‌ها: اشتراک ویژگی‌ها و کمبود داده؛ و در استنتاج کلاس‌های نامعتبر ماسک می‌شوند و Argmax به کار می‌رود.

۸. G2P برای OOV از نوع Seq2Seq است چون طول دنبالهٔ واج‌ها لزوماً برابر طول دنبالهٔ نویسه‌ها نیست.

۹. هزینهٔ محاسباتی مهم است: تا جای ممکن از فرهنگ و روش‌های ساده‌تر استفاده کنید و مدل‌های پیچیده را فقط وقتی لازم است وارد کنید.

اصطلاح	مفهوم
Logit	امتیاز خام پیش از تبدیل به احتمال
Softmax، Sigmoid	تبدیل لاجیت‌ها به توزیع احتمال (چندکلاسه) یا به عدد در $(۰, ۱)$ (دودویی)
Greedy، Sampling، Top-k، Top-p	روش‌های انتخاب خروجی از توزیع احتمال در استنتاج
Temperature	کنترل تیزی توزیع با تقسیم لاجیت‌ها بر T
Early Stopping	توقف آموزش در کمینهٔ خطای اعتبارسنجی
Underfitting، Overfitting	ناتوانی در یادگیری الگوها، یا حفظ‌کردن نویز داده آموزش
Regularization	محدودسازی پیچیدگی مؤثر مدل (Dropout، L1، L2)
Contextual/Static Embedding	بردار ثابت هر واژه / بردار وابسته به جمله
Self-Supervised Learning	ساخت برچسب از خود داده
MLM، NSP	پیش‌بینی توکن ماسک‌شده؛ پیش‌بینی اینکه آیا جملهٔ دوم ادامهٔ جملهٔ اول است
Analogy	قیاس برداری، مانند $\text{king} - \text{man} + \text{woman} \approx \text{queen}$
Probing	آموزش دسته‌بند ساده روی خروجی لایه‌های فریزشدهٔ مدل برای سنجش اطلاعات قابل استخراج
Homograph، OOV	هم‌نویسه با تلفظ‌های متفاوت؛ واژهٔ خارج از فرهنگ
G2P، Seq2Seq، Decoder/Encoder	تبدیل نویسه به واج؛ نگاشت دنباله به دنباله؛ رمزگذار/رمزگشا
Cross-Attention	توجه رمزگشا به نمایش‌های دنبالهٔ ورودی

جدول ۷.۹: اصطلاحات کلیدی فصل.

فصل ۱۰

کدگذاری موقعیت

۱.۱۰ جایگاه این بحث در درس

در جلسه‌های پیشین بحث Embedding را به پایان رساندیم و آخرین موضوع، معماری Sequence-to-Sequence برای پردازش نویسه‌ها (مسئلهٔ G2P) بود. پیش از ادامهٔ آن معماری، باید یکی از مشکلات مهم Embedding پویا (بافتی) و راه‌حل آن را بشناسیم: **کدگذاری موقعیت** (Positional Encoding). پس از آن به معماری قبلی برمی‌گردیم و اجزای بیشتری به شبکه اضافه می‌کنیم تا معماری توانمندتری داشته باشیم. مفاهیم Query، Key، Value و Self-Attention را در فصل قبل (بخش «راه‌های ساخت Embedding بافتی» و بخش Cross-Attention) دیدیم و اینجا فقط به اندازهٔ نیاز مرور می‌کنیم.

نکتهٔ روی تخته

کدگذاری موقعیت فقط در *Embedding* پویا معنا پیدا می‌کند؛ Embedding ایستا مستقل از بافت (context-free) است و در آن اصلاً مسئلهٔ «نقش کلمه نسبت به کلمه‌های دیگر» مطرح نیست.

۲.۱۰ مسئلهٔ ترتیب در Attention

۱.۲.۱۰ دو جمله با کلمات یکسان

دو جملهٔ زیر را در نظر بگیرید:

- «ایران آمریکا را شکست داد.»
- «آمریکا ایران را شکست داد.»

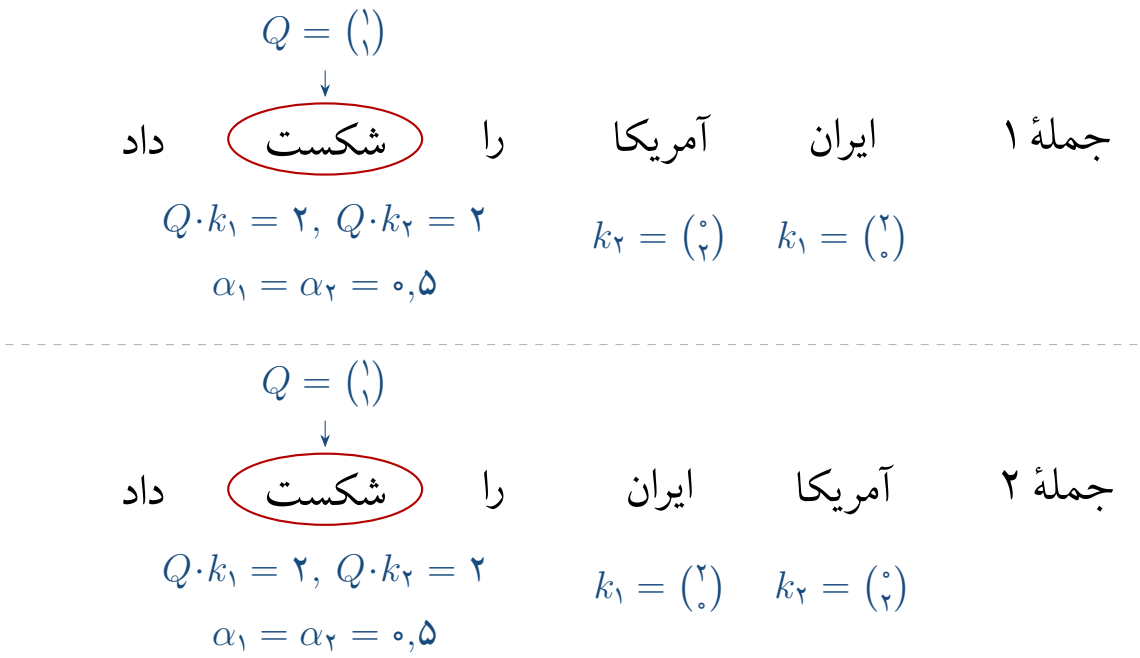
کلمه‌ها یکسان‌اند ولی معنا کاملاً فرق می‌کند: در جملهٔ اول ایران برنده است و در جملهٔ دوم آمریکا. فرض کنید کانون توجه کلمهٔ «شکست» باشد. در Embedding پویا انتظار داریم این کلمه به بقیهٔ جمله «نگاه کند»، اطلاعات لازم را بگیرد و نمایشی وابسته به بافت بسازد. چون نقش کلمه‌ها در دو جمله متفاوت است، نمایش «شکست» در این دو جمله

باید متفاوت باشد. در Embedding ایستا، کلمهٔ «شکست» در ده جملهٔ مختلف اساساً همان بردار ثابت را دارد و این تمایز اصلاً ساخته نمی‌شود؛ ولی در Embedding پویا همین تمایز هدف اصلی است.

۲.۲.۱۰ مرور Query، Key، Value

در رویکرد موازی (Self-Attention) کلمهٔ هدف («شکست») نقش Query را دارد و کلمه‌های دیگر هرکدام یک Key و یک Value دارند. مدل با مقایسهٔ Query با Keyها وزن توجه α_i را برای هر کلمه می‌سازد و بردار بافت را به‌صورت ترکیب وزن‌دار Valueها به دست می‌آورد:

$$\text{Context Vector} = \sum_i \alpha_i V_i.$$



شکل ۱.۱۰: مسئلهٔ ترتیب: کلمهٔ «شکست» (دایره‌شده) در هر دو جمله همان $Q = (۱, ۱)$ را دارد و Key کلمه‌های دیگر هم یکسان است؛ فقط جای آن‌ها عوض شده است. در هر دو جمله $Q \cdot k_۱ = Q \cdot k_۲ = ۲$ و وزن‌ها برابر می‌شوند، پس بدون اطلاعات موقعیت مدل تفاوتی نمی‌بیند. (بازسازی‌شده از تختهٔ کلاس)

۳.۲.۱۰ مثال عددی ساده‌شده کلاس

روی تخته، Query کلمهٔ «شکست» را بردار $q = (۱, ۱)$ و Key دو کلمهٔ دیگر را (طبق خوانش تخته) $k_۱ = (۲, ۰)$ و $k_۲ = (۰, ۲)$ گرفتیم. هر دو ضرب داخلی برابر ۲ می‌شوند:

$$q \cdot k_۱ = ۱\cdot ۲ + ۱\cdot ۰ = ۲, \qquad q \cdot k_۲ = ۱\cdot ۰ + ۱\cdot ۲ = ۲,$$

پس امتیازها برابرند و وزن‌ها $\alpha_۱ = \alpha_۲ = ۰{,}۵$ می‌شوند. اگر Value هر دو را ۱ فرض کنیم، بردار بافت $C = ۰{,}۵ \times ۱ + ۰{,}۵ \times ۱ = ۱$ است. حالا جای دو کلمه را عوض کنید: Key و Value هر کلمه عوض نشده و فقط ترتیب

فهرست جابه‌جا شده است؛ جمع وزن‌دار دقیقاً همان ۱ را می‌دهد. یعنی مدل نمی‌تواند بفهمد کدام کلمه زودتر آمده است.

پرسش: در دو جمله چه چیزی تغییر کرده است؟ پاسخ: موقعیت کلمه‌ها. تا اینجا اطلاعات موقعیت را وارد Embedding نکرده‌ایم، پس در رویکرد موازی مدل فقط «مجموعه‌ای» از نمایش کلمه‌ها را می‌بیند و ترتیب را صریحاً نمی‌داند. راه‌حل، افزودن اطلاعات موقعیت به نمایش هر کلمه است.

کدگذاری موقعیت (Positional Encoding)

افزودن اطلاعات «این عنصر چندمین عنصر دنباله است» به نمایش هر عنصر، تا مدل علاوه بر اینکه بداند هر کلمه چیست، بداند کجا قرار گرفته است. مثلاً در «ایران آمریکا را شکست داد»: «ایران» موقعیت ۱، «آمریکا» موقعیت ۲، «را» موقعیت ۳ و «شکست» موقعیت ۴. با جابه‌جایی کلمه‌ها، اطلاعات موقعیت هم باید متناسب تغییر کند.

دقت: «بی‌توجه به ترتیب» یعنی چه؟

در مثال کلاس برای ساده‌سازی گفته شد که ترتیب کلمه‌ها «اثری ندارد». دقیق‌تر: Self-Attention بدون کدگذاری موقعیت **هم‌متغیر نسبت به جایگشت** (Permutation-Equivariant) است؛ یعنی اگر ورودی را جابه‌جا کنیم، خروجی هر عنصر تغییر نمی‌کند و فقط سطرها همان جابه‌جایی را می‌بینند. بردار بافت یک Query مشخص نسبت به جابه‌جایی فهرست Value/Keyها کاملاً ثابت است (همان چیزی که در مثال بالا دیدیم). این با «ترتیب بی‌اثر است» به یک معنا یکی است، ولی نباید با «Attention هیچ‌چیز از بافت نمی‌فهمد» اشتباه گرفته شود: کلمه‌ها هنوز محتوای هم را می‌بینند و تنها اطلاعات ترتیب از دست می‌رود.

[محتوای افزوده] نمایش عددی: بدون و با کدگذاری موقعیت

سه بردار دوبعدی داریم: $A = (۱, ۰)$، $B = (۰, ۱)$ و بردار کلمهٔ هدف $S = (۱, ۱)$. جملهٔ اول به ترتیب A, B, S و جملهٔ دوم به ترتیب B, A, S است. برای سادگی $W_Q = W_K = W_V = I$ و امتیازها بر $\sqrt{۲}$ تقسیم می‌شوند. خروجی Attention برای S (که همهٔ سه عنصر را می‌بیند):

	ترتیب A, B, S	ترتیب B, A, S
بدون کدگذاری موقعیت	$(۰٫۷۵۲;\ ۰٫۷۵۲)$	$(۰٫۷۵۲;\ ۰٫۷۵۲)$
با افزودن PE سینوسی ($d = ۲$)	$(۱٫۵۰۲;\ ۰٫۸۶۷)$	$(۱٫۷۵۱;\ ۰٫۶۶۰)$

بدون موقعیت دو خروجی یکی است؛ با افزودن PE (ردیف‌های ۰ تا ۲ ماتریس سینوسی، بخش‌های بعد) دو جمله از هم متمایز می‌شوند.

۳.۱۰ آیا مدل‌های بازگشتی هم به کدگذاری موقعیت نیاز دارند؟

بحث کنید (روی تخته)

بحث کنید که آیا در روش بازگشتی هم به پوزیشن انکدینگ نیاز داریم؟

پاسخ مطرح‌شده در کلاس: در رویکرد بازگشتی (LSTM/RNN) عنصرهای دنباله به‌ترتیب پردازش می‌شوند. مدل کلمهٔ اول را می‌بیند و یک حالت پنهان می‌سازد؛ با رسیدن کلمهٔ دوم، حالت پنهان اطلاعات هر دو را در خود دارد؛ و همین‌طور تا انتها. پس ترتیب در خودِ فرایند محاسبه نهفته است. مثلاً اگر در یک دنبالهٔ نویسه‌ای حرف «ت» دو بار تکرار شود، حالت پنهان هنگام دیدن «ت» دوم با حالت پنهان هنگام دیدن «ت» اول یکسان نیست، چون اولی چیزی از گذشته ندارد و دومی اطلاعات نویسه‌های قبلی (از جمله همان «ت» اول) را حمل می‌کند. بنابراین در رویکرد بازگشتیِ بررسی‌شده در کلاس نیازی به افزودن صریح کدگذاری موقعیت، به شکلی که برای رویکرد موازی لازم است، نداریم. در مقابل، در رویکرد موازی همهٔ عنصرها هم‌زمان پردازش می‌شوند و ترتیب خودبه‌خود وارد محاسبهٔ Attention نمی‌شود.

جدول ۱.۱۰: مقایسهٔ منشأ اطلاعات ترتیب در دو رویکرد ساخت Embedding بافتی.

	ترتیبی (LSTM/RNN)	موازی (Self-Attention)
نحوهٔ پردازش	گام‌به‌گام	همهٔ عنصرها هم‌زمان
منشأ اطلاعات ترتیب	خودِ بازگشت (حالت پنهان)	باید صریحاً افزوده شود
نیاز به کدگذاری موقعیت	خیر (در بحث کلاس)	بله
محدودیت اصلی	فراموشی در دنباله‌های بلند، پردازش غیرموازی	نیاز به تعریف موقعیت

[محتوای افزوده] ظرایف این پرسش

- اطلاعات ترتیب در RNN «ضمنی» است: حالت پنهان نشان نمی‌دهد «الان در موقعیت ۱۷ هستیم»، بلکه تاریخچه‌ای فشرده از آنچه دیده شده است. برای بسیاری از کارها همین کافی است. محدودیت دیگری هم وجود دارد (فراموشی اطلاعات قدیمی در دنباله‌های بلند) که جدا بررسی می‌شود.
- اگر روی خروجی‌های RNN یک لایهٔ Attention بگذاریم (مانند معماری‌های رمزگذار-رمزگشا با Attention پیش از Transformer)، حالت‌های رمزگذار پیشاپیش اطلاعات ترتیب را حمل می‌کنند و باز هم کدگذاری موقعیت صریح لازم نیست.
- در تصویر تخته برای مثال عددی (بخش ۱۱.۱۰) در معماری رمزگذار-رمزگشا، هم‌زمان با Embedding نویسه‌ها (CE) یک PE نوشته شده است؛ یعنی در معماری Attentionمحور، کدگذاری موقعیت باید حضور داشته باشد.

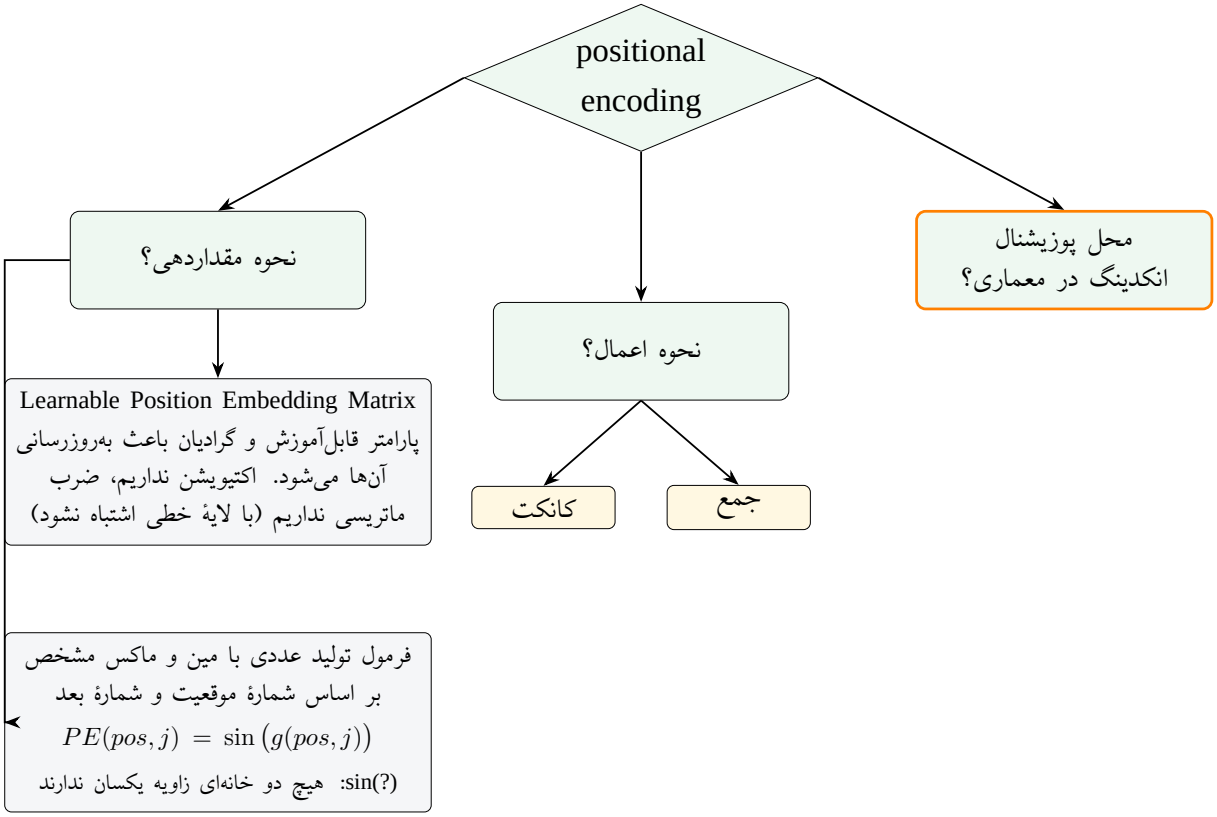
۴.۱۰ سه پرسش طراحی

در کلاس مسئله به سه پرسش شکسته شد که روی تخته به‌صورت یک نمودار دیده می‌شود:

۱. **محل**: کدگذاری موقعیت را در کدام بخش معماری قرار دهیم؟

۲. **نحوه‌اعمال**: اطلاعات موقعیت را چگونه به Embedding متصل کنیم؟ (جمع یا کانکت)

۳. **نحوه‌مقداردهی**: مقدارهای کدگذاری موقعیت را چگونه تعیین کنیم؟ (یادگیری یا فرمول)



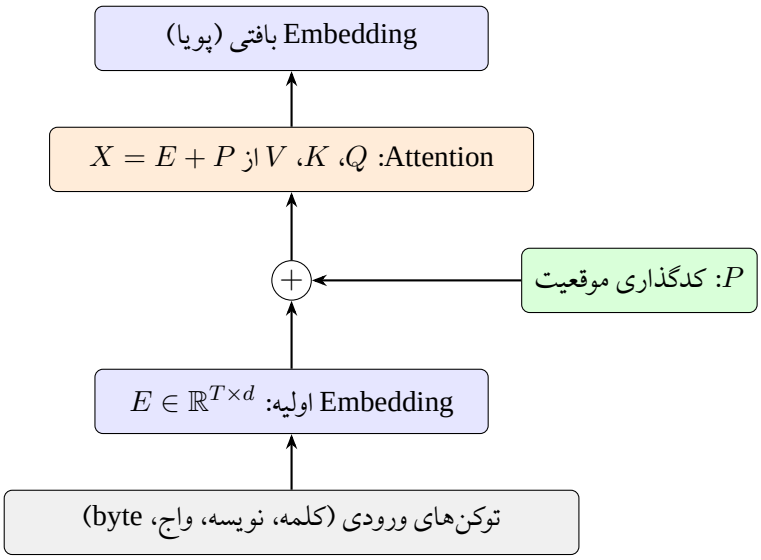
شکل ۲.۱۰: نمودار تخته: سه پرسش طراحی کدگذاری موقعیت (در این بازسازی به ترتیب خواندن فارسی از راست به چپ چیده شده‌اند). پرسش محل در معماری روی تخته دایره شده بود؛ برای مقداردهی دو راه (ماتریس یادگرفتنی و فرمول) یادداشت شده بود. (بازسازی‌شده از تختهٔ کلاس)

۱.۴.۱۰ محل قرارگیری در معماری

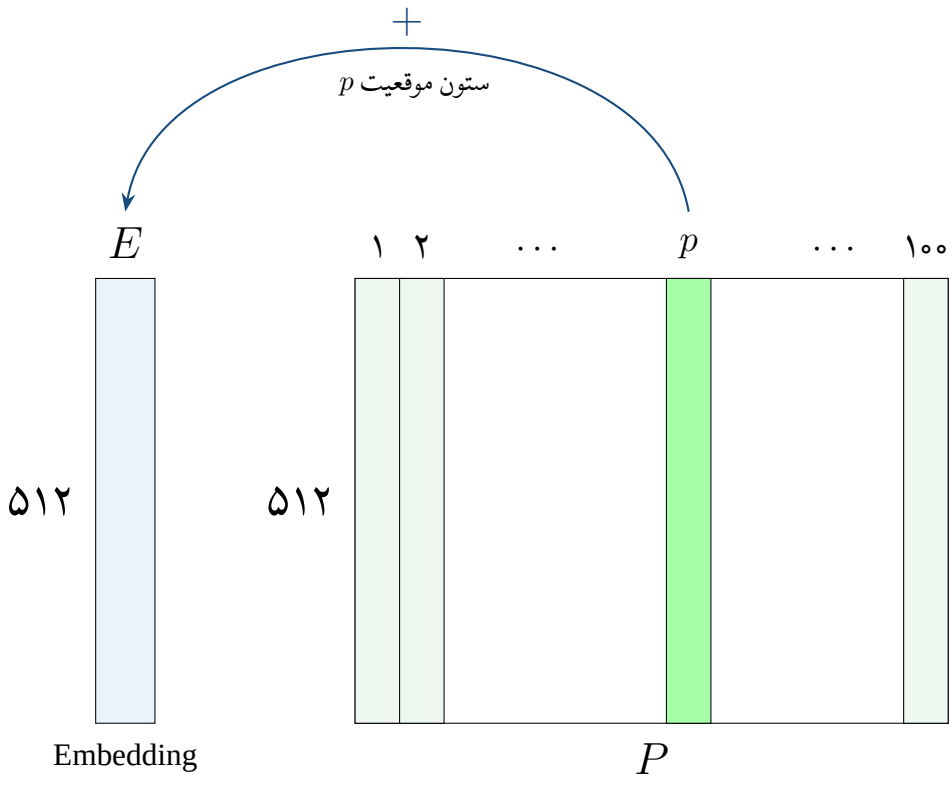
فرض کنید ابتدا یک لایهٔ Embedding داریم که برای هر توکن یک بردار اولیه می‌سازد و سپس می‌خواهیم با Attention این بردار را با توجه به بقیهٔ عنصرها بهبود دهیم. اطلاعات موقعیت باید بعد از *Embedding* اولیه و پیش از ورود به محاسبات *Attention* اضافه شود، چون هنگام مقایسهٔ Query و Key مدل باید بتواند تفاوت جایگاه عنصرها را هم ببیند.

انعطاف معماری

کدگذاری موقعیت یک ماژول است و محل و شیوهٔ استفاده از آن به معماری وابسته است. در طراحی شبکه باید بدانیم در کدام مرحله به اطلاعات موقعیت نیاز داریم، به‌ویژه اگر Attention بر اساس نمایش‌های ورودی محاسبه می‌شود. استاد اشاره کرد ممکن است در امتحان سؤال طراحی معماری مطرح شود، مثلاً اینکه چگونه اطلاعات موقعیت را در بخش مناسبی از یک شبکه وارد کنیم.



شکل ۳.۱۰: جای کدگذاری موقعیت در معماری: پس از Embedding اولیه و پیش از Attention. (شکل افزوده)



شکل ۴.۱۰: طرح تخته برای جمع $E + P$: بردار Embedding ۵۱۲ بعدی (ستون سمت چپ) با ستونِ موقعیت مورد نظر از ماتریس موقعیت (۵۱۲ سطر و ۱۰۰ ستون) جمع می‌شود. روی تخته ماتریس به‌صورت ترانهادهٔ $P \in \mathbb{R}^{۱۰۰ \times ۵۱۲}$ رسم شده بود. (بازسازی‌شده از تختهٔ کلاس)

۲.۴.۱۰ نحوهٔ اعمال: کانکت یا جمع

کانکت (Concatenation). بردار موقعیت جداگانه‌ای (مثلاً ۱۰ بعدی) می‌سازیم و به انتهای Embedding ۵۱۲ بعدی می‌چسبانیم: $۵۱۲ + ۱۰ = ۵۲۲$. مشکل: ابعاد نمایش بزرگ‌تر می‌شود، در حالی که انتخاب ابعاد Embedding خود یک تصمیم مهم طراحی است و نمی‌خواهیم با هر اطلاعات جدید ابعاد را افزایش دهیم.

جمع (Addition). بردار موقعیت را با Embedding جمع می‌کنیم؛ پس باید دقیقاً هم‌اندازهٔ آن باشد (برای Embedding ۵۱۲ بعدی، بردار موقعیت هم ۵۱۲ بعدی):

$$\boxed{X = E + P}$$

نمایش نهایی همچنان ۵۱۲ بعدی می‌ماند. این روشی است که در کلاس برای ادامهٔ بحث انتخاب شد.

جدول ۲.۱۰: مقایسهٔ کانکت و جمع برای ترکیب E (با $d = ۵۱۲$) و بردار موقعیت. (جدول افزوده)

ویژگی	کانکت	جمع
بُعد بردار موقعیت	d_p دلخواه (مثلاً ۱۰)	باید برابر d باشد (۵۱۲)
بُعد نمایش نهایی	$d + d_p = ۵۲۲$	$d = ۵۱۲$
تأثیر روی لایه‌های بعد	ابعاد ورودی بزرگ‌تر و پارامتر بیشتر	بدون تغییر
جداماندن محتوا و موقعیت	کاملاً در مختصات جدا	در یک فضای مشترک ترکیب می‌شوند

[محتوای افزوده] آیا جمع، اطلاعات را «خراب» نمی‌کند؟

در نگاه اول جمع شبیه آمیختن محتوا و موقعیت است. با این حال: (الف) در ابعاد زیاد، دو بردار تقریباً «در جهت‌های متفاوتی» قرار می‌گیرند و شبکه می‌تواند هر دو را از مجموع بازیابی کند؛ (ب) اگر W ماتریس نخستین تبدیل خطی بعدی باشد، $W(E+P) = WE + WP$ است، و این برابر با کانکت بردارها و ضرب در ماتریسی است که دو نیمهٔ آن W یکسان‌اند؛ یعنی جمع حالت خاصی از کانکت با وزن‌های مشترک است و پارامتر اضافی نمی‌خواهد. این استدلال شهودی است، نه برهانی که برای هر معماری درست باشد.

۳.۴.۱۰ ماتریس کدگذاری موقعیت

فرض کنید ابعاد Embedding برابر ۵۱۲ باشد و بخواهیم موقعیت‌ها را تا طول ۱۰۰ پوشش دهیم. ماتریس موقعیت چنین است:

$$\boxed{P \in \mathbb{R}^{۱۰۰ \times ۵۱۲}}$$

هر سطر مربوط به یک موقعیت و هر ستون مربوط به یک بعد از Embedding است. اگر کلمه‌ای در موقعیت دهم باشد، سطر دهم P را برمی‌داریم و با Embedding همان کلمه جمع می‌کنیم:

$$X_{pos} = E_{token} + P_{pos}.$$

(روی تخته ماتریس به‌صورت ۵۱۲ سطر و ۱۰۰ ستون، یعنی ترانهادهٔ این نمایش، کشیده شده بود: هر ستون یک موقعیت. این فقط قرارداد نمایش است.) تا اینجا فقط اندازهٔ ماتریس معلوم است؛ مقدارها را از کجا بیاوریم؟ دو راه مطرح شد: ماتریس را یاد بگیریم یا با یک فرمول ثابت بسازیم.

۵.۱۰ روش اول: کدگذاری موقعیت یادگرفتنی

۱.۵.۱۰ ایده

مقدارهای P را از پیش با فرمول تعیین نمی‌کنیم؛ ماتریس را مجموعه‌ای از پارامترهای قابل‌آموزش می‌گیریم (Learnable Position Embedding Matrix) و مدل مقدارهای آن را در آموزش یاد می‌گیرد. این همان ایدهٔ Embedding قابل‌آموزش است، در برابر One-Hot که با یک قاعدهٔ ثابت ساخته می‌شود. به‌جای اینکه خودمان بگوییم موقعیت اول چه اعدادی دارد، این را به مدل می‌سپاریم. در مثال کلاس، $۵۱۲ \times ۱۰۰ = ۵۱,۲۰۰$ پارامتر اضافه می‌شود.

۲.۵.۱۰ آیا لایهٔ خطی است؟ فعال‌ساز دارد؟

روی تخته نوشته شد: «اکتیویشن نداریم، ضرب ماتریسی نداریم (با لایه خطی اشتباه نشود)». این ماتریس مجموعه‌ای از پارامترهاست که مستقیماً به Embedding اولیه اضافه می‌شود: ضرب ماتریسی، Bias یا تابع فعال‌ساز روی آن اعمال نمی‌شود. فعال‌ساز برای ایجاد رفتار غیرخطی در لایه‌ها به کار می‌رود، ولی اینجا هدف ساخت یک نگاشت غیرخطی نیست؛ فقط می‌خواهیم برای هر موقعیت یک بردار داشته باشیم و مقدارهای آن در آموزش اصلاح شوند.

دقت: جدول جست‌وجو

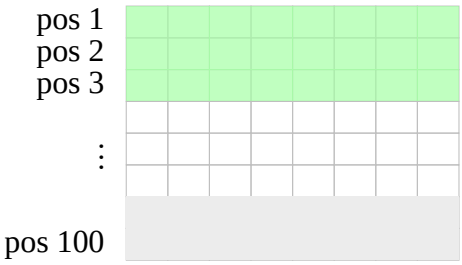
در پیاده‌سازی، این ماتریس همان یک **جدول جست‌وجو** (Lookup Table) است، دقیقاً مثل ماتریس Embedding کلمه‌ها: شمارهٔ موقعیت، سطر مربوط را بازمی‌گرداند. از نظر ریاضی معادل ضرب بردار One-Hot موقعیت در P است، اما نه ضرب واقعاً اجرا می‌شود و نه Bias یا فعال‌ساز وجود دارد. پس دو عبارت «لایهٔ خطی نیست» و «در حد یک ماتریس پارامتر است» هر دو درست‌اند.

۳.۵.۱۰ آموزش از راه پس‌انتشار

پرسش دانشجو: اگر فقط یک ماتریس پارامتر است و لایهٔ خطی هم نیست، چطور یاد گرفته می‌شود؟ پاسخ: مثل بقیهٔ پارامترهای شبکه، با Backpropagation. خروجی جمع $X = E + P$ وارد بقیهٔ شبکه می‌شود و در انتها به یک تابع خطا (Loss) می‌رسیم. این خطا نسبت به خروجی نهایی و هدف همان مسئله حساب می‌شود (رگرسیون با MSE، دسته‌بندی، یا حتی چند تابع هزینهٔ هم‌زمان)، نه نسبت به خود Embedding. گرادیان آن با قاعدهٔ زنجیره‌ای به عقب برمی‌گردد و چون P در محاسبهٔ خروجی نقش داشته، به P هم می‌رسد:

$$\text{Loss} \xrightarrow{\text{Backprop}} E,\ P.$$

چون $X_t = E_{token_t} + P_t$ یک جمع است، $\frac{\partial L}{\partial P_t} = \frac{\partial L}{\partial X_t}$.



شکل ۵.۱۰: اگر دادهٔ آموزشی فقط توالی‌هایی تا طول ۳ داشته باشد، فقط سه سطر نخست P گرادیان می‌گیرند. (شکل افزوده)

۴.۵.۱۰ آیا بردارهای موقعیت حتماً متمایزند؟

در حالت یادگرفتنی شرط صریحی برای متمایز بودن سطرهای P نمی‌گذاریم و به مدل نمی‌گوییم موقعیت اول و دوم حتماً فرق کنند. انتظار این است که با داده، تابع خطا و ابعاد زیاد، مدل نمایش مناسبی بیاموزد؛ استاد اشاره کرد درباره تضمین دقیق این موضوع می‌شود بیشتر بررسی کرد. (در عمل سطرها با مقدار اولیهٔ تصادفی شروع می‌شوند و بنابراین از ابتدا هم متفاوت‌اند؛ مسئله این است که سطرِ آموزش‌ندیده معنای مفیدی ندارد، نه اینکه لزوماً با سطر دیگر برابر باشد.)

۶.۱۰ روش دوم: کدگذاری موقعیت ثابت (فرمولی)

۱.۶.۱۰ ورودی‌های فرمول

اگر نخواهیم P را یاد بگیریم، باید قاعده‌ای برای تولید آن بنویسیم. چون هدف این است که مدل بتواند موقعیت‌های مختلف را از هم تشخیص دهد (مثلاً دو جملهٔ «شکارچی پلنگ را زد» و «پلنگ شکارچی را زد»)، نمایش موقعیت‌های مختلف باید قابل‌تمایز باشد؛ اگر موقعیت اول و دوم نمایش یکسانی بگیرند، مشکل پابرجا می‌ماند. هر خانهٔ ماتریس به دو چیز وابسته است: شمارهٔ موقعیت (pos) و شمارهٔ بعد (j):

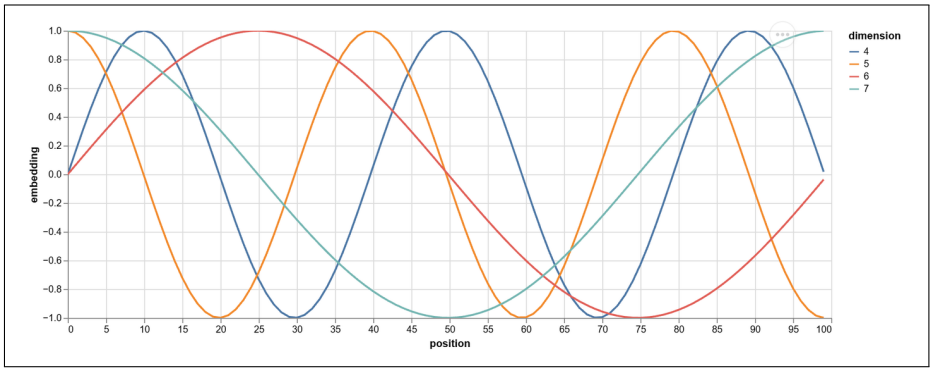
$$P(pos, j) = f(pos, j).$$

۲.۶.۱۰ فرمول سینوسی

روی تخته نوشته شد: «فرمول تولید عددی با مین و مکس مشخص بر اساس شمارهٔ موقعیت و شمارهٔ بعد»:

$$PE(pos, j) = \sin\big(g(pos, j)\big),$$

که در آن $g(pos, j)$ یک زاویه است که از موقعیت و بعد ساخته می‌شود. چون $-۱ \leq \sin(x) \leq ۱$ (و همین بازه برای کسینوس)، مقدارها کراندار و عددی‌اند. استاد وارد جزئیات فرمول نشد و تأکید را روی منطق گذاشت، نه حفظ فرمول؛ فقط اشاره کرد در فرمول متداول از سینوس و کسینوس با الگوهای متفاوت برای اندیس‌های زوج و فرد استفاده می‌شود.



شکل ۱۰.۶: نمودار تخته: مقدار PE برحسب موقعیت (۰ تا ۱۰۰) برای چهار بعد ۴ تا ۷. هر بعد یک موج با فرکانس ویژهٔ خود است. فرمول $PE(pos, j) = \sin(g(pos, j))$ و یادداشت «هیچ دو خانه‌ای زاویه یکسان ندارند» در تخته بود. (برگرفته از تختهٔ کلاس)

فرمول استاندارد (Vaswani et al., 2017)

برای $i = ۰, ۱, \ldots, d/۲ - ۱$:

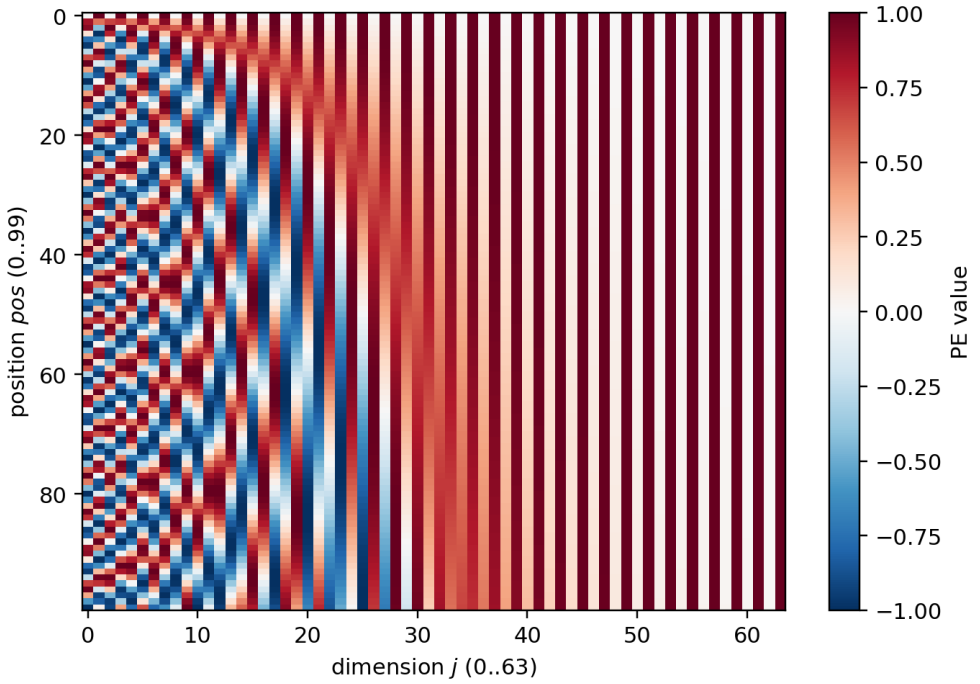
$$PE(pos,\ ۲i) = \sin\left(\frac{pos}{۱۰۰۰۰^{۲i/d}}\right), \qquad PE(pos,\ ۲i+۱) = \cos\left(\frac{pos}{۱۰۰۰۰^{۲i/d}}\right).$$

یعنی بعدها دوبه‌دو (سینوس، کسینوس) با یک فرکانس $\omega_i = ۱۰۰۰۰^{-۲i/d}$ هستند و با بزرگ‌شدن i فرکانس کم می‌شود: بعدهای کم‌شماره موج‌های سریع (برای تمایز موقعیت‌های نزدیک) و بعدهای پرشماره موج‌های بسیار کند (برای تمایز موقعیت‌های دور) می‌سازند.

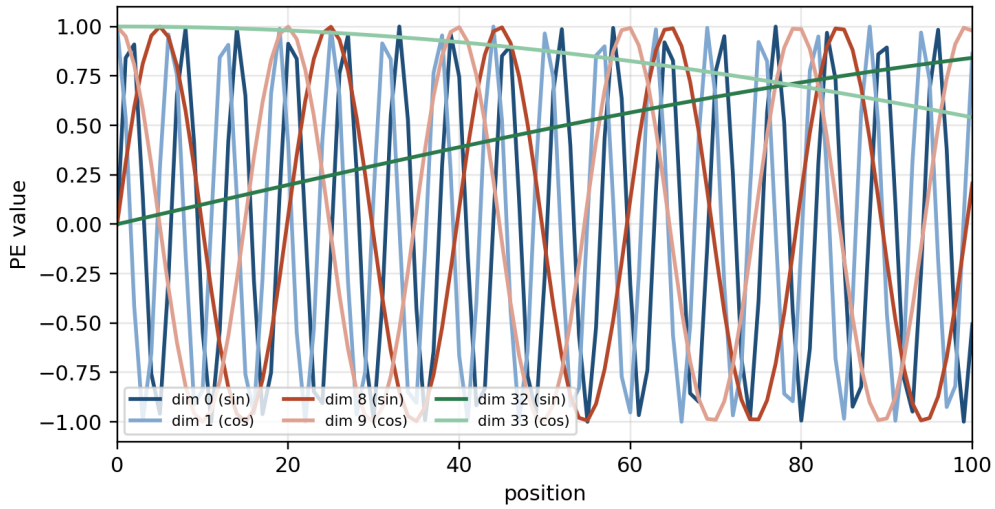
فرمول کلاس نسخهٔ ساده‌شده‌فرمول استاندارد است

فرمول $PE(pos, j) = \sin(g(pos, j))$ نسخهٔ ساده‌شدهٔ فرمول استاندارد است: در نسخهٔ کامل بعدهای فرد کسینوس می‌گیرند و $g(pos, j) = pos/۱۰۰۰۰^{۲\lfloor j/۲ \rfloor/d}$. همچنین نمودار تخته برای چهار بعد (۴ تا ۷) دوره‌های حدود ۴۰ و ۱۰۰ را نشان می‌دهد که تصویری آموزشی است؛ در فرمول استاندارد با $d = ۵۱۲$ بعدهای ۴ و ۵ دورهٔ حدود $۲\pi/\omega_۲ \approx ۶,۷$ دارند. کیفیت مشترک هر دو تصویر (جفت‌شدن سینوس و کسینوس و کم‌شدن فرکانس با بعد) درست است. نمودار افزوده‌شدهٔ زیر نمایش واقعی فرمول استاندارد است.

دربارهٔ یادداشت «هیچ دو خانه‌ای زاویه یکسان ندارند»: برای هر بعد ثابت، دو موقعیت مختلف زاویهٔ متفاوت دارند (چون $\omega_i > ۰$). اما به‌طور کلی نمی‌توان گفت هیچ دو خانهٔ ماتریس زاویهٔ برابر ندارند؛ مثلاً با $d = ۵۱۲$ داریم $\omega_{i+۶۴} = \omega_i/۱۰$ و بنابراین زاویهٔ $(pos = ۱۰, i + ۶۴)$ برابر زاویهٔ $(pos = ۱, i)$ است. آنچه مهم است این است که بردار کامل هر موقعیت (ترکیب همهٔ بعدها) برای موقعیت‌های مختلف متفاوت است؛ این به‌ویژه به‌خاطر جفت (سینوس، کسینوس) با فرکانس‌های متنوع برقرار است.



شکل ۷.۱۰: ماتریس PE سینوسی استاندارد با $d = ۶۴$ و ۱۰۰ موقعیت (محور افقی: بعد، محور عمودی: موقعیت). بعدهای کم‌شماره (چپ) سریع نوسان می‌کنند و بعدهای پرشماره الگوی کندتر دارند. (شکل افزوده)



شکل ۸.۱۰: مقدار PE برحسب موقعیت برای چند بعد از ماتریس $d = ۶۴$: فرکانس‌های بالا (ابعاد ۰ و ۱)، متوسط (۸ و ۹) و پایین (۳۲ و ۳۳). هر جفت (سینوس، کسینوس) یک فرکانس دارد. (شکل افزوده)

[محتوای افزوده] مثال عددی: $d = ۴$ و موقعیت‌های ۰، ۱، ۲

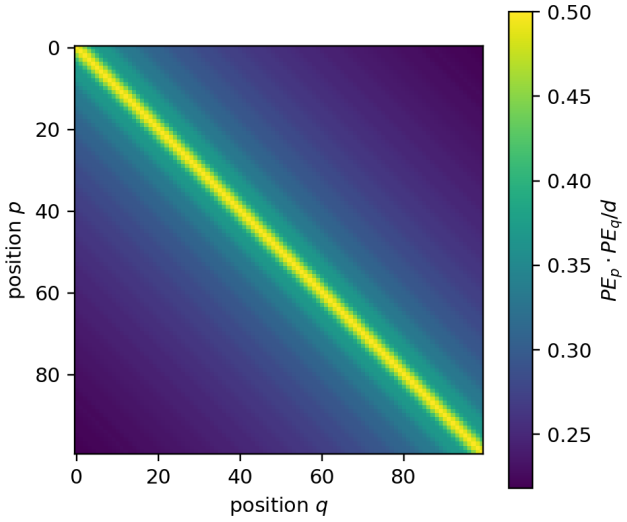
برای $d = ۴$ دو فرکانس داریم: $i = ۰$ با $\omega_۰ = ۱$ و $i = ۱$ با $\omega_۱ = ۱۰۰۰۰^{-۲/۴} = ۰٫۰۱$. ردیف هر موقعیت $(\sin(pos\,\omega_۰), \cos(pos\,\omega_۰), \sin(pos\,\omega_۱), \cos(pos\,\omega_۱))$ است:

pos	بعد ۰	بعد ۱	بعد ۲	بعد ۳
۰	۰٫۰۰۰۰	۱٫۰۰۰۰	۰٫۰۰۰۰	۱٫۰۰۰۰
۱	۰٫۸۴۱۵	۰٫۵۴۰۳	۰٫۰۱۰۰	۰٫۹۹۹۹
۲	۰٫۹۰۹۳	−۰٫۴۱۶۱	۰٫۰۲۰۰	۰٫۹۹۹۸

مثلاً $\sin(۱) \approx ۰٫۸۴۱۵$ و $\cos(۲) \approx -۰٫۴۱۶۱$. همهٔ مقدارها در $[-۱, ۱]$ و سه ردیف متفاوت‌اند. اگر این ردیف‌ها با Embedding ۴ بعدی هر توکن جمع شوند، همان $X = E + P$ به دست می‌آید.

[محتوای افزوده] ویژگی‌های دیگر فرمول سینوسی

- **قابل محاسبه برای هر موقعیت:** بردار موقعیت ۵۰ بدون مشاهدهٔ آن در دادهٔ آموزشی از فرمول به دست می‌آید.
- **بدون پارامتر آموزشی:** ماتریس با فرمول ساخته می‌شود و گرادیان نمی‌گیرد.
- **ساختار نسبی:** چون $\sin(a+b)$ و $\cos(a+b)$ با فرمول جمع زاویه‌ها نوشته می‌شوند، $PE(pos+k)$ برای هر k ثابت یک تبدیل خطی ثابت (دوران در هر جفت بعد) از $PE(pos)$ است. در نتیجه ضرب داخلی دو بردار موقعیت فقط به فاصلهٔ آن‌ها بستگی دارد: $\frac{۱}{d} PE(p) \cdot PE(q) = \frac{۱}{d} \sum_i \cos(\omega_i (p-q))$.



شکل ۹.۱۰: شباهت $\frac{۱}{d} PE(p) \cdot PE(q)$ بین هر دو موقعیت ($d = ۵۱۲$): روی قطر برابر ۱ و با دورشدن از قطر کاهش می‌یابد. مقدار فقط تابع $|p - q|$ است. (شکل افزوده)

۷.۱۰ مقایسهٔ دو روش

جدول ۳.۱۰: مقایسهٔ کدگذاری موقعیت یادگرفتنی و ثابت (برگرفته از جدول جلسه، با کمی توضیح افزوده).

ویژگی	یادگرفتنی (Learned)	ثابت (Fixed)
تعیین مقدارها	از طریق آموزش	با فرمول مشخص
پارامتر قابل‌آموزش	دارد (۵۱۲ × ۱۰۰ در مثال)	ندارد
وابستگی به دادهٔ آموزشی	زیاد	کم
موقعیت‌های دیده‌نشده در آموزش	ممکن است خوب یاد گرفته نشده باشند	با فرمول قابل محاسبه‌اند
چالش اصلی	پوشش مناسب موقعیت‌ها در دادهٔ آموزشی	انتخاب قاعدهٔ مناسب برای نمایش موقعیت‌ها
انعطاف	زیاد؛ مدل شکل را خودش می‌یابد	محدود به شکل فرمول

۸.۱۰ سؤال مفهومی مهم استاد: دادهٔ آموزشی کوتاه

دو مدل داریم: در مدل اول موقعیت با فرمول محاسبه می‌شود و در مدل دوم موقعیت در طول آموزش یاد گرفته می‌شود. اگر دادهٔ آموزشی عمدتاً جملهٔ کوتاه باشد، برای موقعیت‌های بلندتر کدام انتخاب بهتر است؟

دو مدل دارم

- مدل اول: موقعیت با فرمول محاسبه می‌شود.
- مدل دوم: موقعیت در طول آموزش یاد گرفته می‌شود.

اگر داده‌های آموزشی عمدتاً جمله‌های کوتاه باشند، کدام بهتر است؟

مدل دوم ممکن است موقعیت‌های پرتکرار را خوب یاد بگیرد، ولی برای موقعیت‌های بسیار دورتر بردار آموزش‌دیده‌ای نداشته باشد. بنابراین، قابل‌آموزش بودن انعطاف بیشتری می‌دهد، اما می‌تواند تعمیم به موقعیت‌های ندیده را دشوار کند.

شکل ۱۰.۱۰: سؤال (کادر زرد) و پاسخ نوشته‌شده روی تختهٔ کلاس. (بازسازی‌شده از تختهٔ کلاس)

پاسخ کلاس. مدل با کدگذاری ثابت انتخاب مناسب‌تری است. دلیل: فرض کنید برای مدل یادگرفتنی ماتریسی با ۱۰۰ سطر داریم ($P \in \mathbb{R}^{۱۰۰\times ۵۱۲}$) ولی دادهٔ آموزشی فقط توالی‌هایی با حداکثر طول ۳ دارد. در آموزش فقط سطرهای ۱

تا ۳ استفاده می‌شوند و گرادیان فقط به همین سطرها می‌رسد؛ بردارهای موقعیت ۵۰ یا ۸۰ آموزش مؤثری نمی‌بینند. در آزمون، با یک توالی به طول ۵۰ مدل باید از نمایش‌هایی استفاده کند که هرگز یاد نگرفته است و عملکرد افت می‌کند. در روش ثابت، بردار موقعیت ۵۰ با فرمول محاسبه می‌شود و لازم نیست آن موقعیت در دادهٔ آموزشی دیده شده باشد.

نکات روش‌شناختی این سؤال

- موضوع فقط تعداد نمونه‌ها نیست، بلکه پوشش موقعیت‌ها در دادهٔ آموزشی است: ممکن است دادهٔ بسیار بزرگ ولی همگی کوتاه باشد، که باز هم تجربهٔ کافی دربارهٔ موقعیت‌های بالاتر نمی‌دهد. اگر دادهٔ آموزشی همهٔ موقعیت‌ها را خوب پوشش دهد، روش یادگرفتنی هم نمایش مناسبی یاد می‌گیرد.
- پاسخ دانشجو «اندازهٔ ماتریس را کوچک بگیریم» فرض مسئله را عوض می‌کند. صورت دقیق سؤال این است: ظرفیت ماتریس ۱۰۰ موقعیت است ولی دادهٔ آموزشی تا طول ۳؛ اندازه را تغییر نمی‌دهیم و در همین شرایط دو روش را مقایسه می‌کنیم.
- استاد گفت در امتحان فرض‌های سؤال را دقیق‌تر بیان خواهد کرد تا چنین ابهامی پیش نیاید.

صورت پیشنهادی امتحان: «دو مدل داریم که هر دو برای توالی‌هایی با حداکثر طول ۱۰۰ طراحی شده‌اند. مدل اول از کدگذاری موقعیت ثابت و مدل دوم از کدگذاری یادگرفتنی استفاده می‌کند. اگر تمام دادهٔ آموزشی فقط شامل توالی‌هایی با طول حداکثر ۳ باشد، کدام روش برای مواجهه با موقعیت‌های بلندتر مناسب‌تر است و چرا؟»

دقت: «ثابت بهتر است» تضمین کامل نیست

مزیت روش ثابت این است که خودِ نمایش موقعیت به آموزش هر سطر وابسته نیست. این به‌تنهایی تضمین نمی‌کند که کل مدل روی توالی‌های بلندتر از آنچه دیده خوب کار کند؛ وزن‌های Attention هم فقط روی موقعیت‌های کوتاه آموزش دیده‌اند و در عمل Transformerهای سینوسی هم در بلندتر از طول آموزش اغلب افت می‌کنند (به همین دلیل روش‌های موقعیت نسبی مطرح شدند). پس پاسخ درست برای امتحان این است که روش ثابت مناسب‌تر است، نه اینکه مشکل را کاملاً حل کند. استاد هم همین‌گونه نتیجه گرفت.

۹.۱۰ کدگذاری موقعیت به توالی وابسته است، نه به «جمله»

دانشجو پرسید مدل‌هایی مانند Transformer در سطح توکن کار می‌کنند و لزوماً جمله را واحد اصلی نمی‌گیرند. پاسخ استاد: کدگذاری موقعیت ذاتاً به مفهوم «جمله» وابسته نیست. عنصرهای توالی می‌توانند کلمه، نویسه، واج یا حتی بایت باشند و کدگذاری موقعیت فقط مشخص می‌کند هر عنصر چندمین عنصر توالی ورودی است:

- ورودی نویسه‌ای: موقعیت پنجم یعنی نویسهٔ پنجم؛
- ورودی کلمه‌ای: موقعیت پنجم یعنی کلمهٔ پنجم؛
- ورودی واجی: موقعیت پنجم یعنی واج پنجم.

اگر ورودی شبکه ۱۰۰ نویسه باشد، ۱۰۰ موقعیت به ۱۰۰ نویسه برمی‌گردد؛ اگر ۱۰۰ کلمه باشد، همان تعداد موقعیت برای کلمه‌ها به کار می‌رود. این کاملاً به طراحی معماری و Tokenization بستگی دارد.

۱۰.۱۰ طول زمینه (Context Length)

پرسش دانشجو: اگر توالی ۱۱۰ عنصر باشد ولی ماتریس موقعیت فقط برای ۱۰۰ موقعیت تعریف شده باشد چه می‌شود؟

- حداکثر طول ورودی یک تصمیم طراحی است. برای توالی‌های بلندتر باید تصمیم بگیریم چه کنیم؛ یک راه شکستن ورودی به بخش‌های کوچک‌تر و استفاده از پنجره (Window یا Context Window) است، یعنی مدل در هر گام بخش مشخصی از توالی را پردازش می‌کند.
- اندازهٔ پوشش موقعیت به طراحی مدل و Task بستگی دارد و یک عدد ثابت برای همهٔ مدل‌ها و مسئله‌ها وجود ندارد. مثلاً مدل نویسه‌ای معمولاً به موقعیت‌های بیشتری نیاز دارد تا مدل کلمه‌ای، چون توالی نویسه‌ها بلندتر است.
- برای ورودی‌های چند هزار یا چند ده هزار عنصری، علاوه بر پنجره‌بندی، معماری‌های مختلف ماژول‌ها و شیوه‌های متفاوتی برای مدیریت اطلاعات موقعیت دارند؛ محل و تعداد این ماژول‌ها بخشی از طراحی معماری است.

[محتوای افزوده] دو رفتار متفاوت برای عنصر ۱۰۱ام

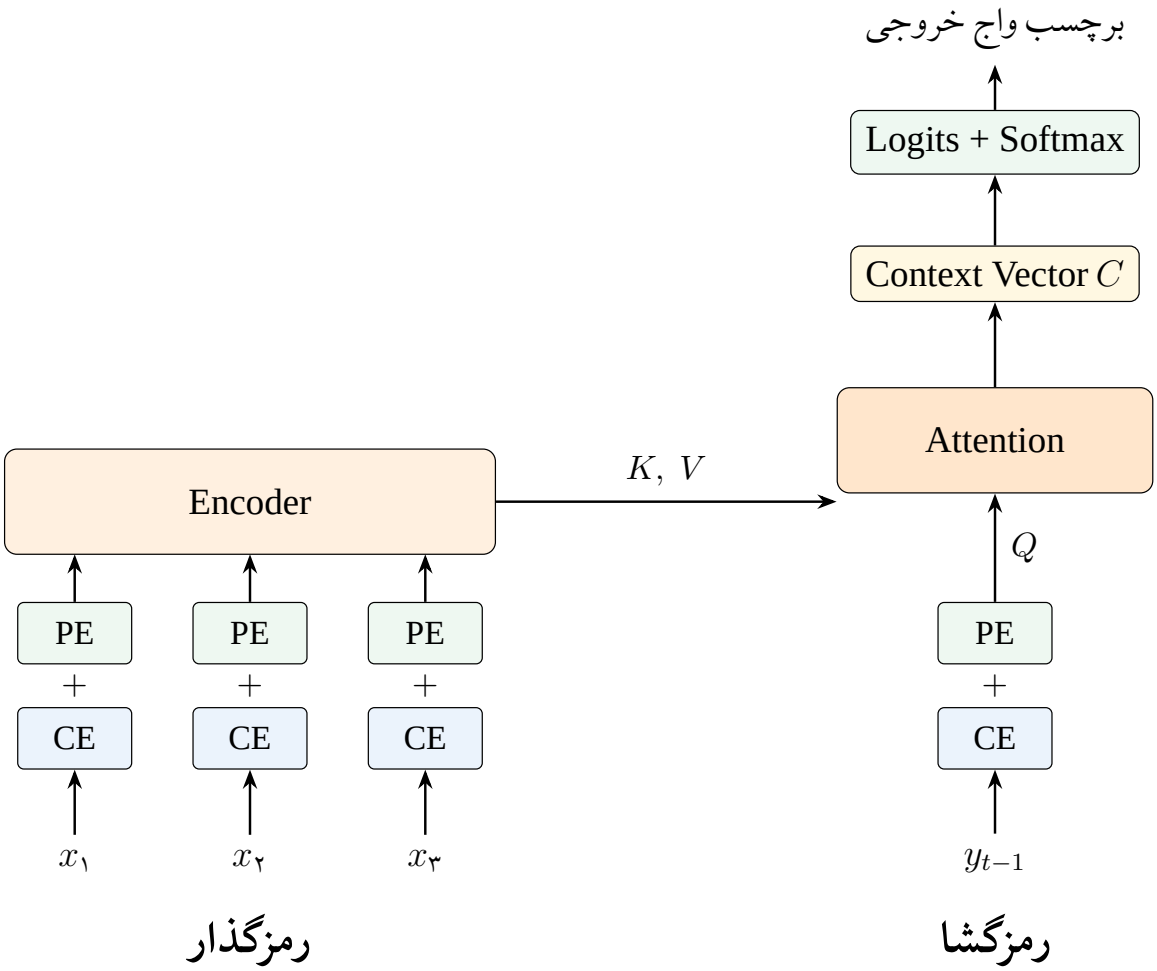
در روش یادگرفتنی با جدول ۱۰۰ سطری، موقعیت ۱۰۱ سطری ندارد و عملاً خطای اندیس رخ می‌دهد؛ ورودی باید بریده یا تقسیم شود. در روش فرمولی می‌توان $PE(۱۰۱)$ را حساب کرد، ولی مدل با چنین موقعیتی هرگز آموزش ندیده و کیفیت تضمین‌شده نیست. این مثال دوباره نشان می‌دهد چرا طول حداکثر یک فراپارامتر معماری است. روش‌های جدیدتر (کدگذاری موقعیت نسبی، RoPE، ALiBi) برای کاهش این محدودیت پیشنهاد شده‌اند؛ خارج از محتوای کلاس.

۱۱.۱۰ مثال عددی کامل: Attention در رمزگشا

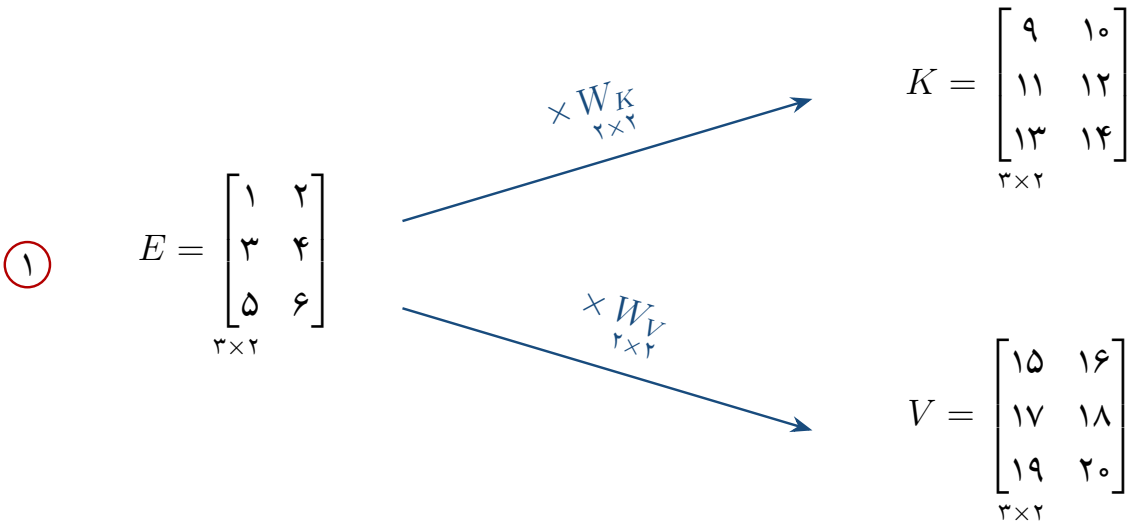
در ادامهٔ جلسه، استاد روی تخته یک مثال عددی دست‌نویس از محاسبات Attention در حالت رمزگذار-رمزگشا (همان معماری G2P) حل کرد. تصویر بالای تخته دو پشته را نشان می‌دهد: رمزگذار (ورودی نویسه‌ها با Embedding نویسه، CE، و کدگذاری موقعیت PE) و رمزگشا (توکن فعلی با CE و PE) که Query آن بردار بافت C را می‌سازد؛ بالای تخته برچسب چند واج نوشته شده است.

۱.۱۱.۱۰ گام ۱: Key و Value از خروجی رمزگذار

سه توکن ورودی داریم و ماتریس Embedding آن‌ها $E \in \mathbb{R}^{۳\times ۲}$ است. با ضرب در W_K و W_V (هر دو ۲×۲) ماتریس‌های K و V هر دو ۲×۳ به دست می‌آیند. مقدارهای نوشته‌شده روی تخته در شکل زیر آمده است:



شکل ۱۱.۱۰: نمای کلی مثال تخته: ورودی رمزگذار (CE به‌علاوهٔ PE) و ورودی رمزگشا (CE به‌علاوهٔ PE) که Query آن با Value/Key رمزگذار ترکیب می‌شود و بردار بافتی C را می‌سازد. برچسب‌های واجِ بالای تخته دست‌خط ناخوانا بود و اینجا فقط به‌صورت کلی نشان داده شده‌اند. (بازسازی‌شده از تختهٔ کلاس)



شکل ۱۲.۱۰: گام ۱: E (۲ × ۳) در W_K و W_V (۲ × ۲) ضرب می‌شود و K و V (۲ × ۳) به دست می‌آیند. روی تخته W_K و W_V فقط به‌صورت قاب‌های خالی کشیده شده بودند و مقدارشان نوشته نشده بود. (بازسازی‌شده از تختهٔ کلاس)

[محتوای افزوده] ماتریس‌های وزنی سازگار با K و V

چون سطرهای E تصاعد حسابی‌اند، ماتریس‌های ۲ × ۲ یکتا و سازگاری وجود دارند: حل دستگاه $EW_K = K$ از دو سطر اول و بررسی سطر سوم ($۵\cdot(-۷)+۶\cdot۸=۱۳$ و $۵\cdot(-۸)+۶\cdot۹=۱۴$) می‌دهد

$$W_K = \begin{bmatrix} -۷ & -۸ \\ ۸ & ۹ \end{bmatrix}, \qquad W_V = \begin{bmatrix} -۱۳ & -۱۴ \\ ۱۴ & ۱۵ \end{bmatrix}.$$

یعنی $K = EW_K$ و $V = EW_V$ دقیقاً برقرارند.

۲.۱۱.۱۰ گام ۲: Query از توکن رمزگشا

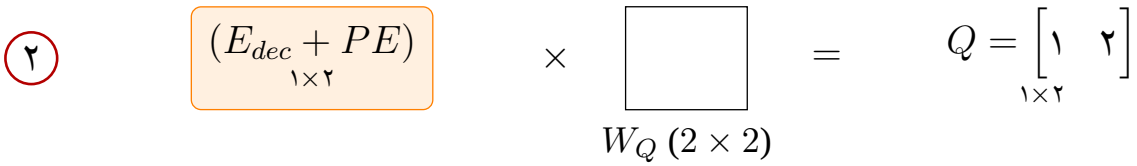
توکن فعلی رمزگشا بعد از Embedding با کدگذاری موقعیتش جمع می‌شود: $x = E_{dec} + P_{pos}$ (برداری ۲ × ۱). سپس با W_Q (۲ × ۲) به Query (۲ × ۱) تبدیل می‌شود:

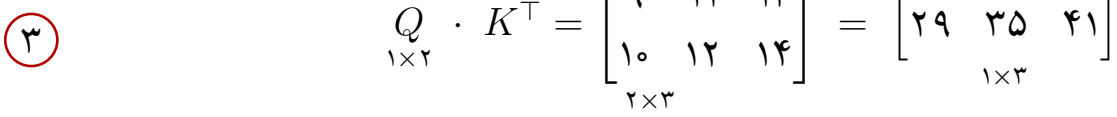
$$Q = (E_{dec} + P_{pos})\, W_Q \in \mathbb{R}^{۱\times۲}.$$

یادداشت زردرنگ روی تخته در همین جا «$+PE$» را نشان می‌دهد؛ یعنی موقعیت قبل از ساخت Q در نمایش وارد می‌شود.

۳.۱۱.۱۰ گام ۳: امتیازها $QK^\top$

$$\text{scores} = QK^\top \in \mathbb{R}^{۱\times۳} \quad (۱\times۲)\cdot(۲\times۳).$$





شکل ۱۰.۱۳: گام‌های ۲ و ۳: Embedding توکن رمزگشا با PE جمع و در W_Q ضرب می‌شود تا Q ساخته شود (بالا)؛ سپس $QK^\top$ امتیازها را می‌دهد (پایین). مقدارهای Q و امتیازها دست‌خط به‌سختی خوانایی بودند و در اینجا بر پایهٔ خوانش توضیح‌داده‌شده در متن آمده‌اند. (بازسازی‌شده از تختهٔ کلاس)

نکتهٔ خوانایی: مقدارهای Q و امتیازها

اعداد دست‌نویس Q و امتیازها در تخته به‌سختی خوانا هستند. با توجه به ساختار $K^\top = \begin{bmatrix}۹ & ۱۱ & ۱۳\\ ۱۰ & ۱۲ & ۱۴\end{bmatrix}$، خوانش‌ای که با اعداد تخته بیشترین سازگاری را دارد $Q=(۱,۲)$ و امتیازها $(۲۹,۳۵,۴۱)$ است:

$$QK^\top = (۱\cdot۹+۲\cdot۱۰,\ ۱\cdot۱۱+۲\cdot۱۲,\ ۱\cdot۱۳+۲\cdot۱۴) = (۲۹,\ ۳۵,\ ۴۱).$$

این خوانش قطعی نیست؛ ولی ماتریس‌های E، K و V و ابعاد همهٔ گام‌ها روی تخته کاملاً خوانا بودند و منطق محاسبه از مقدار دقیق Q مستقل است. در ادامه برای تکمیل محاسبه از همین $Q=(۱,۲)$ استفاده می‌شود.

۴.۱۱.۱۰ گام ۴: بردار بافت (جمع وزن‌دار Valueها)

$$C = \sum_{i=۱}^{۳} \alpha_i V_i = \alpha_۱(۱۵,۱۶) + \alpha_۲(۱۷,۱۸) + \alpha_۳(۱۹,۲۰) \in \mathbb{R}^{۱\times۲}.$$

روی تخته سه ضریب کنار سه سطر V نوشته شد و بردار حاصل با برچسب Context Vector دایره شد. ضریب‌های نوشته‌شده روی تخته با خوانش بالا به امتیازها شبیه‌اند و زیر آن‌ها یک یادداشت آبی به‌صورت جمع سه عدد دیده می‌شود؛ ولی خوانش دقیق این اعداد ممکن نیست، پس در ادامه صرفاً روش درست محاسبه توضیح داده می‌شود.

امتیاز خام ضریب توجه نیست

در Attention واقعی، امتیازهای $QK^\top$ پیش از ضرب در V باید به وزن‌هایی با مجموع ۱ تبدیل شوند (Softmax، معمولاً پس از تقسیم بر $\sqrt{d_k}$). اگر امتیازهای خام ضریب شوند، حاصل

$$C = ۲۹(۱۵, ۱۶) + ۳۵(۱۷, ۱۸) + ۴۱(۱۹, ۲۰) = (۱۸۰۹, \ ۱۹۱۴)$$

می‌شود که از دامنهٔ مقدارهای V (۱۵ تا ۲۰) بسیار بزرگ‌تر است. حتی تقسیم بر مجموع ($۱۰۵ = ۴۱ + ۳۵ + ۲۹$) نتیجهٔ $C \approx (۱۷٫۲۳;\ ۱۸٫۲۳)$ را می‌دهد که قابل قبول‌تر است ولی هنوز Softmax نیست.

[محتوای افزوده] محاسبهٔ درست با Softmax

با امتیازهای $(۲۹, ۳۵, ۴۱)$:

$$\alpha = \mathrm{softmax}(۲۹, ۳۵, ۴۱) \approx (۰٫۰۰۰۰۰۶;\ ۰٫۰۰۲۵;\ ۰٫۹۹۷۵),$$
$$C = \alpha V \approx (۱۸٫۹۹۵;\ ۱۹٫۹۹۵).$$

چون اختلاف امتیازها بزرگ است، Softmax تقریباً همهٔ وزن را به یک عنصر می‌دهد (توجه «تیز»). برای همین امتیازها را بر $\sqrt{d_k} = \sqrt{۲}$ تقسیم می‌کنند: $\mathrm{softmax}(۲۰٫۵۱;\ ۲۴٫۷۵;\ ۲۸٫۹۹) \approx (۰٫۰۰۰۲;\ ۰٫۰۱۴۲;\ ۰٫۹۸۵۶)$ و $C \approx (۱۸٫۹۷;\ ۱۹٫۹۷)$. در یک مدل واقعی با d_k بزرگ‌تر این مقیاس‌دهی مهم‌تر است.

۵.۱۱.۱۰ گام ۵: لجیت و Softmax روی واژگان

بردار بافت C (۲×۱) از یک لایهٔ خروجی می‌گذرد:

$$\text{logits} = C\,W + b, \qquad W \in \mathbb{R}^{۲\times ۵},\ b \in \mathbb{R}^{۱\times ۵},$$

که لجیت ۵×۱ می‌دهد (روی تخته اندازه‌ها ۵×۲، ۵×۱ و ۵×۱ نوشته شدند؛ یعنی اندازهٔ واژگانِ مثال ۵ است). در پایان Softmax روی واژگان احتمال هر توکن بعدی را می‌دهد.

[محتوای افزوده] نمونهٔ عددی گام ۵

فرض کنید $C \approx (۱۹, ۲۰)$ و $W = \begin{bmatrix} ۰٫۱ & -۰٫۰۵ & ۰٫۰۲ & ۰٫۰۴ & -۰٫۱ \\ ۰ & ۰٫۰۵ & -۰٫۰۳ & ۰٫۰۶ & ۰٫۱ \end{bmatrix}$ و $b = ۰$. آنگاه $\text{logits} = (۱٫۹۰;\ ۰٫۰۵;\ -۰٫۲۲;\ ۱٫۹۶;\ ۰٫۱۰)$ و $\text{softmax} \approx (۰٫۳۹۹;\ ۰٫۰۶۳;\ ۰٫۰۴۸;\ ۰٫۴۲۴;\ ۰٫۰۶۶)$ که مجموعش ۱ است و توکن چهارم محتمل‌ترین است. (مقدارهای W فرضی‌اند.)

④
$$C = \alpha_1 \begin{bmatrix} 15 & 16 \end{bmatrix} + \alpha_2 \begin{bmatrix} 17 & 18 \end{bmatrix} + \alpha_3 \begin{bmatrix} 19 & 20 \end{bmatrix} = \underset{1\times 2}{\boxed{C}}$$

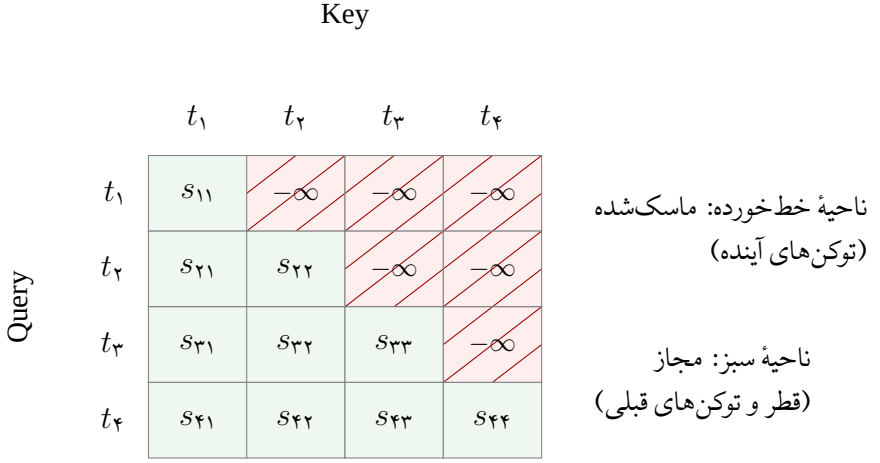
Context Vector

⑤
$$\underset{1\times 5}{\text{logits}} = \underset{1\times 2}{C}\ \underset{2\times 5}{W} + \underset{1\times 5}{b} = \begin{bmatrix} z_1 & z_2 & z_3 & z_4 & z_5 \end{bmatrix} \xrightarrow{\text{softmax}} \underset{1\times 5}{\begin{bmatrix} p_1 & p_2 & p_3 & p_4 & p_5 \end{bmatrix}}$$

شکل ۱۰.۱۴: گام‌های ۴ و ۵: جمع وزن‌دار سطرهای V با ضرایب α_i بردار بافت C (۲ × ۱) را می‌سازد؛ سپس لجیت $CW + b$ (۵ × ۱) و Softmax به احتمال هر توکن می‌رسد. ضرایب نوشته‌شده روی تخته ناخوانا بود و به‌صورت نماد α_i آمده است. (بازسازی‌شده از تختهٔ کلاس)

۶.۱۱.۱۰ ماسک علّی (پایین‌مثلثی)

در سمت راست تخته، $QK^\top$ برای همهٔ موقعیت‌های رمزگشا (ماتریس مربعی با برچسب سطرها و ستون‌ها) و یک ماتریس ماسک نیز کشیده شد: مثلث بالاراست خط‌خورده (ماسک‌شده) است و ناحیهٔ پایین‌چپ باقی می‌ماند؛ طبق روش معمول، قطر اصلی هم باقی می‌ماند (هر توکن به خودش و توکن‌های قبلی نگاه می‌کند).



شکل ۱۰.۱۵: ماتریس امتیازهای $QK^\top$ همهٔ موقعیت‌های رمزگشا و ماسک علّی: مثلث بالاراست (خط‌خورده) پیش از Softmax با $-\infty$ جایگزین می‌شود. روی تخته چهار موقعیت کشیده شده بود و برچسب‌های آن ناخوانا بود. (بازسازی‌شده از تختهٔ کلاس)

دلیل: هنگام تولید توکن موقعیت t رمزگشا نباید توکن‌های آینده را ببیند، چون هنگام تولید واقعی هنوز وجود ندارند. با افزودن $-\infty$ به امتیازهای آینده پیش از Softmax، وزن آن‌ها صفر می‌شود. برای ۳ توکن:

$$\text{mask} = \begin{bmatrix} 0 & -\infty & -\infty \\ 0 & 0 & -\infty \\ 0 & 0 & 0 \end{bmatrix}, \qquad \alpha = \text{softmax}\big(QK^\top/\sqrt{d_k} + \text{mask}\big).$$

یادداشت‌های پایانی روی تخته

جدا از مثال، روی چارچوب TTS دو یادداشت جدید آمده بود: (۱) همان پرسش بحث دربارهٔ نیاز روش بازگشتی به کدگذاری موقعیت (بخش ۳.۱۰) و (۲) «مدل‌های اتورگرسیو (Autoregressive) و Teacher Forcing در زمان آموزش». مورد دوم هنوز در این جلسه تدریس نشد و موضوع بعدی است.

[محتوای افزوده] مدل اتورگرسیو و Teacher Forcing (پیش‌نمایش)

در مدل **اتورگرسیو** (Autoregressive) هر خروجی به خروجی‌های پیشین وابسته است: $P(y_1, \dots, y_T) = \prod_t P(y_t \mid y_{<t}, x)$. هنگام استنتاج مدل خروجی قبلی خودش را به‌عنوان ورودی بعدی می‌دهد. هنگام آموزش با Teacher Forcing به‌جای خروجی پیش‌بینی‌شدهٔ مدل، توکن درست موقعیت قبلی به رمزگشا داده می‌شود. این باعث می‌شود همهٔ موقعیت‌ها هم‌زمان (موازی) با کمک ماسک علّی آموزش ببینند و خطای یک گام روی گام‌های بعد پخش نشود؛ اما شکاف آموزش و استنتاج هم ایجاد می‌کند. جزئیات در ادامهٔ درس خواهد آمد.

۱۲.۱۰ جمع‌بندی

- Self-Attention موازی بدون اطلاعات موقعیت نسبت به ترتیب عنصرها بی‌اطلاع است (هم‌متغیر نسبت به جایگشت)؛ مدل RNN ترتیب را ضمناً از بازگشت می‌گیرد.
- کدگذاری موقعیت پس از Embedding اولیه و پیش از Attention با جمع $X = E + P$ اعمال می‌شود؛ جمع، ابعاد را ثابت نگه می‌دارد.
- ماتریس $P \in \mathbb{R}^{L \times d}$ را می‌توان یاد گرفت (جدول جست‌وجو، بدون فعال‌ساز یا ضرب ماتریسی، فقط سطرهای دیده‌شده گرادیان می‌گیرند) یا با فرمول سینوسی ساخت (بدون پارامتر، برای هر موقعیت قابل محاسبه).
- موقعیت به توالی ورودی (کلمه، نویسه، واج، بایت) مربوط است نه لزوماً «جمله»؛ حداکثر طول توالی یک تصمیم طراحی است.
- در مثال عددی، K و V از رمزگذار، Q از رمزگشا (با $+PE$)، امتیازها $QK^\top$، Softmax، $C = \alpha V$، لجیت $CW + b$ و ماسک علّی به‌ترتیب آمدند.

نکات مهم برای مرور و امتحان

۱. چرا Self-Attention بدون کدگذاری موقعیت دو جملهٔ «ایران آمریکا را شکست داد» و «آمریکا ایران را شکست داد» را با هم اشتباه می‌گیرد؟ چرا RNN این مشکل را ندارد؟

۲. محل کدگذاری موقعیت در معماری، و دلیل آن (پیش از Attention).

۳. مقایسهٔ کانکت و جمع؛ فرمول $X = E + P$ و اندازهٔ $P \in \mathbb{R}^{۱۰۰ \times ۵۱۲}$؛ تفسیر سطر و ستون.

۴. کدگذاری یادگرفتنی: پارامتر قابل‌آموزش، یادگیری با Backprop، بدون فعال‌ساز و ضرب ماتریسی (لایهٔ خطی نیست).

۵. کدگذاری ثابت: ورودی‌های فرمول (pos و j)، کران $[-۱, ۱]$ سینوس و کسینوس.

۶. سؤال امتحانی مهم: دادهٔ آموزشی کوتاه (طول ۳) و ماتریس ۱۰۰ موقعیتی؛ چرا کدگذاری ثابت مناسب‌تر است؟ در پاسخ فرض‌ها را (ظرفیت ۱۰۰، دادهٔ تا طول ۳، بدون تغییر اندازهٔ ماتریس) دقیق بنویسید.

۷. ممکن است سؤال طراحی بیاید: اطلاعات موقعیت را در کجای یک شبکهٔ داده‌شده وارد می‌کنید؟

۸. مثال عددی Attention: ابعاد هر گام ($E, K, V : ۳ \times ۲$، $Q : ۱ \times ۲$، $QK^\top : ۱ \times ۳$، $C : ۱ \times ۲$، لجیت ۵×۱).